

ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

**ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN
DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI
Ở VIỆT NAM**

ĐÀM CÔNG DANH

danh.dc251317M@sis.hust.edu.vn

Chuyên ngành Toán Tin

Giảng viên hướng dẫn: TS. Lê Kim Thư Chữ ký của GVHD

TS. Lê Thị Thanh An

Bộ môn: Toán Tin

Viện: Toán ứng dụng và Tin học

HÀ NỘI - 2026

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

BẢN XÁC NHẬN CHỈNH SỬA LUẬN VĂN THẠC SĨ

Họ và tên tác giả luận văn: Đàm Công Danh.

Đề tài luận văn: Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam.

Chuyên ngành: Toán Tin.

Mã học viên: 20251317M

Tác giả, Người hướng dẫn khoa học và Hội đồng chấm luận văn xác nhận tác giả đã sửa chữa, bổ sung luận văn theo biên bản họp Hội đồng ngày ... với các nội dung sau.

Ngày tháng năm 2026

Giảng viên hướng dẫn

Tác giả luận văn

CHỦ TỊCH HỘI ĐỒNG

ĐỀ TÀI LUẬN VĂN

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

TS. Lê Kim Thư

Lời cảm ơn

Trước hết, em xin trân trọng cảm ơn Khoa Toán Tin đã tạo điều kiện thuận lợi và hỗ trợ em trong quá trình học tập, nghiên cứu tại chương trình thạc sĩ Toán Tin.

Em xin bày tỏ lòng biết ơn sâu sắc tới TS. Lê Kim Thư và TS. Lê Thị Thanh An, những người đã tận tình hướng dẫn, góp ý chuyên môn và chia sẻ kinh nghiệm trong suốt quá trình thực hiện luận văn. Em đồng thời xin chân thành cảm ơn quý thầy, cô và các học viên khóa 2026 của Khoa Toán Tin đã trao đổi, động viên và hỗ trợ em hoàn thành nghiên cứu này.

Mặc dù đã nỗ lực hoàn thiện, luận văn khó tránh khỏi những hạn chế nhất định. Em kính mong nhận được các ý kiến đóng góp của quý thầy, cô và bạn đọc để nghiên cứu được tiếp tục bổ sung và hoàn thiện.

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

LỜI MỞ ĐẦU

Lý do lựa chọn đề tài

Tín dụng là hoạt động cốt lõi của ngân hàng thương mại, đồng thời là nguồn phát sinh rủi ro có ảnh hưởng trực tiếp đến lợi nhuận, chất lượng tài sản và mức độ an toàn của ngân hàng. Vì vậy, đánh giá và xếp hạng tín dụng không chỉ phục vụ quyết định cấp tín dụng mà còn hỗ trợ giám sát khoản vay, phân loại nợ và nhận diện sớm dấu hiệu suy giảm chất lượng tín dụng.

Sự gia tăng về quy mô và mức độ đa dạng của dữ liệu ngân hàng đặt ra yêu cầu đổi mới phương pháp đánh giá rủi ro. Các phương pháp truyền thống có ưu điểm về tính minh bạch, nhưng có thể gặp hạn chế trước quan hệ phi tuyến, tương tác phức tạp và tình trạng mất cân bằng giữa các nhóm nợ. Trí tuệ nhân tạo và học máy vì vậy mở ra khả năng khai thác dữ liệu hiệu quả hơn, đồng thời hỗ trợ chuẩn hóa và tự động hóa một phần quy trình đánh giá.

Trong bối cảnh đó, đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*” được thực hiện nhằm đánh giá khả năng áp dụng các mô hình học máy vào phân loại năm nhóm nợ trên dữ liệu thực tế. Nghiên cứu đồng thời xem xét vai trò của các nhóm thông tin nghiệp vụ và khả năng rút gọn đặc trưng, qua đó tạo cơ sở cho việc phát triển hệ thống cảnh báo sớm rủi ro tín dụng.

Phần thực nghiệm tập trung vào hai nội dung. Thứ nhất, luận văn xây dựng và đánh giá ngoài mẫu các mô hình phân loại năm nhóm nợ trên hai bộ dữ liệu. Thứ hai, trên cơ sở ba kỳ báo cáo liên tiếp của bộ dữ liệu B (tạo thành hai cặp kỳ quan sát độc lập), nghiên cứu xây dựng bài toán dự báo khả năng khoản vay chuyển sang nhóm nợ có mức rủi ro cao hơn trong các tháng tiếp theo. Thiết kế này cho phép bước đầu đánh giá khả năng cảnh báo sớm và kiểm tra độ ổn định của kết quả giữa hai cặp kỳ, đồng thời làm rõ những giới hạn phát sinh từ mức độ mất cân bằng của sự kiện chuyển nhóm.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là việc ứng dụng các phương pháp thống kê và học máy trong phân loại mức độ rủi ro tín dụng. Trọng tâm của luận văn gồm so sánh hiệu năng mô hình, đánh giá ảnh hưởng của mất cân bằng lớp, phân tích vai trò của đặc trưng và đề xuất định hướng dữ liệu cho cảnh báo sớm.

Nghiên cứu sử dụng hai bộ dữ liệu tín dụng đã được ẩn danh từ một ngân hàng thương mại tại Việt Nam. Phạm vi dữ liệu bao gồm thông tin khách hàng, khoản vay và các yếu tố nghiệp vụ liên quan; tên ngân hàng và thông tin định danh trực tiếp không được công bố.

Các mô hình được đánh giá theo quy trình huấn luyện và kiểm định thống nhất trên từng bộ dữ liệu. Kết quả giữa hai bộ chỉ được đối chiếu về xu hướng do khác biệt về quy mô, cấu trúc biến và phân bố nhóm nợ. Các thông số dữ liệu, cấu hình tiền xử lý và thiết kế thực nghiệm được trình bày chi tiết tại Chương 3.

Động lực ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng

Việc ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng được thúc đẩy bởi ba yêu cầu chính: khai thác tốt hơn dữ liệu ngày càng đa dạng; nâng cao tính nhất quán và hiệu quả của quy trình đánh giá; và hỗ trợ nhận diện sớm các khoản vay có dấu hiệu suy giảm. Trong lĩnh vực ngân hàng, hiệu quả dự báo cần đi cùng khả năng giải thích, kiểm soát và giám sát để mô hình có thể được sử dụng như một công cụ hỗ trợ quyết định.

TÓM TẮT NỘI DUNG LUẬN VĂN

Luận văn nghiên cứu ứng dụng học máy trong phân loại năm nhóm nợ trên hai bộ dữ liệu của một ngân hàng thương mại tại Việt Nam, đồng thời khảo sát khả năng dự báo chuyển sang nhóm nợ cao hơn trong các tháng tiếp theo trên bộ dữ liệu có ba kỳ quan sát (hai cặp kỳ độc lập). Quy trình thực nghiệm gồm tiền xử lý, xây dựng đặc trưng, hạn chế rò rỉ thông tin, xử lý mất cân bằng, đối sánh mô hình và giải thích bằng mức độ quan trọng của đặc trưng cùng SHAP. Macro-F1 là chỉ tiêu chính của bài toán năm lớp; average precision (ký hiệu PR-AUC trong các bảng) được dùng cho bài toán chuyển nhóm.

LightGBM đạt Macro-F1 cao nhất trong các bảng so sánh chính trên tập kiểm định, bằng 0,6484 ở bộ A và 0,6930 ở bộ B. Trên kỳ dữ liệu tiếp theo của bộ B, Random Forest đạt Macro-F1 cao nhất, bằng 0,5065; Macro-F1 của các mô hình giảm tương đối từ 12,7–32,1%. Các thí nghiệm rút gọn đặc trưng cho thấy việc bổ sung biến không luôn cải thiện kết quả. Phân tích SHAP đối chiếu giữa hai bộ dữ liệu độc lập cho kết quả nhất quán về nhóm thông tin quan trọng nhất (Top-2 trùng khớp 100%, tương quan hạng Spearman 0,80). Với bài toán chuyển nhóm, kiểm định trên hai cặp kỳ báo cáo thật cho kết quả trái ngược: trên cặp 1 (30/04/2026–31/05/2026), XGBoost đạt average precision trung bình 0,1806 qua kiểm định chéo 5 phần, lặp 10 lần; nhưng trên cặp 2 độc lập (31/05/2026–30/06/2026), cùng cấu hình chỉ đạt 0,0053 và không mô hình nào vượt ROC-AUC 0,5521 — xấp xỉ mức ngẫu nhiên. Kiểm định chuyển giao ngoài thời gian xác nhận kết luận này. Khả năng dự báo chuyển nhóm nợ vì vậy chưa được chứng minh là ổn định theo thời gian, dù đã có bằng chứng khai thác được tín hiệu ở một giai đoạn quan sát cụ thể.

Ngoài phần mở đầu và tài liệu tham khảo, nội dung luận văn được kết cấu thành năm chương như sau:

- **Chương 1: Giới thiệu tổng quan về đề tài.** Trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi, phương pháp và phạm vi nghiên cứu.
- **Chương 2: Cơ sở lý thuyết và các nghiên cứu liên quan.** Hệ thống hóa những khái niệm nền tảng về tín dụng, rủi ro tín dụng và xếp hạng tín dụng; giới thiệu các phương pháp học máy được sử dụng; đồng thời tổng quan các công trình có liên quan để xác định khoảng trống nghiên cứu.
- **Chương 3: Dữ liệu và phương pháp nghiên cứu.** Mô tả hai bộ dữ liệu, quy trình tiền xử lý và xây dựng đặc trưng, phương pháp xử lý mất cân bằng lớp, thiết kế thực nghiệm và hệ thống chỉ tiêu đánh giá; đồng thời trình bày phương pháp cho bài toán bổ sung dự báo chuyển nhóm nợ trong các tháng tiếp theo trên bộ B, áp dụng cho hai cặp kỳ báo cáo độc lập, bao gồm cách ghép kỳ báo cáo, kiểm soát nguy cơ rò rỉ thông tin và thiết kế đánh giá cho sự kiện hiếm.
- **Chương 4: Kết quả thực nghiệm và thảo luận.** Trình bày kết quả trên từng bộ dữ liệu và thảo luận theo ba câu hỏi nghiên cứu về xử lý mất cân bằng, vai trò của số lượng đặc trưng và các nhóm thông tin quan trọng (đôi chiều SHAP giữa hai bộ dữ liệu), và khả năng dự báo chuyển nhóm nợ; báo cáo kết quả đối sánh mô hình cho bài toán chuyển nhóm nợ trên hai cặp kỳ quan sát kèm kiểm tra độ ổn định, Recall@k và giải thích SHAP.
- **Chương 5: Kết luận và kiến nghị.** Tổng hợp các kết quả chủ yếu, làm rõ đóng góp và hạn chế của nghiên cứu, đề xuất một số kiến nghị đối với ngân

hàng và định hướng nghiên cứu tiếp theo.

Học viên thực hiện

Đàm Công Danh

Mục lục

Lời mở đầu	4
Một số thuật ngữ viết tắt	13
Danh mục hình vẽ	15
Danh mục bảng	18
1 GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI	19
1.1 Bối cảnh và động lực nghiên cứu	19
1.2 Sự phát triển của các phương pháp đánh giá tín dụng	21
1.3 Phát biểu bài toán và phạm vi nghiên cứu	24
1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu	26
1.5 Tóm tắt chương	29
2 CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN	30
2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ	30
2.2 Từ đánh giá truyền thống đến các mô hình học máy	32
2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng	35
2.4 Hệ thống chỉ tiêu đánh giá mô hình	39

2.5	Nghiên cứu liên quan, khoảng trống và định hướng	40
2.6	Tóm tắt chương	42
3	DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	43
3.1	Định hướng và phạm vi thực nghiệm	43
3.2	Quy trình nghiên cứu tổng thể	44
3.3	Công nghệ và môi trường triển khai	46
3.4	Bước 1: Thu thập dữ liệu	47
3.5	Bước 2: EDA & làm sạch dữ liệu	48
3.6	Bước 3: Tiền xử lý & chọn biến	52
3.7	Bước 4: Chia dữ liệu & cân bằng lớp	74
3.8	Bước 5: Huấn luyện mô hình	76
3.9	Bài toán bổ sung: dự báo chuyển nhóm nợ trong các tháng tiếp theo (bộ B)	80
3.10	Tóm tắt chương	86
4	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	88
4.1	Nguyên tắc báo cáo kết quả	88
4.2	Thước đo đánh giá	89
4.3	Kết quả trên bộ dữ liệu A	91
4.4	Kết quả trên bộ dữ liệu B	94
4.5	So sánh chiến lược mất cân bằng: kết hợp SMOTE và trọng số lớp	108
4.6	Độ nhạy của siêu tham số	110
4.7	Đối chiếu ba câu hỏi nghiên cứu	113
4.8	Kết quả bài toán dự báo chuyển nhóm nợ (bộ B)	115

4.9	Ý nghĩa đối với mô hình chuyển nhóm nợ	124
4.10	Tóm tắt chương	125
5	KẾT LUẬN VÀ KIẾN NGHỊ	126
5.1	Kết luận chung	126
5.2	Trả lời các câu hỏi nghiên cứu	127
5.3	Đóng góp của nghiên cứu	129
5.4	Hạn chế của nghiên cứu	131
5.5	Kiến nghị đối với ngân hàng	135
5.6	Hướng nghiên cứu tiếp theo	137
5.7	Kết luận chương	138
	Tài liệu tham khảo	139

Một số thuật ngữ viết tắt

Viết tắt	Thuật ngữ tiếng Anh	Diễn giải tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ML	Machine Learning	Học máy
NHTM	Commercial Bank	Ngân hàng thương mại
NHNN	State Bank of Vietnam	Ngân hàng Nhà nước Việt Nam
XHTD	Credit Rating	Xếp hạng tín dụng
PD	Probability of Default	Xác suất khách hàng không thực hiện nghĩa vụ trả nợ
LGD	Loss Given Default	Tỷ lệ tổn thất khi xảy ra vỡ nợ
EAD	Exposure at Default	Giá trị dư nợ tại thời điểm vỡ nợ
IV	Information Value	Giá trị thông tin, dùng đánh giá sức phân biệt của đặc trưng
SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật sinh mẫu tổng hợp cho lớp thiểu số
SHAP	SHapley Additive exPlanations	Phương pháp giải thích đóng góp của đặc trưng dựa trên giá trị Shapley
ROC	Receiver Operating Characteristic	Đường cong biểu diễn quan hệ giữa tỷ lệ dương tính thật và dương tính giả
AUC	Area Under the Curve	Diện tích dưới đường cong đánh giá khả năng phân biệt
AP / PR-AUC	Average Precision / Precision-Recall Area Under the Curve	Luận văn tính average precision (AP); ký hiệu PR-AUC trong các bảng
F1	F1-score	Trung bình điều hòa của Precision và Recall
CV	Cross-validation	Kiểm định chéo
API	Application Programming Interface	Giao diện lập trình ứng dụng
RF	Random Forest	Thuật toán rừng ngẫu nhiên
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường gradient tối ưu
<i>LightGBM</i>	Light Gradient Boosting Machine	Thuật toán tăng cường gradient dạng cây tối ưu cho hiệu năng

Danh mục hình vẽ

2.1	Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng	32
2.2	Cơ chế cộng dồn các cây trong XGBoost	34
2.3	Minh họa hai chiến lược phát triển cây quyết định	35
2.4	Ví dụ biểu đồ waterfall minh họa nguyên lý phân rã dự báo theo giá trị SHAP	37
2.5	Ví dụ biểu đồ SHAP beeswarm trong phân tích mức độ tác động của đặc trưng	38
3.1	Pipeline nghiên cứu tổng thể — từ thu thập dữ liệu tới kết luận và ứng dụng	45
3.2	Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001) . . .	57
3.3	Ma trận tương quan Pearson giữa các biến số của bộ dữ liệu A	59
3.4	Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A	59
3.5	Top 15 biến (trong bề đặc trưng hợp lệ) có tỷ lệ thiếu cao nhất — bộ dữ liệu B	61
3.6	Ma trận tương quan giữa 12 biến số (8 biến gốc + 4 biến kỹ thuật) — bộ dữ liệu B	62
3.7	Các tầng số lượng biến trong nghiên cứu	68
4.1	Ma trận nhầm lẫn — XGBoost (none), tập kiểm định minh họa	118

4.2	Đường cong Precision-Recall — XGBoost (none)	119
4.3	Recall@k — XGBoost (none)	120
4.4	Phân tán PR-AUC qua 5 phần, lặp 10 lần kiểm định chéo — chiến lược none	121

Danh mục bảng

2.1	Các nhóm nợ trong nghiên cứu	31
3.1	Các công nghệ chính được sử dụng trong nghiên cứu	46
3.2	Phân bố năm nhóm nợ trong bộ dữ liệu A	47
3.3	Phân bố năm nhóm nợ trong dữ liệu (kỳ 20260430)	48
3.4	Số bản ghi có trường ngày lưu sai định dạng (số thứ tự Excel) — bộ dữ liệu A	49
3.5	Thống kê mô tả và số ngoại lệ theo IQR — các biến gốc của bộ dữ liệu A	50
3.6	Các biến số gốc có tỷ lệ thiếu khác 0 — bộ dữ liệu B	51
3.7	Thống kê mô tả, tỷ lệ thiếu và ngoại lệ IQR của các biến số gốc — bộ dữ liệu B	51
3.8	Các biến được xây dựng thêm từ dữ liệu ban đầu	54
3.9	Thống kê mô tả và số ngoại lệ theo IQR — ba biến kỹ thuật của bộ dữ liệu A	56
3.10	Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A	58
3.11	Thống kê mô tả bốn biến kỹ thuật của bộ dữ liệu B	61
3.12	Information Value của 13 biến — bộ dữ liệu A	63
3.13	Phân bố 20 đặc trưng của bộ dữ liệu B theo mức Information Value	65

3.14	Information Value của 20 đặc trưng — bộ dữ liệu B	65
3.15	Ví dụ ba hồ sơ thực tế của bộ A trước và sau xử lý	71
3.16	Ví dụ ba hồ sơ thực tế của bộ B có giá trị thiếu, trước và sau xử lý	72
3.17	Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu A	78
3.18	Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu B	79
3.19	Ma trận chuyển nhóm nợ từ kỳ 20260430 (T) sang kỳ 20260531 ($T + h$)	81
3.20	Phân bổ nhóm nợ tại T của khoản vay bị loại so với khoản vay được giữ lại	83
4.1	Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng	91
4.2	Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A	92
4.3	Tỷ trọng mức độ quan trọng theo nhóm nghiệp vụ của bộ dữ liệu A	93
4.4	Kết quả ngoài mẫu của các mô hình trên 20 đặc trưng — tập kiểm định (20% kỳ 20260430)	94
4.5	Kết quả trên tập kiểm tra ở kỳ sau 20260531 (không tham gia huấn luyện/chọn mô hình)	96
4.6	Precision, Recall và F1 của LightGBM theo nhóm nợ — tập kiểm định vs. tập kiểm tra ở kỳ sau	97
4.7	Recall nhóm 3 và nhóm 4 theo mô hình — tập kiểm định	98
4.8	Hiệu năng LightGBM theo số lượng đặc trưng Top- k	99
4.9	Tỷ trọng mức độ quan trọng của LightGBM theo nhóm nghiệp vụ (Gain)	101

4.10	Ba nhóm nghiệp vụ có chỉ số ưu tiên cao nhất — bộ dữ liệu B	103
4.11	Importance theo SHAP (trung bình $ \phi_j $) — bộ dữ liệu A . . .	104
4.12	Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu A	104
4.13	Importance theo SHAP (trung bình $ \phi_j $) — bộ dữ liệu B . . .	105
4.14	Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu B	106
4.15	Ánh xạ nhóm nghiệp vụ và đối chiếu tỷ trọng SHAP giữa bộ A và bộ B	107
4.16	So sánh bốn chiến lược mất cân bằng — XGBoost, bộ A . . .	109
4.17	So sánh bốn chiến lược mất cân bằng — LightGBM, bộ B . .	109
4.18	So sánh Macro-F1 giữa cấu hình mặc định và cấu hình tốt nhất trong lưới khảo sát	111
4.19	Độ nhạy Macro-F1 theo mô hình (trên toàn bộ lưới đã thử) . .	112
4.20	So sánh 6 mô hình trên bài toán dự báo chuyển nhóm nợ (chiến lược tốt nhất theo PR-AUC, 5 phần, lặp 10 lần)	116
4.21	Bốn chiến lược mất cân bằng đối với XGBoost	117
4.22	Recall@k — XGBoost (none), tập kiểm định minh họa (19.794 hồ sơ, 53 sự kiện)	119
4.23	Importance theo SHAP (trung bình $ \phi_j $, lớp “xấu đi”) — mô hình dự báo chuyển nhóm nợ	121
4.24	Đối chiếu PR-AUC/ROC-AUC giữa cặp 1 và cặp 2 với cùng cấu hình mô hình (kiểm định chéo 5×10)	123

Chương 1

GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI

Chương này xác lập bối cảnh, khoảng trống nghiên cứu, mục tiêu và ba câu hỏi nghiên cứu của luận văn. Phạm vi thực nghiệm gồm phân loại năm nhóm nợ và dự báo chuyển sang nhóm nợ cao hơn trong các tháng tiếp theo trên dữ liệu của một ngân hàng thương mại tại Việt Nam.

1.1 Bối cảnh và động lực nghiên cứu

1.1.1 Hoạt động tín dụng và rủi ro tín dụng

Hoạt động tín dụng có vai trò đặc biệt quan trọng đối với ngân hàng thương mại. Thông qua hoạt động cấp tín dụng, ngân hàng cung ứng vốn cho cá nhân và tổ chức, đồng thời tạo ra nguồn thu từ lãi và phí. Tuy nhiên, do nghĩa vụ trả nợ được thực hiện trong tương lai, ngân hàng luôn phải đối mặt với sự không chắc chắn liên quan đến khả năng trả nợ của khách hàng.

Rủi ro tín dụng phát sinh khi khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính theo cam kết. Rủi ro này có thể bắt nguồn từ năng lực tài chính suy giảm, dòng tiền không ổn định, quản trị doanh nghiệp yếu, biến động thu nhập, thay đổi môi trường kinh doanh, biến động lãi suất, thông tin không

đầy đủ hoặc hành vi gian lận. Hậu quả của rủi ro tín dụng có thể thể hiện qua nợ quá hạn, nợ xấu, chi phí dự phòng tăng, lợi nhuận giảm và mức độ an toàn vốn suy giảm.

Trong quản trị hiện đại, đánh giá tín dụng không nên chỉ được thực hiện một lần tại thời điểm phê duyệt. Ngân hàng cần cập nhật thông tin trong toàn bộ vòng đời khoản vay, theo dõi sự thay đổi của dư nợ, hành vi thanh toán, thời hạn, tình trạng cơ cấu lại và nhóm nợ. Điều này tạo ra nhu cầu xây dựng các mô hình có khả năng học từ dữ liệu lịch sử và hỗ trợ dự báo rủi ro theo thời gian.

1.1.2 Chuyển đổi số trong ngân hàng và vai trò của dữ liệu

Chuyển đổi số trong ngân hàng không chỉ là số hóa kênh giao dịch mà còn bao gồm tái cấu trúc quy trình nghiệp vụ, tự động hóa vận hành, xây dựng nền tảng dữ liệu và ứng dụng các mô hình phân tích trong quản trị.

Trong tín dụng, ngân hàng có thể khai thác nhiều nhóm dữ liệu như thông tin định danh, lịch sử hợp đồng, dư nợ, hạn mức, số ngày quá hạn, thời hạn khoản vay, mục đích vay, nhóm nợ, trạng thái cơ cấu lại và dữ liệu hành vi. Khi dữ liệu được làm sạch và quản trị phù hợp, các mô hình học máy có thể hỗ trợ nhận diện quy luật mà quy tắc thủ công khó phát hiện. Tuy nhiên, dữ liệu ngân hàng cũng có những thách thức như giá trị thiếu, sai lệch nghiệp vụ, mất cân bằng lớp, thay đổi theo thời gian và nguy cơ rò rỉ thông tin.

1.1.3 Giới hạn của thông tin CIC và yêu cầu về công cụ cảnh báo sớm nội bộ

Thông tin nhóm nợ tại thời điểm báo cáo mô tả trạng thái đã được ghi nhận của khách hàng hoặc khoản vay. Việc dùng các trường trực tiếp hình thành nhóm nợ, chẳng hạn số ngày quá hạn, để phân loại lại chính trạng thái đó có thể tạo ra kết quả cao nhưng chưa chứng minh được khả năng dự báo diễn biến tiếp theo. Trong luận văn, bài toán phân loại hiện tại được dùng để đối sánh mô hình; bài toán chuyển nhóm được xây dựng riêng để khảo sát tín hiệu cảnh báo sớm.

Việc tổ chức tín dụng sử dụng thông tin CIC và hệ thống xếp hạng tín dụng nội bộ cần được đặt trong khuôn khổ quy định về phân loại tài sản có. Thông tư số 31/2024/TT-NHNN, có hiệu lực từ ngày 01/07/2024 và thay thế Thông tư số 11/2021/TT-NHNN, đã được sửa đổi, bổ sung bởi Thông tư số 37/2025/TT-NHNN [21, 22]. Luận văn sử dụng các văn bản này làm căn cứ về bối cảnh phân loại nợ; kết quả của mô hình nghiên cứu chưa phải căn cứ để thay thế quy trình phân loại nợ theo quy định.

Công cụ cảnh báo sớm nội bộ có thể hỗ trợ lựa chọn hồ sơ cần rà soát dựa trên thông tin sẵn có tại thời điểm đánh giá. Nghiên cứu hiện tại chưa đo lường độ trễ cập nhật, chi phí tra cứu hoặc hiệu quả của quy trình sử dụng CIC, nên không thực hiện đối sánh hiệu quả với CIC. Mục 1.3.1 cụ thể hóa bài toán dự báo chuyển nhóm trong phạm vi dữ liệu cho phép.

1.2 Sự phát triển của các phương pháp đánh giá tín dụng

Đánh giá tín dụng đã trải qua ba giai đoạn phát triển chính. Giai đoạn đầu dựa trên phương pháp chuyên gia, tiêu biểu là khung 5C (*Character, Capacity,*

Capital, Collateral, Conditions) — công cụ tổ chức thông tin để cán bộ tín dụng tổng hợp nhận định, không phải thuật toán tự động tạo xác suất vỡ nợ [14, 27]. Giai đoạn thứ hai chuyển sang các mô hình thống kê định lượng, mở đầu bằng phân tích phân biệt đa biến của Altman [1] và hồi quy logistic của Ohlson [23], cho phép ước lượng xác suất rủi ro thay vì chỉ xếp loại theo kinh nghiệm, nhưng vẫn giả định quan hệ tuyến tính giữa biến đầu vào và rủi ro. Giai đoạn thứ ba là sự chuyển dịch sang các mô hình học máy, có khả năng nắm bắt quan hệ phi tuyến phức tạp hơn mà không cần thiết kế tương tác thủ công.

Các nghiên cứu tổng quan của Hand và Henley [14], Thomas [27], Crook [10] và các nghiên cứu đối chiếu mô hình của Baesens và cộng sự [2], Lessmann và cộng sự [17] hệ thống hóa quá trình chuyển dịch này. Điểm chung được các tác giả nhấn mạnh là không tồn tại một thuật toán luôn vượt trội trên mọi bộ dữ liệu; hiệu quả phụ thuộc vào chất lượng dữ liệu, cách chia mẫu và tiêu chí đánh giá được sử dụng. Cơ sở lý thuyết chi tiết của các mô hình học máy được luận văn sử dụng, cùng tổng quan đầy đủ hơn về các nghiên cứu liên quan, được trình bày ở Chương 2 (Mục 2.2 và Mục 2.5); phần này chỉ tóm lược bối cảnh phát triển làm cơ sở xác định khoảng trống nghiên cứu dưới đây.

1.2.1 Khoảng trống nghiên cứu và định vị đề tài

Từ bối cảnh phát triển trên, có thể xác định các khoảng trống liên quan trực tiếp đến nghiên cứu của luận văn:

1. Phần lớn nghiên cứu ứng dụng học máy trong tín dụng tập trung vào mục tiêu nhị phân (tốt/xấu) hoặc dự báo phá sản doanh nghiệp; bài toán phân loại nhiều nhóm nợ có thứ tự (5 nhóm theo quy định phân loại nợ tại Việt

Nam) ít được khảo sát trực tiếp trên dữ liệu ngân hàng thực tế.

2. Thông tin nhóm nợ từ CIC mang tính hồi cứu (Mục 1.1.3); giá trị bổ sung của một công cụ cảnh báo sớm nội bộ — dự báo diễn biến trước khi nhóm nợ CIC được cập nhật — chưa được kiểm chứng bằng thực nghiệm cụ thể trên dữ liệu ngân hàng Việt Nam.
3. Dữ liệu tín dụng thực tế tại ngân hàng thương mại Việt Nam ít được công bố hoặc sử dụng trong nghiên cứu học thuật, khiến kết luận từ các bộ dữ liệu công khai (thường nhỏ, thời gian thu thập đã cũ) khó áp dụng trực tiếp cho bối cảnh trong nước.
4. Yêu cầu về hệ thống xếp hạng tín dụng nội bộ, bao gồm phương pháp định tính, đã được quy định tại Thông tư số 31/2024/TT-NHNN (thay thế Thông tư số 11/2021/TT-NHNN) [21, 22], nhưng bằng chứng thực nghiệm về khả năng dự báo chuyển nhóm nợ trong ngắn hạn bằng học máy trên dữ liệu ngân hàng Việt Nam còn hạn chế.

Luận văn định vị đóng góp vào các khoảng trống (1), (2) và (4): xây dựng và đối sánh mô hình phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của cùng một ngân hàng thương mại, đồng thời xây dựng và đánh giá trung thực một bài toán dự báo chuyển nhóm nợ trong ngắn hạn nhằm trả lời trực tiếp yêu cầu về công cụ cảnh báo sớm. Khoảng trống (3) được đáp ứng một phần qua việc sử dụng dữ liệu ngân hàng thực tế trong toàn bộ thực nghiệm. Khoảng trống theo từng dòng nghiên cứu cụ thể (mô hình, thước đo đánh giá, khả năng giải thích) được phân tích sâu hơn ở Chương 2 sau khi đã trình bày đầy đủ cơ sở lý thuyết.

1.3 Phát biểu bài toán và phạm vi nghiên cứu

Cho tập dữ liệu:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i, t_i)\}_{i=1}^N,$$

trong đó N là số quan sát; $\mathbf{x}_i \in \mathbb{R}^p$ là véc-tơ gồm p đặc trưng của quan sát i ; $y_i \in \{1, 2, 3, 4, 5\}$ là nhóm nợ; và t_i là thời điểm ghi nhận nếu trường thời gian khả dụng.

Mục tiêu là xây dựng:

$$f_{\theta} : \mathbf{x}_i \longrightarrow (p_{i1}, p_{i2}, p_{i3}, p_{i4}, p_{i5}),$$

trong đó f_{θ} là bộ phân loại được xác định bởi tập tham số θ ; p_{ik} là xác suất do mô hình gán quan sát i vào nhóm k . với:

$$p_{ik} = P(Y_i = k \mid \mathbf{x}_i), \quad \sum_{k=1}^5 p_{ik} = 1.$$

Nhãn dự báo:

$$\hat{y}_i = \arg \max_{k \in \{1, 2, 3, 4, 5\}} p_{ik}.$$

Ký hiệu $\hat{y}_i$ là nhãn dự báo; toán tử $\arg \max$ chọn chỉ số nhóm có xác suất lớn nhất.

Do năm nhóm có quan hệ về mức độ rủi ro:

$$1 < 2 < 3 < 4 < 5,$$

bài toán cần vừa đạt hiệu quả tổng thể, vừa nhận diện nhóm rủi ro cao, giảm khoảng cách sai lệch, hạn chế đánh giá thấp rủi ro, duy trì khả năng tổng quát hóa theo thời gian và bảo đảm khả năng giải thích.

1.3.1 Bài toán bổ sung: dự báo chuyển nhóm nợ trong ngắn hạn

Bên cạnh bài toán phân loại nhóm nợ tại một thời điểm nêu trên, luận văn xác lập một bài toán bổ sung nhằm trực tiếp trả lời yêu cầu về công cụ cảnh báo sớm đã nêu ở Mục 1.1.3: dự báo khả năng một khoản vay chuyển sang nhóm rủi ro cao hơn trong một khoảng thời gian ngắn, sử dụng duy nhất thông tin sẵn có tại thời điểm đánh giá.

Gọi $G_{i,T} \in \{1, \dots, 5\}$ là nhóm nợ của khoản vay i tại thời điểm T và $G_{i,T+h}$ là nhóm nợ của cùng khoản vay sau khoảng dự báo h . Nhân dự báo được xác định:

$$Y_i = \mathbb{I}(G_{i,T+h} > G_{i,T}),$$

trong đó $\mathbb{I}(\cdot)$ nhận giá trị 1 khi khoản vay chuyển sang nhóm cao hơn và 0 khi giữ nguyên hoặc cải thiện. Tập đầu vào $\mathbf{x}_{i,T}$ được xây dựng từ bản ghi kỳ T ; nhóm nợ kỳ sau chỉ được dùng để tạo nhãn.

Bài toán bổ sung này chỉ áp dụng được cho bộ dữ liệu B, do đây là bộ duy nhất có nhiều kỳ báo cáo liên tiếp của cùng một danh mục khoản vay. Ngân hàng đã cung cấp ba kỳ báo cáo (20260430, 20260531 và 20260630), cho phép ghép thành hai cặp kỳ độc lập — cặp 1: 20260430→20260531 ($h = 31$ ngày); cặp 2: 20260531→20260630 ($h = 30$ ngày) — theo từng khoản vay bằng khóa định danh khế ước, qua đó kiểm tra được độ ổn định của kết quả dự báo giữa hai cặp kỳ thay vì chỉ dựa trên một cặp duy nhất. Bộ dữ liệu A chỉ phản ánh trạng thái tại một mốc thời gian duy nhất nên tiếp tục được sử dụng cho bài toán phân loại tại một thời điểm như đã trình bày, không hỗ trợ bài toán chuyển nhóm.

1.3.2 Đóng góp của nghiên cứu

Đóng góp của luận văn thể hiện ở thiết kế bài toán và tổ chức thực nghiệm trên dữ liệu tín dụng thực tế, bám sát ba câu hỏi nghiên cứu ở Mục 1.4.2:

1. đối sánh mô hình phân loại năm nhóm nợ trên hai cấu trúc dữ liệu của cùng một ngân hàng, kết hợp đối chiếu bốn chiến lược xử lý mất cân bằng lớp (không xử lý, trọng số lớp, SMOTE, kết hợp), với năm mô hình trong bảng kết quả chính của bộ A và sáu mô hình của bộ B;
2. đánh giá vai trò của số lượng đặc trưng và các nhóm thông tin nghiệp vụ đối với hiệu quả phân loại; đối chiếu mức độ quan trọng bằng SHAP trên cả hai bộ dữ liệu độc lập để kiểm tra tính nhất quán của kết luận;
3. xây dựng và đánh giá trung thực bài toán dự báo chuyển nhóm nợ trong ngắn hạn trên hai cặp kỳ báo cáo thật liên tiếp của bộ B, bao gồm cả kiểm tra độ ổn định của kết quả giữa hai cặp kỳ độc lập, thay vì chỉ báo cáo kết quả của một cặp kỳ duy nhất.

Luận văn không đề xuất thuật toán mới. Tính thứ tự của năm nhóm nợ được thảo luận về mặt lý thuyết; việc đánh giá sai số theo thứ tự chưa được thực hiện trong các bảng kết quả chính và được xác định là hướng bổ sung.

1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu

1.4.1 Mục tiêu nghiên cứu

Mục tiêu tổng quát.

Xây dựng và đánh giá các mô hình học máy nhằm hỗ trợ phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam, đồng

thời xác định cấu hình đặc trưng có giá trị cho định hướng cảnh báo sớm.

Mục tiêu cụ thể.

1. Hệ thống hóa lý thuyết và nghiên cứu liên quan.
2. Làm sạch và xây dựng đặc trưng từ dữ liệu thực tế.
3. Xây dựng Logistic Regression làm mô hình cơ sở, so sánh với Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost.
4. Đánh giá ảnh hưởng của các chiến lược xử lý mất cân bằng lớp đến hiệu năng từng mô hình.
5. Phân tích hiệu năng theo từng nhóm nợ và thảo luận giới hạn của cách đánh giá chưa xét thứ tự.
6. Xác định các nhóm thông tin nghiệp vụ có đóng góp quan trọng bằng phân tích số lượng đặc trưng và SHAP, đối chiếu giữa hai bộ dữ liệu.
7. Xây dựng và đánh giá bài toán dự báo chuyển nhóm nợ trong ngắn hạn trên bộ dữ liệu B (Mục 1.3.1), kiểm tra độ ổn định của kết quả trên nhiều cặp kỳ báo cáo thật.

1.4.2 Câu hỏi nghiên cứu

1. Các chiến lược xử lý mất cân bằng lớp khác nhau ảnh hưởng như thế nào đến hiệu năng của các mô hình phân loại nhóm nợ, và mô hình nào phù hợp nhất trên từng bộ dữ liệu?
2. Việc có nhiều đặc trưng/dữ liệu hơn có luôn cải thiện hiệu quả phân loại nhóm nợ hay không, và những nhóm thông tin nghiệp vụ nào có đóng góp quan trọng nhất mà ngân hàng nên ưu tiên hoàn thiện, duy trì chất lượng?

3. Mô hình học máy có thể dự báo khả năng một khoản vay chuyển sang nhóm nợ cao hơn trong ngắn hạn hay không, chỉ dựa trên thông tin sẵn có tại thời điểm đánh giá, và khả năng dự báo này có ổn định giữa các kỳ quan sát khác nhau hay không?

1.4.3 Phương pháp nghiên cứu

Luận văn kết hợp phương pháp nghiên cứu định tính trong tổng quan tài liệu với phương pháp định lượng trong xử lý dữ liệu, xây dựng mô hình và đánh giá thực nghiệm. Quy trình thực nghiệm được triển khai độc lập trên Data_credit_rating_VN.xlsx (bộ A) và dữ liệu Thông tin tín dụng (bộ B), bao gồm làm sạch dữ liệu, xây dựng đặc trưng, phân tích khám phá dữ liệu, chia mẫu ngẫu nhiên có phân tầng, xử lý mất cân bằng lớp, huấn luyện, đánh giá và giải thích mô hình. Riêng bộ B được đánh giá bổ sung trên một tập kiểm tra ở kỳ sau theo thời gian thuộc kỳ báo cáo kế tiếp. Do khác biệt về cấu trúc và phân bố dữ liệu, kết quả của hai bộ chỉ được đối chiếu về xu hướng, không được so sánh trực tiếp như các mẫu đồng nhất.

Riêng đối với bộ B, ngân hàng đã cung cấp ba kỳ báo cáo liên tiếp của cùng một danh mục khoản vay (20260430, 20260531 và 20260630), cho phép ghép thành hai cặp kỳ độc lập theo khóa định danh khế ước để xây dựng bài toán bổ sung dự báo chuyển nhóm nợ trong ngắn hạn (Mục 1.3.1). Việc có hai cặp kỳ, thay vì chỉ một, cho phép kiểm tra độ ổn định của kết quả dự báo theo thời gian — một yêu cầu quan trọng khi đánh giá công cụ cảnh báo sớm. Quy trình xây dựng nhãn và tập đặc trưng cho bài toán này tách biệt hoàn toàn với quy trình phân loại tại một thời điểm, được trình bày chi tiết ở Chương 3.

Về khoa học, luận văn bổ sung bằng chứng thực nghiệm về phân loại năm nhóm nợ, kết hợp mất cân bằng và khả năng giải thích. Về thực tiễn, kết quả có thể hỗ trợ chuẩn hóa đánh giá, nhận diện khoản vay suy giảm và xây dựng cảnh báo sớm. Mô hình chỉ đóng vai trò hỗ trợ, không thay thế hoàn toàn quyết định của cán bộ tín dụng.

1.5 Tóm tắt chương

Chương 1 đã trình bày bối cảnh và động lực nghiên cứu xuất phát từ vai trò của hoạt động tín dụng và rủi ro tín dụng trong ngân hàng thương mại; đồng thời phân tích giới hạn hồi cứu của thông tin CIC và căn cứ pháp lý cho yêu cầu về công cụ cảnh báo sớm nội bộ (Mục 1.1.3). Chương cũng tóm lược sự phát triển của các phương pháp đánh giá tín dụng và xác định bốn khoảng trống nghiên cứu làm cơ sở định vị đề tài (Mục 1.2.1); xác lập bài toán phân loại năm nhóm nợ và bài toán bổ sung dự báo chuyển nhóm nợ trong ngắn hạn trên bộ dữ liệu B (Mục 1.3.1), cùng mục tiêu, ba câu hỏi nghiên cứu và phương pháp nghiên cứu. Các đóng góp và giới hạn của phạm vi thực nghiệm cũng được xác định nhằm bảo đảm rằng những kết luận của luận văn phù hợp với bằng chứng thu được.

Trên cơ sở đó, Chương 2 sẽ hệ thống hóa cơ sở lý thuyết về tín dụng, rủi ro và phân loại nhóm nợ, trình bày các mô hình học máy được sử dụng, những thách thức đặc thù của dữ liệu tín dụng, hệ thống chỉ tiêu đánh giá và tổng quan các nghiên cứu liên quan, làm nền tảng lý thuyết cho phần dữ liệu và phương pháp thực nghiệm ở Chương 3.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

Chương này trình bày nền tảng về phân loại nợ, các mô hình học máy, thước đo đánh giá và phương pháp giải thích mô hình. Phần tổng quan nghiên cứu xác định cơ sở lựa chọn phương pháp và giới hạn cần lưu ý khi áp dụng vào dữ liệu của luận văn.

2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ

2.1.1 Khái niệm tín dụng và rủi ro tín dụng

Tín dụng là quan hệ kinh tế trong đó bên cho vay chuyển giao quyền sử dụng một lượng giá trị cho bên đi vay trong một khoảng thời gian xác định, với nghĩa vụ hoàn trả theo các điều kiện đã thỏa thuận.

Rủi ro tín dụng là khả năng phát sinh tổn thất do khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính. Rủi ro chịu ảnh hưởng từ năng lực tài chính, đặc điểm khoản vay, lịch sử tín dụng, chính sách cấp tín dụng và điều kiện kinh tế.

2.1.2 Phân loại nhóm nợ

Bảng 2.1: Các nhóm nợ trong nghiên cứu

1	Nợ đủ tiêu chuẩn	Mức rủi ro thấp.
2	Nợ cần chú ý	Đã xuất hiện dấu hiệu cần theo dõi.
3	Nợ dưới tiêu chuẩn	Khả năng thu hồi suy giảm đáng kể.
4	Nợ nghi ngờ	Mức rủi ro cao.
5	Nợ có khả năng mất vốn	Mức rủi ro cao nhất.


2.1.3 Xếp hạng tín dụng và tổn thất kỳ vọng

Xếp hạng tín dụng là quá trình gán khách hàng hoặc khoản vay vào một hạng rủi ro dựa trên thông tin tài chính, đặc điểm khoản vay và lịch sử thực hiện nghĩa vụ. Trong phạm vi luận văn, năm nhóm nợ được xem là các mức rủi ro có thứ tự; mô hình được xây dựng để hỗ trợ nhận diện nhóm nợ tương ứng của từng quan sát.

Tổn thất kỳ vọng có thể biểu diễn:

$$EL = PD \times LGD \times EAD.$$

Trong đó EL là tổn thất kỳ vọng; PD là xác suất vỡ nợ trong kỳ đánh giá; LGD là tỷ lệ tổn thất khi vỡ nợ sau khi xét khả năng thu hồi; và EAD là dư nợ tại thời điểm vỡ nợ. Luận văn hiện tập trung vào phân loại trạng thái rủi ro, chưa trực tiếp ước lượng đủ ba cấu phần của EL [4].



Hình 2.1: Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng

Nguồn: Tác giả tổng hợp và vẽ lại từ Basel Committee on Banking Supervision [4].

2.2 Từ đánh giá truyền thống đến các mô hình học máy

2.2.1 Sự chuyển dịch từ phương pháp truyền thống sang học máy

Phương pháp chuyên gia có khả năng khai thác thông tin định tính nhưng chủ quan. Z-score của Altman có ý nghĩa nền tảng nhưng phụ thuộc dữ liệu kế toán và quan hệ tuyến tính. Logistic Regression dễ giải thích nhưng khó tự động nắm bắt tương tác phức tạp.

Học máy là nhánh của AI trong đó mô hình học quy luật từ dữ liệu. Bài toán của luận văn thuộc học có giám sát.

2.2.2 Mô hình tuyến tính và cây quyết định

Logistic Regression đa lớp.

$$P(Y = k | \mathbf{x}) = \frac{\exp(\beta_{k0} + \beta_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\beta_{j0} + \beta_j^T \mathbf{x})}.$$

Trong đó K là số lớp; $\mathbf{x}$ là véc-tơ đặc trưng; β_{k0} là hệ số chặn của lớp k ; β_k là véc-tơ hệ số của lớp k ; và mẫu số chuẩn hóa để tổng xác suất của K lớp bằng 1

[15].

Decision Tree.

Decision Tree chia không gian đặc trưng bằng các điều kiện dạng $x_j \leq s$. Mô hình dễ diễn giải nhưng có thể quá khớp nếu không kiểm soát độ sâu và số quan sát tại lá.

Random Forest.

$$\hat{y} = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^B.$$


Trong đó B là số cây; $h_b(\mathbf{x})$ là dự báo lớp của cây thứ b tại hồ sơ $\mathbf{x}$; và mode chọn lớp xuất hiện nhiều nhất trong các dự báo cây [6].

2.2.3 Các mô hình boosting

XGBoost.

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t).$$

Trong đó t là vòng boosting; n là số quan sát huấn luyện; $l(\cdot)$ là hàm mất mát; $\hat{y}_i^{(t-1)}$ là dự báo tích lũy trước vòng t ; f_t là cây mới; và $\Omega(f_t)$ là số hạng phạt độ phức tạp của cây nhằm hạn chế quá khớp [9].



Hình 2.2: Cơ chế cộng dồn các cây trong XGBoost

Nguồn: Tài liệu chính thức của XGBoost [12], giấy phép Apache 2.0; minh họa cho cơ chế mô tả trong Chen và Guestrin [9]; truy cập ngày 15/08/2026.

Hình 2.2 thể hiện cách dự báo được cập nhật tuần tự. Mỗi cây mới $f_t(\mathbf{x})$ hiệu chỉnh phần sai số còn lại của tổ hợp trước đó bằng cách cộng thêm điểm số tại lá tương ứng của hồ sơ đang xét, có nhân hệ số học η ; XGBoost đồng thời đưa số hạng chính quy $\Omega(f_t)$ vào hàm mục tiêu để kiểm soát độ phức tạp.

LightGBM.

LightGBM tối ưu tốc độ và bộ nhớ bằng các kỹ thuật như Gradient-based One-Side Sampling và Exclusive Feature Bundling. Thuật toán phát triển cây theo lá tốt nhất, tức là tại mỗi bước ưu tiên tách lá tạo ra mức giảm hàm mất mát lớn nhất. Cách phát triển này có thể hội tụ nhanh nhưng cũng làm cây mất cân đối và dễ quá khớp khi dữ liệu nhỏ; vì vậy cần kiểm soát num_leaves, min_data_in_leaf và max_depth [16, 20].



Hình 2.3: Minh họa hai chiến lược phát triển cây quyết định

Nguồn: Tài liệu chính thức của *LightGBM* [20], giấy phép MIT; truy cập ngày 15/08/2026.

Hình 2.3 cho thấy sự khác biệt trực quan giữa hai chiến lược. Phương pháp theo tầng mở rộng đồng thời các nút ở cùng độ sâu và thường tạo ra cấu trúc tương đối cân đối. Ngược lại, *LightGBM* tiếp tục phân chia lá mang lại mức giảm hàm mất mát lớn nhất, vì vậy cây có thể phát triển không đối xứng. Cơ chế này góp phần nâng cao hiệu quả tối ưu, nhưng đồng thời đòi hỏi kiểm soát độ sâu và số lá để hạn chế hiện tượng quá khớp [16, 20].

CatBoost.

CatBoost có khả năng xử lý trực tiếp biến phân loại và sử dụng cơ chế *ordered boosting* để hạn chế rò rỉ thông tin trong quá trình huấn luyện [24].

2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng

2.3.1 Thách thức đối với hiệu năng dự báo

Mất cân bằng lớp.

Khi các nhóm nợ có tần suất chênh lệch lớn, mô hình có xu hướng thiên về lớp đa số. Hai hướng xử lý phổ biến, độc lập nhau và có thể kết hợp, là điều chỉnh ở cấp thuật toán (trọng số lớp trong hàm mất mát) và điều chỉnh ở cấp dữ liệu (sinh thêm quan sát tổng hợp cho lớp thiểu số).

Cấp thuật toán — trọng số lớp.

$$\mathcal{L} = - \sum_{i=1}^N w_{y_i} \sum_{k=1}^K \mathbb{I}(y_i = k) \log p_{ik}.$$

Trong đó N là số quan sát; K là số lớp; w_{y_i} là trọng số gán cho lớp thật của quan sát i ; $\mathbb{I}(y_i = k)$ bằng 1 khi $y_i = k$ và bằng 0 trong trường hợp khác; p_{ik} là xác suất dự báo lớp k . Trọng số lớn hơn cho lớp hiếm làm sai số của lớp đó có ảnh hưởng lớn hơn tới hàm mất mát. Trọng số thường được tính theo tần suất nghịch đảo:

$$w_c = \frac{N}{K n_c},$$

trong đó n_c là số quan sát thuộc lớp c ; mỗi quan sát i được gán trọng số w_{y_i} .

Cấp dữ liệu — SMOTE. SMOTE (*Synthetic Minority Over-sampling Technique*) tạo một điểm tổng hợp cho lớp thiểu số bằng nội suy tuyến tính giữa một quan sát và một láng giềng gần cùng lớp:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim U(0, 1),$$

trong đó $\mathbf{x}_i$ là véc-tơ của một quan sát lớp thiểu số; $\mathbf{x}_{nn}$ là một trong các láng giềng gần của nó; λ là số ngẫu nhiên phân bố đều trên $[0, 1]$; và $\mathbf{x}_{\text{new}}$ là điểm nội suy [8]. Khác với trọng số lớp (không đổi số quan sát, chỉ đổi ảnh hưởng của từng quan sát lên hàm mất mát), SMOTE làm tăng số quan sát huấn luyện của lớp thiểu số bằng dữ liệu nội suy chứ không phải quan sát độc lập mới. Hai hướng có thể dùng riêng hoặc kết hợp; hiệu quả thực tế của từng chiến lược trên dữ liệu của luận văn được đối chiếu thực nghiệm ở Mục 3.7.2 (Chương 3) và Mục 4.5 (Chương 4).


Tính thứ tự. Năm nhóm nợ có thứ tự rủi ro từ thấp đến cao nên hai sai số lệch

một bậc và lệch bốn bậc không có mức độ nghiêm trọng như nhau. Ordinal MAE được giới thiệu như một thước đo có thể bổ sung để lượng hóa số bậc sai lệch trung bình. Các bảng thực nghiệm hiện tại chưa báo cáo chỉ tiêu này, nên kết luận về mô hình chưa bao gồm đánh giá định lượng theo thứ tự nhóm nợ.

2.3.2 Khả năng giải thích và yêu cầu ứng dụng

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j.$$

Trong đó $f(\mathbf{x})$ là đầu ra mô hình cần giải thích; ϕ_0 là giá trị nền; p là số đặc trưng; và ϕ_j là đóng góp SHAP của đặc trưng j cho hồ sơ $\mathbf{x}$ [18].




Hình 2.4: Ví dụ biểu đồ waterfall minh họa nguyên lý phân rã dự báo theo giá trị SHAP

Nguồn: Tài liệu chính thức của SHAP [19], giấy phép MIT, dựa trên phương pháp của Lundberg và Lee [18]; truy cập ngày 15/08/2026.

Dự báo theo SHAP bắt đầu từ giá trị nền ϕ_0 (ký hiệu $E[f(X)]$ trong Hình 2.4), sau đó được điều chỉnh tăng hoặc giảm bởi đóng góp của từng đặc trưng cho tới khi đạt đầu ra $f(\mathbf{x})$ của hồ sơ đang xét. Dấu của ϕ_j cho biết chiều tác động

đối với đầu ra đang được giải thích (thanh màu đỏ: đóng góp dương; thanh màu xanh: đóng góp âm), còn độ lớn tuyệt đối phản ánh cường độ đóng góp. Hình 2.4 chỉ minh họa nguyên lý phân rã từ tài liệu SHAP; các giá trị SHAP thực nghiệm của luận văn được tính riêng trên dữ liệu tín dụng ở Chương 4.



Hình 2.5: Ví dụ biểu đồ SHAP beeswarm trong phân tích mức độ tác động của đặc trưng

Nguồn: Kho tài liệu chính thức của SHAP [19], dựa trên phương pháp của Lundberg và Lee [18], giấy phép MIT; truy cập ngày 15/08/2026.

Trong biểu đồ beeswarm, mỗi điểm biểu thị một quan sát; vị trí trên trục hoành phản ánh giá trị SHAP, còn màu sắc thể hiện mức độ cao hoặc thấp của giá trị đặc trưng. Các đặc trưng được sắp xếp theo tổng độ lớn ảnh hưởng, qua đó cho phép xem xét đồng thời tầm quan trọng, chiều tác động và mức độ phân tán của ảnh hưởng trên toàn bộ tập dữ liệu. Hình 2.5 chỉ minh họa cách đọc biểu đồ từ tài liệu SHAP; các kết luận thực nghiệm của luận văn được rút ra từ dữ liệu tín dụng và các biểu đồ được tạo riêng ở Chương 4.

2.4 Hệ thống chỉ tiêu đánh giá mô hình

2.4.1 Chỉ tiêu tổng thể và theo lớp

Accuracy.

$$Accuracy = \frac{\sum_{k=1}^K C_{kk}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}.$$

Trong đó C_{ij} là số quan sát có lớp thật i và lớp dự báo j ; tử số là tổng phần tử đường chéo; mẫu số là tổng số quan sát.

Precision, Recall và F1.

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k},$$

Trong đó TP_k là số dự báo đúng lớp k ; FP_k là số quan sát lớp khác bị dự báo nhầm thành k ; và FN_k là số quan sát lớp k bị dự báo sang lớp khác.

$$F1_k = 2 \frac{Precision_k \times Recall_k}{Precision_k + Recall_k}.$$

2.4.2 Chỉ tiêu cho dữ liệu mất cân bằng

Macro F1.

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Weighted F1.

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k.$$

Trong đó n_k là số quan sát thật của lớp k và N là tổng số quan sát. Khi một lớp chiếm tỷ trọng rất lớn, Weighted-F1 có thể che khuất hiệu năng thấp của lớp hiếm.

Balanced Accuracy.

$$\text{Balanced Accuracy} = \frac{1}{K} \sum_{k=1}^K \text{Recall}_k.$$

Balanced Accuracy là trung bình Recall của K lớp, nên mỗi lớp có trọng số như nhau bất kể tần suất.

2.4.3 Chỉ tiêu phản ánh thứ tự nhóm nợ

Ordinal MAE.

$$\text{Ordinal MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

Ký hiệu có ý nghĩa như phần Tính thứ tự; giá trị càng nhỏ thì khoảng cách nhóm dự báo so với nhóm thật càng thấp.

2.5 Nghiên cứu liên quan, khoảng trống và định hướng

2.5.1 Kết quả chính của các nghiên cứu liên quan

Hand và Henley [14] hệ thống hóa các phương pháp phân loại thống kê; Thomas [27] mở rộng phạm vi từ đánh giá tại thời điểm phê duyệt sang theo dõi hành vi trong vòng đời khoản vay. Baesens và cộng sự [2] và Lessmann và cộng sự [17] cho thấy hiệu quả mô hình phụ thuộc vào dữ liệu, thước đo và quy trình đánh giá.

Brown và Mues [7] nhấn mạnh ảnh hưởng của mất cân bằng. Xia và cộng sự [29] cho thấy boosted tree có khả năng cải thiện dự báo. Barboza và cộng sự [3] ghi nhận kết quả cạnh tranh của các mô hình cây trong dự báo phá sản. Dastile và cộng sự [11] chỉ ra các hạn chế phổ biến về dữ liệu nhỏ, mất cân bằng, thiếu

chuẩn đánh giá và khả năng giải thích.

Tại Việt Nam, nghiên cứu thường tập trung vào đánh giá rủi ro tín dụng cá nhân, rủi ro doanh nghiệp và dự báo nợ xấu. Tuy nhiên, chưa có nhiều nghiên cứu công bố việc phân loại trực tiếp năm nhóm nợ trên dữ liệu thực tế, kết hợp so sánh nhiều mô hình, chia dữ liệu theo thời gian, đánh giá có xét thứ tự và phân tích khả năng giải thích.

2.5.2 Khoảng trống và định hướng của luận văn

Mục 1.2.1 (Chương 1) đã nêu bốn khoảng trống làm động lực nghiên cứu ở cấp bối cảnh. Sau khi hệ thống hóa lý thuyết và tổng quan tài liệu đầy đủ hơn ở chương này, có thể bổ sung thêm các khoảng trống ở cấp phương pháp:

1. tính thứ tự của năm nhóm nợ chưa được khai thác đầy đủ trong phần lớn nghiên cứu tham khảo;
2. phương pháp chia mẫu ngẫu nhiên vẫn phổ biến hơn chia mẫu theo thời gian, dù rủi ro tín dụng có tính thời điểm;
3. lớp rủi ro cao (nhóm nợ 3–5) chiếm tỷ trọng rất nhỏ nhưng ít được đánh giá bằng thước đo phù hợp với dữ liệu mất cân bằng;
4. mô hình phức tạp (boosting) thường thiếu khả năng giải thích đi kèm.

Định hướng nghiên cứu. Luận văn xây dựng bài toán phân loại năm nhóm nợ, kiểm tra và hình thành các đặc trưng nghiệp vụ, sử dụng Logistic Regression làm mô hình cơ sở để đối chiếu với các mô hình cây và mô hình tăng cường, đồng thời xử lý mất cân bằng lớp theo cả hai hướng lý thuyết ở Mục 2.3.1, đánh giá bằng hệ thống chỉ tiêu đa lớp và giải thích mô hình thông qua mức độ quan

trọng của đặc trưng cùng SHAP. Thực nghiệm phân loại hiện tại sử dụng phép chia ngẫu nhiên có phân tầng và đánh giá bổ sung trên kỳ tiếp theo của bộ B. Bài toán chuyển nhóm được kiểm định trên hai cặp kỳ quan sát thật độc lập của bộ B, cho phép đánh giá bước đầu về độ ổn định của kết quả theo thời gian — điều mà một cặp kỳ duy nhất không thể thực hiện được.

2.6 Tóm tắt chương

Chương này đã trình bày cơ sở lý thuyết, thành tựu và hạn chế của các công trình nền tảng, các mô hình được sử dụng, các vấn đề đặc thù của dữ liệu tín dụng, hệ thống chỉ tiêu đánh giá, tổng quan nghiên cứu, khoảng trống và định hướng của luận văn.

Trên cơ sở lý thuyết và định hướng đã xác lập, Chương 3 sẽ trình bày cụ thể nguồn dữ liệu, quy trình xử lý, phân tích khám phá dữ liệu, xây dựng đặc trưng nghiệp vụ và phương pháp thực nghiệm được cài đặt trong mã nguồn trên hai bộ dữ liệu thực tế của luận văn.

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Chương này mô tả dữ liệu, cách xây dựng đặc trưng và thiết kế thực nghiệm cho hai bài toán nghiên cứu. Các bước xử lý, chia mẫu và đánh giá được trình bày cùng những giới hạn có thể ảnh hưởng đến khả năng tái lập và diễn giải kết quả.

3.1 Định hướng và phạm vi thực nghiệm

Nguồn dữ liệu gồm hai bộ dữ liệu chứa thông tin đã mã hóa về các khoản vay tại ngân hàng thương mại thuộc phạm vi nghiên cứu. Bộ dữ liệu A, `Data_credit_rating_VN.xlsx`, gồm 27.001 quan sát và 21 biến ban đầu; biến đích `NHOMNOMOI` nhận giá trị 1–5 (năm nhóm nợ). Bộ dữ liệu B trích xuất từ ba kỳ báo cáo liên tiếp: `20260430.xlsx` (100.617 hợp đồng, 41 cột, dùng huấn luyện/kiểm định nội bộ), `20260531.xlsx` (100.274 hợp đồng, 33 cột, làm *tập kiểm tra ở kỳ sau* và cặp 1 của bài toán chuyển nhóm) và `20260630.xlsx` (cặp 2 của bài toán chuyển nhóm). Biến đích `Nhóm nợ tự phân loại` cũng nhận giá trị 1–5. Vì kỳ `20260531` chỉ chứa 33/41 cột của kỳ `20260430`, tập đặc trưng của bộ B

chỉ xây từ các cột hiện diện ở cả hai kỳ, bảo đảm mô hình huấn luyện trên kỳ 20260430 áp dụng được cho kỳ sau (Mục 3.6.4).

Phạm vi thực nghiệm gồm hai bài toán có mục tiêu khác nhau: phân loại trạng thái hiện tại của khoản vay vào một trong năm nhóm nợ trên cả hai bộ dữ liệu, và dự báo khả năng chuyển sang nhóm nợ cao hơn trong các tháng tiếp theo trên bộ B (ghép các kỳ báo cáo liên tiếp). Bài toán thứ hai hướng trực tiếp tới mục tiêu cảnh báo sớm; bài toán thứ nhất dùng để đối sánh phương pháp mô hình hóa, đánh giá vai trò nhóm đặc trưng và kiểm tra khả năng tổng quát hóa ngoài mẫu.

Nếu có dữ liệu bảng theo thời gian, nhãn chuyển nhóm cần được định nghĩa:


$$Y_{i,t}^{(h)} = \begin{cases} 1, & G_{i,t+h} > G_{i,t}, \\ 0, & G_{i,t+h} \leq G_{i,t}, \end{cases}$$

trong đó i biểu thị khoản vay hoặc khách hàng; t là thời điểm quan sát; h là khoảng dự báo; $G_{i,t} \in \{1, 2, 3, 4, 5\}$ là nhóm nợ tại thời điểm t ; và $Y_{i,t}^{(h)} = 1$ biểu thị sự chuyển dịch sang nhóm có mức rủi ro cao hơn trong khoảng h . Trong thực nghiệm trên bộ B, luận văn sử dụng hai kỳ báo cáo liên tiếp và xác định $h = 31$ ngày. Toàn bộ đặc trưng đầu vào được lấy tại thời điểm t , còn trạng thái tại $t + h$ chỉ được sử dụng để xây dựng nhãn, qua đó hạn chế nguy cơ rò rỉ thông tin từ tương lai.

3.2 Quy trình nghiên cứu tổng thể

Quy trình nghiên cứu gồm thu thập và kiểm tra dữ liệu, thiết kế đặc trưng, phân chia mẫu, ước lượng các phép tiền xử lý trên tập huấn luyện, xử lý mất cân bằng, huấn luyện và đánh giá mô hình (Hình 3.1). Các phép biến đổi có tham số học từ

dữ liệu, gồm điền khuyết, mã hóa và chuẩn hóa, phải được ước lượng trong từng phần huấn luyện rồi áp dụng sang phần kiểm định. Phân tích IV và lựa chọn đặc trưng trên toàn bộ mẫu có thể gây thiên lệch lựa chọn; các cấu hình đặc trưng hiện tại được xem là kết quả khám phá, cần xác nhận bằng quy trình lựa chọn chỉ sử dụng dữ liệu huấn luyện.



Hình 3.1: Pipeline nghiên cứu tổng thể — từ thu thập dữ liệu tới kết luận và ứng dụng

3.3 Công nghệ và môi trường triển khai

Toàn bộ quy trình thực nghiệm và ứng dụng minh họa được xây dựng bằng Python 3.11. Ngôn ngữ này được lựa chọn nhờ hệ sinh thái thư viện tương đối hoàn chỉnh cho xử lý dữ liệu, học máy, giải thích mô hình và phát triển ứng dụng tương tác. Các công nghệ chính được tổng hợp tại Bảng 3.1. Danh sách này được xác định từ tệp `requirements.txt` và các mô-đun được sử dụng trực tiếp trong mã nguồn của nghiên cứu.

Bảng 3.1: Các công nghệ chính được sử dụng trong nghiên cứu

Công nghệ	Vai trò
Python 3.11	Tổ chức toàn bộ quy trình xử lý dữ liệu, huấn luyện, đánh giá, lưu trữ và phục vụ mô hình.
pandas, NumPy	Đọc Excel, biến đổi bảng dữ liệu, xử lý giá trị thiếu, xây dựng đặc trưng.
scikit-learn	Logistic Regression, Decision Tree, Random Forest, tiền xử lý, chia mẫu, chỉ tiêu đánh giá.
imbalanced-learn	SMOTE, BorderlineSMOTE, ADASYN, SMOTETomek và lấy mẫu dưới ngẫu nhiên.
XGBoost, LightGBM, CatBoost	Ba họ mô hình boosting dựa trên cây quyết định.
SHAP	Đóng góp của đặc trưng ở phạm vi toàn cục, theo nhóm nghiệp vụ và từng quan sát.
Plotly, Matplotlib	Phân bố dữ liệu, ma trận nhầm lẫn, đường cong hiệu năng, mức độ quan trọng.
Streamlit	Giao diện phân tích khám phá, huấn luyện, dự báo và so sánh mô hình.
OpenPyXL, Pickle	Đọc/ghi Excel và tuần tự hóa mô hình đã huấn luyện.

Lớp dữ liệu dùng pandas/NumPy; lớp mô hình hóa dùng scikit-learn, imbalanced-learn và ba thư viện boosting; lớp giải thích/trực quan hóa dùng SHAP, Plotly, Matplotlib; Streamlit đảm nhiệm giao diện — cách phân tách này giúp các bước tiền xử lý, huấn luyện và đánh giá tái sử dụng thống nhất giữa các

chức năng của ứng dụng.

3.4 Bước 1: Thu thập dữ liệu

Bước đầu tiên của quy trình gồm thu thập và kiểm tra hai tệp dữ liệu gốc, xác định biến đích và khảo sát sơ bộ phân bố nhóm nợ trước khi thực hiện các bước xử lý tiếp theo.

3.4.1 Bộ dữ liệu A: Data_credit_rating_VN

Bộ dữ liệu A gồm 27.001 hợp đồng vay và không có bản ghi thiếu dữ liệu tại biến đích NHOMNOMOI. Theo Bảng 3.2, nhóm 1 chiếm 77,65%, trong khi nhóm 3 chỉ chiếm 2,24%, cho thấy phân bố nhóm nợ có mức độ mất cân bằng đáng kể.

Bảng 3.2: Phân bố năm nhóm nợ trong bộ dữ liệu A

Nhóm	Toàn bộ	Tỷ lệ (%)	Huấn luyện	Kiểm định
1	20.965	77,65	16.771	4.194
2	1.287	4,77	1.030	257
3	604	2,24	483	121
4	784	2,90	627	157
5	3.361	12,45	2.689	672
Tổng	27.001	100,00	21.600	5.401

3.4.2 Bộ dữ liệu B: Thông tin tín dụng

Bộ dữ liệu B gồm 100.617 hợp đồng vay ở kỳ báo cáo 20260430 và không có bản ghi thiếu dữ liệu tại biến đích Nhóm nợ tự phân loại. Theo Bảng 3.3, tỷ lệ giữa nhóm có nhiều quan sát nhất (nhóm 1) và nhóm có ít quan sát nhất (nhóm 3) xấp xỉ 89 lần. Tuy nhiên, quy mô tuyệt đối của các nhóm hiếm, gồm 998 hồ sơ ở nhóm 3 và 1.446 hồ sơ ở nhóm 4, vẫn cho phép thực hiện đánh giá theo lớp.

Bảng 3.3: Phân bố năm nhóm nợ trong dữ liệu (kỳ 20260430)

Nhóm	Toàn bộ có nhân	Tỷ lệ (%)	Huấn luyện (80%)	Kiểm định (20%)
1	88.875	88,34	71.100	17.775
2	6.321	6,28	5.057	1.264
3	998	0,99	798	200
4	1.446	1,44	1.157	289
5	2.977	2,96	2.382	595
Tổng	100.617	100,00	80.493	20.124

Bộ B có hai tầng đánh giá cho bài toán phân loại hiện tại: tập kiểm định 20% tách ngẫu nhiên có phân tầng từ kỳ 20260430, dùng để so sánh cấu hình; và toàn bộ kỳ 20260531, dùng để đánh giá bổ sung theo thời gian. Kiểm tra trực tiếp trường ETL_DATE xác nhận 100.617 quan sát kỳ đầu thuộc ngày 30/04/2026 và 100.274 quan sát kỳ sau thuộc ngày 31/05/2026, cách nhau 31 ngày. Có 98.968 khách ước xuất hiện ở cả hai kỳ. Vì vậy, tập kỳ sau được tách khỏi bước huấn luyện mô hình nhưng không độc lập về khoản vay hoặc khách hàng. Kết quả chủ yếu phản ánh khả năng áp dụng mô hình sang kỳ tiếp theo của danh mục đang theo dõi, chưa đại diện cho khả năng tổng quát hóa sang khách hàng mới. Tập đặc trưng chung cũng đã được xác định từ cấu trúc cột của cả hai kỳ.

3.5 Bước 2: EDA & làm sạch dữ liệu

Hai bộ dữ liệu gốc được khảo sát bằng thống kê mô tả, tỷ lệ giá trị thiếu, phương pháp phát hiện ngoại lệ theo khoảng tứ phân vị (IQR) và ma trận tương quan Pearson giữa các biến số. Kết quả phân tích được sử dụng để nhận diện các biến cần chuẩn hóa, các cặp biến có nguy cơ đa cộng tuyến và các phân phối lệch cần lựa chọn phương pháp điều chỉnh phù hợp. Vì vậy, bước phân tích này vừa cung cấp mô tả dữ liệu, vừa làm căn cứ cho các quyết định tiền xử lý tại Bước 3 (Mục

3.6.7).

3.5.1 Bộ dữ liệu A

Làm sạch định dạng trường ngày

Trước khi tính các thống kê mô tả, hai trường ngày OPEN_DATE và NGAYDENHAN được kiểm tra định dạng. Kết quả cho thấy phần lớn bản ghi lưu ngày dưới dạng chuỗi văn bản dd/mm/yyyy (ví dụ “28/12/2010”), nhưng một bộ phận đáng kể lại lưu dưới dạng số thứ tự ngày kiểu Excel (Excel serial date, ví dụ “40490” thay vì “08/11/2010”), phát sinh từ lỗi định dạng ô tính khi xuất dữ liệu nguồn. Bảng 3.4 thống kê số bản ghi bị ảnh hưởng.

Bảng 3.4: Số bản ghi có trường ngày lưu sai định dạng (số thứ tự Excel) — bộ dữ liệu A

Trường	Số bản ghi bị ảnh hưởng	Tỷ lệ (%)
OPEN_DATE	9.949	36,84
NGAYDENHAN	9.890	36,63

Bộ phân tích cú pháp ngày tháng của mã nguồn chỉ nhận diện các mẫu văn bản dd/mm/yyyy và yyyy-mm-dd [hh:mm:ss] ; áp dụng trực tiếp lên dữ liệu chưa kiểm tra định dạng sẽ khiến các bản ghi dạng số thứ tự bị bỏ qua và chuyển thành giá trị thiếu (NaT) một cách âm thầm. Các số thứ tự ngày kiểu Excel được quy đổi về đúng giá trị ngày tháng theo mốc gốc chuẩn của Excel (30/12/1899); bản ghi đã ở dạng văn bản được giữ nguyên. Sau bước làm sạch, cả hai trường không còn bản ghi nào bị thiếu hoặc phân tích cú pháp thất bại.

Bảng 3.5 trình bày thống kê mô tả và số ngoại lệ theo IQR (ngoài $[Q_1 - 1,5IQR, Q_3 + 1,5IQR]$) của năm biến số gốc của bộ A trên toàn bộ 27.001 quan sát.

Bảng 3.5: Thống kê mô tả và số ngoại lệ theo IQR — các biến gốc của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất	Ngoại lệ (%)
BASE_BAL	$4,28 \times 10^8$	$6,40 \times 10^9$	2	$3,50 \times 10^7$	$3,85 \times 10^{11}$	7,13
CURR_BAL	$3,56 \times 10^8$	$5,32 \times 10^9$	1	$4,40 \times 10^7$	$2,96 \times 10^{11}$	9,12
LAISUAT	0,0688	0,0681	0	0,1000	0,4000	0,01
ORGNBR	58,34	35,95	3	59	138	0,00
PARENTORGNBR	42,53	34,29	3	34	138	0,00

Không biến số nào của bộ A có giá trị thiếu. Độ lệch chuẩn của BASE_BAL và CURR_BAL lớn hơn trung bình hàng chục lần — dấu hiệu phân phối lệch phải mạnh, điển hình của biến tiền tệ trong dữ liệu ngân hàng — nhất quán với tỷ lệ ngoại lệ cao nhất (9,12% và 7,13%) trong năm biến; LAISUAT, ORGNBR và PARENTORGNBR gần như không có ngoại lệ.

Trong năm biến gốc, CURR_BAL và BASE_BAL có tỷ lệ ngoại lệ cao nhất (9,12% và 7,13%), nhất quán với độ lệch phải mạnh đã nêu ở Bảng 3.5; LAISUAT, ORGNBR và PARENTORGNBR gần như không có ngoại lệ.

Về biến phân loại, MJACCTTYPCD có 3 nhóm (CNS 82,51%, MTG 9,26%, CML 8,23%) — mất cân bằng nhưng không cực đoan như biến đích. CURRMIACCTTYPCD có 31 nhóm và MUCDICHVAY có 79 nhóm mục đích vay, với 5 mục đích phổ biến nhất chiếm 83,06% hồ sơ. Cả hai biến có bản chất định danh không thứ tự, nhưng quy trình dùng LabelEncoder gán số nguyên theo thứ tự xuất hiện — hạn chế kỹ thuật cần lưu ý khi diễn giải hệ số hoặc ranh giới quyết định của Logistic Regression và Decision Tree.

3.5.2 Bộ dữ liệu B

Khác với bộ dữ liệu A, bộ dữ liệu B có một số biến gốc thiếu dữ liệu gần như tuyệt đối, nhưng đại đa số biến còn lại không thiếu giá trị nào. Bảng 3.6 liệt kê

các biến gốc có tỷ lệ thiếu khác 0.

Bảng 3.6: Các biến số gốc có tỷ lệ thiếu khác 0 — bộ dữ liệu B

Biến	Tỷ lệ thiếu (%)
Số tiền nợ lãi cơ cấu	99,82
Số tiền nợ gốc cơ cấu	99,72
Số lần cơ cấu lại thời hạn trả nợ	99,60
Phương thức cho vay	0,05

Ba biến về cơ cấu nợ thiếu gần như tuyệt đối (trên 99,5%) vì phần lớn hợp đồng chưa từng được cơ cấu lại thời hạn trả nợ. Trong trường hợp này, giá trị thiếu mang ý nghĩa nghiệp vụ (“không phát sinh sự kiện cơ cấu”), không nhất thiết là lỗi ghi nhận. Do đó, SimpleImputer(strategy="median") được áp dụng thống nhất cho các biến số thay vì loại bỏ ba biến trên. Với trung vị của phần dữ liệu quan sát được bằng 0 ở biến Số tiền nợ lãi cơ cấu (Bảng 3.7), phương pháp điền khuyết này hạn chế việc tạo ra các giá trị giả định quá khác biệt so với thực tế, đồng thời vẫn bảo toàn tín hiệu của nhóm hồ sơ đã từng được cơ cấu nợ.

Bảng 3.7: Thống kê mô tả, tỷ lệ thiếu và ngoại lệ IQR của các biến số gốc — bộ dữ liệu B

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Thiếu (%)	Ngoại lệ (%)
Số dư nợ theo nguyên tệ	5.092,31	121.908,73	122,00	0,00	12,07
Lãi phải thu hạch toán nội bảng	41,26	1.328,05	1,00	0,00	14,43
Lãi chưa thu hạch toán ngoại bảng	16,06	283,84	0,00	0,00	6,35
Lãi suất	11,29	4,14	10,00	0,00	0,00
Số lần cơ cấu lại thời hạn trả nợ	1,69	0,98	1,00	99,60	7,94
Số tiền nợ gốc cơ cấu	5.439,41	15.091,54	341,50	99,72	15,36
Số tiền nợ lãi cơ cấu	469,66	764,14	216,00	99,82	12,71
Mã chi nhánh TCTD	—	—	—	0,00	0,00

Độ lệch chuẩn lớn hơn trung bình nhiều lần ở hầu hết các biến (điển hình Số dư nợ theo nguyên tệ, gấp khoảng 24 lần trung bình) là bằng chứng

phân phối lệch phải mạnh, tương tự BASE_BAL và CURR_BAL của bộ A; tỷ lệ ngoại lệ IQR xác nhận điều này, cao nhất ở Số tiền nợ gốc cơ cấu (15,36%). Ba biến về cơ cấu nợ thiếu gần như tuyệt đối (trên 99,5%) vì phần lớn hợp đồng chưa từng được cơ cấu lại thời hạn trả nợ — giá trị thiếu mang ý nghĩa nghiệp vụ (“không phát sinh sự kiện cơ cấu”), không phải lỗi ghi nhận. SimpleImputer(strategy="median") được áp dụng thống nhất cho các biến số thay vì loại bỏ ba biến này; với trung vị bằng 0 ở Số tiền nợ lãi cơ cấu, phương pháp này hạn chế tạo giá trị giả định khác biệt so với thực tế trong khi vẫn bảo toàn tín hiệu của nhóm hồ sơ đã từng cơ cấu nợ.

Trong tám biến số gốc, ba cặp có tương quan lớn nhất là Số dư nợ theo nguyên tệ với Số tiền nợ gốc cơ cấu ($r = 0,908$), Số dư nợ theo nguyên tệ với Số tiền nợ lãi cơ cấu ($r = 0,850$), và Lãi suất với Số tiền nợ gốc cơ cấu ($r = -0,613$) — chưa vượt ngưỡng loại biến, nhưng cho thấy các biến thuộc nhóm Dư nợ & Thanh toán cùng phản ánh một phần thông tin về quy mô và trạng thái khoản vay. Trung vị lãi suất có xu hướng tăng từ nhóm 1 đến nhóm 5 (không trình bày hình do các nhóm 3, 4 chỉ có 998 và 1.446 quan sát, Bảng 3.3).

3.6 Bước 3: Tiền xử lý & chọn biến

Bước thứ ba xây dựng tập đặc trưng dùng cho huấn luyện, bao gồm loại các trường có nguy cơ rò rỉ dữ liệu, tạo đặc trưng nghiệp vụ, tính Weight of Evidence và Information Value (WOE/IV), xác lập tập đặc trưng, xử lý giá trị thiếu, mã hóa và chuẩn hóa. Mọi tham số tiền xử lý, như trung vị, trung bình, độ lệch chuẩn và danh mục mã hóa, chỉ được ước lượng trên tập huấn luyện để tránh rò

rỉ thông tin từ tập kiểm định.

3.6.1 Kiểm soát rò rỉ dữ liệu

Rò rỉ thông tin phát sinh khi biến đầu vào chứa dữ liệu chỉ xuất hiện sau thời điểm dự báo hoặc là phép biến đổi trực tiếp của biến đích. Đối với bộ A, các biến NHOMNO_TCBS và NHOMNO được loại khỏi tập đầu vào; trong đó, NHOMNO có tương quan rất cao với NHOMNOMOI, nên việc giữ lại biến này có thể khiến mô hình tái tạo gần như trực tiếp quy tắc hình thành nhãn. Quá trình sàng lọc cũng loại biến DUNO_QD bị trùng lặp, trường mô tả văn bản trùng với mã sản phẩm và các trường hằng số hoặc có lượng thông tin không đáng kể.

Ở bộ B, bảy trường bị loại vì có quan hệ trực tiếp với quy tắc phân loại nhóm nợ theo quy định của Ngân hàng Nhà nước: Nhóm nợ phân loại sau khi tham chiếu CIC (một biến thể khác của biến đích); Dư nợ gốc chậm trả thực tế, Ngày chậm trả nợ gốc, Số tiền lãi chậm trả thực tế và Ngày chậm trả nợ lãi (số ngày và số tiền chậm trả là căn cứ trực tiếp để phân loại nhóm nợ); cùng với Dự phòng cụ thể phải trích nội bảng và Dự phòng cụ thể đã trích nội bảng. Tỷ lệ trích lập dự phòng cụ thể là hàm xác định theo nhóm nợ, lần lượt bằng 0%, 5%, 20%, 50% và 100% đối với nhóm 1 đến nhóm 5. Việc giữ các trường này có thể làm phát sinh rò rỉ thông tin, khiến mô hình tái tạo quy tắc hình thành nhãn thay vì nhận diện tín hiệu dự báo.

Đối với bài toán dự báo chuyển nhóm nợ, yêu cầu kiểm soát rò rỉ cần được thực hiện chặt chẽ hơn: mọi đặc trưng $X_{i,t}$ phải sẵn có tại hoặc trước thời điểm t , trong khi nhãn được xác định trong khoảng từ $t + 1$ đến $t + h$. Phép chia mẫu ngẫu nhiên được sử dụng trong nghiên cứu hiện tại phù hợp với mục tiêu kiểm

định mô hình phân loại trạng thái, nhưng chưa tối ưu cho bài toán cảnh báo sớm. Khi có dữ liệu theo thời gian, việc chia mẫu theo trình tự thời gian là cần thiết để ngăn thông tin tương lai tham gia quá trình huấn luyện.

3.6.2 Xây dựng đặc trưng nghiệp vụ

Hai nhánh dữ liệu sử dụng công thức tạo biến khác nhau. Bộ A tạo ba biến từ ngày mở, ngày đáo hạn, dư nợ hiện tại và dư nợ gốc. Bộ B tạo bốn biến kỹ thuật từ ngày giải ngân, ngày kết thúc khế ước và số lần cơ cấu lại thời hạn trả nợ.

Các biến này không tồn tại trực tiếp trong dữ liệu ban đầu mà được xây dựng từ một hoặc nhiều trường gốc nhằm chuyển thông tin kỹ thuật thành các đại lượng có ý nghĩa nghiệp vụ rõ ràng hơn. Bảng 3.8 tổng hợp nguồn hình thành và cách diễn giải của toàn bộ 7 biến được bổ sung.

Bảng 3.8: Các biến được xây dựng thêm từ dữ liệu ban đầu

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
A	LOAN_TENURE_DAYS	OPEN_DATE, NGÀYDENHAN	Tổng thời hạn theo hợp đồng, tính bằng số ngày từ ngày mở đến ngày đáo hạn. Giá trị lớn biểu thị khoản vay có kỳ hạn dài hơn.
A	DAYS_TO_MATURITY	NGÀYDENHAN, ngày tham chiếu d_0	Số ngày còn lại đến ngày đáo hạn. Giá trị dương biểu thị khoản vay chưa đáo hạn; bằng 0 là đáo hạn tại ngày tham chiếu; giá trị âm biểu thị khoản vay đã qua ngày đáo hạn.
A	UTIL_RATE	CURR_BAL, BASE_BAL	Tỷ lệ giữa dư nợ hiện tại và dư nợ gốc. Giá trị gần 1 cho biết dư nợ hiện tại xấp xỉ dư nợ gốc; nhỏ hơn 1 phản ánh dư nợ đã giảm; lớn hơn 1 có thể phản ánh giải ngân bổ sung hoặc biến động số dư.
B	ENG_LOAN_AGE_DAYS	ETL_DATE, Ngày giải ngân	Số ngày đã trôi qua kể từ ngày giải ngân tới ngày chốt dữ liệu (ETL_DATE) của chính hồ sơ đó, tức tuổi của khoản vay. Giá trị lớn biểu thị khoản vay đã tồn tại lâu hơn.
B	ENG_DAYS_TO_MATURITY	Ngày kết thúc khế ước, ETL_DATE	Số ngày còn lại đến ngày kết thúc khế ước, tính từ ETL_DATE. Giá trị âm cho biết khế ước đã qua ngày kết thúc so với ngày chốt dữ liệu.
B	ENG_TENOR_ACTUAL_DAYS	Ngày kết thúc khế ước, Ngày giải ngân	Kỳ hạn thực tế của khế ước, bằng chênh lệch giữa ngày kết thúc và ngày giải ngân.

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
B	ENG_HAS_RESTRUCTURE	Số lần cơ cấu lại thời hạn trả nợ	Biến nhị phân nhận giá trị 1 khi số lần cơ cấu lại thời hạn trả nợ lớn hơn 0 và nhận giá trị 0 trong trường hợp còn lại (kể cả khi thiếu dữ liệu). Biến chỉ phản ánh việc từng phát sinh cơ cấu, không cho biết mức độ.

Các biến phát sinh trên được tính hoàn toàn từ các trường đầu vào và không sử dụng biến đích. Do đó, bản thân quá trình tạo biến không trực tiếp làm lộ nhãn nhóm nợ. Tuy nhiên, trước khi triển khai thực tế, thời điểm hình thành của từng trường gốc vẫn phải được kiểm tra để bảo đảm trường đó đã tồn tại tại thời điểm dự báo; nếu một trường chỉ phát sinh sau thời điểm quan sát, biến được tạo từ trường đó vẫn có thể gây rò rỉ thông tin theo thời gian.

Đặc trưng của bộ dữ liệu A

Với ngày tham chiếu cố định $d_0 = 31/12/2021$, các biến được tính như sau:

$$LOAN_TENURE_DAYS_i = \max\{0, d_i^{\text{maturity}} - d_i^{\text{open}}\},$$

$$DAYS_TO_MATURITY_i = d_i^{\text{maturity}} - d_0.$$

Trong đó d_i^{open} là ngày mở khoản vay; d_i^{maturity} là ngày đến hạn; chênh lệch ngày được biểu diễn bằng số ngày dương hoặc âm. Việc cố định d_0 giúp cùng một hồ sơ nhận cùng giá trị khi tái chạy.

Tỷ lệ sử dụng dư nợ của bộ A được cài đặt:

$$UTIL_RATE_i = \begin{cases} \text{clip}\left(\frac{CURR_BAL_i}{BASE_BAL_i}, 0, 10\right), & BASE_BAL_i > 0, \\ 0, & BASE_BAL_i \leq 0. \end{cases}$$

Trong đó CURR_BAL là dư nợ hiện tại; BASE_BAL là dư nợ gốc hoặc cơ sở; và toán tử $\text{clip}(x, 0, 10)$ giới hạn giá trị trong đoạn $[0, 10]$ để giảm ảnh hưởng của tỷ

số ngoại lệ.

Kiểm tra đặc trưng đã tạo của bộ dữ liệu A

Sau khi ba biến LOAN_TENURE_DAYS, DAYS_TO_MATURITY và UTIL_RATE được tạo, mục này khảo sát thống kê mô tả, ngoại lệ và tương quan của chúng cùng năm biến gốc đã trình bày ở Bước 2 (mục 3.5), trước khi tính Information Value ở mục sau.

Bảng 3.9: Thống kê mô tả và số ngoại lệ theo IQR — ba biến kỹ thuật của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất	Ngoại lệ (%)
LOAN_TENURE_DAYS	2.292,5	2.452,0	0	1.461	18.292	10,20
DAYS_TO_MATURITY	672,7	2.397,7	-5.513	96	16.798	23,08
UTIL_RATE	2,4561	3,2557	2×10^{-8}	0,9429	10,0000	17,21


DAYS_TO_MATURITY có tỷ lệ ngoại lệ cao nhất (23,08%) vì nhận cả giá trị âm (đã quá hạn đáo hạn so với d_0) lẫn giá trị dương lớn (kỳ hạn dài) — đặc điểm nghiệp vụ thực, không bị loại hay cắt ngưỡng. UTIL_RATE có 17,21% ngoại lệ do một số khách hàng có dư nợ hiện tại vượt xa dư nợ gốc (giải ngân bổ sung nhiều lần); đây là lý do công thức trên chủ động **clip** kết quả vào $[0, 10]$, tránh một số ít hồ sơ có tỷ lệ hàng trăm lần làm lệch cực đoan bước chuẩn hóa z-score khi đưa vào Logistic Regression.

Phép clip giới hạn giá trị trong một khoảng xác định thay vì loại bỏ quan sát ngoài khoảng đó:

$$\text{clip}(u; 0, 10) = \min\{\max(u, 0), 10\}.$$

Ngưỡng trên bằng 10 tương ứng dư nợ hiện tại gấp 10 lần dư nợ gốc. Cách xử lý này giữ nguyên số quan sát và bảo lưu tín hiệu "mức sử dụng rất cao", nhưng

làm các mức UTIL_RATE trên 10 không còn phân biệt được với nhau — một lựa chọn tăng ổn định mô hình, không hàm ý các giá trị vượt ngưỡng sai về nghiệp vụ.



Hình 3.2: Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001)

Hình 3.2 minh họa trực quan hai đặc điểm đã nêu bằng số: BASE_BAL và CURR_BAL lệch phải mạnh trên thang gốc nên được vẽ theo log₁₀ để thấy rõ hình chuông tương đối; UTIL_RATE có một cột dồn rõ rệt tại đúng giá trị 10, bằng chứng trực quan cho thấy phép **clip** đã cắt và dồn một lượng đáng kể hồ sơ (khoảng 3.200, tương ứng phần vượt ngưỡng của 17,21% ngoại lệ ở Bảng 3.9) về đúng biên trên; DAYS_TO_MATURITY có hai đỉnh, một quanh 0 (khoản vay gần đáo hạn hoặc mới quá hạn) và một dải trải dài về phía dương (khoản vay kỳ hạn dài).


Ma trận tương quan (Bảng 3.10, minh họa trực quan ở Hình 3.3) cho thấy ba

cặp biến có $|r| \geq 0,7$.


Bảng 3.10: Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A

Biến 1	Biến 2	Hệ số tương quan r
LOAN_TENURE_DAYS	DAYS_TO_MATURITY	0,942
BASE_BAL	CURR_BAL	0,923
ORGNBR	PARENTORGNBR	0,738
LAISUAT	LOAN_TENURE_DAYS	0,352
LAISUAT	UTIL_RATE	-0,327

Ba cặp tương quan mạnh nhất đều có cách giải thích nghiệp vụ trực tiếp: LOAN_TENURE_DAYS và DAYS_TO_MATURITY cùng được tính từ ngày mở và ngày đáo hạn nên gần như là hai phép biến đổi tuyến tính của cùng thông tin gốc; CURR_BAL là dư nợ hiện tại nên tương quan cao với dư nợ gốc BASE_BAL; ORGNBR và PARENTORGNBR phản ánh cấu trúc phân cấp chi nhánh—đơn vị cấp trên. Mức tương quan này không đủ cao để loại biến (không có cặp nào $|r| > 0,95$), nhưng đủ để giải thích vì sao trong bảng SHAP ở Chương 4, importance của hai biến kỳ hạn thường lẫn lộn lẫn nhau tùy ngẫu nhiên hoá của mô hình cây; đây là hạn chế cố hữu khi diễn giải importance trên các biến tương quan [18].



Hình 3.3: Ma trận tương quan Pearson giữa các biến số của bộ dữ liệu A



Hình 3.4: Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A

Hình 3.4 cho thấy trung vị DAYS_TO_MATURITY giảm dần khá đều từ nhóm 1 đến nhóm 4 rồi đổi hướng ở nhóm 5, phù hợp việc đây là biến SHAP xếp hạng cao nhất ở Chương 4, nhưng cũng gợi ý quan hệ giữa biến này và nhóm nợ không hoàn toàn đơn điệu, cần thận trọng khi diễn giải nhân quả.

Đặc trưng thời gian của bộ dữ liệu B

Ba trong bốn biến kỹ thuật của bộ B được tính bằng chênh lệch ngày, sử dụng ETL_DATE của từng hồ sơ làm mốc tham chiếu để bảo đảm khả năng tái lập kết quả. Mỗi hồ sơ có một ngày chốt dữ liệu cố định tại thời điểm trích xuất báo cáo, nên giá trị của các biến thời gian không thay đổi khi thực thi lại mã nguồn tại một thời điểm khác. Biến còn lại được tính trực tiếp từ số lần cơ cấu lại thời hạn trả nợ.

$$ENG_LOAN_AGE_DAYS_i = ETL_DATE_i - d_i^{\text{disb}},$$

$$ENG_DAYS_TO_MATURITY_i = d_i^{\text{end}} - ETL_DATE_i,$$

$$ENG_TENOR_ACTUAL_DAYS_i = d_i^{\text{end}} - d_i^{\text{disb}},$$

trong đó d_i^{disb} là ngày giải ngân; d_i^{end} là ngày kết thúc kế ước; và ETL_DATE_i là ngày chốt dữ liệu của hồ sơ i . Biến nhị phân còn lại:

$$ENG_HAS_RESTRUCTURE_i = \begin{cases} 1, & SoLanCoCauLai_i > 0, \\ 0, & \text{ngược lại (kể cả khi thiếu dữ liệu)}. \end{cases}$$


Trường Thời điểm truy đòi, ban đầu được xem xét làm nguồn cho một biến thời gian thứ năm, bị loại khỏi danh sách cột ngày sau khi kiểm tra thực nghiệm cho thấy trường này trùng khớp 100% với Ngày kết thúc kế ước trên toàn bộ dữ liệu quan sát được; giữ lại sẽ chỉ tạo ra một biến kỹ thuật trùng lặp hoàn toàn với ENG_DAYS_TO_MATURITY, không bổ sung thông tin mới.

Kiểm tra đặc trưng đã tạo của bộ dữ liệu B


Cả bốn biến kỹ thuật của bộ B đều **không có giá trị thiếu** (0,00%), vì được tính trực tiếp từ ETL_DATE, ngày giải ngân và ngày kết thúc khế ước, ba trường có mặt ở toàn bộ 100.617 hồ sơ. Bảng 3.11 trình bày thống kê mô tả.

Bảng 3.11: Thống kê mô tả bốn biến kỹ thuật của bộ dữ liệu B

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Ngoại lệ IQR (%)
ENG_LOAN_AGE_DAYS	602,82	632,71	395	3,05
ENG_DAYS_TO_MATURITY	1.667,40	2.778,31	711	11,51
ENG_TENOR_ACTUAL_DAYS	2.270,22	2.850,29	1.461	12,45
ENG_HAS_RESTRUCTURE	0,004	0,063	0	0,40



Hình 3.5: Top 15 biến (trong bề đặc trưng hợp lệ) có tỷ lệ thiếu cao nhất — bộ dữ liệu B



Hình 3.6: Ma trận tương quan giữa 12 biến số (8 biến gốc + 4 biến kỹ thuật) — bộ dữ liệu B

Trong 12 biến số, hệ số tương quan lớn nhất bằng 0,975 (Hình 3.6), thuộc về cặp biến số ngày đến đáo hạn và kỳ hạn thực tế. Mỗi tương quan này xuất phát từ việc cả hai đặc trưng cùng sử dụng mốc Ngày kết thúc kế ước, tương tự mối quan hệ giữa LOAN_TENURE_DAYS và DAYS_TO_MATURITY ở bộ A (Mục 3.6.2). Do hệ số tương quan vượt ngưỡng tham khảo 0,95, hai biến có khả năng chứa thông tin trùng lặp đáng kể. Tuy vậy, nghiên cứu vẫn giữ lại cả hai do chúng biểu thị hai khía cạnh nghiệp vụ khác nhau, lần lượt là kỳ hạn còn lại và tổng kỳ hạn thực tế. Đây là điểm cần thận trọng khi diễn giải mức độ quan trọng ở Chương 4, bởi đóng góp của hai biến có thể cùng bắt nguồn từ một nguồn thông tin cơ sở.

3.6.3 Weight of Evidence và Information Value (WOE/IV)

Information Value (IV) được sử dụng để lượng hóa khả năng phân tách giữa nhóm nợ “tốt” và nhóm nợ “xấu” của từng biến trước khi đưa vào mô hình. Nghiên cứu quy ước nhãn nhị phân “tốt” tương ứng với nhóm 1 và “xấu” tương ứng với các nhóm 2–5; các biến số được chia thành 10 khoảng theo phân vị. IV được tính trên tập đặc trưng còn lại sau khi loại các trường có nguy cơ rò rỉ tại Mục 3.6.1 và bổ sung các đặc trưng nghiệp vụ, qua đó cung cấp căn cứ định lượng để xác lập tập đặc trưng tại Mục 3.6.4.

Bảng Information Value đầy đủ của bộ dữ liệu A

Bảng 3.12 trình bày giá trị IV của toàn bộ 13 biến trong tập phân tích, bao gồm SEX và LOAIKH, theo thứ tự giảm dần. Vai trò của hai biến này trong quá trình lựa chọn tập đặc trưng được thảo luận tại Mục 3.6.4.

Bảng 3.12: Information Value của 13 biến — bộ dữ liệu A

Biến	IV	Mức
DAYS_TO_MATURITY	4,5541	(!) Nghi ngờ (leakage?)
CURRMIACTTYP	1,9921	(!) Nghi ngờ (leakage?)
LOAN_TENURE_DAYS	1,9410	(!) Nghi ngờ (leakage?)
MUCDICHVAY	1,4141	(!) Nghi ngờ (leakage?)
UTIL_RATE	1,3334	(!) Nghi ngờ (leakage?)
MJACCTTYP	0,9695	Rất mạnh
LAISUAT	0,7851	Rất mạnh
BASE_BAL	0,5356	Rất mạnh
PARENTORGNBR	0,3201	Mạnh
CURR_BAL	0,2585	Trung bình
ORGNBR	0,1820	Trung bình
SEX	0,0081	Vô dụng
LOAIKH	0,0000	Vô dụng

Kết quả cho thấy 5 trong tổng số 13 biến có $IV > 1,0$, vượt ngưỡng mà Siddiqi xem là dấu hiệu cần thận trọng do biến có thể đại diện gián tiếp hoặc làm rò rỉ biến đích [26]; năm biến này cũng nằm trong nhóm có mức độ quan trọng cao nhất theo SHAP và Gain ở Chương 4. Có hai khả năng cần phân biệt: nếu biến được tính trực tiếp từ NHOMNOMOI hoặc quy tắc hình thành nhãn, biến đó phải bị loại tương tự NHOMNO (Mục 3.6.1); nếu biến độc lập với nhãn nhưng có quan hệ nghiệp vụ chặt chẽ với nhóm nợ, IV cao có thể phản ánh tín hiệu thực tế. Do chưa có đầy đủ thông tin về quy trình hình thành dữ liệu nguồn, đây được xem là một giới hạn cần lưu ý khi diễn giải mô hình.

Luận văn nghiêng về khả năng thứ hai đối với ba biến tự xây dựng (DAYS_TO_MATURITY, LOAN_TENURE_DAYS, UTIL_RATE) vì cả ba đều tính từ ngày mở, ngày đáo hạn hoặc số dư nợ — các trường tồn tại độc lập với quy trình xếp nhóm, không phải biến phái sinh của NHOMNOMOI. Với hai biến phân loại nhiều danh mục CURRMIACTTYP (31 nhóm) và MUCDICHVAY (79 nhóm), IV cao một phần có thể là hiện tượng thống kê: biến định danh nhiều danh mục dễ đạt IV cao giả tạo dù không có quan hệ nhân quả mạnh — hạn chế đã biết của công thức IV [26]. Luận văn khuyến nghị giữ nguyên 5 biến này vì không tìm thấy bằng chứng tính trực tiếp từ nhãn, nhưng nêu rõ đây là điểm cần rà soát cùng đơn vị nghiệp vụ trước khi triển khai thực tế, đặc biệt với hai biến nhiều danh mục.

Bảng Information Value của bộ dữ liệu B

Áp dụng cùng phương pháp tính IV như bộ A (mục 3.6.3) cho toàn bộ 20 đặc trưng hợp lệ của bộ B. Bảng 3.13 tổng hợp số lượng biến theo từng mức IV; Bảng 3.14 liệt kê chi tiết từng biến.

Bảng 3.13: Phân bố 20 đặc trưng của bộ dữ liệu B theo mức Information Value

Mức IV	Số biến	Tỷ lệ (%)
Vô dụng (< 0,02)	7	35,0
Yếu (0,02–0,1)	6	30,0
Mạnh (0,3–0,5)	3	15,0
Trung bình (0,1–0,3)	2	10,0
Rất mạnh (0,5–1,0)	1	5,0
(!) Nghi ngờ (> 1,0)	1	5,0
Tổng	20	100,0

Bảng 3.14: Information Value của 20 đặc trưng — bộ dữ liệu B

Biến	IV	Mức
ENG_LOAN_AGE_DAYS	1,1170	(!) Nghi ngờ (leakage?)
Lãi phải thu hạch toán nội bảng	0,5420	Rất mạnh
ENG_TENOR_ACTUAL_DAYS	0,3793	Mạnh
Mô tả mục đích sử dụng tiền vay	0,3611	Mạnh
Lãi suất	0,3130	Mạnh
ENG_DAYS_TO_MATURITY	0,2549	Trung bình
Số dư nợ theo nguyên tệ	0,1892	Trung bình
Phương thức cho vay	0,0732	Yếu
Số tiền nợ gốc cơ cấu	0,0626	Yếu
Số lần cơ cấu lại thời hạn trả nợ	0,0620	Yếu
Mục đích sử dụng tiền vay phân theo ngành kinh tế	0,0620	Yếu
Mã chi nhánh TCTD	0,0415	Yếu
Số tiền nợ lãi cơ cấu	0,0320	Yếu
Mã thời hạn cấp tín dụng	0,0107	Vô dụng
Mã tiền tệ	0,0039	Vô dụng
ENG_HAS_RESTRUCTURE	0,0000	Vô dụng
Hình thức cấp tín dụng	0,0000	Vô dụng
Lãi chưa thu hạch toán ngoại bảng	0,0000	Vô dụng
Nguồn cấp tín dụng	0,0000	Vô dụng
Hoạt động cấp tín dụng bằng phương tiện điện tử	0,0000	Vô dụng

Bảng 3.14 cho thấy ENG_LOAN_AGE_DAYS, biến kỹ thuật được xây dựng trong nghiên cứu, có IV cao nhất (1,1170), vượt ngưỡng mà Siddiqi xem là dấu hiệu

cần thận trọng [26]. Biến này được tính hoàn toàn từ ETL_DATE và Ngày giải ngân, là hai trường tồn tại độc lập với quy tắc xếp nhóm nợ. Do đó, IV cao có thể phản ánh hiệu ứng tuổi khoản vay (*seasoning effect*): khoản vay tồn tại lâu hơn có nhiều thời gian phát sinh chậm trả, trong khi khoản vay mới giải ngân thường chưa đủ thời gian để phát sinh quá hạn. Nghiên cứu giữ lại biến này nhưng không diễn giải mối liên hệ quan sát được như bằng chứng nhân quả.

Bảy trên hai mươi đặc trưng (35,0%) có $IV < 0,02$, tức “vô dụng” theo ngưỡng đơn biến, nhưng vẫn được giữ trong tập huấn luyện vì quy tắc lọc ở mục 3.6.2 chỉ loại theo tiêu chí leakage/trùng lặp/hàng số, không lọc theo IV. Tỷ lệ này khá thấp vì bề đặc trưng đã nhỏ và tập trung (20 biến), nên ít cột dư thừa/gần hàng số.

3.6.4 Xây dựng tập đặc trưng huấn luyện

Bộ dữ liệu A: tập 11 biến và tập mở rộng 13 biến

Cấu hình huấn luyện chính sử dụng 11 đặc trưng đã qua sàng lọc, gồm ba biến phân loại và tám biến số. Để đánh giá độ nhạy của tiêu chí lựa chọn biến, tập phân tích được mở rộng lên 13 đặc trưng bằng cách bổ sung SEX và LOAIKH. Theo Bảng 3.12, hai biến này có IV lần lượt bằng 0,008 và 0,000, đều thấp hơn ngưỡng 0,02 thường được xem là không có giá trị dự báo đơn biến đáng kể [26]. Việc đưa hai biến trở lại tập mở rộng nhằm kiểm tra liệu mô hình cây đa biến có thể khai thác các tương tác mà IV đơn biến không phản ánh hay không. Kết quả tại Chương 4 cho thấy sự khác biệt về hiệu quả là không đáng kể.

Sau khi phân tích ngày và tạo biến, bộ A có tám biến số:

- năm biến từ tệp nguồn: BASE_BAL, CURR_BAL, LAISUAT, ORGNBR và

PARENTORGNBR;

- ba biến tạo thêm về kỳ hạn khoản vay, số ngày đến đáo hạn và tỷ lệ sử dụng hạn mức.

Năm biến phân loại trong tập đầy đủ được chia thành:

- ba biến cấu hình chính: MJACCTTYPCD, CURRMIACCTTYPCD và MUCDICHVAY;
- hai biến IV thấp đưa lại để kiểm chứng: SEX và LOAIKH.

Đối với bộ 11 biến chính, phép đếm từ tập nguồn là:

$$21 - 1 - 10 - 2 + 3 = 11,$$

trong đó 21 là số cột thô; 1 là biến đích; 10 là số trường trong danh sách loại; 2 là hai trường ngày chỉ dùng để tạo biến; và 3 là số biến kỹ thuật được bổ sung. Pool phân tích có 13 biến vì đưa lại hai biến SEX và LOAIKH.

Bộ dữ liệu B: từ 33 cột chung tới 20 đặc trưng mô hình

Con số 33 là số cột có mặt ở cả hai kỳ báo cáo (20260430 và 20260531), không phải số biến thực tế đưa vào bộ phân loại. Tám cột chỉ có ở kỳ 20260430 không được dùng làm đặc trưng vì tập kiểm tra ở kỳ sau 20260531 không có các cột này. Bước xây dựng bể đặc trưng từ 33 cột chung thực hiện bốn lớp lọc:

1. loại biến đích;
2. loại 4 trường định danh (mã/tên khách hàng, số hợp đồng, số khế ước) và 7 trường gây rò rỉ đã nêu ở mục 3.6.1 (nhóm nợ đối chiếu CIC, dư nợ/lãi chậm trả thực tế và ngày chậm trả, dự phòng cụ thể phải trích và đã trích);

3. không đưa trực tiếp 3 trường ngày (ETL_DATE, ngày giải ngân, ngày kết thúc khế ước) vào mô hình; các trường này chỉ dùng để tạo 4 biến thời gian ở mục 3.6.2. Loại thêm 1 trường ngày trùng lặp hoàn toàn (Thời điểm truy đòi) và 1 cột hằng số (Số tiền đã thanh toán, toàn bộ giá trị bằng 0 trong dữ liệu quan sát được).


Sau quá trình sàng lọc, tập dữ liệu còn 8 biến số và 8 biến phân loại. Bước xây dựng đặc trưng nghiệp vụ bổ sung 4 biến số, đưa tổng số biến đầu vào lên:

$$p = 8 + 8 + 4 = 20.$$

Tương đương, phép đếm từ tập nguồn có thể viết:

$$33 - 1 - 4 - 7 - 4 - 1 + 4 = 20.$$

Trong đó, 1 là biến đích; 4 là số trường định danh; 7 là số trường có nguy cơ rò rỉ thông tin; 4 là số trường ngày (3 dùng để sinh đặc trưng, 1 trùng lặp bị loại); 1 là cột hằng số; và 4 là số biến được xây dựng thêm. Ràng buộc 33 cột chung giữa hai kỳ báo cáo đã tự nhiên giới hạn bề đặc trưng ở quy mô nhỏ và tập trung (20 đặc trưng), khiến câu hỏi “có thể giảm còn bao nhiêu đặc trưng” ở Chương 4 mang ý nghĩa thực tiễn trực tiếp hơn: bề đặc trưng ban đầu vốn đã không có nhiều dư thừa cần cắt bớt.



Hình 3.7: Các tầng số lượng biến trong nghiên cứu

Đối với bộ B, nghiên cứu không xác lập trước một tập đặc trưng rút gọn cố định. Toàn bộ 20 đặc trưng hợp lệ được sử dụng trong cấu hình huấn luyện chính;

khả năng rút gọn được đánh giá thông qua thực nghiệm sử dụng k đặc trưng có mức độ quan trọng cao nhất, trình bày tại Chương 4.

Nhóm đặc trưng nghiệp vụ

Đối với bộ A, 13 biến được phân vào sáu nhóm: Dư nợ và hạn mức sử dụng; Lãi suất; Kỳ hạn khoản vay; Đơn vị/chi nhánh; Sản phẩm và mục đích vay; Nhân khẩu học có IV thấp. Đối với bộ B, 20 biến được phân vào sáu nhóm: (1) Dư nợ & Thanh toán; (2) Lãi suất; (3) Kỳ hạn & Cơ cấu lại; (4) Hình thức & Mục đích vay; (5) Chi nhánh; và (6) Đặc trưng kỹ thuật.

Việc phân nhóm biến phục vụ hai mục đích: giải thích mô hình ở cấp độ nghiệp vụ và xây dựng khuyến nghị đầu tư dữ liệu. Tuy nhiên, tổng mức độ quan trọng của một nhóm chỉ phản ánh cách mô hình sử dụng dữ liệu hiện có và không cung cấp bằng chứng về quan hệ nhân quả.

3.6.5 Giá trị thiếu và chuẩn hóa

Đối với biến số, `SimpleImputer(strategy="median")` thay giá trị thiếu bằng trung vị học trên tập huấn luyện:

$$\tilde{x}_{ij} = \begin{cases} x_{ij}, & x_{ij} \text{ quan sát được,} \\ \text{median}\{x_{\ell j} : \ell \in \mathcal{T}\}, & x_{ij} \text{ thiếu,} \end{cases}$$

trong đó x_{ij} là giá trị biến j của quan sát i ; $\mathcal{T}$ là tập chỉ số huấn luyện; và $\tilde{x}_{ij}$ là giá trị sau điền khuyết.

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và

LightGBM, biến số sau điền khuyết được chuẩn hóa:

$$z_{ij} = \frac{\tilde{x}_{ij} - \mu_j}{\sigma_j},$$

trong đó μ_j và σ_j lần lượt là trung bình và độ lệch chuẩn của biến j sau điền khuyết trên tập huấn luyện; z_{ij} là giá trị chuẩn hóa. Việc chuẩn hóa đặc biệt cần cho hồi quy logistic, còn mô hình cây ít nhạy hơn với thang đo [5, 15].

3.6.6 Biến phân loại

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, mã nguồn sử dụng một bộ LabelEncoder riêng cho từng cột. Nếu xuất hiện giá trị mới chưa có trong tập huấn luyện, giá trị đó được ánh xạ về lớp đầu tiên của bộ mã hóa. Cách xử lý này bảo đảm khả năng thực thi nhưng có thể tạo ra thứ tự không có ý nghĩa đối với biến định danh; đây là một hạn chế của quy trình tiền xử lý cần được lưu ý khi diễn giải kết quả.

CatBoost sử dụng preprocessor riêng: biến số chỉ được điền trung vị, không chuẩn hóa; biến phân loại thiếu được thay bằng UNKNOWN và giữ dạng chuỗi để thuật toán xử lý trực tiếp, phù hợp cơ chế của CatBoost [24].

Việc sử dụng trung vị thay cho trung bình ở bước điền khuyết được lựa chọn dựa trên kết quả phân tích khám phá tại mục 3.5. Các biến tiền tệ trong cả hai bộ dữ liệu có phân phối lệch phải mạnh (Bảng 3.5, 3.7), độ lệch chuẩn lớn hơn giá trị trung bình nhiều lần và tỷ lệ ngoại lệ theo IQR đáng kể. Trung vị ít nhạy cảm hơn với ngoại lệ và phân phối lệch, trong khi trung bình có thể bị chi phối bởi các giá trị cực lớn, khiến giá trị điền khuyết kém đại diện cho phần lớn hồ sơ [5].

3.6.7 Ví dụ minh họa trước và sau xử lý

Để minh họa các phép biến đổi nêu trên, Bảng 3.15 trình bày ba hồ sơ thực tế trong tập kiểm định của bộ A qua từng bước xử lý.

Bảng 3.15: Ví dụ ba hồ sơ thực tế của bộ A trước và sau xử lý

Biến	Hồ sơ #5944	Hồ sơ #7333	Hồ sơ #12595
<i>Giá trị thô (không có biến nào thiếu ở bộ A)</i>			
BASE_BAL	201.000.000	5.000.000	300.000.000
CURR_BAL	77.050.000	9.184.112	180.000.000
LAISUAT	0,1173	0,0000	0,1200
UTIL_RATE	0,3833	1,8368	0,6000
MJACCTTYPCD	CNS	CNS	CNS
CURRMIACTTYPCD	TH01	VS01	TH01
<i>Sau chuẩn hóa z-score (học μ, σ trên tập huấn luyện)</i>			
BASE_BAL	−0,0334	−0,0651	−0,0173
CURR_BAL	−0,0501	−0,0628	−0,0310
LAISUAT	0,7095	−1,0111	0,7491
UTIL_RATE	−0,6374	−0,1923	−0,5710
<i>Sau mã hóa LabelEncoder (học trên tập huấn luyện)</i>			
MJACCTTYPCD	1	1	1
CURRMIACTTYPCD	12	22	12

Bước điền khuyết không làm thay đổi giá trị ở đây (bộ A không thiếu dữ liệu); ví dụ chủ yếu thể hiện tác động của mã hóa và chuẩn hóa. Hồ sơ #7333 có UTIL_RATE thô bằng 1,8368 nhưng z-score âm (−0,1923), dù tỷ lệ sử dụng cao hơn hai hồ sơ còn lại, vì UTIL_RATE trung bình toàn mẫu xấp xỉ 2,46 (Bảng 3.9) — z-score chỉ có ý nghĩa *tương đối* trong phân phối lệch, không nên diễn giải như chỉ số rủi ro tuyệt đối.

Bảng 3.16 minh họa ba hồ sơ thực tế của bộ B có giá trị thiếu tại biến Phương thức cho vay. Trong dữ liệu gốc, biến này thiếu ở 46 trong tổng số 100.617 hồ sơ, tương ứng 0,05%.

Bảng 3.16: Ví dụ ba hồ sơ thực tế của bộ B có giá trị thiếu, trước và sau xử lý

Biến	Hồ sơ #22771	Hồ sơ #26934	Hồ sơ #26961
<i>Giá trị thô</i>			
Số dư nợ theo nguyên tệ	338	13.700	8.840
Lãi suất	16,50	16,95	21,00
Phương thức cho vay	<i>NaN</i>	<i>NaN</i>	<i>NaN</i>
Nhóm nợ tự phân loại	5	5	5
<i>Sau chuẩn hóa z-score (học μ, σ trên tập huấn luyện)</i>			
Số dư nợ theo nguyên tệ	-0,0390	0,0706	0,0307
Lãi suất	1,2578	1,3667	2,3438
<i>Sau điền khuyết (most_frequent) / mã hóa</i>			
Phương thức cho vay	11	11	11

Cả ba hồ sơ đều thuộc nhóm nợ 5 và thiếu Phương thức cho vay; cỡ mẫu nhỏ nên chưa đủ khẳng định tương quan với nhóm nợ, nhưng là điểm cần theo dõi thêm. `SimpleImputer(strategy="most_frequent")` thay giá trị thiếu bằng danh mục phổ biến nhất trên tập huấn luyện (mã 11, chiếm 76,9% trong ba giá trị hợp lệ 11/14/16) trước khi mã hóa; CatBoost giữ dạng chuỗi UNKNOWN thay vì điền most_frequent. Ba biến số trong bảng cho thấy cùng hiệu ứng nén biến thiên sau chuẩn hóa: dù Số dư nợ theo nguyên tệ của hồ sơ #26934 lớn gấp hơn 40 lần hồ sơ #22771, z-score tương ứng chỉ chênh khoảng 0,11, do độ lệch chuẩn toàn mẫu (121.908,73) lớn hơn nhiều trung bình (5.092,31).

3.6.8 Phân tích số lượng và nhóm đặc trưng

Trong cấu hình phân tích, XGBoost được sử dụng cho bộ A và LightGBM cho bộ B để xác lập thứ hạng mức độ quan trọng của đặc trưng. Với các đặc trưng được sắp xếp sao cho $I_{(1)} \geq \dots \geq I_{(p)}$, tỷ lệ mức độ quan trọng tích lũy tại k được

xác định như sau:

$$Q(k) = \frac{\sum_{j=1}^k I_{(j)}}{\sum_{j=1}^p I_{(j)}} \times 100\%.$$

Trong đó $I_{(j)}$ là mức độ quan trọng của đặc trưng có thứ hạng j ; $p = 13$ đối với tập đầy đủ của bộ A và $p = 20$ đối với bộ B. Đại lượng $Q(k)$ phản ánh tỷ lệ mức độ quan trọng tích lũy, không phải tỷ lệ hiệu quả dự báo được duy trì. Vì vậy, số biến đạt 95% mức độ quan trọng chỉ được xem là cấu hình ứng viên và phải được huấn luyện, đánh giá lại trên dữ liệu ngoài mẫu. Các giá trị khảo sát là $k \in \{3, 5, 7, 9, 11, 13\}$ đối với bộ A và $k \in \{3, 5, 8, 11, 14, 17, 20\}$ đối với bộ B.

Đóng góp của nhóm đặc trưng g được xác định theo công thức:

$$I_g = \sum_{j: g(j)=g} I_j, \quad S_g = \frac{I_g}{\sum_r I_r} \times 100\%,$$

trong đó $g(j)$ ánh xạ đặc trưng j vào nhóm nghiệp vụ tương ứng; I_g là tổng mức độ quan trọng và S_g là tỷ trọng của nhóm.

Chỉ số ưu tiên dữ liệu được xác định như sau:

$$\text{Priority}_g = S_g \left(\frac{M_g}{100} + 0, 1 \right),$$

trong đó M_g là tỷ lệ thiếu trung bình của nhóm g và 0,1 là hệ số nền do tác giả quy ước. Chỉ số này chỉ có vai trò hỗ trợ sắp xếp nội dung thảo luận, chưa phải là một hàm lợi ích kinh tế đã được hiệu chỉnh và kiểm định.

Phương pháp lựa chọn biến có hai giới hạn cần lưu ý. Thứ nhất, nhiều giá trị k được khảo sát trên cùng một tập kiểm định trước khi lựa chọn cấu hình có kết quả cao nhất, do đó có thể phát sinh thiên lệch lựa chọn. Các đường cong hiệu quả theo k chỉ được sử dụng cho mục đích phân tích khám phá, không được xem là kết quả của một quy trình lựa chọn biến đã kiểm định độc lập. Thứ hai, tổng

mức độ quan trọng theo nhóm không thể thay thế thực nghiệm loại bỏ lần lượt từng nhóm đặc trưng.

3.7 Bước 4: Chia dữ liệu & cân bằng lớp

Bước thứ tư chia dữ liệu thành tập huấn luyện và kiểm định theo nguyên tắc phân tầng, sau đó xử lý mất cân bằng lớp chỉ trên tập huấn luyện.

3.7.1 Chia tập huấn luyện–kiểm định

Mã nguồn đặt tham số `RANDOM_STATE=42`, tỷ lệ kiểm định bằng 0,2 và thực hiện phép chia ngẫu nhiên có phân tầng theo nhãn. Bộ dữ liệu A được chia thành 21.600 quan sát huấn luyện và 5.401 quan sát kiểm định. Bộ dữ liệu B (kỳ 20260430) được chia thành 80.493 quan sát huấn luyện và 20.124 quan sát kiểm định (Bảng 3.3); ngoài ra, toàn bộ 100.274 quan sát của kỳ 20260531 được giữ lại làm tập kiểm tra ở kỳ sau, không tham gia bước chia phân tầng này (mục 3.4.2).

Mô hình phân loại nhóm nợ được đánh giá theo hai tầng. Tầng thứ nhất sử dụng phép chia huấn luyện–kiểm định theo tỷ lệ 80/20 để so sánh các mô hình trong cùng điều kiện. Tầng thứ hai sử dụng kiểm định chéo phân tầng lặp lại (*Repeated Stratified K-Fold*), được trình bày chi tiết tại Mục 3.8.2. Với $R = 3$ lần lặp và $F = 5$ phần, mô hình được ước lượng $R \times F = 15$ lần; mỗi quan sát xuất hiện trong phần kiểm định đúng một lần ở mỗi lượt lặp. Thiết kế này không làm tăng số quan sát thực tế, nhưng giúp giảm mức độ phụ thuộc của Recall ở các lớp hiếm vào một lần chia mẫu duy nhất.

3.7.2 Xử lý mất cân bằng lớp

Mục 2.3.1 (Chương 2) đã trình bày lý thuyết của hai hướng xử lý mất cân bằng lớp: trọng số lớp (cấp thuật toán) và SMOTE (cấp dữ liệu). Mục này chỉ trình bày cách áp dụng cụ thể cho từng bộ dữ liệu.

Đối với bộ A, chiến lược `smote_moderate` nâng số quan sát huấn luyện của các lớp 2, 3, 4 và 5 từ 1.030, 483, 627 và 2.689 lên lần lượt 3.000, 2.000, 2.000 và 5.000. Đối với bộ B, chiến lược tùy chỉnh nâng số quan sát của bốn lớp tương ứng từ 5.057, 798, 1.157 và 2.382 lên 8.000, 4.000, 4.500 và 6.000 — tương đương khoảng 5,6–11,2% số mẫu lớp đa số. Tỷ trọng mẫu tổng hợp trong từng lớp, tính bằng $(n_{\text{sau}} - n_{\text{gốc}})/n_{\text{sau}}$, dao động 36,79–80,05% cho các nhóm 2–5 của bộ B, cho thấy một số lớp phụ thuộc nhiều vào mẫu nội suy; tăng số mẫu huấn luyện không làm tăng lượng quan sát độc lập. SMOTE được thực hiện sau bước tiền xử lý và trước bước huấn luyện mô hình, chỉ tác động đến tập huấn luyện.

Đối với XGBoost, trọng số lớp được tính lại trong từng phần huấn luyện của kiểm định chéo qua `compute_sample_weights()`, không dùng tần suất lớp của phần kiểm định. Đối với CatBoost, mọi chiến lược khác `none` được ánh xạ sang cơ chế `auto_class_weights=Balanced`; SMOTE không áp dụng trực tiếp trên biến phân loại dạng chuỗi.

Chiến lược kết hợp áp dụng SMOTE rồi gán trọng số lớp sau lấy mẫu. Hai thao tác cùng thay đổi ảnh hưởng của lớp thiểu số lên quá trình học, nhưng hiệu quả cuối cùng phụ thuộc cách lấy mẫu, cách tính trọng số và thuật toán; luận văn không mặc định rằng kết hợp sẽ cải thiện kết quả — Mục 4.5 (Chương 4) điều chỉnh thực nghiệm bốn chiến lược trên từng bộ dữ liệu.

Biến phân loại sau mã hóa có thể bị SMOTE nội suy thành giá trị không

tương ứng với danh mục hợp lệ — giới hạn của thiết kế hiện tại, cần khảo sát bằng phương pháp lấy mẫu phù hợp với dữ liệu hỗn hợp. Với bộ B, kết quả Top- k báo cáo trong luận văn dùng LightGBM và SMOTE tùy chỉnh, cùng chiến lược với bảng mô hình đầy đủ (`credit_info_topk.csv`); các cấu hình khác trong ứng dụng minh họa không dùng để diễn giải đường cong Top- k này.

3.8 Bước 5: Huấn luyện mô hình

Bước thứ năm huấn luyện và tinh chỉnh các mô hình phân loại, đồng thời mô tả cách mô hình được lưu trữ, triển khai phục vụ ứng dụng, và định hướng giám sát vận hành sau này.

3.8.1 Xây dựng mô hình

Mã nguồn cài đặt Logistic Regression, Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost. Các tham số chính gồm:

- Decision Tree: độ sâu tối đa 10, tối thiểu 10 mẫu ở lá;
- Random Forest: 300 cây, độ sâu tối đa 15, tối thiểu 5 mẫu ở lá [6];
- XGBoost: 400 cây, độ sâu 6, learning rate 0,05, subsample và colsample bằng 0,8 [9];
- LightGBM: 400 cây, độ sâu 8, learning rate 0,05, subsample và colsample bằng 0,8 [16];
- CatBoost: 400 vòng lặp, độ sâu 6, learning rate 0,05 và hàm mất mát đa lớp [24].

Các giá trị trên được thiết lập cố định trong mã nguồn và không phải kết quả của quá trình tìm kiếm theo lưới. Vì vậy, luận văn không xem các cấu hình này là siêu tham số tối ưu. Đối với bộ A, môi trường tái lập hiện tại khiến Logistic Regression phát sinh lỗi tương thích giao diện lập trình ứng dụng liên quan đến tham số `multi_class`; do đó, mô hình này chưa được đưa vào bảng kết quả xác nhận chính của bộ A ở Chương 4. Đối với bộ B, cả sáu mô hình, kể cả Logistic Regression, đều chạy thành công trong môi trường dùng để tái lập kết quả của luận văn, nên bảng so sánh chính của bộ B có đầy đủ sáu mô hình.

3.8.2 Hiệu chỉnh mô hình

Kiểm định phân tầng lặp và hiệu chỉnh quyết định

Gọi m_{rf} là Macro-F1 tại lần lặp r và phần kiểm định f . Giá trị tổng hợp được xác định như sau:

$$\bar{m} = \frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F m_{rf}, \quad s_m = \sqrt{\frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F (m_{rf} - \bar{m})^2}.$$

Trong đó $\bar{m}$ là Macro-F1 trung bình và s_m là độ lệch chuẩn theo cách cài đặt `numpy.std` với mẫu số RF . Precision, Recall và F1 từng nhóm được tổng hợp tương tự. `total_support` bằng Rn_c , tức tổng số lần quan sát lớp c xuất hiện trong các tập kiểm định, không phải số khách hàng độc lập mới.

Từ xác suất $\hat{p}_{ic}$, nghiên cứu xem xét hệ số ưu tiên $b_c \geq 1$ đối với lớp hiếm:

$$\hat{y}_i = \arg \max_c (b_c \hat{p}_{ic}).$$

Trong đó $\hat{p}_{ic}$ là xác suất quan sát i thuộc lớp c ; b_c là hệ số ưu tiên, có giá trị mặc định bằng 1; và $\hat{y}_i$ là nhãn sau hiệu chỉnh. Các giá trị $b_c \in \{1, 2, 3, 5, 8, 12, 20\}$

được khảo sát nhằm tối đa hóa Macro-F1. Tuy nhiên, do hệ số được lựa chọn trên cùng tập dữ liệu dùng để hiển thị kết quả, phân tích này có nguy cơ tạo ra ước lượng lạc quan và không được sử dụng làm kết quả kiểm định chính. Trong triển khai thực tế, hệ số cần được lựa chọn trên tập xác thực riêng, cố định trước khi đánh giá trên tập kiểm tra.

Thiết kế tìm kiếm theo lưới

Bảng so sánh mô hình ở Chương 4 sử dụng một cấu hình siêu tham số cố định cho mỗi thuật toán (Mục 3.8.1). Để đánh giá mức độ nhạy của kết luận đối với lựa chọn siêu tham số, phương pháp tìm kiếm theo lưới được áp dụng cho sáu mô hình trên cả hai bộ dữ liệu. Chiến lược xử lý mất cân bằng và cách chia mẫu được giữ nguyên; chỉ các siêu tham số của bộ phân loại thay đổi. Lưới của bộ A gồm 65 cấu hình (Bảng 3.17); lưới của bộ B gồm 60 cấu hình (Bảng 3.18) và được thu gọn để phù hợp với chi phí tính toán trên 80.493 quan sát huấn luyện. Tổng cộng có 125 cấu hình được khảo sát.

Bảng 3.17: Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu A

Mô hình	Tham số và giá trị thử	Số cấu hình
Decision Tree	$\text{max_depth} \in \{5, 10, 15, 20\}$, $\text{min_samples_leaf} \in \{5, 10, 20\}$	12
Random Forest	$\text{n_estimators} \in \{100, 300, 500\}$, $\text{max_depth} \in \{10, 15, 20\}$, $\text{min_samples_leaf} \in \{5, 10\}$	18
XGBoost	$\text{max_depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,05; 0,1\}$ tại $\text{n_estimators}=400$, cộng $\text{n_estimators} \in \{200, 600\}$ tại cấu hình mặc định	11
LightGBM	tương tự XGBoost	11
CatBoost	$\text{depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,05; 0,1\}$ tại $\text{iterations}=400$	9
Logistic Regression	$C \in \{0,01; 0,1; 1,0; 10,0\}$	4

Bảng 3.18: Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu B

Mô hình	Tham số và giá trị thử	Số cấu hình
Logistic Regression	$C \in \{0,01; 0,1; 1,0; 10,0\}$	4
Decision Tree	$\text{max_depth} \in \{5, 8, 12, 20\}, \text{min_samples_leaf} \in \{5, 20\}$	8
Random Forest	$\text{n_estimators} \in \{200, 400\}, \text{max_depth} \in \{10, 20, \text{None}\}, \text{min_samples_leaf} \in \{5, 15\}$	12
XGBoost	$\text{max_depth} \in \{3, 6, 9\} \times \text{learning_rate} \in \{0,03; 0,1\} \times \text{n_estimators} \in \{200, 400\}$	12
LightGBM	tương tự XGBoost	12
CatBoost	$\text{depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,1\} \times \text{iterations} \in \{200, 400\}$	12

Không gian tìm kiếm được xác lập trước dựa trên các giá trị thường dùng của từng họ mô hình và không bao phủ toàn bộ miền siêu tham số. Nghiên cứu cũng chưa áp dụng kiểm định chéo lồng nhau; cấu hình có kết quả cao nhất được lựa chọn trên một tập kiểm định duy nhất, do đó có thể chịu ảnh hưởng của thiên lệch lựa chọn tương tự phân tích theo k đặc trưng. Vì vậy, kết quả này chỉ phản ánh độ nhạy của mô hình trong phạm vi lưới đã khảo sát, không được xem là một phép đối sánh tối ưu toàn diện. Kết quả chi tiết được trình bày tại Mục 4.6 của Chương 4.

3.8.3 Triển khai mô hình

Sau khi huấn luyện, mô hình được lưu trữ bằng pickle trong các tệp có mẫu tên `model_key.pkl`; mô hình có ROC-AUC cao nhất được ghi vào `best_model.txt` để ứng dụng lựa chọn mặc định. Chức năng *Dự báo* sử dụng mô hình đã lưu để tiếp nhận danh sách khách hàng mới ở định dạng Excel hoặc CSV, sau đó trả về nhóm nợ dự báo cùng xác suất thuộc từng nhóm.

Luận văn không quy đổi xác suất dự báo thành một thang điểm số kiểu scorecard (300–850) do chưa có dữ liệu để đối chiếu, kiểm định thang điểm đó với tổn thất thực tế; đầu ra của mô hình được giữ nguyên ở dạng nhóm nợ và xác suất theo từng nhóm, đúng với mục tiêu phân loại đã xác lập ở Chương 1.

3.8.4 Giám sát và bảo trì mô hình

Hệ thống hiện tại chưa triển khai cơ chế giám sát và bảo trì mô hình tự động. Cụ thể, phân bố dữ liệu đầu vào chưa được theo dõi định kỳ, lịch tái huấn luyện chưa được thiết lập và phiên bản dữ liệu, mô hình chưa được lưu vết một cách hệ thống ngoài các tệp mô hình cục bộ. Đây là yêu cầu cần được hoàn thiện trước khi triển khai thực tế. Các nội dung về giám sát Macro-F1, Recall của lớp rủi ro, hiệu chỉnh xác suất, phát hiện thay đổi phân bố và tái huấn luyện được đề xuất tại phần Quản trị mô hình ở Chương 5.

3.9 Bài toán bổ sung: dự báo chuyển nhóm nợ trong các tháng tiếp theo (bộ B)

Mục này trình bày phương pháp cho bài toán bổ sung đã xác lập ở Mục 1.3.1 Chương 1: dự báo khả năng một khoản vay chuyển sang nhóm nợ cao hơn trong các tháng tiếp theo. Ngân hàng đã cung cấp ba kỳ báo cáo liên tiếp của bộ B (20260430, 20260531, 20260630), cho phép ghép thành hai cặp kỳ độc lập: cặp 1 (20260430→20260531, $h = 31$ ngày) và cặp 2 (20260531→20260630, $h = 30$ ngày). Quy trình xây dựng nhãn, kiểm soát rò rỉ và thiết kế đánh giá dưới đây áp dụng giống hệt nhau cho cả hai cặp; các số liệu minh họa trong mục này lấy từ cặp 1, còn kết quả đối chiếu cả hai cặp được trình bày ở Chương 4. Bài toán này

chỉ áp dụng cho bộ B vì đây là bộ duy nhất có nhiều kỳ báo cáo liên tiếp.

3.9.1 Ghép hai kỳ báo cáo và xây dựng nhãn

Hai tệp dữ liệu của bộ B đều chứa trường Số khế ước, xác nhận thực nghiệm là khóa không trùng lặp trong từng tệp được khảo sát (không có giá trị trùng lặp ở cả 100.617 dòng của kỳ 20260430 lẫn 100.274 dòng của kỳ 20260531). Ghép hai tệp theo khóa này (inner join) thu được 98.968 khoản vay xuất hiện ở cả hai kỳ, tương ứng 98,4% số khoản vay của kỳ 20260430. Với mỗi khoản vay khớp được, nhãn chuyển nhóm được xác định bởi công thức:

$$Y_i = \mathbb{I}(G_{i,T+h} > G_{i,T}),$$

đã được nêu ở Mục 1.3.1. Toàn bộ cột đặc trưng của $\mathbf{x}_{i,T}$ trong bước ghép này lấy từ tệp kỳ 20260430; tệp kỳ 20260531 chỉ đóng góp duy nhất giá trị nhóm nợ dùng để so sánh, không có cột đặc trưng nào của kỳ 20260531 được đưa vào bước ghép.

Bảng 3.19 trình bày ma trận chuyển nhóm đầy đủ trên 98.968 khoản vay khớp được.

Bảng 3.19: Ma trận chuyển nhóm nợ từ kỳ 20260430 (T) sang kỳ 20260531 ($T + h$)

Nhóm tại T	Nhóm tại $T + h$				
	1	2	3	4	5
1	87.057	214	0	0	0
2	159	6.123	10	0	0
3	5	0	981	10	0
4	0	0	0	1.411	31
5	2	0	0	0	2.965

Trong 98.968 khoản vay, 265 khoản (0,268%) chuyển sang nhóm rủi ro cao

hơn, gồm 214 khoản 1→2, 10 khoản 2→3, 10 khoản 3→4 và 31 khoản 4→5; 166 khoản (0,168%) cải thiện nhóm; phần còn lại (99,56%) giữ nguyên nhóm. Đây là bài toán sự kiện hiếm, khác về bản chất thống kê so với bài toán phân loại 5 nhóm đã trình bày ở các mục trước; thiết kế đánh giá riêng được trình bày ở Mục 3.9.4.

3.9.2 Kiểm soát nguy cơ rò rỉ thông tin

Tập đặc trưng của bài toán chuyển nhóm được xây dựng bằng đúng các hàm đã dùng cho bài toán phân loại tại một thời điểm (Mục 3.6.4), áp dụng lên khung dữ liệu đã ghép: lọc theo phân loại nghiệp vụ `FEATURE_GROUPS`, sau đó sinh bốn đặc trưng kỹ thuật từ ngày giải ngân, ngày kết thúc khế ước và `ETL_DATE`. Vì cột nhóm nợ của kỳ 20260531 không nằm trong danh mục `FEATURE_GROUPS`, cơ chế lọc theo danh sách cho phép (whitelist) loại trừ cột này khỏi tập đặc trưng một cách cấu trúc, không phụ thuộc vào việc người thực hiện có nhớ loại bỏ hay không. Nhờ đó, 20 đặc trưng đưa vào mô hình (12 biến số gồm 4 biến kỹ thuật và 8 biến phân loại) được xây dựng từ bản ghi của kỳ T . Việc các giá trị này đã thực sự sẵn có tại thời điểm ra quyết định còn cần được kiểm chứng bằng lịch sử cập nhật và nguồn gốc dữ liệu; thời điểm ghi trên tệp tự thân chưa loại trừ khả năng cập nhật hồi tố.

Đây là điểm khác biệt căn bản so với việc dùng số ngày quá hạn hiện tại để phân loại lại nhóm nợ hiện tại đã phân tích ở Mục 1.1.3: trường hợp đó là vòng lặp tuần hoàn vì biến đầu vào và nhãn cùng mô tả một thời điểm, biến đầu vào gần như là căn cứ trực tiếp hình thành nhãn. Ở bài toán chuyển nhóm, biến đầu vào mô tả trạng thái tại T còn nhãn mô tả diễn biến đến $T + h$ với $h = 31$ ngày;

cách xây dựng này loại các cột lấy từ kỳ sau khỏi $\mathbf{x}_{i,T}$.

Tuy vậy, cần lưu ý hai điểm khi diễn giải mức độ quan trọng của đặc trưng ở Chương 4. Thứ nhất, các biến phản ánh trạng thái dư nợ và lãi tại T (Số dư nợ theo nguyên tệ, Lãi phải thu hạch toán nội bảng, Lãi chưa thu hạch toán ngoại bảng) có thể đã mang dấu hiệu sớm của suy giảm chất lượng tín dụng; các tín hiệu này có thể được dùng để dự báo nếu đã sẵn có tại thời điểm đánh giá và không bị cập nhật từ thông tin kỳ sau. Thứ hai, Số lần cơ cấu lại thời hạn trả nợ có thể phản ánh phản ứng của ngân hàng trước dấu hiệu khó khăn đã nhận biết từ trước, nên tương quan giữa biến này và nhãn chuyển nhóm cần được diễn giải thận trọng, không suy diễn quan hệ nhân quả một chiều.

3.9.3 Rủi ro sai lệch do loại khoản vay không khớp

Nhãn chuyển nhóm chỉ xác định được cho khoản vay khớp ở cả hai kỳ; 1.649 khoản vay của kỳ 20260430 không còn xuất hiện ở kỳ 20260531 (có thể do tắt toán hoặc xóa nợ, hai file không phân biệt được nguyên nhân) bị loại khỏi mẫu. Bảng 3.20 đối chiếu phân bố nhóm nợ tại T giữa nhóm bị loại và nhóm được giữ lại.

Bảng 3.20: Phân bố nhóm nợ tại T của khoản vay bị loại so với khoản vay được giữ lại

Nhóm tại T	Bị loại	Tỷ lệ trong nhóm bị loại (%)	Được giữ	Tỷ lệ loại trong nhóm (%)
1	1.604	97,27	87.271	1,80
2	29	1,76	6.292	0,46
3	2	0,12	996	0,20
4	4	0,24	1.442	0,28
5	10	0,61	2.967	0,34

Có 97,27% khoản vay bị loại thuộc nhóm 1 tại T ; tỷ lệ bị loại trong riêng

nhóm 1 là 1,80%, cao hơn các nhóm còn lại. Phân bố này mô tả đặc điểm của các khoản vay không khớp, nhưng không xác định được nguyên nhân vắng mặt ở kỳ sau. Do thiếu thông tin phân biệt tất toán, xóa nợ và thay đổi ghi nhận, luận văn chưa thể loại trừ sai lệch chọn mẫu hoặc ước lượng số sự kiện chuyển nhóm trong các khoản vay bị loại.

3.9.4 Thiết kế đánh giá cho sự kiện hiếm

Luận văn tính average precision bằng hàm `average_precision_score` và ký hiệu là PR-AUC trong các bảng:

$$AP = \sum_n (R_n - R_{n-1}) P_n,$$

trong đó P_n và R_n là Precision và Recall tại ngưỡng thứ n . Đây là tổng có trọng số theo mức tăng Recall, khác với diện tích tính bằng quy tắc hình thang trên đường cong Precision–Recall [25]. Tỷ lệ sự kiện dương được dùng làm mức tham chiếu của xếp hạng ngẫu nhiên; tỷ số AP so với tỷ lệ này không phải tỷ số lợi ích kinh tế.

Với tỷ lệ sự kiện dương 0,268% (265/98.968), các chỉ tiêu và cách chia mẫu đã dùng cho bài toán 5 lớp cần điều chỉnh trên ba điểm.

Thứ nhất, một bộ phân loại luôn dự báo *không xấu đi* có Accuracy bằng 0,997322 nhưng Weighted-F1 chỉ bằng 0,995985 và Recall lớp dương bằng 0. Vì vậy, luận văn dùng average precision làm tiêu chí chính của bài toán chuyển nhóm, đồng thời báo cáo Precision/Recall lớp dương và kết quả tại các tỷ lệ ưu tiên rà soát. Ngưỡng 0,5 chỉ là mốc minh họa, chưa được tối ưu theo chi phí nghiệp vụ.

Thứ hai, đánh giá chính dựa trên kiểm định chéo phân tầng lặp lại (RepeatedStratifiedKFold, 5 phần $\times$ 10 lần lặp, cùng phương pháp nhưng khác số lần lặp so với Mục 3.8.2), không dựa trên một lần chia 80/20 duy nhất: mỗi phần kiểm định trong 5 phần chỉ chứa khoảng 53 sự kiện dương, nên một lần chia đơn có thể phản ánh may rủi của riêng lần chia đó hơn là năng lực thật của mô hình. Một lần chia 80/20 minh họa vẫn được thực hiện để tạo ma trận nhầm lẫn, đường cong Precision-Recall và giải thích SHAP, nhưng bằng chứng chính về hiệu năng là kết quả kiểm định chéo lặp lại.

Thứ ba, khác với bài toán phân loại tại một thời điểm, nơi kỳ 20260531 đóng vai trò tập kiểm tra ở kỳ sau ngoài thời gian (Mục 4.4.3), mỗi cặp $(T, T + h)$ của bài toán chuyển nhóm dùng trọn cả hai kỳ báo cáo để ghép nhãn nên không còn kỳ nào khác trong CÙNG cặp để làm tập kiểm tra ngoài thời gian riêng. Việc có hai cặp độc lập (cặp 1 và cặp 2) khắc phục một phần hạn chế này: cặp 2 đóng vai trò kiểm tra ngoài thời gian cho kết luận rút ra từ cặp 1, theo hai cách — đối chiếu trực tiếp hiệu năng của cùng một cấu hình mô hình trên hai cặp, và kiểm định chuyển giao ngoài thời gian nghiêm ngặt hơn (huấn luyện một lần trên cặp 1, chấm điểm trực tiếp trên cặp 2 không huấn luyện lại). Kết quả của cả hai phép kiểm tra được trình bày ở Chương 4; do mới có hai cặp kỳ quan sát, việc khái quát hóa sang nhiều giai đoạn khác trong tương lai vẫn là hướng cần tiếp tục.

Bốn chiến lược xử lý mất cân bằng được so sánh: không xử lý, trọng số lớp nghịch đảo tần suất (`class_weight`), SMOTE với mục tiêu oversample vừa phải cho lớp thiểu số, và chiến lược kết hợp cả hai (Mục 3.7.2). Do CatBoost ánh xạ mọi chiến lược khác none về cùng cơ chế `auto_class_weights=Balanced`, ba chiến lược `class_weight`/SMOTE/kết hợp không tạo thêm khác biệt so với nhau đối với riêng mô hình này nên chỉ hai chiến lược được so sánh cho

CatBoost. Kết quả đối sánh được trình bày tại Chương 4.

3.10 Tóm tắt chương

Chương 3 đã trình bày dữ liệu, công nghệ và các bước phương pháp được sử dụng trong nghiên cứu, gồm phân tích khám phá, làm sạch, kiểm soát rò rỉ, xây dựng đặc trưng, tính IV, xử lý giá trị thiếu, mã hóa, chuẩn hóa, chia mẫu có phân tầng và xử lý mất cân bằng lớp bằng SMOTE hoặc trọng số lớp. Tập đặc trưng cuối cùng gồm 11 biến (cấu hình chính) hoặc 13 biến (cấu hình mở rộng) đối với bộ A, và 20 biến đối với bộ B; sáu thuật toán được xây dựng và đánh giá, kết hợp kiểm định chéo phân tầng lặp lại và khảo sát 125 cấu hình siêu tham số. Các lựa chọn kỹ thuật then chốt, gồm điền khuyết bằng trung vị, giới hạn UTIL_RATE trong khoảng $[0, 10]$, ngưỡng IV bằng 0,02 và mốc ETL_DATE cho các biến thời gian của bộ B, đều được xác lập trên cơ sở đặc điểm thống kê và ý nghĩa nghiệp vụ của dữ liệu đã trình bày ở trên.

Chương cũng trình bày phương pháp cho bài toán bổ sung dự báo chuyển nhóm nợ trong các tháng tiếp theo trên bộ B, áp dụng đồng nhất cho hai cặp kỳ báo cáo thật (cặp 1: 20260430→20260531, $h = 31$ ngày, 265 sự kiện dương/98.968; cặp 2: 20260531→20260630, $h = 30$ ngày): ghép khoản vay qua khóa Số khế ước, xây nhãn từ diễn biến nhóm nợ $T \rightarrow T + h$, kiểm soát các cột lấy từ kỳ sau, điều chỉnh thiết kế đánh giá phù hợp với sự kiện hiếm (PR-AUC, Recall@k, kiểm định chéo lặp lại), và kiểm tra độ ổn định của kết quả giữa hai cặp kỳ độc lập.

Trên cơ sở quy trình phương pháp nêu trên, Chương 4 trình bày hệ thống thước đo, kết quả đối sánh mô hình, hiệu quả theo số lượng đặc trưng, mức đóng góp của các nhóm đặc trưng, kết quả giải thích bằng SHAP, độ nhạy của siêu

tham số, và kết quả của bài toán dự báo chuyển nhóm nợ.

Chương 4

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

Chương này trình bày kết quả phân loại nhóm nợ trên hai bộ dữ liệu và dự báo chuyển nhóm nợ trong các tháng tiếp theo trên bộ B. Các kết quả được thảo luận theo ba câu hỏi nghiên cứu, với trọng tâm là hiệu năng ngoài mẫu, vai trò của đặc trưng và giới hạn của khả năng ứng dụng.

4.1 Nguyên tắc báo cáo kết quả

Các bảng trong chương tổng hợp kết quả thực nghiệm đã lưu trong thư mục `code/results`, sử dụng bộ dữ liệu A và hai kỳ quan sát của bộ B. Bộ A được chia 80/20 có phân tầng với `random_state=42`. Với bài toán năm lớp của bộ B, tập kiểm định 20% kỳ 20260430 được dùng để so sánh cấu hình, còn kỳ 20260531 được dùng để đánh giá bổ sung theo thời gian. Hai kỳ có nhiều khoản vay trùng nhau, nên không diễn giải tập kỳ sau là mẫu khách hàng độc lập (Mục 3.4.2). Kết quả giữa hai bộ chỉ được đối chiếu về xu hướng do khác biệt về biên đích, quy mô và đặc trưng.

Đối với bộ A, bảng so sánh mô hình sử dụng 11 biến trong cấu hình chính và chiến lược `smote_moderate`; phân tích theo số lượng biến được thực hiện trên tập 13 biến. Đối với bộ B, bảng so sánh sử dụng 20 đặc trưng và chiến lược SMOTE tùy chỉnh; thí nghiệm với k đặc trưng quan trọng nhất cũng dùng chiến lược SMOTE tùy chỉnh này. Vì vậy, mỗi kết quả chỉ có ý nghĩa trong cấu hình thực nghiệm tương ứng và không được xem là kết quả của quá trình tìm kiếm siêu tham số.

Bảng so sánh chính của bộ A giữ năm mô hình có kết quả được báo cáo; Logistic Regression chưa được tái lập thành công trong cùng quy trình, nên không được dùng để kết luận về thứ hạng trên bộ A. Một số giá trị của mô hình này còn lưu trong khảo sát siêu tham số trước đó được đánh dấu riêng tại Mục 4.6. Với bộ B, bảng so sánh có sáu mô hình. Ngoài ra, lần chạy bổ sung về chiến lược mất cân bằng cho kết quả khác bảng chính; mức chênh lệch được công bố tại Mục 4.5. Việc đối chiếu tập kết quả chưa thay thế cho tái lập toàn bộ các bảng trong một môi trường thống nhất.

4.2 Thước đo đánh giá

4.2.1 Ma trận nhầm lẫn đa lớp

Với $K = 5$ lớp, phần tử C_{ab} của ma trận nhầm lẫn là số quan sát có lớp thực a nhưng được dự báo thành lớp b . Đường chéo C_{aa} là số dự báo đúng của lớp a . Trong bài toán này, ma trận đa lớp phù hợp hơn cách ký hiệu TP–TN của bài toán nhị phân.

4.2.2 Precision, Recall và F1 theo lớp

Với lớp k :

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k},$$
$$F1_k = \frac{2P_k R_k}{P_k + R_k}.$$

Trong đó TP_k là số quan sát lớp k được dự báo đúng; FP_k là số quan sát thuộc lớp khác nhưng bị dự báo thành k ; FN_k là số quan sát lớp k bị dự báo sang lớp khác; P_k là Precision; R_k là Recall.

Macro-F1 cho trọng số bằng nhau cho năm lớp:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k,$$

trong đó $K = 5$. Weighted-F1 dùng tỷ trọng hỗ trợ:

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k,$$

trong đó n_k là số quan sát thực của lớp k và $N = \sum_k n_k$. Ở bộ B, nhóm 1 chiếm 88,34% (Bảng 3.3), nên Weighted-F1 vẫn có thể ở mức cao dù Recall của các nhóm hiếm thấp hơn nhiều; vì vậy Macro-F1 được ưu tiên làm tiêu chí chính. Bộ A cân bằng hơn nhưng nhóm 1 vẫn chiếm 77,65%, nên cùng nguyên tắc báo cáo được áp dụng.

4.2.3 Accuracy và ROC-AUC đa lớp

$$\text{Accuracy} = \frac{\sum_{k=1}^K C_{kk}}{N}.$$

Accuracy là tỷ lệ tổng dự báo đúng nhưng bị chi phối bởi lớp 1.

ROC-AUC được tính theo One-vs-Rest và lấy trung bình macro:

$$\text{AUC}_{\text{macro, OvR}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}(y^{(k)}, \hat{p}^{(k)}),$$

trong đó $y^{(k)}$ là nhãn nhị phân “thuộc/không thuộc lớp k ”; $\hat{p}^{(k)}$ là xác suất dự báo cho lớp k ; và AUC đo khả năng xếp hạng giữa mẫu dương và âm [13].

Ngoài bốn chỉ tiêu trên, Chương 3 (mục 3.8.2) đã trình bày cơ chế `RepeatedStratifiedKFold` và hiệu chỉnh ngưỡng theo lớp, hai công cụ hỗ trợ ước lượng ổn định hơn cho các nhóm nợ hiếm; hai công cụ này được nhắc lại khi cần trong các mục kết quả dưới đây.

4.3 Kết quả trên bộ dữ liệu A

4.3.1 So sánh mô hình trên bộ 11 đặc trưng

Bảng 4.1: Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Decision Tree	0,8847	0,5896	0,8786	0,8765
Random Forest	0,9052	0,6179	0,8917	0,9182
XGBoost	0,9096	0,6442	0,8982	0,9201
LightGBM	0,9113	0,6484	0,9001	0,9181
CatBoost	0,7497	0,5454	0,8033	0,9006

LightGBM đạt Macro-F1 cao nhất (0,6484), tiếp theo là XGBoost (0,6442). XGBoost đồng thời đạt ROC-AUC macro cao nhất (0,9201). Do mô-đun phân tích đặc trưng trong mã nguồn sử dụng XGBoost làm cấu hình mặc định, các phân tích tiếp theo đối với bộ A được thực hiện trên mô hình này nhằm bảo đảm tính nhất quán với quy trình thực nghiệm.

4.3.2 Hiệu năng theo số lượng đặc trưng

Bảng 4.2: Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A

k	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
3	0,9021	0,6152	0,8873	0,8874
5	0,9022	0,6184	0,8878	0,8887
7	0,9019	0,6212	0,8887	0,9014
9	0,9093	0,6383	0,8975	0,9203
11	0,9074	0,6364	0,8958	0,9223
13	0,9098	0,6434	0,8977	0,9192

Trong các tập gồm k đặc trưng quan trọng nhất, tập đầy đủ 13 biến đạt Macro-F1 cao nhất, nhưng đường cong không tăng đơn điệu (tập 11 biến đứng đầu thấp hơn tập 9 biến đứng đầu). Huấn luyện theo đúng danh sách 11 biến của cấu hình chính (khác với chọn 11 biến quan trọng nhất) cho XGBoost Macro-F1 bằng 0,6442, cao hơn 0,6434 của tập 13 biến — bổ sung lại SEX và LOAIKH không cải thiện đáng kể. Tỷ lệ $\rho_{A,9} = 0,6383/0,6434 \approx 0,9920$ cho thấy cấu hình 9 biến đạt khoảng 99,20% Macro-F1 của tập 13 biến — mốc nhỏ nhất trong các k đã khảo sát đạt ít nhất 99%, không chứng minh 9 là số biến tối thiểu trên toàn bộ không gian lựa chọn.

4.3.3 Nhóm đặc trưng và chỉ số ưu tiên dữ liệu

Bảng 4.3: Tỷ trọng mức độ quan trọng theo nhóm nghiệp vụ của bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng (%)
Kỳ hạn khoản vay	40,1
Sản phẩm và mục đích vay	21,9
Dư nợ và hạn mức sử dụng	12,9
Đơn vị/Chi nhánh	9,4
Nhân khẩu học có IV thấp	8,1
Lãi suất	7,6

Hai biến DAYS_TO_MATURITY và LOAN_TENURE_DAYS có mức độ quan trọng lần lượt bằng 24,48% và 15,63%, đưa tổng tỷ trọng của nhóm Kỳ hạn khoản vay lên 40,1%. Nhóm Sản phẩm và mục đích vay có tỷ trọng lớn thứ hai, đạt 21,9%.

Đường cong tích lũy cần 12 trong tổng số 13 biến để đạt 95% mức độ quan trọng và cần toàn bộ 13 biến để đạt 99%. Kết quả này không mâu thuẫn với việc cấu hình 9 biến duy trì 99,20% Macro-F1, bởi mức độ quan trọng tích lũy và hiệu quả dự báo ngoài mẫu là hai đại lượng khác nhau.

Các nhóm đặc trưng của bộ A hầu như không có giá trị thiếu; riêng nhóm Nhân khẩu học có IV thấp ghi nhận tỷ lệ thiếu trung bình 2,05%. Do đó, việc chỉ số quy ước xếp nhóm Kỳ hạn khoản vay ở vị trí đầu chủ yếu xuất phát từ mức độ quan trọng của nhóm, không phải từ sự thiếu hụt dữ liệu. Kết quả này gợi ý ngân hàng cần duy trì chất lượng các trường ngày và phát triển dữ liệu lịch sử theo thời gian, thay vì chỉ bổ sung thêm các trường kỳ hạn tĩnh.

4.4 Kết quả trên bộ dữ liệu B

4.4.1 Mức độ mất cân bằng và hệ quả đánh giá

Tập kiểm định (20% của kỳ 20260430) gồm 20.124 quan sát, trong đó nhóm 1 có 17.776 quan sát. Một bộ phân loại luôn dự báo nhóm 1 đã có Accuracy:

$$\text{Accuracy}_{\text{majority}} = \frac{17.776}{20.124} = 0,8834.$$

Trong đó 17.776 là số mẫu nhóm 1 và 20.124 là tổng số mẫu kiểm định. Trên tập kiểm tra ở kỳ sau 20260531, tỷ lệ tương ứng là $88.527/100.274 = 0,8829$, gần với tỷ lệ của kỳ huấn luyện. Sự tương đồng về tỷ trọng nhóm 1 chưa đủ để kết luận phân phối đặc trưng hoặc quan hệ giữa đầu vào và nhãn ổn định. Vì vậy, Accuracy khoảng 88% chưa đủ để chứng minh mô hình nhận diện được rủi ro. Kết quả cần được đọc cùng Macro-F1 và Recall từng nhóm, phù hợp cảnh báo của Brown và Mues về đánh giá dữ liệu tín dụng mất cân bằng [7].

4.4.2 So sánh các mô hình

Bảng 4.4: Kết quả ngoài mẫu của các mô hình trên 20 đặc trưng — tập kiểm định (20% kỳ 20260430)

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Logistic Regression	0,9056	0,3959	0,8680	0,8660
Decision Tree	0,9328	0,6590	0,9158	0,9129
Random Forest	0,9337	0,6587	0,9158	0,9371
XGBoost	0,9363	0,6846	0,9197	0,9403
LightGBM	0,9367	0,6930	0,9206	0,9411
CatBoost	0,6913	0,6046	0,7673	0,9195

Khác với bộ A, cả sáu mô hình đều được thực thi thành công trên bộ B. LightGBM đạt Macro-F1 cao nhất, bằng 0,6930, trong khi XGBoost đạt 0,6846; mức chênh lệch 0,0084 vẫn nhỏ hơn biên độ biến động theo siêu tham số của chính hai mô hình này tại Mục 4.6, lần lượt bằng 0,0541 và 0,0763. LightGBM đồng thời đạt Accuracy và ROC-AUC macro cao nhất, bằng 0,9367 và 0,9411, nên được lựa chọn cho các phân tích tiếp theo về đặc trưng và SHAP. Logistic Regression và CatBoost có Macro-F1 thấp hơn các mô hình dựa trên cây còn lại trong cấu hình thực nghiệm này.

Accuracy của CatBoost, bằng 0,6913, thấp hơn hẳn năm mô hình còn lại trong khi ROC-AUC macro vẫn đạt 0,9195. Khoảng cách này cho thấy mô hình xếp hạng xác suất tốt nhưng gán nhãn lệch khỏi nhóm đa số tại ngưỡng arg max, hệ quả của việc sử dụng trọng số lớp; vì vậy Accuracy của CatBoost không so sánh trực tiếp được với các mô hình khác. Logistic Regression đạt Accuracy 0,9056 nhưng Macro-F1 chỉ 0,3959 — minh họa rõ nhất cho nhận định rằng Accuracy bị nhóm đa số chi phối và không phản ánh khả năng phát hiện nợ xấu.

4.4.3 Đánh giá trên tập kiểm tra ở kỳ sau (20260531)

Bên cạnh tập kiểm định nội bộ, bộ B được đánh giá bổ sung trên toàn bộ 100.274 hồ sơ của kỳ báo cáo kế tiếp, 20260531. Quy trình tiền xử lý và mô hình đã được ước lượng từ kỳ 20260430 được giữ nguyên, không huấn luyện lại trên dữ liệu mới. Kết quả được trình bày tại Bảng 4.5.

Bảng 4.5: Kết quả trên tập kiểm tra ở kỳ sau 20260531 (không tham gia huấn luyện/chọn mô hình)

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Logistic Regression	0,8915	0,3455	0,8560	0,8257
Decision Tree	0,8919	0,4693	0,8807	0,8354
Random Forest	0,9066	0,5065	0,8917	0,8961
XGBoost	0,9060	0,4911	0,8897	0,9202
LightGBM	0,9071	0,4995	0,8915	0,9229
CatBoost	0,7066	0,4105	0,7682	0,9045

Thứ hạng mô hình thay đổi giữa hai tầng đánh giá. LightGBM có Macro-F1 cao nhất trên tập kiểm định nội bộ (0,6930) nhưng đạt 0,4995 trên tập kiểm tra ở kỳ sau; Random Forest tăng từ vị trí thứ tư (0,6587) lên cao nhất ở kỳ sau (0,5065) — không phải vì hiệu năng tuyệt đối tăng mà vì mức giảm thấp nhất trong nhóm mô hình cây (23,1%, so với 12,7–32,1% của các mô hình khác). ROC-AUC macro của LightGBM và XGBoost giảm ít hơn Macro-F1 (từ 0,9411→0,9229 và 0,9403→0,9202), cho thấy khả năng xếp hạng xác suất được duy trì tốt hơn chất lượng nhãn tại ngưỡng quyết định hiện hành. Kết quả củng cố nhận định: phép chia ngẫu nhiên có phân tầng trong cùng một kỳ dữ liệu có thể ước lượng lạc quan khả năng tổng quát hóa theo thời gian, qua đó khẳng định yêu cầu chia mẫu theo thời gian đối với bài toán dự báo chuyển nhóm nợ.

Thứ hạng theo Macro-F1 và Accuracy cũng không trùng nhau ở kỳ sau: LightGBM giữ Accuracy và ROC-AUC macro cao nhất (0,9071 và 0,9229), trong khi Random Forest dẫn đầu Macro-F1 và Weighted-F1 (0,5065 và 0,8917) — khoảng cách giữa hai mô hình dưới 0,007 ở ba chỉ tiêu đầu, chỉ ROC-AUC macro chênh 0,0268. Kết luận về mô hình dẫn đầu ở kỳ sau vì vậy phụ thuộc chỉ tiêu được chọn, chưa đủ cơ sở coi là ổn định.

4.4.4 Kết quả chi tiết theo nhóm nợ

Bảng 4.6 trình bày Precision, Recall, F1 của LightGBM, mô hình dẫn đầu tập kiểm định, trên cả hai tầng đánh giá.

Bảng 4.6: Precision, Recall và F1 của LightGBM theo nhóm nợ — tập kiểm định vs. tập kiểm tra ở kỳ sau

Nhóm	Kiểm định (20% kỳ 20260430)				Kiểm tra kỳ sau (20260531)			
	Số mẫu	Precision	Recall	F1	Số mẫu	Precision	Recall	F1
1	17.776	0,9452	0,9990	0,9714	88.527	0,9412	0,9877	0,9639
2	1.264	0,8133	0,1930	0,3120	6.339	0,8073	0,1712	0,2824
3	200	0,5829	0,5100	0,5440	991	0,2644	0,5409	0,3552
4	289	0,7178	0,7128	0,7153	1.421	0,3499	0,7945	0,4858
5	595	0,9390	0,9059	0,9222	2.996	0,9949	0,2583	0,4102

Với từ 200 đến 1.421 quan sát ở mỗi nhóm hiểm tùy theo tầng đánh giá, Recall trong Bảng 4.6 có độ tin cậy cao hơn trường hợp chỉ có một số ít quan sát. Tuy nhiên, các chỉ tiêu vẫn có thể chịu ảnh hưởng của khác biệt phân bố giữa hai kỳ dữ liệu.

Trên tập kiểm định, Recall nhóm 3 và 4 lần lượt bằng 0,5100 và 0,7128, trong khi nhóm 2 chỉ đạt 0,1930. Luận văn chưa xác định ngưỡng chấp nhận nghiệp vụ nên không xem các giá trị này là bằng chứng mô hình đã đáp ứng yêu cầu vận hành. Trên kỳ sau, Recall nhóm 3 tăng nhẹ lên 0,5409 và Recall nhóm 4 tăng lên 0,7945, nhưng Precision của hai nhóm giảm mạnh xuống 0,2644 và 0,3499 — mô hình phát hiện được nhiều hồ sơ thuộc hai nhóm này hơn nhưng đánh đổi bằng số cảnh báo sai tăng gấp nhiều lần. Recall nhóm 5 giảm từ 0,9059 xuống 0,2583, cho thấy phần lớn hồ sơ thuộc nhóm này bị phân loại sang nhóm khác. Nhóm 2 tiếp tục có Recall thấp nhất, bằng 0,1712.

Bảng 4.7: Recall nhóm 3 và nhóm 4 theo mô hình — tập kiểm định

Mô hình	Recall nhóm 3	Recall nhóm 4
Decision Tree	0,545	0,599
Random Forest	0,505	0,675
XGBoost	0,480	0,727
LightGBM	0,510	0,713
CatBoost	0,645	0,689
Logistic Regression	0,020	—

CatBoost đạt Recall nhóm 3 cao nhất (0,645) nhưng Accuracy chỉ 0,6913 và Weighted-F1 0,7673 do dùng trọng số lớp; Logistic Regression gần như không nhận diện nhóm 2–3 (Recall 0,0008 và 0,020) dù Accuracy tổng thể bằng 0,9056. Hai trường hợp đối lập này làm rõ giới hạn của xếp hạng theo một chỉ số duy nhất: CatBoost đánh đổi Accuracy để đạt Recall cao và đều ở nhóm hiếm, còn Logistic Regression đạt Accuracy cao bằng cách dự báo gần như toàn bộ hồ sơ về nhóm 1. Lựa chọn mô hình triển khai vì vậy không nên chỉ dựa vào một thứ hạng chung, mà cần gắn với chi phí bỏ sót/rà soát cụ thể — và theo Mục 4.4.3, cũng không nên chỉ dựa vào thứ hạng trên tập kiểm định cùng kỳ dữ liệu.

4.4.5 Đánh giá các lớp hiếm bằng quy trình kiểm định lặp

Quy trình kiểm định chéo phân tầng lặp lại báo cáo giá trị trung bình và độ lệch chuẩn của Precision, Recall và F1 theo từng lớp qua nhiều lần chia mẫu. Với cấu hình 3×5 phần, mỗi hồ sơ thuộc nhóm 3 và 4 xuất hiện trong phần kiểm định ba lần qua các lượt lặp. Cách tiếp cận này làm giảm mức độ phụ thuộc của ước lượng vào một lần chia mẫu, nhưng không làm tăng số khách hàng độc lập và không thể thay thế dữ liệu ngoài thời gian.

Đối với XGBoost, trọng số nghịch đảo tần suất được tính và truyền riêng

trong từng phần huấn luyện của kiểm định chéo. Tuy nhiên, Bảng 4.4 sử dụng chiến lược SMOTE tùy chỉnh, nên cơ chế trọng số không ảnh hưởng trực tiếp đến các kết quả được báo cáo trong bảng này.

Phân tích hiệu chỉnh lớp hiếm nhân xác suất dự báo của từng lớp với một hệ số trước khi áp dụng phép arg max. Đây là phân tích độ nhạy đối với sự đánh đổi giữa Precision và Recall, không phải một mô hình độc lập. Do hệ số được lựa chọn trên chính tập đánh giá, Macro-F1 sau hiệu chỉnh không được đưa vào bảng kết quả chính. Một thiết kế chặt chẽ hơn cần tách riêng tập huấn luyện, tập xác thực và tập kiểm tra; hệ số được lựa chọn trên tập xác thực và chỉ đánh giá một lần trên tập kiểm tra.

4.4.6 Hiệu năng theo số lượng đặc trưng

Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Các đặc trưng được sắp xếp theo mức độ quan trọng của mô hình LightGBM sử dụng tập đầy đủ. Mô hình sau đó được huấn luyện lại với từng giá trị k , trong khi chiến lược SMOTE được giữ nguyên. Kết quả được trình bày tại Bảng 4.8.

Bảng 4.8: Hiệu năng LightGBM theo số lượng đặc trưng Top- k

k	Macro-F1	ROC-AUC macro
3	0,6606	0,9085
5	0,6767	0,9289
8	0,6961	0,9406
11	0,7017	0,9410
14	0,7009	0,9407
17	0,7034	0,9410
20 (đầy đủ)	0,6930	0,9411

Thứ tự đặc trưng được lấy theo mức độ quan trọng Gain của LightGBM. Đây

là điểm cần lưu ý khi đối chiếu với các phiên bản kết quả trước: LightGBM mặc định trả về số lần chia nhánh (split count) chứ không phải Gain, nên cấu hình hiện tại đặt tham số `importance_type="gain"` để thống nhất với XGBoost. Thứ tự đặc trưng theo Gain khác đáng kể so với theo số lần chia nhánh, và điều này ảnh hưởng trực tiếp đến đường cong Top- k ở các giá trị k nhỏ.

Cấu hình 17 đặc trưng đạt Macro-F1 cao nhất (0,7034) so với 0,6930 của tập đầy đủ 20 biến; cấu hình 8 đặc trưng (40% số biến) đạt 0,6961, cũng cao hơn tập đầy đủ. Kết quả tại $k = 8, 11, 14, 17$ nằm trong khoảng 0,696–0,704 (thay đổi không đáng kể); ngay tại $k = 3$, Macro-F1 đã đạt 0,6606 (95,3% mức tập đầy đủ). So với bộ A, bộ B cho bằng chứng rõ hơn về tính không đơn điệu giữa số lượng đặc trưng và hiệu quả dự báo — việc bổ sung đặc trưng không tất yếu cải thiện kết quả, và ba đặc trưng có Gain cao nhất đã mang phần lớn năng lực dự báo. Các giá trị k được khảo sát và lựa chọn trên cùng tập kiểm định (20.124 hồ sơ), nên đường cong chỉ có ý nghĩa khám phá; thiên lệch lựa chọn vẫn áp dụng như đã nêu ở bộ A, và cấu hình rút gọn cần được xác nhận lại trên tập kiểm tra ở kỳ sau hoặc quy trình xác thực lồng nhau trước khi khuyến nghị triển khai.

Có thể giảm còn bao nhiêu đặc trưng?

Theo mức độ quan trọng tích lũy (Gain) của LightGBM, 8 đặc trưng đầu tiên chiếm 95% và 9 đặc trưng chiếm 99% tổng mức độ quan trọng. Mức độ tập trung này cao hơn so với bộ A, nơi cần lần lượt 12 và 13 đặc trưng để đạt hai ngưỡng tương ứng. Tại $k = 8$, tỷ lệ Macro-F1 so với tập đầy đủ ($k = 20$) là:

$$\rho_8 = \frac{0,6961}{0,6930} \approx 1,0045.$$

Trong đó 0,6961 là Macro-F1 của cấu hình 8 biến và 0,6930 là Macro-F1 của tập đầy đủ 20 biến trong cùng quy trình đánh giá. Chênh lệch quan sát được là nhỏ và cần được kiểm định lại trước khi khái quát.

Do đó, cấu hình 8 trong tổng số 20 đặc trưng được xem là một ứng viên rút gọn vì không làm giảm Macro-F1 trên tập kiểm định. Cấu hình này cần được xác nhận trên tập kiểm tra ở kỳ sau kỳ 20260531 hoặc bằng quy trình xác thực lồng nhau trước khi đưa ra khuyến nghị triển khai.

Ở cấp dữ liệu thô, quy trình đã giảm từ 33 cột chung giữa hai kỳ báo cáo xuống 20 đặc trưng hợp lệ, tương đương loại:

$$\frac{33 - 20}{33} \times 100\% \approx 39,39\%.$$

Mức giảm này chủ yếu bắt nguồn từ việc loại bỏ các trường định danh, trường có nguy cơ rò rỉ thông tin, trường ngày ban đầu và một cột hằng số, thay vì từ quá trình lựa chọn dựa trên hiệu quả dự báo. Số cột chung giữa hai kỳ cũng bị giới hạn bởi cấu trúc dữ liệu thực tế (Mục 3.6.4).

4.4.7 Đóng góp của các nhóm đặc trưng

Bảng 4.9: Tỷ trọng mức độ quan trọng của LightGBM theo nhóm nghiệp vụ (Gain)

Nhóm nghiệp vụ	Tỷ trọng (%)
Dư nợ & Thanh toán	69,3
Đặc trưng kỹ thuật	20,9
Chi nhánh	4,4
Lãi suất	4,0
Hình thức & Mục đích vay	0,7
Kỳ hạn & Cơ cấu lại	0,7

Theo Gain, nhóm Dư nợ & Thanh toán chiếm 69,3% tổng mức độ quan trọng, tiếp theo là Đặc trưng kỹ thuật (bốn biến xây dựng tại Chương 3) với 20,9% — cộng lại 90,2%; Chi nhánh và Lãi suất chiếm 4,4% và 4,0%, hai nhóm còn lại chỉ 0,7% mỗi nhóm. Gain (tổng mức giảm hàm mất mát do chia nhánh trên biến, khác số lần chia nhánh) được chọn làm thước đo báo cáo vì phản ánh đóng góp vào chất lượng dự báo sát hơn; theo số lần chia nhánh, nhóm Đặc trưng kỹ thuật lại dẫn đầu do các biến thời gian liên tục bị chia nhánh nhiều lần với mức giảm nhỏ mỗi lần — SHAP (Mục 4.4.9) cũng xếp Dư nợ & Thanh toán cao nhất, cũng cố lựa chọn Gain.

Kết quả phản ánh mức độ mô hình sử dụng từng nhóm, chưa lượng hóa đầy đủ giá trị biên của nhóm đó, vì mức độ quan trọng có thể chia sẻ giữa các biến tương quan — đặc biệt `ENG_DAYS_TO_MATURITY` và `ENG_TENOR_ACTUAL_DAYS` với $r = 0,975$. Cũng cố kết luận cần thí nghiệm loại bỏ lần lượt từng nhóm và đo thay đổi Macro-F1 ngoài mẫu.

4.4.8 Ưu tiên đầu tư dữ liệu

Nhóm Dư nợ & Thanh toán và nhóm Đặc trưng kỹ thuật đều có tỷ lệ thiếu trung bình bằng 0,00%. Vì vậy, chỉ số ưu tiên của hai nhóm chủ yếu phản ánh mức độ quan trọng và hệ số nền 0,1 trong công thức $Priority_g = S_g(M_g/100 + 0,1)$, không phản ánh khoảng trống về tính đầy đủ của dữ liệu. Ba nhóm có chỉ số ưu tiên cao nhất:

Bảng 4.10: Ba nhóm nghiệp vụ có chỉ số ưu tiên cao nhất — bộ dữ liệu B

Nhóm nghiệp vụ	Mức độ quan trọng (%)	Tỷ lệ thiếu (%)	Chỉ số ưu tiên
Dư nợ & Thanh toán	69,3	0,00	6,93
Đặc trưng kỹ thuật	20,9	0,00	2,09
Kỳ hạn & Cơ cấu lại	0,7	74,79	0,59

Nhóm Kỳ hạn & Cơ cấu lại xếp thứ ba dù chỉ chiếm 0,7% tổng mức độ quan trọng, do tỷ lệ thiếu 74,79% làm thành phần $M_g/100$ chiếm ưu thế so với hệ số nền 0,1. Đây chính là cơ chế mà công thức hướng tới: nhóm đang thiếu nhiều dữ liệu được nâng thứ hạng so với các nhóm đã đầy đủ. Hai nhóm có chỉ số thấp nhất là Lãi suất (0,40) và Hình thức & Mục đích vay (0,07). Do các nhóm có mức độ quan trọng cao đã tương đối đầy đủ, kiến nghị tập trung vào duy trì chất lượng ngày giải ngân, ngày kết thúc khế ước và chuẩn hóa các trường dư nợ, lãi phải thu hoặc chưa thu, theo đúng bản chất quy ước, chưa phải hàm lợi ích kinh tế, của chỉ số này đã nêu tại Mục 3.6.8 Chương 3.

4.4.9 Giải thích mô hình và giới hạn của mức độ quan trọng

Mã nguồn hỗ trợ SHAP, dựa trên giá trị Shapley và mô hình cộng tính $f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j$ đã trình bày tại Mục 2.3.2 Chương 2, trong đó $\phi_j > 0$ làm đầu ra của lớp đang xét tăng so với giá trị nền ϕ_0 , còn $\phi_j < 0$ làm giảm [18].

SHAP giải thích cách mô hình hình thành dự báo, nhưng không chứng minh rằng thay đổi một biến sẽ gây ra thay đổi rủi ro. Các biến về số dư và giải ngân có tương quan có thể chia sẻ mức độ đóng góp. Vì vậy, kết luận nghiệp vụ cần kết hợp SHAP, phân tích độ ổn định và nhận định của chuyên gia.

Kết quả SHAP trên bộ dữ liệu A

SHAP được tính bằng TreeExplainer cho đúng mô hình XGBoost đã dùng ở bảng so sánh chính (11 biến, smote_moderate), trên toàn bộ 5.401 quan sát kiểm định. Bảng 4.11 liệt kê trung bình $|\phi_j|$ của từng biến trên cả năm lớp.

Bảng 4.11: Importance theo SHAP (trung bình $|\phi_j|$) — bộ dữ liệu A

Biến	Trung bình $ \phi_j $
DAYS_TO_MATURITY	0,8489
UTIL_RATE	0,3217
LOAN_TENURE_DAYS	0,2652
CURR_BAL	0,2493
LAISUAT	0,2404
PARENTORGNBR	0,2219
ORGNBR	0,2176
BASE_BAL	0,1903
CURRMIACTTYP	0,1419
MUCDICHVAY	0,0699
MJACCTTYP	0,0220

DAYS_TO_MATURITY có trung bình độ lớn SHAP cao nhất. Nhóm Kỳ hạn khoản vay chiếm 39,9% theo SHAP và đứng đầu trong cả hai phân tích. Sự đồng thuận về thứ hạng là bằng chứng mô tả trong các cấu hình đã khảo sát; chưa đủ để xác lập độ ổn định trên dữ liệu hoặc mô hình khác.

Bảng 4.12: Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng SHAP (%)
Kỳ hạn khoản vay	39,9
Dư nợ và hạn mức sử dụng	27,3
Đơn vị/Chi nhánh	15,8
Lãi suất	8,6
Sản phẩm và mục đích vay	8,4

Tỷ trọng của nhóm Dư nợ và hạn mức sử dụng tăng từ 12,9% theo Gain lên

27,3% theo SHAP, còn nhóm Sản phẩm và mục đích vay giảm từ 21,9% xuống 8,4%. Hai phép đo đồng thời được tính trên cấu hình khác nhau: Gain ở đây thuộc tập 13 biến, còn SHAP thuộc cấu hình chính 11 biến. Vì vậy, chênh lệch chưa thể quy hoàn toàn cho phương pháp giải thích. Với XGBoost, gain phản ánh mức cải thiện trung bình của hàm mục tiêu tại các lần chia sử dụng biến; weight mới phản ánh số lần chia sử dụng biến [28]. Để đối chiếu trực tiếp hai thước đo, cần tính chúng trên cùng mô hình, tập đặc trưng và mẫu đánh giá.

Kết quả SHAP trên bộ dữ liệu B

Với bộ B, SHAP được tính trên mô hình LightGBM 20 biến, SMOTE tùy chỉnh, lấy mẫu tối đa 500 quan sát kiểm định. Bảng 4.13 liệt kê toàn bộ 20 biến, xếp giảm dần theo $|\phi_j|$ trung bình.

Bảng 4.13: Importance theo SHAP (trung bình $|\phi_j|$) — bộ dữ liệu B

Biến	$ \phi_j $	Biến	$ \phi_j $
Lãi chưa thu hạch toán ngoại bảng	1,0846	Mục đích SD tiền vay (ngành KT)	0,0581
ENG_LOAN_AGE_DAYS	0,8449	Mô tả mục đích SD tiền vay	0,0399
ENG_DAYS_TO_MATURITY	0,2430	Mã thời hạn cấp tín dụng	0,0378
Số dư nợ theo nguyên tệ	0,2344	Phương thức cho vay	0,0309
Lãi suất	0,2117	Kênh điện tử	0,0090
Mã chi nhánh TCTD	0,1854	ENG_HAS_RESTRUCTURE	0,0020
ENG_TENOR_ACTUAL_DAYS	0,1798	Số tiền nợ lãi cơ cấu	0,0016
Lãi phải thu hạch toán nội bảng	0,1611	Số tiền nợ gốc cơ cấu	0,0016
		Số lần cơ cấu lại thời hạn trả nợ	0,0010
		Hình thức cấp tín dụng	0,0000
		Mã tiền tệ	0,0000
		Nguồn cấp tín dụng	0,0000

Trong phân tích SHAP, Lãi chưa thu hạch toán ngoại bảng và ENG_LOAN_AGE_DAYS có mức đóng góp trung bình lớn nhất. Kết quả bổ sung

góc nhìn theo dự báo cho phân tích Gain và IV. Ba thước đo có mục đích và cách tổng hợp khác nhau, nên không thể coi sự đồng thuận giữa chúng là kiểm định độc lập về giá trị nghiệp vụ của từng biến.

Bảng 4.14: Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu B

Nhóm nghiệp vụ	Tỷ trọng SHAP (%)	Tỷ trọng Gain (%)
Dư nợ & Thanh toán	44,5	69,3
Đặc trưng kỹ thuật	38,2	20,9
Lãi suất	6,4	4,0
Chi nhánh	5,6	4,4
Hình thức & Mục đích vay	4,1	0,7
Kỳ hạn & Cơ cấu lại	1,3	0,7

Bảng 4.14 cho thấy hai thước đo thống nhất ở thứ hạng: nhóm Dư nợ & Thanh toán dẫn đầu theo cả Gain và SHAP, tiếp theo là nhóm Đặc trưng kỹ thuật. Tổng tỷ trọng của hai nhóm là 90,2% theo Gain và 82,7% theo SHAP. Tuy nhiên, mức độ tập trung khác nhau đáng kể: Gain gán 69,3% cho nhóm dẫn đầu, còn SHAP chỉ gán 44,5% và phân bổ lại phần chênh cho nhóm Đặc trưng kỹ thuật, từ 20,9% lên 38,2%. Nhóm Chi nhánh chiếm 4,4% theo Gain và 5,6% theo SHAP. Các khác biệt này cho thấy mức đóng góp tương đối nhạy với thước đo: Gain đo mức giảm hàm mất mát trong quá trình huấn luyện, còn SHAP đo đóng góp vào từng dự báo trên mẫu kiểm định. Kiến nghị về dữ liệu cần dựa thêm trên thí nghiệm loại bỏ nhóm, độ ổn định theo kỳ và chi phí nghiệp vụ.

4.4.10 So sánh khả năng giải thích giữa hai bộ dữ liệu

Bộ A và bộ B có cấu trúc cột, đơn vị đo và kỳ báo cáo hoàn toàn khác nhau, nên so sánh trực tiếp chỉ có ý nghĩa ở cấp nhóm nghiệp vụ (Bảng 4.12 và Bảng 4.14), không phải ở cấp biến thô. Bảng 4.15 ánh xạ các nhóm tương ứng theo nội dung

nghiệp vụ, không theo tên gọi: nhóm Kỳ hạn khoản vay của bộ A tương ứng với nhóm Đặc trưng kỹ thuật của bộ B vì ba trong bốn biến kỹ thuật của bộ B (ENG_LOAN_AGE_DAYS, ENG_DAYS_TO_MATURITY, ENG_TENOR_ACTUAL_DAYS) đều mô tả thời hạn/tuổi khoản vay.

Bảng 4.15: Ánh xạ nhóm nghiệp vụ và đối chiếu tỷ trọng SHAP giữa bộ A và bộ B

Nhóm — bộ A	Tỷ trọng (%)	Hạng	Nhóm — bộ B	Tỷ trọng (%)	Hạng
Kỳ hạn khoản vay	39,9	1	Đặc trưng kỹ thuật	38,2	2
Dư nợ và hạn mức sử dụng	27,3	2	Dư nợ & Thanh toán	44,5	1
Đơn vị/Chi nhánh	15,8	3	Chi nhánh	5,6	4
Lãi suất	8,6	4	Lãi suất	6,4	3
Sản phẩm và mục đích vay	8,4	5	Hình thức & Mục đích vay	4,1	5
không có nhóm tương ứng			Kỳ hạn & Cơ cấu lại	1,3	6

Hai nhóm dẫn đầu trùng khớp hoàn toàn ở cả hai bộ, chỉ đổi vị trí cho nhau: nhóm Kỳ hạn khoản vay/Đặc trưng kỹ thuật và nhóm Dư nợ cùng chiếm phần lớn tỷ trọng SHAP (67,2% ở bộ A, 82,7% ở bộ B). Trùng khớp Top-2 đạt 100% (2/2); Top-3 đạt 66,7% (2/3), do nhóm Chi nhánh và nhóm Lãi suất đổi vị trí hạng 3–4 giữa hai bộ; xét toàn bộ 5 nhóm ánh xạ được, tập hợp trùng khớp 100% (chỉ nhóm Kỳ hạn & Cơ cấu lại của bộ B, 1,3%, không có nhóm tương ứng ở bộ A do khác biệt cấu trúc dữ liệu gốc). Hệ số tương quan hạng Spearman giữa hai bộ, tính trên 5 nhóm ánh xạ được, bằng 0,80.

Hai bộ dữ liệu độc lập về cấu trúc cột, kỳ báo cáo và một phần danh mục khách hàng, nhưng cho cùng kết luận về nhóm thông tin quan trọng nhất: đặc trưng liên quan đến kỳ hạn/thời hạn khoản vay và dư nợ luôn chiếm ưu thế, trong khi thông tin nhân khẩu học hoặc thủ tục hành chính đóng góp không đáng kể. Đây là bằng chứng củng cố câu trả lời cho Câu hỏi nghiên cứu 2 (Mục 1.4.2, Chương 1): kết luận về nhóm thông tin ưu tiên không phụ thuộc đặc thù của một

bộ dữ liệu cụ thể.

4.4.11 Đối chiếu với các nghiên cứu so sánh mô hình trước đây

Các nghiên cứu đối sánh của Baesens và cộng sự, Lessmann và cộng sự nhấn mạnh vai trò của dữ liệu, cấu hình và thước đo trong so sánh thuật toán [2, 17]. Luận văn chỉ đối chiếu các kết quả về mặt định tính, do khác biệt về nhãn, dữ liệu và thiết kế đánh giá; không so sánh trực tiếp trị số hiệu năng với các công trình đó.

Trong các bảng chính, LightGBM và XGBoost đạt Macro-F1 cao nhất trên tập kiểm định cùng kỳ. Trên kỳ sau của bộ B, Random Forest có Macro-F1 cao nhất. Random Forest cũng là mô hình tổ hợp; thay đổi này cho thấy thứ hạng giữa các họ mô hình tổ hợp có thể thay đổi theo tập đánh giá, không phủ định vai trò của phương pháp tổ hợp nói chung.

CatBoost có Macro-F1 thấp hơn một số mô hình cây trong cấu hình được báo cáo. Tuy nhiên, CatBoost sử dụng cơ chế trọng số lớp và xử lý biến phân loại khác các mô hình dùng SMOTE, nên chênh lệch phản ánh cả thuật toán lẫn quy trình xử lý. Chưa có cơ sở để quy toàn bộ chênh lệch cho riêng trọng số lớp nếu không thực hiện thí nghiệm kiểm soát. Điều này phù hợp với yêu cầu đánh giá riêng các chiến lược xử lý mất cân bằng trên từng dữ liệu [7].

4.5 So sánh chiến lược mất cân bằng: kết hợp SMOTE và trọng số lớp

Mục 3.7.2 Chương 3 đã mô tả một chiến lược kết hợp SMOTE với trọng số lớp w_c , chưa được dùng trong các bảng kết quả chính ở trên (vốn chỉ dùng SMOTE hoặc trọng số lớp riêng biệt). Mục này đối chiếu bốn chiến lược, không xử lý,

trọng số lớp, SMOTE, và kết hợp, trên mô hình tham chiếu của mỗi bộ dữ liệu: XGBoost cho bộ A (11 đặc trưng cấu hình chính), LightGBM cho bộ B (20 đặc trưng), cùng một lần chia 80/20 có phân tầng như bảng kết quả chính.

Bảng 4.16: So sánh bốn chiến lược mất cân bằng — XGBoost, bộ A

Chiến lược	Macro-F1	ROC-AUC	Recall N2	Recall N3	Recall N4
SMOTE	0,6247	0,9210	0,2335	0,3471	0,4395
Không xử lý	0,6197	0,9282	0,1712	0,2810	0,4713
Kết hợp (SMOTE + trọng số lớp)	0,5967	0,9115	0,4825	0,4628	0,5860
Trọng số lớp	0,5966	0,9147	0,5175	0,4793	0,5796

Bảng 4.17: So sánh bốn chiến lược mất cân bằng — LightGBM, bộ B

Chiến lược	Macro-F1	ROC-AUC	Recall N2	Recall N3	Recall N4
SMOTE	0,6930	0,9411	0,1930	0,5100	0,7128
Không xử lý	0,6896	0,9412	0,2065	0,4750	0,6782
Kết hợp (SMOTE + trọng số lớp)	0,6658	0,9335	0,6448	0,5550	0,7266
Trọng số lớp	0,6373	0,9309	0,6772	0,5900	0,6920

Các bảng bổ sung này sử dụng kết quả lưu trong `imbalance_comparison_a.csv` và `imbalance_comparison_b.csv`. Với bộ B, dòng LightGBM/SMOTE đạt Macro-F1 bằng 0,6930, **trùng khớp** với giá trị tại Bảng 4.4. Đây là kết quả mong đợi về mặt thiết kế, vì khóa chiến lược SMOTE của bộ B trong script so sánh chính là `imbalance_strategy="custom"` kết hợp `CREDIT_INFO_SMOTE_STRATEGY` — đúng cấu hình đã dùng ở bảng so sánh chính. Sự trùng khớp này xác nhận hai lần chạy độc lập tái lập được cùng một kết quả trong cùng môi trường thực nghiệm.

Với bộ A, Macro-F1 của XGBoost/SMOTE bằng 0,6247, thấp hơn 0,0195 so với 0,6442 ở bảng chính. Chênh lệch này chưa được tái lập lại trong cùng quy trình nên nguyên nhân chưa được xác định; các giá trị được giữ nguyên theo

nguồn và chỉ dùng để so sánh các chiến lược trong cùng bảng. Cần lưu ý rằng thứ hạng trong bảng của bộ A không chứng minh kết quả của hai lần chạy đã được tái lập tương đương.

Ở bộ A, Macro-F1 của chiến lược kết hợp và trọng số lớp gần nhau (0,5967 và 0,5966), nhưng Recall không trùng khớp ở mọi nhóm: nhóm 2 giảm từ 0,5175 xuống 0,4825, chênh 0,0350; nhóm 3 giảm 0,0165 và nhóm 4 tăng 0,0064. Ở bộ B, kết hợp đạt Macro-F1 0,6658 so với 0,6373 của trọng số lớp, chênh 0,0285, và có Recall nhóm 4 cao nhất trong bốn chiến lược (0,7266). Tuy nhiên, Macro-F1 vẫn thấp hơn SMOTE riêng lẻ (0,6930). Các kết quả này mô tả đánh đổi giữa hiệu năng tổng thể và nhận diện từng lớp, chưa xác lập nguyên nhân của khác biệt.

Trong hai thí nghiệm, chiến lược kết hợp không đạt giá trị cao nhất ở Macro-F1 hoặc ROC-AUC. Vì vậy, kết quả chưa ủng hộ việc mặc định kết hợp SMOTE với trọng số lớp; phương án lựa chọn cần được kiểm chứng theo mục tiêu đánh giá và chi phí sai số.

4.6 Độ nhạy của siêu tham số

Các dòng Logistic Regression của bộ A đánh dấu † là kết quả lưu từ khảo sát trước, chưa được tái lập trong cùng quy trình với bảng so sánh chính. Chúng chỉ được giữ để mô tả hồ sơ khảo sát, không dùng để đối sánh thứ hạng hiện tại của bộ A. Các giá trị cải thiện là thay đổi tương đối của Macro-F1, tính bằng $(F1_{\text{tốt nhất}}/F1_{\text{mặc định}} - 1) \times 100\%$.

Không gian tìm kiếm gồm 65 cấu hình cho bộ A và 60 cấu hình cho bộ B, được trình bày tại Mục 3.8.2 của Chương 3. Phần này so sánh cấu hình mặc định

với cấu hình đạt Macro-F1 cao nhất trong phạm vi lưới khảo sát, đồng thời phân tích mức độ nhảy của từng mô hình đối với siêu tham số.

4.6.1 Cấu hình mặc định so với cấu hình tốt nhất tìm được

Bảng 4.18: So sánh Macro-F1 giữa cấu hình mặc định và cấu hình tốt nhất trong lưới khảo sát

Bộ	Mô hình	Macro-F1 (mặc định)	Macro-F1 (tốt nhất)	Cải thiện
A	Decision Tree	0,5896	0,6086	+3,22%
A	Random Forest	0,6179	0,6303	+2,01%
A	XGBoost	0,6442	0,6442	+0,00%
A	LightGBM	0,6484	0,6484	+0,00%
A	CatBoost	0,5454	0,5677	+4,08%
A	Logistic Regression [†]	0,4204	0,4220	+0,37%
B	LightGBM	0,6930	0,6960	+0,44%
B	XGBoost	0,6846	0,6874	+0,41%
B	Decision Tree	0,6590	0,6653	+0,95%
B	Random Forest	0,6587	0,6645	+0,89%
B	CatBoost	0,6046	0,6228	+3,02%
B	Logistic Regression	0,3959	0,3959	+0,00%

Trong phạm vi các cấu hình được khảo sát, LightGBM đạt Macro-F1 cao nhất ở cả cấu hình mặc định (0,6930) và cấu hình được lựa chọn từ lưới (0,6960, với `max_depth=6`, `learning_rate=0,1`, `n_estimators=400`). Mức cải thiện tương ứng chỉ bằng 0,44%.

Trong lưới của bộ B, thay đổi tương đối của Macro-F1 so với cấu hình mặc định nằm trong khoảng +0,00% đến +3,02%. CatBoost cải thiện nhiều nhất, bằng 3,02%, khi tăng `depth` từ 6 lên 8 và `learning_rate` từ 0,05 lên 0,1, giữ nguyên `iterations=400`. Ở đầu còn lại, Logistic Regression không cải thiện: lưới khảo sát bốn giá trị C và cấu hình tốt nhất trùng với giá trị mặc định $C = 1,0$. Trường hợp này minh họa rằng một không gian tìm kiếm hữu hạn không bảo

đảm chứa cấu hình tốt hơn giá trị mặc định, đồng thời cho thấy hạn chế của Logistic Regression trên bộ B không nằm ở việc chọn siêu tham số mà ở dạng hàm tuyến tính của mô hình: Recall nhóm 2 và nhóm 3 lần lượt chỉ đạt 0,0008 và 0,020 ở cấu hình tốt nhất.

Bốn mô hình cây còn lại đều cải thiện dưới 1%, ngoại trừ CatBoost. Mức cải thiện nhỏ này là kết quả trong một lưới hữu hạn và trên cùng tập kiểm định dùng để chọn cấu hình; chưa thể suy ra nguyên nhân từ quy mô dữ liệu hoặc mức độ phi tuyến.

4.6.2 Độ nhạy tham số theo mô hình

Bảng 4.19: Độ nhạy Macro-F1 theo mô hình (trên toàn bộ lưới đã thử)

Bộ	Mô hình	Macro-F1 nhỏ nhất	Macro-F1 lớn nhất	Biên độ	Độ lệch chuẩn
A	Decision Tree	0,5626	0,6086	0,0460	0,0164
A	CatBoost	0,5259	0,5677	0,0418	0,0128
A	LightGBM	0,6223	0,6484	0,0261	0,0065
A	Logistic Regression [†]	0,3993	0,4220	0,0227	0,0106
A	XGBoost	0,6270	0,6442	0,0173	0,0059
A	Random Forest	0,6135	0,6303	0,0168	0,0048
B	Decision Tree	0,5866	0,6653	0,0787	0,0330
B	XGBoost	0,6111	0,6874	0,0763	0,0236
B	Logistic Regression	0,3264	0,3959	0,0695	0,0320
B	CatBoost	0,5534	0,6228	0,0694	0,0230
B	LightGBM	0,6419	0,6960	0,0541	0,0169
B	Random Forest	0,6248	0,6645	0,0397	0,0140

Random Forest có biên độ Macro-F1 nhỏ nhất trong lưới khảo sát ở cả hai bộ (0,0168 và 0,0397) — phù hợp cơ chế lấy trung bình trên nhiều cây của bagging, có tác dụng giảm phương sai so với cây đơn [6]. Decision Tree có biên độ lớn nhất ở cả hai bộ (0,0460 và 0,0787); XGBoost có biên độ lớn hơn LightGBM

trên bộ B (0,0763 so với 0,0541). Vì mỗi thuật toán được khảo sát trên một lưới riêng, các biên độ này chỉ mô tả độ nhạy trong không gian tìm kiếm tương ứng, không phải đặc tính cố định của thuật toán; kết luận về độ ổn định cũng chỉ có giá trị trong phạm vi lưới đã khảo sát.

Biên độ của bộ B lớn hơn bộ A ở cả sáu mô hình, đáng lưu ý khi đọc Bảng 4.4: chênh lệch Macro-F1 giữa LightGBM và XGBoost ở cấu hình mặc định (0,0084) nhỏ hơn biên độ dao động theo siêu tham số của chính từng mô hình (0,0541 và 0,0763) — thứ hạng giữa hai mô hình này trên bộ B chưa đủ vững để coi là kết luận về thuật toán.

Lưới tham số và cấu hình tốt nhất đều được đánh giá trên cùng tập kiểm định (20% kỳ 20260430), không phải tập kiểm tra ở kỳ sau 20260531; mức cải thiện ở Bảng 4.18 vì vậy có thể lạc quan hơn hiệu quả thực tế do thiên lệch lựa chọn — rủi ro này đã thể hiện rõ ở Mục 4.4.3, nơi thứ hạng mô hình trên tập kiểm định không giữ nguyên trên tập kiểm tra ở kỳ sau. Trước khi triển khai cấu hình đã tinh chỉnh, cần cố định quy trình lựa chọn và xác nhận trên một kỳ dữ liệu chưa dùng để phát triển mô hình, ví dụ bằng kiểm định chéo lồng nhau.

4.7 Đối chiếu ba câu hỏi nghiên cứu

Câu hỏi 1 — Các chiến lược xử lý mất cân bằng lớp ảnh hưởng thế nào đến hiệu năng, và mô hình nào phù hợp nhất? Ở cấu hình mặc định (không xử lý mất cân bằng), LightGBM đạt Macro-F1 cao nhất trên cả hai bộ dữ liệu: 0,6484 (bộ A, Bảng 4.1) và 0,6930 (bộ B, Bảng 4.4); XGBoost xếp thứ hai với 0,6442 và 0,6846. Tuy nhiên, chênh lệch này (0,0084 trên bộ B) nhỏ hơn biên độ dao động của chính hai mô hình theo siêu tham số (Mục 4.6), nên chưa đủ vững để

coi là khác biệt thuật toán. Đối chiếu bốn chiến lược mất cân bằng (Mục 4.5) cho thấy SMOTE riêng lẻ đạt Macro-F1 cao nhất trên bộ B (0,6930) nhưng không phải trên mọi tiêu chí: chiến lược trọng số lớp và kết hợp SMOTE+trọng số lớp có Recall nhóm hiếm cao hơn dù Macro-F1 thấp hơn — không có chiến lược nào vượt trội tuyệt đối trên mọi thước đo, cho thấy lựa chọn chiến lược cần gắn với mục tiêu đánh giá và chi phí sai số cụ thể, không nên mặc định là kết hợp sẽ luôn tốt hơn. CatBoost là một ngoại lệ đáng chú ý: Accuracy thấp hẳn (0,6913 ở bộ B) trong khi ROC-AUC vẫn cao (0,9195), do trọng số lớp làm ngưỡng arg max lệch khỏi nhóm đa số — minh họa rằng Accuracy một mình không đủ để đánh giá mô hình trên dữ liệu mất cân bằng.

Câu hỏi 2 — Nhiều đặc trưng/dữ liệu hơn có luôn cải thiện hiệu quả, và nhóm thông tin nào quan trọng nhất? Kết quả không ủng hộ việc thêm biến luôn cải thiện mô hình: trên bộ A, cấu hình 11 biến đạt Macro-F1 bằng 0,6442, cao hơn 0,6434 khi bổ sung SEX và LOAIKH; trên bộ B, cấu hình rút gọn 17 và 8 biến lần lượt đạt 0,7034 và 0,6961, cả hai đều cao hơn 0,6930 của tập đầy đủ 20 biến — cấu hình 8 biến được xem là một ứng viên rút gọn đáng cân nhắc. Về nhóm thông tin quan trọng nhất, phân tích SHAP ở Mục 4.4.10 cho thấy hai nhóm Kỳ hạn khoản vay và Dư nợ luôn chiếm ưu thế ở CẢ HAI bộ dữ liệu độc lập (Top-2 trùng khớp 100%, tương quan hạng Spearman 0,80) — đây là bằng chứng nhất quán, không phụ thuộc đặc thù của một bộ dữ liệu cụ thể. Vì hai nhóm dẫn đầu ở bộ B (Dư nợ & Thanh toán, Đặc trưng kỹ thuật) đều không có giá trị thiếu, khuyến nghị ưu tiên của ngân hàng là duy trì chất lượng ghi nhận các trường này (dư nợ, lãi phải thu/chưa thu, ngày giải ngân, ngày kết thúc khế ước) hơn là mở rộng thêm biến mới có mức đóng góp thấp.

Câu hỏi 3 — Mô hình có thể dự báo khả năng chuyển nhóm nợ trong ngắn hạn hay không, và kết quả có ổn định giữa các kỳ quan sát hay không? Câu trả lời khác nhau tùy theo cặp kỳ quan sát. Trên cặp 1 (20260430→20260531), XGBoost đạt PR-AUC trung bình 0,1806 qua kiểm định chéo — cao hơn khoảng 67 lần tỷ lệ sự kiện nền — cho thấy tín hiệu dự báo thực sự tồn tại trong mẫu này. Tuy nhiên, trên cặp 2 độc lập (20260531→20260630), cùng cấu hình chỉ đạt PR-AUC 0,0053, và không mô hình nào trong sáu mô hình khảo sát vượt quá PR-AUC 0,0060 hay ROC-AUC 0,5521 — xấp xỉ mức của một bộ phân loại ngẫu nhiên (Mục 4.8.4). Kiểm định chuyển giao ngoài thời gian (huấn luyện trên cặp 1, chấm điểm trực tiếp trên cặp 2) cũng cho kết quả tương tự. Vì vậy, câu trả lời trung thực là: mô hình *có thể* khai thác tín hiệu dự báo chuyển nhóm trong một số giai đoạn quan sát, nhưng khả năng này **chưa được chứng minh là ổn định** giữa hai kỳ quan sát độc lập hiện có — đây là bằng chứng quan trọng nhất của luận văn đối với câu hỏi cảnh báo sớm, cả về mặt khả quan (cặp 1) lẫn về mặt thận trọng cần thiết (cặp 2).

4.8 Kết quả bài toán dự báo chuyển nhóm nợ (bộ B)

Mục này báo cáo kết quả thực nghiệm cho bài toán bổ sung đã trình bày phương pháp ở Mục 3.9 Chương 3: dự báo khả năng một khoản vay chuyển sang nhóm nợ cao hơn trong các tháng tiếp theo. Kết quả chi tiết ở Mục 4.8.1–4.8.3 dựa trên cặp 1 (20260430→20260531, 98.968 khoản vay khớp, 265 sự kiện dương, 0,268%), dùng làm bằng chứng minh họa và huấn luyện chính; Mục 4.8.4 đối chiếu với cặp 2 (20260531→20260630, 98.620 khoản vay khớp, 258 sự kiện dương, 0,262%) để kiểm tra độ ổn định của kết quả.

4.8.1 So sánh mô hình và chiến lược xử lý mất cân bằng

Bảng 4.20 trình bày kết quả kiểm định chéo phân tầng 5 phần, lặp 10 lần, tạo 50 lượt đánh giá. Với mỗi mô hình, bảng chọn chiến lược có average precision trung bình cao nhất trong các chiến lược đã khảo sát: không xử lý, SMOTE, trọng số lớp và kết hợp SMOTE với trọng số lớp. Riêng CatBoost có hai cơ chế khác nhau là không dùng trọng số và dùng trọng số lớp. Do chiến lược được chọn bằng chính các kết quả kiểm định này, thứ hạng có thể chịu thiên lệch lựa chọn; chưa có tập kiểm tra độc lập cho việc chọn mô hình và chiến lược.

Bảng 4.20: So sánh 6 mô hình trên bài toán dự báo chuyển nhóm nợ (chiến lược tốt nhất theo PR-AUC, 5 phần, lặp 10 lần)

Mô hình	Chiến lược	PR-AUC	ROC-AUC	Precision(+)	Recall(+)
XGBoost	none	0,1806±0,0491	0,8458±0,0268	0,887±0,121	0,110±0,038
LightGBM	custom	0,1761±0,0488	0,8399±0,0305	0,753±0,145	0,125±0,043
Random Forest	none	0,1679±0,0485	0,8497±0,0256	0,580±0,499	0,016±0,015
CatBoost	none	0,1277±0,0439	0,8307±0,0269	0,866±0,272	0,055±0,026
Decision Tree	custom	0,0805±0,0409	0,6879±0,0451	0,205±0,085	0,101±0,048
Logistic Regression	none	0,0050±0,0008	0,6208±0,0332	0,000	0,000

Các giá trị sau dấu $\pm$ là độ lệch chuẩn của chỉ tiêu qua 50 phần kiểm định, không phải khoảng tin cậy. Precision(+)/Recall(+) được tính riêng cho lớp chuyển sang nhóm nợ cao hơn tại ngưỡng 0,5. XGBoost không xử lý mất cân bằng có average precision trung bình cao nhất (0,1806), cao khoảng 67 lần tỷ lệ sự kiện nền (0,268%), nên được chọn cho các phân tích minh họa. LightGBM đạt 0,1761 và Random Forest đạt 0,1679; chênh lệch trung bình này chưa đủ để kết luận XGBoost vượt trội có ý nghĩa thống kê. Random Forest có ROC-AUC trung bình cao nhất (0,8497), cho thấy thứ hạng còn phụ thuộc thước đo.

Logistic Regression đạt average precision 0,0050, khoảng 1,86 lần tỷ lệ sự

kiện nền 0,00268 và thấp hơn các mô hình cây trong cấu hình khảo sát. Kết quả gợi ý lợi ích của mô hình cây đối với dữ liệu này, nhưng chưa xác định được nguyên nhân chênh lệch. Không so sánh trực tiếp khoảng cách average precision của bài toán nhị phân với khoảng cách Macro-F1 của bài toán năm lớp để suy luận mức độ phi tuyến.

Bảng 4.21 đối chiếu bốn chiến lược mất cân bằng cho riêng XGBoost, gồm cả chiến lược kết hợp SMOTE với trọng số lớp đã mô tả ở Mục 3.7.2 Chương 3.

Bảng 4.21: Bốn chiến lược mất cân bằng đối với XGBoost


Chiến lược	PR-AUC	ROC-AUC	Precision(+)	Recall(+)
none	0,1806±0,0491	0,8458±0,0268	0,887±0,121	0,110±0,038
custom (SMOTE)	0,1710±0,0474	0,8457±0,0285	0,744±0,161	0,120±0,044
Kết hợp (SMOTE + class_weight)	0,1612±0,0472	0,8336±0,0281	0,074±0,012	0,288±0,047
class_weight	0,1541±0,0443	0,8265±0,0248	0,074±0,013	0,265±0,049

Với XGBoost, không xử lý mất cân bằng đạt average precision trung bình cao nhất trong bốn chiến lược. Trọng số lớp nâng Recall(+) từ 0,110 lên 0,265 tại ngưỡng 0,5, đồng thời giảm Precision(+) từ 0,887 xuống 0,074. Kết quả thể hiện đánh đổi giữa khả năng phát hiện sự kiện và tỷ lệ cảnh báo đúng tại ngưỡng đang xét; không thể suy ra hiệu quả nghiệp vụ chỉ từ Recall.


Chiến lược kết hợp có average precision 0,1612 và Recall(+) 0,288, cao hơn các giá trị tương ứng 0,1541 và 0,265 của trọng số lớp riêng lẻ; Precision(+) đều xấp xỉ 0,074 khi làm tròn. Các chênh lệch này là so sánh mô tả trong cùng thiết kế kiểm định, chưa phải bằng chứng thống kê rằng chiến lược kết hợp tốt hơn.

4.8.2 Đánh giá minh họa và Recall@k

Bảng 4.20 là bằng chứng chính. Để minh họa cụ thể, mô hình được chọn để minh họa (XGBoost, none) được huấn luyện lại trên một lần chia 80/20 (Mục 3.9.4), đạt PR-AUC 0,1705 và ROC-AUC 0,8487 trên 19.794 hồ sơ kiểm định (53 sự kiện dương), nhất quán với kết quả kiểm định chéo. Tại ngưỡng mặc định 0,5, mô hình chỉ gán nhãn dương cho 6 trong 53 sự kiện thật (Recall 0,113) nhưng cả 6 dự báo đều đúng (Precision 1,000); Hình 4.1 và Hình 4.2 minh họa ma trận nhầm lẫn và đường cong Precision-Recall tương ứng.



Hình 4.1: Ma trận nhầm lẫn — XGBoost (none), tập kiểm định minh họa




Hình 4.2: Đường cong Precision-Recall — XGBoost (none)

Ngưỡng 0,5 chỉ phát hiện một phần nhỏ sự kiện trong phép chia minh họa và chưa được lựa chọn theo chi phí nghiệp vụ. Bảng 4.22 bổ sung Recall và Precision khi cố định tỷ lệ hồ sơ được rà soát. Cách đánh giá này sử dụng thứ hạng điểm dự báo thay vì một ngưỡng xác suất cố định; lựa chọn k vẫn cần phù hợp với nguồn lực và chi phí xử lý.


Bảng 4.22: Recall@ k — XGBoost (none), tập kiểm định minh họa (19.794 hồ sơ, 53 sự kiện)

Top- k %	Số hồ sơ	Số sự kiện phát hiện	Recall@ k	Precision@ k
1%	198	14	26,4%	7,1%
2%	396	19	35,8%	4,8%
5%	990	30	56,6%	3,0%
10%	1.979	35	66,0%	1,8%



Hình 4.3: Recall@k — XGBoost (none)

Trong phép chia minh họa, 990 hồ sơ có điểm dự báo cao nhất chứa 30 trong tổng số 53 sự kiện chuyển nhóm trong 31 ngày. Recall@5% bằng 56,6%, Precision@5% bằng 3,03%; 960 hồ sơ trong danh sách không có sự kiện theo nhân quan sát và 23 sự kiện nằm ngoài danh sách. Nếu chọn ngẫu nhiên cùng số hồ sơ, số sự kiện phát hiện kỳ vọng khoảng 2,65, tương ứng Recall khoảng 5%. Kết quả gợi ý khả năng ưu tiên rà soát tốt hơn chọn ngẫu nhiên trong mẫu này, nhưng chưa lượng hóa lợi ích kinh tế hoặc hiệu quả so với quy trình sử dụng CIC. Hình 4.4 mô tả phân tán average precision qua 50 lượt đánh giá của chiến lược không xử lý mất cân bằng; không phải mọi mô hình trong hình đều dùng chiến lược được chọn ở Bảng 4.20.



Hình 4.4: Phân tán PR-AUC qua 5 phần, lặp 10 lần kiểm định chéo — chiến lược none

4.8.3 Giải thích bằng SHAP

Bảng 4.23 liệt kê trung bình độ lớn SHAP của đầu ra lớp chuyển nhóm trên mô hình XGBoost được chọn. SHAP được tính trên 500 quan sát lấy ngẫu nhiên từ tập kiểm định của phép chia 80/20, với hạt giống 42, không lọc riêng các quan sát dương. Số 265 là tổng số sự kiện trong bộ dữ liệu ghép, không phải cỡ mẫu SHAP. Các giá trị giải thích đầu ra thô của mô hình, không được diễn giải như mức tăng xác suất trực tiếp.

Bảng 4.23: Importance theo SHAP (trung bình $|\phi_j|$, lớp “xấu đi”) — mô hình dự báo chuyển nhóm nợ

Biến	Trung bình $ \phi_j $
Lãi phải thu hạch toán nội bảng	0,9351
Số dư nợ theo nguyên tệ	0,6096
ENG_DAYS_TO_MATURITY	0,5700
ENG_TENOR_ACTUAL_DAYS	0,4978
ENG_LOAN_AGE_DAYS	0,4585
Mã chi nhánh TCTD	0,3810
Lãi suất	0,3494
Lãi chưa thu hạch toán ngoại bảng	0,2175

Lãi phải thu hạch toán nội bảng có trung bình độ lớn SHAP cao nhất (0,9351), tiếp theo là dư nợ và các biến thời hạn. Tên trường chưa đủ để đồng nhất toàn bộ lãi phải thu với lãi đã quá hạn; diễn giải sâu hơn cần dựa trên định nghĩa kế toán và thời điểm ghi nhận trong từ điển dữ liệu của ngân hàng. Các biến cơ cấu nợ có SHAP gần 0 trong mẫu tính toán, nhưng chưa đủ cơ sở kết luận chúng không có giá trị dự báo ở các kỳ khác. Do mẫu SHAP được lấy ngẫu nhiên trong dữ liệu rất mất cân bằng, cần bổ sung phân tích có phân tầng theo nhân và kiểm tra độ ổn định khi mở rộng dữ liệu.

Các đặc trưng được xây dựng từ bản ghi tại T và không lấy cột đầu vào từ kỳ sau. Tuy nhiên, việc xác nhận chúng đã sẵn có khi ra quyết định cần dựa thêm trên lịch sử cập nhật dữ liệu (Mục 3.9.2). SHAP phản ánh cách mô hình sử dụng các giá trị này, không xác lập quan hệ nhân quả.

4.8.4 Độ ổn định giữa hai cặp kỳ quan sát

Ngân hàng đã cung cấp kỳ báo cáo thứ ba (20260630), cho phép ghép cặp 2 (20260531→20260630) theo đúng quy trình đã dùng cho cặp 1 (Mục 3.9, Chương 3) và đối chiếu trực tiếp kết quả giữa hai cặp kỳ độc lập — phép kiểm tra ổn định theo thời gian nghiêm ngặt hơn một cặp kỳ duy nhất. Cặp 2 gồm 98.620 khoản vay khớp được (98,4% của kỳ 20260531), với 258 sự kiện dương (0,262%) — quy mô và tỷ lệ sự kiện gần như tương đồng với cặp 1 (98.968 khoản vay, 265 sự kiện, 0,268%).

Bảng 4.24: Đối chiếu PR-AUC/ROC-AUC giữa cặp 1 và cặp 2 với cùng cấu hình mô hình (kiểm định chéo 5×10)

Mô hình	Chiến lược	Cặp 1 (thật)		Cặp 2 (thật)	
		PR-AUC	ROC-AUC	PR-AUC	ROC-AUC
XGBoost	none	0,1806±0,0491	0,8458±0,0268	0,0053±0,0049	0,4890±0,0325
LightGBM	custom	0,1761±0,0488	0,8399±0,0305	0,0044±0,0029	0,4913±0,0360
Random Forest	none	0,1679±0,0485	0,8497±0,0256	0,0042±0,0012	0,4781±0,0322
CatBoost	none	0,1277±0,0439	0,8307±0,0269	0,0060±0,0023	0,5521±0,0404
Decision Tree	custom	0,0805±0,0409	0,6879±0,0451	0,0040±0,0017	0,5025±0,0451
Logistic Regression	none	0,0050±0,0008	0,6208±0,0332	0,0027±0,0004	0,4783±0,0349

Kết quả không lặp lại giữa hai cặp kỳ đối với bất kỳ mô hình nào. Ở cặp 2, PR-AUC nằm trong khoảng 0,0027–0,0060 — chỉ xấp xỉ mức tham chiếu ngẫu nhiên ứng với tỷ lệ sự kiện dương 0,262% ($\approx 0,0026$) — và ROC-AUC nằm trong khoảng 0,478–0,552, không khác biệt có ý nghĩa so với 0,5 (một bộ phân loại ngẫu nhiên). XGBoost, mô hình tốt nhất ở cặp 1 (PR-AUC 0,1806), rơi xuống PR-AUC 0,0053 ở cặp 2 — mức giảm tương đối hơn 97%. Ngay cả CatBoost, mô hình có ROC-AUC cao nhất ở cặp 2 (0,5521), vẫn chỉ nhỉnh hơn không đáng kể so với ngẫu nhiên và thấp hơn nhiều so với ROC-AUC 0,8307 của chính nó ở cặp 1. Việc chọn mô hình/chiến lược tốt nhất riêng cho cặp 2 (CatBoost, Mục kiểm định chéo) không thay đổi kết luận: đây vẫn là hiệu năng gần mức ngẫu nhiên, không phải một cấu hình thay thế tốt hơn.

Kiểm định chuyển giao ngoài thời gian — huấn luyện đúng một lần trên toàn bộ cặp 1 bằng cấu hình tốt nhất của cặp 1 (XGBoost, none), sau đó chấm điểm trực tiếp trên toàn bộ 98.620 khoản vay của cặp 2 mà **không huấn luyện lại** — cho kết quả PR-AUC 0,0032 và ROC-AUC 0,5639; tại ngưỡng 0,5, mô hình không gắn nhãn dương cho bất kỳ khoản vay nào trong 258 sự kiện thật (Recall và Precision đều bằng 0). Đây là phép kiểm tra nghiêm ngặt nhất về khả năng

khái quát hóa của một mô hình cụ thể theo thời gian, và cho kết quả tệ hơn cả việc huấn luyện lại từ đầu trên cặp 2.

Ba phép kiểm tra độc lập — đối chiếu cùng cấu hình, chọn mô hình tốt nhất riêng cho cặp 2, và chuyển giao ngoài thời gian không huấn luyện lại — đều hội tụ về cùng kết luận: **tín hiệu dự báo chuyển nhóm quan sát được ở cặp 1 không lặp lại được ở cặp 2**. Ba nguyên nhân khả dĩ, không loại trừ lẫn nhau, được xem xét. Thứ nhất, số sự kiện dương rất thưa (265 và 258) khiến cấu hình được chọn ở cặp 1 — kể cả sau kiểm định chéo 5×10 — vẫn có thể phản ánh đặc điểm ngẫu nhiên riêng của mẫu đó hơn là một quy luật tổng quát. Thứ hai, hai giai đoạn quan sát (tháng 4–5 và tháng 5–6 năm 2026) có thể khác nhau về đặc điểm khách hàng chuyển nhóm, chịu ảnh hưởng của các yếu tố mùa vụ hoặc kinh tế không quan sát được trong tập đặc trưng hiện có. Thứ ba, cấu hình tốt nhất của cặp 1 có thể đã khớp với các đặc điểm riêng (idiosyncratic) của chính giai đoạn đó hơn là học được quan hệ nhân quả ổn định giữa đặc trưng và khả năng chuyển nhóm. Với chỉ hai cặp kỳ quan sát, luận văn chưa đủ cơ sở để phân biệt và định lượng đóng góp của từng nguyên nhân; đây là hạn chế cốt lõi cần thêm dữ liệu nhiều kỳ hơn để khắc phục (Chương 5).

4.9 Ý nghĩa đối với mô hình chuyển nhóm nợ

Kết quả ở Mục 4.8 cung cấp bằng chứng thăm dò về khả năng xếp hạng hồ sơ theo nguy cơ chuyển nhóm trong các tháng tiếp theo, dựa trên cặp 1. Đối chiếu với cặp 2 độc lập ở Mục 4.8.4 là phép kiểm tra bổ sung quan trọng cho tính vững của kết luận này. Việc áp dụng còn bị giới hạn bởi các điểm sau:

1. mới có hai cặp $(T, T + h)$ với cửa sổ dự báo khoảng 30–31 ngày; chưa kiểm

- định được trên nhiều cặp kỳ báo cáo hơn hay các cửa sổ dự báo dài hơn (1, 3, 6, 12 tháng);
2. mỗi cặp chỉ có 258–265 sự kiện dương và khoảng 53 sự kiện trong mỗi phần kiểm định; độ lệch chuẩn qua các phần phản ánh biến động do chia mẫu, chưa phải khoảng tin cậy hoặc kiểm định khác biệt giữa mô hình;
 3. nhân chỉ được xác định cho khoản vay khớp ở cả hai kỳ của từng cặp; rủi ro sai lệch do loại khoản vay tất toán/xóa nợ đã được thảo luận ở Mục 3.9.3 nhưng chưa được loại trừ hoàn toàn;
 4. ngưỡng quyết định và tỷ lệ ưu tiên top- $k\%$ chưa được gắn với chi phí bỏ sót/rà soát thực tế của ngân hàng; đây là bước tiếp theo cần thiết trước khi xem xét triển khai (Mục 5.5.3).

4.10 Tóm tắt chương

Chương 4 đã trình bày kết quả phân loại nhóm nợ, phân tích đặc trưng, chiến lược mất cân bằng và độ nhạy siêu tham số. Hiệu năng và thứ hạng mô hình thay đổi khi chuyển từ kiểm định cùng kỳ sang kỳ sau của bộ B. Các khác biệt giữa nguồn kết quả của bộ A được nêu rõ để giới hạn phạm vi đối sánh.

Bài toán dự báo chuyển nhóm nợ trong các tháng tiếp theo được kiểm định trên hai cặp kỳ quan sát độc lập của bộ B. Các kết luận theo ba câu hỏi nghiên cứu là cơ sở cho phần kiến nghị và hạn chế ở Chương 5.

Trên cơ sở các kết quả và hạn chế đã trình bày, Chương 5 sẽ tổng kết những đóng góp chính của luận văn, nêu rõ các hạn chế cần lưu ý và đề xuất kiến nghị đối với ngân hàng cùng hướng nghiên cứu tiếp theo.

Chương 5

KẾT LUẬN VÀ KIẾN NGHỊ

Chương này tổng hợp kết quả theo ba câu hỏi nghiên cứu, xác định đóng góp và giới hạn của luận văn, đồng thời đề xuất yêu cầu dữ liệu và kiểm định trước khi xem xét ứng dụng mô hình.

5.1 Kết luận chung

Luận văn đã tổ chức thực nghiệm phân loại năm nhóm nợ trên hai bộ dữ liệu của một ngân hàng thương mại và xây dựng bài toán dự báo chuyển nhóm nợ trong các tháng tiếp theo trên bộ B. Kết quả cho thấy mô hình học máy khai thác được tín hiệu phân loại và xếp hạng trong phạm vi mẫu khảo sát, nhưng hiệu năng phụ thuộc vào cấu hình, kỳ dữ liệu và cách đánh giá.

Trong các bảng so sánh chính, LightGBM có Macro-F1 cao nhất trên tập kiểm định của bộ A và bộ B, lần lượt bằng 0,6484 và 0,6930. Khi đánh giá ở kỳ sau của bộ B, Random Forest có Macro-F1 cao nhất (0,5065), còn LightGBM đạt 0,4995. Mức giảm tương đối của Macro-F1 trên sáu mô hình nằm trong khoảng 12,7–32,1%. Hai kỳ có nhiều khoản vay trùng nhau; vì vậy, kết quả phản ánh sự thay đổi hiệu năng trên danh mục qua thời gian, chưa chứng minh khả năng dự

báo cho khách hàng mới.

Bài toán chuyển nhóm được kiểm định trên hai cặp kỳ báo cáo thật độc lập của bộ B. Trên cặp 1 (20260430→20260531, 98.968 khoản vay, 265 sự kiện dương), XGBoost đạt average precision trung bình 0,1806 qua kiểm định chéo 5 phần, lặp 10 lần — cao hơn khoảng 67 lần tỷ lệ sự kiện nền. Trên cặp 2 độc lập (20260531→20260630, 98.620 khoản vay, 258 sự kiện dương), cùng cấu hình chỉ đạt PR-AUC 0,0053, và không mô hình nào trong sáu mô hình khảo sát vượt ROC-AUC 0,5521 — xấp xỉ một bộ phân loại ngẫu nhiên. Kiểm định chuyển giao ngoài thời gian (huấn luyện trên cặp 1, chấm điểm trực tiếp trên cặp 2) xác nhận kết luận này. Tín hiệu dự báo quan sát được ở cặp 1 vì vậy chưa được chứng minh là ổn định qua thời gian.

5.2 Trả lời các câu hỏi nghiên cứu

Ba câu hỏi nghiên cứu được trả lời dựa trên các kết quả ở Mục 4.7, Mục 4.4.10 và Mục 4.8. Các nhận định dưới đây chỉ có giá trị trong phạm vi dữ liệu và cấu hình đã khảo sát.

5.2.1 Câu hỏi 1 — Các chiến lược xử lý mất cân bằng lớp ảnh hưởng thế nào đến hiệu năng, và mô hình nào phù hợp nhất?

Ở cấu hình mặc định, LightGBM đạt Macro-F1 cao nhất trên cả hai bộ dữ liệu (0,6484 và 0,6930), nhưng chênh lệch với XGBoost nhỏ hơn biên độ dao động theo siêu tham số của chính hai mô hình, nên chưa đủ vững để kết luận về thuật toán. Không có chiến lược xử lý mất cân bằng nào (không xử lý, SMOTE, trọng số lớp, kết hợp) vượt trội tuyệt đối trên mọi thước đo: SMOTE riêng lẻ tối đa

hóa Macro-F1, còn trọng số lớp và chiến lược kết hợp cải thiện Recall của các lớp hiếm với chi phí giảm Macro-F1 tổng thể. Lựa chọn chiến lược vì vậy cần gắn với mục tiêu đánh giá và chi phí sai số cụ thể của ngân hàng, không nên mặc định theo một chiến lược duy nhất.

5.2.2 Câu hỏi 2 — Nhiều đặc trưng/dữ liệu hơn có luôn cải thiện hiệu quả, và nhóm thông tin nào quan trọng nhất?

Kết quả không cho thấy quan hệ tăng đơn điệu giữa số lượng đặc trưng và Macro-F1: một số tập rút gọn (9 biến ở bộ A, 8 biến ở bộ B) đạt hiệu năng gần với hoặc cao hơn tập đầy đủ trong phép chia khảo sát; vì lựa chọn tập biến dựa trên cùng tập kiểm định, cần xác nhận trên dữ liệu chưa tham gia lựa chọn trước khi coi đây là số biến tối ưu. Về nhóm thông tin quan trọng nhất, phân tích SHAP đối chiếu giữa hai bộ dữ liệu độc lập (Mục 4.4.10) cho kết quả nhất quán: nhóm Kỳ hạn khoản vay/Đặc trưng kỹ thuật và nhóm Dư nợ luôn chiếm ưu thế (Top-2 trùng khớp 100%, tương quan hạng Spearman 0,80), trong khi thông tin nhân khẩu học hoặc thủ tục hành chính đóng góp không đáng kể. Vì các nhóm dẫn đầu đã tương đối đầy đủ dữ liệu, ưu tiên của ngân hàng nên là duy trì chất lượng và tính nhất quán của các trường này (ngày giải ngân, ngày kết thúc kế ước, dư nợ, các khoản lãi phải thu/chưa thu) thay vì mở rộng thu thập thêm biến mới. Các tỷ trọng này phản ánh cách mô hình sử dụng dữ liệu, không phải bằng chứng nhân quả (Mục 5.4.6).

5.2.3 Câu hỏi 3 — Mô hình có thể dự báo khả năng chuyển nhóm nợ trong ngắn hạn hay không, và kết quả có ổn định giữa các kỳ quan sát hay không?

Có và không, tùy giai đoạn quan sát. Trên cặp 1, mô hình khai thác được tín hiệu dự báo rõ ràng (PR-AUC 0,1806, cao hơn khoảng 67 lần tỷ lệ sự kiện nền). Trên cặp 2 độc lập, kết quả của mọi mô hình và mọi chiến lược đều xấp xỉ mức ngẫu nhiên (PR-AUC cao nhất chỉ 0,0060, ROC-AUC cao nhất chỉ 0,5521), và kiểm định chuyển giao ngoài thời gian (huấn luyện trên cặp 1, chấm điểm trực tiếp trên cặp 2) cũng không cải thiện được kết quả này. Vì vậy, khả năng dự báo chuyển nhóm nợ **chưa được chứng minh là ổn định** theo thời gian; kết luận về giá trị ứng dụng của công cụ cảnh báo sớm cần thận trọng và chờ thêm bằng chứng từ nhiều kỳ quan sát hơn (Mục 5.4.1).

5.3 Đóng góp của nghiên cứu

5.3.1 Đóng góp phương pháp

Nghiên cứu xây dựng hai quy trình thực nghiệm độc lập dựa trên cùng một hệ nguyên tắc, bao gồm lựa chọn biến theo phân nhóm nghiệp vụ, xây dựng đặc trưng, điền khuyết, chuẩn hóa, mã hóa, xử lý mất cân bằng lớp và huấn luyện mô hình. Việc loại NHOMNO khỏi bộ A, đồng thời loại các trường phản ánh trực tiếp nhóm nợ hoặc số ngày quá hạn khỏi bộ B, nhằm hạn chế khả năng mô hình học lại quy tắc hình thành nhãn.

Nghiên cứu cũng tách ba khái niệm thường bị đồng nhất: số cột thô, số đặc trưng hợp lệ và số đặc trưng rút gọn theo hiệu năng. Sự phân biệt này giúp câu

hỏi “có cần giữ toàn bộ số cột thô không” được trả lời chặt chẽ hơn. Việc đối chiếu bốn câu hỏi đầu trên hai cấu trúc dữ liệu còn cho thấy kết luận về số lượng và nhóm đặc trưng không nên được khái quát từ một bộ dữ liệu duy nhất. Ở bộ B, việc bổ sung một tập kiểm tra ở kỳ sau theo thời gian còn cho thấy ngay cả kết luận rút ra từ một bộ dữ liệu cũng có thể không giữ nguyên khi kiểm tra ngoài thời gian thu thập dữ liệu huấn luyện.

Một đóng góp phương pháp của nghiên cứu là xây dựng thực nghiệm dự báo chuyển nhóm nợ bằng cách ghép các kỳ báo cáo liên tiếp của bộ B theo khóa định danh khế ước và xác định nhãn $Y_i = \mathbb{I}(G_{i,T+h} > G_{i,T})$, áp dụng đồng nhất cho hai cặp kỳ độc lập để kiểm tra được độ ổn định của kết quả thay vì chỉ báo cáo một cặp duy nhất. Thiết kế đặc trưng và nhãn được kiểm tra nhằm hạn chế rò rỉ thông tin (Mục 3.9.2). Đồng thời, phương pháp chia mẫu và hệ thống chỉ tiêu đánh giá được điều chỉnh cho phù hợp với tỷ lệ sự kiện dương rất thấp (dưới 0,3%), thay vì áp dụng trực tiếp cách đánh giá của bài toán phân loại năm lớp.

5.3.2 Đóng góp thực tiễn

Kết quả cung cấp:

- kết quả đối sánh sáu mô hình được thực thi thành công trên bộ B (và năm mô hình trên bộ A);
- bảng hiệu năng theo lớp trên cả tập kiểm định và tập kiểm tra ở kỳ sau của bộ B, cho thấy rõ khoảng cách giữa hiệu năng “trong phân phối” và hiệu năng ngoài thời gian;
- hai đường cong hiệu quả theo số lượng đặc trưng, trong đó cấu hình 8 biến của bộ B đạt Macro-F1 cao hơn một lượng nhỏ so với tập đầy đủ 20 biến;

- xếp hạng nhóm thông tin nghiệp vụ riêng cho từng bộ, đối chiếu chéo giữa Gain và SHAP;
- khuyến nghị duy trì dữ liệu kỳ hạn ở bộ A, đồng thời duy trì chất lượng dữ liệu Dư nợ & Thanh toán và Đặc trưng kỹ thuật ở bộ B (không phải thu thập thêm, vì hai nhóm này đã không thiếu dữ liệu);
- kết quả thăm dò về dự báo chuyển nhóm nợ trong các tháng tiếp theo từ dữ liệu nội bộ, kèm Recall/Precision theo tỷ lệ hồ sơ được ưu tiên rà soát (Mục 4.8).

Những kết quả này có thể hỗ trợ thiết kế thí nghiệm cảnh báo sớm tiếp theo, nhưng chưa nên tích hợp tự động vào quyết định tín dụng. Đặc biệt với bộ B, bằng chứng về khoảng cách hiệu năng ngoài thời gian (mục 5.4.2) và việc kết quả dự báo chuyển nhóm không ổn định giữa hai cặp kỳ quan sát độc lập (Mục 4.8) là hai lý do trực tiếp để thận trọng.

5.4 Hạn chế của nghiên cứu

5.4.1 Kết quả dự báo chuyển nhóm không ổn định giữa hai cặp kỳ quan sát

Ba kỳ báo cáo liên tiếp của bộ B (20260430, 20260531, 20260630) được ghép thành hai cặp $(T, T + h)$ độc lập để xây dựng nhãn $Y_i = \mathbb{I}(G_{i,T+h} > G_{i,T})$, huấn luyện mô hình và đánh giá khả năng dự báo chuyển nhóm (Mục 4.8). Trong khi đó, bộ A chỉ có một mốc thời gian nên không đáp ứng điều kiện xây dựng nhãn cho bài toán này.

Đối chiếu cùng cấu hình mô hình giữa hai cặp (Bảng 4.24) cho thấy PR-AUC

giảm từ 0,1806 (cặp 1, XGBoost) xuống 0,0053 (cặp 2) — mức giảm tương đối hơn 97%; ROC-AUC giảm từ 0,8458 xuống 0,4890, không còn khác biệt có ý nghĩa so với 0,5. Kết quả này nhất quán qua ba phép kiểm tra độc lập: đối chiếu cùng cấu hình, chọn mô hình tốt nhất riêng cho cặp 2 (CatBoost, PR-AUC cao nhất chỉ 0,0060), và kiểm định chuyển giao ngoài thời gian (huấn luyện một lần trên cặp 1, chấm điểm trực tiếp trên cặp 2, PR-AUC 0,0032, Recall và Precision đều bằng 0 tại ngưỡng 0,5).

Ba nguyên nhân khả dĩ, không loại trừ lẫn nhau, được xem xét: (1) số sự kiện dương rất thưa (265 và 258) khiến cấu hình được chọn ở cặp 1 có thể phản ánh đặc điểm ngẫu nhiên riêng của mẫu đó hơn một quy luật tổng quát, dù đã qua kiểm định chéo 5×10 ; (2) hai giai đoạn quan sát (tháng 4–5 và tháng 5–6 năm 2026) có thể khác nhau về đặc điểm khách hàng chuyển nhóm do yếu tố mùa vụ hoặc kinh tế không quan sát được trong tập đặc trưng hiện có; (3) cấu hình tốt nhất của cặp 1 có thể đã khớp với đặc điểm riêng của chính giai đoạn đó hơn là học được quan hệ ổn định giữa đặc trưng và khả năng chuyển nhóm. Với chỉ hai cặp kỳ quan sát, luận văn chưa đủ cơ sở để phân biệt và định lượng đóng góp của từng nguyên nhân — đây là hạn chế cốt lõi cần thêm dữ liệu nhiều kỳ hơn để khắc phục.

5.4.2 Khoảng cách tổng quát hóa ngoài thời gian ở bộ B

Bộ B có 998 hồ sơ ở nhóm 3 và 1.446 hồ sơ ở nhóm 4, do đó quy mô tuyệt đối của các lớp này không còn là hạn chế chính. Tuy nhiên, trên tập kiểm tra ở kỳ sau kỳ 20260531 (Mục 4.4.3), Macro-F1 của các mô hình giảm từ 15,4–32,1% so với tập kiểm định nội bộ và thứ hạng mô hình thay đổi. Random Forest đạt

kết quả cao nhất trên tập kiểm tra ở kỳ sau, trong khi LightGBM chuyển từ vị trí cao nhất trên tập kiểm định xuống vị trí thứ ba.

Kết quả cho thấy phép chia ngẫu nhiên có phân tầng trong cùng một kỳ dữ liệu có thể ước lượng lạc quan hơn khả năng tổng quát hóa theo thời gian. Nguyên nhân có thể bao gồm sự thay đổi quan hệ giữa đầu vào và biến đích, đặc thù của cặp kỳ báo cáo 20260430–20260531 hoặc hiện tượng mô hình khớp với các đặc điểm riêng của kỳ huấn luyện. Do chỉ có hai kỳ báo cáo, luận văn chưa đủ cơ sở để phân biệt và định lượng từng nguyên nhân.

5.4.3 Thiết kế kiểm định

Các bảng so sánh chính của bài toán năm lớp dựa trên một phép chia ngẫu nhiên có phân tầng, kèm đánh giá kỳ sau đối với bộ B. Bài toán chuyển nhóm sử dụng kiểm định chéo 5 phần, lặp 10 lần cho mỗi cặp kỳ quan sát, nay đã có hai cặp độc lập. Các phần kiểm định có dữ liệu dùng chung qua các lần lặp trong cùng một cặp; độ lệch chuẩn của chỉ tiêu không phải khoảng tin cậy của hiệu năng trên các kỳ tương lai. Việc chọn mô hình và chiến lược trên chính kết quả kiểm định của cặp 1 còn có thể tạo thiên lệch lựa chọn khi áp dụng sang cặp 2.

Các giá trị k được khảo sát trên cùng một tập kiểm định trước khi lựa chọn cấu hình có kết quả cao nhất, vì vậy có thể phát sinh thiên lệch lựa chọn. Tập 9 biến của bộ A và tập 8 biến của bộ B chỉ được xem là các cấu hình ứng viên từ phân tích khám phá. Giá trị k cần được lựa chọn trên tập xác thực hoặc thông qua kiểm định chéo lồng nhau, sau đó đánh giá một lần trên tập kiểm tra ở kỳ sau. Đối với bộ B, kỳ 20260531 đã được dùng để phân tích khả năng tổng quát hóa của các mô hình; đánh giá xác nhận cuối cùng nên sử dụng một kỳ mới chưa

tham gia phát triển mô hình.

5.4.4 Mã hóa biến phân loại

Label Encoding có thể tạo thứ tự số giả cho các danh mục. SMOTE sau mã hóa còn có thể nội suy ra giá trị không tương ứng danh mục hợp lệ. Cần so sánh One-Hot Encoding, encoding theo xác suất hoặc mô hình xử lý danh mục nguyên bản.

5.4.5 Tối ưu và hiệu chỉnh mô hình

Nghiên cứu chưa áp dụng kiểm định chéo lồng nhau và chưa đánh giá hiệu chỉnh xác suất. Bộ A còn giới hạn về tái lập: Logistic Regression chưa có kết quả chạy lại trong cùng quy trình với bảng chính, và Macro-F1 XGBoost/SMOTE khác nhau giữa bảng chính và thí nghiệm bổ sung. Nguyên nhân chưa được xác định đầy đủ nên cần lưu cấu hình, phiên bản dữ liệu và môi trường của từng lần chạy trước khi thống nhất lại các kết quả. Việc lựa chọn hệ số điều chỉnh xác suất lớp hiếm trên chính tập đánh giá chỉ có ý nghĩa khám phá; hệ số cần được chọn trong tầng xác thực, cố định rồi đánh giá trên dữ liệu mới.

5.4.6 Mức độ quan trọng của đặc trưng không phản ánh quan hệ nhân quả

Mức độ quan trọng của đặc trưng và SHAP phản ánh cách mô hình sử dụng dữ liệu, không chứng minh quan hệ nhân quả [18]. Các biến tương quan có thể chia sẻ hoặc thay thế mức độ đóng góp của nhau; chỉ số ưu tiên dữ liệu được sử dụng trong luận văn mới mang tính quy ước và chưa được liên kết với chi phí kinh tế.

Ở bộ B, Gain của LightGBM và SHAP cùng xác định Đặc trưng kỹ thuật và Dư nợ & Thanh toán là hai nhóm có mức độ quan trọng cao nhất, mặc dù thứ tự giữa hai nhóm thay đổi. Nhóm Chi nhánh đạt 15,3% theo Gain nhưng chỉ 5,5% theo SHAP, cho thấy kết quả diễn giải có thể nhạy cảm với thước đo, đặc biệt đối với biến phân loại có nhiều danh mục. Ở bộ A, mức độ đồng thuận thấp hơn khi hai nhóm Dư nợ–hạn mức và Sản phẩm–mục đích vay thay đổi đáng kể về thứ hạng giữa Gain và SHAP. Vì chỉ số ưu tiên dữ liệu tại Chương 4 được tính từ Gain, mọi kiến nghị đầu tư dữ liệu cần được đối chiếu bằng nhiều phương pháp giải thích trước khi áp dụng.

Đối với bài toán chuyển nhóm, SHAP được tính trên 500 quan sát lấy ngẫu nhiên từ tập kiểm định, giải thích đầu ra của lớp chuyển nhóm; không chỉ tính trên các quan sát dương. Trong dữ liệu mất cân bằng mạnh, mẫu này có thể chứa rất ít sự kiện. Thứ hạng đặc trưng cần được kiểm tra bằng lấy mẫu có phân tầng, mẫu lớn hơn và dữ liệu từ các kỳ khác. Lãi phải thu nội bảng có đóng góp trung bình cao nhất trong mẫu SHAP, nhưng chưa đủ căn cứ để đồng nhất trường này với lãi quá hạn hoặc kết luận về nguyên nhân khó khăn thanh toán.

5.5 Kiến nghị đối với ngân hàng

5.5.1 Xây dựng dữ liệu ảnh chụp theo thời gian

Ngân hàng cần lưu trữ dữ liệu ảnh chụp trạng thái khoản vay tại các kỳ cố định, sử dụng khóa định danh khoản vay và khách hàng nhất quán. Mỗi quan sát cần bao gồm ngày ghi nhận, nhóm nợ tại thời điểm ghi nhận và nhóm nợ tại các khoảng dự báo 1, 3, 6 hoặc 12 tháng. Đây là điều kiện tiên quyết để chuyển từ phân loại trạng thái hiện tại sang dự báo khả năng chuyển nhóm nợ.

5.5.2 Ưu tiên chất lượng trước khi mở rộng số lượng biến

Thay vì bổ sung nhiều trường rời rạc, ngân hàng nên:

1. chuẩn hóa ngày giải ngân, ngày kết thúc hợp đồng/khế ước và lịch sử thay đổi kỳ hạn;
2. duy trì tính nhất quán về cấu trúc cột giữa các kỳ báo cáo liên tiếp: bộ B cho thấy 8/41 cột của một kỳ có thể vắng mặt ở kỳ kế tiếp, buộc phải thu hẹp tập đặc trưng để mô hình dùng được xuyên suốt các kỳ;
3. thống nhất danh mục sản phẩm, mục đích vay và hình thức cấp tín dụng;
4. ghi nhận nguồn gốc và lịch sử cập nhật để xác định thời điểm biến thực sự sẵn có;
5. giám sát sự thay đổi phân bố và tỷ lệ thiếu theo từng kỳ; đồng thời kiểm định hồi cứu mô hình trên nhiều kỳ báo cáo liên tiếp trước khi triển khai;
6. đối chiếu ít nhất hai thước đo mức độ quan trọng, chẳng hạn Gain và SHAP, trước khi quyết định đầu tư thu thập một nhóm dữ liệu cụ thể.

5.5.3 Thiết kế cảnh báo theo chi phí

Ngưỡng cảnh báo phải dựa trên năng lực xử lý và chi phí sai lầm. Có thể tối ưu:

$$\mathcal{C}(\tau) = c_{FN}FN(\tau) + c_{FP}FP(\tau),$$

trong đó τ là ngưỡng cảnh báo; $FN(\tau)$ là số khoản vay chuyển nhóm nhưng bị bỏ sót; $FP(\tau)$ là số cảnh báo sai; c_{FN} là chi phí trung bình của bỏ sót; và c_{FP} là chi phí rà soát/cơ hội của cảnh báo sai. Ngưỡng tối ưu là giá trị làm $\mathcal{C}(\tau)$ nhỏ nhất dưới các ràng buộc nghiệp vụ.

5.5.4 Quản trị mô hình

Mô hình cần được triển khai dưới vai trò hỗ trợ quyết định, với sự kiểm tra và phê duyệt của cán bộ có thẩm quyền. Ngân hàng cần lưu vết phiên bản dữ liệu, mã nguồn, mô hình, nguyên nhân cảnh báo và kết quả xử lý; theo dõi Macro-F1, Recall của các lớp rủi ro, mức độ hiệu chỉnh xác suất và sự thay đổi phân bố; đồng thời thiết lập lịch tái huấn luyện phù hợp.

5.6 Hướng nghiên cứu tiếp theo

Với bài toán chuyển nhóm nợ đã có bằng chứng thực nghiệm ban đầu (Mục 4.8), hướng nghiên cứu ưu tiên chuyển từ “xây dựng nhãn” sang “kiểm định độ ổn định và mở rộng cửa sổ dự báo” trước khi xem xét triển khai. Các bước tiếp theo gồm:

1. thu thập thêm kỳ báo cáo liên tiếp để có nhiều hơn hai cặp $(T, T + h)$, có kiểm soát chồng lấn giữa các khoảng dự báo; đây là cơ sở để kiểm định độ ổn định của mô hình theo thời gian một cách chắc chắn hơn hai cặp quan sát hiện có;
2. xây nhãn $Y_{i,t}^{(h)}$ cho nhiều cửa sổ dự báo h (1, 3, 6, 12 tháng) khi có đủ chuỗi kỳ báo cáo, thay vì chỉ $h = 31$ ngày như hiện tại;
3. chia dữ liệu theo thời gian và theo khách hàng khi có nhiều kỳ báo cáo hơn;
4. hiệu chỉnh xác suất dự báo (calibration) và gán ngưỡng/tỷ lệ ưu tiên top- $k\%$ với chi phí bỏ sót–rà soát thực tế (Mục 5.5.3), thay vì chỉ báo cáo Recall@ k mô tả như hiện tại;

5. thực hiện thí nghiệm loại bỏ nhóm đặc trưng và đánh giá mức độ quan trọng bằng hoán vị trên tập kiểm định, đối với cả bài toán 5 lớp và bài toán chuyển nhóm;
6. làm rõ nguyên nhân loại trừ của 1.649 khoản vay không khớp giữa hai kỳ (Mục 3.9.3); cần trường dữ liệu phân biệt tất toán và xóa nợ mà hai file hiện tại không có;
7. thử nghiệm mô hình ordinal, survival hoặc multi-state cho bài toán phân loại 5 lớp vì các nhóm nợ có thứ tự.

Mô hình đa trạng thái có thể mô tả xác suất:

$$p_{ab}^{(h)} = P(G_{i,t+h} = b \mid G_{i,t} = a, \mathbf{X}_{i,t}),$$

trong đó a là nhóm nợ tại thời điểm quan sát; b là nhóm đích sau khoảng dự báo h ; $\mathbf{X}_{i,t}$ là véc-tơ thông tin sẵn có tại t ; và $p_{ab}^{(h)}$ là xác suất chuyển từ a sang b . Cách tiếp cận này phù hợp hơn phân loại độc lập nếu mục tiêu cuối cùng là ma trận chuyển nhóm.

5.7 Kết luận chương

Các kết quả của luận văn tạo cơ sở để thiết kế những thí nghiệm tiếp theo về phân loại và cảnh báo chuyển nhóm nợ. Ưu tiên trước khi ứng dụng là thống nhất khả năng tái lập, bổ sung dữ liệu qua nhiều kỳ, kiểm định quy trình lựa chọn mô hình trên dữ liệu mới và lượng hóa chi phí của cảnh báo đúng, cảnh báo sai và bỏ sót.

Tài liệu tham khảo

- [1] Edward I. Altman. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609, 1968.
- [2] Bart Baesens, Tony Van Gestel, Stijn Viaene, Maria Stepanova, Johan Suykens, and Jan Vanthienen. Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, 54(6):627–635, 2003.
- [3] Flavio Barboza, Herbert Kimura, and Edward I. Altman. Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83:405–417, 2017.
- [4] Basel Committee on Banking Supervision. Basel Framework: IRB Approach – Risk Components. https://www.bis.org/basel_framework/chapter/CRE/32.htm, 2024. Truy cập ngày 26/07/2026.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [6] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [7] Ian Brown and Christophe Mues. An experimental comparison of

- classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3):3446–3453, 2012.
- [8] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [9] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [10] Jonathan N. Crook, David B. Edelman, and Lyn C. Thomas. Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3):1447–1465, 2007.
- [11] Xolani Dastile, Tugrul Celik, and Moeketsi Potsane. Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing*, 91:106263, 2020.
- [12] DMLC / XGBoost Contributors. XGBoost Documentation: Introduction to Boosted Trees. <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>, 2026. Giấy phép Apache 2.0; truy cập ngày 15/08/2026.
- [13] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [14] David J. Hand and William E. Henley. Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A*, 160(3):523–541, 1997.

- [15] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.
- [16] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3149–3157, 2017.
- [17] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.
- [18] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774, 2017.
- [19] Lundberg, Scott and SHAP Contributors. SHAP Documentation: Waterfall Plot. https://shap.readthedocs.io/en/latest/example_notebooks/api_examples/plots/waterfall.html, 2026. Giấy phép MIT; truy cập ngày 15/08/2026.
- [20] Microsoft Corporation. LightGBM Documentation: Leaf-wise (Best-first) Tree Growth. <https://lightgbm.readthedocs.io/en/latest/Features.html>, 2026. Truy cập ngày 26/07/2026.
- [21] Ngân hàng Nhà nước Việt Nam. Thông tư số 31/2024/tt-nhnn quy định về phân loại tài sản có trong hoạt động của ngân hàng thương mại, tổ chức tín dụng phi ngân hàng, chi nhánh ngân hàng nước ngoài. <https://vbpl.vn/>

- nganhangnhanuoc/Pages/vbpq-luocdo.aspx?ItemID=168260, 2024.
Ban hành ngày 30/06/2024; truy cập ngày 07/09/2026.
- [22] Ngân hàng Nhà nước Việt Nam. Thông tư số 37/2025/tt-nhnn sửa đổi, bổ sung một số điều của thông tư số 31/2024/tt-nhnn. <https://vbpl.vn/nganhangnhanuoc/Pages/vbpq-toanvan.aspx?ItemID=183515>, 2025. Quan hệ sửa đổi được đối chiếu trên Cơ sở dữ liệu quốc gia về văn bản pháp luật; truy cập ngày 07/09/2026.
- [23] James A. Ohlson. Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131, 1980.
- [24] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.
- [25] scikit-learn developers. average_precision_score. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html. Tài liệu chính thức; truy cập ngày 07/09/2026.
- [26] Naeem Siddiqi. *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons, 2006.
- [27] Lyn C. Thomas. A survey of credit and behavioural scoring: Forecasting financial risk of lending to consumers. *International Journal of Forecasting*, 16(2):149–172, 2000.
- [28] XGBoost developers. Python api reference: Feature importance. <https://>

`xgboost.readthedocs.io/en/stable/python/python_api.html`.

Tài liệu chính thức; truy cập ngày 07/09/2026.

- [29] Yufei Xia, Chuanzhi Liu, Bin Da, and Faming Xie. A boosted decision tree approach using bayesian hyper-parameter optimization for credit scoring. *Expert Systems with Applications*, 78:225–241, 2017.