

ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG
XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN
HÀNG THƯƠNG MẠI Ở VIỆT NAM

ĐÀM CÔNG DANH

danh.dc251317M@sis.hust.edu.vn

Chuyên ngành Toán Tin

Giảng viên hướng dẫn: TS. Lê Kim Thư

Chữ ký của GVHD

TS. Lê Thị Thanh An

Bộ môn:

Toán Tin

Viện:

Toán ứng dụng và Tin học

HÀ NỘI - 2026

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

BẢN XÁC NHẬN CHỈNH SỬA LUẬN VĂN THẠC SĨ

Họ và tên tác giả luận văn: Đàm Công Danh.

Đề tài luận văn: Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam.

Chuyên ngành: Toán Tin.

Mã học viên: 20251317M

Tác giả, Người hướng dẫn khoa học và Hội đồng chấm luận văn xác nhận tác giả đã sửa chữa, bổ sung luận văn theo biên bản họp Hội đồng ngày ... với các nội dung sau.

Ngày tháng năm 2026

Giảng viên hướng dẫn

Tác giả luận văn

CHỦ TỊCH HỘI ĐỒNG

ĐỀ TÀI LUẬN VĂN

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN
CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM.

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

TS. Lê Kim Thư

Lời cảm ơn

Lời đầu tiên, em xin cảm ơn Viện Toán ứng dụng và Tin học đã tạo điều kiện cho phép thực hiện và hỗ trợ em trong quá trình thực hiện nghiên cứu cũng như suốt thời gian theo học chương trình thạc sĩ Toán Tin tại đơn vị.

Đặc biệt, em xin cảm ơn hai cô - TS. Lê Kim Thư và TS. Lê Thị Thanh An đã tận tình quan tâm, hướng dẫn, chia sẻ kinh nghiệm, kiến thức để em có thể hoàn thành được đề tài một cách tốt nhất. Em cũng xin cảm ơn các thầy cô cùng các bạn học viên khóa 2025 trong Viện Toán ứng dụng và Tin học đã góp phần giúp em hoàn thành luận văn này.

Mặc dù đã cố gắng nhưng luận văn vẫn không thể tránh khỏi những sai sót. Em mong nhận được những góp ý từ các thầy cô, các bạn độc giả để luận văn được hoàn thiện hơn. Em xin chân thành cảm ơn!

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

LỜI MỞ ĐẦU

Lý do lựa chọn đề tài

Trong nền kinh tế hiện đại, ngân hàng thương mại giữ vai trò trung gian tài chính quan trọng thông qua việc huy động vốn, cung ứng tín dụng và phân bổ nguồn lực cho các chủ thể trong nền kinh tế. Trong các hoạt động của ngân hàng thương mại, tín dụng là một nghiệp vụ cốt lõi, có đóng góp đáng kể vào thu nhập nhưng đồng thời cũng là nguồn phát sinh rủi ro lớn. Khi khách hàng không thực hiện đầy đủ nghĩa vụ trả nợ, ngân hàng có thể chịu tổn thất về dòng tiền, lợi nhuận, chi phí dự phòng và vốn tự có. Ở phạm vi rộng hơn, chất lượng tín dụng suy giảm có thể ảnh hưởng đến tính an toàn của toàn hệ thống tài chính.

Quản trị rủi ro tín dụng vì vậy không chỉ dừng ở việc xem xét hồ sơ tại thời điểm phê duyệt mà còn bao gồm hoạt động theo dõi, phân loại, cảnh báo sớm và cập nhật mức độ rủi ro trong suốt vòng đời khoản vay. Một hệ thống xếp hạng tín dụng hiệu quả giúp ngân hàng chuẩn hóa quá trình đánh giá, hỗ trợ xác định hạn mức, lãi suất, điều kiện bảo đảm, chính sách giám sát sau vay và mức độ ưu tiên xử lý đối với từng khách hàng hoặc khoản vay.

Trong thực tế, dữ liệu tín dụng tại ngân hàng ngày càng có quy mô lớn, đa dạng về nguồn và phức tạp về cấu trúc. Ngoài các thông tin nhân khẩu học và tài chính, ngân hàng còn lưu trữ dữ liệu về hợp đồng tín dụng, dư nợ, thời hạn

vay, lịch sử trả nợ, nhóm nợ, mục đích vay, loại sản phẩm, trạng thái cơ cấu lại khoản vay và nhiều đặc trưng nghiệp vụ khác. Mỗi quan hệ giữa các biến này với rủi ro tín dụng thường không hoàn toàn tuyến tính và có thể thay đổi theo thời gian, theo chính sách cấp tín dụng, theo đặc điểm sản phẩm hoặc theo điều kiện kinh tế.

Các phương pháp đánh giá tín dụng truyền thống như phương pháp chuyên gia, phân tích phân biệt, hồi quy logistic và scorecard có ưu điểm về tính minh bạch, khả năng giải thích và mức độ thuận tiện trong triển khai. Tuy nhiên, các phương pháp này có thể gặp hạn chế khi cần xử lý đồng thời số lượng lớn biến, quan hệ phi tuyến, tương tác phức tạp, dữ liệu mất cân bằng và sự thay đổi phân phối theo thời gian. Sự phát triển của trí tuệ nhân tạo và học máy đã mở ra khả năng xây dựng các mô hình dự báo có năng lực khai thác dữ liệu tốt hơn, đặc biệt với các thuật toán cây, ensemble và gradient boosting.

Phần lớn các công trình về chấm điểm tín dụng trước đây tiếp cận bài toán dưới dạng phân loại nhị phân, trong đó khách hàng được chia thành nhóm tốt và nhóm xấu hoặc nhóm vỡ nợ và không vỡ nợ. Trong khi đó, dữ liệu được sử dụng trong luận văn có biến mục tiêu gồm năm nhóm nợ, tương ứng với các mức rủi ro tăng dần. Đây không chỉ là bài toán phân loại đa lớp mà còn là bài toán có cấu trúc thứ tự, bởi sai số dự báo nhóm 5 thành nhóm 1 nghiêm trọng hơn sai số dự báo nhóm 5 thành nhóm 4.

Xuất phát từ những vấn đề trên, đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*” được thực hiện nhằm xây dựng và đánh giá một quy trình phân loại năm nhóm nợ trên dữ liệu thực tế đã được ẩn danh. Nghiên cứu không đặt mục tiêu đề xuất một thuật toán học máy hoàn toàn mới, mà tập trung phát triển cách mô hình hóa, xây

dụng đặc trưng, thiết kế thực nghiệm và đánh giá bài toán phù hợp hơn với đặc điểm nghiệp vụ tín dụng tại ngân hàng Việt Nam.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của luận văn là các phương pháp thống kê và học máy được sử dụng để phân loại mức độ rủi ro tín dụng của khách hàng hoặc khoản vay. Trọng tâm của nghiên cứu là bài toán dự báo nhóm nợ từ 1 đến 5 dựa trên dữ liệu lịch sử.

Về dữ liệu, luận văn sử dụng dữ liệu tín dụng đã được ẩn danh từ một ngân hàng thương mại tại Việt Nam. Các nhóm thông tin được xem xét có thể bao gồm thông tin khách hàng, thông tin khoản vay, dư nợ, ngày mở, ngày đến hạn, thời hạn tín dụng, lãi suất, mục đích vay, nhóm nợ hiện tại, nhóm nợ nội bộ, trạng thái cơ cấu lại khoản vay và các biến nghiệp vụ liên quan.

Về phương pháp, luận văn sử dụng Logistic Regression làm mô hình cơ sở và so sánh với Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost. Nghiên cứu đồng thời xem xét mất cân bằng lớp, đặc trưng thời gian, tính thứ tự của nhãn và khả năng giải thích mô hình.

Về không gian, nghiên cứu được thực hiện trong phạm vi dữ liệu của một ngân hàng thương mại tại Việt Nam. Do yêu cầu bảo mật, tên ngân hàng và các thông tin định danh trực tiếp không được công bố.

Về thời gian, nghiên cứu sử dụng dữ liệu lịch sử trong khoảng thời gian do ngân hàng cung cấp. Việc chia dữ liệu được ưu tiên thực hiện theo thứ tự thời gian để mô phỏng điều kiện triển khai thực tế.

Động lực ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng

Động lực thứ nhất xuất phát từ quy mô và mức độ đa dạng của dữ liệu tín dụng. Các thuật toán học máy có khả năng khai thác đồng thời nhiều đặc trưng, phát hiện tương tác và mô hình hóa quan hệ phi tuyến mà các mô hình tuyến tính có thể không thể hiện đầy đủ.

Động lực thứ hai là nhu cầu chuẩn hóa và tự động hóa quy trình đánh giá rủi ro. Một mô hình được xây dựng và kiểm định phù hợp có thể hỗ trợ xử lý số lượng lớn hồ sơ, rút ngắn thời gian phân tích và giảm sự phụ thuộc vào đánh giá chủ quan.

Động lực thứ ba là nhu cầu nhận diện sớm sự suy giảm chất lượng tín dụng. Thay vì chỉ dự báo khách hàng tốt hay xấu, mô hình có thể hỗ trợ phân loại mức độ rủi ro chi tiết hơn và phát hiện các khoản vay có khả năng chuyển sang nhóm nợ cao.

Động lực thứ tư là yêu cầu kết hợp hiệu quả dự báo với khả năng giải thích. Trong lĩnh vực ngân hàng, mô hình không chỉ cần chính xác mà còn cần cung cấp thông tin về các yếu tố ảnh hưởng đến quyết định, phục vụ kiểm định, giám sát và giải trình.

Tóm tắt nội dung luận văn

Ngoài phần mở đầu, kết luận, tài liệu tham khảo và phụ lục, luận văn được kết cấu thành các chương như sau:

- **Chương 1: Giới thiệu tổng quan về đề tài.** Chương này trình bày bối cảnh nghiên cứu, tính cấp thiết, câu hỏi nghiên cứu, phương pháp nghiên cứu, ý nghĩa và đóng góp của đề tài.
- **Chương 2: Cơ sở lý thuyết và các nghiên cứu liên quan.** Chương này trình bày các khái niệm về tín dụng, rủi ro tín dụng, xếp hạng tín dụng, trí tuệ nhân tạo, học máy và tổng quan các nghiên cứu trong và ngoài nước.
- **Chương 3: Dữ liệu và phương pháp nghiên cứu.** Chương này mô tả bộ dữ liệu nghiên cứu, quy trình tiền xử lý dữ liệu, xây dựng đặc trưng, lựa chọn mô hình và phương pháp đánh giá.
- **Chương 4: Kết quả thực nghiệm và thảo luận.** Chương này trình bày kết quả huấn luyện các mô hình trí tuệ nhân tạo, so sánh hiệu quả mô hình và phân tích các yếu tố ảnh hưởng đến xếp hạng tín dụng.
- **Chương 5: Kết luận và khuyến nghị.** Chương này tổng hợp kết quả nghiên cứu, nêu các đóng góp chính, hạn chế của đề tài và đề xuất hướng nghiên cứu tiếp theo.

Học viên thực hiện

Đàm Công Danh

Mục lục

Lời mở đầu	4
Lý do lựa chọn đề tài	4
Đối tượng và phạm vi nghiên cứu	6
Động lực ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng	7
Một số thuật ngữ viết tắt	15
Danh sách hình vẽ	16
Danh sách bảng	17
1 GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI	18
1.1 Bối cảnh hoạt động tín dụng và rủi ro tín dụng	18
1.2 Tổng quan về chấm điểm và xếp hạng tín dụng	19
1.3 Chuyển đổi số trong ngân hàng và vai trò của dữ liệu	19
1.4 Thành tựu và hạn chế của các phương pháp đánh giá tín dụng truyền thống	20
1.4.1 Phương pháp chuyên gia	20
1.4.2 Altman và mô hình Z-score	20
1.4.3 Ohlson và mô hình xác suất phá sản	21

1.4.4	Hand và Henley	21
1.4.5	Lyn C. Thomas	22
1.4.6	Jonathan N. Crook	22
1.4.7	Baesens và Lessmann	22
1.4.8	Nhận xét tổng hợp	23
1.5	Phát biểu bài toán nghiên cứu	23
1.5.1	Điểm phát triển so với các công trình đi trước	24
1.6	Phương pháp nghiên cứu	25
1.7	Mục tiêu nghiên cứu	25
1.7.1	Mục tiêu tổng quát	25
1.7.2	Mục tiêu cụ thể	25
1.8	Câu hỏi nghiên cứu	26
1.9	Ý nghĩa khoa học và thực tiễn	26
2	CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN	27
2.1	Tín dụng và rủi ro tín dụng	27
2.1.1	Khái niệm tín dụng	27
2.1.2	Khái niệm rủi ro tín dụng	27
2.1.3	Phân loại nhóm nợ	28
2.2	Chấm điểm và xếp hạng tín dụng	28
2.3	Các phương pháp đánh giá tín dụng truyền thống	28
2.4	Trí tuệ nhân tạo và học máy	28
2.5	Các mô hình sử dụng	29
2.5.1	Logistic Regression đa lớp	29
2.5.2	Decision Tree	29

2.5.3	Random Forest	29
2.5.4	XGBoost	29
2.5.5	LightGBM	29
2.5.6	CatBoost	29
2.6	Các vấn đề đặc thù của dữ liệu tín dụng	30
2.6.1	Mất cân bằng lớp	30
2.6.2	Tính thứ tự	30
2.6.3	Thay đổi theo thời gian	30
2.6.4	Khả năng giải thích	30
2.7	Chỉ tiêu đánh giá	30
2.7.1	Accuracy	30
2.7.2	Precision, Recall và F1	30
2.7.3	Macro F1	31
2.7.4	Weighted F1	31
2.7.5	Balanced Accuracy	31
2.7.6	Ordinal MAE	31
2.8	Tổng quan nghiên cứu liên quan	31
2.9	Khoảng trống nghiên cứu	32
2.10	Định hướng nghiên cứu	32
2.11	Tóm tắt chương	32
3	DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	33
3.1	Quy trình nghiên cứu	33
3.2	Mô tả dữ liệu nghiên cứu	34
3.2.1	Nguồn dữ liệu	34

3.2.2	Biến mục tiêu	34
3.2.3	Mô tả các nhóm biến	35
3.3	Tiền xử lý dữ liệu	36
3.3.1	Làm sạch dữ liệu	36
3.3.2	Xử lý giá trị thiếu	36
3.3.3	Xử lý ngoại lệ	37
3.4	Phân tích khám phá dữ liệu	37
3.4.1	Phân bố biến mục tiêu	37
3.4.2	Phân tích tương quan	38
3.5	Xây dựng đặc trưng	38
3.5.1	Biến thời gian	38
3.5.2	Biến hành vi tín dụng	39
3.5.3	Mã hóa biến phân loại	39
3.6	Xử lý mất cân bằng dữ liệu	39
3.7	Thiết kế thực nghiệm	40
3.7.1	Chia tập dữ liệu	40
3.7.2	Cross Validation	40
3.8	Xây dựng mô hình	40
3.9	Đánh giá mô hình	41
3.9.1	Accuracy	41
3.9.2	Precision	41
3.9.3	Recall	41
3.9.4	F1-Score	41
3.9.5	Confusion Matrix	42
3.9.6	ROC-AUC	42

3.10	Tóm tắt chương	42
4	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	43
4.1	Môi trường thực nghiệm	43
4.1.1	Cấu hình phần cứng	43
4.1.2	Môi trường phần mềm	44
4.2	Phân tích dữ liệu sau tiền xử lý	44
4.2.1	Phân bố dữ liệu	44
4.2.2	Phân tích tương quan	45
4.3	Kết quả huấn luyện mô hình	45
4.3.1	Logistic Regression	45
4.3.2	Decision Tree	46
4.3.3	Random Forest	46
4.3.4	XGBoost	46
4.3.5	LightGBM	47
4.3.6	CatBoost	47
4.4	So sánh các mô hình	47
4.5	Đánh giá chi tiết mô hình tốt nhất	48
4.5.1	Confusion Matrix	48
4.5.2	ROC-AUC	48
4.6	Giải thích mô hình bằng SHAP	49
4.6.1	Feature Importance	49
4.6.2	SHAP Summary Plot	49
4.7	Thảo luận kết quả	50
4.8	Tóm tắt chương	50

5	KẾT LUẬN VÀ KIẾN NGHỊ	51
5.1	Kết luận	51
5.2	Đóng góp của nghiên cứu	53
5.2.1	Đóng góp về mặt khoa học	53
5.2.2	Đóng góp về mặt thực tiễn	54
5.3	Hạn chế của nghiên cứu	54
5.4	Kiến nghị đối với ngân hàng thương mại	55
5.4.1	Nâng cao chất lượng dữ liệu	55
5.4.2	Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng . .	56
5.4.3	Phát triển hệ thống Explainable AI	56
5.5	Hướng phát triển trong tương lai	56
5.5.1	Mở rộng quy mô dữ liệu	56
5.5.2	Khai thác dữ liệu phi truyền thống	57
5.5.3	Ứng dụng Deep Learning	57
5.5.4	Xây dựng hệ thống cảnh báo sớm	57
5.5.5	Triển khai thực tế	58
5.6	Kết luận chương	58

Một số thuật ngữ viết tắt

Danh sách hình vẽ

3.1	Quy trình nghiên cứu đề xuất	33
3.2	Phân bố biến mục tiêu	37
4.1	Phân bố biến mục tiêu	45
4.2	Ma trận tương quan giữa các biến	45
4.3	So sánh Accuracy giữa các mô hình	47
4.4	Confusion Matrix của CatBoost	48
4.5	ROC Curve của mô hình CatBoost	48
4.6	Tầm quan trọng của các đặc trưng theo SHAP	49
4.7	SHAP Summary Plot	49

Danh sách bảng

2.1	Các nhóm nợ trong nghiên cứu	28
3.1	Ý nghĩa các nhóm nhãn	35
3.2	Một số biến quan trọng trong nghiên cứu	36
4.1	Cấu hình môi trường thực nghiệm	43
4.2	Các công cụ sử dụng trong nghiên cứu	44
4.3	Phân bố các nhóm tín dụng	44
4.4	Kết quả Logistic Regression	45
4.5	Kết quả Decision Tree	46
4.6	Kết quả Random Forest	46
4.7	Kết quả XGBoost	46
4.8	Kết quả LightGBM	47
4.9	Kết quả CatBoost	47
4.10	So sánh các mô hình	47

Chương 1

GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh hoạt động tín dụng và rủi ro tín dụng

Hoạt động tín dụng có vai trò đặc biệt quan trọng đối với ngân hàng thương mại. Thông qua hoạt động cấp tín dụng, ngân hàng cung ứng vốn cho cá nhân và tổ chức, đồng thời tạo ra nguồn thu từ lãi và phí. Tuy nhiên, do nghĩa vụ trả nợ được thực hiện trong tương lai, ngân hàng luôn phải đối mặt với sự không chắc chắn liên quan đến khả năng trả nợ của khách hàng.

Rủi ro tín dụng phát sinh khi khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính theo cam kết. Rủi ro này có thể bắt nguồn từ năng lực tài chính suy giảm, dòng tiền không ổn định, quản trị doanh nghiệp yếu, biến động thu nhập, thay đổi môi trường kinh doanh, biến động lãi suất, thông tin không đầy đủ hoặc hành vi gian lận. Hậu quả của rủi ro tín dụng có thể thể hiện qua nợ quá hạn, nợ xấu, chi phí dự phòng tăng, lợi nhuận giảm và mức độ an toàn vốn suy giảm.

Trong quản trị hiện đại, đánh giá tín dụng không nên chỉ được thực hiện một lần tại thời điểm phê duyệt. Ngân hàng cần cập nhật thông tin trong toàn bộ vòng đời khoản vay, theo dõi sự thay đổi của dư nợ, hành vi thanh toán, thời

hạn, tình trạng cơ cấu lại và nhóm nợ. Điều này tạo ra nhu cầu xây dựng các mô hình có khả năng học từ dữ liệu lịch sử và hỗ trợ dự báo rủi ro theo thời gian.

1.2 Tổng quan về chấm điểm và xếp hạng tín dụng

Chấm điểm tín dụng là quá trình sử dụng dữ liệu để tính toán một điểm số, một xác suất hoặc một giá trị định lượng phản ánh mức độ rủi ro của khách hàng. Xếp hạng tín dụng là quá trình chuyển kết quả đánh giá thành các nhóm hoặc hạng rủi ro có ý nghĩa quản trị. Hai khái niệm có liên hệ chặt chẽ nhưng không hoàn toàn đồng nhất.

Trong hoạt động ngân hàng, kết quả chấm điểm và xếp hạng có thể được sử dụng để hỗ trợ quyết định cấp tín dụng, xác định hạn mức, xây dựng chính sách lãi suất, giám sát khoản vay, phân loại khách hàng, hỗ trợ trích lập dự phòng và xây dựng hệ thống cảnh báo sớm.

Đối với nghiên cứu này, đầu ra cần dự báo là nhóm nợ từ 1 đến 5. Vì vậy, thuật ngữ “phân loại nhóm nợ” được sử dụng để mô tả trực tiếp bài toán, trong khi “chấm điểm tín dụng” và “xếp hạng tín dụng” được sử dụng trong phần cơ sở lý thuyết và tổng quan nghiên cứu.

1.3 Chuyển đổi số trong ngân hàng và vai trò của dữ liệu

Chuyển đổi số trong ngân hàng không chỉ là số hóa kênh giao dịch mà còn bao gồm tái cấu trúc quy trình nghiệp vụ, tự động hóa vận hành, xây dựng nền tảng dữ liệu và ứng dụng các mô hình phân tích trong quản trị.

Trong tín dụng, ngân hàng có thể khai thác nhiều nhóm dữ liệu như thông tin định danh, lịch sử hợp đồng, dư nợ, hạn mức, số ngày quá hạn, thời hạn khoản

vay, mục đích vay, nhóm nợ, trạng thái cơ cấu lại và dữ liệu hành vi. Khi dữ liệu được làm sạch và quản trị phù hợp, các mô hình học máy có thể hỗ trợ nhận diện quy luật mà quy tắc thủ công khó phát hiện. Tuy nhiên, dữ liệu ngân hàng cũng có những thách thức như giá trị thiếu, sai lệch nghiệp vụ, mất cân bằng lớp, thay đổi theo thời gian và nguy cơ rò rỉ thông tin.

1.4 Thành tựu và hạn chế của các phương pháp đánh giá tín dụng truyền thống

1.4.1 Phương pháp chuyên gia

Phương pháp chuyên gia dựa trên kinh nghiệm của cán bộ tín dụng và các khung đánh giá như 5C. Thành tựu của phương pháp này là hệ thống hóa các yếu tố định tính và định lượng cần xem xét, cho phép sử dụng thông tin về uy tín, năng lực quản trị, triển vọng ngành và tài sản bảo đảm.

Tuy nhiên, phương pháp này phụ thuộc vào kinh nghiệm cá nhân, khó bảo đảm tính nhất quán, khó mở rộng và khó lượng hóa mức đóng góp của từng yếu tố.

1.4.2 Altman và mô hình Z-score

Altman [?] đã đưa phân tích phân biệt đa biến vào dự báo phá sản doanh nghiệp thông qua mô hình:

$$Z = 1.2X_1 + 1.4X_2 + 3.3X_3 + 0.6X_4 + 1.0X_5.$$

Thành tựu nổi bật của Altman là chứng minh rằng việc kết hợp nhiều tỷ số tài chính có thể dự báo khó khăn tài chính tốt hơn việc xem xét từng chỉ số riêng

lẻ. Công trình này tạo nền tảng cho dự báo phá sản và xếp hạng doanh nghiệp.

Hạn chế của mô hình là phụ thuộc vào mẫu doanh nghiệp, ngành, chuẩn kế toán và giai đoạn nghiên cứu. Mô hình sử dụng chủ yếu dữ liệu kế toán, giả định quan hệ tuyến tính và không phù hợp trực tiếp với dữ liệu khách hàng cá nhân hoặc dữ liệu hành vi.

1.4.3 Ohlson và mô hình xác suất phá sản

Ohlson [?] sử dụng hồi quy logistic để ước lượng xác suất phá sản. Đóng góp quan trọng là chuyển đầu ra từ một điểm phân biệt sang xác suất, tạo điều kiện thuận lợi cho lựa chọn ngưỡng và diễn giải rủi ro.

Hạn chế là quan hệ giữa log-odds và biến đầu vào được giả định tuyến tính, còn các tương tác và quan hệ phi tuyến phải được thiết kế thủ công.

1.4.4 Hand và Henley

Hand và Henley [?] hệ thống hóa các phương pháp phân loại thống kê trong consumer credit scoring. Hai tác giả làm rõ rằng không tồn tại một thuật toán duy nhất luôn tốt nhất trên mọi bộ dữ liệu; kết quả phụ thuộc vào chất lượng dữ liệu, lựa chọn biến, cách chia mẫu và tiêu chí đánh giá.

Hạn chế chủ yếu xuất phát từ bối cảnh thời điểm nghiên cứu: boosting, explainable AI, fairness và dữ liệu quy mô lớn chưa phát triển như hiện nay; phần lớn nội dung tập trung vào phân loại nhị phân.

1.4.5 Lyn C. Thomas

Thomas [?] có đóng góp nổi bật trong việc hệ thống hóa application scoring và behavioural scoring. Ông mở rộng credit scoring từ quyết định phê duyệt ban đầu sang quản lý khách hàng trong suốt vòng đời khoản vay.

Hạn chế của nhiều mô hình truyền thống được Thomas tổng hợp là tập trung vào dữ liệu có cấu trúc, phân loại tốt–xấu và giả định quan hệ tương đối ổn định theo thời gian.

1.4.6 Jonathan N. Crook

Crook có nhiều đóng góp trong reject inference, behavioural scoring, survival analysis và mô hình rủi ro động. Các nghiên cứu của ông làm rõ selection bias do dữ liệu huấn luyện thường chỉ gồm khách hàng đã được duyệt và mở rộng bài toán từ “có vỡ nợ hay không” sang “khi nào vỡ nợ”.

Hạn chế của reject inference là không thể quan sát chắc chắn nhãn thật của hồ sơ bị từ chối; survival model cũng phụ thuộc vào các giả định có thể không phù hợp với mọi dữ liệu.

1.4.7 Baesens và Lessmann

Baesens và Lessmann có đóng góp quan trọng trong benchmark giữa các mô hình thống kê và học máy. Lessmann và cộng sự [?] cho thấy thứ hạng mô hình thay đổi theo dữ liệu, thước đo và quy trình thực nghiệm; ensemble thường cạnh tranh nhưng không thể mặc định luôn tối ưu.

Hạn chế của nhiều benchmark là sử dụng dữ liệu công khai nhỏ, cũ, chủ yếu nhị phân và chưa phản ánh đầy đủ dữ liệu ngân hàng thực tế.

1.4.8 Nhận xét tổng hợp

Các công trình nền tảng đã chuyển đánh giá tín dụng từ chủ quan sang định lượng, tạo ra điểm số và xác suất rủi ro, hình thành application scoring, behavioural scoring và quy trình kiểm định mô hình. Tuy nhiên, các hạn chế chung còn lại gồm tập trung vào nhị phân, khó mô hình hóa phi tuyến, phụ thuộc vào xây dựng biến thủ công, chưa xử lý đầy đủ mất cân bằng, thứ tự, drift và explainability.

1.5 Phát biểu bài toán nghiên cứu

Cho tập dữ liệu:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i, t_i)\}_{i=1}^N,$$

trong đó $\mathbf{x}_i$ là vector đặc trưng, $y_i \in \{1, 2, 3, 4, 5\}$ là nhóm nợ và t_i là thời điểm ghi nhận.

Mục tiêu là xây dựng:

$$f_{\theta} : \mathbf{x}_i \longrightarrow (p_{i1}, p_{i2}, p_{i3}, p_{i4}, p_{i5}),$$

với:

$$p_{ik} = P(Y_i = k \mid \mathbf{x}_i), \quad \sum_{k=1}^5 p_{ik} = 1.$$

Nhãn dự báo:

$$\hat{y}_i = \arg \max_{k \in \{1, 2, 3, 4, 5\}} p_{ik}.$$

Do năm nhóm có quan hệ về mức độ rủi ro:

$$1 < 2 < 3 < 4 < 5,$$

bài toán cần vừa đạt hiệu quả tổng thể, vừa nhận diện nhóm rủi ro cao, giảm

khoảng cách sai lệch, hạn chế đánh giá thấp rủi ro, duy trì khả năng tổng quát hóa theo thời gian và bảo đảm khả năng giải thích.

1.5.1 Điểm phát triển so với các công trình đi trước

Nghiên cứu phát triển hơn các công trình đi trước ở các khía cạnh:

1. chuyển từ nhị phân sang phân loại trực tiếp năm nhóm nợ;
2. xem xét thứ tự của nhãn bằng $|y_i - \hat{y}_i|$;
3. sử dụng dữ liệu thực tế đã ẩn danh từ ngân hàng Việt Nam;
4. xây dựng đặc trưng nghiệp vụ về thời hạn, mục đích vay, cơ cấu nợ và tính nhất quán;
5. ưu tiên chia dữ liệu theo thời gian;
6. xem mất cân bằng lớp là thành phần trung tâm;
7. so sánh sáu mô hình trong cùng một quy trình;
8. kết hợp hiệu quả dự báo với feature importance và SHAP;
9. lựa chọn mô hình theo hiệu quả, nhận diện rủi ro, sai lệch thứ tự và khả năng giải thích.

Tính mới của luận văn không nằm ở việc phát minh một thuật toán mới, mà nằm ở cách xây dựng, đánh giá và tổ chức bài toán phù hợp hơn với dữ liệu tín dụng thực tế.

1.6 Phương pháp nghiên cứu

Luận văn kết hợp nghiên cứu định tính để tổng quan tài liệu với nghiên cứu định lượng để xử lý dữ liệu, xây dựng mô hình và đánh giá thực nghiệm. Quy trình gồm thu thập, làm sạch, xây dựng đặc trưng, EDA, chia theo thời gian, xử lý mất cân bằng, huấn luyện, đánh giá và giải thích mô hình.

1.7 Mục tiêu nghiên cứu

1.7.1 Mục tiêu tổng quát

Xây dựng và đánh giá các mô hình học máy nhằm hỗ trợ phân loại năm nhóm nợ trên dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam.

1.7.2 Mục tiêu cụ thể

1. Hệ thống hóa lý thuyết và nghiên cứu liên quan.
2. Làm sạch và xây dựng đặc trưng từ dữ liệu thực tế.
3. Xây dựng Logistic Regression làm baseline.
4. So sánh với Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost.
5. Đánh giá ảnh hưởng của mất cân bằng lớp.
6. Phân tích tính thứ tự và mức độ nghiêm trọng của sai số.
7. Kiểm tra khả năng tổng quát hóa theo thời gian.
8. Giải thích kết quả bằng các phương pháp phù hợp.

1.8 Câu hỏi nghiên cứu

1. Những đặc trưng nào ảnh hưởng đáng kể đến phân loại nhóm nợ?
2. Học máy có cải thiện so với Logistic Regression hay không?
3. Mô hình nào cân bằng tốt nhất giữa hiệu quả tổng thể và nhận diện nhóm rủi ro?
4. Xử lý mất cân bằng ảnh hưởng thế nào đến nhóm 3, 4, 5?
5. Xem xét thứ tự có giúp giảm sai số nghiêm trọng hay không?
6. Mô hình có ổn định trên dữ liệu thời kỳ sau hay không?
7. Các biến quan trọng có phù hợp với nghiệp vụ tín dụng hay không?

1.9 Ý nghĩa khoa học và thực tiễn

Về khoa học, luận văn bổ sung bằng chứng thực nghiệm về phân loại năm nhóm nợ, kết hợp mất cân bằng, yếu tố thời gian và khả năng giải thích. Về thực tiễn, kết quả có thể hỗ trợ chuẩn hóa đánh giá, nhận diện khoản vay suy giảm và xây dựng cảnh báo sớm. Mô hình chỉ đóng vai trò hỗ trợ, không thay thế hoàn toàn quyết định của cán bộ tín dụng.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1 Tín dụng và rủi ro tín dụng

2.1.1 Khái niệm tín dụng

Tín dụng là quan hệ kinh tế trong đó bên cho vay chuyển giao quyền sử dụng một lượng giá trị cho bên đi vay trong một khoảng thời gian xác định, với nghĩa vụ hoàn trả theo các điều kiện đã thỏa thuận.

2.1.2 Khái niệm rủi ro tín dụng

Rủi ro tín dụng là khả năng phát sinh tổn thất do khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính. Rủi ro chịu ảnh hưởng từ năng lực tài chính, đặc điểm khoản vay, lịch sử tín dụng, chính sách cấp tín dụng và điều kiện kinh tế.

2.1.3 Phân loại nhóm nợ

Bảng 2.1: Các nhóm nợ trong nghiên cứu

1	Nợ đủ tiêu chuẩn	Mức rủi ro thấp.
2	Nợ cần chú ý	Đã xuất hiện dấu hiệu cần theo dõi.
3	Nợ dưới tiêu chuẩn	Khả năng thu hồi suy giảm đáng kể.
4	Nợ nghi ngờ	Mức rủi ro cao.
5	Nợ có khả năng mất vốn	Mức rủi ro cao nhất.

2.2 Chấm điểm và xếp hạng tín dụng

Chấm điểm tín dụng tạo ra một giá trị định lượng phản ánh rủi ro; xếp hạng tín dụng gán khách hàng hoặc khoản vay vào một nhóm rủi ro. Hai khái niệm liên hệ nhưng không đồng nhất [? ?].

Tổn thất kỳ vọng có thể biểu diễn:

$$EL = PD \times LGD \times EAD.$$

2.3 Các phương pháp đánh giá tín dụng truyền thống

Phương pháp chuyên gia có khả năng khai thác thông tin định tính nhưng chủ quan. Z-score của Altman có ý nghĩa nền tảng nhưng phụ thuộc dữ liệu kế toán và quan hệ tuyến tính. Logistic Regression dễ giải thích nhưng khó tự động nắm bắt tương tác phức tạp.

2.4 Trí tuệ nhân tạo và học máy

Học máy là nhánh của AI trong đó mô hình học quy luật từ dữ liệu. Bài toán của luận văn thuộc học có giám sát.

2.5 Các mô hình sử dụng

2.5.1 Logistic Regression đa lớp

$$P(Y = k | \mathbf{x}) = \frac{\exp(\beta_{k0} + \beta_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\beta_{j0} + \beta_j^T \mathbf{x})}.$$

2.5.2 Decision Tree

Decision Tree chia không gian đặc trưng bằng các điều kiện dạng $x_j \leq s$. Mô hình dễ giải thích nhưng dễ overfitting.

2.5.3 Random Forest

$$\hat{y} = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^B.$$

2.5.4 XGBoost

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t).$$

2.5.5 LightGBM

LightGBM tối ưu tốc độ và bộ nhớ, nhưng cần kiểm soát độ sâu và số lá.

2.5.6 CatBoost

CatBoost xử lý biến phân loại và sử dụng ordered boosting để hạn chế leakage.

2.6 Các vấn đề đặc thù của dữ liệu tín dụng

2.6.1 Mất cân bằng lớp

$$\mathcal{L} = - \sum_{i=1}^N w_{y_i} \sum_{k=1}^K \mathbb{I}(y_i = k) \log p_{ik}.$$

2.6.2 Tính thứ tự

$$MAE_{\text{ordinal}} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

2.6.3 Thay đổi theo thời gian

$$\mathcal{D}_{\text{train}} < \mathcal{D}_{\text{validation}} < \mathcal{D}_{\text{test}}.$$

2.6.4 Khả năng giải thích

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j.$$

2.7 Chỉ tiêu đánh giá

2.7.1 Accuracy

$$Accuracy = \frac{\sum_{k=1}^K C_{kk}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}.$$

2.7.2 Precision, Recall và F1

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k},$$
$$F1_k = 2 \frac{Precision_k \times Recall_k}{Precision_k + Recall_k}.$$

2.7.3 Macro F1

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

2.7.4 Weighted F1

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k.$$

2.7.5 Balanced Accuracy

$$\text{Balanced Accuracy} = \frac{1}{K} \sum_{k=1}^K \text{Recall}_k.$$

2.7.6 Ordinal MAE

$$\text{Ordinal MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

2.8 Tổng quan nghiên cứu liên quan

Hand và Henley [?] hệ thống hóa các phương pháp thống kê; Thomas [?] mở rộng từ application scoring sang behavioural scoring. Baesens và cộng sự [?] và Lessmann và cộng sự [?] cho thấy hiệu quả mô hình phụ thuộc vào dữ liệu, thước đo và quy trình đánh giá.

Brown và Mues [?] nhấn mạnh ảnh hưởng của mất cân bằng. Xia và cộng sự [?] cho thấy boosted tree có khả năng cải thiện dự báo. Barboza và cộng sự [?] ghi nhận kết quả cạnh tranh của các mô hình cây trong dự báo phá sản. Dastile và cộng sự [?] chỉ ra các hạn chế phổ biến về dữ liệu nhỏ, mất cân bằng, thiếu chuẩn đánh giá và khả năng giải thích.

Tại Việt Nam, nghiên cứu thường tập trung vào credit scoring cá nhân, rủi ro doanh nghiệp và dự báo nợ xấu. Tuy nhiên, chưa có nhiều nghiên cứu công bố

việc phân loại trực tiếp năm nhóm nợ trên dữ liệu thực tế, kết hợp so sánh nhiều mô hình, temporal split, ordinal evaluation và explainability.

2.9 Khoảng trống nghiên cứu

1. Phần lớn nghiên cứu dùng mục tiêu nhị phân.
2. Tính thứ tự của năm nhóm nợ chưa được khai thác đầy đủ.
3. Dữ liệu thực tế tại ngân hàng Việt Nam ít được công bố.
4. Random split vẫn phổ biến hơn temporal split.
5. Lớp rủi ro cao ít quan sát nhưng chưa được đánh giá đầy đủ.
6. Mô hình phức tạp thường thiếu khả năng giải thích.

2.10 Định hướng nghiên cứu

Luận văn xây dựng bài toán năm nhóm nợ, kiểm tra và xây dựng đặc trưng nghiệp vụ, sử dụng Logistic Regression làm baseline, so sánh với mô hình cây và boosting, xử lý mất cân bằng, chia theo thời gian, đánh giá bằng chỉ tiêu đa lớp và thứ tự, đồng thời giải thích mô hình bằng feature importance và SHAP.

2.11 Tóm tắt chương

Chương này đã trình bày cơ sở lý thuyết, thành tựu và hạn chế của các công trình nền tảng, các mô hình được sử dụng, các vấn đề đặc thù của dữ liệu tín dụng, tổng quan nghiên cứu, khoảng trống và định hướng của luận văn.

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Quy trình nghiên cứu

Nghiên cứu được thực hiện theo quy trình gồm các bước chính như Hình 3.1.

Hình 3.1: Quy trình nghiên cứu đề xuất

Quy trình nghiên cứu bao gồm các bước:

1. Thu thập dữ liệu tin dụng.
2. Tiền xử lý dữ liệu.
3. Phân tích khám phá dữ liệu (EDA).
4. Xây dựng đặc trưng.
5. Xử lý mất cân bằng dữ liệu.
6. Huấn luyện mô hình.
7. Đánh giá mô hình.

8. Lựa chọn mô hình tối ưu.

Quy trình này được xây dựng dựa trên phương pháp khai phá dữ liệu CRISP-DM và các nghiên cứu ứng dụng Machine Learning trong xếp hạng tín dụng [? ?].

3.2 Mô tả dữ liệu nghiên cứu

3.2.1 Nguồn dữ liệu

Dữ liệu sử dụng trong nghiên cứu được trích xuất từ hệ thống tín dụng của một ngân hàng thương mại tại Việt Nam.

Tập dữ liệu phản ánh lịch sử tín dụng của khách hàng cá nhân trong một khoảng thời gian xác định, bao gồm các thông tin:

- Thông tin nhân khẩu học.
- Thông tin hợp đồng tín dụng.
- Thông tin dư nợ.
- Thông tin lịch sử thanh toán.
- Thông tin CIC.
- Nhóm nợ thực tế.

Sau quá trình làm sạch dữ liệu, bộ dữ liệu nghiên cứu bao gồm khoảng 30.012 quan sát.

3.2.2 Biến mục tiêu

Biến mục tiêu của nghiên cứu là:

classification

Biến này phản ánh mức độ rủi ro tín dụng của khách hàng.

Bảng 3.1: Ý nghĩa các nhóm nhãn

Nhãn	Ý nghĩa
1	Nợ đủ tiêu chuẩn
2	Nợ cần chú ý
3	Nợ dưới tiêu chuẩn
4	Nợ nghi ngờ
5	Nợ có khả năng mất vốn

Bài toán nghiên cứu được xác định là bài toán phân loại đa lớp (Multi-class Classification).

3.2.3 Mô tả các nhóm biến

Các biến đầu vào được chia thành các nhóm chính:

1. Thông tin khách hàng.
2. Thông tin hợp đồng tín dụng.
3. Thông tin dư nợ.
4. Thông tin lịch sử thanh toán.
5. Thông tin CIC.

Ví dụ:

Bảng 3.2: Một số biến quan trọng trong nghiên cứu

Biến	Kiểu dữ liệu	Ý nghĩa
OPEN_DATE	Date	Ngày mở khoản vay
NGAYDENHAN	Date	Ngày đến hạn
DU_NO	Numeric	Dư nợ hiện tại
SO_NGAY_QUA_HAN	Numeric	Số ngày quá hạn
SO_HD_TIN_DUNG	Numeric	Số hợp đồng tín dụng
classification	Target	Nhóm nợ

3.3 Tiền xử lý dữ liệu

3.3.1 Làm sạch dữ liệu

Các bước làm sạch dữ liệu bao gồm:

- Loại bỏ bản ghi trùng lặp.
- Chuẩn hóa tên biến.
- Chuẩn hóa định dạng ngày tháng.
- Kiểm tra tính hợp lệ của dữ liệu.

Ví dụ:

$$OPEN_DATE \leq NGAYDENHAN$$

Các bản ghi vi phạm điều kiện trên được xem là bất thường và bị loại bỏ khỏi tập dữ liệu.

3.3.2 Xử lý giá trị thiếu

Giá trị thiếu (Missing Values) là vấn đề phổ biến trong dữ liệu tín dụng [?].

Trong nghiên cứu này:

- Biến số được thay thế bằng trung vị.
- Biến phân loại được thay thế bằng giá trị xuất hiện nhiều nhất.
- Một số biến ngày tháng được thay thế bằng ngày mặc định 01/01/3000.

3.3.3 Xử lý ngoại lệ

Các giá trị bất thường được phát hiện bằng:

- Boxplot.
- IQR Method.
- Z-score.

Các quan sát ngoại lệ cực đoan được Winsorize hoặc loại bỏ khỏi dữ liệu huấn luyện.

3.4 Phân tích khám phá dữ liệu

3.4.1 Phân bố biến mục tiêu

Biểu đồ phân bố của biến classification được trình bày tại Hình 3.2.

Hình 3.2: Phân bố biến mục tiêu

Kết quả cho thấy dữ liệu bị mất cân bằng mạnh giữa các nhóm nợ.

3.4.2 Phân tích tương quan

Hệ số tương quan Pearson được sử dụng để đánh giá mối quan hệ giữa các biến số [?].

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Ma trận tương quan được trực quan hóa bằng Heatmap.

3.5 Xây dựng đặc trưng

Feature Engineering là bước quan trọng nhằm cải thiện hiệu quả dự báo của mô hình [?].

3.5.1 Biến thời gian

Từ các trường ngày tháng:

- OPEN_DATE
- NGÀYDENHAN

tạo thêm:

- Tuổi khoản vay.
- Số ngày còn lại đến hạn.
- Thời gian tín dụng.

Ví dụ:

$$LoanAge = CurrentDate - OPEN_DATE$$

3.5.2 Biến hành vi tín dụng

Các đặc trưng được xây dựng:

- Tỷ lệ quá hạn.
- Tỷ lệ sử dụng tín dụng.
- Tổng số khoản vay.
- Tần suất phát sinh nợ quá hạn.

3.5.3 Mã hóa biến phân loại

Các biến phân loại được xử lý bằng:

- Label Encoding.
- One-Hot Encoding.

3.6 Xử lý mất cân bằng dữ liệu

Dữ liệu tín dụng thường có hiện tượng mất cân bằng lớp nghiêm trọng [?].

Trong nghiên cứu này áp dụng phương pháp SMOTE (Synthetic Minority Over-sampling Technique) [?].

Nguyên lý của SMOTE là tạo thêm các mẫu tổng hợp cho lớp thiểu số:

$$x_{new} = x_i + \lambda (x_{nn} - x_i)$$

Trong đó:

- x_i là điểm dữ liệu gốc.

- x_{nn} là láng giềng gần nhất.
- $\lambda \in [0, 1]$.

3.7 Thiết kế thực nghiệm

3.7.1 Chia tập dữ liệu

Dữ liệu được chia theo tỷ lệ:

- Training set: 80%
- Test set: 20%

Kỹ thuật Stratified Split được sử dụng để đảm bảo phân bố nhãn tương tự giữa hai tập dữ liệu.

3.7.2 Cross Validation

Để giảm sai lệch trong đánh giá mô hình, nghiên cứu sử dụng kỹ thuật K-Fold Cross Validation với:

$$K = 5$$

3.8 Xây dựng mô hình

Các mô hình được huấn luyện bao gồm:

1. Logistic Regression [?]
2. Decision Tree [?]

3. Random Forest [?]

4. XGBoost [?]

5. LightGBM [?]

6. CatBoost [?]

Mỗi mô hình được tối ưu tham số bằng Grid Search.

3.9 Đánh giá mô hình

Các chỉ tiêu đánh giá bao gồm:

3.9.1 Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

3.9.2 Precision

$$Precision = \frac{TP}{TP + FP}$$

3.9.3 Recall

$$Recall = \frac{TP}{TP + FN}$$

3.9.4 F1-Score

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

3.9.5 Confusion Matrix

Confusion Matrix cho phép đánh giá khả năng phân loại của mô hình trên từng nhóm nợ.

3.9.6 ROC-AUC

ROC-AUC được sử dụng để đánh giá khả năng phân biệt giữa các lớp [?].

3.10 Tóm tắt chương

Chương này đã trình bày nguồn dữ liệu nghiên cứu, quy trình tiền xử lý dữ liệu, kỹ thuật xây dựng đặc trưng, phương pháp xử lý mất cân bằng dữ liệu, thiết kế thực nghiệm và các tiêu chí đánh giá mô hình.

Các nội dung này là cơ sở để xây dựng, huấn luyện và đánh giá các mô hình trí tuệ nhân tạo phục vụ bài toán xếp hạng tín dụng trong Chương 4. ““

““latex

Chương 4

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

4.1 Môi trường thực nghiệm

4.1.1 Cấu hình phần cứng

Các thí nghiệm được thực hiện trên máy tính có cấu hình như sau:

Bảng 4.1: Cấu hình môi trường thực nghiệm

CPU	Apple M-series / Intel Core i7
RAM	16 GB
Ổ cứng	SSD 512 GB
Hệ điều hành	macOS / Ubuntu

4.1.2 Môi trường phần mềm

Bảng 4.2: Các công cụ sử dụng trong nghiên cứu

Ngôn ngữ	Python 3.x
Pandas	Xử lý dữ liệu
NumPy	Tính toán số học
Scikit-learn	Machine Learning
XGBoost	Gradient Boosting
LightGBM	Gradient Boosting
CatBoost	Gradient Boosting
SHAP	Explainable AI
Matplotlib	Visualization
Seaborn	Visualization

4.2 Phân tích dữ liệu sau tiền xử lý

4.2.1 Phân bố dữ liệu

Sau quá trình làm sạch dữ liệu, tập dữ liệu cuối cùng bao gồm:

$$N = 30012$$

quan sát.

Phân bố biến mục tiêu được thể hiện trong Bảng 4.3.

Bảng 4.3: Phân bố các nhóm tín dụng

Nhóm	Số lượng	Tỷ lệ (%)
1	xxx	xx.xx
2	xxx	xx.xx
3	xxx	xx.xx
4	xxx	xx.xx
5	xxx	xx.xx

Hình 4.1: Phân bố biến mục tiêu

Kết quả cho thấy dữ liệu có hiện tượng mất cân bằng giữa các lớp, trong đó nhóm nợ đủ tiêu chuẩn chiếm tỷ trọng lớn nhất.

4.2.2 Phân tích tương quan

Ma trận tương quan Pearson được sử dụng để đánh giá mối quan hệ giữa các biến số.

Hình 4.2: Ma trận tương quan giữa các biến

Kết quả cho thấy các biến liên quan đến lịch sử tín dụng, số ngày quá hạn và dư nợ có mức tương quan đáng kể với biến mục tiêu.

4.3 Kết quả huấn luyện mô hình

4.3.1 Logistic Regression

Logistic Regression được sử dụng làm mô hình cơ sở (Baseline Model) do tính đơn giản và khả năng diễn giải cao [?].

Bảng 4.4 trình bày kết quả của mô hình.

Bảng 4.4: Kết quả Logistic Regression

Accuracy	xx.xx
Precision	xx.xx
Recall	xx.xx
F1-score	xx.xx

4.3.2 Decision Tree

Decision Tree được xây dựng nhằm khai thác các quan hệ phi tuyến trong dữ liệu [?].

Bảng 4.5: Kết quả Decision Tree

Accuracy	xx.xx
Precision	xx.xx
Recall	xx.xx
F1-score	xx.xx

4.3.3 Random Forest

Random Forest giúp giảm hiện tượng overfitting bằng cách kết hợp nhiều cây quyết định [?].

Bảng 4.6: Kết quả Random Forest

Accuracy	xx.xx
Precision	xx.xx
Recall	xx.xx
F1-score	xx.xx

4.3.4 XGBoost

XGBoost là thuật toán boosting được đánh giá rất cao trong các bài toán tín dụng [?].

Bảng 4.7: Kết quả XGBoost

Accuracy	xx.xx
Precision	xx.xx
Recall	xx.xx
F1-score	xx.xx

4.3.5 LightGBM

LightGBM được thiết kế nhằm tối ưu tốc độ huấn luyện trên dữ liệu lớn [?].

Bảng 4.8: Kết quả LightGBM

Accuracy	xx.xx
Precision	xx.xx
Recall	xx.xx
F1-score	xx.xx

4.3.6 CatBoost

CatBoost xử lý tốt các biến phân loại và hạn chế overfitting [?].

Bảng 4.9: Kết quả CatBoost

Accuracy	xx.xx
Precision	xx.xx
Recall	xx.xx
F1-score	xx.xx

4.4 So sánh các mô hình

Bảng 4.10 trình bày kết quả tổng hợp.

Bảng 4.10: So sánh các mô hình

Mô hình	Accuracy	Precision	Recall	F1-score
Logistic Regression	xx.xx	xx.xx	xx.xx	xx.xx
Decision Tree	xx.xx	xx.xx	xx.xx	xx.xx
Random Forest	xx.xx	xx.xx	xx.xx	xx.xx
XGBoost	xx.xx	xx.xx	xx.xx	xx.xx
LightGBM	xx.xx	xx.xx	xx.xx	xx.xx
CatBoost	xx.xx	xx.xx	xx.xx	xx.xx

Hình 4.3: So sánh Accuracy giữa các mô hình

Kết quả cho thấy các mô hình Ensemble Learning có hiệu quả cao hơn đáng kể so với Logistic Regression và Decision Tree.

4.5 Đánh giá chi tiết mô hình tốt nhất

Giả sử CatBoost đạt kết quả tốt nhất.

4.5.1 Confusion Matrix

Hình 4.4: Confusion Matrix của CatBoost

Ma trận nhầm lẫn cho thấy phần lớn các khách hàng thuộc nhóm nợ đủ tiêu chuẩn được nhận diện chính xác.

Tuy nhiên các nhóm 3, 4 và 5 vẫn tồn tại hiện tượng nhầm lẫn do số lượng quan sát thấp hơn.

4.5.2 ROC-AUC

Đường cong ROC được sử dụng để đánh giá khả năng phân biệt giữa các lớp [?].

Hình 4.5: ROC Curve của mô hình CatBoost

Giá trị AUC trung bình đạt:

$$AUC = xx.xx$$

cho thấy khả năng phân loại tốt của mô hình.

4.6 Giải thích mô hình bằng SHAP

Một trong những hạn chế của các mô hình Ensemble là khả năng giải thích thấp.

Để khắc phục vấn đề này, nghiên cứu sử dụng SHAP (SHapley Additive exPlanations) [?].

SHAP được xây dựng dựa trên lý thuyết giá trị Shapley:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)]$$

4.6.1 Feature Importance

Hình 4.6: Tầm quan trọng của các đặc trưng theo SHAP

Kết quả cho thấy các biến ảnh hưởng lớn nhất đến xếp hạng tín dụng bao gồm:

- Số ngày quá hạn.
- Dư nợ hiện tại.
- Lịch sử tín dụng.
- Số khoản vay đang hoạt động.
- Tuổi khoản vay.

4.6.2 SHAP Summary Plot

Hình 4.7: SHAP Summary Plot

SHAP Summary Plot cho thấy chiều hướng tác động của từng biến lên xác suất rơi vào nhóm nợ xấu.

4.7 Thảo luận kết quả

Kết quả nghiên cứu cho thấy các thuật toán Machine Learning hiện đại có khả năng hỗ trợ hiệu quả cho bài toán xếp hạng tín dụng.

Các mô hình boosting như XGBoost, LightGBM và CatBoost đạt hiệu năng cao hơn các mô hình truyền thống. Điều này phù hợp với các nghiên cứu trước đây của Baesens và cộng sự [?] cũng như Lessmann và cộng sự [?].

Việc áp dụng SMOTE giúp cải thiện khả năng nhận diện các nhóm nợ có tỷ lệ xuất hiện thấp. Đồng thời, SHAP giúp nâng cao khả năng giải thích của mô hình, đáp ứng yêu cầu minh bạch trong lĩnh vực tài chính ngân hàng.

Từ góc độ thực tiễn, mô hình đề xuất có thể được tích hợp vào hệ thống xếp hạng tín dụng nội bộ nhằm hỗ trợ cán bộ tín dụng trong quá trình đánh giá khách hàng và cảnh báo sớm rủi ro tín dụng.

4.8 Tóm tắt chương

Chương này đã trình bày kết quả thực nghiệm của các mô hình học máy trên bộ dữ liệu tín dụng thực tế của một ngân hàng thương mại tại Việt Nam.

Kết quả cho thấy các mô hình Ensemble Learning, đặc biệt là CatBoost và XGBoost, đạt hiệu quả dự báo cao hơn so với các mô hình truyền thống. Bên cạnh đó, phương pháp SHAP giúp giải thích các quyết định của mô hình và xác định các yếu tố ảnh hưởng quan trọng đến kết quả xếp hạng tín dụng.

Các kết quả này là cơ sở để đưa ra kết luận và khuyến nghị trong Chương 5.

““

““latex

Chương 5

KẾT LUẬN VÀ KIẾN NGHỊ

5.1 Kết luận

Trong bối cảnh chuyển đổi số đang diễn ra mạnh mẽ trong ngành ngân hàng, việc ứng dụng trí tuệ nhân tạo vào hoạt động quản trị rủi ro tín dụng ngày càng trở thành một xu hướng tất yếu. Xếp hạng tín dụng không chỉ đóng vai trò hỗ trợ quyết định cấp tín dụng mà còn là công cụ quan trọng giúp ngân hàng kiểm soát rủi ro, nâng cao chất lượng danh mục tín dụng và đảm bảo an toàn hoạt động.

Xuất phát từ yêu cầu thực tiễn đó, luận văn đã thực hiện nghiên cứu đề tài:

"Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam"

Mục tiêu của nghiên cứu là xây dựng và đánh giá các mô hình trí tuệ nhân tạo nhằm hỗ trợ bài toán xếp hạng tín dụng khách hàng dựa trên dữ liệu thực tế của ngân hàng thương mại.

Thông qua quá trình nghiên cứu, luận văn đã hoàn thành các nội dung chính bao gồm:

- Tổng quan cơ sở lý thuyết về tín dụng, rủi ro tín dụng, xếp hạng tín dụng và trí tuệ nhân tạo trong lĩnh vực tài chính ngân hàng.
- Tổng hợp và phân tích các nghiên cứu trong nước và quốc tế liên quan đến bài toán chấm điểm tín dụng và xếp hạng tín dụng.
- Xây dựng quy trình xử lý dữ liệu tín dụng bao gồm làm sạch dữ liệu, xử lý dữ liệu thiếu, phát hiện dữ liệu bất thường, xây dựng đặc trưng và xử lý mất cân bằng dữ liệu.
- Huấn luyện và đánh giá nhiều mô hình học máy khác nhau như Logistic Regression, Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost.
- So sánh hiệu quả của các mô hình trên bộ dữ liệu thực tế và lựa chọn mô hình có hiệu năng tốt nhất.
- Ứng dụng phương pháp SHAP nhằm giải thích kết quả dự báo của mô hình, nâng cao tính minh bạch trong quá trình ra quyết định tín dụng.

Kết quả nghiên cứu cho thấy các mô hình học máy hiện đại có khả năng hỗ trợ hiệu quả cho bài toán xếp hạng tín dụng. So với các phương pháp truyền thống, các mô hình Ensemble Learning như Random Forest, XGBoost, LightGBM và CatBoost đạt hiệu năng dự báo cao hơn, đồng thời có khả năng khai thác các quan hệ phi tuyến trong dữ liệu tín dụng.

Bên cạnh đó, việc sử dụng các kỹ thuật xử lý mất cân bằng dữ liệu như SMOTE giúp cải thiện khả năng nhận diện các nhóm khách hàng có mức độ rủi ro cao, vốn thường chiếm tỷ lệ nhỏ trong tập dữ liệu.

Kết quả nghiên cứu cũng cho thấy các yếu tố như lịch sử tín dụng, số ngày quá hạn, dư nợ hiện tại, số lượng khoản vay đang hoạt động và thời gian quan hệ

tín dụng là những yếu tố quan trọng ảnh hưởng đến kết quả xếp hạng tín dụng của khách hàng.

5.2 Đóng góp của nghiên cứu

5.2.1 Đóng góp về mặt khoa học

Về mặt học thuật, luận văn đã hệ thống hóa các cơ sở lý thuyết liên quan đến:

- Rủi ro tín dụng;
- Xếp hạng tín dụng;
- Trí tuệ nhân tạo;
- Học máy trong lĩnh vực tài chính ngân hàng.

Nghiên cứu đồng thời cung cấp thêm bằng chứng thực nghiệm về hiệu quả của các thuật toán học máy hiện đại trong bài toán xếp hạng tín dụng tại Việt Nam.

Kết quả nghiên cứu góp phần bổ sung nguồn tài liệu tham khảo cho các nghiên cứu tiếp theo về:

- Credit Scoring;
- Credit Rating;
- Default Prediction;
- Early Warning System;
- Explainable Artificial Intelligence.

5.2.2 Đóng góp về mặt thực tiễn

Về mặt thực tiễn, nghiên cứu đã xây dựng được quy trình hoàn chỉnh từ xử lý dữ liệu đến xây dựng mô hình xếp hạng tín dụng có thể áp dụng trong môi trường ngân hàng.

Mô hình đề xuất có thể hỗ trợ:

- Đánh giá mức độ tín nhiệm của khách hàng.
- Cảnh báo sớm rủi ro tín dụng.
- Hỗ trợ cán bộ tín dụng trong quá trình ra quyết định.
- Nâng cao chất lượng danh mục tín dụng.
- Giảm thiểu rủi ro phát sinh nợ xấu.

Ngoài ra, kết quả nghiên cứu có thể được tích hợp vào hệ thống xếp hạng tín dụng nội bộ hoặc hệ thống hỗ trợ quyết định của ngân hàng.

5.3 Hạn chế của nghiên cứu

Mặc dù đạt được các kết quả tích cực, nghiên cứu vẫn tồn tại một số hạn chế nhất định.

Thứ nhất, dữ liệu nghiên cứu chỉ được thu thập từ một ngân hàng thương mại. Do đó, kết quả nghiên cứu có thể chưa phản ánh đầy đủ đặc điểm của toàn bộ hệ thống ngân hàng tại Việt Nam.

Thứ hai, bộ dữ liệu nghiên cứu chủ yếu bao gồm các thông tin tín dụng truyền thống. Các nguồn dữ liệu thay thế như dữ liệu giao dịch số, dữ liệu hành

vi khách hàng, dữ liệu mạng xã hội hoặc dữ liệu viễn thông chưa được khai thác.

Thứ ba, nghiên cứu tập trung vào các thuật toán học máy truyền thống và các mô hình boosting. Các mô hình học sâu (Deep Learning) chưa được xem xét trong phạm vi nghiên cứu.

Thứ tư, mô hình được đánh giá chủ yếu trên dữ liệu lịch sử. Việc triển khai và đánh giá hiệu quả trong môi trường thực tế chưa được thực hiện.

Thứ năm, mặc dù đã sử dụng SHAP để giải thích mô hình, khả năng giải thích của các mô hình học máy phức tạp vẫn còn là một thách thức trong lĩnh vực tài chính ngân hàng.

5.4 Kiến nghị đối với ngân hàng thương mại

Từ kết quả nghiên cứu, tác giả đề xuất một số kiến nghị đối với ngân hàng thương mại như sau:

5.4.1 Nâng cao chất lượng dữ liệu

Ngân hàng cần tiếp tục đầu tư vào hệ thống quản trị dữ liệu nhằm:

- Chuẩn hóa dữ liệu tín dụng.
- Nâng cao chất lượng dữ liệu đầu vào.
- Giảm thiểu dữ liệu thiếu và dữ liệu sai lệch.
- Xây dựng kho dữ liệu tập trung.

5.4.2 Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng

Ngân hàng nên từng bước tích hợp các mô hình trí tuệ nhân tạo vào hệ thống xếp hạng tín dụng hiện có nhằm:

- Tăng độ chính xác trong đánh giá tín dụng.
- Rút ngắn thời gian phê duyệt hồ sơ.
- Tăng khả năng cảnh báo sớm rủi ro.
- Hỗ trợ tự động hóa quy trình tín dụng.

5.4.3 Phát triển hệ thống Explainable AI

Trong môi trường ngân hàng, khả năng giải thích quyết định là yếu tố đặc biệt quan trọng.

Do đó, ngân hàng cần:

- Xây dựng các mô hình có khả năng giải thích.
- Kết hợp SHAP hoặc các công cụ Explainable AI.
- Đảm bảo tính minh bạch trong quá trình ra quyết định.

5.5 Hướng phát triển trong tương lai

Trong tương lai, nghiên cứu có thể được mở rộng theo một số hướng sau:

5.5.1 Mở rộng quy mô dữ liệu

Thu thập dữ liệu từ nhiều ngân hàng khác nhau nhằm xây dựng mô hình có khả năng tổng quát hóa tốt hơn.

5.5.2 Khai thác dữ liệu phi truyền thống

Bổ sung các nguồn dữ liệu thay thế như:

- Dữ liệu giao dịch số.
- Dữ liệu thanh toán điện tử.
- Dữ liệu hành vi khách hàng.
- Dữ liệu từ ví điện tử.

5.5.3 Ứng dụng Deep Learning

Nghiên cứu các mô hình học sâu như:

- Artificial Neural Network (ANN);
- Deep Neural Network (DNN);
- AutoEncoder;
- Transformer;
- TabNet.

để cải thiện hiệu quả xếp hạng tín dụng.

5.5.4 Xây dựng hệ thống cảnh báo sớm

Kết hợp mô hình xếp hạng tín dụng với hệ thống cảnh báo sớm nhằm dự báo khả năng chuyển nhóm nợ của khách hàng trong tương lai.

5.5.5 Triển khai thực tế

Nghiên cứu khả năng triển khai mô hình trên nền tảng Web hoặc Mobile Banking nhằm hỗ trợ cán bộ tín dụng trong môi trường thực tế.

5.6 Kết luận chương

Chương này đã tổng kết toàn bộ nội dung nghiên cứu của luận văn, làm rõ những kết quả đạt được, các đóng góp khoa học và thực tiễn của đề tài.

Kết quả nghiên cứu cho thấy trí tuệ nhân tạo có tiềm năng lớn trong việc nâng cao hiệu quả xếp hạng tín dụng tại các ngân hàng thương mại Việt Nam. Các mô hình học máy hiện đại không chỉ giúp cải thiện độ chính xác dự báo mà còn hỗ trợ ngân hàng trong công tác quản trị rủi ro tín dụng và chuyển đổi số.

Mặc dù vẫn còn một số hạn chế, nghiên cứu đã tạo nền tảng cho các hướng phát triển tiếp theo trong lĩnh vực ứng dụng trí tuệ nhân tạo vào quản trị rủi ro tín dụng tại Việt Nam. ““