ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM

ĐÀM CÔNG DANH

danh.dc251317M@sis.hust.edu.vn

Chuyên ngành Toán Tin

Giảng viên hướng dẫn: **TS. Lê Kim Thư** Chữ kí của GVHD

TS. Lê Thị Thanh An

Bộ môn: **Toán Tin**

Viện: **Toán ứng dụng và Tin học**

HÀ NỘI - 2026

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

BẢN XÁC NHẬN CHỈNH SỬA LUẬN VĂN THẠC SĨ

Họ và tên tác giả luận văn: Đàm Công Danh.

Đề tài luận văn: Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam.

Chuyên ngành: Toán Tin.

Mã học viên: 20251317M

Tác giả, Người hướng dẫn khoa học và Hội đồng chấm luận văn xác nhận tác giả đã sửa chữa, bổ sung luận văn theo biên bản họp Hội đồng ngày ... với các nội dung sau.

Ngày tháng năm 2026

Giảng viên hướng dẫn **Tác giả luận văn**

CHỦ TỊCH HỘI ĐỒNG

ĐỀ TÀI LUẬN VĂN

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

TS. Lê Kim Thư

Lời cam đoan

Tôi xin cam đoan luận văn thạc sĩ *"Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam"* là công trình nghiên cứu do tôi thực hiện dưới sự hướng dẫn khoa học của TS. Lê Kim Thư và TS. Lê Thị Thanh An.

Các số liệu, kết quả trình bày trong luận văn là trung thực, có nguồn gốc rõ ràng và chưa từng được công bố trong bất kỳ công trình nào khác. Những nội dung tham khảo, trích dẫn từ các công trình của tác giả khác đều được ghi rõ nguồn trong danh mục tài liệu tham khảo.

Tôi xin chịu trách nhiệm hoàn toàn về tính trung thực của nội dung luận văn.

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

Lời cảm ơn

Trước hết, em xin trân trọng cảm ơn Khoa Toán Tin đã tạo điều kiện thuận lợi và hỗ trợ em trong quá trình học tập, nghiên cứu tại chương trình thạc sĩ Toán Tin.

Em xin bày tỏ lòng biết ơn sâu sắc tới TS. Lê Kim Thư và TS. Lê Thị Thanh An, những người đã tận tình hướng dẫn, góp ý chuyên môn và chia sẻ kinh nghiệm trong suốt quá trình thực hiện luận văn. Em đồng thời xin chân thành cảm ơn quý thầy, cô và các học viên khóa 2026 của Khoa Toán Tin đã trao đổi, động viên và hỗ trợ em hoàn thành nghiên cứu này.

Mặc dù đã nỗ lực hoàn thiện, luận văn khó tránh khỏi những hạn chế nhất định. Em kính mong nhận được các ý kiến đóng góp của quý thầy, cô và bạn đọc để nghiên cứu được tiếp tục bổ sung và hoàn thiện.

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

Mục lục

Lời cam đoan **iv**

Lời cảm ơn **v**

Một số thuật ngữ viết tắt **xi**

Danh mục bảng **xv**

Danh mục hình vẽ **xvi**

Mở đầu **1**

1 TỔNG QUAN NGHIÊN CỨU VÀ CƠ SỞ LÝ THUYẾT **6**

1.1 Bối cảnh và động lực nghiên cứu 6

1.1.1 Tín dụng, rủi ro tín dụng và quản trị theo vòng đời khoản vay . 6

1.1.2 Tính hồi cứu của thông tin nhóm nợ và nhu cầu cảnh báo sớm nội bộ 7

1.2 Cơ sở lý luận về tín dụng và phân loại nhóm nợ 8

1.2.1 Khái niệm tín dụng, rủi ro tín dụng và phân loại nhóm nợ . . . 8

1.2.2 Xếp hạng tín dụng và tổn thất kỳ vọng 9

1.3 Các phương pháp đánh giá tín dụng và mô hình học máy 10

1.3.1 Từ phương pháp chuyên gia đến mô hình thống kê 10

1.3.2 Mô hình tuyến tính và cây quyết định 10

1.3.3 Các mô hình tăng cường gradient 11
1.4 Thách thức khi mô hình hóa dữ liệu tín dụng 12
1.4.1 Mất cân bằng lớp và tính thứ tự của nhóm nợ 12
1.4.2 Khả năng giải thích mô hình 13
1.5 Tổng quan nghiên cứu và khoảng trống nghiên cứu 14
1.5.1 Nghiên cứu quốc tế 14
1.5.2 Nghiên cứu tại Việt Nam 15
1.5.3 Khoảng trống nghiên cứu và định vị đề tài 17
Tóm tắt chương 18

2 DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU 19
2.1 Bài toán nghiên cứu và quy trình tổng thể 19
2.1.1 Phát biểu bài toán phân loại năm nhóm nợ 19
2.1.2 Phát biểu bài toán dự báo chuyển nhóm nợ 20
2.1.3 Quy trình nghiên cứu và môi trường triển khai 20
2.2 Dữ liệu nghiên cứu 21
2.2.1 Bộ dữ liệu A 21
2.2.2 Bộ dữ liệu B và ba kỳ báo cáo 22
2.2.3 Kết quả làm sạch và đặc điểm phân phối dữ liệu 24
2.3 Tiền xử lý và xây dựng tập đặc trưng 26
2.3.1 Kiểm soát rò rỉ dữ liệu 26
2.3.2 Xây dựng đặc trưng nghiệp vụ 29
2.3.3 WOE/IV: phạm vi sử dụng và sàng lọc rò rỉ 31
2.3.4 Tập đặc trưng huấn luyện và nhóm đặc trưng nghiệp vụ 32
2.3.5 Điền khuyết, chuẩn hóa và mã hóa 33
2.4 Chia mẫu, xử lý mất cân bằng và huấn luyện mô hình 35
2.4.1 Chia mẫu và thiết kế kiểm định 35
2.4.2 Xử lý mất cân bằng lớp 36
2.4.3 Cấu hình mô hình và tìm kiếm siêu tham số 37

2.5 Thiết kế thực nghiệm cho bài toán dự báo chuyển nhóm nợ 38
2.5.1 Ghép kỳ báo cáo và xây dựng nhãn 38
2.5.2 Kiểm soát rò rỉ và rủi ro sai lệch chọn mẫu 38
2.5.3 Thiết kế đánh giá cho sự kiện hiếm 39
2.6 Thước đo đánh giá và nguyên tắc báo cáo kết quả 40
2.6.1 Thước đo cho bài toán phân loại năm lớp 40
2.6.2 Thước đo sự kiện hiếm và nguyên tắc báo cáo 40
Tóm tắt chương 41

3 KẾT QUẢ VÀ THẢO LUẬN 42
3.1 Kết quả phân loại nhóm nợ trên bộ dữ liệu A 44
3.1.1 So sánh mô hình trên cấu hình chính 44
3.1.2 Hiệu năng theo số lượng đặc trưng 45
3.1.3 Đóng góp của các nhóm đặc trưng 45
3.2 Kết quả phân loại nhóm nợ trên bộ dữ liệu B 46
3.2.1 Mức mất cân bằng và so sánh mô hình trên tập kiểm định nội bộ 46
3.2.2 Đánh giá ngoài thời gian trên kỳ 20260531 47
3.2.3 Hiệu năng theo từng nhóm nợ và các lớp hiếm 48
3.2.4 Hiệu năng theo số lượng đặc trưng 50
3.2.5 Đóng góp của các nhóm đặc trưng 51
3.3 Giải thích mô hình và độ ổn định của kết luận giải thích 53
3.3.1 Kết quả SHAP trên hai bộ dữ liệu 53
3.3.2 Đối chiếu Gain và SHAP trên cùng cấu hình 54
3.3.3 Đối chiếu kết quả giải thích giữa hai bộ dữ liệu 55
3.4 Độ nhạy theo chiến lược mất cân bằng và siêu tham số 55
3.4.1 So sánh bốn chiến lược xử lý mất cân bằng 55
3.4.2 Độ nhạy theo siêu tham số 56
3.4.3 Độ nhạy theo lựa chọn tiền xử lý 58
3.5 Kết quả bài toán dự báo chuyển nhóm nợ 59

3.5.1 So sánh mô hình và chiến lược trên cặp kỳ 1 59
3.5.2 Đánh giá theo tỷ lệ rà soát (Recall@k) 60
3.5.3 Giải thích bằng SHAP 62
3.5.4 Độ ổn định giữa hai cặp kỳ quan sát 63
3.5.5 Ý nghĩa và giới hạn ứng dụng 67
3.6 Thảo luận theo bốn câu hỏi nghiên cứu 67
Tóm tắt chương 69

4 KẾT LUẬN VÀ KIẾN NGHỊ 70
4.1 Kết luận theo bốn câu hỏi nghiên cứu 70
4.2 Đóng góp của nghiên cứu 72
4.2.1 Đóng góp về phương pháp 72
4.2.2 Đóng góp thực tiễn 72
4.3 Hạn chế của nghiên cứu 73
4.3.1 Dữ liệu và độ ổn định theo thời gian 73
4.3.2 Thiết kế kiểm định và lựa chọn mô hình 74
4.3.3 Tiền xử lý và diễn giải kết quả 74
4.4 Kiến nghị đối với ngân hàng 75
4.4.1 Dữ liệu ảnh chụp theo thời gian và chất lượng trường dữ liệu . 75
4.4.2 Thiết kế ngưỡng cảnh báo theo chi phí 76
4.4.3 Quản trị và giám sát mô hình 77
4.5 Hướng nghiên cứu tiếp theo 78

Tài liệu tham khảo 79

Phụ lục 87
P1 Công nghệ sử dụng 87
P2 Chi tiết khảo sát và làm sạch dữ liệu 88
P3 Information Value đầy đủ 91
P4 Ví dụ hồ sơ trước và sau xử lý 93

P5 Không gian tìm kiếm siêu tham số 94
P6 Kết quả bổ sung 95

Một số thuật ngữ viết tắt

Viết tắt	Thuật ngữ tiếng Anh	Diễn giải tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ML	Machine Learning	Học máy
NHTM	Commercial Bank	Ngân hàng thương mại
NHNN	State Bank of Vietnam	Ngân hàng Nhà nước Việt Nam
TCTD	Credit Institution	Tổ chức tín dụng
XHTD	Credit Rating	Xếp hạng tín dụng
CIC	Credit Information Center	Trung tâm Thông tin tín dụng Quốc gia Việt Nam
PD	Probability of Default	Xác suất khách hàng không thực hiện nghĩa vụ trả nợ
LGD	Loss Given Default	Tỷ lệ tổn thất khi xảy ra vỡ nợ
EAD	Exposure at Default	Giá trị dư nợ tại thời điểm vỡ nợ
IV	Information Value	Giá trị thông tin, dùng đánh giá sức phân biệt của đặc trưng
WOE	Weight of Evidence	Trọng số bằng chứng, cơ sở để tính Information Value
EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu
IQR	Interquartile Range	Khoảng tứ phân vị, dùng phát hiện giá trị ngoại lệ
ETL	Extract – Transform – Load	Quy trình trích xuất, chuyển đổi và nạp dữ liệu; `ETL_DATE` là ngày chốt dữ liệu của kỳ báo cáo

Viết tắt	Thuật ngữ tiếng Anh	Diễn giải tiếng Việt
SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật sinh mẫu tổng hợp cho lớp thiểu số
SHAP	SHapley Additive exPlanations	Phương pháp giải thích đóng góp của đặc trưng dựa trên giá trị Shapley
ROC	Receiver Operating Characteristic	Đường cong biểu diễn quan hệ giữa tỷ lệ dương tính thật và dương tính giả
AUC	Area Under the Curve	Diện tích dưới đường cong đánh giá khả năng phân biệt
AP	Average Precision	Độ chính xác trung bình, xấp xỉ diện tích dưới đường Precision–Recall; thước đo chính của bài toán chuyển nhóm
F1	F1-score	Trung bình điều hòa của Precision và Recall
MAE	Mean Absolute Error	Sai số tuyệt đối trung bình; Ordinal MAE đo số bậc sai lệch trung bình giữa nhóm dự báo và nhóm thực
CV	Cross-validation	Kiểm định chéo
API	Application Programming Interface	Giao diện lập trình ứng dụng
RF	Random Forest	Thuật toán rừng ngẫu nhiên
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường gradient tối ưu
LightGBM	Light Gradient Boosting Machine	Thuật toán tăng cường gradient dạng cây tối ưu cho hiệu năng
CatBoost	Categorical Boosting	Thuật toán tăng cường gradient xử lý trực tiếp biến phân loại

Danh mục bảng

1.1 Năm nhóm nợ và tiêu chí định lượng chủ yếu 8

2.1 Phân bố năm nhóm nợ trong bộ dữ liệu A 22
2.2 Phân bố năm nhóm nợ trong bộ dữ liệu B (kỳ 20260430) 23
2.3 Tổng hợp kết quả làm sạch và khảo sát dữ liệu 24
2.4 Rà soát rò rỉ: Macro-F1 khi loại các biến nghi vấn (tập kiểm định; bộ B thêm kỳ sau) 28
2.5 Các biến được xây dựng thêm từ dữ liệu ban đầu 29
2.6 Phân bố số biến theo mức Information Value 32
2.7 Từ cột dữ liệu thô tới tập đặc trưng huấn luyện 33
2.8 Ma trận chuyển nhóm nợ của cặp 1 (20260430 → 20260531) 38

3.1 Tóm tắt kết quả chính theo bốn câu hỏi nghiên cứu 43
3.2 Kết quả trên tập kiểm định của bộ dữ liệu A (11 đặc trưng, SMOTE) . 44
3.3 Hiệu năng XGBoost theo số lượng đặc trưng — bộ dữ liệu A 45
3.4 Kết quả trên tập kiểm định của bộ dữ liệu B (20 đặc trưng, SMOTE) . 46
3.5 Kết quả trên tập ngoài thời gian 20260531 (không tham gia huấn luyện và chọn mô hình) 47
3.6 Precision, Recall và F1 của LightGBM theo nhóm nợ — tập kiểm định và kỳ sau 48
3.7 Ma trận nhầm lẫn năm lớp của LightGBM (hàng: nhóm thực; cột: nhóm dự báo) 49

3.8 Recall các nhóm hiếm theo mô hình — tập kiểm định và kỳ sau 50
3.9 Hiệu năng LightGBM theo số lượng đặc trưng — bộ dữ liệu B, tập kiểm định 51
3.10 Tỷ trọng SHAP theo nhóm nghiệp vụ trên hai bộ dữ liệu 53
3.11 Gain và SHAP trên cùng mô hình: tỷ trọng nhóm và tương quan hạng Spearman 54
3.12 Bốn chiến lược mất cân bằng — XGBoost, bộ A 56
3.13 Bốn chiến lược mất cân bằng — LightGBM, bộ B 56
3.14 Độ nhạy Macro-F1 theo siêu tham số (65 cấu hình bộ A, 60 cấu hình bộ B) 57
3.15 Kiểm chứng ba lựa chọn tiền xử lý — Macro-F1 58
3.16 Sáu mô hình dự báo chuyển nhóm nợ trên cặp 1 (kiểm định chéo 5×10) 60
3.17 Recall@k và Precision@k trên tập kiểm định minh họa của hai cặp kỳ 61
3.18 Mức độ quan trọng SHAP (trung bình $|\phi_j|$) của mô hình dự báo chuyển nhóm, mẫu phân tầng 63
3.19 Đặc điểm sự kiện và hiệu năng trên hai cặp kỳ 64
3.20 Bảy phép kiểm tra chẩn đoán cặp kỳ 2 65

4.1 Kiến nghị về dữ liệu, gắn với phát hiện cụ thể trong luận văn 75
P1.1 Các công nghệ chính được sử dụng trong nghiên cứu 87
P2.1 Số bản ghi có trường ngày lưu dạng số thứ tự Excel — bộ dữ liệu A . . 88
P2.2 Thống kê mô tả và tỷ lệ ngoại lệ IQR — biến số của bộ dữ liệu A . . . 88
P2.3 Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A 88
P2.4 Thống kê mô tả, tỷ lệ thiếu và ngoại lệ IQR — biến số của bộ dữ liệu B (kỳ 20260430) 89
P3.1 Information Value của 13 biến — bộ dữ liệu A 91
P3.2 Information Value của 20 đặc trưng — bộ dữ liệu B 92
P4.1 Ba hồ sơ của bộ A trước và sau xử lý 93
P4.2 Ba hồ sơ của bộ B có giá trị thiếu, trước và sau xử lý 93

P5.1 Không gian tìm kiếm siêu tham số — bộ dữ liệu A (65 cấu hình) . . . 94
P5.2 Không gian tìm kiếm siêu tham số — bộ dữ liệu B (60 cấu hình) . . . 95
P6.1 Ma trận nhầm lẫn của LightGBM và XGBoost — bộ A, tập kiểm định (hàng: nhóm thực; cột: nhóm dự báo) 95
P6.2 Gain và SHAP từng biến — XGBoost 11 biến, bộ dữ liệu A 96
P6.3 SHAP (trung bình $|\phi_j|$) và Gain từng biến — LightGBM 20 biến, bộ dữ liệu B 96
P6.4 Ảnh hưởng của việc sửa lỗi điền khuyết ba biến cơ cấu nợ — bộ dữ liệu B, Macro-F1 97
P6.5 Ma trận chuyển nhóm nợ của cặp 2 (20260531 $\rightarrow$ 20260630) 97
P6.6 Khoản vay bị loại do không có mặt trên tập ngoài thời gian, theo nhóm nợ tại T 97

Danh mục hình vẽ

1.1 Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng 9
1.2 Cơ chế cộng dồn các cây trong XGBoost 11

2.1 Quy trình nghiên cứu tổng thể 21
2.2 Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001) 26

3.1 Đường Precision–Recall của XGBoost trên tập kiểm định minh họa, cặp 1 (nhãn PR-AUC trong hình là AP) 62

P2.1 Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A 89
P2.2 Ma trận tương quan giữa 12 biến số (8 biến gốc và 4 biến tạo thêm) — bộ dữ liệu B 90

TÓM TẮT NỘI DUNG LUẬN VĂN

Luận văn nghiên cứu ứng dụng học máy trong phân loại năm nhóm nợ trên hai bộ dữ liệu của một ngân hàng thương mại tại Việt Nam, đồng thời khảo sát khả năng dự báo khoản vay chuyển sang nhóm nợ cao hơn trong tháng tiếp theo trên bộ dữ liệu có ba kỳ báo cáo (hai cặp kỳ). Quy trình gồm tiền xử lý, xây dựng đặc trưng, kiểm soát rò rỉ ba lớp, xử lý mất cân bằng, đối sánh sáu mô hình và giải thích bằng Gain và SHAP. Macro-F1 và Ordinal MAE là chỉ tiêu của bài toán năm lớp; average precision (AP) và Recall@k là chỉ tiêu của bài toán chuyển nhóm.

LightGBM đạt Macro-F1 cao nhất trên tập kiểm định, bằng 0,6484 ở bộ A và 0,6989 ở bộ B, và giữ được mức này khi áp dụng sang kỳ báo cáo kế tiếp của bộ B (0,7023). Sai số của các mô hình cây tổ hợp hầu hết chỉ lệch một bậc nhóm nợ; điểm yếu lớn nhất và ổn định qua các kỳ là nhóm 2, với khoảng 77% hồ sơ bị dự báo thành nhóm 1. Thí nghiệm loại biến cho thấy một phần lớn hiệu năng phân loại năm nhóm dựa vào các biến hình thành cùng lúc với nhãn (lãi chưa thu ngoại bảng, số ngày đến đáo hạn), nên kết quả này phản ánh khả năng tái hiện trạng thái nhóm nợ hơn là năng lực dự báo. Về giải thích mô hình, Gain và SHAP tính trên cùng một mô hình thống nhất về thứ hạng nhóm thông tin (tương quan hạng Spearman 0,90 và 0,89); giữa hai bộ dữ liệu, hai nhóm dẫn đầu trùng khớp nhưng tương quan hạng 0,80 trên năm nhóm chưa đạt ý nghĩa thống kê.

Với bài toán dự báo chuyển nhóm, XGBoost đạt AP 0,1806 trên cặp kỳ thứ nhất, gấp khoảng 67 lần mức ngẫu nhiên, tương ứng việc rà soát 5% danh mục bắt được 56,6% số khoản vay sắp chuyển nhóm. Trên cặp kỳ thứ hai độc lập, với số lượng và cơ cấu sự kiện gần như giống hệt, mọi mô hình chỉ đạt mức ngẫu nhiên. Bảy phép kiểm tra chẩn đoán đã được thực hiện để loại trừ lỗi xử lý, trong đó một lỗi thật được phát hiện và sửa (lệch định dạng trường ngày giữa các kỳ); sau khi sửa, kết luận về cặp kỳ thứ hai không thay đổi. Khả năng dự báo chuyển nhóm nợ vì vậy có thể tồn tại trong một số giai đoạn nhưng chưa được chứng minh là ổn định theo thời gian; dữ liệu nhiều kỳ là điều kiện tiên quyết trước khi xây dựng công cụ cảnh báo sớm.

THESIS ABSTRACT

This thesis applies machine learning to classify five debt groups using two datasets from a Vietnamese commercial bank, and examines whether loans moving to a higher-risk group in the following month can be forecast on a dataset with three reporting periods (two period pairs). The pipeline covers preprocessing, feature engineering, three-layer leakage control, class-imbalance handling, a benchmark of six models, and interpretation with Gain and SHAP. Macro-F1 and Ordinal MAE are used for the five-class problem; average precision (AP) and Recall@k for the transition problem.

LightGBM attains the highest validation Macro-F1, at 0.6484 on dataset A and 0.6989 on dataset B, and retains that level when applied to the next reporting period of dataset B (0.7023). Errors of the tree ensembles are mostly off by a single debt group; the largest and most persistent weakness is group 2, of which about 77% of records are predicted as group 1. Ablation shows that much of the five-class performance relies on variables formed together with the label (off-balance-sheet unpaid interest, days to maturity), so these results reflect the ability to reproduce the current debt group rather than to forecast risk. On interpretation, Gain and SHAP computed on the same model agree on the ranking of information groups (Spearman rank correlation 0.90 and 0.89); across the two datasets the top two groups coincide, but the rank correlation of 0.80 over five groups is not statistically significant.

For the transition problem, XGBoost reaches an AP of 0.1806 on the first period pair, about 67 times the random level, meaning that reviewing 5% of the portfolio captures 56.6% of the loans about to migrate. On the independent second pair, with almost identical event counts and composition, every model performs at chance level. Seven diagnostic checks were run to rule out processing errors; one genuine error was found and fixed (inconsistent date formats across periods), after which the conclusion about the second pair was unchanged. The ability to forecast debt-group transitions may therefore exist in some periods but has not been shown to be stable over time; multi-period data is a prerequisite for an early-warning tool.

Học viên thực hiện

Đàm Công Danh

MỞ ĐẦU

Lý do lựa chọn đề tài

Tín dụng là hoạt động cốt lõi của ngân hàng thương mại, đồng thời là nguồn phát sinh rủi ro có ảnh hưởng trực tiếp đến lợi nhuận, chất lượng tài sản và mức độ an toàn của ngân hàng. Đánh giá và xếp hạng tín dụng vì vậy không chỉ phục vụ quyết định cấp tín dụng mà còn hỗ trợ giám sát khoản vay, phân loại nợ và nhận diện sớm dấu hiệu suy giảm chất lượng tín dụng.

Sự gia tăng về quy mô và mức độ đa dạng của dữ liệu ngân hàng đặt ra yêu cầu đổi mới phương pháp đánh giá rủi ro. Các phương pháp truyền thống có ưu điểm về tính minh bạch, nhưng gặp hạn chế trước quan hệ phi tuyến, tương tác phức tạp và tình trạng mất cân bằng giữa các nhóm nợ. Học máy mở ra khả năng khai thác dữ liệu hiệu quả hơn, với điều kiện hiệu quả dự báo đi cùng khả năng giải thích, kiểm soát và giám sát để mô hình có thể được dùng như một công cụ hỗ trợ quyết định.

Bên cạnh đó, thông tin nhóm nợ mà ngân hàng nhận được, kể cả từ Trung tâm Thông tin tín dụng Quốc gia (CIC), phản ánh trạng thái đã được ghi nhận của khoản vay. Nhu cầu thực tế của ngân hàng là biết trước những khoản vay có nguy cơ chuyển sang nhóm nợ cao hơn để rà soát kịp thời. Từ hai lý do trên, đề tài *"Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam"* được lựa chọn.

Mục tiêu và câu hỏi nghiên cứu

Mục tiêu tổng quát. Xây dựng và đánh giá các mô hình học máy hỗ trợ phân loại năm nhóm nợ trên dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam, xác định nhóm thông tin có giá trị và kiểm chứng khả năng dự báo chuyển nhóm nợ phục vụ cảnh báo sớm.

Mục tiêu cụ thể.

1. Hệ thống hóa cơ sở lý thuyết và tổng quan nghiên cứu liên quan.
2. Làm sạch dữ liệu, kiểm soát rò rỉ, xây dựng đặc trưng nghiệp vụ và xử lý mất cân bằng lớp.
3. So sánh sáu mô hình phân loại (Logistic Regression làm mô hình cơ sở, Decision Tree, Random Forest, XGBoost, LightGBM, CatBoost) theo cả chỉ tiêu tổng thể, từng nhóm nợ và sai lệch theo thứ tự.
4. Xác định nhóm thông tin nghiệp vụ quan trọng và đánh giá độ ổn định của kết quả giải thích.
5. Xây dựng và kiểm chứng bài toán dự báo chuyển nhóm nợ trên hai cặp kỳ báo cáo thật.

Câu hỏi nghiên cứu

CH1. Chiến lược xử lý mất cân bằng lớp ảnh hưởng thế nào đến hiệu năng phân loại nhóm nợ, và mô hình nào phù hợp nhất trên từng bộ dữ liệu?

CH2. Nhiều đặc trưng hơn có luôn cải thiện hiệu quả phân loại hay không, và nhóm thông tin nghiệp vụ nào đóng góp nhiều nhất?

CH3. Kết luận về mức độ quan trọng của đặc trưng có ổn định khi đổi thước đo giải thích (Gain, SHAP) và khi chuyển sang bộ dữ liệu khác hay không?

CH4. Chỉ với thông tin sẵn có tại thời điểm đánh giá, mô hình có dự báo được khoản vay chuyển sang nhóm nợ cao hơn trong tháng tiếp theo hay không, và kết quả có ổn định giữa các kỳ quan sát?

Đối tượng, phạm vi và dữ liệu nghiên cứu

Đối tượng nghiên cứu là việc ứng dụng các phương pháp thống kê và học máy trong phân loại mức độ rủi ro tín dụng theo năm nhóm nợ và trong dự báo chuyển nhóm nợ ngắn hạn.

Nghiên cứu sử dụng hai bộ dữ liệu tín dụng đã ẩn danh của cùng một ngân hàng thương mại tại Việt Nam; tên ngân hàng và thông tin định danh trực tiếp không được công bố.

- **Bộ A** (`Data_credit_rating_VN.xlsx`): 27.001 khoản vay, 21 cột, là ảnh chụp tại một thời điểm.
- **Bộ B** (Thông tin tín dụng): ba kỳ báo cáo liên tiếp 30/04/2026, 31/05/2026 và 30/06/2026 của cùng một danh mục, mỗi kỳ khoảng 100 nghìn khế ước và 33 cột.

Hai bộ khác nhau về quy mô, cấu trúc biến và phân bố nhóm nợ, nên kết quả giữa hai bộ chỉ được đối chiếu về xu hướng. Bài toán dự báo chuyển nhóm chỉ thực hiện trên bộ B, bộ duy nhất có nhiều kỳ báo cáo.

Phương pháp và ý nghĩa của nghiên cứu

Luận văn kết hợp tổng quan tài liệu với phương pháp định lượng: làm sạch và xây dựng đặc trưng, huấn luyện sáu mô hình với bốn chiến lược xử lý mất cân bằng, đánh giá ngoài mẫu trên tập kiểm định và trên kỳ báo cáo sau, giải thích mô hình bằng Gain và SHAP. Với bài toán chuyển nhóm, ba kỳ của bộ B được ghép thành hai cặp kỳ độc lập theo khóa khế ước; mô hình được đánh giá bằng kiểm định chéo lặp và kiểm định chuyển giao giữa hai cặp. Chi tiết được trình bày ở Chương 2.

Về khoa học, luận văn bổ sung bằng chứng thực nghiệm về phân loại năm nhóm nợ có thứ tự trên dữ liệu ngân hàng Việt Nam, đối chiếu kết quả giải thích giữa hai bộ dữ liệu độc lập và đánh giá khả năng dự báo chuyển nhóm trên hai cặp kỳ thật thay vì một cặp. Luận văn không đề xuất thuật toán mới; đóng góp nằm ở thiết kế bài toán và tổ chức kiểm chứng thực nghiệm (Mục 1.5.3).

Về thực tiễn, kết quả giúp ngân hàng xác định nhóm dữ liệu cần duy trì chất lượng, nhận diện điều kiện dữ liệu cần có trước khi xây dựng công cụ cảnh báo sớm nội bộ và thiết kế ngưỡng cảnh báo theo năng lực rà soát. Mô hình chỉ đóng vai trò hỗ trợ, không thay thế quyết định của cán bộ tín dụng hay quy trình phân loại nợ theo quy định.

Kết cấu luận văn

Ngoài Mở đầu, Tài liệu tham khảo và Phụ lục, luận văn gồm bốn chương:

- **Chương 1: Tổng quan nghiên cứu và cơ sở lý thuyết** — bối cảnh, cơ sở lý luận về tín dụng và nhóm nợ, các mô hình học máy, thách thức khi mô hình hóa dữ liệu tín dụng, tổng quan nghiên cứu và khoảng trống nghiên cứu.
- **Chương 2: Dữ liệu và phương pháp nghiên cứu** — phát biểu hai bài toán, dữ liệu, tiền xử lý và xây dựng đặc trưng, chia mẫu và huấn luyện, thiết kế bài toán chuyển nhóm và thước đo đánh giá.
- **Chương 3: Kết quả và thảo luận** — kết quả trên bộ A và bộ B, giải thích mô

hình, độ nhạy theo chiến lược mất cân bằng và siêu tham số, kết quả dự báo chuyển nhóm và thảo luận theo bốn câu hỏi nghiên cứu.

- **Chương 4: Kết luận và kiến nghị** — kết luận, đóng góp, hạn chế, kiến nghị đối với ngân hàng và hướng nghiên cứu tiếp theo.

Chương 1

TỔNG QUAN NGHIÊN CỨU VÀ CƠ SỞ LÝ THUYẾT

Chương này trình bày bối cảnh và động lực nghiên cứu, cơ sở lý luận về tín dụng và phân loại nhóm nợ, các mô hình học máy được sử dụng, những thách thức đặc thù khi mô hình hóa dữ liệu tín dụng, và cuối cùng là tổng quan nghiên cứu làm căn cứ xác định khoảng trống mà luận văn hướng tới.

1.1 Bối cảnh và động lực nghiên cứu

1.1.1 Tín dụng, rủi ro tín dụng và quản trị theo vòng đời khoản vay

Hoạt động tín dụng là kênh cung ứng vốn chính của ngân hàng thương mại cho cá nhân và tổ chức, đồng thời tạo nguồn thu từ lãi và phí. Do nghĩa vụ trả nợ được thực hiện trong tương lai, ngân hàng luôn đối mặt với rủi ro tín dụng, tức khả năng khách hàng không thực hiện đầy đủ nghĩa vụ tài chính theo cam kết. Rủi ro này có thể bắt nguồn từ năng lực tài chính suy giảm, dòng tiền không ổn định, biến động thu nhập hoặc môi trường kinh doanh, thông tin không đầy đủ hay hành vi gian lận; hậu quả thể hiện qua

nợ quá hạn, nợ xấu, chi phí dự phòng tăng và mức độ an toàn vốn suy giảm.

Trong quản trị hiện đại, đánh giá tín dụng không chỉ thực hiện một lần tại thời điểm phê duyệt mà cần được cập nhật trong toàn bộ vòng đời khoản vay: theo dõi dư nợ, hành vi thanh toán, thời hạn, tình trạng cơ cấu lại và nhóm nợ. Chuyển đổi số giúp ngân hàng lưu trữ các thông tin này một cách hệ thống; khi dữ liệu được làm sạch và quản trị phù hợp, mô hình học máy có thể nhận diện những quy luật mà quy tắc thủ công khó phát hiện. Tuy vậy, dữ liệu ngân hàng cũng có những đặc điểm gây khó khăn cho mô hình hóa như giá trị thiếu, mất cân bằng lớp, thay đổi theo thời gian và nguy cơ rò rỉ thông tin (Mục 1.4).

1.1.2 Tính hồi cứu của thông tin nhóm nợ và nhu cầu cảnh báo sớm nội bộ

Nhóm nợ tại một thời điểm báo cáo mô tả trạng thái đã được ghi nhận của khoản vay, được xác định chủ yếu từ số ngày quá hạn và các căn cứ định tính theo quy định (Mục 1.2.1). Thông tin nhóm nợ trao đổi qua CIC cũng có bản chất này: nó cho ngân hàng biết khoản vay *đã* ở nhóm nào, không cho biết khoản vay *sẽ* chuyển sang nhóm nào. Vì vậy, việc dùng các trường trực tiếp hình thành nhóm nợ, như số ngày quá hạn, để phân loại lại chính trạng thái đó có thể đạt độ chính xác rất cao nhưng không chứng minh được khả năng dự báo.

Nhu cầu thực tế của ngân hàng là một công cụ cảnh báo sớm nội bộ: từ thông tin sẵn có tại thời điểm đánh giá, xếp hạng các khoản vay theo nguy cơ chuyển sang nhóm nợ cao hơn để ưu tiên rà soát. Khung pháp lý hiện hành về phân loại tài sản có là Thông tư số 31/2024/TT-NHNN, có hiệu lực từ 01/07/2024, thay thế Thông tư số 11/2021/TT-NHNN và được sửa đổi, bổ sung bởi Thông tư số 37/2025/TT-NHNN [38, 39, 37]. Luận văn sử dụng các văn bản này làm căn cứ về bối cảnh; kết quả mô hình không phải căn cứ để thay thế quy trình phân loại nợ theo quy định. Luận văn cũng không đo lường độ trễ cập nhật hay chi phí tra cứu CIC, nên không đối sánh hiệu quả với CIC; bài toán chuyển nhóm ở Chương 2 được xây dựng để khảo sát tín hiệu

cảnh báo sớm trong phạm vi dữ liệu cho phép.

1.2 Cơ sở lý luận về tín dụng và phân loại nhóm nợ

1.2.1 Khái niệm tín dụng, rủi ro tín dụng và phân loại nhóm nợ

Tín dụng là quan hệ kinh tế trong đó bên cho vay chuyển giao quyền sử dụng một lượng giá trị cho bên đi vay trong một khoảng thời gian xác định, với nghĩa vụ hoàn trả theo điều kiện đã thỏa thuận. Rủi ro tín dụng là khả năng phát sinh tổn thất do bên vay không thực hiện đầy đủ nghĩa vụ; mức rủi ro chịu ảnh hưởng của năng lực tài chính, đặc điểm khoản vay, lịch sử tín dụng, chính sách cấp tín dụng và điều kiện kinh tế [4].

Tại Việt Nam, nợ được phân thành năm nhóm có thứ tự rủi ro tăng dần. Theo phương pháp định lượng tại Điều 10 Thông tư số 31/2024/TT-NHNN, căn cứ chủ yếu là số ngày quá hạn của khoản nợ (Bảng 1.1); tổ chức tín dụng còn có thể phân loại vào nhóm rủi ro cao hơn dựa trên đánh giá định tính hoặc kết quả xếp hạng tín dụng nội bộ theo phương pháp định tính [38].

Bảng 1.1: Năm nhóm nợ và tiêu chí định lượng chủ yếu

Nhóm	**Tên gọi**	**Tiêu chí định lượng chủ yếu**	**Mức rủi ro**
1	Nợ đủ tiêu chuẩn	Trong hạn hoặc quá hạn dưới 10 ngày	Thấp nhất
2	Nợ cần chú ý	Quá hạn từ 10 đến 90 ngày	Cần theo dõi
3	Nợ dưới tiêu chuẩn	Quá hạn từ 91 đến 180 ngày	Nợ xấu
4	Nợ nghi ngờ	Quá hạn từ 181 đến 360 ngày	Nợ xấu, cao
5	Nợ có khả năng mất vốn	Quá hạn trên 360 ngày	Nợ xấu, cao nhất

Nguồn: Tác giả tổng hợp từ Thông tư số 31/2024/TT-NHNN [38]; bảng chỉ nêu tiêu chí số ngày quá hạn, không liệt kê đầy đủ các trường hợp cơ cấu lại và phân loại định tính.

Hai hệ quả của Bảng 1.1 định hình thiết kế thực nghiệm. Thứ nhất, các trường số ngày và số tiền quá hạn gần như quyết định nhãn, nên phải loại khỏi đầu vào

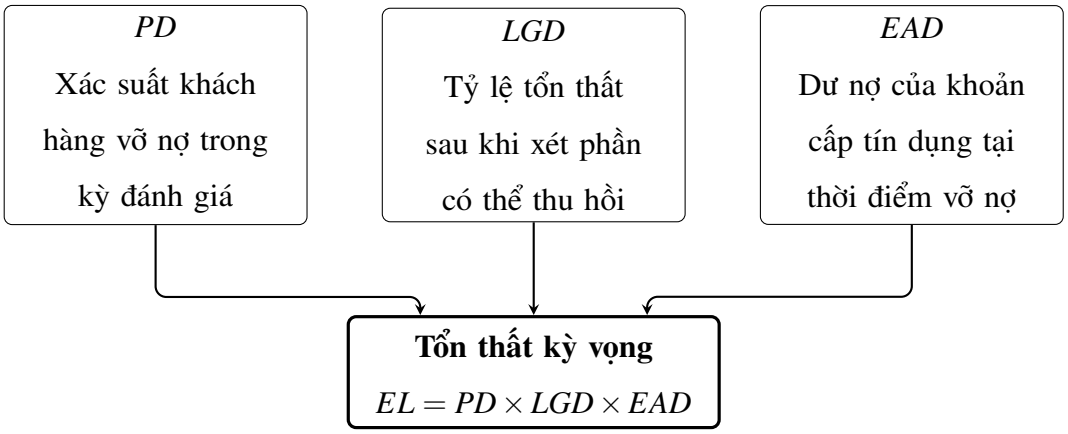
(Mục 2.3.1). Thứ hai, năm nhóm có thứ tự, nên sai lệch một bậc và sai lệch bốn bậc không nghiêm trọng như nhau (Mục 1.4.1).

1.2.2 Xếp hạng tín dụng và tổn thất kỳ vọng

Xếp hạng tín dụng là quá trình gán khách hàng hoặc khoản vay vào một hạng rủi ro dựa trên thông tin tài chính, đặc điểm khoản vay và lịch sử thực hiện nghĩa vụ. Trong phạm vi luận văn, năm nhóm nợ được xem là các mức rủi ro có thứ tự, và mô hình hỗ trợ nhận diện nhóm nợ tương ứng của từng khoản vay. Theo khung Basel, tổn thất kỳ vọng được biểu diễn:

$$EL = PD \times LGD \times EAD,$$

trong đó *PD* là xác suất vỡ nợ trong kỳ đánh giá, *LGD* là tỷ lệ tổn thất khi vỡ nợ sau khi xét khả năng thu hồi và *EAD* là dư nợ tại thời điểm vỡ nợ (Hình 1.1) [5]. Luận văn tập trung vào phân loại trạng thái rủi ro và dự báo chuyển nhóm, chưa ước lượng đủ ba cấu phần của *EL*.



Hình 1.1: Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng

Nguồn: Tác giả tổng hợp và vẽ lại từ Basel Committee on Banking Supervision [5].

1.3 Các phương pháp đánh giá tín dụng và mô hình học máy

1.3.1 Từ phương pháp chuyên gia đến mô hình thống kê

Đánh giá tín dụng đã trải qua ba giai đoạn. Giai đoạn đầu dựa trên phương pháp chuyên gia, tiêu biểu là khung 5C (*Character, Capacity, Capital, Collateral, Conditions*) — công cụ tổ chức thông tin để cán bộ tín dụng tổng hợp nhận định, khai thác được thông tin định tính nhưng mang tính chủ quan [20, 48]. Giai đoạn thứ hai là các mô hình thống kê định lượng, mở đầu bằng phân tích phân biệt đa biến của Altman [1] và hồi quy logistic của Ohlson [40], cho phép ước lượng xác suất rủi ro nhưng giả định quan hệ tuyến tính giữa biến đầu vào và rủi ro (trên thang logit). Giai đoạn thứ ba là học máy: mô hình học quy luật từ dữ liệu thay vì theo quy tắc cố định, nắm bắt được quan hệ phi tuyến và tương tác mà không cần thiết kế thủ công. Bài toán của luận văn thuộc học có giám sát.

1.3.2 Mô hình tuyến tính và cây quyết định

Logistic Regression đa lớp ước lượng xác suất của lớp k:

$$P(Y = k \mid \mathbf{x}) = \frac{\exp(\beta_{k0} + \beta_k^T \mathbf{x})}{\sum_{j=1}^{K} \exp(\beta_{j0} + \beta_j^T \mathbf{x})},$$

trong đó K là số lớp, $\mathbf{x}$ là véc-tơ đặc trưng, β_{k0} và β_k là hệ số chặn và véc-tơ hệ số của lớp k [21]. Mô hình dễ diễn giải và được dùng làm mô hình cơ sở.

Decision Tree chia không gian đặc trưng bằng các điều kiện dạng $x_j \leq s$; mô hình dễ diễn giải nhưng dễ quá khớp nếu không kiểm soát độ sâu và số quan sát tại lá [44].

Random Forest tổ hợp B cây huấn luyện trên các mẫu bootstrap và tập con đặc trưng ngẫu nhiên, dự báo bằng biểu quyết đa số $\hat{y} = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^{B}$, trong đó $h_b(\mathbf{x})$ là dự báo của cây thứ b. Việc lấy trung bình nhiều cây làm giảm phương sai so với cây đơn

[6].

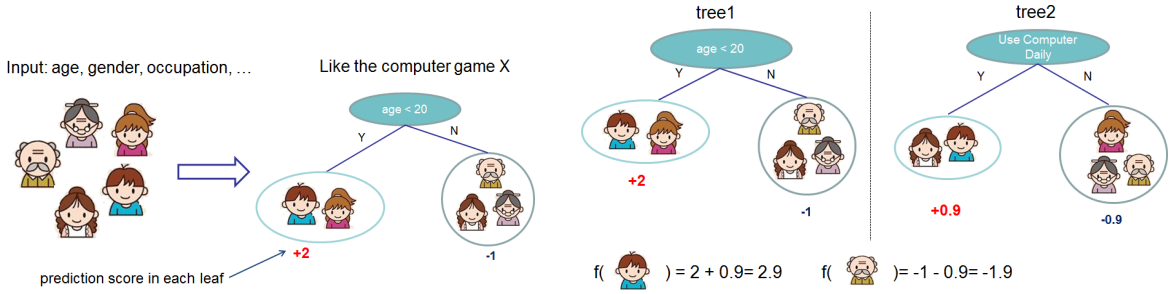
1.3.3 Các mô hình tăng cường gradient

Các mô hình boosting xây dựng cây tuần tự, mỗi cây mới hiệu chỉnh phần sai số còn lại của tổ hợp trước đó [18].

XGBoost tối thiểu hóa tại vòng t hàm mục tiêu có chính quy:

$$\mathscr{L}^{(t)} = \sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t),$$

trong đó n là số quan sát huấn luyện, $l(\cdot)$ là hàm mất mát, $\hat{y}_i^{(t-1)}$ là dự báo tích lũy trước vòng t, f_t là cây mới và $\Omega(f_t)$ phạt độ phức tạp của cây [11]. Hình 1.2 minh họa cơ chế cộng dồn: điểm dự báo của một hồ sơ là tổng điểm tại các lá mà hồ sơ rơi vào ở từng cây.



(a) Một cây CART đơn

(b) Cộng dồn điểm của nhiều cây: $f(\mathbf{x}) = \sum_t f_t(\mathbf{x})$

Hình 1.2: Cơ chế cộng dồn các cây trong XGBoost

Nguồn: Tài liệu chính thức của XGBoost [16], giấy phép Apache 2.0; truy cập ngày 15/08/2026.

LightGBM tối ưu tốc độ và bộ nhớ bằng Gradient-based One-Side Sampling và Exclusive Feature Bundling, đồng thời phát triển cây theo lá có mức giảm hàm mất mát lớn nhất thay vì theo tầng. Cách phát triển này hội tụ nhanh nhưng tạo cây không cân đối và dễ quá khớp khi dữ liệu nhỏ, nên cần kiểm soát `num_leaves`, `min_data_in_leaf`

và `max_depth` [23, 30].

CatBoost xử lý trực tiếp biến phân loại bằng thống kê mục tiêu có thứ tự và dùng cơ chế *ordered boosting* để hạn chế rò rỉ thông tin trong quá trình huấn luyện [43].

1.4 Thách thức khi mô hình hóa dữ liệu tín dụng

1.4.1 Mất cân bằng lớp và tính thứ tự của nhóm nợ

Khi các nhóm nợ có tần suất chênh lệch lớn, mô hình có xu hướng thiên về lớp đa số [7]. Hai hướng xử lý, có thể dùng riêng hoặc kết hợp, là điều chỉnh ở cấp thuật toán và ở cấp dữ liệu.

Cấp thuật toán — trọng số lớp. Hàm mất mát entropy chéo được gán trọng số theo lớp thật của từng quan sát:

$$\mathscr{L} = -\sum_{i=1}^{N} w_{y_i} \sum_{k=1}^{K} \mathbb{I}(y_i = k) \log p_{ik}, \qquad w_c = \frac{N}{K n_c},$$

trong đó N là số quan sát, p_{ik} là xác suất dự báo lớp k, n_c là số quan sát lớp c và $\mathbb{I}(\cdot)$ là hàm chỉ thị. Trọng số nghịch đảo tần suất làm sai số trên lớp hiếm có ảnh hưởng lớn hơn tới hàm mất mát mà không thay đổi số quan sát.

Cấp dữ liệu — SMOTE. SMOTE sinh điểm tổng hợp cho lớp thiểu số bằng nội suy giữa một quan sát $\mathbf{x}_i$ và một láng giềng gần cùng lớp $\mathbf{x}_{nn}$:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda \left(\mathbf{x}_{nn} - \mathbf{x}_i \right), \qquad \lambda \sim U(0,1)$$

[10]. SMOTE làm tăng số quan sát huấn luyện của lớp thiểu số bằng dữ liệu nội suy, không phải quan sát độc lập mới; với biến phân loại đã mã hóa số, phép nội suy có thể tạo giá trị không tương ứng danh mục hợp lệ.

Tính thứ tự. Năm nhóm nợ có thứ tự rủi ro, nên nhầm nhóm 5 thành nhóm 4 ít nghiêm trọng hơn nhiều so với nhầm nhóm 5 thành nhóm 1. Các thước đo phân loại thông

thường như Accuracy hay F1 coi mọi sai lệch như nhau; luận văn vì vậy bổ sung Ordinal MAE, đo số bậc sai lệch trung bình giữa nhóm dự báo và nhóm thực (Mục 2.6).

1.4.2 Khả năng giải thích mô hình

Mô hình dùng trong tín dụng cần giải thích được để cán bộ tín dụng, bộ phận quản trị rủi ro và cơ quan quản lý có thể kiểm tra [8]. Với mô hình cây, hai cách đo mức độ quan trọng phổ biến là Gain, tức tổng mức giảm hàm mất mát tại các lần chia nhánh dùng đặc trưng đó [54], và SHAP, dựa trên giá trị Shapley của lý thuyết trò chơi hợp tác. SHAP phân rã đầu ra của mô hình cho một hồ sơ $\mathbf{x}$ thành tổng đóng góp của các đặc trưng:

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^{p} \phi_j,$$

trong đó ϕ_0 là giá trị nền, tức giá trị kỳ vọng của đầu ra mô hình trên tập tham chiếu, p là số đặc trưng và ϕ_j là đóng góp của đặc trưng j [28]. Đẳng thức này có nghĩa: dự báo cho một hồ sơ cụ thể bằng giá trị nền cộng với tổng các phần điều chỉnh do từng đặc trưng gây ra, và tổng luôn khớp đúng với đầu ra thực tế của mô hình. Dấu của ϕ_j cho biết chiều tác động, độ lớn $|\phi_j|$ cho biết cường độ; trung bình $|\phi_j|$ trên nhiều hồ sơ là thước đo mức độ quan trọng toàn cục, và đây là dạng được luận văn sử dụng ở Chương 3. Với mô hình cây, Lundberg và cộng sự [27] đề xuất thuật toán `TreeExplainer` tính chính xác ϕ_j trong thời gian đa thức thay vì phải xấp xỉ, và đây là thuật toán được dùng trong thư viện SHAP [29] mà luận văn sử dụng.

Gain và SHAP đo hai đại lượng khác nhau: Gain phản ánh cách đặc trưng được dùng khi huấn luyện, SHAP phản ánh đóng góp vào dự báo trên một mẫu cụ thể. Cả hai chỉ mô tả cách mô hình sử dụng dữ liệu, không chứng minh quan hệ nhân quả, và có thể chia sẻ đóng góp giữa các biến tương quan [28]. Vì vậy luận văn đối chiếu hai thước đo trên cùng một mô hình và đối chiếu kết quả giữa hai bộ dữ liệu trước khi rút ra kết luận (Mục 3.3).

1.5 Tổng quan nghiên cứu và khoảng trống nghiên cứu

1.5.1 Nghiên cứu quốc tế

So sánh mô hình. Các tổng quan của Hand và Henley [20], Thomas [48] và Crook và cộng sự [13] hệ thống hóa quá trình chuyển từ chấm điểm thống kê sang các phương pháp học máy, đồng thời mở rộng phạm vi đánh giá từ thời điểm phê duyệt sang theo dõi hành vi trong vòng đời khoản vay. West [53] so sánh mạng nơ-ron với các mô hình thống kê trên dữ liệu tín dụng tiêu dùng. Baesens và cộng sự [2] đối sánh 17 thuật toán trên tám bộ dữ liệu, và Lessmann và cộng sự [26] cập nhật với 41 phương pháp trên tám bộ dữ liệu; kết luận chung là các mô hình tổ hợp như Random Forest thường đứng ở nhóm dẫn đầu, song không thuật toán nào vượt trội trên mọi bộ dữ liệu, và kết quả phụ thuộc chất lượng dữ liệu, cách chia mẫu và thước đo. Xia và cộng sự [55] cho thấy XGBoost có tinh chỉnh siêu tham số cải thiện chấm điểm tín dụng; Barboza và cộng sự [3] ghi nhận ưu thế của mô hình cây tổ hợp trong dự báo phá sản. Gunnarsson và cộng sự [19] cho thấy học sâu không vượt XGBoost trên dữ liệu bảng tín dụng.

Mất cân bằng và thiết kế đánh giá. Brown và Mues [7] chỉ ra hiệu năng của nhiều thuật toán suy giảm mạnh khi tỷ lệ vỡ nợ giảm, và Random Forest cùng gradient boosting chịu ảnh hưởng ít hơn. Dastile và cộng sự [14], trong tổng quan có hệ thống giai đoạn 2010–2018, chỉ ra các hạn chế phổ biến: dữ liệu công khai nhỏ và cũ, xử lý mất cân bằng chưa nhất quán, thiếu chuẩn đánh giá và thiếu khả năng giải thích. Với sự kiện hiếm, Saito và Rehmsmeier [45] khuyến nghị dùng đường Precision–Recall thay vì chỉ ROC.

Dữ liệu theo thời gian và giải thích. Khandani và cộng sự [24] dùng dữ liệu giao dịch theo tháng để dự báo nợ quá hạn thẻ tín dụng trước 3–12 tháng, cho thấy giá trị của dữ liệu hành vi theo thời gian. Lando và Skødeberg [25] mô hình hóa ma trận chuyển hạng tín nhiệm, cơ sở lý thuyết cho bài toán chuyển nhóm. Moreno-Torres và cộng sự [31] hệ thống hóa hiện tượng dịch chuyển phân phối giữa dữ liệu huấn luyện và dữ liệu áp dụng — nguyên nhân khiến kết quả kiểm định cùng kỳ có thể lạc quan. Bussmann

và cộng sự [8] ứng dụng SHAP cho mô hình XGBoost trong quản trị rủi ro tín dụng.

1.5.2 Nghiên cứu tại Việt Nam

Nghiên cứu về rủi ro tín dụng trên dữ liệu Việt Nam có thể chia thành ba hướng, khác nhau ở đơn vị quan sát và biến đích.

Hướng thứ nhất — yếu tố quyết định nợ xấu ở cấp ngân hàng. Các nghiên cứu này dùng dữ liệu bảng của nhiều ngân hàng trong nhiều năm, biến đích là tỷ lệ nợ xấu của cả ngân hàng, và phương pháp là kinh tế lượng. Pham Hai và Le Ha Diem [41] phân tích quan hệ giữa cấu trúc vốn và rủi ro tín dụng của các ngân hàng thương mại Việt Nam. Hướng này trả lời câu hỏi vĩ mô về nguyên nhân nợ xấu, nhưng không tạo ra công cụ đánh giá được từng khoản vay.

Hướng thứ hai — chấm điểm tín dụng ở cấp khách hàng bằng mô hình thống kê. Dinh Thi Huyen Thanh và Kleimeier [15] xây dựng mô hình chấm điểm tín dụng cho thị trường ngân hàng bán lẻ Việt Nam bằng hồi quy logistic, là công trình nền tảng của hướng này. Pham Vo Ninh Binh và cộng sự [42] so sánh các mô hình dự báo kiệt quệ tài chính và phá sản cho doanh nghiệp niêm yết Việt Nam. Điểm chung là biến đích nhị phân (tốt/xấu, phá sản/không phá sản).

Hướng thứ ba — học máy trên dữ liệu tín dụng Việt Nam. Tran Khanh Quoc và cộng sự [49] đối sánh các mô hình tổ hợp (LightGBM, CatBoost, Random Forest) với SVM và hồi quy logistic cho bài toán chấm điểm tín dụng trong ngân hàng Việt Nam, và ghi nhận ưu thế của nhóm mô hình tổ hợp. Tran Kim Long và cộng sự [50] kết hợp học máy với giải thích mô hình để dự báo kiệt quệ tài chính trên dữ liệu Việt Nam — một trong số ít công trình trong nước quan tâm tới khả năng giải thích. Tran Van Trung và Nguyen Vuong Ngoc Anh [51] so sánh sáu thuật toán cho chấm điểm khách hàng cá nhân tại ngân hàng thương mại Việt Nam. Nguyen Nhat và Ngo Duy [33] đối sánh bốn thuật toán boosting (AdaBoost, XGBoost, LightGBM, CatBoost) trên dữ liệu khách hàng cá nhân tại thị trường Việt Nam và ghi nhận LightGBM cho kết quả tốt nhất. Nguyễn Đức Duy và Nguyễn Việt Dũng [36] dùng XGBoost dự báo vỡ nợ doanh

nghiệp nhỏ và vừa, kết hợp dữ liệu kế toán, hóa đơn điện tử và sao kê ngân hàng.

Công bố trên tạp chí chuyên ngành trong nước. Bốn công trình sau, đều đăng bằng tiếng Việt trên tạp chí chuyên ngành, cho thấy khá rõ quá trình chuyển dịch của hướng thứ ba. Nguyễn Tiến Hưng và Lê Thị Huyền Trang [35] xây dựng các mô hình chấm điểm tín dụng lai ghép giữa cây quyết định với hồi quy logistic, K láng giềng gần nhất và mạng thần kinh nhân tạo, trong đó mô hình lai cây quyết định — mạng nơ-ron cho kết quả tốt nhất; đây là một trong những công bố sớm nhất trên tạp chí trong nước đặt vấn đề thay mô hình thống kê truyền thống bằng kỹ thuật học máy. Trương Thị Thùy Dương và Lê Hải Trung [52] so sánh các phương pháp học máy với hồi quy logistic trong dự báo rủi ro phá sản của doanh nghiệp Việt Nam và kết luận XGBoost cùng Random Forest vượt trội hơn các phương pháp còn lại — nhất quán với kết quả đối sánh quốc tế [26, 55]. Nguyễn Minh Nhật và Ngô Hoàng Khánh Duy [34] đối sánh hồi quy logistic, cây quyết định, XGBoost và mạng nơ-ron nhân tạo trên 1.200 quan sát doanh nghiệp nhỏ và vừa giai đoạn 2010–2022 (141 trường hợp vỡ nợ, tỷ lệ 11,75%), trong đó mạng nơ-ron đạt F1 bằng 0,756 và độ chính xác bằng 0,9345. Khoảng cách giữa hai con số này minh họa đúng vấn đề mà luận văn phải xử lý: với dữ liệu mất cân bằng, độ chính xác tổng thể chủ yếu phản ánh nhóm đa số nên không dùng được làm thước đo chính (Mục 2.6). Gần đây nhất, Đàm Thanh Tú và cộng sự [56] huấn luyện LightGBM trên 417.440 hồ sơ thẻ tín dụng của một ngân hàng thương mại Việt Nam và dùng SHAP để xác định các yếu tố chi phối quyết định của mô hình; đây là công bố trong nước gần với hướng giải thích mô hình của luận văn nhất, song vẫn dừng ở một thước đo giải thích trên một bộ dữ liệu.

Ba hướng trên cho thấy học máy đã được áp dụng khá rộng trên dữ liệu tín dụng Việt Nam, và các mô hình tổ hợp thường cho kết quả tốt nhất — nhất quán với kết luận quốc tế. Tuy nhiên có bốn điểm mà các nghiên cứu này chưa đề cập — kể cả bốn công bố trong nước vừa nêu — và đó chính là chỗ luận văn định vị: (i) biến đích gần như luôn là nhị phân (tốt/xấu, vỡ nợ/không vỡ nợ, duyệt/không duyệt), chưa nghiên cứu nào phân loại trực tiếp *năm nhóm nợ* theo Thông tư 31/2024/TT-NHNN; (ii) do biến

đích nhị phân nên *tính thứ tự* của mức rủi ro không được đưa vào thước đo; (iii) dữ liệu thường là ảnh chụp một thời điểm, nên kết quả không được kiểm tra trên *kỳ báo cáo sau*; và (iv) chưa có nghiên cứu nào xây dựng bài toán *dự báo chuyển nhóm nợ* từ nhiều kỳ báo cáo liên tiếp của cùng danh mục. Nguyên nhân chủ yếu là dữ liệu cấp khế ước theo nhiều kỳ của ngân hàng trong nước hiếm khi được cung cấp cho nghiên cứu học thuật.

1.5.3 Khoảng trống nghiên cứu và định vị đề tài

Từ tổng quan trên, có ba khoảng trống liên quan trực tiếp đến luận văn:

1. *Về đối tượng bài toán và nguồn dữ liệu.* Phần lớn nghiên cứu đặt mục tiêu nhị phân (tốt/xấu) hoặc dự báo phá sản, trên bộ dữ liệu công khai nhỏ và cũ [14]; các nghiên cứu trên dữ liệu Việt Nam cũng theo đúng khuôn mẫu này [15, 49, 51, 33]. Bài toán phân loại năm nhóm nợ có thứ tự theo quy định Việt Nam ít được khảo sát trên dữ liệu thực tế của ngân hàng trong nước.

2. *Về khả năng cảnh báo sớm.* Thông tin nhóm nợ mang tính hồi cứu (Mục 1.1.2); khả năng dự báo một khoản vay chuyển sang nhóm nợ cao hơn trong ngắn hạn bằng học máy, và độ ổn định của khả năng đó qua các kỳ, chưa được kiểm chứng trên dữ liệu ngân hàng Việt Nam. Nguyên nhân là các nghiên cứu trong nước hầu hết dùng dữ liệu ảnh chụp một thời điểm, trong khi bài toán này đòi hỏi nhiều kỳ báo cáo liên tiếp của cùng danh mục khoản vay.

3. *Về thiết kế đánh giá và giải thích.* Tính thứ tự của nhóm nợ ít được đưa vào thước đo; phép chia ngẫu nhiên phổ biến hơn kiểm tra theo thời gian; và kết quả giải thích thường được báo cáo bằng một thước đo trên một bộ dữ liệu, không kiểm tra độ ổn định. Trong các nghiên cứu trên dữ liệu Việt Nam, Tran Kim Long và cộng sự [50] cùng Đàm Thanh Tú và cộng sự [56] là hai công trình đưa giải thích mô hình vào phân tích, nhưng cả hai đều báo cáo một thước đo giải thích (SHAP)

trên một bộ dữ liệu, nên chưa kiểm tra được độ ổn định của kết luận giải thích khi đổi thước đo hoặc đổi bộ dữ liệu.

Luận văn định vị đóng góp như sau:

1. đối sánh sáu mô hình và bốn chiến lược xử lý mất cân bằng cho bài toán năm nhóm nợ trên hai bộ dữ liệu thực tế của cùng một ngân hàng, báo cáo cả Macro-F1, hiệu năng từng nhóm và Ordinal MAE, kèm đánh giá trên kỳ báo cáo sau (khoảng trống 1 và 3);
2. đối chiếu mức độ quan trọng bằng Gain và SHAP trên cùng mô hình, và bằng SHAP giữa hai bộ dữ liệu, để phân biệt kết luận nào ổn định và kết luận nào phụ thuộc thước đo (khoảng trống 3);
3. xây dựng bài toán dự báo chuyển nhóm nợ trên hai cặp kỳ báo cáo thật, kiểm tra độ ổn định giữa hai cặp và báo cáo trung thực cả kết quả không lặp lại (khoảng trống 2).

Tóm tắt chương

Chương 1 đã trình bày bối cảnh, cơ sở lý luận về tín dụng và năm nhóm nợ, các mô hình học máy được sử dụng và hai thách thức chính khi mô hình hóa dữ liệu tín dụng là mất cân bằng lớp và yêu cầu giải thích. Tổng quan nghiên cứu cho thấy ba khoảng trống về đối tượng bài toán, khả năng cảnh báo sớm và thiết kế đánh giá. Chương 2 cụ thể hóa hai bài toán nghiên cứu, dữ liệu và phương pháp thực nghiệm.

Chương 2

DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Chương này phát biểu hai bài toán nghiên cứu, mô tả dữ liệu, quy trình tiền xử lý và xây dựng đặc trưng, cách chia mẫu, xử lý mất cân bằng và huấn luyện mô hình, thiết kế thực nghiệm cho bài toán chuyển nhóm nợ và hệ thống thước đo đánh giá. Các bảng thống kê mô tả chi tiết được trình bày ở Phụ lục.

2.1 Bài toán nghiên cứu và quy trình tổng thể

2.1.1 Phát biểu bài toán phân loại năm nhóm nợ

Cho tập dữ liệu $\mathscr{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$, trong đó $\mathbf{x}_i \in \mathbb{R}^p$ là véc-tơ p đặc trưng của khoản vay i và $y_i \in \{1, \ldots, 5\}$ là nhóm nợ tại thời điểm báo cáo. Mục tiêu là xây dựng bộ phân loại $f_\theta : \mathbf{x}_i \mapsto (p_{i1}, \ldots, p_{i5})$ với $p_{ik} = P(Y_i = k \mid \mathbf{x}_i)$, $\sum_k p_{ik} = 1$, và nhãn dự báo $\hat{y}_i = \arg\max_k p_{ik}$. Do năm nhóm có thứ tự $1 < 2 < \cdots < 5$ và phân bố rất lệch, mô hình cần vừa đạt hiệu quả tổng thể, vừa nhận diện được các nhóm rủi ro hiếm, vừa hạn chế sai lệch nhiều bậc.

Bài toán này phân loại *trạng thái hiện tại*, nên được dùng để đối sánh phương pháp

mô hình hóa, đánh giá vai trò nhóm đặc trưng và kiểm tra khả năng áp dụng sang kỳ báo cáo sau; nó không trực tiếp là bài toán cảnh báo sớm (Mục 1.1.2).

2.1.2 Phát biểu bài toán dự báo chuyển nhóm nợ

Gọi $G_{i,T} \in \{1,\ldots,5\}$ là nhóm nợ của khoản vay i tại kỳ báo cáo T và $G_{i,T+h}$ là nhóm nợ của cùng khoản vay ở kỳ báo cáo sau, cách h ngày. Nhãn được định nghĩa:

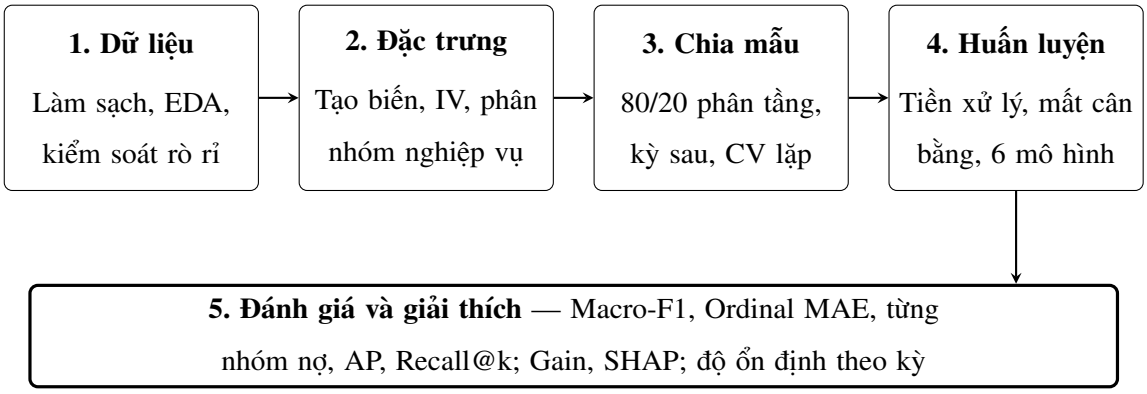
$$Y_i = \mathbb{I}(G_{i,T+h} > G_{i,T}),$$

nhận giá trị 1 khi khoản vay chuyển sang nhóm rủi ro cao hơn và 0 khi giữ nguyên hoặc cải thiện. Đầu vào $\mathbf{x}_{i,T}$ chỉ được xây dựng từ bản ghi kỳ T; nhóm nợ kỳ sau chỉ dùng để tạo nhãn. Đây là bài toán cảnh báo sớm theo nghĩa của Mục 1.1.2: xếp hạng các khoản vay theo nguy cơ xấu đi trước khi sự kiện được ghi nhận.

Bài toán chỉ thực hiện được trên bộ B, bộ duy nhất có nhiều kỳ báo cáo của cùng danh mục. Ba kỳ 30/04, 31/05 và 30/06/2026 tạo thành hai cặp kỳ: *cặp 1* (20260430→20260531, $h = 31$ ngày) và *cặp 2* (20260531→20260630, $h = 30$ ngày). Có hai cặp thay vì một cho phép kiểm tra kết quả có lặp lại qua thời gian hay không — đây là điểm nhấn thiết kế của luận văn.

2.1.3 Quy trình nghiên cứu và môi trường triển khai

Hình 2.1 tóm tắt quy trình chung cho cả hai bài toán. Nguyên tắc xuyên suốt là mọi phép biến đổi có tham số học từ dữ liệu (điền khuyết, chuẩn hóa, mã hóa, SMOTE) chỉ được ước lượng trên phần huấn luyện rồi áp dụng sang phần đánh giá.



Hình 2.1: Quy trình nghiên cứu tổng thể

Toàn bộ quy trình được cài đặt bằng Python 3.11 với pandas/NumPy cho xử lý dữ liệu, scikit-learn và imbalanced-learn cho tiền xử lý, chia mẫu và SMOTE, ba thư viện XGBoost, LightGBM, CatBoost cho các mô hình boosting, và thư viện SHAP [29] cho giải thích mô hình; ứng dụng minh họa dùng Streamlit. Danh mục công nghệ chi tiết ở Bảng P1.1 (Phụ lục). Mọi phép chia mẫu và mô hình dùng hạt giống ngẫu nhiên cố định `random_state=42` để tái lập được.

2.2 Dữ liệu nghiên cứu

2.2.1 Bộ dữ liệu A

Bộ A (`Data_credit_rating_VN.xlsx`) gồm 27.001 khoản vay và 21 cột; biến đích `NHOMNOMOI` nhận giá trị 1–5 và không thiếu ở bản ghi nào. Đây là ảnh chụp danh mục tại một thời điểm. Phân bố nhóm nợ lệch mạnh (Bảng 2.1): nhóm 1 chiếm 77,65%, nhóm 3 chỉ 2,24%.

Bảng 2.1: Phân bố năm nhóm nợ trong bộ dữ liệu A

Nhóm	Toàn bộ	Tỷ lệ (%)	Huấn luyện	Kiểm định
1	20.965	77,65	16.771	4.194
2	1.287	4,77	1.030	257
3	604	2,24	483	121
4	784	2,90	627	157
5	3.361	12,45	2.689	672
Tổng	27.001	100,00	21.600	5.401

Do không có ngày trích xuất chính xác, các biến thời gian của bộ A được tính theo một ngày tham chiếu cố định $d_0 = 31/12/2021$, là mốc cuối năm sau ngày mở khoản vay muộn nhất (Mục 2.3.2). Việc chọn d_0 không ảnh hưởng đến kết quả mô hình: biến số ngày đến đáo hạn bằng ngày đáo hạn trừ d_0, nên đổi d_0 chỉ tịnh tiến biến này một hằng số — phép tịnh tiến bị triệt tiêu khi chuẩn hóa z-score và không đổi thứ tự các giá trị mà mô hình cây dùng để chia nhánh. Kiểm tra lại với ba mốc d_0 là 31/12/2020, 31/12/2021 và 31/12/2023 cho Macro-F1 của XGBoost trùng khớp hoàn toàn (0,6442); Logistic Regression chênh không quá 0,002 do sai số của thuật toán tối ưu. Tuy vậy, *dấu* của biến chỉ có ý nghĩa "đã đáo hạn/chưa đáo hạn" khi d_0 trùng thời điểm trích xuất, nên luận văn không diễn giải dấu của biến này theo nghĩa tuyệt đối.

2.2.2 Bộ dữ liệu B và ba kỳ báo cáo

Bộ B gồm ba tệp Thông tin tín dụng của cùng một danh mục khoản vay, có cùng 33 cột: kỳ 20260430 (100.617 khế ước), kỳ 20260531 (100.274) và kỳ 20260630 (98.620). Trường `ETL_DATE` xác nhận ngày chốt dữ liệu của từng kỳ; trường `Số khế ước` là khóa duy nhất trong từng tệp. Biến đích `Nhóm nợ tự phân loại` nhận giá trị 1–5 và không thiếu ở bản ghi nào. Mất cân bằng mạnh hơn bộ A: nhóm 1 chiếm 88,33%, gấp khoảng 89 lần nhóm 3 (Bảng 2.2); tuy vậy quy mô tuyệt đối của các nhóm hiếm (998 hồ sơ nhóm 3, 1.446 hồ sơ nhóm 4) đủ để đánh giá theo từng nhóm.

Bảng 2.2: Phân bố năm nhóm nợ trong bộ dữ liệu B (kỳ 20260430)

Nhóm	Toàn bộ	Tỷ lệ (%)	Huấn luyện (80%)	Kiểm định (20%)
1	88.875	88,33	71.099	17.776
2	6.321	6,28	5.057	1.264
3	998	0,99	798	200
4	1.446	1,44	1.157	289
5	2.977	2,96	2.382	595
Tổng	100.617	100,00	80.493	20.124

Quan hệ giữa hai bộ dữ liệu

Vì Câu hỏi nghiên cứu 3 đối chiếu kết quả giải thích giữa hai bộ, mức độ độc lập giữa chúng cần được nêu rõ. Hai bộ do cùng một ngân hàng cung cấp nhưng khác nhau ở bốn điểm có thể kiểm chứng trực tiếp từ dữ liệu: (i) *thời gian*, bộ A trích xuất khoảng năm 2020 còn bộ B là các kỳ tháng 4–6/2026, cách nhau khoảng sáu năm; (ii) *cấu trúc*, bộ A có 21 cột đặt tên viết tắt tiếng Anh theo hệ thống lõi của ngân hàng, bộ B có 33 cột đặt tên tiếng Việt theo mẫu báo cáo của Ngân hàng Nhà nước; (iii) *đơn vị quan sát*, bộ A ở cấp hợp đồng vay còn bộ B ở cấp khế ước; và (iv) *khóa định danh*, hai bộ không dùng chung hệ khóa nên không thể ghép để kiểm tra chồng lấn khách hàng.

Hệ quả cho việc diễn giải: hai bộ độc lập về thời gian, cấu trúc biến và hệ thống nguồn, nhưng *không* độc lập về tổ chức phát sinh dữ liệu, và mức chồng lấn khách hàng không xác định được. Vì vậy khi hai bộ cho cùng một kết luận về nhóm thông tin quan trọng (Mục 3.3.3), bằng chứng đó mạnh hơn so với việc chỉ dùng một bộ, nhưng không tương đương với việc lặp lại nghiên cứu trên một ngân hàng khác — các đặc thù về chính sách cấp tín dụng, cơ cấu danh mục và quy ước ghi nhận dữ liệu của cùng một tổ chức vẫn có thể ảnh hưởng tới cả hai bộ theo cùng một hướng.

Vai trò của ba kỳ được phân định như sau. Với bài toán năm nhóm nợ, kỳ 20260430 dùng để huấn luyện và kiểm định nội bộ; toàn bộ kỳ 20260531 là *tập ngoài thời gian*, không tham gia huấn luyện hay chọn mô hình. Với bài toán chuyển nhóm, kỳ 20260430

và 20260531 tạo cặp 1, kỳ 20260531 và 20260630 tạo cặp 2. Có 98.968 khế ước xuất hiện ở cả hai kỳ đầu, nên tập ngoài thời gian tách khỏi bước huấn luyện nhưng không độc lập về khoản vay: kết quả trên tập này phản ánh khả năng áp dụng mô hình sang kỳ tiếp theo của danh mục đang theo dõi, không phải khả năng tổng quát hóa sang khách hàng mới.

2.2.3 Kết quả làm sạch và đặc điểm phân phối dữ liệu

Hai bộ dữ liệu được khảo sát bằng thống kê mô tả, tỷ lệ thiếu, ngoại lệ theo khoảng tứ phân vị (IQR) và tương quan Pearson; kết quả chi tiết ở Phụ lục P2. Bảng 2.3 tổng hợp những nhận định dẫn tới quyết định tiền xử lý.

Bảng 2.3: Tổng hợp kết quả làm sạch và khảo sát dữ liệu

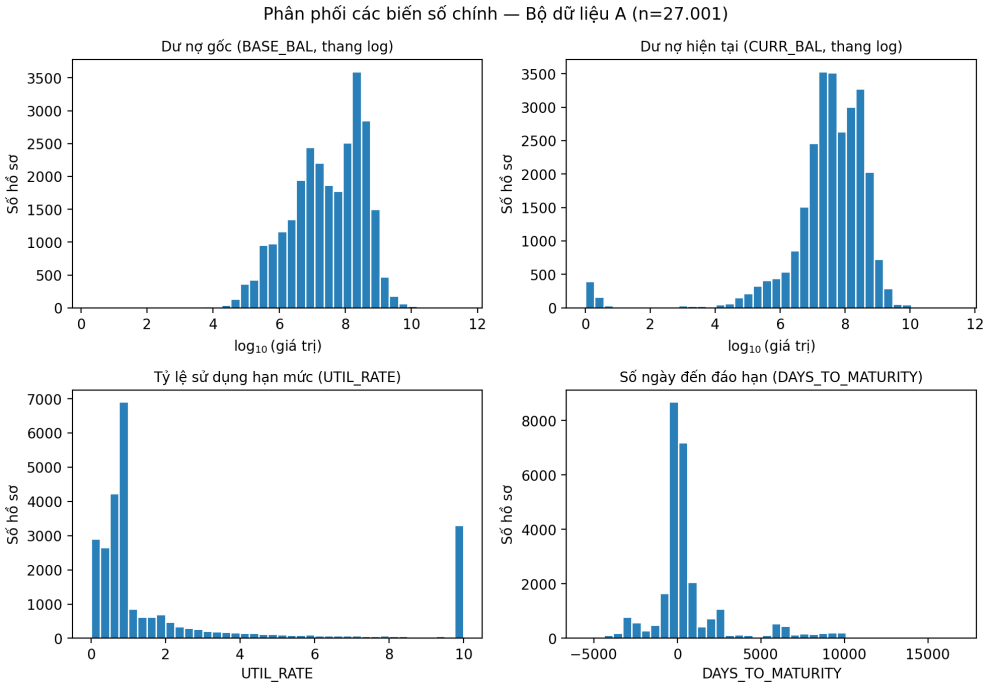
Khía cạnh	**Bộ A**	**Bộ B**
Định dạng ngày	36,84% `OPEN_DATE` và 36,63% `NGAYDENHAN` lưu dạng số thứ tự ngày Excel; đã quy đổi, không còn giá trị thiếu	Kỳ 20260430 lưu dạng `yyyymmdd`, hai kỳ 20260531 và 20260630 lưu ngày giải ngân và ngày kết thúc khế ước dạng số thứ tự Excel; đã quy đổi (Mục 2.2.3)
Giá trị thiếu	Không có	Ba biến cơ cấu nợ thiếu 99,60–99,82% (khoản vay chưa từng cơ cấu); `Phương thức cho vay` thiếu 0,05%
Phân phối biến tiền tệ	Lệch phải mạnh: độ lệch chuẩn `BASE_BAL`, `CURR_BAL` gấp 15 lần trung bình; ngoại lệ IQR 7–9%	Lệch phải mạnh: độ lệch chuẩn dư nợ gấp 24 lần trung bình; ngoại lệ IQR tới 15,4%
Tương quan cao	Hai biến kỳ hạn ($r = 0,942$); hai biến dư nợ ($r = 0,923$)	Hai biến kỳ hạn ($r = 0,975$); dư nợ với nợ gốc cơ cấu ($r = 0,908$)
Hệ quả xử lý	Điền trung vị, chuẩn hóa z-score, giới hạn tỷ lệ sử dụng dư nợ	Điền 0 cho biến cơ cấu nợ, trung vị cho biến số khác; thận trọng khi diễn giải mức độ quan trọng của cặp biến tương quan

Lệch định dạng trường ngày giữa các kỳ của bộ B

Ba kỳ báo cáo của bộ B có cùng danh mục 33 cột, nhưng *không* cùng định dạng lưu trữ trường ngày. Kỳ 20260430 lưu ngày dưới dạng số nguyên `yyyymmdd` (ví dụ `20220817`), trong khi kỳ 20260531 và 20260630 lưu `Ngày giải ngân` và `Ngày kết thúc khế ước` dưới dạng số thứ tự ngày kiểu Excel (ví dụ `45965`, tương ứng 04/11/2025). Đây là cùng một lớp lỗi định dạng đã gặp ở bộ A, nhưng biểu hiện ngược lại về mức độ nguy hiểm: bộ phân tích cú pháp chỉ nhận dạng `yyyymmdd` sẽ trả về giá trị rỗng cho *toàn bộ* hai cột này ở hai kỳ sau mà không phát sinh bất kỳ thông báo lỗi nào, kéo theo ba đặc trưng kỹ thuật tính từ chúng (tuổi khoản vay, số ngày đến đáo hạn, kỳ hạn thực tế) rỗng 100%.

Sau khi quy đổi theo mốc gốc 30/12/1899, cả ba kỳ đều không còn giá trị ngày bị thiếu. Một phép kiểm tra nhất quán xác nhận quy đổi đúng: tuổi khoản vay trung vị của danh mục tăng đều 395, 426 và 456 ngày qua ba kỳ, tức tăng khoảng 30 ngày mỗi kỳ, đúng với việc cùng một danh mục già đi một tháng. Ba trường ngày khác cũng lệch định dạng theo cách tương tự (`Thời điểm truy đòi`, `Ngày chậm trả nợ gốc`, `Ngày chậm trả nợ lãi`) nhưng đều đã bị loại khỏi tập đặc trưng vì trùng lặp hoặc rò rỉ (Mục 2.3.1), nên không ảnh hưởng đến mô hình. Mục 4.3.1 (Chương 4) nêu bài học rút ra từ lỗi này.

Hình 2.2 minh họa đặc điểm chung của biến tiền tệ và biến kỳ hạn: `BASE_BAL`, `CURR_BAL` chỉ có dạng gần chuông trên thang logarit; tỷ lệ sử dụng dư nợ có một cột dồn tại giá trị 10 do phép giới hạn; số ngày đến đáo hạn có hai đỉnh, ứng với khoản vay gần đáo hạn và khoản vay dài hạn.



Hình 2.2: Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001)

2.3 Tiền xử lý và xây dựng tập đặc trưng

2.3.1 Kiểm soát rò rỉ dữ liệu

Rò rỉ dữ liệu phát sinh khi biến đầu vào chứa thông tin chỉ có sau thời điểm dự báo hoặc là hệ quả trực tiếp của biến đích [22]. Luận văn xử lý theo ba lớp.

Lớp 1 — loại các trường tái tạo nhãn. Ở bộ A, loại `NHOMNO` (tương quan 0,98 với biến đích) và `NHOMNO_TCBS` (dạng văn bản của nhãn). Ở bộ B, loại bảy trường: nhóm nợ sau tham chiếu CIC (một phiên bản khác của nhãn); dư nợ gốc, tiền lãi và số ngày chậm trả (căn cứ trực tiếp phân loại theo Bảng 1.1); dự phòng cụ thể phải trích và đã trích. Hai trường cuối là hàm xác định theo nhóm nợ: Nghị định số 86/2024/NĐ-CP, văn bản quy định mức trích lập dự phòng kể từ ngày 11/07/2024 (tách khỏi Thông tư số 31/2024/TT-NHNN vốn chỉ quy định việc phân loại), ấn định tỷ lệ trích lập dự phòng cụ thể lần lượt bằng 0%, 5%, 20%, 50% và 100% cho nhóm 1 đến nhóm 5 [12]. Giữ hai trường này trong tập đặc trưng gần như tương đương với việc cung cấp trực

tiếp biến đích cho mô hình.

Lớp 2 — loại trường định danh, trùng lặp và hằng số. Ví dụ DUNO_QD trùng hoàn toàn CURR_BAL; Thời điểm truy đòi trùng hoàn toàn Ngày kết thúc khế ước; Số tiền đã thanh toán bằng 0 ở mọi bản ghi.

Lớp 3 — rà soát các biến còn lại có dấu hiệu là hệ quả của phân loại. Hai biến được rà soát sau khi xuất hiện ở vị trí dẫn đầu về mức độ quan trọng (Bảng 2.4).

- Lãi chưa thu hạch toán ngoại bảng (bộ B) dương ở 0,01% khoản vay nhóm 1 nhưng ở 21,5%, 78,1%, 93,0% và 97,2% khoản vay nhóm 2 đến 5; 99,86% giá trị dương thuộc nhóm 2–5. Phân bố này không phải một tương quan thực nghiệm tình cờ mà là hệ quả bắt buộc của quy định kế toán. Điều 5 khoản 2 điểm a Thông tư số 16/2018/TT-BTC quy định tổ chức tín dụng chỉ hạch toán lãi phải thu phát sinh trong kỳ vào thu nhập "đối với các khoản nợ được phân loại là nợ đủ tiêu chuẩn không phải trích dự phòng rủi ro cụ thể", còn lãi phải thu phát sinh trong kỳ "của các khoản nợ còn lại thì không phải hạch toán thu nhập, tổ chức tín dụng, chi nhánh ngân hàng nước ngoài thực hiện theo dõi ngoại bảng để đôn đốc thu" [9]. Chính kết quả phân loại nợ là điều kiện quyết định một khoản lãi nằm nội bảng hay ngoại bảng. Lãi phải thu hạch toán nội bảng có quan hệ ngược chiều đúng như quy định dự đoán (dương ở 58,4% khoản vay nhóm 1 và 1,2% nhóm 5). Hai biến vì vậy là *hệ quả kế toán* của việc phân loại nợ, không phải tín hiệu dự báo độc lập.

- DAYS_TO_MATURITY (bộ A): tỷ lệ khoản vay có ngày đáo hạn trước ngày mở khoản vay muộn nhất (08/11/2020) tăng từ 4,0% ở nhóm 1 lên 28,7%, 50,0%, 55,2% và 88,0% ở nhóm 2 đến 5. Khoản vay đã qua ngày đáo hạn mà còn dư nợ gần như chắc chắn là khoản quá hạn gốc, nên biến này mang một phần thông tin của số ngày quá hạn.

Bảng 2.4: Rà soát rò rỉ: Macro-F1 khi loại các biến nghi vấn (tập kiểm định; bộ B thêm kỳ sau)

Bộ	Cấu hình	Macro-F1	Ordinal MAE	Macro-F1 kỳ sau
A	XGBoost, đầy đủ 11 biến	0,6442	0,158	—
A	Bỏ `DAYS_TO_MATURITY`	0,5153	0,198	—
A	Bỏ thêm `LOAN_TENURE_DAYS`	0,4757	0,229	—
B	LightGBM, đầy đủ 20 biến	0,6989	0,069	0,7023
B	Bỏ lãi chưa thu ngoại bảng	0,4742	0,132	0,5149
B	Bỏ cả hai biến lãi	0,4396	0,154	0,4737

Căn cứ pháp lý nêu trên cho phép kết luận hai điều mà nếu chỉ dựa vào số liệu thì không kết luận được. Thứ nhất, *chiều quan hệ* đã xác định: nhóm nợ quyết định cách hạch toán lãi, không phải lãi ngoại bảng dẫn tới nhóm nợ. Thứ hai, *thời điểm* đã xác định: việc chuyển lãi ra ngoại bảng gắn với kỳ phân loại — khoản 7 cùng điều còn quy định phần lãi đã hạch toán thu nhập nhưng sau đó đánh giá không thu được thì hạch toán giảm doanh thu nếu cùng kỳ kế toán, hoặc vào chi phí nếu khác kỳ, và theo dõi ngoại bảng để đôn đốc thu [9]. Tại một ảnh chụp danh mục cuối kỳ, biến lãi ngoại bảng và nhãn nhóm nợ vì vậy là hai đại lượng *đồng thời*, không phải một đại lượng có trước và một đại lượng có sau. Với `DAYS_TO_MATURITY` không có ràng buộc pháp lý tương tự; kết luận ở đây yếu hơn, chỉ dừng ở bằng chứng thực nghiệm rằng biến mang một phần thông tin của số ngày quá hạn.

Luận văn vẫn giữ các biến này trong cấu hình chính, vì chúng sẵn có trong kho dữ liệu tại thời điểm báo cáo và vì cần một mốc so sánh với cách làm phổ biến là dùng toàn bộ trường sẵn có; nhưng Bảng 2.4 cho thấy phần hiệu năng phụ thuộc vào chúng là rất lớn. Vì vậy kết quả phân loại năm nhóm ở Chương 3 được hiểu là khả năng *tái hiện* trạng thái nhóm nợ khi đã có thông tin kế toán và thời hạn của cùng kỳ, không phải năng lực dự báo độc lập; khi cần một mốc tham chiếu cho mục tiêu cảnh báo sớm thì cấu hình thận trọng mới là con số phù hợp. Câu hỏi dự báo được kiểm chứng riêng bằng bài toán chuyển nhóm, nơi các biến này mô tả trạng thái tại T còn nhãn mô tả diễn biến đến $T+h$.

Điểm còn lại phụ thuộc vào xác nhận của đơn vị nghiệp vụ chỉ là một chi tiết vận hành: trong quy trình chốt số cuối kỳ của ngân hàng, trường lãi ngoại bảng được làm mới trước hay sau khi chương trình phân loại nợ chạy, và khoảng trễ giữa hai bước là bao lâu. Chi tiết này không làm thay đổi hai kết luận trên, vì quy định đã ràng buộc hai đại lượng vào cùng một kỳ kế toán; nó chỉ quyết định liệu trường này có dùng được như đầu vào *tại thời điểm T* cho mô hình chuyển nhóm hay không. Nội dung cần xác nhận được nêu thành câu hỏi cụ thể ở Bảng 4.1 (Chương 4).

2.3.2 Xây dựng đặc trưng nghiệp vụ

Bảy biến được xây dựng thêm từ các trường gốc để chuyển thông tin kỹ thuật thành đại lượng có ý nghĩa nghiệp vụ (Bảng 2.5). Các biến chỉ dùng trường đầu vào, không dùng biến đích.

Bảng 2.5: Các biến được xây dựng thêm từ dữ liệu ban đầu

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
A	LOAN_TENURE_DAYS	OPEN_DATE, NGAYDENHAN	Tổng thời hạn hợp đồng (ngày).
A	DAYS_TO_MATURITY	NGAYDENHAN, d_0	Số ngày từ ngày tham chiếu đến ngày đáo hạn.
A	UTIL_RATE	CURR_BAL, BASE_BAL	Tỷ lệ dư nợ hiện tại trên dư nợ gốc; nhỏ hơn 1 là đã trả bớt, lớn hơn 1 có thể do giải ngân bổ sung.
B	ENG_LOAN_AGE_DAYS	ETL_DATE, Ngày giải ngân	Tuổi khoản vay tại ngày chốt dữ liệu.
B	ENG_DAYS_TO_MATURITY	Ngày kết thúc khế ước, ETL_DATE	Số ngày còn lại đến ngày kết thúc khế ước; âm nếu đã qua.
B	ENG_TENOR_ACTUAL_DAYS	Ngày kết thúc khế ước, Ngày giải ngân	Kỳ hạn thực tế của khế ước.

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
B	ENG_HAS_RESTRUCTURE	Số lần cơ cấu lại thời hạn trả nợ	Bằng 1 nếu đã từng cơ cấu lại, bằng 0 nếu chưa (kể cả khi trường gốc trống).

Với bộ A, gọi d_i^{open}, d_i^{mat} là ngày mở và ngày đáo hạn:

$$LOAN_TENURE_DAYS_i = \max\{0, d_i^{\text{mat}} - d_i^{\text{open}}\},$$
$$DAYS_TO_MATURITY_i = d_i^{\text{mat}} - d_0,$$

$$UTIL_RATE_i = \begin{cases} \min\{\max(CURR_BAL_i / BASE_BAL_i, 0), 10\}, & BASE_BAL_i > 0, \\ 0, & \text{ngược lại.} \end{cases}$$

Ngưỡng trên 10 (dư nợ hiện tại gấp 10 lần dư nợ gốc) giữ nguyên số quan sát nhưng hạn chế ảnh hưởng của khoảng 17% hồ sơ có tỷ số ngoại lệ lên bước chuẩn hóa. Với bộ B, ba biến thời gian dùng ETL_DATE của chính hồ sơ làm mốc, nên giá trị không đổi khi chạy lại mã nguồn ở thời điểm khác:

$$ENG_LOAN_AGE_DAYS_i = ETL_i - d_i^{\text{disb}},$$
$$ENG_DAYS_TO_MATURITY_i = d_i^{\text{end}} - ETL_i,$$
$$ENG_TENOR_ACTUAL_DAYS_i = d_i^{\text{end}} - d_i^{\text{disb}},$$

trong đó d_i^{disb} là ngày giải ngân và d_i^{end} là ngày kết thúc khế ước. Thống kê mô tả và tương quan của các biến tạo thêm ở Bảng P2.2 và Bảng P2.4 (Phụ lục). Đáng lưu ý là hai biến kỳ hạn có tương quan rất cao ở cả hai bộ ($r = 0,942$ và $0,975$) vì cùng dùng mốc ngày đáo hạn; luận văn giữ cả hai vì chúng biểu thị hai khía cạnh nghiệp vụ khác nhau (kỳ hạn còn lại và tổng kỳ hạn), nhưng mức độ quan trọng của chúng có thể chia sẻ cho nhau.

2.3.3 WOE/IV: phạm vi sử dụng và sàng lọc rò rỉ

Information Value (IV) lượng hóa khả năng một biến tách nhóm "tốt" khỏi nhóm "xấu". Với biến x được chia thành các khoảng b (10 khoảng phân vị với biến số, từng danh mục với biến phân loại):

$$\mathrm{WOE}_b = \ln \frac{g_b/G}{d_b/D}, \qquad \mathrm{IV} = \sum_b \left(\frac{g_b}{G} - \frac{d_b}{D} \right) \mathrm{WOE}_b,$$

trong đó g_b, d_b là số hồ sơ tốt và xấu trong khoảng b; G, D là tổng số hồ sơ tốt và xấu [47]. Luận văn quy ước "tốt" là nhóm 1 và "xấu" là nhóm 2–5.

IV trong luận văn được tính trên toàn bộ mẫu để mô tả dữ liệu. Vì đây là một đại lượng học từ nhãn, cần kiểm tra xem việc dùng cả phần kiểm định có làm sai lệch kết luận hay không. Tính lại IV *chỉ trên tập huấn luyện* cho cả hai bộ cho thấy chênh lệch tuyệt đối lớn nhất là 0,058 (biến `CURRMIACCTTYPCD` của bộ A, từ 1,9921 xuống 1,9339), và *không biến nào* đổi mức phân loại quanh ngưỡng cảnh báo 1,0. Kết luận rút ra từ IV vì vậy không phụ thuộc phạm vi mẫu dùng để tính. Điều này hợp lý vì IV ở đây chỉ đóng vai trò mô tả và sàng lọc rò rỉ, không được dùng làm tiêu chí chọn biến.

IV được định nghĩa cho biến đích nhị phân, nên việc gộp nhóm 2–5 làm mất thông tin thứ tự mà bài toán năm lớp cần. Một biến có IV thấp chỉ không tách được nhóm 1 khỏi phần còn lại, nhưng vẫn có thể phân biệt các nhóm 3, 4, 5. Vì vậy IV *không* được dùng để loại biến; nó giữ hai vai trò: (i) thước đo mô tả theo thông lệ xếp hạng tín dụng; và (ii) công cụ sàng lọc rò rỉ, qua các biến có IV vượt ngưỡng cảnh báo 1,0 của Siddiqi [47]. Bảng 2.6 tổng hợp phân bố IV của hai bộ theo thứ tự mức IV; giá trị từng biến ở Bảng P3.1 và Bảng P3.2 (Phụ lục).

Bảng 2.6: Phân bố số biến theo mức Information Value

Mức IV	Bộ A (13 biến)	Bộ B (20 biến)
Nghi ngờ ($> 1,0$)	5	1
Rất mạnh (0,5–1,0)	3	1
Mạnh (0,3–0,5)	1	3
Trung bình (0,1–0,3)	2	2
Yếu (0,02–0,1)	0	6
Vô dụng ($< 0,02$)	2	7

Ở bộ A, năm biến vượt ngưỡng 1,0 gồm số ngày đến đáo hạn (IV bằng 4,55), tổng kỳ hạn, tỷ lệ sử dụng dư nợ và hai biến phân loại `CURRMIACCTTYPCD`, `MUCDICHVAY`. Biến thứ nhất đã được rà soát ở Mục 2.3.1; hai biến phân loại nhiều danh mục (31 và 79 danh mục) dễ có IV cao giả tạo, một hạn chế đã biết của công thức IV [47]. Ở bộ B, biến vượt ngưỡng duy nhất là tuổi khoản vay `ENG_LOAN_AGE_DAYS` (1,12), tính từ ngày chốt dữ liệu và ngày giải ngân, nên IV cao nhiều khả năng phản ánh hiệu ứng tuổi khoản vay (*seasoning*): khoản vay mới giải ngân chưa đủ thời gian phát sinh quá hạn. Đáng chú ý, `Lãi chưa thu hạch toán ngoại bảng` có IV xấp xỉ 0 dù phân tách mạnh theo nhóm nợ (Mục 2.3.1): 93,6% giá trị của biến bằng 0, nên phép chia 10 khoảng phân vị nhiều khả năng dồn gần như toàn bộ quan sát vào một khoảng và làm mất tín hiệu. IV đơn biến vì vậy không đủ để phát hiện mọi dấu hiệu rò rỉ.

2.3.4 Tập đặc trưng huấn luyện và nhóm đặc trưng nghiệp vụ

Bảng 2.7 tổng hợp quá trình đi từ số cột thô tới số đặc trưng đưa vào mô hình.

Bảng 2.7: Từ cột dữ liệu thô tới tập đặc trưng huấn luyện

Bước	Bộ A	Bộ B
Số cột thô	21	33
– Biến đích	−1	−1
– Trường tái tạo nhãn (Lớp 1)	−2	−7
– Trường định danh, trùng lặp, hằng số (Lớp 2)	−6	−6
– Trường ngày chỉ dùng để tạo biến	−2	−3
– Biến IV ≈ 0 (`SEX`, `LOAIKH`)	−2	—
+ Biến tạo thêm (Bảng 2.5)	+3	+4
Tập đặc trưng cấu hình chính	**11** (3 phân loại, 8 số)	**20** (8 phân loại, 12 số)
Tập phân tích mở rộng	13 (thêm `SEX`, `LOAIKH`)	20

Ở bộ A, `SEX` và `LOAIKH` được đưa ra khỏi cấu hình chính do IV bằng 0,008 và 0,000, nhưng được giữ trong tập mở rộng 13 biến để kiểm chứng bằng hiệu năng của chính bài toán năm lớp (Mục 3.1.2). Ở bộ B, cả 20 đặc trưng hợp lệ được dùng trong cấu hình chính; khả năng rút gọn được đánh giá bằng thực nghiệm theo số đặc trưng. Ba kỳ của bộ B có danh mục cột trùng khớp hoàn toàn, nên mô hình huấn luyện ở kỳ 20260430 áp dụng trực tiếp cho hai kỳ sau.

Để diễn giải ở cấp nghiệp vụ, các biến được phân vào sáu nhóm ở mỗi bộ. Bộ A: Dư nợ và hạn mức sử dụng; Lãi suất; Kỳ hạn khoản vay; Đơn vị/Chi nhánh; Sản phẩm và mục đích vay; Nhân khẩu học có IV thấp. Bộ B: Dư nợ & Thanh toán (gồm dư nợ và hai biến lãi); Lãi suất; Kỳ hạn & Cơ cấu lại; Hình thức & Mục đích vay; Chi nhánh; Đặc trưng kỹ thuật (bốn biến tạo thêm). Tổng mức độ quan trọng của một nhóm chỉ phản ánh cách mô hình sử dụng dữ liệu hiện có, không phải quan hệ nhân quả.

2.3.5 Điền khuyết, chuẩn hóa và mã hóa

Điền khuyết có phân biệt ngữ nghĩa giá trị thiếu. Không phải mọi giá trị thiếu đều cùng bản chất, và ba biến cơ cấu nợ của bộ B là ví dụ rõ nhất. Chúng thiếu 99,60–99,82% không phải vì dữ liệu bị mất, mà vì phần lớn khế ước *chưa từng* được cơ cấu lại thời

hạn trả nợ; giá trị thiếu ở đây mang nghĩa nghiệp vụ "không phát sinh sự kiện", nên giá trị đúng là **0**.

Áp dụng máy móc phép điền trung vị cho ba biến này sẽ gán cho mọi hồ sơ chưa từng cơ cấu các giá trị trung vị *của riêng phần đã từng cơ cấu* — tức 1 lần cơ cấu, 341,5 và 216 đơn vị tiền. Hệ quả là dữ liệu tự mâu thuẫn: biến `ENG_HAS_RESTRUCTURE` có trung bình 0,004, tức chỉ khoảng 400 trên 100.617 khế ước từng được cơ cấu, trong khi biến "số lần cơ cấu" sau điền khuyết lại cho thấy toàn bộ 100.617 khế ước đều đã cơ cấu ít nhất một lần. Vì vậy quy trình điền 0 cho ba biến này *trước* khi vào bước tiền xử lý chung. So sánh hai cách xử lý cho thấy Macro-F1 thay đổi trong khoảng $-0,005$ đến $+0,006$ tùy mô hình và không đổi thứ hạng của các mô hình dẫn đầu ở cả hai tầng đánh giá (Bảng P6.4, Phụ lục); mức ảnh hưởng nhỏ là do ba biến có mức độ quan trọng gần 0 và thông tin "đã từng cơ cấu hay chưa" đã được `ENG_HAS_RESTRUCTURE` mã hóa riêng. Với bài toán dự báo chuyển nhóm, ảnh hưởng bằng *không* theo đúng nghĩa đen: cả ba biến có Gain bằng 0 trong mô hình XGBoost được chọn, tức mô hình chưa bao giờ chia nhánh theo chúng, nên mọi kết quả ở Mục 3.5 không đổi (đã xác nhận bằng cách chạy lại: AP cặp 1 giữ nguyên 0,1705). Dù ảnh hưởng nhỏ, luận văn vẫn sửa vì đây là lỗi về tính đúng của dữ liệu, không phải một lựa chọn kỹ thuật có thể đánh đổi.

Các biến số còn lại — nơi giá trị thiếu thực sự có nghĩa "không có dữ liệu" — được điền trung vị học trên tập huấn luyện:

$$\tilde{x}_{ij} = \begin{cases} x_{ij}, & x_{ij} \text{ quan sát được}, \\ \text{median}\{x_{\ell j} : \ell \in \mathscr{T}\}, & x_{ij} \text{ thiếu}, \end{cases}$$

trong đó $\mathscr{T}$ là tập chỉ số huấn luyện; trung vị được chọn thay trung bình vì các biến tiền tệ lệch phải mạnh (Bảng 2.3). Biến phân loại thiếu được điền danh mục phổ biến nhất.

Chuẩn hóa. Với năm mô hình không phải CatBoost, biến số được chuẩn hóa $z_{ij} = (\tilde{x}_{ij} - \mu_j)/\sigma_j$ với μ_j, σ_j học trên tập huấn luyện. Bước này cần cho hồi quy logistic, còn mô hình cây không nhạy với thang đo [21].

Mã hóa. Năm mô hình trên dùng `LabelEncoder` cho từng biến phân loại; danh mục chưa gặp ở tập huấn luyện được ánh xạ về danh mục đầu tiên. Cách này tạo thứ tự số không có ý nghĩa với biến định danh — một hạn chế về nguyên tắc, được kiểm chứng bằng thực nghiệm tại Mục 3.4.3: thay bằng One-Hot không giúp mô hình cây nhưng cải thiện rõ Logistic Regression. CatBoost dùng tiền xử lý riêng: chỉ điền khuyết biến số, giữ biến phân loại dạng chuỗi (giá trị thiếu thành `UNKNOWN`) để thuật toán xử lý trực tiếp [43]. Ví dụ hồ sơ trước và sau xử lý ở Bảng P4.1 và Bảng P4.2 (Phụ lục).

2.4 Chia mẫu, xử lý mất cân bằng và huấn luyện mô hình

2.4.1 Chia mẫu và thiết kế kiểm định

Mỗi bộ được chia ngẫu nhiên có phân tầng theo nhãn thành 80% huấn luyện và 20% kiểm định: bộ A thành 21.600 và 5.401 quan sát, bộ B (kỳ 20260430) thành 80.493 và 20.124 quan sát.

Luận văn dùng thống nhất hai thuật ngữ sau cho hai tầng đánh giá của bộ B, vì chúng trả lời hai câu hỏi khác nhau và rất dễ nhầm lẫn:

- **Tập kiểm định nội bộ** — 20% của kỳ 20260430, tách ngẫu nhiên có phân tầng. Các quan sát này cùng kỳ báo cáo với dữ liệu huấn luyện, chỉ khác ở chỗ không tham gia ước lượng tham số. Tập này trả lời câu hỏi "mô hình khái quát hóa sang hồ sơ chưa thấy trong cùng điều kiện hay không".
- **Tập ngoài thời gian** — toàn bộ 100.274 quan sát của kỳ 20260531, không tham gia huấn luyện lẫn lựa chọn mô hình hay siêu tham số. Tập này trả lời câu hỏi "mô hình huấn luyện ở một kỳ còn dùng được cho kỳ kế tiếp hay không". Do 98% khế ước xuất hiện ở cả hai kỳ, đây là phép kiểm tra theo *thời gian*, không phải theo *khách hàng*.

Bảng so sánh mô hình chính báo cáo song song cả hai tầng.

Để kiểm tra sự phụ thuộc vào một lần chia, luận văn dùng kiểm định chéo phân tầng lặp lại (`RepeatedStratifiedKFold`): dữ liệu được chia thành F phần, lặp R lần với các hoán vị khác nhau, cho $R \times F$ lần ước lượng. Với chỉ tiêu m_{rf} ở lần lặp r, phần f:

$$\bar{m} = \frac{1}{RF} \sum_{r=1}^{R} \sum_{f=1}^{F} m_{rf}, \qquad s_m = \sqrt{\frac{1}{RF} \sum_{r=1}^{R} \sum_{f=1}^{F} (m_{rf} - \bar{m})^2}.$$

Bài toán năm lớp dùng $R = 3$, $F = 5$; bài toán chuyển nhóm dùng $R = 10$, $F = 5$ (Mục 2.5.3). Độ lệch chuẩn s_m phản ánh biến động do chia mẫu, không phải khoảng tin cậy của hiệu năng trên dữ liệu tương lai, vì các phần kiểm định có dữ liệu dùng chung qua các lần lặp. Khi so sánh hai mô hình trên cùng các phần kiểm định, luận văn dùng kiểm định t hiệu chỉnh của Nadeau và Bengio [32], trong đó phương sai của chênh lệch được nhân thêm hệ số $(1/(RF) + n_{\text{test}}/n_{\text{train}})$ để bù cho sự chồng lấn giữa các tập huấn luyện; giá trị p được hiệu chỉnh Holm khi so sánh nhiều cặp.

2.4.2 Xử lý mất cân bằng lớp

Bốn chiến lược được so sánh: không xử lý, trọng số lớp nghịch đảo tần suất, SMOTE và kết hợp SMOTE với trọng số lớp (Mục 1.4.1). SMOTE chỉ áp dụng trên tập huấn luyện, sau tiền xử lý và trước huấn luyện, với mục tiêu nâng lớp thiểu số lên mức vừa phải thay vì cân bằng hoàn toàn:

- bộ A: nhóm 2, 3, 4, 5 từ 1.030, 483, 627, 2.689 lên 3.000, 2.000, 2.000, 5.000;
- bộ B: từ 5.057, 798, 1.157, 2.382 lên 8.000, 4.000, 4.500, 6.000 (5,6–11,2% lớp đa số); tỷ trọng mẫu tổng hợp trong từng lớp là 36,8–80,1%.

SMOTE là chiến lược của cấu hình chính cho bài toán năm lớp. Vì SMOTE nội suy tuyến tính trên mọi cột, kể cả cột phân loại đã mã hóa số, nó có thể sinh ra giá trị không ứng với danh mục hợp lệ nào; biến thể SMOTE-NC xử lý riêng nhóm cột phân loại và được đối chiếu tại Mục 3.4.3. Với XGBoost, trọng số lớp được tính trong từng phần huấn luyện và truyền qua `sample_weight`. CatBoost không dùng SMOTE vì

biến phân loại dạng chuỗi không nội suy được; mọi chiến lược khác "không xử lý" được ánh xạ sang `auto_class_weights=Balanced`.

2.4.3 Cấu hình mô hình và tìm kiếm siêu tham số

Cấu hình mặc định của sáu mô hình: Logistic Regression ($C = 1$, `lbfgs`); Decision Tree (độ sâu tối đa 10, tối thiểu 10 mẫu ở lá); Random Forest (300 cây, độ sâu 15, tối thiểu 5 mẫu ở lá); XGBoost và LightGBM (400 cây, độ sâu 6 và 8, tốc độ học 0,05, tỷ lệ lấy mẫu dòng và cột 0,8); CatBoost (400 vòng, độ sâu 6, tốc độ học 0,05). Đây là giá trị thường dùng, không phải kết quả tối ưu.

Để đánh giá độ nhạy của kết luận với siêu tham số, tìm kiếm theo lưới được thực hiện cho sáu mô hình trên cả hai bộ, giữ nguyên chiến lược mất cân bằng và phép chia mẫu: 65 cấu hình cho bộ A và 60 cấu hình cho bộ B (Bảng P5.1 và Bảng P5.2, Phụ lục). Cấu hình tốt nhất được chọn trên chính tập kiểm định, chưa dùng kiểm định chéo lồng nhau, nên kết quả chỉ mô tả độ nhạy trong phạm vi lưới.

Để phân tích số lượng và nhóm đặc trưng, các đặc trưng được xếp theo mức độ quan trọng Gain $I_{(1)} \geq \cdots \geq I_{(p)}$ của mô hình tham chiếu (XGBoost cho bộ A, LightGBM cho bộ B). Tỷ lệ quan trọng tích lũy của k đặc trưng đầu và tỷ trọng của nhóm nghiệp vụ g là:

$$Q(k) = \frac{\sum_{j=1}^{k} I_{(j)}}{\sum_{j=1}^{p} I_{(j)}} \times 100\%, \qquad S_g = \frac{\sum_{j:\, g(j)=g} I_j}{\sum_j I_j} \times 100\%,$$

trong đó $g(j)$ là nhóm của đặc trưng j. $Q(k)$ là tỷ lệ mức độ quan trọng, không phải tỷ lệ hiệu năng được giữ lại; vì vậy mô hình được huấn luyện lại với từng $k \in \{3,5,7,9,11,13\}$ (bộ A) và $k \in \{3,5,8,11,14,17,20\}$ (bộ B) để đo hiệu năng thực. Các k được so sánh trên cùng tập kiểm định nên đường cong chỉ có ý nghĩa khám phá.

2.5 Thiết kế thực nghiệm cho bài toán dự báo chuyển nhóm nợ

2.5.1 Ghép kỳ báo cáo và xây dựng nhãn

Hai kỳ của mỗi cặp được ghép theo `Số khế ước` (inner join). Cặp 1 có 98.968 khoản vay khớp, bằng 98,4% kỳ 20260430; cặp 2 có 98.620 khoản vay khớp. Mọi cột đặc trưng lấy từ kỳ T; kỳ $T+h$ chỉ đóng góp nhóm nợ để tạo nhãn. Bảng 2.8 trình bày ma trận chuyển nhóm của cặp 1.

Bảng 2.8: Ma trận chuyển nhóm nợ của cặp 1 (20260430 $\rightarrow$ 20260531)

Nhóm tại T	Nhóm tại $T+h$				
	1	2	3	4	5
1	87.057	**214**	0	0	0
2	159	6.123	**10**	0	0
3	5	0	981	**10**	0
4	0	0	0	1.411	**31**
5	2	0	0	0	2.965

Có 265 khoản vay (0,268%) chuyển sang nhóm cao hơn, tất cả đều chỉ tăng một bậc; 166 khoản (0,168%) cải thiện; 99,56% giữ nguyên. Cặp 2 có cấu trúc gần giống: 258 sự kiện (0,262%), gồm 206 khoản 1$\rightarrow$2, 8 khoản 2$\rightarrow$3, 12 khoản 3$\rightarrow$4 và 32 khoản 4$\rightarrow$5 (Bảng P6.5, Phụ lục). Đây là bài toán sự kiện hiếm, khác về bản chất thống kê so với bài toán năm lớp.

2.5.2 Kiểm soát rò rỉ và rủi ro sai lệch chọn mẫu

Tập 20 đặc trưng được xây dựng bằng đúng các hàm của bài toán năm lớp, áp dụng lên khung dữ liệu đã ghép. Cơ chế lọc theo danh sách cho phép loại trừ cột nhóm nợ kỳ sau khỏi đầu vào một cách cấu trúc. Khác với việc dùng số ngày quá hạn hiện tại để phân loại lại nhóm nợ hiện tại — nơi đầu vào và nhãn mô tả cùng một thời điểm — ở

đây đầu vào mô tả trạng thái tại T, còn nhãn mô tả diễn biến đến $T + h$. Các biến lãi đã rà soát ở Mục 2.3.1 vì vậy là thông tin hợp lệ cho bài toán này, với điều kiện chúng thực sự sẵn có tại T và không bị cập nhật hồi tố — điều cần xác minh bằng lịch sử cập nhật dữ liệu.

Nhãn chỉ xác định được cho khoản vay có mặt ở cả hai kỳ. Ở cặp 1, 1.649 khoản vay kỳ T không còn trên tập ngoài thời gian (tất toán, xóa nợ hoặc thay đổi ghi nhận; dữ liệu không phân biệt được) và bị loại. Trong số này 97,27% thuộc nhóm 1, và tỷ lệ bị loại trong nhóm 1 (1,80%) cao hơn các nhóm khác (0,20–0,46%); cặp 2 có phân bố tương tự (Bảng P6.6, Phụ lục). Do thiếu thông tin về nguyên nhân, luận văn chưa loại trừ được sai lệch chọn mẫu, chẳng hạn trường hợp một phần khoản vay bị loại thực chất đã xấu đi rồi được xử lý.

2.5.3 Thiết kế đánh giá cho sự kiện hiếm

Với tỷ lệ sự kiện 0,268%, thiết kế đánh giá được điều chỉnh ở ba điểm. Thứ nhất, một bộ phân loại luôn dự báo "không xấu đi" đã có Accuracy 0,9973, nên thước đo chính là average precision (AP) cùng Recall@k (Mục 2.6.2). Thứ hai, bằng chứng chính là kiểm định chéo phân tầng 5 phần lặp 10 lần: mỗi phần kiểm định chỉ có khoảng 53 sự kiện, nên một lần chia đơn có thể phản ánh may rủi của lần chia hơn là năng lực của mô hình; một phép chia 80/20 minh họa được dùng thêm để vẽ đường Precision–Recall, tính Recall@k và SHAP. Thứ ba, mỗi cặp đã dùng cả hai kỳ để tạo nhãn nên không còn kỳ ngoài thời gian trong cùng cặp; cặp 2 đóng vai trò kiểm tra ngoài thời gian cho kết luận từ cặp 1 theo hai cách: (i) đánh giá lại cùng cấu hình trên cặp 2; (ii) *chuyển giao*, tức huấn luyện một lần trên toàn bộ cặp 1 rồi chấm điểm trực tiếp toàn bộ cặp 2 mà không huấn luyện lại.

Sáu mô hình và bốn chiến lược mất cân bằng được so sánh; với mỗi mô hình, chiến lược có AP trung bình cao nhất được báo cáo. SMOTE cho bài toán này nâng lớp dương từ khoảng 212 lên 1.200 quan sát trong mỗi phần huấn luyện.

2.6 Thước đo đánh giá và nguyên tắc báo cáo kết quả

2.6.1 Thước đo cho bài toán phân loại năm lớp

Với $K = 5$ lớp, phần tử C_{ab} của ma trận nhầm lẫn là số quan sát có lớp thực a được dự báo là b. Với lớp k, Precision, Recall và F1 là:

$$P_k = \frac{C_{kk}}{\sum_a C_{ak}}, \qquad R_k = \frac{C_{kk}}{\sum_b C_{kb}}, \qquad F1_k = \frac{2P_kR_k}{P_k + R_k}.$$

Các chỉ tiêu tổng hợp gồm:

$$F1_{\text{macro}} = \frac{1}{K}\sum_k F1_k, \qquad F1_{\text{weighted}} = \sum_k \frac{n_k}{N} F1_k,$$

$$\text{Accuracy} = \frac{\sum_k C_{kk}}{N}, \qquad \text{Ordinal MAE} = \frac{1}{N}\sum_{i=1}^{N} |y_i - \hat{y}_i|,$$

trong đó n_k là số quan sát thực của lớp k và $N = \sum_k n_k$. ROC-AUC được tính theo cách một-với-phần-còn-lại và lấy trung bình macro trên năm lớp [17].

Mỗi chỉ tiêu trả lời một câu hỏi khác nhau. Accuracy và Weighted-F1 bị chi phối bởi nhóm 1 (77,65% ở bộ A, 88,33% ở bộ B): một bộ phân loại luôn dự báo nhóm 1 đã đạt Accuracy 0,7765 và 0,8834. **Macro-F1** cho năm lớp trọng số bằng nhau nên được chọn làm **tiêu chí chính**. ROC-AUC đo khả năng xếp hạng xác suất, không phụ thuộc ngưỡng arg max. Ordinal MAE đo số bậc sai lệch trung bình, phản ánh tính thứ tự của nhóm nợ mà các chỉ tiêu còn lại bỏ qua; giá trị càng nhỏ càng tốt.

2.6.2 Thước đo sự kiện hiếm và nguyên tắc báo cáo

Với bài toán chuyển nhóm, luận văn dùng **average precision** (ký hiệu **AP** trong toàn bộ luận văn):

$$AP = \sum_n (R_n - R_{n-1}) P_n,$$

trong đó P_n, R_n là Precision và Recall tại ngưỡng thứ n khi xếp các hồ sơ theo điểm dự báo giảm dần [46]. AP xấp xỉ diện tích dưới đường Precision–Recall, phù hợp với sự kiện hiếm hơn ROC-AUC [45]; mức AP của một cách xếp hạng ngẫu nhiên bằng tỷ lệ sự kiện (0,00268 ở cặp 1). Luận văn báo cáo thêm ROC-AUC, Precision và Recall của lớp dương tại ngưỡng 0,5, và **Recall@k**: tỷ lệ sự kiện nằm trong $k\%$ hồ sơ có điểm cao nhất. Recall@k gắn trực tiếp với năng lực rà soát của ngân hàng: nếu chỉ rà soát được 5% danh mục, Recall@5% cho biết phần sự kiện bắt được.

Kết quả được báo cáo theo bốn nguyên tắc: (i) mỗi con số gắn với một cấu hình xác định (bộ dữ liệu, tập đặc trưng, chiến lược mất cân bằng, tập đánh giá); (ii) kết quả hai bộ chỉ đối chiếu về xu hướng do khác biệt về nhãn, quy mô và đặc trưng; (iii) các lựa chọn dựa trên tập kiểm định (số đặc trưng k, siêu tham số, chiến lược) được coi là khám phá, và kỳ 20260531 của bộ B là phép kiểm tra độc lập với các lựa chọn đó; (iv) các bảng dùng kết quả lưu trong `code/results` và được tạo lại bằng mã nguồn đi kèm.

Tóm tắt chương

Chương 2 đã phát biểu hai bài toán: phân loại năm nhóm nợ tại một thời điểm trên hai bộ dữ liệu, và dự báo chuyển nhóm nợ trên hai cặp kỳ báo cáo của bộ B. Quy trình tiền xử lý kiểm soát rò rỉ theo ba lớp, trong đó lớp rà soát cuối cho thấy một phần đáng kể hiệu năng phân loại năm nhóm dựa vào các biến lãi và thời hạn hình thành cùng lúc với nhãn. Tập đặc trưng cấu hình chính gồm 11 biến (bộ A) và 20 biến (bộ B); sáu mô hình được so sánh với bốn chiến lược mất cân bằng. Macro-F1 là tiêu chí chính của bài toán năm lớp, bổ sung Ordinal MAE; AP và Recall@k là tiêu chí chính của bài toán chuyển nhóm. Chương 3 trình bày kết quả.

Chương 3

KẾT QUẢ VÀ THẢO LUẬN

Chương này trình bày kết quả phân loại năm nhóm nợ trên bộ A và bộ B, kết quả giải thích mô hình, độ nhạy theo chiến lược mất cân bằng và siêu tham số, kết quả dự báo chuyển nhóm nợ trên hai cặp kỳ, và cuối cùng thảo luận theo bốn câu hỏi nghiên cứu. Các thước đo và nguyên tắc báo cáo đã trình bày ở Mục 2.6. Bảng 3.1 tóm tắt trước kết quả chính theo từng câu hỏi nghiên cứu và chỉ ra mục trình bày chi tiết.

Bảng 3.1: Tóm tắt kết quả chính theo bốn câu hỏi nghiên cứu

Câu hỏi	**Kết quả chính**	**Mục**
CH1	Các mô hình cây tổ hợp dẫn đầu ở cả hai bộ; LightGBM đạt Macro-F1 cao nhất (0,6484 ở bộ A và 0,6989 ở bộ B) nhưng khác biệt với XGBoost và Random Forest nhỏ hơn biên độ do siêu tham số. SMOTE vừa phải tối đa hóa Macro-F1, trọng số lớp tối đa hóa Recall nhóm hiếm; chiến lược kết hợp không vượt trội.	3.1.1, 3.4.1, 3.4.2
CH2	Thêm đặc trưng không luôn cải thiện: Top-7 của bộ A và Top-8 của bộ B đạt hiệu năng ngang tập đầy đủ. Hai khối dẫn đầu là thời hạn/tuổi khoản vay và dư nợ–lãi, nhưng thí nghiệm loại biến cho thấy phần lớn hiệu năng đến từ hai biến gắn với quy tắc phân loại.	3.1.2, 3.2.4, 3.2.5
CH3	Trên cùng một mô hình, Gain và SHAP thống nhất về thứ hạng nhóm (Spearman 0,90 và 0,89). Giữa hai bộ dữ liệu, hai nhóm dẫn đầu trùng khớp nhưng tương quan hạng 0,80 trên năm nhóm chưa đạt ý nghĩa thống kê.	3.3.2, 3.3.3
CH4	Ở cặp kỳ 1, rà soát 5% danh mục bắt được 56,6% số khoản vay sắp chuyển nhóm. Ở cặp kỳ 2 độc lập, mọi mô hình chỉ đạt mức ngẫu nhiên; kết luận này vẫn đứng vững sau khi loại trừ lỗi xử lý bằng bảy phép kiểm tra chẩn đoán.	3.5.1, 3.5.2, 3.5.4

Ngoài bốn câu hỏi trên, Mục 3.2.2 báo cáo một kết quả đáng chú ý về phương pháp: hiệu năng phân loại năm nhóm giữ được gần như nguyên vẹn khi áp dụng mô hình sang kỳ báo cáo kế tiếp, trái với kết luận ở phiên bản phân tích trước vốn bắt nguồn từ một lỗi xử lý dữ liệu đã được phát hiện và sửa (Mục 2.2.3).

3.1 Kết quả phân loại nhóm nợ trên bộ dữ liệu A

3.1.1 So sánh mô hình trên cấu hình chính

Bảng 3.2 trình bày kết quả của sáu mô hình trên cấu hình chính (11 đặc trưng, SMOTE) và tập kiểm định 5.401 quan sát. Làm mốc so sánh, bộ phân loại luôn dự báo nhóm 1 có Accuracy 0,7765, Macro-F1 0,1748 và Ordinal MAE 0,677.

Bảng 3.2: Kết quả trên tập kiểm định của bộ dữ liệu A (11 đặc trưng, SMOTE)

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro	Ordinal MAE
Logistic Regression	0,8734	0,4204	0,8368	0,8059	0,2785
Decision Tree	0,8847	0,5896	0,8786	0,8765	0,2085
Random Forest	0,9052	0,6179	0,8917	0,9182	0,1711
XGBoost	0,9096	0,6442	0,8982	**0,9201**	0,1576
LightGBM	**0,9113**	**0,6484**	**0,9001**	0,9181	**0,1529**
CatBoost	0,7497	0,5454	0,8033	0,9006	0,3366

LightGBM dẫn đầu Macro-F1 (0,6484), Accuracy và Ordinal MAE (0,1529); XGBoost đứng thứ hai về Macro-F1 (0,6442) và cao nhất về ROC-AUC (0,9201). Chênh lệch giữa hai mô hình này nhỏ (0,0042 Macro-F1), nhỏ hơn biên độ dao động theo siêu tham số (Mục 3.4.2). Logistic Regression có Accuracy 0,8734 nhưng Macro-F1 chỉ 0,4204 vì gần như không nhận diện được nhóm 2 và 3 (Recall 0,000 và 0,008). CatBoost có Accuracy thấp nhất (0,7497) và Ordinal MAE cao nhất (0,3366) vì trọng số lớp cân bằng khiến 818/4.194 hồ sơ nhóm 1 bị dự báo thành nhóm 2, nhưng đổi lại có Recall nhóm 2 cao nhất (0,6265). Ordinal MAE xếp hạng các mô hình gần như trùng với Macro-F1. Ma trận nhầm lẫn (Bảng P6.1, Phụ lục) cho thấy với LightGBM, 59,3% sai số chỉ lệch một bậc, nhưng phần còn lại là sai lệch từ hai bậc trở lên, chiếm 3,6% toàn bộ tập kiểm định. Đáng chú ý, 77% hồ sơ nhóm 3 bị phân loại sai và 68% hồ sơ nhóm 4 bị phân loại sai đều rơi về nhóm 1 — tức đánh giá thấp rủi ro nhiều bậc, đúng loại sai lệch mà Ordinal MAE phạt nặng và cũng là loại nghiêm trọng nhất về nghiệp vụ. Bộ A vì vậy khó hơn bộ B ở điểm này: cùng chỉ tiêu, tỷ lệ sai lệch từ hai

bậc trở lên của bộ B chỉ là 0,41% (Mục 3.2.3). XGBoost được dùng làm mô hình tham chiếu cho các phân tích đặc trưng tiếp theo của bộ A.

3.1.2 Hiệu năng theo số lượng đặc trưng

Để kiểm tra việc thêm biến có luôn cải thiện kết quả, 13 biến của tập mở rộng được xếp theo Gain của XGBoost 13 biến, rồi huấn luyện lại với k biến đầu (Bảng 3.3). Cần phân biệt hai khái niệm: "*Top-11*" là 11 biến có Gain cao nhất trong tập 13 biến (gồm `SEX`, không gồm `MJACCTTYPCD`), khác với "*11 biến cấu hình chính*" ở Bảng 3.2.

Bảng 3.3: Hiệu năng XGBoost theo số lượng đặc trưng — bộ dữ liệu A

Tập đặc trưng	Accuracy	Macro-F1	ROC-AUC macro	Ordinal MAE
Top-3	0,8958	0,6021	0,8826	0,2103
Top-5	0,8946	0,6140	0,9007	0,2087
Top-7	0,9065	0,6411	0,9197	0,1683
Top-9	0,9078	0,6388	0,9202	0,1603
Top-11	0,9096	0,6336	**0,9207**	0,1568
Top-13 (tập mở rộng)	**0,9098**	0,6434	0,9192	**0,1539**
11 biến cấu hình chính	0,9096	**0,6442**	0,9201	0,1576

Đường hiệu năng không tăng đơn điệu: Top-7 (0,6411) cao hơn Top-9 và Top-11. Top-7 — gồm hai biến kỳ hạn, lãi suất, hai mã đơn vị, dư nợ gốc và tỷ lệ sử dụng dư nợ — đạt 99,6% Macro-F1 của tập 13 biến, là cấu hình nhỏ nhất đạt ngưỡng 99% trong các k đã khảo sát. Cấu hình chính 11 biến (0,6442) nhỉnh hơn tập 13 biến (0,6434), tức việc bổ sung `SEX` và `LOAIKH` không cải thiện kết quả, xác nhận quyết định loại hai biến này bằng chính hiệu năng của bài toán năm lớp. Vì các k được so sánh trên cùng tập kiểm định, Top-7 chỉ là cấu hình ứng viên.

3.1.3 Đóng góp của các nhóm đặc trưng

Theo Gain của mô hình XGBoost 11 biến, nhóm Kỳ hạn khoản vay chiếm 56,5% tổng mức độ quan trọng, riêng `DAYS_TO_MATURITY` chiếm 45,0%; tiếp theo là Dư nợ và

hạn mức sử dụng (16,3%), Đơn vị/Chi nhánh (12,7%), Sản phẩm và mục đích vay (8,2%) và Lãi suất (6,4%). Mức tập trung cao vào một biến phù hợp với kết quả rà soát ở Bảng 2.4: bỏ `DAYS_TO_MATURITY` làm Macro-F1 giảm từ 0,6442 xuống 0,5153. Đối chiếu với SHAP trên cùng mô hình ở Mục 3.3.2.

3.2 Kết quả phân loại nhóm nợ trên bộ dữ liệu B

3.2.1 Mức mất cân bằng và so sánh mô hình trên tập kiểm định nội bộ

Tập kiểm định (20% kỳ 20260430) có 20.124 quan sát, trong đó 17.776 thuộc nhóm 1. Bộ phân loại luôn dự báo nhóm 1 đã có Accuracy $17.776/20.124 = 0,8834$, nên Accuracy khoảng 0,9 chưa chứng minh mô hình nhận diện được rủi ro [7]. Bảng 3.4 trình bày kết quả sáu mô hình trên 20 đặc trưng.

Bảng 3.4: Kết quả trên tập kiểm định của bộ dữ liệu B (20 đặc trưng, SMOTE)

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro	Ordinal MAE
Logistic Regression	0,9072	0,4098	0,8700	0,8692	0,1393
Decision Tree	0,9325	0,6566	0,9155	0,9127	0,0747
Random Forest	0,9338	0,6610	0,9158	0,9368	0,0726
XGBoost	0,9360	0,6797	0,9194	0,9402	0,0700
LightGBM	**0,9371**	**0,6989**	**0,9211**	**0,9410**	**0,0688**
CatBoost	0,6897	0,6009	0,7662	0,9187	0,3180

LightGBM dẫn đầu ở cả năm chỉ tiêu, XGBoost đứng thứ hai (Macro-F1 0,6797); chênh lệch 0,0192 vẫn nhỏ hơn biên độ dao động theo siêu tham số của hai mô hình (0,0613 và 0,0833, Mục 3.4.2). LightGBM được dùng làm mô hình tham chiếu cho các phân tích đặc trưng và SHAP của bộ B. Hai trường hợp đối lập minh họa giới hạn của Accuracy: Logistic Regression đạt Accuracy 0,9072 nhờ dự báo gần như mọi hồ sơ thành nhóm 1 (Recall nhóm 3 chỉ 0,025); CatBoost có Accuracy 0,6897 nhưng

ROC-AUC vẫn 0,9187, tức xếp hạng xác suất tốt nhưng trọng số lớp đẩy nhãn $\arg\max$ khỏi nhóm đa số.

3.2.2 Đánh giá ngoài thời gian trên kỳ 20260531

Mô hình và quy trình tiền xử lý ước lượng từ kỳ 20260430 được áp dụng nguyên vẹn, không huấn luyện lại, cho toàn bộ 100.274 hồ sơ kỳ 20260531 (Bảng 3.5). Mức Accuracy của bộ phân loại luôn dự báo nhóm 1 ở kỳ này là 0,8829.

Bảng 3.5: Kết quả trên tập ngoài thời gian 20260531 (không tham gia huấn luyện và chọn mô hình)

Mô hình	Accuracy	Macro-F1	Thay đổi Macro-F1 (%)	ROC-AUC macro	Ordinal MAE
Logistic Regression	0,8964	0,3840	$-6,3$	0,8570	0,1720
Decision Tree	0,8992	0,5903	$-10,1$	0,9142	0,1650
Random Forest	0,9215	0,6618	$+0,1$	0,9418	0,1168
XGBoost	**0,9255**	0,6826	$+0,4$	0,9488	**0,1003**
LightGBM	0,9195	**0,7023**	$+\mathbf{0,5}$	**0,9510**	0,1074
CatBoost	0,6732	0,5812	$-3,3$	0,9214	0,3665

Thay đổi Macro-F1 tính tương đối so với tập kiểm định ở Bảng 3.4; dấu dương nghĩa là kỳ sau tốt hơn.

Hiệu năng giữ được gần như nguyên vẹn trên tập ngoài thời gian đối với ba mô hình cây tổ hợp: LightGBM tăng từ 0,6989 lên 0,7023, XGBoost từ 0,6797 lên 0,6826 và Random Forest từ 0,6610 lên 0,6618. Hai mô hình giảm là Decision Tree ($-10,1\%$) và CatBoost ($-3,3\%$); Logistic Regression giảm $6,3\%$ từ một mức vốn đã rất thấp. ROC-AUC của cả ba mô hình tổ hợp thậm chí *tăng* nhẹ trên tập ngoài thời gian (LightGBM 0,9410→0,9510), phù hợp với việc kỳ sau có nhiều gấp năm lần số quan sát nên ước lượng ổn định hơn. Ordinal MAE tăng vừa phải (LightGBM 0,0688→0,1074), cho thấy sai lệch theo bậc có nới rộng nhưng không đáng kể.

Kết quả này cần được đọc cùng một lưu ý về phương pháp. Ở phiên bản phân tích

trước, bảng này cho thấy Macro-F1 giảm 12,7–32,1% và kết luận rằng phép chia ngẫu nhiên trong cùng kỳ ước lượng lạc quan khả năng tổng quát hóa theo thời gian. Kết luận đó *không đúng*: nó bắt nguồn từ lỗi phân tích cú pháp trường ngày ở kỳ 20260531 (Mục 2.2.3), khiến ba trong hai mươi đặc trưng rỗng hoàn toàn ở tập kiểm tra và bị thay bằng trung vị của tập huấn luyện. Sau khi sửa, khoảng cách tổng quát hóa ngoài thời gian gần như biến mất. Điều này không phủ nhận rủi ro dịch chuyển phân phối nói chung [31], nhưng cho thấy trong phạm vi hai kỳ liên tiếp của cùng danh mục, quan hệ giữa đặc trưng và nhóm nợ đủ ổn định để mô hình huấn luyện ở một kỳ áp dụng được cho kỳ kế tiếp. Cũng cần nhắc lại rằng hai kỳ có 98% khoản vay trùng nhau, nên kết quả này phản ánh độ ổn định trên danh mục đang theo dõi, chưa phải khả năng tổng quát hóa sang khách hàng mới.

3.2.3 Hiệu năng theo từng nhóm nợ và các lớp hiếm

Bảng 3.6 trình bày hiệu năng theo nhóm của LightGBM trên hai tầng đánh giá, và Bảng 3.7 trình bày ma trận nhầm lẫn năm lớp tương ứng.

Bảng 3.6: Precision, Recall và F1 của LightGBM theo nhóm nợ — tập kiểm định và kỳ sau

Nhóm	Kiểm định (20% kỳ 20260430)				Ngoài thời gian (20260531)			
	Số mẫu	Precision	Recall	F1	Số mẫu	Precision	Recall	F1
1	17.776	0,945	0,999	0,971	88.527	0,944	0,974	0,959
2	1.264	0,819	0,194	0,313	6.339	0,488	0,208	0,291
3	200	0,614	0,525	0,566	991	0,741	0,630	0,681
4	289	0,720	0,720	0,720	1.421	0,495	0,844	0,624
5	595	0,939	0,909	0,924	2.996	0,964	0,949	0,956

Bảng 3.7: Ma trận nhầm lẫn năm lớp của LightGBM (hàng: nhóm thực; cột: nhóm dự báo)

Thực	Kiểm định (20% kỳ 20260430)					Ngoài thời gian (20260531)				
	1	2	3	4	5	1	2	3	4	5
1	**17.760**	13	1	0	2	**86.220**	1.212	54	1.016	25
2	972	**245**	40	7	0	4.877	**1.316**	111	30	5
3	34	28	**105**	32	1	171	103	**624**	91	2
4	14	12	23	**208**	32	53	50	44	**1.200**	74
5	9	1	2	42	**541**	41	16	9	87	**2.843**

Ma trận nhầm lẫn làm rõ ba hiện tượng mà các chỉ tiêu tổng hợp che khuất. Thứ nhất, **nhóm 2 là điểm yếu lớn nhất** và là điểm yếu duy nhất tồn tại ở cả hai tầng đánh giá: 77% hồ sơ nhóm 2 ở tập kiểm định và 77% trên tập ngoài thời gian bị dự báo thành nhóm 1. Mô hình gần như không tách được giai đoạn "cần chú ý" khỏi nợ đủ tiêu chuẩn — đáng chú ý vì đây chính là nhóm mà cảnh báo sớm có giá trị nhất. Thứ hai, ba nhóm rủi ro cao 3, 4, 5 được nhận diện tốt và *ổn định* giữa hai kỳ, với Recall lần lượt 0,630, 0,844 và 0,949 trên tập ngoài thời gian, đều không thấp hơn tập kiểm định nội bộ. Thứ ba, sai số của mô hình hầu hết là lệch một bậc: tỷ lệ hồ sơ sai lệch từ hai bậc trở lên chỉ là 0,41% ở tập kiểm định nội bộ và 1,47% trên tập ngoài thời gian, nên Ordinal MAE giữ ở mức thấp (0,069 và 0,107). Trường hợp sai lệch nhiều bậc đáng kể duy nhất là 1.016 hồ sơ nhóm 1 bị dự báo thành nhóm 4 trên tập ngoài thời gian, chiếm 1,1% số hồ sơ nhóm 1 — cảnh báo thừa chứ không phải bỏ sót rủi ro, nên ít nghiêm trọng hơn về mặt nghiệp vụ.

Bảng 3.8: Recall các nhóm hiểm theo mô hình — tập kiểm định và kỳ sau

Mô hình	Kiểm định			Kỳ sau		
	Nhóm 3	Nhóm 4	Nhóm 5	Nhóm 3	Nhóm 4	Nhóm 5
Logistic Regression	0,025	0,180	0,721	0,008	0,189	0,722
Decision Tree	0,545	0,602	0,879	0,543	0,671	0,903
Random Forest	0,520	0,664	0,884	0,596	0,735	0,914
XGBoost	0,470	0,709	0,909	0,590	0,811	0,939
LightGBM	0,525	**0,720**	**0,909**	0,630	**0,844**	**0,949**
CatBoost	**0,635**	0,678	0,854	**0,650**	0,729	0,885

Bảng 3.8 cho thấy khả năng nhận diện ba nhóm rủi ro cao không những giữ được mà còn *tốt hơn* trên tập ngoài thời gian với cả năm mô hình cây. Với LightGBM, Recall nhóm 3 tăng từ 0,525 lên 0,630 và nhóm 4 từ 0,720 lên 0,844. Một phần của mức tăng này đến từ cỡ mẫu: kỳ sau có 991 và 1.421 hồ sơ ở hai nhóm này, gấp khoảng năm lần tập kiểm định, nên ước lượng Recall ổn định hơn. CatBoost vẫn là mô hình có Recall nhóm 3 cao nhất ở cả hai tầng, đúng như thiết kế dùng trọng số lớp, nhưng phải đánh đổi bằng Accuracy thấp hơn hẳn. Lựa chọn mô hình triển khai vì vậy cần gắn với chi phí bỏ sót của từng nhóm, không chỉ một thứ hạng chung.

3.2.4 Hiệu năng theo số lượng đặc trưng

Các đặc trưng được xếp theo Gain của LightGBM 20 biến, rồi huấn luyện lại với k biến đầu, giữ nguyên chiến lược SMOTE (Bảng 3.9).

Bảng 3.9: Hiệu năng LightGBM theo số lượng đặc trưng — bộ dữ liệu B, tập kiểm định

k	$Q(k)$ (%)	Macro-F1	ROC-AUC macro
3	73,0	0,6606	0,9085
5	86,5	0,6767	0,9289
8	98,5	0,6961	0,9406
11	99,7	**0,7017**	0,9410
14	99,9	0,6959	0,9410
17	100,0	0,6935	**0,9412**
20 (đầy đủ)	100,0	0,6989	0,9410

Tám đặc trưng đầu chiếm 98,5% tổng Gain và đạt Macro-F1 0,6961, chỉ kém tập đầy đủ 20 biến 0,003; cấu hình 11 biến đạt cao nhất (0,7017), nhỉnh hơn cả tập đầy đủ. Toàn bộ các cấu hình từ 8 biến trở lên nằm trong khoảng hẹp 0,694–0,702. Ba đặc trưng đầu — lãi chưa thu ngoại bảng, dư nợ và số ngày đến đáo hạn — đã đạt 94,5% Macro-F1 của tập đầy đủ, nhất quán với mức tập trung Gain vào biến lãi ngoại bảng (Mục 3.2.5). Bộ B cho bằng chứng rõ hơn bộ A rằng thêm đặc trưng không tất yếu cải thiện kết quả. Ở cấp dữ liệu thô, quy trình giảm từ 33 cột xuống 20 đặc trưng (39,4%), nhưng mức giảm này đến từ việc loại trường định danh, rò rỉ, trường ngày và hằng số (Bảng 2.7), không phải từ lựa chọn theo hiệu năng. Cấu hình 8 biến là ứng viên rút gọn, cần xác nhận trên kỳ dữ liệu chưa dùng để chọn k.

3.2.5 Đóng góp của các nhóm đặc trưng

Theo Gain của LightGBM, nhóm Dư nợ & Thanh toán chiếm 69,2% — riêng `Lãi chưa thu hạch toán ngoại bảng` chiếm 54,8% — và nhóm Đặc trưng kỹ thuật chiếm 21,0%; bốn nhóm còn lại gồm Chi nhánh (4,3%), Lãi suất (4,0%), Hình thức & Mục đích vay (0,7%) và Kỳ hạn & Cơ cấu lại (0,7%). Như đã rà soát ở Mục 2.3.1, biến lãi ngoại bảng là hệ quả kế toán của việc phân loại nợ theo Điều 5 Thông tư số 16/2018/TT-BTC [9]; vì vậy tỷ trọng cao của nhóm Dư nợ & Thanh toán cần được

hiểu là mô hình khai thác thông tin kế toán hình thành cùng lúc với nhãn, không phải bằng chứng rằng dư nợ là yếu tố dẫn tới nợ xấu.

Hiệu năng của cấu hình thận trọng

Để người đọc thấy rõ phần hiệu năng *không* dựa vào các biến gắn với quy tắc phân loại, Bảng 2.4 (Chương 2) báo cáo thêm một cấu hình thận trọng. Bỏ biến lãi chưa thu ngoại bảng làm Macro-F1 của LightGBM giảm từ 0,6989 xuống 0,4742 trên tập kiểm định nội bộ; bỏ cả hai biến lãi còn 0,4396. Trên tập ngoài thời gian, hai mức tương ứng là 0,5149 và 0,4737 so với 0,7023 của cấu hình đầy đủ. Tương tự ở bộ A, bỏ `DAYS_TO_MATURITY` làm Macro-F1 của XGBoost giảm từ 0,6442 xuống 0,5153.

Cách đọc đúng của hai nhóm số liệu này như sau. Cấu hình đầy đủ trả lời câu hỏi "từ toàn bộ dữ liệu sẵn có tại thời điểm báo cáo, mô hình tái hiện nhóm nợ chính xác đến mức nào", và câu trả lời là khá chính xác (Macro-F1 khoảng 0,70). Cấu hình thận trọng trả lời câu hỏi khác: "nếu loại các biến hình thành cùng lúc với nhãn, mô hình còn lại bao nhiêu năng lực", và câu trả lời là khoảng 0,47–0,52 — vẫn cao hơn hẳn mô hình tuyến tính đầy đủ biến (0,41) nhưng thấp hơn nhiều cấu hình đầy đủ. Luận văn giữ cấu hình đầy đủ làm cấu hình chính vì mọi biến đều sẵn có hợp lệ tại thời điểm báo cáo và bài toán ở đây là phân loại trạng thái hiện tại, không phải dự báo; nhưng khi diễn giải cho mục tiêu cảnh báo sớm thì cấu hình thận trọng mới là mốc tham chiếu phù hợp. Bài toán chuyển nhóm ở Mục 3.5 không gặp vấn đề này, vì ở đó đặc trưng mô tả trạng thái tại T còn nhãn mô tả diễn biến đến $T + h$, nên hai biến lãi là thông tin hợp lệ.

3.3 Giải thích mô hình và độ ổn định của kết luận giải thích

3.3.1 Kết quả SHAP trên hai bộ dữ liệu

SHAP được tính bằng `TreeExplainer` [27] của thư viện SHAP [29] cho đúng mô hình tham chiếu của mỗi bộ, trên cỡ mẫu tương đương để hai bộ so sánh được với nhau: XGBoost 11 biến trên toàn bộ 5.401 quan sát kiểm định của bộ A, và LightGBM 20 biến trên 5.000 quan sát lấy ngẫu nhiên từ tập kiểm định của bộ B. Với bài toán chuyển nhóm, nơi sự kiện quá hiếm để lấy mẫu ngẫu nhiên có ý nghĩa, mẫu được lấy *có phân tầng theo nhãn* (Mục 3.5.3). Mức độ quan trọng của một biến là trung bình $|\phi_j|$ trên các quan sát và năm lớp; giá trị từng biến ở Bảng P6.2 và Bảng P6.3 (Phụ lục). Bảng 3.10 tổng hợp theo nhóm nghiệp vụ.

Bảng 3.10: Tỷ trọng SHAP theo nhóm nghiệp vụ trên hai bộ dữ liệu

Nhóm — bộ A	SHAP (%)	Hạng	Nhóm tương ứng — bộ B	SHAP (%)	Hạng
Kỳ hạn khoản vay	41,0	1	Đặc trưng kỹ thuật	38,8	2
Dư nợ và hạn mức sử dụng	26,8	2	Dư nợ & Thanh toán	43,5	1
Đơn vị/Chi nhánh	14,7	3	Chi nhánh	5,5	4
Lãi suất	8,8	4	Lãi suất	6,5	3
Sản phẩm và mục đích vay	8,7	5	Hình thức & Mục đích vay	4,5	5
(không có nhóm tương ứng)			Kỳ hạn & Cơ cấu lại	1,3	6

Ở bộ A, `DAYS_TO_MATURITY` có SHAP trung bình cao nhất (31,3% tổng), tiếp theo tỷ lệ sử dụng dư nợ và tổng kỳ hạn. Ở bộ B, `Lãi chưa thu hạch toán ngoại bảng` (31,2% tổng SHAP) và tuổi khoản vay `ENG_LOAN_AGE_DAYS` (25,8%) dẫn đầu; ba biến cơ cấu nợ, mã tiền tệ, nguồn và hình thức cấp tín dụng có SHAP gần 0. Nhóm Kỳ hạn khoản vay của bộ A được ánh xạ với nhóm Đặc trưng kỹ thuật của bộ B vì ba trong bốn biến kỹ thuật của bộ B mô tả thời hạn và tuổi khoản vay.

3.3.2 Đối chiếu Gain và SHAP trên cùng cấu hình

Để kiểm tra kết luận có phụ thuộc thước đo giải thích hay không, Gain và SHAP được so sánh trên *cùng một mô hình, cùng tập đặc trưng* (Bảng 3.11). Phép so sánh này thay thế đối chiếu trước đây giữa Gain của tập 13 biến và SHAP của tập 11 biến, vốn trộn lẫn khác biệt về thước đo với khác biệt về cấu hình.

Bảng 3.11: Gain và SHAP trên cùng mô hình: tỷ trọng nhóm và tương quan hạng Spearman

Bộ A — XGBoost 11 biến			Bộ B — LightGBM 20 biến		
Nhóm	Gain (%)	SHAP (%)	Nhóm	Gain (%)	SHAP (%)
Kỳ hạn khoản vay	56,5	41,0	Dư nợ & Thanh toán	69,2	43,5
Dư nợ và hạn mức	16,3	26,8	Đặc trưng kỹ thuật	21,0	38,8
Đơn vị/Chi nhánh	12,7	14,7	Chi nhánh	4,3	5,5
Sản phẩm, mục đích	8,2	8,7	Lãi suất	4,0	6,5
Lãi suất	6,4	8,8	Hình thức, mục đích	0,7	4,5
			Kỳ hạn & Cơ cấu lại	0,7	1,3
ρ cấp biến ($n = 11$)	0,755 ($p = 0,007$)		ρ cấp biến ($n = 20$)	0,964 ($p < 0,001$)	
ρ cấp nhóm ($n = 5; 6$)	0,900 ($p = 0,037$)		ρ cấp nhóm	0,886 ($p = 0,019$)	

Trên cùng mô hình, hai thước đo thống nhất cao về thứ hạng: tương quan Spearman cấp nhóm là 0,90 (bộ A) và 0,89 (bộ B), cả hai có ý nghĩa ở mức 5%; ba nhóm dẫn đầu trùng thứ tự ở cả hai bộ. Khác biệt nằm ở *mức độ tập trung*: Gain dồn tỷ trọng vào nhóm dẫn đầu (56,5% và 69,2%) nhiều hơn SHAP (41,0% và 43,5%), còn SHAP phân bổ lại cho nhóm thứ hai. Đây là khác biệt đã biết giữa hai thước đo: Gain cộng dồn mức giảm hàm mất mát ở mọi lần chia, kể cả các lần chia sâu có tác động nhỏ tới dự báo, và ưu tiên biến được dùng ở các nút gốc; SHAP đo đóng góp vào đầu ra trên mẫu đánh giá. Kết luận "nhóm nào quan trọng nhất" vì vậy ổn định theo thước đo, còn kết luận "quan trọng đến mức nào" thì không.

3.3.3 Đối chiếu kết quả giải thích giữa hai bộ dữ liệu

Hai bộ dữ liệu khác nhau về cấu trúc cột, thời điểm và đơn vị quan sát (Mục 2.2.2), nên chỉ so sánh được ở cấp nhóm nghiệp vụ (Bảng 3.10). Hai nhóm dẫn đầu ở cả hai bộ là cùng một cặp nội dung — thời hạn/tuổi khoản vay và dư nợ — chỉ đổi thứ tự cho nhau, cùng chiếm 67,8% tổng SHAP ở bộ A và 82,3% ở bộ B; Top-2 trùng khớp 2/2, Top-3 trùng khớp 2/3 do Chi nhánh và Lãi suất đổi hạng 3–4; nhóm sản phẩm/mục đích vay đứng cuối ở cả hai bộ. Tương quan hạng Spearman trên năm nhóm ánh xạ được là $\rho = 0,80$.

Tuy nhiên, với chỉ năm nhóm, $\rho = 0,80$ *không* có ý nghĩa thống kê ở mức 5%: giá trị p chính xác theo hoán vị (120 hoán vị) là 0,133, theo xấp xỉ tiệm cận là 0,104. Mức trùng khớp vì vậy là bằng chứng mô tả nhất quán với giả thuyết "nhóm thông tin dẫn đầu không phụ thuộc một bộ dữ liệu", chưa phải bằng chứng thống kê cho giả thuyết đó. Hơn nữa, như Mục 2.3.1 đã chỉ ra, biến dẫn đầu ở mỗi bộ (`DAYS_TO_MATURITY` và lãi ngoại bảng) đều mang thông tin gần với quy tắc phân loại; sự trùng khớp giữa hai bộ có thể một phần phản ánh việc cả hai mô hình cùng khai thác dấu vết của quy tắc phân loại nợ, chứ không chỉ các yếu tố rủi ro.

3.4 Độ nhạy theo chiến lược mất cân bằng và siêu tham số

3.4.1 So sánh bốn chiến lược xử lý mất cân bằng

Bốn chiến lược được so sánh trên mô hình tham chiếu của mỗi bộ, cùng phép chia 80/20 như bảng chính (Bảng 3.12 và Bảng 3.13). Cả hai bộ đều được chạy trong cùng một quy trình với các bảng so sánh mô hình chính, nên dòng SMOTE trùng khớp đúng giá trị của bảng chính: 0,6442 ở bộ A (Bảng 3.2) và 0,6989 ở bộ B (Bảng 3.4). Việc hai bảng khớp nhau đến từng chữ số là một phép kiểm tra tái lập: ở phiên bản trước, hai lần chạy độc lập cho bộ A lệch nhau 0,0195 mà không xác định được nguyên nhân;

toàn bộ kết quả nay được sinh từ một lần chạy thống nhất với hạt giống cố định ở mọi bước.

Bảng 3.12: Bốn chiến lược mất cân bằng — XGBoost, bộ A

Chiến lược	Macro-F1	ROC-AUC	Ordinal MAE	Recall N2	Recall N3	Recall N4
SMOTE	**0,6442**	0,9201	0,1576	0,241	0,388	0,484
Không xử lý	0,6257	**0,9265**	**0,1561**	0,175	0,289	0,465
Trọng số lớp	0,6016	0,9167	0,2461	**0,545**	**0,455**	**0,605**
Kết hợp	0,5893	0,9096	0,2444	0,463	0,438	0,580

Bảng 3.13: Bốn chiến lược mất cân bằng — LightGBM, bộ B

Chiến lược	Macro-F1	ROC-AUC	Recall N2	Recall N3	Recall N4
SMOTE	**0,6989**	0,9410	0,194	0,525	0,720
Không xử lý	0,6844	**0,9413**	0,205	0,465	0,664
Kết hợp	0,6615	0,9330	0,634	0,550	**0,723**
Trọng số lớp	0,6385	0,9309	**0,669**	**0,565**	0,706

Ở cả hai bộ, SMOTE với mục tiêu vừa phải đạt Macro-F1 cao nhất, còn không xử lý đạt ROC-AUC cao nhất. Trọng số lớp và chiến lược kết hợp nâng mạnh Recall các nhóm hiếm (Recall nhóm 2 ở bộ B tăng từ 0,19 lên 0,63–0,67) nhưng làm giảm Macro-F1 và, ở bộ A, làm Ordinal MAE tăng từ khoảng 0,16 lên 0,25 do nhiều hồ sơ nhóm 1 bị đẩy sang nhóm 2. Chiến lược kết hợp không đạt giá trị cao nhất ở Macro-F1 hay ROC-AUC trên bộ nào. Không có chiến lược vượt trội tuyệt đối: lựa chọn phụ thuộc việc ngân hàng ưu tiên độ chính xác tổng thể hay bắt được nhiều hồ sơ rủi ro hơn.

3.4.2 Độ nhạy theo siêu tham số

Bảng 3.14 so sánh cấu hình mặc định với cấu hình tốt nhất trong lưới và biên độ Macro-F1 trên toàn lưới của từng mô hình.

Bảng 3.14: Độ nhạy Macro-F1 theo siêu tham số (65 cấu hình bộ A, 60 cấu hình bộ B)

Bộ	Mô hình	Mặc định	Tốt nhất	Cải thiện	Nhỏ nhất	Biên độ
A	Logistic Regression	0,4204	0,4220	+0,37%	0,3993	0,0227
A	Decision Tree	0,5896	0,6086	+3,22%	0,5626	0,0460
A	Random Forest	0,6179	0,6303	+2,01%	0,6135	**0,0168**
A	XGBoost	0,6442	0,6442	+0,00%	0,6270	0,0173
A	LightGBM	0,6484	**0,6484**	+0,00%	0,6223	0,0261
A	CatBoost	0,5454	0,5677	**+4,08%**	0,5259	0,0418
B	Logistic Regression	0,4098	0,4451	$+8,60\%$	0,3266	0,1185
B	Decision Tree	0,6566	0,6614	$+0,73\%$	0,5859	0,0755
B	Random Forest	0,6610	0,6687	$+1,16\%$	0,6297	**0,0390**
B	XGBoost	0,6797	0,6935	$+2,02\%$	0,6102	0,0833
B	LightGBM	0,6989	**0,7030**	$+0,58\%$	0,6417	0,0613
B	CatBoost	0,6009	0,6191	$+3,03\%$	0,5522	0,0669

Ba nhận định chính. Thứ nhất, với các mô hình cây, cấu hình mặc định đã gần tối ưu trong lưới: cải thiện dưới 1,2% ở bốn trên năm mô hình, cao nhất là CatBoost ($+3,03\%$) và XGBoost ($+2,02\%$). Ngoại lệ rõ rệt là Logistic Regression ở bộ B, cải thiện $8,60\%$ khi đổi tham số chính quy C. Kết hợp với kết quả One-Hot ở Mục 3.4.3 ($+4,4\%$), có thể thấy hiệu năng thấp của mô hình tuyến tính trên dữ liệu này đến từ *cả* cách biểu diễn đầu vào *lẫn* tham số chính quy, chứ không chỉ từ giới hạn của dạng hàm tuyến tính; tuy vậy ngay ở cấu hình tốt nhất (0,4451) nó vẫn kém xa các mô hình cây.

Thứ hai, Random Forest có biên độ nhỏ nhất ở cả hai bộ (0,0168 và 0,0390), phù hợp cơ chế lấy trung bình nhiều cây giúp giảm phương sai [6]. Mô hình nhạy nhất khác nhau giữa hai bộ: ở bộ A là Decision Tree (0,0460), ở bộ B là Logistic Regression (0,1185), tiếp theo là XGBoost (0,0833).

Thứ ba, biên độ ở bộ B lớn hơn bộ A với cả sáu mô hình, và chênh lệch Macro-F1 giữa LightGBM và XGBoost ở cấu hình mặc định (0,0192) vẫn nhỏ hơn biên độ của từng mô hình (0,0613 và 0,0833), nên thứ hạng giữa hai mô hình không đủ vững để coi là khác biệt thuật toán. Cấu hình tốt nhất được chọn trên chính tập kiểm định nội

bộ, nên mức cải thiện có thể lạc quan do thiên lệch lựa chọn.

3.4.3 Độ nhạy theo lựa chọn tiền xử lý

Ba lựa chọn tiền xử lý ở Chương 2 có thể bị chất vấn về mặt nguyên tắc: mã chi nhánh là biến định danh nhưng được đưa vào như biến số; SMOTE nội suy tuyến tính cả các cột phân loại đã mã hóa; và LabelEncoder tạo thứ tự số giả cho các biến nhiều danh mục. Mục này kiểm chứng từng lựa chọn bằng thực nghiệm thay vì chỉ nêu như một hạn chế (Bảng 3.15).

Bảng 3.15: Kiểm chứng ba lựa chọn tiền xử lý — Macro-F1

Kiểm chứng	**Mô hình**	**Cấu hình chính**	**Phương án thay thế**	**Chênh**
(a) Mã chi nhánh: biến số so với biến phân loại — bộ B, tập kiểm định nội bộ				
	LightGBM	0,6989	0,6985	$-0,0004$
	XGBoost	0,6797	0,6968	$+0,0171$
	Logistic Regression	0,4098	0,4068	$-0,0030$
(b) SMOTE so với SMOTE-NC — tập kiểm định nội bộ				
Bộ B	LightGBM	0,6989	0,7019	$+0,0030$
Bộ B	XGBoost	0,6797	0,6825	$+0,0028$
Bộ A	XGBoost	0,6442	0,6387	$-0,0055$
(c) LabelEncoder so với One-Hot cho hai biến nhiều danh mục — bộ A				
	XGBoost	0,6442	0,6392	$-0,0050$
	Logistic Regression	0,4204	**0,4388**	$+\mathbf{0,0184}$

(a) Mã chi nhánh. Chuyển mã chi nhánh từ nhóm biến số sang nhóm biến phân loại — tức bỏ bước chuẩn hóa z-score vốn vô nghĩa với một mã định danh — làm Macro-F1 thay đổi không quá 0,017, và đổi dấu tùy mô hình. Trên tập ngoài thời gian, chênh lệch còn nhỏ hơn (không quá 0,004 với cả ba mô hình). Mối lo về nguyên tắc là chính đáng, nhưng trong dữ liệu này nó không làm đổi kết luận nào: thứ hạng mô hình giữ nguyên và LightGBM vẫn dẫn đầu ở cả hai cách.

(b) SMOTE-NC. SMOTE-NC xử lý riêng cột phân loại — lấy giá trị phổ biến nhất trong các láng giềng thay vì nội suy tuyến tính — nên không sinh ra mã danh mục

không hợp lệ. Kết quả cải thiện nhẹ trên bộ B (khoảng $+0,003$) và giảm nhẹ trên bộ A ($-0,006$). Mức chênh này nhỏ hơn biên độ dao động theo siêu tham số của chính các mô hình (Bảng 3.14), nên vấn đề nội suy biến phân loại tuy có thật về nguyên tắc nhưng không phải nguồn sai số đáng kể ở đây.

(c) One-Hot. Đây là kiểm chứng cho kết quả rõ ràng nhất và đúng như lý thuyết dự đoán. Thay LabelEncoder bằng One-Hot (gộp các danh mục xuất hiện dưới 20 lần, sinh 53 cột) cho hai biến nhiều danh mục của bộ A *không* giúp XGBoost ($-0,005$) nhưng cải thiện Logistic Regression rõ rệt ($+0,018$, tức $+4,4\%$ tương đối). Mô hình cây chia nhánh theo ngưỡng nên chịu được thứ tự số giả, còn mô hình tuyến tính buộc phải giả định quan hệ đơn điệu với mã danh mục — một giả định sai. Kết quả này củng cố nhận định ở Mục 3.2.1 rằng hạn chế của Logistic Regression một phần đến từ cách biểu diễn đầu vào, không chỉ từ dạng hàm tuyến tính.

Tổng hợp lại, cả ba lựa chọn tiền xử lý đều có thể cải thiện về mặt nguyên tắc, nhưng không lựa chọn nào làm thay đổi kết luận của luận văn về thứ hạng mô hình hay nhóm thông tin quan trọng. Cấu hình chính được giữ nguyên để mọi bảng kết quả so sánh được với nhau; các phương án thay thế được ghi nhận ở đây làm căn cứ cho lần triển khai tiếp theo.

3.5 Kết quả bài toán dự báo chuyển nhóm nợ

3.5.1 So sánh mô hình và chiến lược trên cặp kỳ 1

Bảng 3.16 trình bày kết quả kiểm định chéo 5 phần lặp 10 lần trên cặp 1 (98.968 khoản vay, 265 sự kiện). Với mỗi mô hình, bảng báo cáo chiến lược có AP trung bình cao nhất; cột cuối là giá trị p của kiểm định t hiệu chỉnh Nadeau–Bengio so với XGBoost, đã hiệu chỉnh Holm [32].

Bảng 3.16: Sáu mô hình dự báo chuyển nhóm nợ trên cặp 1 (kiểm định chéo 5×10)

Mô hình	Chiến lược	AP	ROC-AUC	Precision(+)	Recall(+)	p so với XGBoost
XGBoost	không xử lý	**0,1806±0,0491**	0,8458±0,0268	0,887±0,121	0,110±0,038	—
LightGBM	SMOTE	0,1761±0,0488	0,8399±0,0305	0,753±0,145	0,125±0,043	0,651
Random Forest	không xử lý	0,1679±0,0485	**0,8497±0,0256**	0,580±0,499	0,016±0,015	0,327
CatBoost	không xử lý	0,1277±0,0439	0,8307±0,0269	0,866±0,272	0,055±0,026	0,001
Decision Tree	SMOTE	0,0805±0,0409	0,6879±0,0451	0,205±0,085	0,101±0,048	$< 0,001$
Logistic Regression	không xử lý	0,0050±0,0008	0,6208±0,0332	0,000	0,000	$< 0,001$

Giá trị sau ± là độ lệch chuẩn qua 50 phần kiểm định; Precision(+) và Recall(+) tính cho lớp "xấu đi" tại ngưỡng 0,5. Mức AP của xếp hạng ngẫu nhiên là 0,00268.

XGBoost không xử lý mất cân bằng có AP cao nhất (0,1806), gấp khoảng 67 lần mức ngẫu nhiên. Tuy nhiên, kiểm định hiệu chỉnh cho thấy XGBoost *không* khác biệt có ý nghĩa với LightGBM ($p = 0,651$) và Random Forest ($p = 0,327$); chỉ khác biệt có ý nghĩa với CatBoost, Decision Tree và Logistic Regression. Ba mô hình cây tổ hợp dẫn đầu vì vậy được xem là tương đương. Lưu ý rằng kiểm định Wilcoxon thông thường trên cùng 50 phần cho $p < 0,001$ ở cặp XGBoost–Random Forest; sự khác biệt này minh họa vì sao cần hiệu chỉnh cho việc các phần kiểm định dùng chung dữ liệu huấn luyện. Logistic Regression có AP 0,0050, chỉ gấp 1,9 lần mức ngẫu nhiên.

Với XGBoost, bốn chiến lược mất cân bằng cho AP lần lượt: không xử lý 0,1806, SMOTE 0,1710, kết hợp 0,1612 và trọng số lớp 0,1541. Trọng số lớp nâng Recall(+) tại ngưỡng 0,5 từ 0,110 lên 0,265 nhưng giảm Precision(+) từ 0,887 xuống 0,074 — một đánh đổi về ngưỡng quyết định hơn là cải thiện khả năng xếp hạng, vì AP và ROC-AUC không tăng. Với bài toán xếp hạng để rà soát, không xử lý mất cân bằng là lựa chọn phù hợp.

3.5.2 Đánh giá theo tỷ lệ rà soát (Recall@k)

Để minh họa ý nghĩa nghiệp vụ, mô hình XGBoost không xử lý mất cân bằng được huấn luyện lại trên một phép chia 80/20 ở mỗi cặp. Ở cặp 1, mô hình đạt AP 0,1705 và ROC-AUC 0,8487 trên 19.794 hồ sơ kiểm định (53 sự kiện), nhất quán với kiểm định

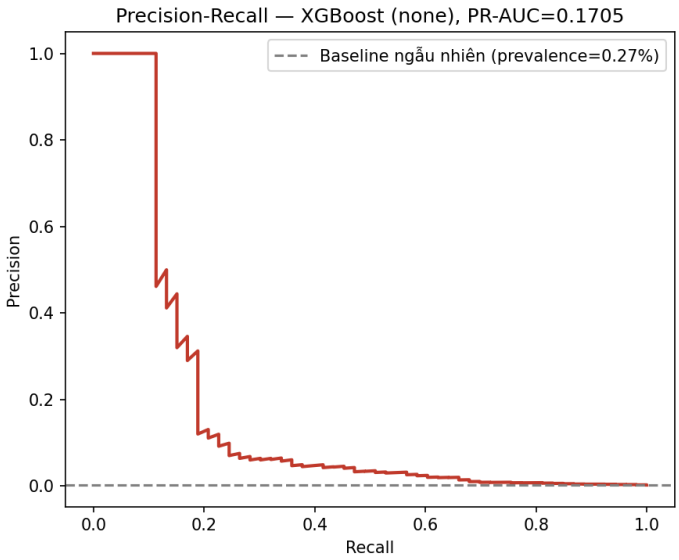
chéo; tại ngưỡng 0,5, mô hình chỉ gắn nhãn dương cho 6/53 sự kiện, nhưng cả 6 đều đúng. Ở cặp 2, cùng cấu hình chỉ đạt AP 0,0029 và ROC-AUC 0,4569. Vì ngưỡng 0,5 không phù hợp với sự kiện hiếm, Bảng 3.17 đánh giá theo tỷ lệ hồ sơ được rà soát.

Bảng 3.17: Recall@k và Precision@k trên tập kiểm định minh họa của hai cặp kỳ

Top-k	Cặp 1 (53 sự kiện)				Cặp 2 (52 sự kiện)			
	Hồ sơ	Bắt được	Recall	Precision	Hồ sơ	Bắt được	Recall	Precision
1%	198	14	**26,4%**	7,1%	197	1	1,9%	0,5%
2%	396	19	**35,8%**	4,8%	394	1	1,9%	0,3%
5%	990	30	**56,6%**	3,0%	986	3	5,8%	0,3%
10%	1.979	35	**66,0%**	1,8%	1.972	8	15,4%	0,4%

Cùng mô hình XGBoost không xử lý mất cân bằng, cùng cách chia 80/20 với hạt giống 42. Với xếp hạng ngẫu nhiên, Recall@k kỳ vọng bằng đúng k.

Bảng 3.17 là cách trình bày gần với nghiệp vụ nhất trong toàn bộ luận văn, vì nó trả lời trực tiếp câu hỏi "nếu chỉ rà soát được k% danh mục thì bắt được bao nhiêu phần sự kiện". Ở cặp 1, rà soát 5% danh mục có điểm cao nhất bắt được 30/53 sự kiện (Recall 56,6%), gấp hơn 11 lần kỳ vọng ngẫu nhiên là 2,65 sự kiện; đổi lại 960/990 hồ sơ trong danh sách không xấu đi (Precision 3,0%). Ở cặp 2, cùng mô hình và cùng tỷ lệ rà soát chỉ bắt được 3/52 sự kiện, tức Recall 5,8% — xấp xỉ đúng mức 5% của việc chọn ngẫu nhiên. Ở mức rà soát 1% và 2%, cặp 2 thậm chí còn kém hơn chọn ngẫu nhiên. Đối chiếu hai cột của bảng này cho thấy rõ nhất ý nghĩa thực tiễn của kết quả ở Mục 3.5.4: một danh sách ưu tiên rà soát xây từ giai đoạn trước có thể hữu ích hoặc hoàn toàn vô ích tùy giai đoạn áp dụng, mà không có dấu hiệu nào trong dữ liệu đầu vào báo trước điều đó. Hình 3.1 trình bày đường Precision–Recall của cặp 1.



Hình 3.1: Đường Precision–Recall của XGBoost trên tập kiểm định minh họa, cặp 1 (nhãn PR-AUC trong hình là AP)

3.5.3 Giải thích bằng SHAP

Vì sự kiện rất hiếm, một mẫu SHAP ngẫu nhiên 500 quan sát chỉ chứa khoảng 1–2 sự kiện. Luận văn vì vậy tính SHAP trên mẫu *phân tầng theo nhãn*: toàn bộ 53 sự kiện của tập kiểm định minh họa cùng 447 quan sát không xấu đi chọn ngẫu nhiên (Bảng 3.18).

Bảng 3.18: Mức độ quan trọng SHAP (trung bình $|\phi_j|$) của mô hình dự báo chuyển nhóm, mẫu phân tầng

Biến	Mẫu phân tầng ($n = 500$)	Chỉ sự kiện ($n = 53$)	Chỉ không xấu đi ($n = 447$)
Lãi phải thu hạch toán nội bảng	0,931	1,043	0,918
Số dư nợ theo nguyên tệ	0,652	0,769	0,638
ENG_DAYS_TO_MATURITY	0,547	0,517	0,550
ENG_TENOR_ACTUAL_DAYS	0,465	0,356	0,478
ENG_LOAN_AGE_DAYS	0,445	0,416	0,448
Mã chi nhánh TCTD	0,400	0,460	0,392
Lãi suất	0,366	0,402	0,361
Lãi chưa thu hạch toán ngoại bảng	0,240	0,373	0,225

Thứ hạng tám biến đầu trên mẫu phân tầng trùng với mẫu ngẫu nhiên trước đây, nên kết luận về biến quan trọng không phụ thuộc cách lấy mẫu. Lãi phải thu hạch toán nội bảng dẫn đầu, tiếp theo dư nợ và ba biến thời hạn. Trên riêng các sự kiện, vai trò của hai biến lãi và dư nợ lớn hơn, còn vai trò của biến kỳ hạn nhỏ hơn: mô hình dựa chủ yếu vào trạng thái lãi và dư nợ tại T để nhận diện khoản vay sắp xấu đi. Diễn giải sâu hơn cần định nghĩa kế toán chính xác của từng trường lãi; SHAP chỉ mô tả cách mô hình dùng các giá trị này, không xác lập quan hệ nhân quả.

3.5.4 Độ ổn định giữa hai cặp kỳ quan sát

Cặp 2 (20260531→20260630) được xây dựng bằng đúng quy trình của cặp 1 và có đặc điểm sự kiện gần như giống hệt (Bảng 3.19): tỷ lệ sự kiện 0,262% so với 0,268%, cơ cấu theo loại chuyển nhóm gần trùng khớp, và mọi sự kiện đều chỉ tăng một bậc. Nếu mô hình học được một quy luật ổn định, kết quả trên cặp 2 phải tương tự cặp 1.

Bảng 3.19: Đặc điểm sự kiện và hiệu năng trên hai cặp kỳ

	Cặp 1 (04→05/2026)	Cặp 2 (05→06/2026)
Khoản vay khớp	98.968	98.620
Sự kiện xấu đi (tỷ lệ)	265 (0,268%)	258 (0,262%)
1→2 / 2→3 / 3→4 / 4→5	214 / 10 / 10 / 31	206 / 8 / 12 / 32
Khoản vay cải thiện nhóm	166	151
AP — XGBoost, không xử lý	**0,1806±0,0491**	0,0047±0,0023
AP — LightGBM, SMOTE	0,1761±0,0488	0,0037±0,0011
AP — Random Forest, không xử lý	0,1679±0,0485	0,0042±0,0010
AP — CatBoost, không xử lý	0,1277±0,0439	**0,0063±0,0023**
AP — Decision Tree, SMOTE	0,0805±0,0409	0,0036±0,0011
AP — Logistic Regression	0,0050±0,0008	0,0028±0,0004
Khoảng ROC-AUC của sáu mô hình	0,621–0,850	0,484–0,555
Mức AP ngẫu nhiên	0,0027	0,0026
Chuyển giao cặp 1 → cặp 2	AP 0,0031; ROC-AUC 0,5526	
Chuyển giao cặp 2 → cặp 1	AP 0,0034; ROC-AUC 0,5425	

Kết quả không lặp lại ở bất kỳ mô hình nào. Ở cặp 2, AP của cả sáu mô hình nằm trong khoảng hẹp quanh mức ngẫu nhiên 0,0026, với độ lệch chuẩn qua 50 phần kiểm định cùng bậc độ lớn với chính giá trị trung bình; ROC-AUC dao động quanh 0,5. Khi không mô hình nào tách được khỏi mức ngẫu nhiên thì thứ hạng giữa chúng không còn ý nghĩa, nên mục này không báo cáo kiểm định so sánh cặp đôi cho cặp 2 như đã làm với cặp 1 ở Bảng 3.16.

Bảy phép kiểm tra loại trừ lỗi xử lý

Một kết quả âm tính mạnh như vậy đòi hỏi phải loại trừ khả năng lỗi kỹ thuật trước khi diễn giải. Luận văn thực hiện bảy phép kiểm tra chẩn đoán (Bảng 3.20); phép kiểm tra thứ ba đã *phát hiện một lỗi thật*.

Bảng 3.20: Bảy phép kiểm tra chẩn đoán cặp kỳ 2

	Kiểm tra	**Kết quả**
1	Toàn vẹn dữ liệu ba kỳ	Không có khóa trùng lặp; danh mục 33 cột trùng khớp; mỗi kỳ đúng một `ETL_DATE`; không thiếu biến đích. Đạt.
2	Tỷ lệ khớp khóa và cơ cấu nhãn	98,4% ở cả hai cặp; 265 và 258 sự kiện; cơ cấu theo loại chuyển nhóm gần trùng khớp. Đạt.
3	Tỷ lệ giá trị thiếu từng đặc trưng	**Phát hiện lỗi:** ba đặc trưng thời gian thiếu 100% ở cặp 2 do lệch định dạng trường ngày (Mục 2.2.3). Sau khi sửa, tỷ lệ thiếu của cả 20 đặc trưng trùng khớp giữa hai cặp.
4	Dịch chuyển phân bố đặc trưng (PSI)	PSI cao nhất 0,048 (lãi chưa thu ngoại bảng), mọi đặc trưng khác dưới 0,04 — đều thấp hơn ngưỡng cảnh báo thông lệ 0,1. Đạt.
5	AUC đơn biến của từng đặc trưng	Ở cặp 1, lãi phải thu nội bảng đạt 0,620 và dư nợ 0,579; ở cặp 2 hai biến này chỉ còn 0,501 và 0,526. Tín hiệu biến mất ngay ở cấp đơn biến, không phải do mô hình.
6	Chuyển giao hai chiều	Huấn luyện cặp 1 chấm cặp 2: AP 0,0031. Huấn luyện cặp 2 chấm cặp 1: AP 0,0034. *Cả hai chiều* đều thất bại.
7	AP theo loại chuyển nhóm	Ở cặp 1, tín hiệu có ở cả nhóm 1→2 (AP 0,162; gấp 74 lần nền) lẫn các chuyển nhóm hiếm hơn (AP 0,058; gấp 116 lần nền). Ở cặp 2, cả hai đều ở mức nền.

Phép chuyển giao được thực hiện theo *cả hai chiều*: huấn luyện một lần trên toàn bộ một cặp rồi chấm điểm toàn bộ cặp còn lại mà không huấn luyện lại. Chiều thuận (cặp 1 $\rightarrow$ cặp 2) cho AP 0,0031 và chiều ngược (cặp 2 $\rightarrow$ cặp 1) cho AP 0,0034, đều xấp xỉ mức ngẫu nhiên. Phép kiểm tra thứ sáu vì vậy có giá trị chẩn đoán cao nhất. Nếu cặp 2 có lỗi xử lý làm hỏng đặc trưng, thì mô hình huấn luyện *trên* cặp 2 cũng phải kém trên cặp 1; nhưng nếu đặc trưng của cặp 2 bình thường mà chỉ nhãn của cặp

2 khó dự báo, thì mô hình huấn luyện trên cặp 2 vẫn có thể hoạt động khi chấm điểm cặp 1. Kết quả cho thấy chiều ngược lại cũng thất bại, kết hợp với phép kiểm tra thứ năm — tín hiệu biến mất ngay ở cấp từng biến đơn lẻ — cho thấy vấn đề nằm ở *quan hệ giữa đặc trưng tại T và sự kiện chuyển nhóm trong giai đoạn tháng 5–6*, không nằm ở dữ liệu hay quy trình.

Sau khi sửa lỗi phát hiện ở phép kiểm tra thứ ba, toàn bộ phân tích cặp 2 đã được chạy lại. Kết quả gần như không đổi (AP của XGBoost 0,0053 trước khi sửa và 0,0047 sau khi sửa), nên kết luận của mục này không bị ảnh hưởng bởi lỗi đó. Điều này trái ngược với bài toán năm lớp, nơi cùng lỗi đã làm sai lệch hoàn toàn kết luận về tổng quát hóa ngoài thời gian (Mục 3.2.2) — khác biệt là do ở bài toán năm lớp, mô hình được huấn luyện ở kỳ có đặc trưng đầy đủ rồi áp dụng sang kỳ thiếu, còn ở cặp 2 thì huấn luyện và đánh giá đều diễn ra trong cùng một kỳ thiếu.

Diễn giải

Bốn phép kiểm tra độc lập — đối chiếu cùng cấu hình, chọn mô hình tốt nhất riêng cho cặp 2, chuyển giao hai chiều, và phân tích theo loại chuyển nhóm — hội tụ về một kết luận: tín hiệu dự báo quan sát được ở cặp 1 không tái hiện ở cặp 2, và điều này không giải thích được bằng lỗi xử lý, khác biệt về số lượng hay cơ cấu sự kiện, hay dịch chuyển phân bố đặc trưng. Có ba cách giải thích khả dĩ, không loại trừ nhau:

1. *Tín hiệu của cặp 1 gắn với đặc điểm riêng của giai đoạn.* Chẳng hạn một nhóm khoản vay cùng đặc điểm dư nợ, lãi hoặc chi nhánh đồng loạt chuyển nhóm trong tháng 5/2026; mô hình học được đặc điểm đó, nhưng nó không lặp lại ở tháng 6.

2. *Dịch chuyển quan hệ giữa đặc trưng và nhãn* giữa hai giai đoạn, do yếu tố mùa vụ, thay đổi chính sách thu hồi nợ hoặc kinh tế không quan sát được trong 20 đặc trưng hiện có [31].

3. *Sự kiện quá thưa.* Với khoảng 260 sự kiện mỗi cặp, dù đã kiểm định chéo lặp, một cấu trúc tình cờ vẫn có thể được mô hình khai thác.

Với chỉ hai cặp kỳ và không có thông tin về nguyên nhân chuyển nhóm, luận văn chưa phân biệt được ba cách giải thích. Kết luận thận trọng là: khả năng dự báo chuyển nhóm nợ *có thể tồn tại* trong một số giai đoạn, nhưng *chưa được chứng minh là ổn định* theo thời gian.

3.5.5 Ý nghĩa và giới hạn ứng dụng

Kết quả cặp 1 cho thấy với dữ liệu nội bộ sẵn có, trong một số giai đoạn, danh sách 5% khoản vay có điểm cao nhất có thể chứa hơn một nửa số khoản vay sắp chuyển nhóm. Kết quả cặp 2 cho thấy chưa thể dựa vào một mô hình huấn luyện trên một giai đoạn để cảnh báo cho giai đoạn sau. Việc áp dụng còn bị giới hạn bởi: (i) mới có hai cặp kỳ với cửa sổ khoảng 30 ngày, chưa kiểm định các cửa sổ 3, 6, 12 tháng; (ii) mỗi cặp chỉ có khoảng 260 sự kiện; (iii) nhãn chỉ xác định cho khoản vay có mặt ở cả hai kỳ, nên chưa loại trừ sai lệch chọn mẫu (Mục 2.5.2); và (iv) tỷ lệ rà soát chưa gắn với chi phí bỏ sót và chi phí rà soát thực tế (Mục 4.4.2).

3.6 Thảo luận theo bốn câu hỏi nghiên cứu

CH1 — Chiến lược mất cân bằng và mô hình phù hợp. Các mô hình cây tổ hợp dẫn đầu ở cả hai bộ. LightGBM có Macro-F1 cao nhất trên tập kiểm định của cả hai bộ và giữ vị trí này ở kỳ báo cáo sau của bộ B, nhưng chênh lệch với XGBoost và Random Forest nhỏ hơn biên độ dao động theo siêu tham số của chính chúng, nên chưa đủ để kết luận về ưu thế thuật toán. SMOTE vừa phải tối đa hóa Macro-F1, trọng số lớp tối đa hóa Recall nhóm hiếm, và chiến lược kết hợp không vượt trội. Điều này phù hợp với kết luận của Lessmann và cộng sự [26] và Brown và Mues [7]: mô hình tổ hợp thường ở nhóm dẫn đầu, song không có thuật toán hay chiến lược tốt nhất tuyệt đối, và kết quả phụ thuộc tiêu chí đánh giá. So với các nghiên cứu trên dữ liệu Việt Nam, kết quả này nhất quán với Tran Khanh Quoc và cộng sự [49] và Nguyen Nhat, Ngo Duy [33], vốn cũng ghi nhận ưu thế của nhóm mô hình tổ hợp và của LightGBM nói riêng, dù hai

nghiên cứu đó đặt bài toán nhị phân còn luận văn đặt bài toán năm lớp có thứ tự.

CH2 — Số lượng đặc trưng và nhóm thông tin quan trọng. Thêm đặc trưng không luôn cải thiện kết quả: Top-7 của bộ A đạt 99,6% Macro-F1 của tập 13 biến, Top-8 của bộ B đạt xấp xỉ tập đầy đủ 20 biến và Top-11 còn nhỉnh hơn, và bổ sung `SEX`, `LOAIKH` không cải thiện bộ A. Hai khối thông tin dẫn đầu ở cả hai bộ là thời hạn/tuổi khoản vay và dư nợ — lãi, còn nhân khẩu học, sản phẩm và thủ tục hành chính đóng góp nhỏ. Tuy vậy, thí nghiệm loại biến cho thấy một phần lớn hiệu năng đến từ hai biến gắn với quy tắc phân loại (`DAYS_TO_MATURITY` và lãi ngoại bảng); "quan trọng" ở đây nghĩa là giúp mô hình *tái hiện* nhóm nợ hiện tại, chưa phải giúp *dự báo* rủi ro.

CH3 — Độ ổn định của kết luận giải thích. Trên cùng một mô hình, Gain và SHAP thống nhất cao về thứ hạng nhóm (Spearman 0,90 và 0,89), chỉ khác về mức độ tập trung. Giữa hai bộ dữ liệu, hai nhóm dẫn đầu trùng khớp và tương quan hạng là 0,80, nhưng với năm nhóm, mức này chưa có ý nghĩa thống kê ($p = 0,133$). Kết luận giải thích vì vậy đủ vững ở cấp "nhóm thông tin dẫn đầu", chưa đủ vững ở cấp tỷ trọng cụ thể hay khi khái quát sang dữ liệu khác, phù hợp với nhận định của Bussmann và cộng sự rằng giải thích bằng SHAP cần được kiểm tra độ ổn định [8].

CH4 — Dự báo chuyển nhóm nợ. Ở cặp 1, mô hình khai thác được tín hiệu rõ rệt (AP gấp 67 lần ngẫu nhiên, Recall@5% bằng 56,6%); ở cặp 2 độc lập, tín hiệu biến mất ở mọi mô hình, ở cả hai chiều chuyển giao, và ngay ở cấp từng biến đơn lẻ. Bảy phép kiểm tra chẩn đoán đã loại trừ các nguyên nhân kỹ thuật, trong đó một lỗi thật được phát hiện và sửa mà không làm đổi kết luận (Mục 3.5.4). Kết quả cặp 1 tương đồng với Khandani và cộng sự [24] về khả năng dự báo nợ quá hạn từ dữ liệu hành vi; kết quả cặp 2 nhấn mạnh rằng bằng chứng từ một giai đoạn là chưa đủ. Đây là phát hiện quan trọng nhất của luận văn đối với mục tiêu cảnh báo sớm: nó chỉ ra cả tiềm năng lẫn điều kiện cần — dữ liệu nhiều kỳ và kiểm định theo thời gian — trước khi xem xét triển khai.

Tóm tắt chương

Trên bài toán năm nhóm nợ, các mô hình cây tổ hợp đạt Macro-F1 khoảng 0,66–0,70 trên tập kiểm định nội bộ và giữ được mức này trên tập ngoài thời gian của bộ B; sai số hầu hết chỉ lệch một bậc, và điểm yếu ổn định duy nhất là nhóm 2. Hai khối thông tin thời hạn và dư nợ — lãi dẫn đầu nhất quán theo cả hai thước đo giải thích và trên cả hai bộ dữ liệu, song phần lớn hiệu năng dựa vào các biến gắn với quy tắc phân loại. Trên bài toán chuyển nhóm, tín hiệu dự báo rõ ở cặp 1 không lặp lại ở cặp 2, và bảy phép kiểm tra chẩn đoán đã loại trừ nguyên nhân kỹ thuật. Chương 4 tổng kết các kết luận, đóng góp, hạn chế và kiến nghị.

Chương 4

KẾT LUẬN VÀ KIẾN NGHỊ

Chương này rút ra kết luận theo bốn câu hỏi nghiên cứu, nêu đóng góp và hạn chế của luận văn, đề xuất kiến nghị đối với ngân hàng và hướng nghiên cứu tiếp theo. Số liệu chi tiết đã trình bày ở Chương 3 và chỉ được dẫn chiếu khi cần.

4.1 Kết luận theo bốn câu hỏi nghiên cứu

Luận văn đã xây dựng và đánh giá sáu mô hình học máy cho bài toán phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của một ngân hàng thương mại Việt Nam, và bài toán dự báo chuyển nhóm nợ trên hai cặp kỳ báo cáo. Các kết luận dưới đây chỉ có giá trị trong phạm vi dữ liệu và cấu hình đã khảo sát.

Về CH1. Các mô hình cây tổ hợp (LightGBM, XGBoost, Random Forest) phù hợp nhất với cả hai bộ dữ liệu, vượt rõ Logistic Regression và Decision Tree. LightGBM dẫn đầu Macro-F1 ở cả hai bộ (0,6484 và 0,6989) và giữ vị trí này cả trên tập ngoài thời gian của bộ B (0,7023). Tuy nhiên khác biệt giữa ba mô hình tổ hợp nhỏ hơn biên độ dao động do siêu tham số của chính chúng, nên chưa đủ để kết luận về ưu thế của một thuật toán. Tương tự, không có chiến lược mất cân bằng tốt nhất tuyệt đối: SMOTE vừa phải cho Macro-F1 cao nhất, trọng số lớp cho Recall nhóm hiếm cao nhất, còn kết hợp hai cách không mang lại lợi ích. Lựa chọn cần xuất phát từ mục tiêu

nghiệp vụ và chi phí sai số.

Về CH2. Nhiều đặc trưng hơn không đồng nghĩa với kết quả tốt hơn: tập 7–8 biến quan trọng nhất đạt hiệu năng tương đương tập đầy đủ ở cả hai bộ. Hai khối thông tin chi phối kết quả là thời hạn/tuổi khoản vay và dư nợ–lãi. Tuy nhiên, rà soát rò rỉ cho thấy một phần lớn hiệu năng phân loại năm nhóm dựa vào các biến hình thành cùng lúc với nhãn: bỏ biến lãi chưa thu ngoại bảng làm Macro-F1 của bộ B giảm từ 0,6989 xuống 0,4742, và bỏ `DAYS_TO_MATURITY` làm Macro-F1 của bộ A giảm từ 0,6442 xuống 0,5153. Vì vậy kết quả phân loại năm nhóm phản ánh khả năng *tái hiện* trạng thái nhóm nợ từ dữ liệu kế toán và thời hạn, không phải năng lực *dự báo* rủi ro; khi cần một mốc tham chiếu cho mục tiêu cảnh báo sớm, cấu hình thận trọng ở Mục 3.2.5 mới là con số phù hợp.

Về CH3. Kết luận về nhóm thông tin quan trọng ổn định khi đổi thước đo: trên cùng một mô hình, Gain và SHAP thống nhất cao về thứ hạng nhóm, chỉ khác về mức độ tập trung. Giữa hai bộ dữ liệu, hai nhóm dẫn đầu trùng khớp, nhưng với năm nhóm so sánh, mức tương quan hạng chưa đạt ý nghĩa thống kê. Kết quả giải thích vì vậy đủ tin cậy để định hướng ưu tiên dữ liệu ở cấp nhóm, chưa đủ để kết luận về tỷ trọng cụ thể hay khái quát sang dữ liệu khác.

Về CH4. Mô hình học máy *có thể* dự báo chuyển nhóm nợ trong tháng tiếp theo trong một số giai đoạn: ở cặp kỳ thứ nhất, rà soát 5% danh mục bắt được hơn một nửa số khoản vay sắp xấu đi. Nhưng khả năng này *chưa ổn định*: ở cặp kỳ thứ hai, với số lượng và cơ cấu sự kiện gần như giống hệt, mọi mô hình đều chỉ đạt mức ngẫu nhiên, kể cả khi chuyển giao mô hình từ cặp thứ nhất. Công cụ cảnh báo sớm dựa trên học máy vì vậy chưa sẵn sàng triển khai; điều kiện tiên quyết là dữ liệu nhiều kỳ để kiểm định độ ổn định.

4.2 Đóng góp của nghiên cứu

4.2.1 Đóng góp về phương pháp

Thứ nhất, luận văn xây dựng quy trình thực nghiệm thống nhất cho hai bộ dữ liệu có cấu trúc khác nhau, trong đó kiểm soát rò rỉ được thực hiện theo ba lớp và lớp cuối — rà soát bằng thí nghiệm loại biến — phát hiện được những biến mà phép lọc theo tên trường hay IV đơn biến bỏ sót. Thứ hai, luận văn đánh giá bài toán năm nhóm nợ theo cả thứ tự (Ordinal MAE, ma trận nhầm lẫn) và theo thời gian (kỳ báo cáo sau), qua đó xác định được nhóm 2 là điểm yếu thực sự của mọi mô hình, còn sai số ở các nhóm rủi ro cao hầu hết chỉ lệch một bậc. Thứ ba, luận văn kiểm tra độ ổn định của kết quả giải thích bằng cách đối chiếu Gain và SHAP trên cùng mô hình và đối chiếu SHAP giữa hai bộ dữ liệu, kèm kiểm định ý nghĩa. Thứ tư, luận văn xây dựng bài toán dự báo chuyển nhóm từ các kỳ báo cáo liên tiếp, đánh giá trên hai cặp kỳ độc lập bằng kiểm định chéo lặp, kiểm định thống kê có hiệu chỉnh và kiểm định chuyển giao, thay vì báo cáo một cặp kỳ duy nhất.

4.2.2 Đóng góp thực tiễn

Kết quả cung cấp cho ngân hàng: (i) bằng chứng đối sánh sáu mô hình và bốn chiến lược mất cân bằng trên dữ liệu của chính ngân hàng, kèm hiệu năng theo từng nhóm nợ; (ii) nhận diện nhóm 2 (nợ cần chú ý) là điểm yếu nhất của mọi mô hình, phần lớn bị nhầm với nhóm 1; (iii) danh sách nhóm dữ liệu cần duy trì chất lượng (thời hạn, dư nợ, lãi) và các trường gần như không đóng góp; (iv) kết quả thăm dò về cảnh báo sớm theo tỷ lệ rà soát, cùng bằng chứng rằng kết quả này chưa ổn định — thông tin quan trọng để tránh đầu tư triển khai quá sớm.

4.3 Hạn chế của nghiên cứu

4.3.1 Dữ liệu và độ ổn định theo thời gian

Hạn chế cốt lõi là độ dài chuỗi thời gian. Bộ A chỉ có một thời điểm và không có ngày trích xuất chính xác; bộ B có ba kỳ liên tiếp, đủ để tạo hai cặp kỳ chuyển nhóm và một kỳ kiểm tra cho bài toán năm lớp. Với chuỗi ngắn như vậy, luận văn quan sát được hiện tượng tín hiệu dự báo chuyển nhóm không lặp lại giữa hai cặp kỳ (Mục 3.5.4) nhưng chưa phân biệt được nguyên nhân trong ba cách giải thích đã nêu. Ngoài ra, tập ngoài thời gian có 98% khoản vay trùng với kỳ huấn luyện, nên kết luận về độ ổn định của bài toán năm lớp chỉ áp dụng cho danh mục đang theo dõi, chưa đánh giá được khả năng tổng quát hóa sang khách hàng mới. Nhãn chuyển nhóm cũng chỉ xác định được cho khoản vay có mặt ở cả hai kỳ, nên chưa loại trừ sai lệch chọn mẫu do tất toán hoặc xóa nợ.

Chất lượng dữ liệu nguồn và rủi ro lỗi xử lý âm thầm. Quá trình rà soát phát hiện một lỗi xử lý có ảnh hưởng lớn tới kết luận: hai kỳ báo cáo 20260531 và 20260630 lưu trường ngày giải ngân và ngày kết thúc khế ước theo định dạng số thứ tự Excel, khác với định dạng `yyyymmdd` của kỳ 20260430, trong khi bộ phân tích cú pháp chỉ nhận dạng định dạng thứ hai (Mục 2.2.3). Hậu quả là ba trong hai mươi đặc trưng rỗng hoàn toàn ở mọi phân tích dùng hai kỳ sau, nhưng không phát sinh thông báo lỗi nào: các giá trị rỗng được bước điền khuyết thay bằng trung vị của tập huấn luyện, nên mô hình vẫn chạy và vẫn cho ra kết quả trông hợp lý.

Trước khi sửa, bảng đánh giá ngoài thời gian cho thấy Macro-F1 giảm 12,7–32,1% và Recall nhóm 5 giảm từ 0,906 xuống 0,258; luận văn đã suy ra từ đó rằng phép chia ngẫu nhiên trong cùng kỳ ước lượng lạc quan khả năng tổng quát hóa theo thời gian. Sau khi sửa, khoảng cách này gần như biến mất (Mục 3.2.2) và kết luận trên bị bác bỏ. Ngược lại, kết luận về bài toán chuyển nhóm không thay đổi sau khi sửa lỗi, nên vẫn giữ nguyên.

Hai bài học rút ra. Thứ nhất, với dữ liệu nhiều kỳ, tính nhất quán về *định dạng* giữa

các kỳ quan trọng ngang tính nhất quán về *danh mục cột*, nhưng khó phát hiện hơn nhiều vì danh mục cột lệch sẽ gây lỗi ngay còn định dạng lệch thì không. Thứ hai, mọi kết luận dạng "hiệu năng suy giảm theo thời gian" cần được kiểm tra bằng thống kê mô tả trên chính tập đánh giá — ở đây chỉ cần đối chiếu tỷ lệ giá trị thiếu của từng đặc trưng giữa hai kỳ là đủ phát hiện lỗi. Luận văn đã bổ sung phép kiểm tra này thành một bước bắt buộc trong quy trình (Mục 3.5.4) và kiến nghị ngân hàng áp dụng khi giám sát mô hình (Mục 4.4.3).

4.3.2 Thiết kế kiểm định và lựa chọn mô hình

Bảng so sánh chính của bài toán năm lớp dựa trên một phép chia 80/20; số đặc trưng k, siêu tham số và chiến lược mất cân bằng đều được chọn trên cùng tập kiểm định, nên các cấu hình "tốt nhất" mang tính khám phá và có thể lạc quan do thiên lệch lựa chọn. Luận văn chưa áp dụng kiểm định chéo lồng nhau và chưa đánh giá hiệu chỉnh xác suất. Kỳ 20260531 của bộ B đã được dùng để phân tích, nên đánh giá xác nhận cuối cùng cần một kỳ mới chưa tham gia phát triển mô hình. Với bài toán chuyển nhóm, độ lệch chuẩn qua các phần kiểm định không phải khoảng tin cậy của hiệu năng tương lai; kiểm định t hiệu chỉnh giảm nhưng không loại bỏ hoàn toàn vấn đề phụ thuộc giữa các phần.

4.3.3 Tiền xử lý và diễn giải kết quả

Về tiền xử lý, ba lựa chọn có thể cải thiện đã được kiểm chứng bằng thực nghiệm chứ không chỉ nêu ra (Mục 3.4.3): mã hóa biến định danh bằng One-Hot thay cho Label Encoding, xử lý mã chi nhánh như biến phân loại, và dùng SMOTE-NC thay cho SMOTE. Cả ba đều làm Macro-F1 thay đổi không quá 0,018 và không đổi thứ hạng mô hình, nên cấu hình chính được giữ nguyên; riêng One-Hot cải thiện rõ Logistic Regression và nên được dùng nếu mô hình tuyến tính được chọn triển khai. Lỗi điền khuyết ba biến cơ cấu nợ đã được sửa và toàn bộ kết quả bộ B chạy lại. Về diễn giải, các kết quả phân loại năm nhóm phụ thuộc đáng kể vào biến lãi ngoại bảng và số ngày đến

đáo hạn. Với biến lãi ngoại bảng, quan hệ với nhãn đã được truy về căn cứ pháp lý chứ không chỉ suy đoán từ số liệu: Điều 5 khoản 2 điểm a Thông tư số 16/2018/TT-BTC lấy chính kết quả phân loại nợ làm điều kiện để lãi phải thu được hạch toán vào thu nhập hay chuyển theo dõi ngoại bảng [9], nên biến này là hệ quả kế toán đồng thời với nhãn (Mục 2.3.1). Phần chưa xác minh được thu hẹp lại thành một chi tiết vận hành — thứ tự và độ trễ giữa bước làm mới trường kế toán và bước chạy phân loại nợ trong quy trình chốt số cuối kỳ — và chi tiết này chỉ ảnh hưởng tới việc dùng trường đó làm đầu vào cho mô hình chuyển nhóm tại thời điểm T. Với `DAYS_TO_MATURITY` thì không có căn cứ pháp lý tương ứng, nên kết luận vẫn dừng ở bằng chứng thực nghiệm. Cuối cùng, Gain và SHAP chỉ mô tả cách mô hình sử dụng dữ liệu, không chứng minh quan hệ nhân quả, và có thể chia sẻ đóng góp giữa các biến tương quan như hai biến kỳ hạn ($r > 0,94$ ở cả hai bộ) [28].

4.4 Kiến nghị đối với ngân hàng

4.4.1 Dữ liệu ảnh chụp theo thời gian và chất lượng trường dữ liệu

Lợi thế của luận văn là đã làm việc trực tiếp trên dữ liệu thật của ngân hàng, nên các kiến nghị dưới đây không dừng ở nguyên tắc chung mà gắn với những vấn đề cụ thể đã phát hiện trong quá trình xử lý (Bảng 4.1).

Bảng 4.1: Kiến nghị về dữ liệu, gắn với phát hiện cụ thể trong luận văn

Phát hiện trong luận văn	**Kiến nghị**
Hai kỳ 20260531 và 20260630 lưu trường ngày theo định dạng khác kỳ 20260430, gây lỗi xử lý âm thầm làm rỗng ba đặc trưng (Mục 4.3.1)	Cố định kiểu dữ liệu của từng trường trong quy trình trích xuất; thêm bước kiểm tra tự động kiểu dữ liệu và miền giá trị ở mỗi kỳ, không chỉ kiểm tra danh mục cột
36,84% bản ghi `OPEN_DATE` và 36,63% `NGAYDENHAN` của bộ A lưu sai định dạng ngày (Bảng P2.1)	Chuẩn hóa định dạng ngày ngay tại khâu kết xuất thay vì để khâu phân tích tự suy đoán; quy định một định dạng duy nhất cho toàn hệ thống

Phát hiện trong luận văn	**Kiến nghị**
Ba biến cơ cấu nợ thiếu 99,6–99,8%, trong đó giá trị thiếu mang nghĩa "chưa từng cơ cấu" chứ không phải "không có dữ liệu" (Mục 2.3.5)	Phân biệt rõ trong từ điển dữ liệu giữa giá trị thiếu do không phát sinh sự kiện và giá trị thiếu do lỗi ghi nhận; với loại thứ nhất nên ghi giá trị 0 thay vì để trống
Trường `Thời điểm truy đòi` trùng khớp 100% với `Ngày kết thúc khế ước`; cột `Số tiền đã thanh toán` bằng 0 ở toàn bộ bản ghi	Rà soát và loại bỏ các trường trùng lặp hoặc không được ghi nhận trong thực tế, vì chúng làm tăng chi phí xử lý mà không mang thông tin
1.649 khoản vay biến mất giữa hai kỳ, không phân biệt được tất toán, xóa nợ hay bán nợ (Mục 2.5.2)	Bổ sung trường lý do rời danh mục; đây là điều kiện để loại trừ sai lệch chọn mẫu trong mọi mô hình dự báo theo thời gian
Biến lãi ngoại bảng là hệ quả kế toán của phân loại nợ (Điều 5 Thông tư số 16/2018/TT-BTC), nhưng thứ tự hai bước khi chốt số cuối kỳ chưa rõ (Mục 2.3.1)	Xác nhận với bộ phận kế toán và công nghệ thông tin: trường lãi ngoại bảng được làm mới trước hay sau khi chương trình phân loại nợ chạy, độ trễ giữa hai bước, và ảnh chụp giao cho bộ phận phân tích lấy ở bước nào. Trên cơ sở đó đánh dấu trong từ điển dữ liệu mỗi trường là *sẵn có trước* hay *hệ quả của* phân loại nợ
Nhóm thời hạn và nhóm dư nợ–lãi dẫn đầu ổn định ở cả hai bộ và cả hai thước đo giải thích (Mục 3.3.3)	Ưu tiên duy trì chất lượng các trường ngày giải ngân, ngày kết thúc khế ước, dư nợ và lãi, thay vì mở rộng thu thập các trường nhân khẩu học hay thủ tục có đóng góp gần 0
Kết quả dự báo chuyển nhóm không lặp lại giữa hai cặp kỳ (Mục 3.5.4)	Lưu ảnh chụp danh mục hằng tháng với khóa khế ước và khóa khách hàng nhất quán, để dựng được nhãn chuyển nhóm cho nhiều giai đoạn và nhiều cửa sổ dự báo

4.4.2 Thiết kế ngưỡng cảnh báo theo chi phí

Kết quả Recall@k (Mục 3.5.2) cho thấy ngưỡng xác suất 0,5 không phù hợp với sự kiện hiếm: ở cặp 1, ngưỡng này chỉ bắt được 11% sự kiện, trong khi rà soát 5% danh mục bắt được 56,6%. Ngân hàng nên xác định ngưỡng theo năng lực rà soát và chi phí

sai lầm, chẳng hạn bằng cách chọn ngưỡng τ tối thiểu hóa

$$\mathscr{C}(\tau) = c_{\text{FN}}\, FN(\tau) + c_{\text{FP}}\, FP(\tau),$$

trong đó $FN(\tau)$ là số khoản vay chuyển nhóm bị bỏ sót, $FP(\tau)$ là số cảnh báo sai, c_{FN} là chi phí trung bình của một lần bỏ sót (dự phòng tăng thêm, tổn thất) và c_{FP} là chi phí rà soát một hồ sơ. Với Precision@5% chỉ khoảng 3%, bài toán chỉ có lợi khi chi phí bỏ sót lớn hơn nhiều chi phí rà soát — một điều kiện cần được lượng hóa bằng số liệu nội bộ.

4.4.3 Quản trị và giám sát mô hình

Mô hình chỉ nên được dùng làm công cụ hỗ trợ, có cán bộ có thẩm quyền kiểm tra và phê duyệt. Song song với phần thực nghiệm, luận văn có xây dựng một ứng dụng minh họa bằng Streamlit gồm các chức năng phân tích khám phá, huấn luyện và đối sánh mô hình, phân tích đặc trưng kèm giải thích SHAP, và dự báo hàng loạt từ tệp Excel hoặc CSV do người dùng tải lên. Ứng dụng dùng lại đúng các hàm tiền xử lý và huấn luyện của phần thực nghiệm nên không phát sinh nhánh xử lý riêng. Đây là công cụ minh họa quy trình, chưa phải sản phẩm triển khai: hệ thống lưu mô hình dưới dạng tệp `pickle`, chưa có phân quyền người dùng, chưa lưu vết yêu cầu dự báo, và chưa có cơ chế giám sát. Trước khi triển khai, ngân hàng cần lưu vết phiên bản dữ liệu, mã nguồn và mô hình; thiết lập ngưỡng cảnh báo khi hiệu năng suy giảm và lịch tái huấn luyện.

Kinh nghiệm từ Mục 4.3.1 cho thấy việc giám sát nên bắt đầu từ lớp dữ liệu chứ không phải lớp mô hình. Cụ thể, ở mỗi kỳ chấm điểm cần tự động kiểm tra và cảnh báo khi: (i) tỷ lệ giá trị thiếu của bất kỳ đặc trưng nào thay đổi bất thường so với kỳ huấn luyện — đây là phép kiểm tra rẻ nhất và đủ phát hiện lỗi định dạng đã nêu; (ii) chỉ số dịch chuyển phân bố của một đặc trưng vượt ngưỡng quy ước; và (iii) kiểu dữ liệu hoặc miền giá trị của một trường khác với kỳ trước. Chỉ khi ba kiểm tra này đạt thì các chỉ tiêu ở lớp mô hình (Macro-F1, Recall nhóm rủi ro, mức hiệu chỉnh xác suất)

mới có ý nghĩa để so sánh giữa các kỳ.

4.5 Hướng nghiên cứu tiếp theo

1. Thu thập thêm kỳ báo cáo để có nhiều cặp $(T, T+h)$, kiểm định độ ổn định của dự báo chuyển nhóm theo cửa sổ trượt và phân biệt ba cách giải thích đã nêu ở Mục 3.5.4.

2. Mở rộng cửa sổ dự báo lên 3, 6, 12 tháng và chia mẫu đồng thời theo thời gian và theo khách hàng.

3. Xây dựng lại bài toán năm lớp và bài toán chuyển nhóm chỉ với các trường đã xác minh là sẵn có trước khi phân loại nợ, để đo năng lực dự báo không bị rò rỉ.

4. Thử nghiệm mô hình có thứ tự và mô hình đa trạng thái cho ma trận chuyển nhóm [25], ước lượng trực tiếp xác suất $p_{ab}^{(h)} = P(G_{i,t+h} = b \mid G_{i,t} = a, \mathbf{X}_{i,t})$ thay vì phân loại độc lập.

5. Hiệu chỉnh xác suất, lựa chọn mô hình bằng kiểm định chéo lồng nhau, và thí nghiệm loại bỏ từng nhóm đặc trưng một cách hệ thống cho cả hai bài toán.

6. Mở rộng tổng quan và đối sánh với các nghiên cứu trong nước khi có dữ liệu hoặc kết quả công bố tương đương.

7. Phát triển ứng dụng minh họa thành công cụ dùng được trong nghiệp vụ: bổ sung phân quyền, lưu vết yêu cầu dự báo và kết quả xử lý, kiểm thử với người dùng thật là cán bộ tín dụng, và đo các chỉ tiêu vận hành như thời gian xử lý một lô hồ sơ. Đây là hướng mở, chưa được đánh giá trong luận văn.

Tài liệu tham khảo

[1] Edward I. Altman. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609, 1968.

[2] Bart Baesens, Tony Van Gestel, Stijn Viaene, Maria Stepanova, Johan Suykens, and Jan Vanthienen. Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, 54(6):627–635, 2003.

[3] Flavio Barboza, Herbert Kimura, and Edward I. Altman. Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83:405–417, 2017.

[4] Basel Committee on Banking Supervision. Principles for the Management of Credit Risk, 2000.

[5] Basel Committee on Banking Supervision. Basel Framework: IRB Approach – Risk Components. `https://www.bis.org/basel_framework/chapter/CRE/32.htm`, 2024. Truy cập ngày 26/07/2026.

[6] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.

[7] Iain Brown and Christophe Mues. An experimental comparison of classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3):3446–3453, 2012.

[8] Niklas Bussmann, Paolo Giudici, Dimitri Marinelli, and Jochen Papenbrock.

Explainable machine learning in credit risk management. *Computational Economics*, 57(1):203–216, 2021.

[9] Bộ Tài chính. Thông tư số 16/2018/TT-BTC hướng dẫn một số điều về chế độ tài chính đối với tổ chức tín dụng, chi nhánh ngân hàng nước ngoài. `https://chinhphu.vn/default.aspx?pageid=27160&docid=193414`, 2018. Ban hành ngày 07/02/2018, hiệu lực từ ngày 26/03/2018; Điều 5 khoản 2 điểm a và khoản 7; truy cập ngày 27/09/2026.

[10] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.

[11] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.

[12] Chính phủ nước Cộng hòa xã hội chủ nghĩa Việt Nam. Nghị định số 86/2024/NĐ-CP quy định về mức trích, phương pháp trích lập dự phòng rủi ro, việc sử dụng dự phòng để xử lý rủi ro trong hoạt động của tổ chức tín dụng, chi nhánh ngân hàng nước ngoài và trường hợp tổ chức tín dụng phân bổ lãi phải thu phải thoái. `https://vanban.chinhphu.vn/?pageid=27160&docid=210640`, 2024. Ban hành ngày 11/07/2024; truy cập ngày 26/09/2026.

[13] Jonathan N. Crook, David B. Edelman, and Lyn C. Thomas. Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3):1447–1465, 2007.

[14] Xolani Dastile, Turgay Celik, and Moshe Potsane. Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing*, 91:106263, 2020.

[15] Thi Huyen Thanh Dinh and Stefanie Kleimeier. A credit scoring model for vietnam's retail banking market. *International Review of Financial Analysis*, 16(5):471–495, 2007.

[16] DMLC / XGBoost Contributors. XGBoost Documentation: Introduction to Boosted Trees. `https://xgboost.readthedocs.io/en/stable/tutorials/model.html`, 2026. Giấy phép Apache 2.0; truy cập ngày 15/08/2026.

[17] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.

[18] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.

[19] Björn Rafn Gunnarsson, Seppe vanden Broucke, Bart Baesens, María Óskarsdóttir, and Wilfried Lemahieu. Deep learning for credit scoring: Do or don't? *European Journal of Operational Research*, 295(1):292–305, 2021.

[20] David J. Hand and William E. Henley. Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A*, 160(3):523–541, 1997.

[21] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.

[22] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):15:1–15:21, 2012.

[23] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3149–3157, 2017.

[24] Amir E. Khandani, Adlar J. Kim, and Andrew W. Lo. Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance*, 34(11):2767–2787, 2010.

[25] David Lando and Torben M. Skødeberg. Analyzing rating transitions and rating drift with continuous observations. *Journal of Banking & Finance*, 26(2–3):423–444, 2002.

[26] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.

[27] Scott M. Lundberg, Gabriel Erion, Hugh Chen, Alex DeGrave, Jordan M. Prutkin, Bala Nair, Ronit Katz, Jonathan Himmelfarb, Nisha Bansal, and Su-In Lee. From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67, 2020.

[28] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774, 2017.

[29] Lundberg, Scott M. and SHAP Contributors. SHAP: A Game Theoretic Approach to Explain the Output of Any Machine Learning Model — Documentation. `https://shap.readthedocs.io/en/latest/`, 2026. Thư viện Python, giấy phép MIT; truy cập ngày 04/10/2026.

[30] Microsoft Corporation. LightGBM Documentation: Leaf-wise (Best-first) Tree Growth. `https://lightgbm.readthedocs.io/en/latest/Features.html`, 2026. Truy cập ngày 26/07/2026.

[31] Jose G. Moreno-Torres, Troy Raeder, Rocío Alaiz-Rodríguez, Nitesh V. Chawla,

and Francisco Herrera. A unifying view on dataset shift in classification. *Pattern Recognition*, 45(1):521–530, 2012.

[32] Claude Nadeau and Yoshua Bengio. Inference for the generalization error. *Machine Learning*, 52(3):239–281, 2003.

[33] Nhat Nguyen and Duy Ngo. Comparative analysis of boosting algorithms for predicting personal default. *Cogent Economics & Finance*, 13(1), 2025.

[34] Minh Nhật Nguyễn and Hoàng Khánh Duy Ngô. Dự báo khả năng vỡ nợ của doanh nghiệp nhỏ và vừa tại Việt Nam: Nghiên cứu trên các mô hình học máy. *Tạp chí Kinh tế – Luật và Ngân hàng*, 26(7):51–64, 2024.

[35] Tiến Hưng Nguyễn and Thị Huyền Trang Lê. Mô hình chấm điểm tín dụng dựa trên sự kết hợp giữa mô hình Cây quyết định, Logit, K láng giềng gần nhất và Mạng thần kinh nhân tạo. *Tạp chí Khoa học và Đào tạo Ngân hàng*, (193):46–54, 2018. ISSN 1859-011X.

[36] Đức Duy Nguyễn and Việt Dũng Nguyễn. Ứng dụng Machine Learning trong dự báo vỡ nợ doanh nghiệp nhỏ và vừa tại Việt Nam. *Nghiên cứu Kinh tế – Tài chính*, 2026. Chuyên trang Nghiên cứu Kinh tế – Tài chính Online, e-ISSN 3093-334X; đăng ngày 06/05/2026, truy cập ngày 03/10/2026.

[37] Ngân hàng Nhà nước Việt Nam. Thông tư số 11/2021/TT-NHNN quy định về phân loại tài sản có, mức trích, phương pháp trích lập dự phòng rủi ro và việc sử dụng dự phòng để xử lý rủi ro trong hoạt động của tổ chức tín dụng, chi nhánh ngân hàng nước ngoài, 2021. Ban hành ngày 30/07/2021, có hiệu lực từ ngày 01/10/2021.

[38] Ngân hàng Nhà nước Việt Nam. Thông tư số 31/2024/tt-nhnn quy định về phân loại tài sản có trong hoạt động của ngân hàng thương mại, tổ chức tín dụng phi ngân hàng, chi nhánh ngân hàng nước ngoài. `https://vbpl.vn/`

nganhangnhanuoc/Pages/vbpq-luocdo.aspx?ItemID=168260, 2024. Ban hành ngày 30/06/2024; truy cập ngày 07/09/2026.

[39] Ngân hàng Nhà nước Việt Nam. Thông tư số 37/2025/tt-nhnn sửa đổi, bổ sung một số điều của thông tư số 31/2024/tt-nhnn. https://vbpl.vn/nganhangnhanuoc/Pages/vbpq-toanvan.aspx?ItemID=183515, 2025. Quan hệ sửa đổi được đối chiếu trên Cơ sở dữ liệu quốc gia về văn bản pháp luật; truy cập ngày 07/09/2026.

[40] James A. Ohlson. Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131, 1980.

[41] Nam Pham Hai and Chi Le Ha Diem. Credit risk of Vietnamese commercial banks: Does capital structure matter? *Journal of Banking Regulation*, 25(3):272–283, 2023.

[42] Binh Pham Vo Ninh, Trung Do Thanh, and Duc Vo Hong. Financial distress and bankruptcy prediction: An appropriate model for listed firms in Vietnam. *Economic Systems*, 42(4):616–624, 2018.

[43] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.

[44] J. Ross Quinlan. Induction of decision trees. *Machine Learning*, 1(1):81–106, 1986.

[45] Takaya Saito and Marc Rehmsmeier. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3):e0118432, 2015.

[46] scikit-learn developers. average_precision_score. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html. Tài liệu chính thức; truy cập ngày 07/09/2026.

[47] Naeem Siddiqi. *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons, 2006.

[48] Lyn C. Thomas. A survey of credit and behavioural scoring: Forecasting financial risk of lending to consumers. *International Journal of Forecasting*, 16(2):149–172, 2000.

[49] Khanh Quoc Tran, Binh Van Duong, Linh Quang Tran, An Le-Hoai Tran, An Trong Nguyen, and Kiet Van Nguyen. Machine learning-based empirical investigation for credit scoring in Vietnam's banking. In *Advances and Trends in Artificial Intelligence (IEA/AIE 2021), Lecture Notes in Computer Science*, pages 564–574. Springer, 2021.

[50] Kim Long Tran, Hoang Anh Le, Thanh Hien Nguyen, and Duc Trung Nguyen. Explainable machine learning for financial distress prediction: Evidence from Vietnam. *Data*, 7(11):160, 2022.

[51] Van Trung Tran and Ngoc Anh Nguyen Vuong. Development of a credit scoring model using machine learning for commercial banks in Vietnam. *Advances and Applications in Statistics*, 92(1):107–120, 2024.

[52] Thị Thùy Dương Trương and Hải Trung Lê. Ứng dụng phương pháp học máy trong dự báo rủi ro phá sản của các doanh nghiệp Việt Nam. *Tạp chí Kinh tế và Phát triển*, (310):44–53, 2023.

[53] David West. Neural network credit scoring models. *Computers & Operations Research*, 27(11–12):1131–1152, 2000.

[54] XGBoost developers. Python api reference: Feature importance. `https://xgboost.readthedocs.io/en/stable/python/python_api.html`. Tài liệu chính thức; truy cập ngày 07/09/2026.

[55] Yufei Xia, Chuanzhe Liu, YuYing Li, and Nana Liu. A boosted decision tree approach using bayesian hyper-parameter optimization for credit scoring. *Expert Systems with Applications*, 78:225–241, 2017.

[56] Thanh Tú Đàm, Duy Mạnh Nguyễn, Thị Thùy Dung Phan, Thị Mỹ Huyền Trịnh, Lệ Ly Sằm, and Tuyết Nhi Vạn. Ứng dụng Trí tuệ nhân tạo giải thích được (XAI) trong tối ưu hóa hạn mức thẻ tín dụng: Bằng chứng từ một ngân hàng thương mại tại Việt Nam. *Tạp chí Kinh tế – Luật và Ngân hàng*, 28(11):83–96, 2025.

PHỤ LỤC

Phụ lục trình bày các bảng và hình chi tiết được dẫn chiếu từ Chương 2 và Chương 3.

P1 Công nghệ sử dụng

Bảng P1.1: Các công nghệ chính được sử dụng trong nghiên cứu

Công nghệ	**Vai trò**
Python 3.11	Tổ chức toàn bộ quy trình xử lý dữ liệu, huấn luyện, đánh giá và phục vụ mô hình.
pandas, NumPy	Đọc Excel, biến đổi bảng dữ liệu, xử lý giá trị thiếu, xây dựng đặc trưng.
scikit-learn	Logistic Regression, Decision Tree, Random Forest, tiền xử lý, chia mẫu, chỉ tiêu đánh giá.
imbalanced-learn	SMOTE và các phương pháp lấy mẫu khác.
XGBoost, LightGBM, CatBoost	Ba họ mô hình boosting dựa trên cây quyết định.
SHAP, SciPy	Giải thích mô hình; kiểm định thống kê (Spearman, kiểm định t, Wilcoxon).
Matplotlib, Plotly, Streamlit	Biểu đồ và giao diện phân tích, huấn luyện, dự báo minh họa.
OpenPyXL, Pickle	Đọc/ghi Excel và lưu mô hình đã huấn luyện.

P2 Chi tiết khảo sát và làm sạch dữ liệu

Bảng P2.1: Số bản ghi có trường ngày lưu dạng số thứ tự Excel — bộ dữ liệu A

Trường	Số bản ghi	Tỷ lệ (%)
OPEN_DATE	9.949	36,84
NGAYDENHAN	9.890	36,63

Các số thứ tự ngày được quy đổi theo mốc gốc của Excel (30/12/1899); sau làm sạch, hai trường không còn bản ghi thiếu hoặc lỗi phân tích cú pháp.

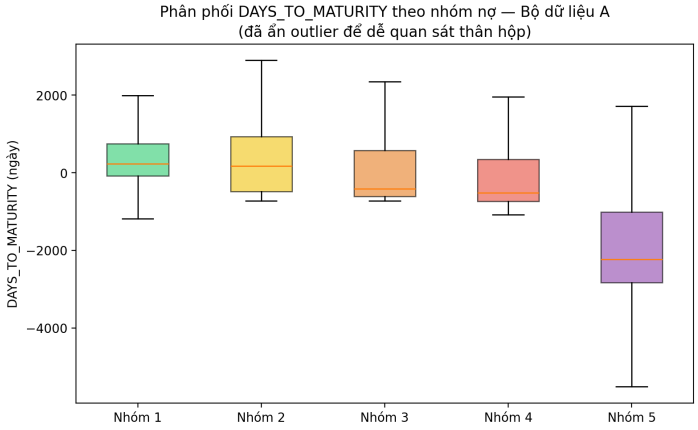
Bảng P2.2: Thống kê mô tả và tỷ lệ ngoại lệ IQR — biến số của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất	Ngoại lệ (%)
BASE_BAL	$4{,}28\times10^{8}$	$6{,}40\times10^{9}$	2	$3{,}50\times10^{7}$	$3{,}85\times10^{11}$	7,13
CURR_BAL	$3{,}56\times10^{8}$	$5{,}32\times10^{9}$	1	$4{,}40\times10^{7}$	$2{,}96\times10^{11}$	9,12
LAISUAT	0,0688	0,0681	0	0,1000	0,4000	0,01
ORGNBR	58,34	35,95	3	59	138	0,00
PARENTORGNBR	42,53	34,29	3	34	138	0,00
LOAN_TENURE_DAYS	2.292,5	2.452,0	0	1.461	18.292	10,20
DAYS_TO_MATURITY	672,7	2.397,7	−5.513	96	16.798	23,08
UTIL_RATE	2,4561	3,2557	2×10^{-8}	0,9429	10,0000	17,21

Biến phân loại của bộ A: MJACCTTYPCD có 3 nhóm (CNS 82,51%, MTG 9,26%, CML 8,23%); CURRMIACCTTYPCD có 31 nhóm; MUCDICHVAY có 79 nhóm, năm mục đích phổ biến nhất chiếm 83,06%.

Bảng P2.3: Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A

Biến 1	Biến 2	r
LOAN_TENURE_DAYS	DAYS_TO_MATURITY	0,942
BASE_BAL	CURR_BAL	0,923
ORGNBR	PARENTORGNBR	0,738
LAISUAT	LOAN_TENURE_DAYS	0,352
LAISUAT	UTIL_RATE	$-0,327$

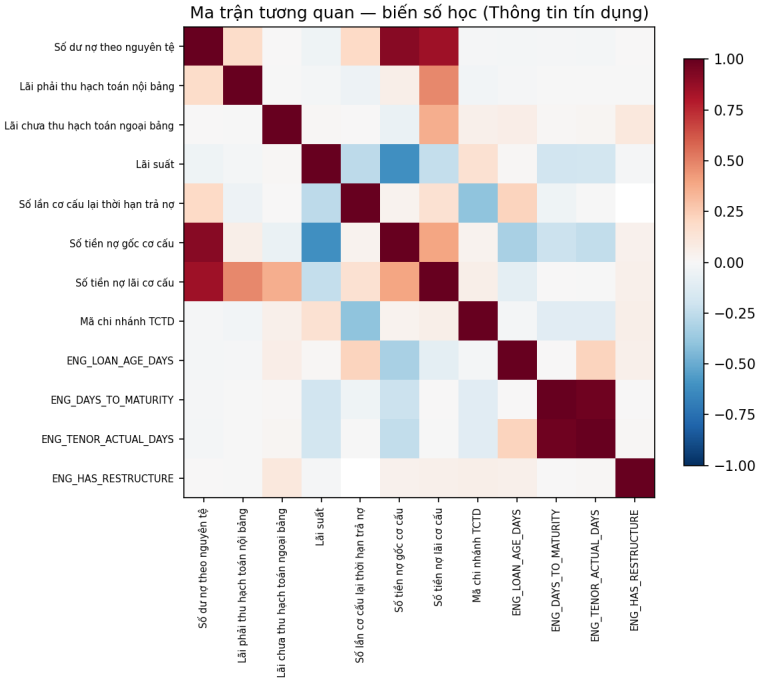


Hình P2.1: Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A

Bảng P2.4: Thống kê mô tả, tỷ lệ thiếu và ngoại lệ IQR — biến số của bộ dữ liệu B (kỳ 20260430)

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Thiếu (%)	Ngoại lệ (%)
Số dư nợ theo nguyên tệ	5.092,31	121.908,73	122,00	0,00	12,07
Lãi phải thu hạch toán nội bảng	41,26	1.328,05	1,00	0,00	14,43
Lãi chưa thu hạch toán ngoại bảng	16,06	283,84	0,00	0,00	6,35
Lãi suất	11,29	4,14	10,00	0,00	0,00
Số lần cơ cấu lại thời hạn trả nợ*	1,69	0,98	1,00	99,60	7,94
Số tiền nợ gốc cơ cấu*	5.439,41	15.091,54	341,50	99,72	15,36
Số tiền nợ lãi cơ cấu*	469,66	764,14	216,00	99,82	12,71
ENG_LOAN_AGE_DAYS	602,82	632,71	395	0,00	3,05
ENG_DAYS_TO_MATURITY	1.667,40	2.778,31	711	0,00	11,51
ENG_TENOR_ACTUAL_DAYS	2.270,22	2.850,29	1.461	0,00	12,45
ENG_HAS_RESTRUCTURE	0,004	0,063	0	0,00	0,40

* *Thống kê tính trên phần quan sát được, tức chỉ trên các khế ước đã từng được cơ cấu lại. Chính ba dòng này cho thấy vì sao phép điền trung vị là sai về nghiệp vụ: trung vị 1,00 lần, 341,50 và 216,00 là đặc trưng của nhóm đã cơ cấu, không phải của 99,6% khế ước chưa từng cơ cấu (Mục 2.3.5).* Phương thức cho vay *(biến phân loại) thiếu 0,05%.*



Hình P2.2: Ma trận tương quan giữa 12 biến số (8 biến gốc và 4 biến tạo thêm) — bộ dữ liệu B

P3 Information Value đầy đủ

Bảng P3.1: Information Value của 13 biến — bộ dữ liệu A

Biến	IV	Mức
DAYS_TO_MATURITY	4,5541	Nghi ngờ ($>1,0$)
CURRMIACCTTYPCD	1,9921	Nghi ngờ ($>1,0$)
LOAN_TENURE_DAYS	1,9410	Nghi ngờ ($>1,0$)
MUCDICHVAY	1,4141	Nghi ngờ ($>1,0$)
UTIL_RATE	1,3334	Nghi ngờ ($>1,0$)
MJACCTTYPCD	0,9695	Rất mạnh
LAISUAT	0,7851	Rất mạnh
BASE_BAL	0,5356	Rất mạnh
PARENTORGNBR	0,3201	Mạnh
CURR_BAL	0,2585	Trung bình
ORGNBR	0,1820	Trung bình
SEX	0,0081	Vô dụng
LOAIKH	0,0000	Vô dụng

Bảng P3.2: Information Value của 20 đặc trưng — bộ dữ liệu B

Biến	IV	Mức
ENG_LOAN_AGE_DAYS	1,1170	Nghi ngờ ($>1,0$)
Lãi phải thu hạch toán nội bảng	0,5420	Rất mạnh
ENG_TENOR_ACTUAL_DAYS	0,3793	Mạnh
Mô tả mục đích sử dụng tiền vay	0,3611	Mạnh
Lãi suất	0,3130	Mạnh
ENG_DAYS_TO_MATURITY	0,2549	Trung bình
Số dư nợ theo nguyên tệ	0,1892	Trung bình
Phương thức cho vay	0,0732	Yếu
Số tiền nợ gốc cơ cấu	0,0626	Yếu
Số lần cơ cấu lại thời hạn trả nợ	0,0620	Yếu
Mục đích sử dụng tiền vay phân theo ngành kinh tế	0,0620	Yếu
Mã chi nhánh TCTD	0,0415	Yếu
Số tiền nợ lãi cơ cấu	0,0320	Yếu
Mã thời hạn cấp tín dụng	0,0107	Vô dụng
Mã tiền tệ	0,0039	Vô dụng
ENG_HAS_RESTRUCTURE	0,0000	Vô dụng
Hình thức cấp tín dụng	0,0000	Vô dụng
Lãi chưa thu hạch toán ngoại bảng	0,0000	Vô dụng
Nguồn cấp tín dụng	0,0000	Vô dụng
Hoạt động cấp tín dụng bằng phương tiện điện tử	0,0000	Vô dụng

P4 Ví dụ hồ sơ trước và sau xử lý

Bảng P4.1: Ba hồ sơ của bộ A trước và sau xử lý

Biến	Hồ sơ #5944	Hồ sơ #7333	Hồ sơ #12595
Giá trị thô			
BASE_BAL	201.000.000	5.000.000	300.000.000
CURR_BAL	77.050.000	9.184.112	180.000.000
LAISUAT	0,1173	0,0000	0,1200
UTIL_RATE	0,3833	1,8368	0,6000
CURRMIACCTTYPCD	TH01	VS01	TH01
Sau chuẩn hóa z-score và mã hóa (học trên tập huấn luyện)			
BASE_BAL	$-0,0334$	$-0,0651$	$-0,0173$
CURR_BAL	$-0,0501$	$-0,0628$	$-0,0310$
LAISUAT	0,7095	$-1,0111$	0,7491
UTIL_RATE	$-0,6374$	$-0,1923$	$-0,5710$
CURRMIACCTTYPCD	12	22	12

Hồ sơ #7333 có tỷ lệ sử dụng dư nợ 1,8368, cao hơn hai hồ sơ còn lại, nhưng z-score âm vì trung bình toàn mẫu của biến này xấp xỉ 2,46: z-score chỉ có ý nghĩa tương đối trong phân phối lệch.

Bảng P4.2: Ba hồ sơ của bộ B có giá trị thiếu, trước và sau xử lý

Biến	Hồ sơ #22771	Hồ sơ #26934	Hồ sơ #26961
Giá trị thô			
Số dư nợ theo nguyên tệ	338	13.700	8.840
Lãi suất	16,50	16,95	21,00
Phương thức cho vay	*thiếu*	*thiếu*	*thiếu*
Sau xử lý			
Số dư nợ theo nguyên tệ (z-score)	$-0,0390$	0,0706	0,0307
Lãi suất (z-score)	1,2578	1,3667	2,3438
Phương thức cho vay (điền mode)	11	11	11

Dư nợ của hồ sơ #26934 lớn gấp hơn 40 lần hồ sơ #22771 nhưng z-score chỉ chênh khoảng 0,11, do độ lệch chuẩn toàn mẫu (121.908,73) lớn hơn nhiều trung bình (5.092,31).

P5 Không gian tìm kiếm siêu tham số

Bảng P5.1: Không gian tìm kiếm siêu tham số — bộ dữ liệu A (65 cấu hình)

Mô hình	Tham số và giá trị thử	Số cấu hình
Decision Tree	max_depth$\in \{5, 10, 15, 20\}$, min_samples_leaf$\in \{5, 10, 20\}$	12
Random Forest	n_estimators$\in \{100, 300, 500\}$, max_depth$\in \{10, 15, 20\}$, min_samples_leaf$\in \{5, 10\}$	18
XGBoost	max_depth$\in \{4, 6, 8\}$ $\times$ learning_rate$\in \{0{,}03; 0{,}05; 0{,}1\}$ tại n_estimators=400, cộng n_estimators$\in \{200, 600\}$ tại cấu hình mặc định	11
LightGBM	tương tự XGBoost	11
CatBoost	depth$\in \{4, 6, 8\}$ $\times$ learning_rate$\in \{0{,}03; 0{,}05; 0{,}1\}$ tại iterations=400	9
Logistic Regression	C$\in \{0{,}01;\ 0{,}1;\ 1{,}0;\ 10{,}0\}$	4

Bảng P5.2: Không gian tìm kiếm siêu tham số — bộ dữ liệu B (60 cấu hình)

Mô hình	Tham số và giá trị thử	Số cấu hình
Logistic Regression	C$\in$ {0,01; 0,1; 1,0; 10,0}	4
Decision Tree	max_depth$\in \{5,8,12,20\}$, min_samples_leaf$\in \{5,20\}$	8
Random Forest	n_estimators$\in \{200,400\}$, max_depth$\in \{10,20,\text{None}\}$, min_samples_leaf$\in \{5,15\}$	12
XGBoost	max_depth$\in \{3,6,9\} \times$ learning_rate$\in$ {0,03;0,1} $\times$ n_estimators$\in \{200,400\}$	12
LightGBM	tương tự XGBoost	12
CatBoost	depth$\in \{4,6,8\} \times$ learning_rate$\in$ {0,03;0,1} $\times$ iterations$\in$ $\{200,400\}$	12

P6 Kết quả bổ sung

Bảng P6.1: Ma trận nhầm lẫn của LightGBM và XGBoost — bộ A, tập kiểm định (hàng: nhóm thực; cột: nhóm dự báo)

Thực	LightGBM					XGBoost				
	1	2	3	4	5	1	2	3	4	5
1	**4.127**	33	13	11	10	**4.125**	31	16	13	9
2	177	**63**	11	3	3	182	**62**	9	3	1
3	56	8	**48**	8	1	57	9	**47**	7	1
4	55	8	4	**76**	14	60	4	5	**76**	12
5	29	5	1	29	**608**	33	3	2	31	**603**

Bảng P6.2: Gain và SHAP từng biến — XGBoost 11 biến, bộ dữ liệu A

Biến	Trung bình $\lvert\phi_j\rvert$	SHAP (%)	Gain (%)
DAYS_TO_MATURITY	0,8991	31,3	45,0
UTIL_RATE	0,3247	11,3	6,3
LOAN_TENURE_DAYS	0,2760	9,6	11,4
CURR_BAL	0,2535	8,8	4,1
LAISUAT	0,2527	8,8	6,4
PARENTORGNBR	0,2114	7,4	6,0
ORGNBR	0,2113	7,4	6,6
BASE_BAL	0,1914	6,7	5,9
CURRMIACCTTYPCD	0,1591	5,5	5,3
MUCDICHVAY	0,0669	2,3	2,3
MJACCTTYPCD	0,0221	0,8	0,7

Bảng P6.3: SHAP (trung bình $\lvert\phi_j\rvert$) và Gain từng biến — LightGBM 20 biến, bộ dữ liệu B

Biến	$\lvert\phi_j\rvert$	Gain (%)
Lãi chưa thu hạch toán ngoại bảng	1,0443	54,8
ENG_LOAN_AGE_DAYS	0,8622	8,4
Số dư nợ theo nguyên tệ	0,2508	9,3
ENG_DAYS_TO_MATURITY	0,2329	8,9
Lãi suất	0,2161	4,0
ENG_TENOR_ACTUAL_DAYS	0,2010	3,7
Mã chi nhánh TCTD	0,1842	4,3
Lãi phải thu hạch toán nội bảng	0,1599	5,1
Mục đích sử dụng tiền vay theo ngành kinh tế	0,0626	0,2
Mô tả mục đích sử dụng tiền vay	0,0447	0,4
Mã thời hạn cấp tín dụng	0,0364	0,5
Phương thức cho vay	0,0328	0,1
Tám biến còn lại	$\leq 0,010$	$\leq 0,1$

Bảng P6.4: Ảnh hưởng của việc sửa lỗi điền khuyết ba biến cơ cấu nợ — bộ dữ liệu B, Macro-F1

Mô hình	Tập kiểm định nội bộ		Tập ngoài thời gian	
	Trung vị (lỗi)	Điền 0 (đã sửa)	Trung vị (lỗi)	Điền 0 (đã sửa)
LightGBM	0,6930	0,6989	0,6960	0,7023
XGBoost	0,6846	0,6797	0,6833	0,6826
Random Forest	0,6587	0,6610	0,6623	0,6618

Bảng P6.5: Ma trận chuyển nhóm nợ của cặp 2 (20260531 $\rightarrow$ 20260630)

Nhóm tại T	Nhóm tại $T+h$				
	1	2	3	4	5
1	86.719	**206**	0	0	0
2	143	6.151	**8**	0	0
3	5	0	970	**12**	0
4	0	0	0	1.389	**32**
5	3	0	0	0	2.982

Bảng P6.6: Khoản vay bị loại do không có mặt trên tập ngoài thời gian, theo nhóm nợ tại T

Nhóm tại T	Cặp 1		Cặp 2	
	Bị loại	Tỷ lệ loại trong nhóm (%)	Bị loại	Tỷ lệ loại trong nhóm (%)
1	1.604	1,80	1.602	1,81
2	29	0,46	37	0,58
3	2	0,20	4	0,40
4	4	0,28	0	0,00
5	10	0,34	11	0,37
Tổng	1.649		1.654	