

ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

**ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN
DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI
Ở VIỆT NAM**

ĐÀM CÔNG DANH

danh.dc251317M@sis.hust.edu.vn

Chuyên ngành Toán Tin

Giảng viên hướng dẫn: TS. Lê Kim Thư Chữ ký của GVHD

TS. Lê Thị Thanh An

Bộ môn: Toán Tin

Viện: Toán ứng dụng và Tin học

HÀ NỘI - 2026

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

BẢN XÁC NHẬN CHỈNH SỬA LUẬN VĂN THẠC SĨ

Họ và tên tác giả luận văn: Đàm Công Danh.

Đề tài luận văn: Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam.

Chuyên ngành: Toán Tin.

Mã học viên: 20251317M

Tác giả, Người hướng dẫn khoa học và Hội đồng chấm luận văn xác nhận tác giả đã sửa chữa, bổ sung luận văn theo biên bản họp Hội đồng ngày ... với các nội dung sau.

Ngày tháng năm 2026

Giảng viên hướng dẫn

Tác giả luận văn

CHỦ TỊCH HỘI ĐỒNG

ĐỀ TÀI LUẬN VĂN

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

TS. Lê Kim Thư

Lời cảm ơn

Trước hết, em xin trân trọng cảm ơn Khoa Toán Tin đã tạo điều kiện thuận lợi và hỗ trợ em trong quá trình học tập, nghiên cứu tại chương trình thạc sĩ Toán Tin.

Em xin bày tỏ lòng biết ơn sâu sắc tới TS. Lê Kim Thư và TS. Lê Thị Thanh An, những người đã tận tình hướng dẫn, góp ý chuyên môn và chia sẻ kinh nghiệm trong suốt quá trình thực hiện luận văn. Em đồng thời xin chân thành cảm ơn quý thầy, cô và các học viên khóa 2026 của Khoa Toán Tin đã trao đổi, động viên và hỗ trợ em hoàn thành nghiên cứu này.

Mặc dù đã nỗ lực hoàn thiện, luận văn khó tránh khỏi những hạn chế nhất định. Em kính mong nhận được các ý kiến đóng góp của quý thầy, cô và bạn đọc để nghiên cứu được tiếp tục bổ sung và hoàn thiện.

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

LỜI MỞ ĐẦU

Lý do lựa chọn đề tài

Tín dụng là hoạt động cốt lõi của ngân hàng thương mại, đồng thời là nguồn phát sinh rủi ro có ảnh hưởng trực tiếp đến lợi nhuận, chất lượng tài sản và mức độ an toàn của ngân hàng. Vì vậy, đánh giá và xếp hạng tín dụng không chỉ phục vụ quyết định cấp tín dụng mà còn hỗ trợ giám sát khoản vay, phân loại nợ và nhận diện sớm dấu hiệu suy giảm chất lượng tín dụng.

Sự gia tăng về quy mô và mức độ đa dạng của dữ liệu ngân hàng đặt ra yêu cầu đổi mới phương pháp đánh giá rủi ro. Các phương pháp truyền thống có ưu điểm về tính minh bạch, nhưng có thể gặp hạn chế trước quan hệ phi tuyến, tương tác phức tạp và tình trạng mất cân bằng giữa các nhóm nợ. Trí tuệ nhân tạo và học máy vì vậy mở ra khả năng khai thác dữ liệu hiệu quả hơn, đồng thời hỗ trợ chuẩn hóa và tự động hóa một phần quy trình đánh giá.

Trong bối cảnh đó, đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*” được thực hiện nhằm đánh giá khả năng áp dụng các mô hình học máy vào phân loại năm nhóm nợ trên dữ liệu thực tế. Nghiên cứu đồng thời xem xét vai trò của các nhóm thông tin nghiệp vụ và khả năng rút gọn đặc trưng, qua đó tạo cơ sở cho việc phát triển hệ thống cảnh báo sớm rủi ro tín dụng.

Phần thực nghiệm tập trung vào hai nội dung. Thứ nhất, luận văn xây dựng và đánh giá ngoài mẫu các mô hình phân loại năm nhóm nợ trên hai bộ dữ liệu. Thứ hai, trên cơ sở hai kỳ báo cáo liên tiếp của bộ dữ liệu B, nghiên cứu xây dựng bài toán dự báo khả năng khoản vay chuyển sang nhóm nợ có mức rủi ro cao hơn trong tháng kế tiếp. Thiết kế này cho phép bước đầu đánh giá khả năng cảnh báo sớm, đồng thời làm rõ những giới hạn phát sinh từ số kỳ quan sát và mức độ mất cân bằng của sự kiện chuyển nhóm.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là việc ứng dụng các phương pháp thống kê và học máy trong phân loại mức độ rủi ro tín dụng. Trọng tâm của luận văn gồm so sánh hiệu năng mô hình, đánh giá ảnh hưởng của mất cân bằng lớp, phân tích vai trò của đặc trưng và đề xuất định hướng dữ liệu cho cảnh báo sớm.

Nghiên cứu sử dụng hai bộ dữ liệu tín dụng đã được ẩn danh từ một ngân hàng thương mại tại Việt Nam. Phạm vi dữ liệu bao gồm thông tin khách hàng, khoản vay và các yếu tố nghiệp vụ liên quan; tên ngân hàng và thông tin định danh trực tiếp không được công bố.

Các mô hình được đánh giá theo quy trình huấn luyện và kiểm định thống nhất trên từng bộ dữ liệu. Kết quả giữa hai bộ chỉ được đối chiếu về xu hướng do khác biệt về quy mô, cấu trúc biến và phân bố nhóm nợ. Các thông số dữ liệu, cấu hình tiền xử lý và thiết kế thực nghiệm được trình bày chi tiết tại Chương 3.

Động lực ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng

Việc ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng được thúc đẩy bởi ba yêu cầu chính: khai thác tốt hơn dữ liệu ngày càng đa dạng; nâng cao tính nhất quán và hiệu quả của quy trình đánh giá; và hỗ trợ nhận diện sớm các khoản vay có dấu hiệu suy giảm. Trong lĩnh vực ngân hàng, hiệu quả dự báo cần đi cùng khả năng giải thích, kiểm soát và giám sát để mô hình có thể được sử dụng như một công cụ hỗ trợ quyết định.

TÓM TẮT NỘI DUNG LUẬN VĂN

Luận văn nghiên cứu khả năng ứng dụng các mô hình học máy trong phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế đã được ẩn danh của một ngân hàng thương mại tại Việt Nam, đồng thời xây dựng một bài toán bổ sung dự báo khả năng chuyển nhóm nợ trong một tháng trên bộ dữ liệu có hai kỳ báo cáo liên tiếp, hướng tiếp cận nhằm khắc phục hạn chế hồi cứu của thông tin CIC. Quy trình nghiên cứu bao gồm làm sạch và tiền xử lý dữ liệu, xây dựng đặc trưng nghiệp vụ, kiểm soát nguy cơ rò rỉ thông tin, xử lý mất cân bằng lớp, huấn luyện và đối sánh sáu mô hình, đồng thời phân tích kết quả bằng mức độ quan trọng của đặc trưng và SHAP. Hiệu quả mô hình phân loại nhóm nợ được đánh giá bằng nhiều chỉ tiêu, trong đó Macro-F1 là chỉ tiêu trọng tâm; riêng bài toán chuyển nhóm nợ, do tỷ lệ sự kiện chỉ 0,268%, được đánh giá bằng PR-AUC và Recall theo top- $k\%$ hồ sơ rủi ro cao nhất.

Kết quả thực nghiệm cho thấy LightGBM đạt Macro-F1 cao nhất trên tập kiểm định của cả hai bộ dữ liệu, lần lượt bằng 0,6484 đối với bộ A và 0,6954 đối với bộ B. Tuy nhiên, trên tập kiểm tra độc lập theo thời gian của bộ B, Random Forest đạt kết quả cao nhất với Macro-F1 bằng 0,5142, trong khi hiệu quả của tất cả mô hình đều giảm từ 15–32% so với tập kiểm định cùng kỳ. Kết quả này cho thấy việc gia tăng số lượng đặc trưng không tất yếu cải thiện hiệu quả dự báo và nhấn mạnh yêu cầu kiểm định mô hình trên dữ liệu ngoài thời gian trước khi triển khai. Đối với bài toán dự báo chuyển nhóm nợ, XGBoost đạt PR-AUC 0,1806, gấp khoảng 67 lần tỷ lệ sự kiện nền; khi ưu tiên rà soát 5% hồ sơ có xác suất cao nhất, mô hình phát hiện được 56,6% số khoản vay thực sự chuyển sang nhóm cao hơn trong tháng tiếp theo. Đây là bằng chứng thực nghiệm ban đầu

cho khả năng cảnh báo sớm độc lập với CIC, dù mới dựa trên một cặp kỳ báo cáo duy nhất và cần được kiểm định thêm qua nhiều giai đoạn thời gian trước khi xem xét triển khai.

Ngoài phần mở đầu, kết luận, tài liệu tham khảo và phụ lục, nội dung luận văn được kết cấu thành năm chương như sau:

- **Chương 1: Giới thiệu tổng quan về đề tài.** Trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi, phương pháp và phạm vi nghiên cứu.
- **Chương 2: Cơ sở lý thuyết và các nghiên cứu liên quan.** Hệ thống hóa những khái niệm nền tảng về tín dụng, rủi ro tín dụng và xếp hạng tín dụng; giới thiệu các phương pháp học máy được sử dụng; đồng thời tổng quan các công trình có liên quan để xác định khoảng trống nghiên cứu.
- **Chương 3: Dữ liệu và phương pháp nghiên cứu.** Mô tả hai bộ dữ liệu, quy trình tiền xử lý và xây dựng đặc trưng, phương pháp xử lý mất cân bằng lớp, thiết kế thực nghiệm và hệ thống chỉ tiêu đánh giá; đồng thời trình bày phương pháp cho bài toán bổ sung dự báo chuyển nhóm nợ trong 1 tháng trên bộ B, bao gồm cách ghép hai kỳ báo cáo, lập luận không rò rỉ nhãn và thiết kế đánh giá cho sự kiện hiếm.
- **Chương 4: Kết quả thực nghiệm và thảo luận.** Trình bày kết quả trên từng bộ dữ liệu và thảo luận theo năm câu hỏi nghiên cứu về số lượng đặc trưng, nhóm thông tin có đóng góp lớn, khả năng rút gọn tập đặc trưng, định hướng ưu tiên dữ liệu và khả năng dự báo chuyển nhóm nợ; báo cáo kết quả đối sánh mô hình cho bài toán chuyển nhóm nợ kèm Recall@k và giải thích SHAP.

- **Chương 5: Kết luận và kiến nghị.** Tổng hợp các kết quả chủ yếu, làm rõ đóng góp và hạn chế của nghiên cứu, đề xuất một số kiến nghị đối với ngân hàng và định hướng nghiên cứu tiếp theo.

Học viên thực hiện

Đàm Công Danh

Mục lục

Lời mở đầu	4
Một số thuật ngữ viết tắt	13
Danh mục hình vẽ	15
Danh mục bảng	18
1 GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI	19
1.1 Bối cảnh và động lực nghiên cứu	19
1.2 Sự phát triển của các phương pháp đánh giá tín dụng	22
1.3 Phát biểu bài toán và phạm vi nghiên cứu	26
1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu	29
1.5 Tóm tắt chương	32
2 CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN	33
2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ	34
2.2 Từ đánh giá truyền thống đến các mô hình học máy	35
2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng	38
2.4 Hệ thống chỉ tiêu đánh giá mô hình	41

2.5	Nghiên cứu liên quan, khoảng trống và định hướng	42
2.6	Tóm tắt chương	44
3	DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	45
3.1	Định hướng và phạm vi thực nghiệm	45
3.2	Quy trình nghiên cứu tổng thể	47
3.3	Công nghệ và môi trường triển khai	48
3.4	Bước 1: Thu thập dữ liệu	50
3.5	Bước 2: EDA & làm sạch dữ liệu	51
3.6	Bước 3: Tiền xử lý & chọn biến	56
3.7	Bước 4: Chia dữ liệu & cân bằng lớp	80
3.8	Bước 5: Huấn luyện mô hình	83
3.9	Bài toán bổ sung: dự báo chuyển nhóm nợ trong 1 tháng (bộ B)	87
3.10	Tóm tắt chương	92
4	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	94
4.1	Nguyên tắc báo cáo kết quả	94
4.2	Thước đo đánh giá	96
4.3	Kết quả trên bộ dữ liệu A	98
4.4	Kết quả trên bộ dữ liệu B	100
4.5	Độ nhạy của siêu tham số	114
4.6	Đối chiếu bốn câu hỏi nghiên cứu	117
4.7	Kết quả bài toán dự báo chuyển nhóm nợ (bộ B)	119
4.8	Ý nghĩa đối với mô hình chuyển nhóm nợ	125
4.9	Tóm tắt chương	126

5 KẾT LUẬN VÀ KIẾN NGHỊ	128
5.1 Kết luận chung	128
5.2 Trả lời các câu hỏi nghiên cứu	130
5.3 Đóng góp của nghiên cứu	132
5.4 Hạn chế của nghiên cứu	134
5.5 Kiến nghị đối với ngân hàng	138
5.6 Hướng nghiên cứu tiếp theo	140
5.7 Kết luận chương	141
Tài liệu tham khảo	142

Một số thuật ngữ viết tắt

Viết tắt	Thuật ngữ tiếng Anh	Diễn giải tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ML	Machine Learning	Học máy
NHTM	Commercial Bank	Ngân hàng thương mại
NHNN	State Bank of Vietnam	Ngân hàng Nhà nước Việt Nam
XHTD	Credit Rating	Xếp hạng tín dụng
PD	Probability of Default	Xác suất khách hàng không thực hiện nghĩa vụ trả nợ
LGD	Loss Given Default	Tỷ lệ tổn thất khi xảy ra vỡ nợ
EAD	Exposure at Default	Giá trị dư nợ tại thời điểm vỡ nợ
IV	Information Value	Giá trị thông tin, dùng đánh giá sức phân biệt của đặc trưng
SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật sinh mẫu tổng hợp cho lớp thiểu số
SHAP	SHapley Additive exPlanations	Phương pháp giải thích đóng góp của đặc trưng dựa trên giá trị Shapley
ROC	Receiver Operating Characteristic	Đường cong biểu diễn quan hệ giữa tỷ lệ dương tính thật và dương tính giả
AUC	Area Under the Curve	Diện tích dưới đường cong đánh giá khả năng phân biệt
PR-AUC	Precision–Recall Area Under the Curve	Diện tích dưới đường cong Precision–Recall
F1	F1-score	Trung bình điều hòa của Precision và Recall
CV	Cross-validation	Kiểm định chéo
API	Application Programming Interface	Giao diện lập trình ứng dụng
RF	Random Forest	Thuật toán rừng ngẫu nhiên
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường gradient tối ưu
<i>LightGBM</i>	Light Gradient Boosting Machine	Thuật toán tăng cường gradient dạng cây tối ưu cho hiệu năng

Danh mục hình vẽ

2.1	Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng	35
2.2	Cơ chế cộng dồn các cây trong XGBoost	37
2.3	Minh họa hai chiến lược phát triển cây quyết định	38
2.4	Ví dụ biểu đồ waterfall minh họa nguyên lý phân rã dự báo theo giá trị SHAP	39
2.5	Ví dụ biểu đồ SHAP beeswarm trong phân tích mức độ tác động của đặc trưng	40
3.1	Pipeline nghiên cứu tổng thể — từ thu thập dữ liệu tới kết luận và ứng dụng	48
3.2	Phân phối Lãi suất theo nhóm nợ — bộ dữ liệu B (kỳ 20260430)	56
3.3	Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001) . . .	62
3.4	Ma trận tương quan Pearson giữa các biến số của bộ dữ liệu A	64
3.5	Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A	64
3.6	Top 15 biến (trong bề đặc trưng hợp lệ) có tỷ lệ thiếu cao nhất — bộ dữ liệu B	66
3.7	Ma trận tương quan giữa 12 biến số (8 biến gốc + 4 biến kỹ thuật) — bộ dữ liệu B	67
3.8	Các tầng số lượng biến trong nghiên cứu	74

4.1	Ma trận nhầm lẫn — XGBoost (none), tập kiểm định minh họa	121
4.2	Đường cong Precision-Recall — XGBoost (none)	122
4.3	Recall@k — XGBoost (none)	123
4.4	Phân tán PR-AUC qua 5×10 lần lặp kiểm định chéo — chiến lược none	124

Danh mục bảng

2.1	Các nhóm nợ trong nghiên cứu	34
3.1	Các công nghệ chính được sử dụng trong nghiên cứu	49
3.2	Phân bố năm nhóm nợ trong bộ dữ liệu A	50
3.3	Phân bố năm nhóm nợ trong dữ liệu (kỳ 20260430)	51
3.4	Số bản ghi có trường ngày lưu sai định dạng (số thứ tự Excel) — bộ dữ liệu A	52
3.5	Thống kê mô tả các biến số gốc của bộ dữ liệu A	53
3.6	Số quan sát ngoại lệ theo IQR — các biến gốc của bộ dữ liệu A	53
3.7	Các biến số gốc có tỷ lệ thiếu khác 0 — bộ dữ liệu B	54
3.8	Thống kê mô tả các biến số gốc — bộ dữ liệu B	55
3.9	Số quan sát ngoại lệ theo IQR — các biến gốc của bộ dữ liệu B	55
3.10	Các biến được xây dựng thêm từ dữ liệu ban đầu	58
3.11	Thống kê mô tả ba biến kỹ thuật của bộ dữ liệu A	60
3.12	Số quan sát ngoại lệ theo IQR — ba biến kỹ thuật của bộ dữ liệu A	60
3.13	Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A	63
3.14	Thống kê mô tả bốn biến kỹ thuật của bộ dữ liệu B	66
3.15	Information Value của 13 biến — bộ dữ liệu A	68
3.16	Phân bố 20 đặc trưng của bộ dữ liệu B theo mức Information Value	70

3.17	Information Value của 20 đặc trưng — bộ dữ liệu B	71
3.18	Ví dụ ba hồ sơ thực tế của bộ A trước và sau xử lý	77
3.19	Ví dụ ba hồ sơ thực tế của bộ B có giá trị thiếu, trước và sau xử lý	78
3.20	Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu A	85
3.21	Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu B	86
3.22	Ma trận chuyển nhóm nợ từ kỳ 20260430 (T) sang kỳ 20260507 (T+1 tháng)	88
3.23	Phân bổ nhóm nợ tại T của khoản vay bị loại so với khoản vay được giữ lại	90
4.1	Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng	98
4.2	Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A	98
4.3	Tỷ trọng mức độ quan trọng theo nhóm nghiệp vụ của bộ dữ liệu A	99
4.4	Kết quả ngoài mẫu của các mô hình trên 20 đặc trưng — tập kiểm định (20% kỳ 20260430)	101
4.5	Kết quả trên tập kiểm tra độc lập 20260507 (không tham gia huấn luyện/chọn mô hình)	102
4.6	Precision, Recall và F1 của LightGBM theo nhóm nợ — tập kiểm định vs. tập kiểm tra độc lập	103
4.7	Hiệu năng LightGBM theo số lượng đặc trưng Top- k	105
4.8	Tỷ trọng mức độ quan trọng của LightGBM theo nhóm nghiệp vụ (Gain)	107
4.9	Importance theo SHAP (trung bình $ \phi_j $) — bộ dữ liệu A	109

4.10 Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu A	110
4.11 Importance theo SHAP (trung bình $ \phi_j $) — bộ dữ liệu B . . .	111
4.12 Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu B	112
4.13 So sánh Macro-F1 giữa cấu hình mặc định và cấu hình tốt nhất trong lưới khảo sát	115
4.14 Độ nhảy Macro-F1 theo mô hình (trên toàn bộ lưới đã thử) . .	116
4.15 So sánh 6 mô hình trên bài toán dự báo chuyển nhóm nợ (chiến lược tốt nhất theo PR-AUC, 5×10 lần lặp)	120
4.16 Ba chiến lược mất cân bằng đối với XGBoost	120
4.17 Recall@k — XGBoost (none), tập kiểm định minh họa (19.794 hồ sơ, 53 sự kiện)	122
4.18 Importance theo SHAP (trung bình $ \phi_j $, lớp “xấu đi”) — mô hình dự báo chuyển nhóm nợ	124

Chương 1

GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI

Chương này trình bày những nội dung có tính định hướng cho toàn bộ luận văn. Trước hết, chương phân tích vai trò của hoạt động tín dụng, bản chất của rủi ro tín dụng và yêu cầu đổi mới phương pháp đánh giá trong bối cảnh chuyển đổi số của ngành ngân hàng. Tiếp theo, sự phát triển của các phương pháp đánh giá tín dụng, từ cách tiếp cận chuyên gia đến mô hình thống kê và học máy, được khái quát nhằm xác định vị trí của nghiên cứu trong hệ thống các công trình đã công bố. Trên cơ sở đó, chương xác lập bài toán phân loại năm nhóm nợ, phạm vi thực nghiệm, mục tiêu và các câu hỏi nghiên cứu. Những nội dung này tạo nền tảng để hệ thống hóa cơ sở lý thuyết, thiết kế phương pháp và phân tích kết quả trong các chương tiếp theo.

1.1 Bối cảnh và động lực nghiên cứu

1.1.1 Hoạt động tín dụng và rủi ro tín dụng

Hoạt động tín dụng có vai trò đặc biệt quan trọng đối với ngân hàng thương mại. Thông qua hoạt động cấp tín dụng, ngân hàng cung ứng vốn cho cá nhân và tổ chức, đồng thời tạo ra nguồn thu từ lãi và phí. Tuy nhiên, do nghĩa vụ trả nợ

được thực hiện trong tương lai, ngân hàng luôn phải đối mặt với sự không chắc chắn liên quan đến khả năng trả nợ của khách hàng.

Rủi ro tín dụng phát sinh khi khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính theo cam kết. Rủi ro này có thể bắt nguồn từ năng lực tài chính suy giảm, dòng tiền không ổn định, quản trị doanh nghiệp yếu, biến động thu nhập, thay đổi môi trường kinh doanh, biến động lãi suất, thông tin không đầy đủ hoặc hành vi gian lận. Hậu quả của rủi ro tín dụng có thể thể hiện qua nợ quá hạn, nợ xấu, chi phí dự phòng tăng, lợi nhuận giảm và mức độ an toàn vốn suy giảm.

Trong quản trị hiện đại, đánh giá tín dụng không nên chỉ được thực hiện một lần tại thời điểm phê duyệt. Ngân hàng cần cập nhật thông tin trong toàn bộ vòng đời khoản vay, theo dõi sự thay đổi của dư nợ, hành vi thanh toán, thời hạn, tình trạng cơ cấu lại và nhóm nợ. Điều này tạo ra nhu cầu xây dựng các mô hình có khả năng học từ dữ liệu lịch sử và hỗ trợ dự báo rủi ro theo thời gian.

1.1.2 Chuyển đổi số trong ngân hàng và vai trò của dữ liệu

Chuyển đổi số trong ngân hàng không chỉ là số hóa kênh giao dịch mà còn bao gồm tái cấu trúc quy trình nghiệp vụ, tự động hóa vận hành, xây dựng nền tảng dữ liệu và ứng dụng các mô hình phân tích trong quản trị.

Trong tín dụng, ngân hàng có thể khai thác nhiều nhóm dữ liệu như thông tin định danh, lịch sử hợp đồng, dư nợ, hạn mức, số ngày quá hạn, thời hạn khoản vay, mục đích vay, nhóm nợ, trạng thái cơ cấu lại và dữ liệu hành vi. Khi dữ liệu được làm sạch và quản trị phù hợp, các mô hình học máy có thể hỗ trợ nhận diện quy luật mà quy tắc thủ công khó phát hiện. Tuy nhiên, dữ liệu ngân hàng cũng

có những thách thức như giá trị thiếu, sai lệch nghiệp vụ, mất cân bằng lớp, thay đổi theo thời gian và nguy cơ rò rỉ thông tin.

1.1.3 Giới hạn của thông tin CIC và yêu cầu về công cụ cảnh báo sớm nội bộ

Trung tâm Thông tin tín dụng Quốc gia (CIC) tổng hợp và cung cấp thông tin nhóm nợ của khách hàng dựa trên báo cáo định kỳ của các tổ chức tín dụng. Tuy nhiên, thông tin CIC mang tính hồi cứu: nhóm nợ chỉ được ghi nhận sau khi khoản vay đã thực sự phát sinh quá hạn theo ngưỡng quy định, tức phản ánh trạng thái đã xảy ra chứ không dự báo trước. Vì vậy, việc xây dựng mô hình chỉ để phân loại lại nhóm nợ hiện tại của một khoản vay dựa trên chính các biến đã xác định nhóm nợ đó (điển hình là số ngày quá hạn hiện tại) có giá trị gia tăng hạn chế: kết quả gần như tái tạo quy tắc xếp nhóm đã có theo quy định, không tạo ra thông tin mới so với những gì CIC đã cho biết.

Bên cạnh tính hồi cứu, việc phụ thuộc vào CIC còn có một số hạn chế thực tiễn đối với hoạt động giám sát danh mục: dữ liệu được cập nhật theo chu kỳ báo cáo giữa các tổ chức tín dụng, tạo ra độ trễ giữa thời điểm rủi ro thực sự phát sinh và thời điểm được phản ánh trên hệ thống; mỗi lượt tra cứu phát sinh chi phí, khó áp dụng để rà soát định kỳ toàn bộ danh mục có quy mô hàng trăm nghìn khoản vay; và khách hàng vay lần đầu, chưa từng phát sinh quan hệ tín dụng, không có lịch sử CIC để tham chiếu.

Về căn cứ pháp lý, Thông tư số 11/2021/TT-NHNN quy định tổ chức tín dụng có thể được Ngân hàng Nhà nước chấp thuận áp dụng chính sách phân loại nợ theo phương pháp định tính, trên cơ sở hệ thống xếp hạng tín dụng nội bộ tự xây

dụng, thay vì chỉ phân loại định lượng theo số ngày quá hạn [21]. Quy định này cho thấy việc phát triển công cụ đánh giá rủi ro nội bộ, hoạt động độc lập với CIC và có khả năng nhận diện sớm dấu hiệu suy giảm chất lượng tín dụng, phù hợp với định hướng chính sách hiện hành, không chỉ là một lựa chọn kỹ thuật đơn thuần.

Nhu cầu thực sự có giá trị đối với ngân hàng, do đó, không nằm ở việc phân loại lại một nhóm nợ đã biết, mà ở việc dự báo khả năng một khoản vay sẽ chuyển sang nhóm rủi ro cao hơn trong thời gian tới, dựa trên thông tin đã có tại thời điểm đánh giá, qua đó cho phép can thiệp sớm (đôn đốc thu hồi, cơ cấu lại, siết hạn mức) trước khi CIC ghi nhận sự suy giảm. Luận văn xác lập đây là hướng tiếp cận bổ sung, được cụ thể hóa thành bài toán riêng ở Mục 1.3.1 trong phạm vi mà dữ liệu hiện có cho phép.

1.2 Sự phát triển của các phương pháp đánh giá tín dụng

1.2.1 Từ đánh giá chuyên gia đến mô hình thống kê

Phương pháp chuyên gia.

Phương pháp chuyên gia dựa trên kinh nghiệm của cán bộ tín dụng và các khung đánh giá như 5C.

Mô hình 5C là khung thẩm định tín dụng truyền thống, trong đó cán bộ tín dụng đánh giá khách hàng theo năm phương diện:

1. *Character* (tư cách và uy tín): mức độ thiện chí trả nợ, lịch sử thực hiện nghĩa vụ, tính trung thực và uy tín của khách hàng;
2. *Capacity* (năng lực trả nợ): khả năng tạo dòng tiền và thu nhập đủ để thực

hiện nghĩa vụ trả nợ đúng hạn;

3. *Capital* (năng lực tài chính): quy mô vốn tự có, mức độ lành mạnh tài chính và khả năng hấp thụ tổn thất của khách hàng;
4. *Collateral* (tài sản bảo đảm): giá trị, tính pháp lý, khả năng thanh khoản và mức độ bù đắp tổn thất của tài sản bảo đảm;
5. *Conditions* (điều kiện): mục đích và điều kiện khoản vay, đồng thời bao gồm bối cảnh ngành, thị trường và kinh tế có thể ảnh hưởng đến khả năng trả nợ.

5C không phải là một thuật toán thông kê tự động tạo ra xác suất vỡ nợ. Đây là khung tổ chức thông tin để chuyên gia tổng hợp nhận định hoặc xếp loại theo quy định nội bộ. Vì vậy, chất lượng kết quả phụ thuộc đáng kể vào dữ liệu được cung cấp, bộ tiêu chí đánh giá và kinh nghiệm của người thẩm định.

Thành tựu của phương pháp này là hệ thống hóa các yếu tố định tính và định lượng cần xem xét, cho phép sử dụng thông tin về uy tín, năng lực quản trị, triển vọng ngành và tài sản bảo đảm [14, 25].

Tuy nhiên, phương pháp này phụ thuộc vào kinh nghiệm cá nhân, khó bảo đảm tính nhất quán, khó mở rộng và khó lượng hóa mức đóng góp của từng yếu tố.

Altman và mô hình Z-score.

Altman [1] đã đưa phân tích phân biệt đa biến vào dự báo phá sản doanh nghiệp thông qua mô hình:

$$Z = 1.2X_1 + 1.4X_2 + 3.3X_3 + 0.6X_4 + 1.0X_5.$$

Trong đó Z là điểm tổng hợp; X_1 là vốn lưu động/tổng tài sản; X_2 là lợi nhuận

giữ lại/tổng tài sản; X_3 là lợi nhuận trước lãi vay và thuế/tổng tài sản; X_4 là giá trị thị trường vốn chủ sở hữu/giá trị sổ sách tổng nợ; và X_5 là doanh thu/tổng tài sản. Các hệ số 1,2; 1,4; 3,3; 0,6 và 1,0 được Altman ước lượng cho mẫu nghiên cứu gốc, không phải trọng số phổ quát cho mọi ngân hàng [1].

Thành tựu nổi bật của Altman là chứng minh rằng việc kết hợp nhiều tỷ số tài chính có thể dự báo khó khăn tài chính tốt hơn việc xem xét từng chỉ số riêng lẻ. Công trình này tạo nền tảng cho dự báo phá sản và xếp hạng doanh nghiệp.

Hạn chế của mô hình là phụ thuộc vào mẫu doanh nghiệp, ngành, chuẩn kế toán và giai đoạn nghiên cứu. Mô hình sử dụng chủ yếu dữ liệu kế toán, giả định quan hệ tuyến tính và không phù hợp trực tiếp với dữ liệu khách hàng cá nhân hoặc dữ liệu hành vi.

Ohlson và mô hình xác suất phá sản.

Ohlson [22] sử dụng hồi quy logistic để ước lượng xác suất phá sản. Đóng góp quan trọng là chuyển đầu ra từ một điểm phân biệt sang xác suất, tạo điều kiện thuận lợi cho lựa chọn ngưỡng và diễn giải rủi ro.

Hạn chế là quan hệ giữa log-odds và biến đầu vào được giả định tuyến tính, còn các tương tác và quan hệ phi tuyến phải được thiết kế thủ công.

1.2.2 Các nghiên cứu về đánh giá và dự báo rủi ro tín dụng

Hand và Henley.

Hand và Henley [14] hệ thống hóa các phương pháp phân loại thống kê trong đánh giá rủi ro tín dụng người vay. Hai tác giả làm rõ rằng không tồn tại một thuật toán duy nhất luôn tốt nhất trên mọi bộ dữ liệu; kết quả phụ thuộc vào chất lượng dữ liệu, lựa chọn biến, cách chia mẫu và tiêu chí đánh giá.

Hạn chế chủ yếu xuất phát từ bối cảnh thời điểm nghiên cứu: boosting, explainable AI, fairness và dữ liệu quy mô lớn chưa phát triển như hiện nay; phần lớn nội dung tập trung vào phân loại nhị phân.

Lyn C. Thomas.

Thomas [25] có đóng góp nổi bật trong việc hệ thống hóa các mô hình đánh giá hồ sơ tại thời điểm phê duyệt và các mô hình theo dõi hành vi sau giải ngân. Cách tiếp cận này mở rộng phạm vi đánh giá từ quyết định ban đầu sang quản lý khách hàng trong suốt vòng đời khoản vay.

Hạn chế của nhiều mô hình truyền thống được Thomas tổng hợp là tập trung vào dữ liệu có cấu trúc, phân loại tốt-xấu và giả định quan hệ tương đối ổn định theo thời gian.

Jonathan N. Crook.

Crook có nhiều đóng góp trong suy luận đối với hồ sơ bị từ chối, phân tích hành vi, phân tích sống còn và mô hình rủi ro động. Các nghiên cứu của ông làm rõ sai lệch chọn mẫu do dữ liệu huấn luyện thường chỉ gồm khách hàng đã được duyệt và mở rộng bài toán từ “có vỡ nợ hay không” sang “khi nào vỡ nợ” [10].

Hạn chế của phương pháp suy luận đối với hồ sơ bị từ chối là không thể quan sát trực tiếp nhãn thực của các hồ sơ này. Bên cạnh đó, mô hình phân tích sống còn phụ thuộc vào một số giả định thống kê có thể không phù hợp với mọi cấu trúc dữ liệu.

Baesens và Lessmann.

Baesens và Lessmann có đóng góp quan trọng trong các nghiên cứu đối chiếu, so sánh mô hình thống kê và học máy. Lessmann và cộng sự [17] cho thấy thứ hạng mô hình thay đổi tùy theo dữ liệu, thước đo và quy trình thực nghiệm; các

mô hình tổ hợp thường đạt kết quả cạnh tranh nhưng không phải lúc nào cũng tối ưu.

Hạn chế của nhiều nghiên cứu đối chiều, so sánh là sử dụng các bộ dữ liệu công khai có quy mô nhỏ, thời gian thu thập đã lâu, chủ yếu phục vụ phân loại nhị phân và chưa phản ánh đầy đủ đặc điểm của dữ liệu ngân hàng trong thực tế.

Nhận xét tổng hợp. Các công trình nền tảng đã chuyển đánh giá tín dụng từ chủ quan sang định lượng, cho phép ước lượng xác suất rủi ro và xây dựng quy trình kiểm định mô hình trong nhiều giai đoạn của vòng đời khoản vay. Tuy nhiên, các hạn chế chung còn lại gồm tập trung vào phân loại nhị phân, khó mô hình hóa quan hệ phi tuyến, phụ thuộc vào xây dựng biến thủ công, chưa xử lý đầy đủ mất cân bằng lớp, thứ tự nhóm nợ, sự thay đổi phân bố dữ liệu và khả năng giải thích.

1.3 Phát biểu bài toán và phạm vi nghiên cứu

Cho tập dữ liệu:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i, t_i)\}_{i=1}^N,$$

trong đó N là số quan sát; $\mathbf{x}_i \in \mathbb{R}^p$ là véc-tơ gồm p đặc trưng của quan sát i ; $y_i \in \{1, 2, 3, 4, 5\}$ là nhóm nợ; và t_i là thời điểm ghi nhận nếu trường thời gian khả dụng.

Mục tiêu là xây dựng:

$$f_{\theta} : \mathbf{x}_i \longrightarrow (p_{i1}, p_{i2}, p_{i3}, p_{i4}, p_{i5}),$$

trong đó f_{θ} là bộ phân loại được xác định bởi tập tham số θ ; p_{ik} là xác suất do

mô hình gán quan sát i vào nhóm k . với:

$$p_{ik} = P(Y_i = k \mid \mathbf{x}_i), \quad \sum_{k=1}^5 p_{ik} = 1.$$

Nhãn dự báo:

$$\hat{y}_i = \arg \max_{k \in \{1,2,3,4,5\}} p_{ik}.$$

Ký hiệu $\hat{y}_i$ là nhãn dự báo; toán tử $\arg \max$ chọn chỉ số nhóm có xác suất lớn nhất.

Do năm nhóm có quan hệ về mức độ rủi ro:

$$1 < 2 < 3 < 4 < 5,$$

bài toán cần vừa đạt hiệu quả tổng thể, vừa nhận diện nhóm rủi ro cao, giảm khoảng cách sai lệch, hạn chế đánh giá thấp rủi ro, duy trì khả năng tổng quát hóa theo thời gian và bảo đảm khả năng giải thích.

1.3.1 Bài toán bổ sung: dự báo chuyển nhóm nợ trong ngắn hạn

Bên cạnh bài toán phân loại nhóm nợ tại một thời điểm nêu trên, luận văn xác lập một bài toán bổ sung nhằm trực tiếp trả lời yêu cầu về công cụ cảnh báo sớm đã nêu ở Mục 1.1.3: dự báo khả năng một khoản vay chuyển sang nhóm rủi ro cao hơn trong một khoảng thời gian ngắn, sử dụng duy nhất thông tin sẵn có tại thời điểm đánh giá.

Gọi $G_{i,T} \in \{1, \dots, 5\}$ là nhóm nợ của khoản vay i tại thời điểm T và $G_{i,T+1}$ là nhóm nợ của cùng khoản vay đó tại thời điểm $T + 1$ tháng. Nhãn dự báo được xác định:

$$Y_i = \mathbb{I}(G_{i,T+1} > G_{i,T}),$$

trong đó $\mathbb{I}(\cdot)$ là hàm chỉ thị, nhận giá trị 1 nếu khoản vay chuyển sang nhóm nợ cao hơn tại $T + 1$ và 0 trong trường hợp còn lại (giữ nguyên hoặc cải thiện). Đặc trưng đầu vào $\mathbf{x}_{i,T}$ chỉ được lấy từ thông tin tại thời điểm T , không bao gồm bất kỳ thông tin nào phát sinh sau T ; đây là khác biệt căn bản so với việc dùng số ngày quá hạn hiện tại để phân loại lại nhóm nợ hiện tại, vốn chỉ tái tạo quy tắc xếp nhóm đã có (Mục 1.1.3) chứ không tạo ra giá trị dự báo.

Bài toán bổ sung này chỉ áp dụng được cho bộ dữ liệu B, do đây là bộ duy nhất có hai kỳ báo cáo liên tiếp của cùng một danh mục khoản vay (20260430 và 20260507, cách nhau một tháng), cho phép ghép cặp $(G_{i,T}, G_{i,T+1})$ theo từng khoản vay bằng khóa định danh khế ước. Bộ dữ liệu A chỉ phản ánh trạng thái tại một mốc thời gian duy nhất nên tiếp tục được sử dụng cho bài toán phân loại tại một thời điểm như đã trình bày, không hỗ trợ bài toán chuyển nhóm.

1.3.2 Đóng góp dự kiến của nghiên cứu

Trên cơ sở kế thừa các công trình trước, luận văn dự kiến đóng góp ở các khía cạnh sau:

1. chuyển từ nhị phân sang phân loại trực tiếp năm nhóm nợ;
2. xem xét thứ tự của nhãn bằng $|y_i - \hat{y}_i|$;
3. sử dụng hai bộ dữ liệu thực tế đã được ẩn danh của một ngân hàng thương mại tại Việt Nam để đối chiếu kết luận trên hai cấu trúc dữ liệu khác nhau;
4. xây dựng đặc trưng nghiệp vụ về thời hạn, mục đích vay, cơ cấu nợ và tính nhất quán;
5. xem mất cân bằng lớp là thành phần trung tâm;

6. đối chiếu, so sánh sáu mô hình học máy; trong đó năm mô hình được thực thi thành công trên bộ dữ liệu A và sáu mô hình được thực thi thành công trên bộ dữ liệu B;
7. kết hợp đánh giá hiệu quả dự báo với mức độ quan trọng của đặc trưng và SHAP;
8. lựa chọn mô hình theo hiệu quả, nhận diện rủi ro, sai lệch thứ tự và khả năng giải thích;
9. xây dựng và đánh giá bài toán bổ sung dự báo chuyển nhóm nợ trong một tháng trên bộ dữ liệu B, bằng cách ghép hai kỳ báo cáo liên tiếp theo khóa định danh khế ước, trực tiếp trả lời yêu cầu về công cụ cảnh báo sớm hoạt động độc lập với CIC đã nêu ở Mục 1.1.3.

Đóng góp của luận văn không tập trung vào việc đề xuất thuật toán mới, mà thể hiện ở cách thiết kế bài toán, tổ chức thực nghiệm và đánh giá mô hình phù hợp với đặc điểm của dữ liệu tín dụng thực tế tại ngân hàng được nghiên cứu.

1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu

1.4.1 Mục tiêu nghiên cứu

Mục tiêu tổng quát.

Xây dựng và đánh giá các mô hình học máy nhằm hỗ trợ phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam, đồng thời xác định cấu hình đặc trưng có giá trị cho định hướng cảnh báo sớm.

Mục tiêu cụ thể.

1. Hệ thống hóa lý thuyết và nghiên cứu liên quan.

2. Làm sạch và xây dựng đặc trưng từ dữ liệu thực tế.
3. Xây dựng Logistic Regression làm mô hình cơ sở.
4. So sánh với Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost.
5. Đánh giá ảnh hưởng của mất cân bằng lớp.
6. Phân tích tính thứ tự và mức độ nghiêm trọng của sai số.
7. Giải thích kết quả bằng các phương pháp phù hợp.
8. Xây dựng và đánh giá bài toán dự báo chuyển nhóm nợ trong một tháng trên bộ dữ liệu B (Mục 1.3.1).

1.4.2 Câu hỏi nghiên cứu

1. Việc gia tăng số lượng đặc trưng có luôn cải thiện hiệu quả phân loại nhóm nợ hay không?
2. Nhóm đặc trưng nghiệp vụ nào có đóng góp lớn nhất đối với kết quả phân loại nhóm nợ?
3. Có thể rút gọn tập đặc trưng đến mức nào mà vẫn duy trì hiệu quả dự báo ngoài mẫu?
4. Ngân hàng nên ưu tiên hoàn thiện và duy trì chất lượng đối với những nhóm thông tin nào để phục vụ mô hình phân loại nhóm nợ và định hướng cảnh báo sớm?
5. Mô hình học máy có thể dự báo khả năng một khoản vay chuyển sang nhóm nợ cao hơn trong một tháng tới hay không, chỉ dựa trên thông tin sẵn có tại

thời điểm đánh giá, khác với việc phân loại lại nhóm nợ hiện tại đã được CIC ghi nhận?

1.4.3 Phương pháp nghiên cứu

Luận văn kết hợp phương pháp nghiên cứu định tính trong tổng quan tài liệu với phương pháp định lượng trong xử lý dữ liệu, xây dựng mô hình và đánh giá thực nghiệm. Quy trình thực nghiệm được triển khai độc lập trên Data_credit_rating_VN.xlsx (bộ A) và dữ liệu Thông tin tín dụng (bộ B), bao gồm làm sạch dữ liệu, xây dựng đặc trưng, phân tích khám phá dữ liệu, chia mẫu ngẫu nhiên có phân tầng, xử lý mất cân bằng lớp, huấn luyện, đánh giá và giải thích mô hình. Riêng bộ B được đánh giá bổ sung trên một tập kiểm tra độc lập theo thời gian thuộc kỳ báo cáo kế tiếp. Do khác biệt về cấu trúc và phân bố dữ liệu, kết quả của hai bộ chỉ được đối chiếu về xu hướng, không được so sánh trực tiếp như các mẫu đồng nhất.

Riêng đối với bộ B, do có hai kỳ báo cáo liên tiếp của cùng một danh mục khoản vay, luận văn còn xây dựng bài toán bổ sung dự báo chuyển nhóm nợ trong một tháng (Mục 1.3.1) bằng cách ghép các khoản vay giữa hai kỳ theo khóa định danh khế ước. Quy trình xây dựng nhãn và tập đặc trưng cho bài toán này tách biệt hoàn toàn với quy trình phân loại tại một thời điểm, được trình bày chi tiết ở Chương 3.

Về khoa học, luận văn bổ sung bằng chứng thực nghiệm về phân loại năm nhóm nợ, kết hợp mất cân bằng và khả năng giải thích. Về thực tiễn, kết quả có thể hỗ trợ chuẩn hóa đánh giá, nhận diện khoản vay suy giảm và xây dựng cảnh báo sớm. Mô hình chỉ đóng vai trò hỗ trợ, không thay thế hoàn toàn quyết định

của cán bộ tín dụng.

1.5 Tóm tắt chương

Chương 1 đã trình bày bối cảnh và động lực nghiên cứu xuất phát từ vai trò của hoạt động tín dụng và rủi ro tín dụng trong ngân hàng thương mại; đồng thời phân tích giới hạn hồi cứu của thông tin CIC và căn cứ pháp lý cho yêu cầu về công cụ cảnh báo sớm nội bộ (Mục 1.1.3). Chương cũng khái quát sự phát triển của các phương pháp đánh giá tín dụng từ cách tiếp cận chuyên gia, mô hình thống kê đến các nghiên cứu học máy; xác lập bài toán phân loại năm nhóm nợ và bài toán bổ sung dự báo chuyển nhóm nợ trong ngắn hạn trên bộ dữ liệu B (Mục 1.3.1), cùng mục tiêu, câu hỏi và phương pháp nghiên cứu. Các đóng góp dự kiến và giới hạn của phạm vi thực nghiệm cũng được xác định nhằm bảo đảm rằng những kết luận của luận văn phù hợp với bằng chứng thu được.

Trên cơ sở đó, Chương 2 sẽ hệ thống hóa cơ sở lý thuyết về tín dụng, rủi ro và phân loại nhóm nợ, trình bày các mô hình học máy được sử dụng, những thách thức đặc thù của dữ liệu tín dụng, hệ thống chỉ tiêu đánh giá và tổng quan các nghiên cứu liên quan, làm nền tảng lý thuyết cho phần dữ liệu và phương pháp thực nghiệm ở Chương 3.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

Trong chương này, luận văn trình bày nền tảng lý thuyết cần thiết để làm rõ bối cảnh và nội dung của bài toán nghiên cứu. Trước hết, chương giới thiệu các khái niệm về tín dụng, rủi ro tín dụng, phân loại nhóm nợ và tổn thất kỳ vọng. Tiếp theo, chương phân tích sự chuyển dịch từ phương pháp đánh giá truyền thống sang các mô hình học máy, trong đó tập trung vào các thuật toán được sử dụng trong phần thực nghiệm. Những thách thức đặc thù của dữ liệu tín dụng, bao gồm mất cân bằng lớp, tính thứ tự của nhóm nợ, sự thay đổi phân bố theo thời gian và yêu cầu giải thích mô hình, cũng được thảo luận. Cuối cùng, chương trình bày hệ thống chỉ tiêu đánh giá, tổng quan các nghiên cứu liên quan và xác định khoảng trống mà luận văn hướng tới giải quyết. Đây là cơ sở lý luận để xây dựng quy trình nghiên cứu ở Chương 3.

2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ

2.1.1 Khái niệm tín dụng và rủi ro tín dụng

Tín dụng là quan hệ kinh tế trong đó bên cho vay chuyển giao quyền sử dụng một lượng giá trị cho bên đi vay trong một khoảng thời gian xác định, với nghĩa vụ hoàn trả theo các điều kiện đã thỏa thuận.

Rủi ro tín dụng là khả năng phát sinh tổn thất do khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính. Rủi ro chịu ảnh hưởng từ năng lực tài chính, đặc điểm khoản vay, lịch sử tín dụng, chính sách cấp tín dụng và điều kiện kinh tế.

2.1.2 Phân loại nhóm nợ

Bảng 2.1: Các nhóm nợ trong nghiên cứu

1	Nợ đủ tiêu chuẩn	Mức rủi ro thấp.
2	Nợ cần chú ý	Đã xuất hiện dấu hiệu cần theo dõi.
3	Nợ dưới tiêu chuẩn	Khả năng thu hồi suy giảm đáng kể.
4	Nợ nghi ngờ	Mức rủi ro cao.
5	Nợ có khả năng mất vốn	Mức rủi ro cao nhất.


2.1.3 Xếp hạng tín dụng và tổn thất kỳ vọng

Xếp hạng tín dụng là quá trình gán khách hàng hoặc khoản vay vào một hạng rủi ro dựa trên thông tin tài chính, đặc điểm khoản vay và lịch sử thực hiện nghĩa vụ. Trong phạm vi luận văn, năm nhóm nợ được xem là các mức rủi ro có thứ tự; mô hình được xây dựng để hỗ trợ nhận diện nhóm nợ tương ứng của từng quan sát.

Tổn thất kỳ vọng có thể biểu diễn:

$$EL = PD \times LGD \times EAD.$$

Trong đó EL là tổn thất kỳ vọng; PD là xác suất vỡ nợ trong kỳ đánh giá; LGD là tỷ lệ tổn thất khi vỡ nợ sau khi xét khả năng thu hồi; và EAD là dư nợ tại thời điểm vỡ nợ. Luận văn hiện tập trung vào phân loại trạng thái rủi ro, chưa trực tiếp ước lượng đủ ba cấu phần của EL [4].



Hình 2.1: Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng

Nguồn: Tác giả tổng hợp và vẽ lại từ Basel Committee on Banking Supervision [4].

2.2 Từ đánh giá truyền thống đến các mô hình học máy

2.2.1 Sự chuyển dịch từ phương pháp truyền thống sang học máy

Phương pháp chuyên gia có khả năng khai thác thông tin định tính nhưng chủ quan. Z-score của Altman có ý nghĩa nền tảng nhưng phụ thuộc dữ liệu kế toán và quan hệ tuyến tính. Logistic Regression dễ giải thích nhưng khó tự động nắm bắt tương tác phức tạp.

Học máy là nhánh của AI trong đó mô hình học quy luật từ dữ liệu. Bài toán của luận văn thuộc học có giám sát.

2.2.2 Mô hình tuyến tính và cây quyết định

Logistic Regression đa lớp.

$$P(Y = k | \mathbf{x}) = \frac{\exp(\beta_{k0} + \beta_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\beta_{j0} + \beta_j^T \mathbf{x})}.$$

Trong đó K là số lớp; $\mathbf{x}$ là véc-tơ đặc trưng; β_{k0} là hệ số chặn của lớp k ; β_k là véc-tơ hệ số của lớp k ; và mẫu số chuẩn hóa để tổng xác suất của K lớp bằng 1 [15].

Decision Tree.

Decision Tree chia không gian đặc trưng bằng các điều kiện dạng $x_j \leq s$. Mô hình dễ giải thích nhưng dễ overfitting.

Random Forest.

$$\hat{y} = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^B.$$


Trong đó B là số cây; $h_b(\mathbf{x})$ là dự báo lớp của cây thứ b tại hồ sơ $\mathbf{x}$; và mode chọn lớp xuất hiện nhiều nhất trong các dự báo cây [6].

2.2.3 Các mô hình boosting

XGBoost.

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t).$$

Trong đó t là vòng boosting; n là số quan sát huấn luyện; $l(\cdot)$ là hàm mất mát; $\hat{y}_i^{(t-1)}$ là dự báo tích lũy trước vòng t ; f_t là cây mới; và $\Omega(f_t)$ là số hạng phạt độ phức tạp của cây nhằm hạn chế quá khớp [9].



Hình 2.2: Cơ chế cộng dồn các cây trong XGBoost

Nguồn: Tài liệu chính thức của XGBoost [12], giấy phép Apache 2.0; minh họa cho cơ chế mô tả trong Chen và Guestrin [9]; truy cập ngày 15/08/2026.

Hình 2.2 thể hiện cách dự báo được cập nhật tuần tự. Mỗi cây mới $f_t(\mathbf{x})$ hiệu chỉnh phần sai số còn lại của tổ hợp trước đó bằng cách cộng thêm điểm số tại lá tương ứng của hồ sơ đang xét, có nhân hệ số học η ; XGBoost đồng thời đưa số hạng chính quy $\Omega(f_t)$ vào hàm mục tiêu để kiểm soát độ phức tạp.

LightGBM.

LightGBM tối ưu tốc độ và bộ nhớ bằng các kỹ thuật như Gradient-based One-Side Sampling và Exclusive Feature Bundling. Thuật toán phát triển cây theo lá tốt nhất, tức là tại mỗi bước ưu tiên tách lá tạo ra mức giảm hàm mất mát lớn nhất. Cách phát triển này có thể hội tụ nhanh nhưng cũng làm cây mất cân đối và dễ quá khớp khi dữ liệu nhỏ; vì vậy cần kiểm soát num_leaves, min_data_in_leaf và max_depth [16, 20].



Hình 2.3: Minh họa hai chiến lược phát triển cây quyết định

Nguồn: Tài liệu chính thức của *LightGBM* [20], giấy phép MIT; truy cập ngày 15/08/2026.

Hình 2.3 cho thấy sự khác biệt trực quan giữa hai chiến lược. Phương pháp theo tầng mở rộng đồng thời các nút ở cùng độ sâu và thường tạo ra cấu trúc tương đối cân đối. Ngược lại, *LightGBM* tiếp tục phân chia lá mang lại mức giảm hàm mất mát lớn nhất, vì vậy cây có thể phát triển không đối xứng. Cơ chế này góp phần nâng cao hiệu quả tối ưu, nhưng đồng thời đòi hỏi kiểm soát độ sâu và số lá để hạn chế hiện tượng quá khớp [16, 20].

CatBoost.

CatBoost có khả năng xử lý trực tiếp biến phân loại và sử dụng cơ chế *ordered boosting* để hạn chế rò rỉ thông tin trong quá trình huấn luyện [23].

2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng

2.3.1 Thách thức đối với hiệu năng dự báo

Mất cân bằng lớp.

$$\mathcal{L} = - \sum_{i=1}^N w_{y_i} \sum_{k=1}^K \mathbb{I}(y_i = k) \log p_{ik}.$$

Trong đó N là số quan sát; K là số lớp; w_{y_i} là trọng số gán cho lớp thật của quan sát i ; $\mathbb{I}(y_i = k)$ bằng 1 khi $y_i = k$ và bằng 0 trong trường hợp khác; p_{ik} là xác suất


dự báo lớp k . Trọng số lớn hơn cho lớp hiếm làm sai số của lớp đó có ảnh hưởng lớn hơn tới hàm mất mát.

Tính thứ tự. Năm nhóm nợ có thứ tự rủi ro từ thấp đến cao nên hai sai số lệch một bậc và lệch bốn bậc không có mức độ nghiêm trọng như nhau. Luận văn sử dụng Ordinal MAE ở phần chỉ tiêu đánh giá để lượng hóa số bậc sai lệch trung bình; chỉ tiêu này chưa được hàm `compute_metrics()` của mã nguồn báo cáo trong kết quả chính.

2.3.2 Khả năng giải thích và yêu cầu ứng dụng

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j.$$


Trong đó $f(\mathbf{x})$ là đầu ra mô hình cần giải thích; ϕ_0 là giá trị nền; p là số đặc trưng; và ϕ_j là đóng góp SHAP của đặc trưng j cho hồ sơ $\mathbf{x}$ [18].



Hình 2.4: Ví dụ biểu đồ waterfall minh họa nguyên lý phân rã dự báo theo giá trị SHAP

Nguồn: Tài liệu chính thức của SHAP [19], giấy phép MIT, dựa trên phương pháp của Lundberg và Lee [18]; truy cập ngày 15/08/2026.

Dự báo theo SHAP bắt đầu từ giá trị nền ϕ_0 (ký hiệu $E[f(X)]$ trong Hình 2.4), sau đó được điều chỉnh tăng hoặc giảm bởi đóng góp của từng đặc trưng cho tới khi đạt đầu ra $f(\mathbf{x})$ của hồ sơ đang xét. Dấu của ϕ_j cho biết chiều tác động đối với đầu ra đang được giải thích (thanh màu đỏ: đóng góp dương; thanh màu xanh: đóng góp âm), còn độ lớn tuyệt đối phản ánh cường độ đóng góp. Hình 2.4 chỉ minh họa nguyên lý phân rã từ tài liệu SHAP; các giá trị SHAP thực nghiệm của luận văn được tính riêng trên dữ liệu tín dụng ở Chương 4.



Hình 2.5: Ví dụ biểu đồ SHAP beeswarm trong phân tích mức độ tác động của đặc trưng

Nguồn: Kho tài liệu chính thức của SHAP [19], dựa trên phương pháp của Lundberg và Lee [18], giấy phép MIT; truy cập ngày 15/08/2026.

Trong biểu đồ beeswarm, mỗi điểm biểu thị một quan sát; vị trí trên trục hoành phản ánh giá trị SHAP, còn màu sắc thể hiện mức độ cao hoặc thấp của giá trị đặc trưng. Các đặc trưng được sắp xếp theo tổng độ lớn ảnh hưởng, qua đó cho phép xem xét đồng thời tầm quan trọng, chiều tác động và mức độ phân tán của ảnh hưởng trên toàn bộ tập dữ liệu. Hình 2.5 chỉ minh họa cách đọc biểu đồ từ tài liệu SHAP; các kết luận thực nghiệm của luận văn được rút ra từ dữ

liệu tín dụng và các biểu đồ được tạo riêng ở Chương 4.

2.4 Hệ thống chỉ tiêu đánh giá mô hình

2.4.1 Chỉ tiêu tổng thể và theo lớp

Accuracy.

$$Accuracy = \frac{\sum_{k=1}^K C_{kk}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}.$$

Trong đó C_{ij} là số quan sát có lớp thật i và lớp dự báo j ; tử số là tổng phần tử đường chéo; mẫu số là tổng số quan sát.

Precision, Recall và F1.

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k},$$

Trong đó TP_k là số dự báo đúng lớp k ; FP_k là số quan sát lớp khác bị dự báo nhầm thành k ; và FN_k là số quan sát lớp k bị dự báo sang lớp khác.

$$F1_k = 2 \frac{Precision_k \times Recall_k}{Precision_k + Recall_k}.$$

2.4.2 Chỉ tiêu cho dữ liệu mất cân bằng

Macro F1.

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Weighted F1.

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k.$$

Trong đó n_k là số quan sát thật của lớp k và N là tổng số quan sát. Khi một lớp chiếm tỷ trọng rất lớn, Weighted-F1 có thể che khuất hiệu năng thấp của lớp

hiếm.

Balanced Accuracy.

$$\text{Balanced Accuracy} = \frac{1}{K} \sum_{k=1}^K \text{Recall}_k.$$

Balanced Accuracy là trung bình Recall của K lớp, nên mỗi lớp có trọng số như nhau bất kể tần suất.

2.4.3 Chỉ tiêu phản ánh thứ tự nhóm nợ

Ordinal MAE.

$$\text{Ordinal MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

Ký hiệu có ý nghĩa như phần Tính thứ tự; giá trị càng nhỏ thì khoảng cách nhóm dự báo so với nhóm thật càng thấp.

2.5 Nghiên cứu liên quan, khoảng trống và định hướng

2.5.1 Kết quả chính của các nghiên cứu liên quan

Hand và Henley [14] hệ thống hóa các phương pháp phân loại thống kê; Thomas [25] mở rộng phạm vi từ đánh giá tại thời điểm phê duyệt sang theo dõi hành vi trong vòng đời khoản vay. Baesens và cộng sự [2] và Lessmann và cộng sự [17] cho thấy hiệu quả mô hình phụ thuộc vào dữ liệu, thước đo và quy trình đánh giá.

Brown và Mues [7] nhấn mạnh ảnh hưởng của mất cân bằng. Xia và cộng sự [26] cho thấy boosted tree có khả năng cải thiện dự báo. Barboza và cộng sự [3] ghi nhận kết quả cạnh tranh của các mô hình cây trong dự báo phá sản. Dastile

và cộng sự [11] chỉ ra các hạn chế phổ biến về dữ liệu nhỏ, mất cân bằng, thiếu chuẩn đánh giá và khả năng giải thích.

Tại Việt Nam, nghiên cứu thường tập trung vào đánh giá rủi ro tín dụng cá nhân, rủi ro doanh nghiệp và dự báo nợ xấu. Tuy nhiên, chưa có nhiều nghiên cứu công bố việc phân loại trực tiếp năm nhóm nợ trên dữ liệu thực tế, kết hợp so sánh nhiều mô hình, chia dữ liệu theo thời gian, đánh giá có xét thứ tự và phân tích khả năng giải thích.

2.5.2 Khoảng trống và định hướng của luận văn

1. Phần lớn nghiên cứu dùng mục tiêu nhị phân.
2. Tính thứ tự của năm nhóm nợ chưa được khai thác đầy đủ.
3. Dữ liệu thực tế tại ngân hàng Việt Nam ít được công bố.
4. Phương pháp chia mẫu ngẫu nhiên vẫn được sử dụng phổ biến hơn phương pháp chia mẫu theo thời gian.
5. Lớp rủi ro cao ít quan sát nhưng chưa được đánh giá đầy đủ.
6. Mô hình phức tạp thường thiếu khả năng giải thích.

Định hướng nghiên cứu. Luận văn xây dựng bài toán phân loại năm nhóm nợ, kiểm tra và hình thành các đặc trưng nghiệp vụ, sử dụng Logistic Regression làm mô hình cơ sở để đối chiếu với các mô hình cây và mô hình tăng cường, đồng thời xử lý mất cân bằng lớp, đánh giá bằng hệ thống chỉ tiêu đa lớp và giải thích mô hình thông qua mức độ quan trọng của đặc trưng cùng SHAP. Thực nghiệm hiện tại sử dụng phép chia ngẫu nhiên có phân tầng; phép chia theo thời gian là yêu cầu cần thiết trong giai đoạn xây dựng nhãn chuyển nhóm nợ.

2.6 Tóm tắt chương

Chương này đã trình bày cơ sở lý thuyết, thành tựu và hạn chế của các công trình nền tảng, các mô hình được sử dụng, các vấn đề đặc thù của dữ liệu tín dụng, hệ thống chỉ tiêu đánh giá, tổng quan nghiên cứu, khoảng trống và định hướng của luận văn.

Trên cơ sở lý thuyết và định hướng đã xác lập, Chương 3 sẽ trình bày cụ thể nguồn dữ liệu, quy trình xử lý, phân tích khám phá dữ liệu, xây dựng đặc trưng nghiệp vụ và phương pháp thực nghiệm được cài đặt trong mã nguồn trên hai bộ dữ liệu thực tế của luận văn.

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Chương này trình bày thiết kế nghiên cứu và cách thức triển khai thực nghiệm trên hai bộ dữ liệu tín dụng. Trước hết, chương xác định phạm vi của bài toán, mô tả nguồn dữ liệu và giới thiệu các công nghệ được sử dụng để xây dựng hệ thống. Tiếp theo, quy trình nghiên cứu được trình bày theo các bước từ phân tích khám phá, làm sạch và tiền xử lý dữ liệu đến xây dựng đặc trưng, kiểm soát rò rỉ thông tin và xử lý mất cân bằng lớp. Phần cuối của chương mô tả phương pháp chia mẫu, huấn luyện, hiệu chỉnh, triển khai và giám sát mô hình. Cách tổ chức này nhằm bảo đảm sự liên kết giữa cơ sở lý thuyết ở Chương 2 với quy trình tạo ra các kết quả thực nghiệm được phân tích ở Chương 4.

3.1 Định hướng và phạm vi thực nghiệm

Nguồn dữ liệu gồm hai bộ dữ liệu chứa thông tin đã được mã hóa về các khoản vay tại ngân hàng thương mại thuộc phạm vi nghiên cứu. Bộ dữ liệu A, `Data_credit_rating_VN.xlsx`, gồm 27.001 quan sát và 21 biến ban đầu;

biến đích NHOMNOMOI nhận giá trị từ 1 đến 5, tương ứng với năm nhóm nợ. Bộ dữ liệu B được trích xuất từ hai kỳ báo cáo liên tiếp của cùng một tổ chức tín dụng: Thông tin tín dụng 20260430.xlsx (100.617 hợp đồng và 41 cột thô, dùng để huấn luyện và kiểm định nội bộ) và Thông tin tín dụng 20260507.xlsx (100.274 hợp đồng và 33 cột thô, dùng làm *tập kiểm tra độc lập*, hoàn toàn tách biệt khỏi quá trình huấn luyện). Biến đích Nhóm nợ tự phân loại cũng nhận giá trị từ 1 đến 5. Do tập dữ liệu kỳ 20260507 chỉ chứa 33 trong tổng số 41 cột của kỳ 20260430, tập đặc trưng của bộ B chỉ được xây dựng từ các cột hiện diện ở cả hai kỳ. Ràng buộc này bảo đảm rằng mô hình được huấn luyện trên kỳ 20260430 có thể áp dụng cho kỳ 20260507 (Mục 3.6.4).

Phạm vi thực nghiệm của luận văn gồm hai bài toán có mục tiêu khác nhau. Bài toán thứ nhất phân loại trạng thái hiện tại của khoản vay vào một trong năm nhóm nợ trên hai bộ dữ liệu A và B. Bài toán thứ hai dự báo khả năng khoản vay chuyển sang nhóm nợ có mức rủi ro cao hơn trong tháng kế tiếp, được xây dựng bằng cách ghép hai kỳ báo cáo liên tiếp của bộ B. Bài toán thứ hai hướng trực tiếp tới mục tiêu hỗ trợ cảnh báo sớm, trong khi bài toán thứ nhất được sử dụng để đối sánh phương pháp mô hình hóa, đánh giá vai trò của các nhóm đặc trưng và kiểm tra khả năng tổng quát hóa ngoài mẫu.

Nếu có dữ liệu bảng theo thời gian, nhãn chuyển nhóm cần được định nghĩa:


$$Y_{i,t}^{(h)} = \begin{cases} 1, & G_{i,t+h} > G_{i,t}, \\ 0, & G_{i,t+h} \leq G_{i,t}, \end{cases}$$

trong đó i biểu thị khoản vay hoặc khách hàng; t là thời điểm quan sát; h là khoảng dự báo; $G_{i,t} \in \{1, 2, 3, 4, 5\}$ là nhóm nợ tại thời điểm t ; và $Y_{i,t}^{(h)} = 1$ biểu

thị sự chuyển dịch sang nhóm có mức rủi ro cao hơn trong khoảng h . Trong thực nghiệm trên bộ B, luận văn sử dụng hai kỳ báo cáo liên tiếp và xác định $h = 1$ tháng. Toàn bộ đặc trưng đầu vào được lấy tại thời điểm t , còn trạng thái tại $t + h$ chỉ được sử dụng để xây dựng nhãn, qua đó hạn chế nguy cơ rò rỉ thông tin từ tương lai.

3.2 Quy trình nghiên cứu tổng thể

Quy trình thực nghiệm được tổ chức thành bảy bước tuần tự, thể hiện tại Hình 3.1: (1) thu thập dữ liệu gốc; (2) phân tích khám phá và làm sạch dữ liệu; (3) tiền xử lý và lựa chọn biến, bao gồm tính WOE/IV, mã hóa và chuẩn hóa; (4) phân chia tập huấn luyện–kiểm định và xử lý mất cân bằng lớp; (5) huấn luyện mô hình; (6) đánh giá hiệu quả và giải thích kết quả; và (7) rút ra kết luận cùng khuyến nghị ứng dụng. Cấu trúc này góp phần hạn chế ảnh hưởng của dữ liệu kiểm định đối với quá trình huấn luyện và phù hợp với nguyên tắc đánh giá ngoài mẫu trong học máy [5, 17].



Hình 3.1: Pipeline nghiên cứu tổng thể — từ thu thập dữ liệu tới kết luận và ứng dụng

3.3 Công nghệ và môi trường triển khai

Toàn bộ quy trình thực nghiệm và ứng dụng minh họa được xây dựng bằng Python 3.11. Ngôn ngữ này được lựa chọn nhờ hệ sinh thái thư viện tương đối hoàn chỉnh cho xử lý dữ liệu, học máy, giải thích mô hình và phát triển ứng dụng

tương tác. Các công nghệ chính được tổng hợp tại Bảng 3.1. Danh sách này được xác định từ tệp `requirements.txt` và các mô-đun được sử dụng trực tiếp trong mã nguồn của nghiên cứu.

Bảng 3.1: Các công nghệ chính được sử dụng trong nghiên cứu

Công nghệ	Vai trò	Nội dung sử dụng trong luận văn
Python 3.11	Ngôn ngữ lập trình	Tổ chức quy trình xử lý dữ liệu, huấn luyện, đánh giá, lưu trữ và phục vụ mô hình.
pandas, NumPy	Xử lý và tính toán dữ liệu	Đọc dữ liệu Excel, biến đổi bảng dữ liệu, xử lý giá trị thiếu, xây dựng đặc trưng và thực hiện các phép tính ma trận.
scikit-learn	Học máy và đánh giá	Xây dựng Logistic Regression, Decision Tree, Random Forest, quy trình tiền xử lý, chia mẫu và tính các chỉ tiêu đánh giá.
imbalanced-learn	Xử lý mất cân bằng lớp	Xây dựng quy trình có SMOTE, BorderlineSMOTE, ADASYN, SMOTETomek và lấy mẫu dưới ngẫu nhiên.
XGBoost, LightGBM, CatBoost	Mô hình boosting	Huấn luyện và đối sánh ba họ mô hình tăng cường dựa trên cây quyết định.
SHAP	Giải thích mô hình	Ước lượng đóng góp của đặc trưng ở phạm vi toàn cục, theo nhóm nghiệp vụ và đối với từng quan sát.
Plotly, Matplotlib	Trực quan hóa	Biểu diễn phân bố dữ liệu, ma trận nhầm lẫn, đường cong hiệu năng và mức độ quan trọng của đặc trưng.
Streamlit	Ứng dụng minh họa	Xây dựng giao diện phân tích khám phá, huấn luyện, chấm điểm, dự báo và so sánh mô hình.
OpenPyXL, Pickle	Trao đổi và lưu trữ	Đọc–ghi tệp Excel và tuần tự hóa mô hình đã huấn luyện để tái sử dụng trong ứng dụng.

Về kiến trúc, lớp dữ liệu được quản lý bằng pandas và NumPy; lớp mô hình hóa được triển khai trên scikit-learn, imbalanced-learn cùng ba thư viện boosting; lớp giải thích và trực quan hóa sử dụng SHAP, Plotly và Matplotlib; trong khi

Streamlit đảm nhiệm lớp giao diện. Cách phân tách này giúp các bước tiền xử lý, huấn luyện và đánh giá được tái sử dụng thống nhất giữa các chức năng của ứng dụng.

3.4 Bước 1: Thu thập dữ liệu

Bước đầu tiên của quy trình gồm thu thập và kiểm tra hai tệp dữ liệu gốc, xác định biến đích và khảo sát sơ bộ phân bố nhóm nợ trước khi thực hiện các bước xử lý tiếp theo.

3.4.1 Bộ dữ liệu A: Data_credit_rating_VN

Bộ dữ liệu A gồm 27.001 hợp đồng vay và không có bản ghi thiếu dữ liệu tại biến đích NHOMNOMOI. Theo Bảng 3.2, nhóm 1 chiếm 77,65%, trong khi nhóm 3 chỉ chiếm 2,24%, cho thấy phân bố nhóm nợ có mức độ mất cân bằng đáng kể.

Bảng 3.2: Phân bố năm nhóm nợ trong bộ dữ liệu A

Nhóm	Toàn bộ	Tỷ lệ (%)	Huấn luyện	Kiểm định
1	20.965	77,65	16.771	4.194
2	1.287	4,77	1.030	257
3	604	2,24	483	121
4	784	2,90	627	157
5	3.361	12,45	2.689	672
Tổng	27.001	100,00	21.600	5.401

3.4.2 Bộ dữ liệu B: Thông tin tín dụng

Bộ dữ liệu B gồm 100.617 hợp đồng vay ở kỳ báo cáo 20260430 và không có bản ghi thiếu dữ liệu tại biến đích Nhóm nợ tự phân loại. Theo Bảng 3.3, tỷ lệ giữa nhóm có nhiều quan sát nhất (nhóm 1) và nhóm có ít quan sát nhất (nhóm

3) xấp xỉ 89 lần. Tuy nhiên, quy mô tuyệt đối của các nhóm hiếm, gồm 998 hồ sơ ở nhóm 3 và 1.446 hồ sơ ở nhóm 4, vẫn cho phép thực hiện đánh giá theo lớp.

Bảng 3.3: Phân bố năm nhóm nợ trong dữ liệu (kỳ 20260430)

Nhóm	Toàn bộ có nhân	Tỷ lệ (%)	Huấn luyện (80%)	Kiểm định (20%)
1	88.875	88,34	71.100	17.775
2	6.321	6,28	5.057	1.264
3	998	0,99	798	200
4	1.446	1,44	1.157	289
5	2.977	2,96	2.382	595
Tổng	100.617	100,00	80.493	20.124

Bộ dữ liệu B trong nghiên cứu này có **hai tầng đánh giá độc lập**: (i) tập kiểm định 20% tách từ chính kỳ 20260430 (Bảng 3.3), dùng để so sánh và chọn mô hình; và (ii) một **tập kiểm tra hoàn toàn tách biệt theo thời gian**, lấy từ kỳ báo cáo kế tiếp 20260507 (100.274 hợp đồng, phân bố lớp gần như tương đồng: nhóm 1 chiếm 88,29%, nhóm 3 chiếm 0,99%, nhóm 4 chiếm 1,42%), không tham gia bất kỳ bước huấn luyện hay lựa chọn mô hình nào. Thiết kế hai tầng này cho phép phân biệt rõ hiệu năng "trong phân phối" (tập kiểm định 20%) với hiệu năng "ngoài thời gian" (tập 20260507). Kết quả ở Chương 4 cho thấy khoảng cách giữa hai tầng này là đáng kể.

3.5 Bước 2: EDA & làm sạch dữ liệu

Hai bộ dữ liệu gốc được khảo sát bằng thống kê mô tả, tỷ lệ giá trị thiếu, phương pháp phát hiện ngoại lệ theo khoảng tứ phân vị (IQR) và ma trận tương quan Pearson giữa các biến số. Kết quả phân tích được sử dụng để nhận diện các biến cần chuẩn hóa, các cặp biến có nguy cơ đa cộng tuyến và các phân phối lệch cần lựa chọn phương pháp điều chỉnh phù hợp. Vì vậy, bước phân tích này vừa cung

cấp mô tả dữ liệu, vừa làm căn cứ cho các quyết định tiền xử lý tại Bước 3 (Mục 3.6.7).

3.5.1 Bộ dữ liệu A

Làm sạch định dạng trường ngày

Trước khi tính các thống kê mô tả, hai trường ngày OPEN_DATE và NGAYDENHAN được kiểm tra định dạng. Kết quả cho thấy phần lớn bản ghi lưu ngày dưới dạng chuỗi văn bản dd/mm/yyyy (ví dụ “28/12/2010”), nhưng một bộ phận đáng kể lại lưu dưới dạng số thứ tự ngày kiểu Excel (Excel serial date, ví dụ “40490” thay vì “08/11/2010”), phát sinh từ lỗi định dạng ô tính khi xuất dữ liệu nguồn. Bảng 3.4 thống kê số bản ghi bị ảnh hưởng.

Bảng 3.4: Số bản ghi có trường ngày lưu sai định dạng (số thứ tự Excel) — bộ dữ liệu A

Trường	Số bản ghi bị ảnh hưởng	Tỷ lệ (%)
OPEN_DATE	9.949	36,84
NGAYDENHAN	9.890	36,63

Bộ phân tích cú pháp ngày tháng của mã nguồn chỉ nhận diện các mẫu văn bản dd/mm/yyyy và yyyy-mm-dd[hh:mm:ss]; nếu áp dụng trực tiếp lên dữ liệu chưa được kiểm tra định dạng, toàn bộ các bản ghi lưu dưới dạng số thứ tự sẽ bị bỏ qua và chuyển thành giá trị thiếu (NaT) một cách âm thầm. Vì vậy, các số thứ tự ngày kiểu Excel trong hai trường này được quy đổi về đúng giá trị ngày tháng tương ứng theo mốc gốc chuẩn của Excel (30/12/1899), còn các bản ghi đã ở dạng văn bản dd/mm/yyyy được giữ nguyên. Sau bước làm sạch, cả OPEN_DATE và NGAYDENHAN không còn bản ghi nào bị thiếu hoặc phân tích cú pháp thất bại.

Bảng 3.5 trình bày thống kê mô tả năm biến số gốc của bộ A trên toàn bộ

27.001 quan sát.

Bảng 3.5: Thống kê mô tả các biến số gốc của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
BASE_BAL	$4,28 \times 10^8$	$6,40 \times 10^9$	2	$3,50 \times 10^7$	$3,85 \times 10^{11}$
CURR_BAL	$3,56 \times 10^8$	$5,32 \times 10^9$	1	$4,40 \times 10^7$	$2,96 \times 10^{11}$
LAISUAT	0,0688	0,0681	0	0,1000	0,4000
ORGNBR	58,34	35,95	3	59	138
PARENTORGNBR	42,53	34,29	3	34	138

Không biến số nào của bộ A có giá trị thiếu cho thấy các nhóm nghiệp vụ của bộ dữ liệu A gần như đầy đủ. Tuy nhiên, độ lệch chuẩn của BASE_BAL và CURR_BAL lớn hơn trung bình hàng chục lần, là dấu hiệu phân phối lệch phải mạnh, điển hình của biến tiền tệ trong dữ liệu ngân hàng.

Bảng 3.6 lượng hóa mức độ lệch bằng số quan sát nằm ngoài khoảng $[Q_1 - 1,5IQR, Q_3 + 1,5IQR]$ cho năm biến gốc này.

Bảng 3.6: Số quan sát ngoại lệ theo IQR — các biến gốc của bộ dữ liệu A

Biến	Số ngoại lệ	Tỷ lệ (%)
CURR_BAL	2.462	9,12
BASE_BAL	1.925	7,13
LAISUAT	4	0,01
ORGNBR	0	0,00
PARENTORGNBR	0	0,00

Trong năm biến gốc, CURR_BAL và BASE_BAL có tỷ lệ ngoại lệ cao nhất (9,12% và 7,13%), nhất quán với độ lệch phải mạnh đã nêu ở Bảng 3.5; LAISUAT, ORGNBR và PARENTORGNBR gần như không có ngoại lệ.

Về biến phân loại, MJACCTTYP_CD có 3 nhóm, trong đó nhóm CNS (vay tiêu dùng) chiếm 82,51%, MTG (thế chấp) 9,26% và CML (thương mại) 8,23%; đây là mức mất cân bằng nhưng không đến mức cực đoan như biến đích.

CURRMIACCTTYP CD có 31 nhóm và MUCDICHVAY có 79 nhóm mục đích vay, với 5 mục đích phổ biến nhất (thẻ Visa/JCB, sửa chữa nhà, tiêu dùng sinh hoạt, nông nghiệp, mua nhượng bất động sản) chiếm 83,06% tổng số hồ sơ. Cả hai biến có bản chất định danh (nominal) không có thứ tự tự nhiên, nhưng quy trình hiện đang dùng LabelEncoder gán số nguyên theo thứ tự xuất hiện. Như đã nêu ở mục tiền xử lý, đây là hạn chế kỹ thuật cần lưu ý khi diễn giải hệ số hoặc ranh giới quyết định của Logistic Regression và Decision Tree.

3.5.2 Bộ dữ liệu B

Khác với bộ dữ liệu A, bộ dữ liệu B có một số biến gốc thiếu dữ liệu gần như tuyệt đối, nhưng đại đa số biến còn lại không thiếu giá trị nào. Bảng 3.7 liệt kê các biến gốc có tỷ lệ thiếu khác 0.

Bảng 3.7: Các biến số gốc có tỷ lệ thiếu khác 0 — bộ dữ liệu B

Biến	Tỷ lệ thiếu (%)
Số tiền nợ lãi cơ cấu	99,82
Số tiền nợ gốc cơ cấu	99,72
Số lần cơ cấu lại thời hạn trả nợ	99,60
Phương thức cho vay	0,05

Ba biến về cơ cấu nợ thiếu gần như tuyệt đối (trên 99,5%) vì phần lớn hợp đồng chưa từng được cơ cấu lại thời hạn trả nợ. Trong trường hợp này, giá trị thiếu mang ý nghĩa nghiệp vụ (“không phát sinh sự kiện cơ cấu”), không nhất thiết là lỗi ghi nhận. Do đó, SimpleImputer(strategy="median") được áp dụng thống nhất cho các biến số thay vì loại bỏ ba biến trên. Với trung vị của phần dữ liệu quan sát được bằng 0 ở biến Số tiền nợ lãi cơ cấu (Bảng 3.8), phương pháp điền khuyết này hạn chế việc tạo ra các giá trị giả định quá khác

biệt so với thực tế, đồng thời vẫn bảo toàn tín hiệu của nhóm hồ sơ đã từng được cơ cấu nợ.

Bảng 3.8: Thống kê mô tả các biến số gốc — bộ dữ liệu B

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Thiếu (%)
Số dư nợ theo nguyên tệ	5.092,31	121.908,73	122,00	0,00
Lãi phải thu hạch toán nội bảng	41,26	1.328,05	1,00	0,00
Lãi chưa thu hạch toán ngoại bảng	16,06	283,84	0,00	0,00
Lãi suất	11,29	4,14	10,00	0,00
Số lần cơ cấu lại thời hạn trả nợ	1,69	0,98	1,00	99,60
Số tiền nợ gốc cơ cấu	5.439,41	15.091,54	341,50	99,72
Số tiền nợ lãi cơ cấu	469,66	764,14	216,00	99,82


Độ lệch chuẩn lớn hơn trung bình nhiều lần ở hầu hết các biến (điển hình Số dư nợ theo nguyên tệ, với độ lệch chuẩn gấp khoảng 24 lần trung bình) là bằng chứng phân phối lệch phải mạnh, tương tự hai biến BASE_BAL và CURR_BAL của bộ A. Tỷ lệ ngoại lệ theo IQR (Bảng 3.9) xác nhận điều này: Số tiền nợ gốc cơ cấu có tới 15,36% giá trị nằm ngoài khoảng IQR trong số các bản ghi quan sát được.

Bảng 3.9: Số quan sát ngoại lệ theo IQR — các biến gốc của bộ dữ liệu B

Biến	Số ngoại lệ	Tỷ lệ (%)
Số tiền nợ gốc cơ cấu	43	15,36
Lãi phải thu hạch toán nội bảng	14.520	14,43
Số tiền nợ lãi cơ cấu	23	12,71
Số dư nợ theo nguyên tệ	12.146	12,07
Số lần cơ cấu lại thời hạn trả nợ	32	7,94
Lãi chưa thu hạch toán ngoại bảng	6.388	6,35
Lãi suất	1	0,00
Mã chi nhánh TCTD	0	0,00

Trong tám biến số gốc, ba cặp có tương quan lớn nhất là Số dư nợ theo nguyên tệ với Số tiền nợ gốc cơ cấu ($r = 0,908$), Số dư nợ theo

nguyên tệ với Số tiền nợ lãi cơ cấu ($r = 0,850$), và Lãi suất với Số tiền nợ gốc cơ cấu ($r = -0,613$). Mặc dù các hệ số chưa vượt ngưỡng loại biến được lựa chọn, chúng cho thấy các biến thuộc nhóm Dư nợ & Thanh toán cùng phản ánh một phần thông tin về quy mô và trạng thái khoản vay.



Hình 3.2: Phân phối Lãi suất theo nhóm nợ — bộ dữ liệu B (kỳ 20260430)

Hình 3.2 cho thấy trung vị lãi suất có xu hướng tăng từ nhóm 1 đến nhóm 5. Phân phối của nhóm 3 và nhóm 4 được ước lượng lần lượt từ 998 và 1.446 quan sát (Bảng 3.3), qua đó hạn chế ảnh hưởng của biến động do cỡ mẫu nhỏ.

3.6 Bước 3: Tiền xử lý & chọn biến

Bước thứ ba xây dựng tập đặc trưng dùng cho huấn luyện, bao gồm loại các trường có nguy cơ rò rỉ dữ liệu, tạo đặc trưng nghiệp vụ, tính Weight of Evidence và Information Value (WOE/IV), xác lập tập đặc trưng, xử lý giá trị thiếu, mã hóa và chuẩn hóa. Mọi tham số tiền xử lý, như trung vị, trung bình, độ lệch chuẩn và danh mục mã hóa, chỉ được ước lượng trên tập huấn luyện để tránh rò rỉ thông tin từ tập kiểm định.

3.6.1 Kiểm soát rò rỉ dữ liệu

Rò rỉ thông tin phát sinh khi biến đầu vào chứa dữ liệu chỉ xuất hiện sau thời điểm dự báo hoặc là phép biến đổi trực tiếp của biến đích. Đối với bộ A, các biến NHOMNO_TCBS và NHOMNO được loại khỏi tập đầu vào; trong đó, NHOMNO có tương quan rất cao với NHOMNOMOI, nên việc giữ lại biến này có thể khiến mô hình tái tạo gần như trực tiếp quy tắc hình thành nhãn. Quá trình sàng lọc cũng loại biến DUNO_QD bị trùng lặp, trường mô tả văn bản trùng với mã sản phẩm và các trường hằng số hoặc có lượng thông tin không đáng kể.

Ở bộ B, bảy trường bị loại vì có quan hệ trực tiếp với quy tắc phân loại nhóm nợ theo quy định của Ngân hàng Nhà nước: Nhóm nợ phân loại sau khi tham chiếu CIC (một biến thể khác của biến đích); Dư nợ gốc chậm trả thực tế, Ngày chậm trả nợ gốc, Số tiền lãi chậm trả thực tế và Ngày chậm trả nợ lãi (số ngày và số tiền chậm trả là căn cứ trực tiếp để phân loại nhóm nợ); cùng với Dự phòng cụ thể phải trích nội bảng và Dự phòng cụ thể đã trích nội bảng. Tỷ lệ trích lập dự phòng cụ thể là hàm xác định theo nhóm nợ, lần lượt bằng 0%, 5%, 20%, 50% và 100% đối với nhóm 1 đến nhóm 5. Việc giữ các trường này có thể làm phát sinh rò rỉ thông tin, khiến mô hình tái tạo quy tắc hình thành nhãn thay vì nhận diện tín hiệu dự báo.

Đối với bài toán dự báo chuyển nhóm nợ, yêu cầu kiểm soát rò rỉ cần được thực hiện chặt chẽ hơn: mọi đặc trưng $X_{i,t}$ phải sẵn có tại hoặc trước thời điểm t , trong khi nhãn được xác định trong khoảng từ $t + 1$ đến $t + h$. Phép chia mẫu ngẫu nhiên được sử dụng trong nghiên cứu hiện tại phù hợp với mục tiêu kiểm định mô hình phân loại trạng thái, nhưng chưa tối ưu cho bài toán cảnh báo sớm. Khi có dữ liệu theo thời gian, việc chia mẫu theo trình tự thời gian là cần thiết

để ngăn thông tin tương lai tham gia quá trình huấn luyện.

3.6.2 Xây dựng đặc trưng nghiệp vụ

Hai nhánh dữ liệu sử dụng công thức tạo biến khác nhau. Bộ A tạo ba biến từ ngày mở, ngày đáo hạn, dư nợ hiện tại và dư nợ gốc. Bộ B tạo bốn biến kỹ thuật từ ngày giải ngân, ngày kết thúc khế ước và số lần cơ cấu lại thời hạn trả nợ.

Các biến này không tồn tại trực tiếp trong dữ liệu ban đầu mà được xây dựng từ một hoặc nhiều trường gốc nhằm chuyển thông tin kỹ thuật thành các đại lượng có ý nghĩa nghiệp vụ rõ ràng hơn. Bảng 3.10 tổng hợp nguồn hình thành và cách diễn giải của toàn bộ 7 biến được bổ sung.

Bảng 3.10: Các biến được xây dựng thêm từ dữ liệu ban đầu

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
A	LOAN_TENURE_DAYS	OPEN_DATE, NGÀYDENHAN	Tổng thời hạn theo hợp đồng, tính bằng số ngày từ ngày mở đến ngày đáo hạn. Giá trị lớn biểu thị khoản vay có kỳ hạn dài hơn.
A	DAYS_TO_MATURITY	NGÀYDENHAN, ngày tham chiếu d_0	Số ngày còn lại đến ngày đáo hạn. Giá trị dương biểu thị khoản vay chưa đáo hạn; bằng 0 là đáo hạn tại ngày tham chiếu; giá trị âm biểu thị khoản vay đã qua ngày đáo hạn.
A	UTIL_RATE	CURR_BAL, BASE_BAL	Tỷ lệ giữa dư nợ hiện tại và dư nợ gốc. Giá trị gần 1 cho biết dư nợ hiện tại xấp xỉ dư nợ gốc; nhỏ hơn 1 phản ánh dư nợ đã giảm; lớn hơn 1 có thể phản ánh giải ngân bổ sung hoặc biến động số dư.
B	ENG_LOAN_AGE_DAYS	ETL_DATE, Ngày giải ngân	Số ngày đã trôi qua kể từ ngày giải ngân tới ngày chốt dữ liệu (ETL_DATE) của chính hồ sơ đó, tức tuổi của khoản vay. Giá trị lớn biểu thị khoản vay đã tồn tại lâu hơn.
B	ENG_DAYS_TO_MATURITY	Ngày kết thúc khế ước, ETL_DATE	Số ngày còn lại đến ngày kết thúc khế ước, tính từ ETL_DATE. Giá trị âm cho biết khế ước đã qua ngày kết thúc so với ngày chốt dữ liệu.
B	ENG_TENOR_ACTUAL_DAYS	Ngày kết thúc khế ước, Ngày giải ngân	Kỳ hạn thực tế của khế ước, bằng chênh lệch giữa ngày kết thúc và ngày giải ngân.

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
B	ENG_HAS_RESTRUCTURE	Số lần cơ cấu lại thời hạn trả nợ	Biến nhị phân nhận giá trị 1 khi số lần cơ cấu lại thời hạn trả nợ lớn hơn 0 và nhận giá trị 0 trong trường hợp còn lại (kể cả khi thiếu dữ liệu). Biến chỉ phản ánh việc từng phát sinh cơ cấu, không cho biết mức độ.

Các biến phát sinh trên được tính hoàn toàn từ các trường đầu vào và không sử dụng biến đích. Do đó, bản thân quá trình tạo biến không trực tiếp làm lộ nhãn nhóm nợ. Tuy nhiên, trước khi triển khai thực tế, thời điểm hình thành của từng trường gốc vẫn phải được kiểm tra để bảo đảm trường đó đã tồn tại tại thời điểm dự báo; nếu một trường chỉ phát sinh sau thời điểm quan sát, biến được tạo từ trường đó vẫn có thể gây rò rỉ thông tin theo thời gian.

Đặc trưng của bộ dữ liệu A

Với ngày tham chiếu cố định $d_0 = 31/12/2021$, các biến được tính như sau:

$$LOAN_TENURE_DAYS_i = \max\{0, d_i^{\text{maturity}} - d_i^{\text{open}}\},$$

$$DAYS_TO_MATURITY_i = d_i^{\text{maturity}} - d_0.$$

Trong đó d_i^{open} là ngày mở khoản vay; d_i^{maturity} là ngày đến hạn; chênh lệch ngày được biểu diễn bằng số ngày dương hoặc âm. Việc cố định d_0 giúp cùng một hồ sơ nhận cùng giá trị khi tái chạy.

Tỷ lệ sử dụng dư nợ của bộ A được cài đặt:

$$UTIL_RATE_i = \begin{cases} \text{clip}\left(\frac{CURR_BAL_i}{BASE_BAL_i}, 0, 10\right), & BASE_BAL_i > 0, \\ 0, & BASE_BAL_i \leq 0. \end{cases}$$

Trong đó CURR_BAL là dư nợ hiện tại; BASE_BAL là dư nợ gốc hoặc cơ sở; và toán tử $\text{clip}(x, 0, 10)$ giới hạn giá trị trong đoạn $[0, 10]$ để giảm ảnh hưởng của tỷ

số ngoại lệ.

Kiểm tra đặc trưng đã tạo của bộ dữ liệu A

Sau khi ba biến LOAN_TENURE_DAYS, DAYS_TO_MATURITY và UTIL_RATE được tạo, mục này khảo sát thống kê mô tả, ngoại lệ và tương quan của chúng cùng năm biến gốc đã trình bày ở Bước 2 (mục 3.5), trước khi tính Information Value ở mục sau.

Bảng 3.11: Thống kê mô tả ba biến kỹ thuật của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
LOAN_TENURE_DAYS	2.292,5	2.452,0	0	1.461	18.292
DAYS_TO_MATURITY	672,7	2.397,7	-5.513	96	16.798
UTIL_RATE	2,4561	3,2557	2×10^{-8}	0,9429	10,0000

Bảng 3.12: Số quan sát ngoại lệ theo IQR — ba biến kỹ thuật của bộ dữ liệu A


Biến	Số ngoại lệ	Tỷ lệ (%)
DAYS_TO_MATURITY	6.233	23,08
UTIL_RATE	4.646	17,21
LOAN_TENURE_DAYS	2.754	10,20

DAYS_TO_MATURITY có tỷ lệ ngoại lệ cao nhất (23,08%) vì biến này nhận cả giá trị âm (khoản vay đã quá hạn đáo hạn tính đến ngày tham chiếu d_0) lẫn giá trị dương lớn (khoản vay kỳ hạn dài); đây là đặc điểm nghiệp vụ thực, không phải lỗi dữ liệu, nên không bị loại hay cắt ngưỡng. Ngược lại, UTIL_RATE có 17,21% ngoại lệ chủ yếu do một bộ phận khách hàng có dư nợ hiện tại vượt xa dư nợ gốc ban đầu (ví dụ giải ngân bổ sung nhiều lần); đây chính là lý do công thức tính UTIL_RATE ở trên chủ động **clip** kết quả vào đoạn $[0, 10]$: nếu không giới hạn, một số ít hồ sơ có tỷ lệ hàng trăm lần sẽ làm lệch cực đoan bước chuẩn hóa z-score của *toàn bộ* biến này khi đưa vào Logistic Regression.

Trong nghiên cứu này, **clip dữ liệu** được hiểu là phép giới hạn giá trị của một biến trong một khoảng xác định, thay vì loại bỏ các quan sát nằm ngoài khoảng đó. Với u là giá trị ban đầu của UTIL_RATE, giá trị sau khi giới hạn được xác định như sau:

$$\text{clip}(u; 0, 10) = \min\{\max(u, 0), 10\}.$$

Theo đó, giá trị nhỏ hơn 0 được thay bằng 0, giá trị lớn hơn 10 được thay bằng 10, còn các giá trị thuộc đoạn $[0, 10]$ được giữ nguyên. Ngưỡng trên bằng 10 tương ứng với trường hợp dư nợ hiện tại bằng 10 lần dư nợ gốc. Cách xử lý này không làm giảm số lượng quan sát và vẫn bảo lưu thông tin rằng hồ sơ có mức sử dụng rất cao, đồng thời hạn chế ảnh hưởng chi phối của một số giá trị cực đoan đối với trung bình, độ lệch chuẩn và quá trình ước lượng mô hình. Tuy nhiên, sau khi giới hạn, các mức UTIL_RATE lớn hơn 10 không còn được phân biệt với nhau; vì vậy, đây là một lựa chọn tiền xử lý nhằm tăng tính ổn định của mô hình, không hàm ý rằng các giá trị vượt ngưỡng là sai về mặt nghiệp vụ.



Hình 3.3: Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001)


Hình 3.3 minh họa trực quan hai đặc điểm đã nêu bằng số: BASE_BAL và CURR_BAL lệch phải mạnh trên thang gốc nên được vẽ theo $\log_{10}$ để thấy rõ hình chuông tương đối; UTIL_RATE có một cột dồn rõ rệt tại đúng giá trị 10, bằng chứng trực quan cho thấy phép **clip** đã cắt và dồn một lượng đáng kể hồ sơ (khoảng 3.200, tương ứng phần vượt ngưỡng của 17,21% ngoại lệ ở Bảng 3.12) về đúng biên trên; DAYS_TO_MATURITY có hai đỉnh, một quanh 0 (khoản vay gần đáo hạn hoặc mới quá hạn) và một dải trải dài về phía dương (khoản vay kỳ hạn dài).

Ma trận tương quan (Bảng 3.13, minh họa trực quan ở Hình 3.4) cho thấy ba cặp biến có $|r| \geq 0,7$.


Bảng 3.13: Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A

Biến 1	Biến 2	Hệ số tương quan r
LOAN_TENURE_DAYS	DAYS_TO_MATURITY	0,942
BASE_BAL	CURR_BAL	0,923
ORGNBR	PARENTORGNBR	0,738
LAISUAT	LOAN_TENURE_DAYS	0,352
LAISUAT	UTIL_RATE	-0,327

Ba cặp tương quan mạnh nhất đều có cách giải thích nghiệp vụ trực tiếp: LOAN_TENURE_DAYS và DAYS_TO_MATURITY cùng được tính từ ngày mở và ngày đáo hạn nên gần như là hai phép biến đổi tuyến tính của cùng thông tin gốc; CURR_BAL là dư nợ hiện tại nên tương quan cao với dư nợ gốc BASE_BAL; ORGNBR và PARENTORGNBR phản ánh cấu trúc phân cấp chi nhánh–đơn vị cấp trên. Mức tương quan này không đủ cao để loại biến (không có cặp nào $|r| > 0,95$), nhưng đủ để giải thích vì sao trong bảng SHAP ở Chương 4, importance của hai biến kỳ hạn thường lẫn át lẫn nhau tùy ngẫu nhiên hoá của mô hình cây; đây là hạn chế cố hữu khi diễn giải importance trên các biến tương quan [18].



Hình 3.4: Ma trận tương quan Pearson giữa các biến số của bộ dữ liệu A



Hình 3.5: Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A

Hình 3.5 cho thấy trung vị DAYS_TO_MATURITY giảm dần khá đều từ nhóm 1 đến nhóm 4 rồi đổi hướng ở nhóm 5, phù hợp việc đây là biến SHAP xếp hạng cao nhất ở Chương 4, nhưng cũng gợi ý quan hệ giữa biến này và nhóm nợ không hoàn toàn đơn điệu, cần thận trọng khi diễn giải nhân quả.

Đặc trưng thời gian của bộ dữ liệu B

Ba trong bốn biến kỹ thuật của bộ B được tính bằng chênh lệch ngày, sử dụng ETL_DATE của từng hồ sơ làm mốc tham chiếu để bảo đảm khả năng tái lập kết quả. Mỗi hồ sơ có một ngày chốt dữ liệu cố định tại thời điểm trích xuất báo cáo, nên giá trị của các biến thời gian không thay đổi khi thực thi lại mã nguồn tại một thời điểm khác. Biến còn lại được tính trực tiếp từ số lần cơ cấu lại thời hạn trả nợ.

$$ENG_LOAN_AGE_DAYS_i = ETL_DATE_i - d_i^{\text{disb}},$$

$$ENG_DAYS_TO_MATURITY_i = d_i^{\text{end}} - ETL_DATE_i,$$

$$ENG_TENOR_ACTUAL_DAYS_i = d_i^{\text{end}} - d_i^{\text{disb}},$$

trong đó d_i^{disb} là ngày giải ngân; d_i^{end} là ngày kết thúc khế ước; và ETL_DATE_i là ngày chốt dữ liệu của hồ sơ i . Biến nhị phân còn lại:

$$ENG_HAS_RESTRUCTURE_i = \begin{cases} 1, & SoLanCoCauLai_i > 0, \\ 0, & \text{ngược lại (kể cả khi thiếu dữ liệu)}. \end{cases}$$


Trường Thời điểm truy đòi, ban đầu được xem xét làm nguồn cho một biến thời gian thứ năm, bị loại khỏi danh sách cột ngày sau khi kiểm tra thực nghiệm cho thấy trường này trùng khớp 100% với Ngày kết thúc khế ước trên toàn bộ dữ liệu quan sát được; giữ lại sẽ chỉ tạo ra một biến kỹ thuật trùng lặp hoàn toàn với ENG_DAYS_TO_MATURITY, không bổ sung thông tin mới.

Kiểm tra đặc trưng đã tạo của bộ dữ liệu B


Cả bốn biến kỹ thuật của bộ B đều **không có giá trị thiếu** (0,00%), vì được tính trực tiếp từ ETL_DATE, ngày giải ngân và ngày kết thúc khế ước, ba trường có mặt ở toàn bộ 100.617 hồ sơ. Bảng 3.14 trình bày thống kê mô tả.

Bảng 3.14: Thống kê mô tả bốn biến kỹ thuật của bộ dữ liệu B

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Ngoại lệ IQR (%)
ENG_LOAN_AGE_DAYS	602,82	632,71	395	3,05
ENG_DAYS_TO_MATURITY	1.667,40	2.778,31	711	11,51
ENG_TENOR_ACTUAL_DAYS	2.270,22	2.850,29	1.461	12,45
ENG_HAS_RESTRUCTURE	0,004	0,063	0	0,40



Hình 3.6: Top 15 biến (trong bể đặc trưng hợp lệ) có tỷ lệ thiếu cao nhất — bộ dữ liệu B



Hình 3.7: Ma trận tương quan giữa 12 biến số (8 biến gốc + 4 biến kỹ thuật) — bộ dữ liệu B

Hình 3.7 cho thấy cặp `ENG_DAYS_TO_MATURITY` và `ENG_TENOR_ACTUAL_DAYS` có hệ số tương quan lớn nhất trong 12 biến số ($r = 0,975$). Mỗi tương quan này xuất phát từ việc cả hai đặc trưng cùng sử dụng mốc Ngày kết thúc khế ước, tương tự mối quan hệ giữa `LOAN_TENURE_DAYS` và `DAYS_TO_MATURITY` ở bộ A (Mục 3.6.2). Do hệ số tương quan vượt ngưỡng tham khảo 0,95, hai biến có khả năng chứa thông tin trùng lặp đáng kể. Tuy vậy, nghiên cứu vẫn giữ lại cả hai do chúng biểu thị hai khía cạnh nghiệp vụ khác nhau, lần lượt là kỳ hạn còn lại và tổng kỳ hạn thực tế. Đây là điểm cần thận trọng khi diễn giải mức độ quan trọng ở Chương 4, bởi đóng góp của hai biến có thể cùng bắt nguồn từ một nguồn thông tin cơ sở.

3.6.3 Weight of Evidence và Information Value (WOE/IV)

Information Value (IV) được sử dụng để lượng hóa khả năng phân tách giữa nhóm nợ “tốt” và nhóm nợ “xấu” của từng biến trước khi đưa vào mô hình. Nghiên cứu quy ước nhãn nhị phân “tốt” tương ứng với nhóm 1 và “xấu” tương ứng với các nhóm 2–5; các biến số được chia thành 10 khoảng theo phân vị. IV được tính trên tập đặc trưng còn lại sau khi loại các trường có nguy cơ rò rỉ tại Mục 3.6.1 và bổ sung các đặc trưng nghiệp vụ, qua đó cung cấp căn cứ định lượng để xác lập tập đặc trưng tại Mục 3.6.4.

Bảng Information Value đầy đủ của bộ dữ liệu A

Bảng 3.15 trình bày giá trị IV của toàn bộ 13 biến trong tập phân tích, bao gồm SEX và LOAIKH, theo thứ tự giảm dần. Vai trò của hai biến này trong quá trình lựa chọn tập đặc trưng được thảo luận tại Mục 3.6.4.

Bảng 3.15: Information Value của 13 biến — bộ dữ liệu A

Biến	IV	Mức
DAYS_TO_MATURITY	4,5541	(!) Nghi ngờ (leakage?)
CURRMIACTTYP	1,9921	(!) Nghi ngờ (leakage?)
LOAN_TENURE_DAYS	1,9410	(!) Nghi ngờ (leakage?)
MUCDICHVAY	1,4141	(!) Nghi ngờ (leakage?)
UTIL_RATE	1,3334	(!) Nghi ngờ (leakage?)
MJACCTTYP	0,9695	Rất mạnh
LAISUAT	0,7851	Rất mạnh
BASE_BAL	0,5356	Rất mạnh
PARENTORGNBR	0,3201	Mạnh
CURR_BAL	0,2585	Trung bình
ORGNBR	0,1820	Trung bình
SEX	0,0081	Vô dụng
LOAIKH	0,0000	Vô dụng

Kết quả cho thấy 5 trong tổng số 13 biến có $IV > 1,0$, vượt ngưỡng mà Siddiqi xem là dấu hiệu cần thận trọng do biến có thể đại diện gián tiếp hoặc làm rò rỉ biến đích [24]. Năm biến này đồng thời nằm trong nhóm có mức độ quan trọng cao nhất theo SHAP và Gain ở Chương 4. Có hai khả năng cần được phân biệt. Thứ nhất, nếu biến được tính trực tiếp từ NHOMNOMOI hoặc từ quy tắc hình thành nhân, biến đó phải được loại tương tự NHOMNO tại Mục 3.6.1. Thứ hai, nếu biến được xác lập độc lập với nhân nhưng có quan hệ nghiệp vụ chặt chẽ với nhóm nợ, IV cao có thể phản ánh tín hiệu thực tế. Do chưa có đầy đủ thông tin về quy trình hình thành dữ liệu nguồn, kết quả này được xem là một giới hạn cần lưu ý khi diễn giải mô hình.

Luận văn nghiêng về khả năng thứ hai đối với ba biến được xây dựng trong nghiên cứu. Cụ thể, DAYS_TO_MATURITY phản ánh số ngày còn lại đến ngày đáo hạn; LOAN_TENURE_DAYS biểu thị thời hạn khoản vay; và UTIL_RATE đo lường tỷ lệ sử dụng dư nợ. Cả ba biến đều được tính từ ngày mở khoản vay, ngày đáo hạn hoặc số dư nợ. Các trường dữ liệu nguồn này tồn tại độc lập với quy trình xếp nhóm nợ và không phải là biến phái sinh của NHOMNOMOI. Tuy nhiên, với hai biến phân loại nhiều danh mục CURRMIACTTYP (31 nhóm) và MUCDICHVAY (79 nhóm), IV cao một phần có thể là hiện tượng thống kê: biến định danh có rất nhiều danh mục dễ đạt IV cao giả tạo vì mỗi danh mục nhỏ đóng góp lệch xác suất riêng, ngay cả khi không có quan hệ nhân quả mạnh; đây là hạn chế đã biết của công thức IV khi áp dụng cho biến nhiều danh mục [24]. Vì vậy, luận văn khuyến nghị: (a) giữ nguyên 5 biến này trong mô hình vì không tìm thấy bằng chứng chúng được tính trực tiếp từ nhân, nhưng (b) nêu rõ đây là hạn chế cần rà soát cùng đơn vị nghiệp vụ trước khi triển khai thực tế, đặc biệt với hai biến phân loại nhiều danh mục.

Bảng Information Value của bộ dữ liệu B

Áp dụng cùng phương pháp tính IV như bộ A (mục 3.6.3) cho toàn bộ 20 đặc trưng hợp lệ của bộ B. Bảng 3.16 tổng hợp số lượng biến theo từng mức IV; Bảng 3.17 liệt kê chi tiết từng biến.

Bảng 3.16: Phân bố 20 đặc trưng của bộ dữ liệu B theo mức Information Value

Mức IV	Số biến	Tỷ lệ (%)
Vô dụng ($< 0,02$)	7	35,0
Yếu ($0,02-0,1$)	6	30,0
Mạnh ($0,3-0,5$)	3	15,0
Trung bình ($0,1-0,3$)	2	10,0
Rất mạnh ($0,5-1,0$)	1	5,0
(!) Nghi ngờ ($> 1,0$)	1	5,0
Tổng	20	100,0

Bảng 3.17: Information Value của 20 đặc trưng — bộ dữ liệu B

Biến	IV	Mức
ENG_LOAN_AGE_DAYS	1,1170	(!) Nghi ngờ (leakage?)
Lãi phải thu hạch toán nội bảng	0,5420	Rất mạnh
ENG_TENOR_ACTUAL_DAYS	0,3793	Mạnh
Mô tả mục đích sử dụng tiền vay	0,3611	Mạnh
Lãi suất	0,3130	Mạnh
ENG_DAYS_TO_MATURITY	0,2549	Trung bình
Số dư nợ theo nguyên tệ	0,1892	Trung bình
Phương thức cho vay	0,0732	Yếu
Số tiền nợ gốc cơ cấu	0,0626	Yếu
Số lần cơ cấu lại thời hạn trả nợ	0,0620	Yếu
Mục đích sử dụng tiền vay phân theo ngành kinh tế	0,0620	Yếu
Mã chi nhánh TCTD	0,0415	Yếu
Số tiền nợ lãi cơ cấu	0,0320	Yếu
Mã thời hạn cấp tín dụng	0,0107	Vô dụng
Mã tiền tệ	0,0039	Vô dụng
ENG_HAS_RESTRUCTURE	0,0000	Vô dụng
Hình thức cấp tín dụng	0,0000	Vô dụng
Lãi chưa thu hạch toán ngoại bảng	0,0000	Vô dụng
Nguồn cấp tín dụng	0,0000	Vô dụng
Hoạt động cấp tín dụng bằng phương tiện điện tử	0,0000	Vô dụng

Bảng 3.17 cho thấy ENG_LOAN_AGE_DAYS, biến kỹ thuật được xây dựng trong nghiên cứu, có IV cao nhất (1,1170), vượt ngưỡng mà Siddiqi xem là dấu hiệu cần thận trọng [24]. Biến này được tính hoàn toàn từ ETL_DATE và Ngày giải ngân, là hai trường tồn tại độc lập với quy tắc xếp nhóm nợ. Do đó, IV cao có thể phản ánh hiệu ứng tuổi khoản vay (*seasoning effect*): khoản vay tồn tại lâu hơn có nhiều thời gian phát sinh chậm trả, trong khi khoản vay mới giải ngân thường chưa đủ thời gian để phát sinh quá hạn. Nghiên cứu giữ lại biến này nhưng không diễn giải mối liên hệ quan sát được như bằng chứng nhân quả.

Bảy trên hai mươi đặc trưng (35,0%) có $IV < 0,02$, tức “vô dụng” theo ngưỡng

đơn biến, nhưng vẫn được giữ trong tập huấn luyện vì quy tắc lọc ở mục 3.6.2 chỉ loại theo tiêu chí leakage/trùng lặp/hàng số, không lọc theo IV. Tỷ lệ này khá thấp vì bề đặc trưng đã nhỏ và tập trung (20 biến), nên ít cột dư thừa/gần hàng số.

3.6.4 Xây dựng tập đặc trưng huấn luyện

Bộ dữ liệu A: tập 11 biến và tập mở rộng 13 biến

Cấu hình huấn luyện chính sử dụng 11 đặc trưng đã qua sàng lọc, gồm ba biến phân loại và tám biến số. Để đánh giá độ nhạy của tiêu chí lựa chọn biến, tập phân tích được mở rộng lên 13 đặc trưng bằng cách bổ sung SEX và LOAIKH. Theo Bảng 3.15, hai biến này có IV lần lượt bằng 0,008 và 0,000, đều thấp hơn ngưỡng 0,02 thường được xem là không có giá trị dự báo đơn biến đáng kể [24]. Việc đưa hai biến trở lại tập mở rộng nhằm kiểm tra liệu mô hình cây đa biến có thể khai thác các tương tác mà IV đơn biến không phản ánh hay không. Kết quả tại Chương 4 cho thấy sự khác biệt về hiệu quả là không đáng kể.

Sau khi phân tích ngày và tạo biến, bộ A có tám biến số:

- năm biến từ tập nguồn: BASE_BAL, CURR_BAL, LAISUAT, ORGNBR và PARENTORGNBR;
- ba biến tạo thêm: LOAN_TENURE_DAYS, DAYS_TO_MATURITY và UTIL_RATE.

Năm biến phân loại trong tập đầy đủ được chia thành:

- ba biến cấu hình chính: MJACCTTYP, CURRMIACTTYP và MUCDICHVAY;
- hai biến IV thấp đưa lại để kiểm chứng: SEX và LOAIKH.

Đối với bộ 11 biến chính, phép đếm từ tệp nguồn là:

$$21 - 1 - 10 - 2 + 3 = 11,$$

trong đó 21 là số cột thô; 1 là biến đích; 10 là số trường trong danh sách loại; 2 là hai trường ngày chỉ dùng để tạo biến; và 3 là số biến kỹ thuật được bổ sung. Pool phân tích có 13 biến vì đưa lại hai biến SEX và LOAIKH.

Bộ dữ liệu B: từ 33 cột chung tới 20 đặc trưng mô hình

Con số 33 là số cột có mặt ở cả hai kỳ báo cáo (20260430 và 20260507), không phải số biến thực tế đưa vào bộ phân loại. Tám cột chỉ có ở kỳ 20260430 (gồm hạn mức tín dụng trên hợp đồng, trạng thái tài sản bảo đảm và các trường ngày hiệu lực/kết thúc hợp đồng) không được dùng làm đặc trưng vì tập kiểm tra độc lập 20260507 không có các cột này. Bước xây dựng bể đặc trưng từ 33 cột chung thực hiện bốn lớp lọc:

1. loại biến đích;
2. loại 4 trường định danh (mã/tên khách hàng, số hợp đồng, số khế ước) và 7 trường gây rò rỉ đã nêu ở mục 3.6.1 (nhóm nợ đối chiếu CIC, dư nợ/lãi chậm trả thực tế và ngày chậm trả, dự phòng cụ thể phải trích và đã trích);
3. không đưa trực tiếp 3 trường ngày (ETL_DATE, ngày giải ngân, ngày kết thúc khế ước) vào mô hình; các trường này chỉ dùng để tạo 4 biến thời gian ở mục 3.6.2. Loại thêm 1 trường ngày trùng lặp hoàn toàn (Thời điểm truy đòi) và 1 cột hằng số (Số tiền đã thanh toán, toàn bộ giá trị bằng 0 trong dữ liệu quan sát được).

Sau quá trình sàng lọc, tập dữ liệu còn 8 biến số và 8 biến phân loại. Bước


xây dựng đặc trưng nghiệp vụ bổ sung 4 biến số, đưa tổng số biến đầu vào lên:

$$p = 8 + 8 + 4 = 20.$$

Tương đương, phép đếm từ tập nguồn có thể viết:

$$33 - 1 - 4 - 7 - 4 - 1 + 4 = 20.$$

Trong đó, 1 là biến đích; 4 là số trường định danh; 7 là số trường có nguy cơ rò rỉ thông tin; 4 là số trường ngày (3 dùng để sinh đặc trưng, 1 trùng lặp bị loại); 1 là cột hằng số; và 4 là số biến được xây dựng thêm. Ràng buộc 33 cột chung giữa hai kỳ báo cáo đã tự nhiên giới hạn bề đặc trưng ở quy mô nhỏ và tập trung (20 đặc trưng), khiến câu hỏi “có thể giảm còn bao nhiêu đặc trưng” ở Chương 4 mang ý nghĩa thực tiễn trực tiếp hơn: bề đặc trưng ban đầu vốn đã không có nhiều dư thừa cần cắt bớt.



Hình 3.8: Các tầng số lượng biến trong nghiên cứu

Đối với bộ B, nghiên cứu không xác lập trước một tập đặc trưng rút gọn cố định. Toàn bộ 20 đặc trưng hợp lệ được sử dụng trong cấu hình huấn luyện chính; khả năng rút gọn được đánh giá thông qua thực nghiệm sử dụng k đặc trưng có mức độ quan trọng cao nhất, trình bày tại Chương 4.

Nhóm đặc trưng nghiệp vụ

Đối với bộ A, 13 biến được phân vào sáu nhóm: Dư nợ và hạn mức sử dụng; Lãi suất; Kỳ hạn khoản vay; Đơn vị/chi nhánh; Sản phẩm và mục đích vay; Nhân

khẩu học có IV thấp. Đối với bộ B, 20 biến được phân vào sáu nhóm: (1) Dư nợ & Thanh toán; (2) Lãi suất; (3) Kỳ hạn & Cơ cấu lại; (4) Hình thức & Mục đích vay; (5) Chi nhánh; và (6) Đặc trưng kỹ thuật.

Việc phân nhóm biến phục vụ hai mục đích: giải thích mô hình ở cấp độ nghiệp vụ và xây dựng khuyến nghị đầu tư dữ liệu. Tuy nhiên, tổng mức độ quan trọng của một nhóm chỉ phản ánh cách mô hình sử dụng dữ liệu hiện có và không cung cấp bằng chứng về quan hệ nhân quả.

3.6.5 Giá trị thiếu và chuẩn hóa

Đối với biến số, `SimpleImputer(strategy="median")` thay giá trị thiếu bằng trung vị học trên tập huấn luyện:

$$\tilde{x}_{ij} = \begin{cases} x_{ij}, & x_{ij} \text{ quan sát được,} \\ \text{median}\{x_{\ell j} : \ell \in \mathcal{T}\}, & x_{ij} \text{ thiếu,} \end{cases}$$

trong đó x_{ij} là giá trị biến j của quan sát i ; $\mathcal{T}$ là tập chỉ số huấn luyện; và $\tilde{x}_{ij}$ là giá trị sau điền khuyết.

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, biến số sau điền khuyết được chuẩn hóa:

$$z_{ij} = \frac{\tilde{x}_{ij} - \mu_j}{\sigma_j},$$

trong đó μ_j và σ_j lần lượt là trung bình và độ lệch chuẩn của biến j sau điền khuyết trên tập huấn luyện; z_{ij} là giá trị chuẩn hóa. Việc chuẩn hóa đặc biệt cần cho hồi quy logistic, còn mô hình cây ít nhạy hơn với thang đo [5, 15].

3.6.6 Biến phân loại

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, mã nguồn sử dụng một bộ LabelEncoder riêng cho từng cột. Nếu xuất hiện giá trị mới chưa có trong tập huấn luyện, giá trị đó được ánh xạ về lớp đầu tiên của bộ mã hóa. Cách xử lý này bảo đảm khả năng thực thi nhưng có thể tạo ra thứ tự không có ý nghĩa đối với biến định danh; đây là một hạn chế của quy trình tiền xử lý cần được lưu ý khi diễn giải kết quả.

CatBoost sử dụng preprocessor riêng: biến số chỉ được điền trung vị, không chuẩn hóa; biến phân loại thiếu được thay bằng UNKNOWN và giữ dạng chuỗi để thuật toán xử lý trực tiếp, phù hợp cơ chế của CatBoost [23].

Việc sử dụng trung vị thay cho trung bình ở bước điền khuyết được lựa chọn dựa trên kết quả phân tích khám phá tại mục 3.5. Các biến tiền tệ trong cả hai bộ dữ liệu có phân phối lệch phải mạnh (Bảng 3.5, 3.8), độ lệch chuẩn lớn hơn giá trị trung bình nhiều lần và tỷ lệ ngoại lệ theo IQR đáng kể. Trung vị ít nhạy cảm hơn với ngoại lệ và phân phối lệch, trong khi trung bình có thể bị chi phối bởi các giá trị cực lớn, khiến giá trị điền khuyết kém đại diện cho phần lớn hồ sơ [5].

3.6.7 Ví dụ minh họa trước và sau xử lý

Để minh họa các phép biến đổi nêu trên, Bảng 3.18 trình bày ba hồ sơ thực tế trong tập kiểm định của bộ A qua từng bước xử lý.

Bảng 3.18: Ví dụ ba hồ sơ thực tế của bộ A trước và sau xử lý

Biến	Hồ sơ #5944	Hồ sơ #7333	Hồ sơ #12595
<i>Giá trị thô (không có biến nào thiếu ở bộ A)</i>			
BASE_BAL	201.000.000	5.000.000	300.000.000
CURR_BAL	77.050.000	9.184.112	180.000.000
LAISUAT	0,1173	0,0000	0,1200
UTIL_RATE	0,3833	1,8368	0,6000
MJACCTTYPCD	CNS	CNS	CNS
CURRMIACTTYPCD	TH01	VS01	TH01
<i>Sau chuẩn hóa z-score (học μ, σ trên tập huấn luyện)</i>			
BASE_BAL	-0,0334	-0,0651	-0,0173
CURR_BAL	-0,0501	-0,0628	-0,0310
LAISUAT	0,7095	-1,0111	0,7491
UTIL_RATE	-0,6374	-0,1923	-0,5710
<i>Sau mã hóa LabelEncoder (học trên tập huấn luyện)</i>			
MJACCTTYPCD	1	1	1
CURRMIACTTYPCD	12	22	12

Vì bộ A không có giá trị thiếu, bước điền khuyết không làm thay đổi số liệu; bảng chỉ còn ý nghĩa với các bộ dữ liệu khác có *NaN*. Điểm đáng chú ý là hồ sơ #7333 có UTIL_RATE thô bằng 1,8368 (dư nợ hiện tại đã vượt 183,7% dư nợ gốc), sau chuẩn hóa cho z-score -0,1923, âm dù bản thân tỷ lệ sử dụng cao hơn hai hồ sơ còn lại, vì UTIL_RATE trung bình toàn mẫu huấn luyện xấp xỉ 2,46 (Bảng 3.11); đây là lý do luận văn nhấn mạnh z-score chỉ có ý nghĩa *tương đối* trong phân phối đã lệch, không nên diễn giải như một chỉ số rủi ro tuyệt đối.

Bảng 3.19 minh họa ba hồ sơ thực tế của bộ B có giá trị thiếu tại biến Phương thức cho vay. Trong dữ liệu gốc, biến này thiếu ở 46 trong tổng số 100.617 hồ sơ, tương ứng 0,05%.

Bảng 3.19: Ví dụ ba hồ sơ thực tế của bộ B có giá trị thiếu, trước và sau xử lý

Biến	Hồ sơ #22771	Hồ sơ #26934	Hồ sơ #26961
<i>Giá trị thô</i>			
Số dư nợ theo nguyên tệ	338	13.700	8.840
Lãi suất	16,50	16,95	21,00
Phương thức cho vay	<i>NaN</i>	<i>NaN</i>	<i>NaN</i>
Nhóm nợ tự phân loại	5	5	5
<i>Sau chuẩn hóa z-score (học μ, σ trên tập huấn luyện)</i>			
Số dư nợ theo nguyên tệ	-0,0390	0,0706	0,0307
Lãi suất	1,2578	1,3667	2,3438
<i>Sau điền khuyết (most_frequent) / mã hóa</i>			
Phương thức cho vay	11	11	11

Cả ba hồ sơ trong ví dụ đều thuộc nhóm nợ 5 và có Phương thức cho vay thiếu; cỡ mẫu nhỏ nên chưa đủ để khẳng định giá trị thiếu ở biến này tương quan với nhóm nợ, nhưng là điểm cần theo dõi thêm khi có nhiều dữ liệu hơn. Với `SimpleImputer(strategy="most_frequent")`, giá trị thiếu được thay bằng danh mục xuất hiện nhiều nhất trên tập huấn luyện, mã 11 (chiếm 76,9% trong ba giá trị hợp lệ 11/14/16 của biến này), trước khi đưa qua `LabelEncoder` như các mô hình còn lại; với `CatBoost`, giá trị thiếu được giữ dạng chuỗi `UNKNOWN` thay vì điền `most_frequent`, theo đúng `preprocessor` riêng đã mô tả ở mục sau. Ba biến số trong bảng cũng cho thấy cùng hiệu ứng nén biến thiên sau chuẩn hóa đã nêu ở ví dụ bộ A: dù Số dư nợ theo nguyên tệ của hồ sơ #26934 (13.700) lớn gấp hơn 40 lần hồ sơ #22771 (338), z-score tương ứng chỉ chênh lệch khoảng 0,11, do độ lệch chuẩn toàn mẫu (121.908,73) lớn hơn nhiều so với trung bình (5.092,31).

3.6.8 Phân tích số lượng và nhóm đặc trưng

Trong cấu hình phân tích, XGBoost được sử dụng để xác lập thứ hạng mức độ quan trọng của đặc trưng riêng cho từng bộ dữ liệu. Với các đặc trưng được sắp xếp sao cho $I_{(1)} \geq \dots \geq I_{(p)}$, tỷ lệ mức độ quan trọng tích lũy tại k được xác định như sau:

$$Q(k) = \frac{\sum_{j=1}^k I_{(j)}}{\sum_{j=1}^p I_{(j)}} \times 100\%.$$

Trong đó $I_{(j)}$ là mức độ quan trọng của đặc trưng có thứ hạng j ; $p = 13$ đối với tập đầy đủ của bộ A và $p = 20$ đối với bộ B. Đại lượng $Q(k)$ phản ánh tỷ lệ mức độ quan trọng tích lũy, không phải tỷ lệ hiệu quả dự báo được duy trì. Vì vậy, số biến đạt 95% mức độ quan trọng chỉ được xem là cấu hình ứng viên và phải được huấn luyện, đánh giá lại trên dữ liệu ngoài mẫu. Các giá trị khảo sát là $k \in \{3, 5, 7, 9, 11, 13\}$ đối với bộ A và $k \in \{3, 5, 8, 11, 14, 17, 20\}$ đối với bộ B.

Đóng góp của nhóm đặc trưng g được xác định theo công thức:

$$I_g = \sum_{j: g(j)=g} I_j, \quad S_g = \frac{I_g}{\sum_r I_r} \times 100\%,$$

trong đó $g(j)$ ánh xạ đặc trưng j vào nhóm nghiệp vụ tương ứng; I_g là tổng mức độ quan trọng và S_g là tỷ trọng của nhóm.

Chỉ số ưu tiên dữ liệu được xác định như sau:

$$\text{Priority}_g = S_g \left(\frac{M_g}{100} + 0, 1 \right),$$

trong đó M_g là tỷ lệ thiếu trung bình của nhóm g và 0,1 là hệ số nền do tác giả quy ước. Chỉ số này chỉ có vai trò hỗ trợ sắp xếp nội dung thảo luận, chưa phải là một hàm lợi ích kinh tế đã được hiệu chỉnh và kiểm định.

Phương pháp lựa chọn biến có hai giới hạn cần lưu ý. Thứ nhất, nhiều giá trị k được khảo sát trên cùng một tập kiểm định trước khi lựa chọn cấu hình có kết quả cao nhất, do đó có thể phát sinh thiên lệch lựa chọn. Các đường cong hiệu quả theo k chỉ được sử dụng cho mục đích phân tích khám phá, không được xem là kết quả của một quy trình lựa chọn biến đã kiểm định độc lập. Thứ hai, tổng mức độ quan trọng theo nhóm không thể thay thế thực nghiệm loại bỏ lần lượt từng nhóm đặc trưng.

3.7 Bước 4: Chia dữ liệu & cân bằng lớp

Bước thứ tư chia dữ liệu thành tập huấn luyện và kiểm định theo nguyên tắc phân tầng, sau đó xử lý mất cân bằng lớp chỉ trên tập huấn luyện.

3.7.1 Chia tập huấn luyện–kiểm định

Mã nguồn đặt tham số `RANDOM_STATE=42`, tỷ lệ kiểm định bằng 0,2 và thực hiện phép chia ngẫu nhiên có phân tầng theo nhãn. Bộ dữ liệu A được chia thành 21.600 quan sát huấn luyện và 5.401 quan sát kiểm định. Bộ dữ liệu B (kỳ 20260430) được chia thành 80.493 quan sát huấn luyện và 20.124 quan sát kiểm định (Bảng 3.3); ngoài ra, toàn bộ 100.274 quan sát của kỳ 20260507 được giữ lại làm tập kiểm tra độc lập, không tham gia bước chia phân tầng này (mục 3.4.2).

Mô hình phân loại nhóm nợ được đánh giá theo hai tầng. Tầng thứ nhất sử dụng phép chia huấn luyện–kiểm định theo tỷ lệ 80/20 để so sánh các mô hình trong cùng điều kiện. Tầng thứ hai sử dụng kiểm định chéo phân tầng lặp lại (*Repeated Stratified K-Fold*), được trình bày chi tiết tại Mục 3.8.2. Với $R = 3$ lần

lặp và $F = 5$ phần, mô hình được ước lượng $R \times F = 15$ lần; mỗi quan sát xuất hiện trong phần kiểm định đúng một lần ở mỗi lượt lặp. Thiết kế này không làm tăng số quan sát thực tế, nhưng giúp giảm mức độ phụ thuộc của Recall ở các lớp hiếm vào một lần chia mẫu duy nhất.

3.7.2 Xử lý mất cân bằng lớp

SMOTE tạo một điểm tổng hợp:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim U(0, 1),$$

trong đó $\mathbf{x}_i$ là véc-tơ của một quan sát lớp thiểu số; $\mathbf{x}_{nn}$ là một trong các láng giềng gần của nó; λ là số ngẫu nhiên phân bố đều trên $[0, 1]$; và $\mathbf{x}_{\text{new}}$ là điểm nội suy [8].

Đối với bộ A, chiến lược `smote_moderate` nâng số quan sát huấn luyện của các lớp 2, 3, 4 và 5 từ 1.030, 483, 627 và 2.689 lên lần lượt 3.000, 2.000, 2.000 và 5.000. Đối với bộ B, chiến lược tùy chỉnh nâng số quan sát của bốn lớp tương ứng từ 5.057, 798, 1.157 và 2.382 lên 8.000, 4.000, 4.500 và 6.000. Sau lấy mẫu, quy mô các lớp thiểu số tương đương khoảng 5,6–11,2% lớp đa số, trong khi tỷ trọng quan sát tổng hợp trong từng lớp vẫn dưới 50%. SMOTE được thực hiện sau bước tiền xử lý và trước bước huấn luyện mô hình, đồng thời chỉ tác động đến tập huấn luyện.

Ví dụ minh họa SMOTE trên nhóm 3 của bộ B

Nhóm 3 (nợ dưới tiêu chuẩn) của bộ B có 798 hồ sơ thực tế trong tập huấn luyện. Xét hai hồ sơ thuộc nhóm này, trong đó hồ sơ thứ nhất là $\mathbf{x}_i$ (Lãi suất=6,85) và hồ sơ lân cận là $\mathbf{x}_{nn}$ (Lãi suất=12,39). Với $\lambda = 0,5$, công thức SMOTE cho

kết quả:

$$x_{\text{new}} = 6,85 + 0,5 \times (12,39 - 6,85) = 9,62.$$

Quan sát tổng hợp không tồn tại trong dữ liệu gốc mà nằm trên đoạn thẳng nối hai hồ sơ cùng nhóm 3 trong không gian đặc trưng đã chuẩn hóa. Đây là cơ chế được SMOTE sử dụng để tăng số quan sát huấn luyện của nhóm 3 từ 798 lên 4.000 theo chiến lược tùy chỉnh. Do nhóm 3 có số lượng quan sát gốc tương đối lớn và thể hiện biến thiên trên phần lớn các đặc trưng, nguy cơ các quan sát tổng hợp không tạo thêm biến thiên có ý nghĩa được đánh giá là không đáng kể trong bộ dữ liệu này.

Code mới còn cho phép học theo chi phí bằng trọng số lớp:

$$w_c = \frac{N}{K n_c},$$

trong đó N là số quan sát huấn luyện, K là số lớp và n_c là số quan sát thuộc lớp c . Mỗi quan sát i được gán trọng số w_{y_i} . Đối với XGBoost, trọng số được tính lại trong từng phần huấn luyện của kiểm định chéo thông qua `compute_sample_weights()`, nhờ đó không sử dụng tần suất lớp của phần kiểm định. Đối với CatBoost, các chiến lược cân bằng khác `none` được ánh xạ sang cơ chế `auto_class_weights=Balanced`; SMOTE không được áp dụng trực tiếp trên các biến phân loại dạng chuỗi.

Hai lưu ý cần nêu rõ. Thứ nhất, biến phân loại đã label-encode được SMOTE nội suy như biến số, có thể sinh giá trị không tương ứng danh mục thực. Thứ hai, trang phân tích Top- k của bộ B gọi chiến lược `smote_moderate`, khác với chiến lược tùy chỉnh của bảng mô hình đầy đủ. Do đó, so sánh số tuyệt đối giữa hai bảng còn chịu ảnh hưởng của chiến lược lấy mẫu. Tài liệu cho thấy xử lý mất

cân bằng có thể làm thay đổi thứ hạng mô hình và không có một kỹ thuật luôn tốt nhất [7].

3.8 Bước 5: Huấn luyện mô hình

Bước thứ năm huấn luyện và tinh chỉnh các mô hình phân loại, đồng thời mô tả cách mô hình được lưu trữ, triển khai phục vụ ứng dụng, và định hướng giám sát vận hành sau này.

3.8.1 Xây dựng mô hình

Mã nguồn cài đặt Logistic Regression, Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost. Các tham số chính gồm:

- Decision Tree: độ sâu tối đa 10, tối thiểu 10 mẫu ở lá;
- Random Forest: 300 cây, độ sâu tối đa 15, tối thiểu 5 mẫu ở lá [6];
- XGBoost: 400 cây, độ sâu 6, learning rate 0,05, subsample và colsample bằng 0,8 [9];
- LightGBM: 400 cây, độ sâu 8, learning rate 0,05, subsample và colsample bằng 0,8 [16];
- CatBoost: 400 vòng lặp, độ sâu 6, learning rate 0,05 và hàm mất mát đa lớp [23].

Các giá trị trên được thiết lập cố định trong mã nguồn và không phải kết quả của quá trình tìm kiếm theo lưới. Vì vậy, luận văn không xem các cấu hình này là siêu tham số tối ưu. Đối với bộ A, môi trường tái lập hiện tại khiến Logistic

Regression phát sinh lỗi tương thích giao diện lập trình ứng dụng liên quan đến tham số `multi_class`; do đó, mô hình này chưa được đưa vào bảng kết quả xác nhận chính của bộ A ở Chương 4. Đối với bộ B, cả sáu mô hình, kể cả Logistic Regression, đều chạy thành công trong môi trường dùng để tái lập kết quả của luận văn, nên bảng so sánh chính của bộ B có đầy đủ sáu mô hình.

3.8.2 Hiệu chỉnh mô hình

Kiểm định phân tầng lặp và hiệu chỉnh quyết định

Gọi m_{rf} là Macro-F1 tại lần lặp r và phần kiểm định f . Giá trị tổng hợp được xác định như sau:

$$\bar{m} = \frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F m_{rf}, \quad s_m = \sqrt{\frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F (m_{rf} - \bar{m})^2}.$$

Trong đó $\bar{m}$ là Macro-F1 trung bình và s_m là độ lệch chuẩn theo cách cài đặt `numpy.std` với mẫu số RF . Precision, Recall và F1 từng nhóm được tổng hợp tương tự. `total_support` bằng Rn_c , tức tổng số lần quan sát lớp c xuất hiện trong các tập kiểm định, không phải số khách hàng độc lập mới.

Từ xác suất $\hat{p}_{ic}$, nghiên cứu xem xét hệ số ưu tiên $b_c \geq 1$ đối với lớp hiếm:

$$\hat{y}_i = \arg \max_c (b_c \hat{p}_{ic}).$$

Trong đó $\hat{p}_{ic}$ là xác suất quan sát i thuộc lớp c ; b_c là hệ số ưu tiên, có giá trị mặc định bằng 1; và $\hat{y}_i$ là nhãn sau hiệu chỉnh. Các giá trị $b_c \in \{1, 2, 3, 5, 8, 12, 20\}$ được khảo sát nhằm tối đa hóa Macro-F1. Tuy nhiên, do hệ số được lựa chọn trên cùng tập dữ liệu dùng để hiển thị kết quả, phân tích này có nguy cơ tạo ra ước lượng lạc quan và không được sử dụng làm kết quả kiểm định chính. Trong

triển khai thực tế, hệ số cần được lựa chọn trên tập xác thực riêng, cố định trước khi đánh giá trên tập kiểm tra.

Thiết kế tìm kiếm theo lưới

Bảng so sánh mô hình ở Chương 4 sử dụng một cấu hình siêu tham số cố định cho mỗi thuật toán (Mục 3.8.1). Để đánh giá mức độ nhạy của kết luận đối với lựa chọn siêu tham số, phương pháp tìm kiếm theo lưới được áp dụng cho sáu mô hình trên cả hai bộ dữ liệu. Chiến lược xử lý mất cân bằng và cách chia mẫu được giữ nguyên; chỉ các siêu tham số của bộ phân loại thay đổi. Lưới của bộ A gồm 65 cấu hình (Bảng 3.20); lưới của bộ B gồm 60 cấu hình (Bảng 3.21) và được thu gọn để phù hợp với chi phí tính toán trên 80.493 quan sát huấn luyện. Tổng cộng có 125 cấu hình được khảo sát.

Bảng 3.20: Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu A

Mô hình	Tham số và giá trị thử	Số cấu hình
Decision Tree	$\text{max_depth} \in \{5, 10, 15, 20\}, \text{min_samples_leaf} \in \{5, 10, 20\}$	12
Random Forest	$\text{n_estimators} \in \{100, 300, 500\}, \text{max_depth} \in \{10, 15, 20\}, \text{min_samples_leaf} \in \{5, 10\}$	18
XGBoost	$\text{max_depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,05; 0,1\}$ tại $\text{n_estimators}=400$, cộng $\text{n_estimators} \in \{200, 600\}$ tại cấu hình mặc định	11
LightGBM	tương tự XGBoost	11
CatBoost	$\text{depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,05; 0,1\}$ tại $\text{iterations}=400$	9
Logistic Regression	$C \in \{0,01; 0,1; 1,0; 10,0\}$	4

Bảng 3.21: Không gian tìm kiếm siêu tham số theo từng mô hình — bộ dữ liệu B

Mô hình	Tham số và giá trị thử	Số cấu hình
Logistic Regression	$C \in \{0,01; 0,1; 1,0; 10,0\}$	4
Decision Tree	$\text{max_depth} \in \{5, 8, 12, 20\}, \text{min_samples_leaf} \in \{5, 20\}$	8
Random Forest	$\text{n_estimators} \in \{200, 400\}, \text{max_depth} \in \{10, 20, \text{None}\}, \text{min_samples_leaf} \in \{5, 15\}$	12
XGBoost	$\text{max_depth} \in \{3, 6, 9\} \times \text{learning_rate} \in \{0,03; 0,1\} \times \text{n_estimators} \in \{200, 400\}$	12
LightGBM	tương tự XGBoost	12
CatBoost	$\text{depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,1\} \times \text{iterations} \in \{200, 400\}$	12

Không gian tìm kiếm được xác lập trước dựa trên các giá trị thường dùng của từng họ mô hình và không bao phủ toàn bộ miền siêu tham số. Nghiên cứu cũng chưa áp dụng kiểm định chéo lồng nhau; cấu hình có kết quả cao nhất được lựa chọn trên một tập kiểm định duy nhất, do đó có thể chịu ảnh hưởng của thiên lệch lựa chọn tương tự phân tích theo k đặc trưng. Vì vậy, kết quả này chỉ phản ánh độ nhạy của mô hình trong phạm vi lưới đã khảo sát, không được xem là một phép đối sánh tối ưu toàn diện. Kết quả chi tiết được trình bày tại Mục 4.5 của Chương 4.

3.8.3 Triển khai mô hình

Sau khi huấn luyện, mô hình được lưu trữ bằng pickle trong các tệp có mẫu tên `model_key.pkl`; mô hình có ROC-AUC cao nhất được ghi vào `best_model.txt` để ứng dụng lựa chọn mặc định. Chức năng *Dự báo* sử dụng mô hình đã lưu để tiếp nhận danh sách khách hàng mới ở định dạng Excel hoặc CSV, sau đó trả về nhóm nợ dự báo cùng xác suất thuộc từng nhóm.

Luận văn không quy đổi xác suất dự báo thành một thang điểm số kiểu scorecard (300–850) do chưa có dữ liệu để đối chiếu, kiểm định thang điểm đó với tổn thất thực tế; đầu ra của mô hình được giữ nguyên ở dạng nhóm nợ và xác suất theo từng nhóm, đúng với mục tiêu phân loại đã xác lập ở Chương 1.

3.8.4 Giám sát và bảo trì mô hình

Hệ thống hiện tại chưa triển khai cơ chế giám sát và bảo trì mô hình tự động. Cụ thể, phân bố dữ liệu đầu vào chưa được theo dõi định kỳ, lịch tái huấn luyện chưa được thiết lập và phiên bản dữ liệu, mô hình chưa được lưu vết một cách hệ thống ngoài các tệp mô hình cục bộ. Đây là yêu cầu cần được hoàn thiện trước khi triển khai thực tế. Các nội dung về giám sát Macro-F1, Recall của lớp rủi ro, hiệu chỉnh xác suất, phát hiện thay đổi phân bố và tái huấn luyện được đề xuất tại phần Quản trị mô hình ở Chương 5.

3.9 Bài toán bổ sung: dự báo chuyển nhóm nợ trong 1 tháng (bộ B)

Mục này trình bày phương pháp cho bài toán bổ sung đã xác lập ở Mục 1.3.1 Chương 1: dự báo khả năng một khoản vay chuyển sang nhóm nợ cao hơn trong một tháng, sử dụng đặc trưng tại kỳ báo cáo 20260430 để dự báo nhóm nợ tại kỳ 20260507. Bài toán này chỉ áp dụng cho bộ B vì đây là bộ duy nhất có hai kỳ báo cáo liên tiếp.

3.9.1 Ghép hai kỳ báo cáo và xây dựng nhãn

Hai tệp dữ liệu của bộ B đều chứa trường Số_khế_ước, xác nhận thực nghiệm là khóa duy nhất tuyệt đối ở từng kỳ (không có giá trị trùng lặp ở cả 100.617

dòng của kỳ 20260430 lần 100.274 dòng của kỳ 20260507). Ghép hai tệp theo khóa này (inner join) thu được 98.968 khoản vay xuất hiện ở cả hai kỳ, tương ứng 98,4% số khoản vay của kỳ 20260430. Với mỗi khoản vay khớp được, nhãn chuyển nhóm được xác định:

$$Y_i = \mathbb{I}(G_{i,T+1} > G_{i,T}),$$

giữ đúng ký hiệu đã nêu ở Mục 1.3.1. Toàn bộ cột đặc trưng của $\mathbf{x}_{i,T}$ trong bước ghép này lấy từ tệp kỳ 20260430; tệp kỳ 20260507 chỉ đóng góp duy nhất giá trị nhóm nợ dùng để so sánh, không có cột đặc trưng nào của kỳ 20260507 được đưa vào bước ghép.

Bảng 3.22 trình bày ma trận chuyển nhóm đầy đủ trên 98.968 khoản vay khớp được.

Bảng 3.22: Ma trận chuyển nhóm nợ từ kỳ 20260430 (T) sang kỳ 20260507 (T+1 tháng)

Nhóm tại T	Nhóm tại T+1 tháng				
	1	2	3	4	5
1	87.057	214	0	0	0
2	159	6.123	10	0	0
3	5	0	981	10	0
4	0	0	0	1.411	31
5	2	0	0	0	2.965

Trong 98.968 khoản vay, 265 khoản (0,268%) chuyển sang nhóm rủi ro cao hơn, gồm 214 khoản 1→2, 10 khoản 2→3, 10 khoản 3→4 và 31 khoản 4→5; 166 khoản (0,168%) cải thiện nhóm; phần còn lại (99,56%) giữ nguyên nhóm. Đây là bài toán sự kiện hiếm, khác về bản chất thống kê so với bài toán phân loại 5 nhóm đã trình bày ở các mục trước; thiết kế đánh giá riêng được trình bày ở Mục 3.9.4.

3.9.2 Vì sao đây không phải rò rỉ nhãn

Tập đặc trưng của bài toán chuyển nhóm được xây dựng bằng đúng các hàm đã dùng cho bài toán phân loại tại một thời điểm (Mục 3.6.4), áp dụng lên khung dữ liệu đã ghép: lọc theo phân loại nghiệp vụ `FEATURE_GROUPS`, sau đó sinh bốn đặc trưng kỹ thuật từ ngày giải ngân, ngày kết thúc khế ước và `ETL_DATE`. Vì cột nhóm nợ của kỳ 20260507 không nằm trong danh mục `FEATURE_GROUPS`, cơ chế lọc theo danh sách cho phép (whitelist) loại trừ cột này khỏi tập đặc trưng một cách cấu trúc, không phụ thuộc vào việc người thực hiện có nhớ loại bỏ hay không. Nhờ đó, toàn bộ 20 đặc trưng đưa vào mô hình (12 biến số gồm 4 biến kỹ thuật, và 8 biến phân loại) đều xác định được tại thời điểm T , trước khi kết quả tại $T + 1$ được biết.

Đây là điểm khác biệt căn bản so với việc dùng số ngày quá hạn hiện tại để phân loại lại nhóm nợ hiện tại đã phân tích ở Mục 1.1.3: trường hợp đó là vòng lặp tuần hoàn vì biến đầu vào và nhãn cùng mô tả một thời điểm, biến đầu vào gần như là căn cứ trực tiếp hình thành nhãn. Ở bài toán chuyển nhóm, biến đầu vào mô tả trạng thái tại T còn nhãn mô tả diễn biến đến $T + 1$ tháng sau đó; quan hệ thời gian một chiều này bảo đảm không có thông tin tương lai lọt vào $\mathbf{x}_{i,T}$.

Tuy vậy, cần lưu ý hai điểm khi diễn giải mức độ quan trọng của đặc trưng ở Chương 4. Thứ nhất, các biến phản ánh trạng thái dư nợ và lãi tại T (Số dư nợ theo nguyên tệ, Lãi phải thu hạch toán nội bảng, Lãi chưa thu hạch toán ngoại bảng) có thể đã mang dấu hiệu sớm của suy giảm chất lượng tín dụng; đây chính là tín hiệu dự báo mà bài toán cảnh báo sớm cần khai thác, không phải rò rỉ. Thứ hai, Số lần cơ cấu lại thời hạn trả nợ có thể phản ánh phản ứng của ngân hàng trước dấu hiệu khó khăn đã nhận biết từ

trước, nên tương quan giữa biến này và nhãn chuyển nhóm cần được diễn giải thận trọng, không suy diễn quan hệ nhân quả một chiều.

3.9.3 Rủi ro sai lệch do loại khoản vay không khớp

Nhãn chuyển nhóm chỉ xác định được cho khoản vay khớp ở cả hai kỳ; 1.649 khoản vay của kỳ 20260430 không còn xuất hiện ở kỳ 20260507 (có thể do tắt toán hoặc xóa nợ, hai file không phân biệt được nguyên nhân) bị loại khỏi mẫu. Bảng 3.23 đối chiếu phân bố nhóm nợ tại *T* giữa nhóm bị loại và nhóm được giữ lại.

Bảng 3.23: Phân bố nhóm nợ tại *T* của khoản vay bị loại so với khoản vay được giữ lại

Nhóm tại <i>T</i>	Bị loại	Tỷ lệ trong nhóm bị loại (%)	Được giữ	Tỷ lệ loại trong nhóm (%)
1	1.604	97,27	87.271	1,81
2	29	1,76	6.292	0,46
3	2	0,12	996	0,20
4	4	0,24	1.442	0,28
5	10	0,61	2.967	0,34

Hai cách đọc bảng cho cùng một kết luận. Theo cột thứ ba, 97,27% khoản vay bị loại thuộc nhóm 1 tại *T*; nếu việc loại bỏ chủ yếu do xóa nợ đối với khoản vay chất lượng kém, tỷ lệ này phải nghiêng về nhóm 4–5, không phải nhóm 1. Theo cột cuối, tỷ lệ bị loại tính trên từng nhóm cao nhất ở nhóm 1 (1,81%), không tăng dần theo mức độ rủi ro của nhóm. Cả hai quan sát cùng gợi ý nguyên nhân loại bỏ chủ yếu là tắt toán khoản vay lành mạnh trước hạn, không phải xóa nợ tập trung ở nhóm rủi ro cao; nếu đúng như vậy, việc loại các khoản vay không khớp sẽ không làm mất đi phần lớn các trường hợp chuyển nhóm nghiêm trọng nhất. Tuy nhiên, do không có trường phân biệt trực tiếp nguyên nhân tắt toán trong dữ liệu hiện có, đây vẫn là suy luận gián tiếp từ phân bố quan sát được, không phải

bằng chứng trực tiếp, và được xác định là hạn chế cần lưu ý ở Chương 5.

3.9.4 Thiết kế đánh giá cho sự kiện hiếm

Với tỷ lệ sự kiện dương 0,268% (265/98.968), các chỉ tiêu và cách chia mẫu đã dùng cho bài toán 5 lớp cần điều chỉnh trên ba điểm.

Thứ nhất, Macro-F1 và ngưỡng quyết định mặc định 0,5 không còn phù hợp làm tiêu chí chọn mô hình: một bộ phân loại luôn dự báo “không xấu đi” đã đạt Weighted-F1 xấp xỉ 0,997 mà không mang lại giá trị cảnh báo nào, đúng vấn đề số liệu không phản ánh đúng năng lực mô hình đã nêu ở Mục 1.1.3. Luận văn dùng PR-AUC (*average precision*) làm tiêu chí chính vì nhạy với mất cân bằng hơn ROC-AUC, đồng thời báo cáo Precision/Recall của riêng lớp dương (không lấy trung bình macro) và Recall tại top- $k\%$ hồ sơ có xác suất cao nhất; đây là chỉ tiêu gắn trực tiếp với năng lực rà soát thực tế của ngân hàng, không phụ thuộc việc chọn ngưỡng xác suất.

Thứ hai, đánh giá chính dựa trên kiểm định chéo phân tầng lặp lại (RepeatedStratifiedKFold, 5 phần $\times$ 10 lần lặp, cùng thiết kế với Mục 3.8.2), không dựa trên một lần chia 80/20 duy nhất: mỗi phần kiểm định trong 5 phần chỉ chứa khoảng 53 sự kiện dương, nên một lần chia đơn có thể phản ánh may rủi của riêng lần chia đó hơn là năng lực thật của mô hình. Một lần chia 80/20 minh họa vẫn được thực hiện để tạo ma trận nhầm lẫn, đường cong Precision-Recall và giải thích SHAP, nhưng bằng chứng chính về hiệu năng là kết quả kiểm định chéo lặp lại.

Thứ ba, khác với bài toán phân loại tại một thời điểm, nơi kỳ 20260507 đóng vai trò tập kiểm tra độc lập ngoài thời gian (Mục 4.4.3), bài toán chuyển nhóm

chỉ có đúng một cặp $(T, T + 1)$ vì đã dùng cả hai kỳ báo cáo để ghép nhãn. Do đó, luận văn chưa có tầng đánh giá ngoài thời gian thứ ba cho riêng bài toán này; khả năng tổng quát hóa sang các cặp kỳ báo cáo khác chưa được kiểm định và được xác định là hạn chế ở Chương 5.

Ba chiến lược xử lý mất cân bằng được so sánh: không xử lý, trọng số lớp nghịch đảo tần suất (`class_weight`), và SMOTE với mục tiêu oversample vừa phải cho lớp thiểu số. Do CatBoost ánh xạ mọi chiến lược khác none về cùng cơ chế `auto_class_weights=Balanced` (Mục 3.7.2), chiến lược SMOTE không tạo thêm khác biệt so với `class_weight` đối với riêng mô hình này nên chỉ hai chiến lược được so sánh cho CatBoost. Kết quả đối sánh được trình bày tại Chương 4.

3.10 Tóm tắt chương

Chương 3 đã trình bày dữ liệu, công nghệ và các bước phương pháp được sử dụng trong nghiên cứu, gồm phân tích khám phá, làm sạch, kiểm soát rò rỉ, xây dựng đặc trưng, tính IV, xử lý giá trị thiếu, mã hóa, chuẩn hóa, chia mẫu có phân tầng và xử lý mất cân bằng lớp bằng SMOTE hoặc trọng số lớp. Tập đặc trưng cuối cùng gồm 11 biến (cấu hình chính) hoặc 13 biến (cấu hình mở rộng) đối với bộ A, và 20 biến đối với bộ B; sáu thuật toán được xây dựng và đánh giá, kết hợp kiểm định chéo phân tầng lặp lại và khảo sát 125 cấu hình siêu tham số. Các lựa chọn kỹ thuật then chốt, gồm điền khuyết bằng trung vị, giới hạn `UTIL_RATE` trong khoảng $[0, 10]$, ngưỡng IV bằng 0,02 và mốc `ETL_DATE` cho các biến thời gian của bộ B, đều được xác lập trên cơ sở đặc điểm thống kê và ý nghĩa nghiệp vụ của dữ liệu đã trình bày ở trên.

Chương cũng trình bày phương pháp cho bài toán bổ sung dự báo chuyển nhóm nợ trong 1 tháng trên bộ B: ghép 98.968 khoản vay khớp giữa hai kỳ báo cáo qua khóa Số khế ước, xây nhãn từ diễn biến nhóm nợ $T \rightarrow T + 1$ tháng (265 sự kiện dương, 0,268%), lập luận vì sao thiết kế này không rò rỉ nhãn, và điều chỉnh thiết kế đánh giá phù hợp với sự kiện hiếm (PR-AUC, Recall@k, kiểm định chéo lặp lại).

Trên cơ sở quy trình phương pháp nêu trên, Chương 4 trình bày hệ thống thước đo, kết quả đối sánh mô hình, hiệu quả theo số lượng đặc trưng, mức đóng góp của các nhóm đặc trưng, kết quả giải thích bằng SHAP, độ nhạy của siêu tham số, và kết quả của bài toán dự báo chuyển nhóm nợ.

Chương 4

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

Trong chương này, luận văn trình bày và thảo luận các kết quả thu được từ quy trình thực nghiệm đã mô tả ở Chương 3. Trước hết, chương xác lập nguyên tắc báo cáo và hệ thống thước đo nhằm bảo đảm việc so sánh mô hình được thực hiện nhất quán. Tiếp theo, kết quả trên từng bộ dữ liệu được phân tích riêng theo hiệu quả phân loại, số lượng đặc trưng, đóng góp của các nhóm thông tin và khả năng giải thích bằng SHAP. Chương đồng thời đánh giá độ nhạy của siêu tham số và khả năng tổng quát hóa trên kỳ dữ liệu độc lập. Trên cơ sở các bằng chứng thực nghiệm, bốn câu hỏi nghiên cứu được trả lời và ý nghĩa của kết quả đối với định hướng xây dựng hệ thống cảnh báo sớm được thảo luận. Nội dung chương là căn cứ trực tiếp cho các kết luận và kiến nghị ở Chương 5.

4.1 Nguyên tắc báo cáo kết quả

Các kết quả định lượng trong chương được tái lập trực tiếp từ tệp `Data_credit_rating_VN.xlsx` và hai tệp `Thông tin tín dụng 20260430.xlsx/Thông`

tin_tin_dung_20260507.xlsx bằng các hàm trong thư mục src. Bộ dữ liệu A được phân chia theo tỷ lệ 80/20 có phân tầng, với tham số `random_state=42`. Bộ dữ liệu B được đánh giá theo hai tầng: 80/20 có phân tầng trên kỳ 20260430 (dùng để so sánh và chọn mô hình), cộng thêm một lần đánh giá bổ sung trên toàn bộ kỳ 20260507 (hoàn toàn tách biệt, không tham gia huấn luyện hay lựa chọn mô hình) để ước lượng khả năng tổng quát hóa ngoài thời gian. Do có sự khác biệt về biến đích, quy mô mẫu, phân bố lớp và không gian đặc trưng, kết quả của từng bộ dữ liệu được trình bày và diễn giải riêng biệt.

Đối với bộ A, bảng so sánh mô hình sử dụng 11 biến trong cấu hình chính và chiến lược `smote_moderate`; phân tích theo số lượng biến được thực hiện trên tập 13 biến. Đối với bộ B, bảng so sánh sử dụng 20 đặc trưng và chiến lược SMOTE tùy chỉnh; thí nghiệm với k đặc trưng quan trọng nhất cũng dùng chiến lược SMOTE tùy chỉnh này. Vì vậy, mỗi kết quả chỉ có ý nghĩa trong cấu hình thực nghiệm tương ứng và không được xem là kết quả của quá trình tìm kiếm siêu tham số.

Trong môi trường thử nghiệm được sử dụng để tái lập kết quả, Logistic Regression phát sinh lỗi tương thích giao diện lập trình ứng dụng liên quan đến tham số `multi_class` khi chạy trên bộ A. Do đó, bảng so sánh chính của bộ A chỉ báo cáo kết quả của năm mô hình được thực thi thành công. Đối với bộ B, lỗi này không xuất hiện trong môi trường hiện tại nên bảng so sánh chính có đầy đủ sáu mô hình. Hạn chế kỹ thuật riêng của bộ A cần được lưu ý khi diễn giải mức độ đầy đủ của phép so sánh trên bộ đó.

4.2 Thước đo đánh giá

4.2.1 Ma trận nhầm lẫn đa lớp

Với $K = 5$ lớp, phần tử C_{ab} của ma trận nhầm lẫn là số quan sát có lớp thực a nhưng được dự báo thành lớp b . Đường chéo C_{aa} là số dự báo đúng của lớp a . Trong bài toán này, ma trận đa lớp phù hợp hơn cách ký hiệu TP–TN của bài toán nhị phân.

4.2.2 Precision, Recall và F1 theo lớp

Với lớp k :

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k},$$
$$F1_k = \frac{2P_k R_k}{P_k + R_k}.$$

Trong đó TP_k là số quan sát lớp k được dự báo đúng; FP_k là số quan sát thuộc lớp khác nhưng bị dự báo thành k ; FN_k là số quan sát lớp k bị dự báo sang lớp khác; P_k là Precision; R_k là Recall.

Macro-F1 cho trọng số bằng nhau cho năm lớp:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k,$$

trong đó $K = 5$. Weighted-F1 dùng tỷ trọng hỗ trợ:

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k,$$

trong đó n_k là số quan sát thực của lớp k và $N = \sum_k n_k$. Ở bộ B, nhóm 1 chiếm 88,34% (Bảng 3.3), nên Weighted-F1 vẫn có thể ở mức cao dù Recall của các

nhóm hiếm thấp hơn nhiều; vì vậy Macro-F1 được ưu tiên làm tiêu chí chính. Bộ A cân bằng hơn nhưng nhóm 1 vẫn chiếm 77,65%, nên cùng nguyên tắc báo cáo được áp dụng.

4.2.3 Accuracy và ROC-AUC đa lớp

$$\text{Accuracy} = \frac{\sum_{k=1}^K C_{kk}}{N}.$$

Accuracy là tỷ lệ tổng dự báo đúng nhưng bị chi phối bởi lớp 1.

Code tính ROC-AUC theo One-vs-Rest và lấy trung bình macro:

$$\text{AUC}_{\text{macro, OvR}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}(y^{(k)}, \hat{p}^{(k)}),$$

trong đó $y^{(k)}$ là nhãn nhị phân “thuộc/không thuộc lớp k ”; $\hat{p}^{(k)}$ là xác suất dự báo cho lớp k ; và AUC đo khả năng xếp hạng giữa mẫu dương và âm [13].

Ngoài bốn chỉ tiêu trên, Chương 3 (mục 3.8.2) đã trình bày cơ chế `RepeatedStratifiedKFold` và hiệu chỉnh ngưỡng theo lớp, hai công cụ hỗ trợ ước lượng ổn định hơn cho các nhóm nọ hiếm; hai công cụ này được nhắc lại khi cần trong các mục kết quả dưới đây.

4.3 Kết quả trên bộ dữ liệu A

4.3.1 So sánh mô hình trên bộ 11 đặc trưng

Bảng 4.1: Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Decision Tree	0,8847	0,5896	0,8786	0,8765
Random Forest	0,9052	0,6179	0,8917	0,9182
XGBoost	0,9096	0,6442	0,8982	0,9201
LightGBM	0,9113	0,6484	0,9001	0,9181
CatBoost	0,7497	0,5454	0,8033	0,9006

LightGBM đạt Macro-F1 cao nhất (0,6484), tiếp theo là XGBoost (0,6442). XGBoost đồng thời đạt ROC-AUC macro cao nhất (0,9201). Do mô-đun phân tích đặc trưng trong mã nguồn sử dụng XGBoost làm cấu hình mặc định, các phân tích tiếp theo đối với bộ A được thực hiện trên mô hình này nhằm bảo đảm tính nhất quán với quy trình thực nghiệm.

4.3.2 Hiệu năng theo số lượng đặc trưng

Bảng 4.2: Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A

k	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
3	0,9021	0,6152	0,8873	0,8874
5	0,9022	0,6184	0,8878	0,8887
7	0,9019	0,6212	0,8887	0,9014
9	0,9093	0,6383	0,8975	0,9203
11	0,9074	0,6364	0,8958	0,9223
13	0,9098	0,6434	0,8977	0,9192

Trong các tập gồm k đặc trưng quan trọng nhất, tập đầy đủ 13 biến đạt Macro-F1 cao nhất; tuy nhiên, đường cong hiệu quả không tăng đơn điệu, thể hiện ở việc

tập 11 biến đứng đầu cho kết quả thấp hơn tập 9 biến đứng đầu. Khi huấn luyện theo đúng danh sách 11 biến của cấu hình chính, thay vì lựa chọn 11 biến có mức độ quan trọng cao nhất, XGBoost đạt Macro-F1 bằng 0,6442, cao hơn mức 0,6434 của tập 13 biến. Weighted-F1 tăng từ 0,8977 lên 0,8982 và ROC-AUC tăng từ 0,9192 lên 0,9201. Như vậy, việc bổ sung lại hai biến SEX và LOAIKH không tạo ra mức cải thiện đáng kể trong phép chia dữ liệu này.

Tỷ lệ Macro-F1 của cấu hình 9 biến so với tập đầy đủ được xác định như sau:

$$\rho_{A,9} = \frac{0,6383}{0,6434} \approx 0,9920,$$

tương ứng khoảng 99,20% Macro-F1 của tập 13 biến trong cùng quy trình đánh giá. Đây là mốc nhỏ nhất trong phạm vi các giá trị k đã khảo sát đạt ít nhất 99%, nhưng không chứng minh rằng chín là số biến tối thiểu trên toàn bộ không gian lựa chọn.

4.3.3 Nhóm đặc trưng và chỉ số ưu tiên dữ liệu

Bảng 4.3: Tỷ trọng mức độ quan trọng theo nhóm nghiệp vụ của bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng (%)
Kỳ hạn khoản vay	40,1
Sản phẩm và mục đích vay	21,9
Dư nợ và hạn mức sử dụng	12,9
Đơn vị/Chi nhánh	9,4
Nhân khẩu học có IV thấp	8,1
Lãi suất	7,6

Hai biến DAYS_TO_MATURITY và LOAN_TENURE_DAYS có mức độ quan trọng lần lượt bằng 24,48% và 15,63%, đưa tổng tỷ trọng của nhóm Kỳ hạn khoản vay lên 40,1%. Nhóm Sản phẩm và mục đích vay có tỷ trọng lớn thứ hai, đạt 21,9%.

Đường cong tích lũy cần 12 trong tổng số 13 biến để đạt 95% mức độ quan trọng và cần toàn bộ 13 biến để đạt 99%. Kết quả này không mâu thuẫn với việc cấu hình 9 biến duy trì 99,20% Macro-F1, bởi mức độ quan trọng tích lũy và hiệu quả dự báo ngoài mẫu là hai đại lượng khác nhau.

Các nhóm đặc trưng của bộ A hầu như không có giá trị thiếu; riêng nhóm Nhân khẩu học có IV thấp ghi nhận tỷ lệ thiếu trung bình 2,05%. Do đó, việc chỉ số quy ước xếp nhóm Kỳ hạn khoản vay ở vị trí đầu chủ yếu xuất phát từ mức độ quan trọng của nhóm, không phải từ sự thiếu hụt dữ liệu. Kết quả này gợi ý ngân hàng cần duy trì chất lượng các trường ngày và phát triển dữ liệu lịch sử theo thời gian, thay vì chỉ bổ sung thêm các trường kỳ hạn tĩnh.

4.4 Kết quả trên bộ dữ liệu B

4.4.1 Mức độ mất cân bằng và hệ quả đánh giá

Tập kiểm định (20% của kỳ 20260430) gồm 20.124 quan sát, trong đó nhóm 1 có 17.776 quan sát. Một bộ phân loại luôn dự báo nhóm 1 đã có Accuracy:

$$\text{Accuracy}_{\text{majority}} = \frac{17.776}{20.124} = 0,8834.$$

Trong đó 17.776 là số mẫu nhóm 1 và 20.124 là tổng số mẫu kiểm định. Trên tập kiểm tra độc lập 20260507, tỷ lệ tương ứng là $88.527/100.274 = 0,8829$, gần như không đổi so với kỳ huấn luyện và xác nhận phân phối lớp ổn định giữa hai kỳ báo cáo. Vì vậy, Accuracy khoảng 88% chưa đủ để chứng minh mô hình nhận diện được rủi ro. Kết quả cần được đọc cùng Macro-F1 và Recall từng nhóm, phù hợp cảnh báo của Brown và Mues về đánh giá dữ liệu tín dụng mất cân bằng [7].

4.4.2 So sánh các mô hình

Bảng 4.4: Kết quả ngoài mẫu của các mô hình trên 20 đặc trưng — tập kiểm định (20% kỳ 20260430)

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Logistic Regression	0,8151	0,4186	0,8716	0,8713
Decision Tree	0,9350	0,6590	0,9158	0,9129
Random Forest	0,9333	0,6568	0,9157	0,9371
XGBoost	0,9350	0,6941	0,9205	0,9401
LightGBM	0,9367	0,6954	0,9207	0,9411
CatBoost	0,8236	0,6046	0,7673	0,9195

Khác với bộ A, cả sáu mô hình đều được thực thi thành công trên bộ B. LightGBM đạt Macro-F1 cao nhất, bằng 0,6954, trong khi XGBoost đạt 0,6941; mức chênh lệch 0,0013 là tương đối nhỏ so với biên độ biến động theo siêu tham số tại Mục 4.5. LightGBM đồng thời đạt ROC-AUC macro cao nhất, bằng 0,9411, nên được lựa chọn cho các phân tích tiếp theo về đặc trưng và SHAP. Logistic Regression và CatBoost có Macro-F1 thấp hơn các mô hình dựa trên cây còn lại trong cấu hình thực nghiệm này.

4.4.3 Đánh giá trên tập kiểm tra độc lập (20260507)

Bên cạnh tập kiểm định nội bộ, bộ B được đánh giá bổ sung trên toàn bộ 100.274 hồ sơ của kỳ báo cáo kế tiếp, 20260507. Quy trình tiền xử lý và mô hình đã được ước lượng từ kỳ 20260430 được giữ nguyên, không huấn luyện lại trên dữ liệu mới. Kết quả được trình bày tại Bảng 4.5.

Bảng 4.5: Kết quả trên tập kiểm tra độc lập 20260507 (không tham gia huấn luyện/chọn mô hình)

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Logistic Regression	0,7583	0,3543	0,8569	0,8264
Decision Tree	0,8990	0,4693	0,8807	0,8354
Random Forest	0,9214	0,5142	0,8928	0,8959
XGBoost	0,9147	0,4989	0,8910	0,9205
LightGBM	0,9143	0,4952	0,8910	0,9232
CatBoost	0,7930	0,4105	0,7682	0,9045

Thứ hạng mô hình thay đổi giữa hai tầng đánh giá. LightGBM có Macro-F1 cao nhất trên tập kiểm định nội bộ (0,6954) nhưng đạt 0,4952 trên tập kiểm tra độc lập; Random Forest tăng từ vị trí thứ tư trên tập kiểm định (0,6568) lên mức cao nhất trên tập kiểm tra độc lập (0,5142). Macro-F1 của cả sáu mô hình đều giảm khi chuyển sang kỳ dữ liệu mới; riêng LightGBM giảm 28,8%. ROC-AUC macro của LightGBM và XGBoost giảm ít hơn Macro-F1, lần lượt từ 0,9411 xuống 0,9232 và từ 0,9401 xuống 0,9205. Điều này cho thấy khả năng xếp hạng xác suất được duy trì tốt hơn chất lượng của nhãn phân loại tại ngưỡng quyết định hiện hành. Kết quả cung cấp bằng chứng rằng phép chia ngẫu nhiên có phân tầng trong cùng một kỳ dữ liệu có thể tạo ra ước lượng lạc quan về khả năng tổng quát hóa theo thời gian, qua đó củng cố yêu cầu chia mẫu theo thời gian đối với bài toán dự báo chuyển nhóm nợ.

4.4.4 Kết quả chi tiết theo nhóm nợ

Bảng 4.6 trình bày Precision, Recall, F1 của LightGBM, mô hình dẫn đầu tập kiểm định, trên cả hai tầng đánh giá.

Bảng 4.6: Precision, Recall và F1 của LightGBM theo nhóm nợ — tập kiểm định vs. tập kiểm tra độc lập

Nhóm	Kiểm định (20% kỳ 20260430)				Kiểm tra độc lập (20260507)			
	Số mẫu	Precision	Recall	F1	Số mẫu	Precision	Recall	F1
1	17.776	0,9453	0,9989	0,9713	88.527	0,9412	0,9876	0,9639
2	1.264	0,8119	0,1946	0,3140	6.339	0,8060	0,1737	0,2858
3	200	0,5977	0,5200	0,5562	991	0,2800	0,5197	0,3640
4	289	0,7153	0,7128	0,7140	1.421	0,3330	0,8079	0,4717
5	595	0,9374	0,9059	0,9214	2.996	0,9973	0,2430	0,3908

Với từ 200 đến 1.421 quan sát ở mỗi nhóm hiểm tùy theo tầng đánh giá, Recall trong Bảng 4.6 có độ tin cậy cao hơn trường hợp chỉ có một số ít quan sát. Tuy nhiên, các chỉ tiêu vẫn có thể chịu ảnh hưởng của khác biệt phân bố giữa hai kỳ dữ liệu.

Trên tập kiểm định, mô hình cân bằng khá tốt giữa các nhóm: Recall nhóm 3 (0,52) và nhóm 4 (0,71) đều ở mức chấp nhận được, nhóm 5 đạt 0,91. Trên tập kiểm tra độc lập, bức tranh đối khác rõ rệt: Recall nhóm 5 sụt mạnh từ 0,91 xuống 0,24, cho thấy mô hình bỏ sót phần lớn hồ sơ nhóm rủi ro cao nhất ở kỳ báo cáo mới; trong khi đó, Recall nhóm 3 và 4 tăng lên (0,52→0,52 và 0,71→0,81) nhưng đổi lại Precision giảm mạnh (nhóm 3: 0,60→0,28; nhóm 4: 0,72→0,33), tức mô hình cảnh báo nhóm 3/4 nhiều hơn nhưng kém chính xác hơn. Nhóm 2 giữ Recall thấp ở cả hai tầng (khoảng 0,17–0,19), là nhóm mô hình khó nhận diện nhất trong toàn bộ năm nhóm.

So sánh Recall trên tập kiểm định giữa các mô hình cho thấy:

- Decision Tree: nhóm 3 đạt 0,555, nhóm 4 đạt 0,668;
- Random Forest: nhóm 3 đạt 0,470, nhóm 4 đạt 0,585;
- XGBoost: nhóm 3 đạt 0,545, nhóm 4 đạt 0,706;

- LightGBM: nhóm 3 đạt 0,520, nhóm 4 đạt 0,713;
- CatBoost: Recall trung bình các nhóm hiếm cao hơn nhưng Accuracy/Weighted-F1 thấp hơn hẳn (0,8236/0,7673) do phát sinh nhiều cảnh báo sai hơn, cùng cơ chế `auto_class_weights=Balanced` đã quan sát được ở bộ A.

CatBoost minh họa rõ đánh đổi giữa phát hiện lớp thiểu số và số cảnh báo sai. Do đó, lựa chọn mô hình triển khai không nên chỉ dựa vào một thứ hạng chung; ngân hàng cần xác định chi phí bỏ sót và chi phí rà soát. Theo phát hiện ở Mục 4.4.3, ngân hàng cũng không nên chỉ dựa vào thứ hạng trên tập kiểm định cùng kỳ dữ liệu.

4.4.5 Đánh giá các lớp hiếm bằng quy trình kiểm định lặp

Quy trình kiểm định chéo phân tầng lặp lại báo cáo giá trị trung bình và độ lệch chuẩn của Precision, Recall và F1 theo từng lớp qua nhiều lần chia mẫu. Với cấu hình 3×5 phần, mỗi hồ sơ thuộc nhóm 3 và 4 xuất hiện trong phần kiểm định ba lần qua các lượt lặp. Cách tiếp cận này làm giảm mức độ phụ thuộc của ước lượng vào một lần chia mẫu, nhưng không làm tăng số khách hàng độc lập và không thể thay thế dữ liệu ngoài thời gian.

Đối với XGBoost, trọng số nghịch đảo tần suất được tính và truyền riêng trong từng phần huấn luyện của kiểm định chéo. Tuy nhiên, Bảng 4.4 sử dụng chiến lược SMOTE tùy chỉnh, nên cơ chế trọng số không ảnh hưởng trực tiếp đến các kết quả được báo cáo trong bảng này.

Phân tích hiệu chỉnh lớp hiếm nhân xác suất dự báo của từng lớp với một hệ số trước khi áp dụng phép `arg max`. Đây là phân tích độ nhạy đối với sự đánh đổi giữa Precision và Recall, không phải một mô hình độc lập. Do hệ số được

lựa chọn trên chính tập đánh giá, Macro-F1 sau hiệu chỉnh không được đưa vào bảng kết quả chính. Một thiết kế chặt chẽ hơn cần tách riêng tập huấn luyện, tập xác thực và tập kiểm tra; hệ số được lựa chọn trên tập xác thực và chỉ đánh giá một lần trên tập kiểm tra.

4.4.6 Hiệu năng theo số lượng đặc trưng

Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Các đặc trưng được sắp xếp theo mức độ quan trọng của mô hình LightGBM sử dụng tập đầy đủ. Mô hình sau đó được huấn luyện lại với từng giá trị k , trong khi chiến lược SMOTE được giữ nguyên. Kết quả được trình bày tại Bảng 4.7.

Bảng 4.7: Hiệu năng LightGBM theo số lượng đặc trưng Top- k

k	Macro-F1	ROC-AUC macro
3	0,2989	0,8136
5	0,4346	0,8719
8	0,6967	0,9408
11	0,6957	0,9411
14	0,6969	0,9406
17	0,7031	0,9406
20 (đầy đủ)	0,6954	0,9411

Bảng 4.7 cho thấy cấu hình 17 đặc trưng đạt Macro-F1 cao nhất, bằng 0,7031, so với 0,6954 của tập đầy đủ 20 biến. Cấu hình 8 đặc trưng, tương ứng 40% số biến, đạt Macro-F1 bằng 0,6967 và cũng cao hơn tập đầy đủ. Các kết quả tại $k = 8, 11, 14, 17$ nằm trong khoảng 0,695–0,703, cho thấy hiệu quả thay đổi không đáng kể trong khoảng này. Ngược lại, Macro-F1 giảm rõ rệt tại $k = 3$ và $k = 5$, lần lượt bằng 0,2989 và 0,4346. Trong phạm vi phép chia mẫu hiện tại, kết quả cho thấy việc bổ sung đặc trưng không tất yếu cải thiện hiệu quả và mô

hình vẫn cần một số lượng đặc trưng tối thiểu.

So với bộ A, kết quả của bộ B cung cấp bằng chứng rõ hơn về tính không đơn điệu giữa số lượng đặc trưng và hiệu quả dự báo. Tuy nhiên, chưa thể quy phần chênh lệch hoàn toàn cho nhiễu của từng biến, bởi các cấu hình được lựa chọn và đánh giá trên cùng một tập kiểm định.

Các giá trị k được khảo sát và lựa chọn trên cùng tập kiểm định gồm 20.124 hồ sơ. Vì vậy, đường cong chỉ có ý nghĩa khám phá và thiên lệch lựa chọn (selection bias) vẫn áp dụng như đã nêu ở bộ A. Cấu hình rút gọn được lựa chọn từ kết quả này cần được xác định trước và đánh giá lại trên tập kiểm tra độc lập 20260507 hoặc quy trình xác thực lồng nhau trước khi khuyến nghị triển khai.

Có thể giảm còn bao nhiêu đặc trưng?

Theo mức độ quan trọng tích lũy của LightGBM, 8 đặc trưng đầu tiên chiếm 95% và 13 đặc trưng chiếm 99% tổng mức độ quan trọng. Mức độ tập trung này cao hơn so với bộ A, nơi cần lần lượt 12 và 13 đặc trưng để đạt hai ngưỡng tương ứng. Tại $k = 8$, tỷ lệ Macro-F1 so với tập đầy đủ ($k = 20$) là:

$$\rho_8 = \frac{0,6967}{0,6954} \approx 1,0019.$$

Trong đó 0,6967 là Macro-F1 của cấu hình 8 biến và 0,6954 là Macro-F1 của tập đầy đủ 20 biến trong cùng quy trình đánh giá. Chênh lệch quan sát được là nhỏ và cần được kiểm định lại trước khi khái quát.

Do đó, cấu hình 8 trong tổng số 20 đặc trưng được xem là một ứng viên rút gọn vì không làm giảm Macro-F1 trên tập kiểm định. Cấu hình này cần được xác nhận trên tập kiểm tra độc lập kỳ 20260507 hoặc bằng quy trình xác thực lồng nhau trước khi đưa ra khuyến nghị triển khai.

Ở cấp dữ liệu thô, quy trình đã giảm từ 33 cột chung giữa hai kỳ báo cáo xuống 20 đặc trưng hợp lệ, tương đương loại:

$$\frac{33 - 20}{33} \times 100\% \approx 39,39\%.$$

Mức giảm này chủ yếu bắt nguồn từ việc loại bỏ các trường định danh, trường có nguy cơ rò rỉ thông tin, trường ngày ban đầu và một cột hằng số, thay vì từ quá trình lựa chọn dựa trên hiệu quả dự báo. Số cột chung giữa hai kỳ cũng bị giới hạn bởi cấu trúc dữ liệu thực tế (Mục 3.6.4).

4.4.7 Đóng góp của các nhóm đặc trưng

Bảng 4.8: Tỷ trọng mức độ quan trọng của LightGBM theo nhóm nghiệp vụ (Gain)

Nhóm nghiệp vụ	Tỷ trọng (%)
Đặc trưng kỹ thuật	37,2
Dư nợ & Thanh toán	30,8
Chi nhánh	15,3
Lãi suất	12,7
Hình thức & Mục đích vay	2,9
Kỳ hạn & Cơ cấu lại	1,1

Theo Gain, nhóm Đặc trưng kỹ thuật gồm bốn biến được xây dựng tại Chương 3 chiếm 37,2% tổng mức độ quan trọng, tiếp theo là nhóm Dư nợ & Thanh toán với 30,8%. Kết quả cho thấy các đặc trưng thời gian, gồm tuổi khoản vay, số ngày đến đáo hạn và kỳ hạn thực tế, chứa thông tin dự báo đáng kể. Nhóm Chi nhánh và Lãi suất lần lượt chiếm 15,3% và 12,7%; hai nhóm Hình thức & Mục đích vay và Kỳ hạn & Cơ cấu lại đều có tỷ trọng dưới 3%.

Kết quả phản ánh mức độ mô hình sử dụng từng nhóm, nhưng chưa lượng hóa đầy đủ giá trị biên của nhóm đó. Mức độ quan trọng có thể được

chia sẻ giữa các biến tương quan, đặc biệt là ENG_DAYS_TO_MATURITY và ENG_TENOR_ACTUAL_DAYS với $r = 0,975$. Để củng cố kết luận, cần thực hiện thí nghiệm loại bỏ lần lượt từng nhóm và đo thay đổi Macro-F1 ngoài mẫu.

4.4.8 Ưu tiên đầu tư dữ liệu

Nhóm Đặc trưng kỹ thuật và nhóm Dư nợ & Thanh toán đều có tỷ lệ thiếu trung bình bằng 0,00%. Vì vậy, chỉ số ưu tiên của hai nhóm chủ yếu phản ánh mức độ quan trọng và hệ số nền 0,1 trong công thức $Priority_g = S_g(M_g/100 + 0,1)$, không phản ánh khoảng trống về tính đầy đủ của dữ liệu. Theo chỉ số quy ước, ba nhóm có giá trị cao nhất là:

1. Đặc trưng kỹ thuật: mức độ quan trọng 37,2%, tỷ lệ thiếu 0,00%, chỉ số ưu tiên 3,72;
2. Dư nợ & Thanh toán: mức độ quan trọng 30,8%, tỷ lệ thiếu 0,00%, chỉ số ưu tiên 3,08;
3. Chi nhánh: mức độ quan trọng 15,3%, tỷ lệ thiếu 0,00%, chỉ số ưu tiên 1,53.

Nhóm Kỳ hạn & Cơ cấu lại có tỷ lệ thiếu 74,79%, nhưng chỉ chiếm 1,1% tổng mức độ quan trọng nên có chỉ số ưu tiên thấp nhất, bằng 0,93. Do các nhóm có mức độ quan trọng cao đã tương đối đầy đủ, kiến nghị tập trung vào duy trì chất lượng ngày giải ngân, ngày kết thúc kế ước và chuẩn hóa các trường dư nợ, lãi phải thu hoặc chưa thu, theo đúng bản chất quy ước, chưa phải hàm lợi ích kinh tế, của chỉ số này đã nêu tại Mục 3.6.8 Chương 3.

4.4.9 Giải thích mô hình và giới hạn của mức độ quan trọng

Mã nguồn hỗ trợ SHAP, dựa trên giá trị Shapley và mô hình cộng tính $f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j$ đã trình bày tại Mục 2.3.2 Chương 2, trong đó $\phi_j > 0$ làm đầu ra của lớp đang xét tăng so với giá trị nền ϕ_0 , còn $\phi_j < 0$ làm giảm [18].

SHAP giải thích cách mô hình hình thành dự báo, nhưng không chứng minh rằng thay đổi một biến sẽ gây ra thay đổi rủi ro. Các biến về số dư và giải ngân có tương quan có thể chia sẻ mức độ đóng góp. Vì vậy, kết luận nghiệp vụ cần kết hợp SHAP, phân tích độ ổn định và nhận định của chuyên gia.

Kết quả SHAP trên bộ dữ liệu A

SHAP được tính bằng TreeExplainer cho đúng mô hình XGBoost đã dùng ở bảng so sánh chính (11 biến, smote_moderate), trên toàn bộ 5.401 quan sát kiểm định. Bảng 4.9 liệt kê trung bình $|\phi_j|$ của từng biến trên cả năm lớp.

Bảng 4.9: Importance theo SHAP (trung bình $|\phi_j|$) — bộ dữ liệu A

Biến	Trung bình $ \phi_j $
DAYS_TO_MATURITY	0,8489
UTIL_RATE	0,3217
LOAN_TENURE_DAYS	0,2652
CURR_BAL	0,2493
LAISUAT	0,2404
PARENTORGNBR	0,2219
ORGNBR	0,2176
BASE_BAL	0,1903
CURRMIACTTYP	0,1419
MUCDICHVAY	0,0699
MJACCTTYP	0,0220

DAYS_TO_MATURITY vượt trội các biến còn lại theo SHAP, phù hợp việc nó đứng đầu bảng importance dạng Gain ở Bảng 4.3. Quy về nhóm nghiệp vụ (Bảng

4.10), Kỳ hạn khoản vay vẫn đứng đầu với 39,9%, gần như trùng khớp 40,1% theo Gain, cho thấy kết luận “kỳ hạn là nhóm quan trọng nhất của bộ A” ổn định qua hai phương pháp đo importance khác nhau.

Bảng 4.10: Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng SHAP (%)
Kỳ hạn khoản vay	39,9
Dư nợ và hạn mức sử dụng	27,3
Đơn vị/Chi nhánh	15,8
Lãi suất	8,6
Sản phẩm và mục đích vay	8,4

Tuy nhiên, hai nhóm còn lại đổi thứ hạng đáng kể: Dư nợ và hạn mức sử dụng tăng từ 12,9% (Gain) lên 27,3% (SHAP), trong khi Sản phẩm và mục đích vay giảm từ 21,9% xuống 8,4%. Khác biệt này phù hợp với đặc điểm biến MUCDICHVAY có 79 danh mục: Gain-importance của XGBoost cộng dồn theo số lần một biến được dùng để chia nhánh, nên biến phân loại nhiều danh mục có xu hướng được chọn làm điểm chia thường xuyên hơn dù mức đóng góp thực tế theo từng dự báo (đo bằng SHAP) không lớn tương ứng; đây là thiên lệch đã được ghi nhận với các thước đo importance dựa trên cấu trúc cây [18]. Vì vậy, luận văn khuyến nghị dùng SHAP làm căn cứ chính khi so sánh nhóm nghiệp vụ, chỉ dùng Gain như tham chiếu bổ sung.

Kết quả SHAP trên bộ dữ liệu B

Với bộ B, SHAP được tính trên mô hình LightGBM 20 biến, SMOTE tùy chỉnh, lấy mẫu tối đa 500 quan sát kiểm định. Bảng 4.11 liệt kê toàn bộ 20 biến, xếp giảm dần theo $|\phi_j|$ trung bình.

Bảng 4.11: Importance theo SHAP (trung bình $|\phi_j|$) — bộ dữ liệu B

Biến	$ \phi_j $	Biến	$ \phi_j $
Lãi chưa thu hạch toán ngoại bảng	1,0870	Mục đích SD tiền vay (ngành KT)	0,0488
ENG_LOAN_AGE_DAYS	0,8514	Mô tả mục đích SD tiền vay	0,0467
Số dư nợ theo nguyên tệ	0,2482	Mã thời hạn cấp tín dụng	0,0345
ENG_DAYS_TO_MATURITY	0,2461	Phương thức cho vay	0,0272
Lãi suất	0,2193	Kênh điện tử	0,0078
ENG_TENOR_ACTUAL_DAYS	0,1882	ENG_HAS_RESTRUCTURE	0,0025
Mã chi nhánh TCTD	0,1844	Số tiền nợ gốc cơ cấu	0,0018
Lãi phải thu hạch toán nội bảng	0,1616	Số tiền nợ lãi cơ cấu	0,0018
		Số lần cơ cấu lại thời hạn trả nợ	0,0014
		Hình thức cấp tín dụng	0,0001
		Mã tiền tệ	0,0000
		Nguồn cấp tín dụng	0,0000

Đặc trưng kỹ thuật và Dư nợ & Thanh toán chiếm phần lớn Top-8 theo Gain của cùng mô hình (Bảng 4.8), nhưng thứ hạng cá thể theo SHAP có khác biệt đáng chú ý: Lãi chưa thu hạch toán ngoại bảng đứng đầu SHAP (0,3130 IV, mức Mạnh) nhưng không phải biến có Gain cao nhất trong nhóm Dư nợ & Thanh toán; ngược lại, ENG_LOAN_AGE_DAYS, biến có IV cao nhất toàn bộ bề đặc trưng (Bảng 3.17), đứng thứ hai SHAP, nhất quán với vai trò nổi bật của nó ở cả ba thước đo (IV, Gain nhóm, SHAP). Mức đồng thuận khá cao này một phần vì bề đặc trưng nhỏ (20 biến) nên ít chỗ cho các biến có Gain cao cục bộ nhưng đóng góp trung bình thấp.

Bảng 4.12: Tỷ trọng mức độ quan trọng theo SHAP của các nhóm nghiệp vụ — bộ dữ liệu B

Nhóm nghiệp vụ	Tỷ trọng SHAP (%)	Tỷ trọng Gain (%)
Dư nợ & Thanh toán	44,6	30,8
Đặc trưng kỹ thuật	38,4	37,2
Lãi suất	6,5	12,7
Chi nhánh	5,5	15,3
Hình thức & Mục đích vay	3,9	2,9
Kỳ hạn & Cơ cấu lại	1,2	1,1

Bảng 4.12 cho thấy hai nhóm dẫn đầu, Dư nợ & Thanh toán và Đặc trưng kỹ thuật, hoán đổi vị trí thứ nhất/thứ hai giữa hai thước đo (Gain xếp Đặc trưng kỹ thuật trước, SHAP xếp Dư nợ & Thanh toán trước), nhưng tổng tỷ trọng của cả hai gần như không đổi (68,0% theo Gain và 83,0% theo SHAP, cả hai đều áp đảo bốn nhóm còn lại). Khác biệt rõ nhất là nhóm Chi nhánh: 15,3% theo Gain nhưng chỉ 5,5% theo SHAP. Đây là dấu hiệu mã chi nhánh TCTD (49 giá trị) được mô hình cây dùng làm điểm chia thường xuyên (Gain cao) nhưng đóng góp trung bình theo từng dự báo lại khiêm tốn hơn (SHAP thấp hơn tương ứng), cùng cơ chế thiên lệch của Gain-importance với biến phân loại nhiều danh mục đã ghi nhận ở bộ A. Vì hai nhóm dẫn đầu giữ nguyên ở cả hai thước đo (chỉ đổi thứ tự trong nội bộ top-2), khuyến nghị ưu tiên đầu tư dữ liệu ở Mục 4.4.8, vốn tính từ Gain, tương đối ít nhạy cảm với lựa chọn phương pháp importance, nhưng vẫn nên đối chiếu cả hai thước đo trước khi ra quyết định đầu tư dữ liệu thực tế, theo đúng khuyến nghị chung đã nêu ở bộ A.

4.4.10 Đối chiếu với các nghiên cứu so sánh mô hình trước đây

Baesens và cộng sự (2003) so sánh nhiều thuật toán phân loại trên tám bộ dữ liệu tín dụng châu Âu và Mỹ, kết luận rằng các phương pháp phi tuyến (mạng

ơ-ron, SVM) không vượt trội nhất quán so với Logistic Regression, và chênh lệch hiệu năng giữa thuật toán tốt nhất và Logistic Regression trên nhiều bộ dữ liệu là không lớn [2]. Kết quả của bộ A trong Bảng 4.1 một phần phù hợp nhận định này: Logistic Regression đạt Macro-F1 0,4204, thấp hơn rõ rệt so với XGBoost (0,6442) và LightGBM (0,6484), nhưng ROC-AUC macro của Logistic Regression (0,8059) không quá xa so với nhóm boosting (quanh 0,92). Điều này cho thấy Logistic Regression vẫn giữ được khả năng *xếp hạng* rủi ro tương đối tốt dù nhãn cứng sau ngưỡng kém chính xác hơn nhiều, theo đúng cách phân biệt giữa Macro-F1 (đánh giá nhãn cứng) và ROC-AUC (đánh giá khả năng xếp hạng xác suất) đã dùng để đọc kết quả bộ B ở mục trước.

Lessmann và cộng sự (2015) mở rộng benchmark của Baesens et al. trên nhiều bộ dữ liệu và giai đoạn thời gian mới hơn, kết luận rằng các phương pháp ensemble (Random Forest, Gradient Boosting) có xu hướng thắng thế nhất quán hơn theo thời gian so với các mô hình đơn lẻ, đồng thời khuyến nghị dùng nhiều thước đo (không chỉ Accuracy hoặc AUC) khi lớp mất cân bằng [17]. Cả bộ A và bộ B của luận văn xác nhận nửa đầu nhận định này trên tập kiểm định: bốn phương pháp ensemble/boosting (Random Forest, XGBoost, LightGBM, CatBoost) đều vượt Decision Tree về ROC-AUC ở cả hai bộ, và LightGBM hoặc XGBoost luôn có Macro-F1 cao nhất trong sáu mô hình trên tập kiểm định (Bảng 4.1, 4.4). Tuy nhiên, kết quả trên tập kiểm tra độc lập 20260507 của bộ B (Bảng 4.5) cho thấy khuyến nghị “ensemble/boosting thắng thế nhất quán theo thời gian” của Lessmann et al. cần được hiểu cẩn trọng hơn: trên dữ liệu thực sự tách biệt theo thời gian, Random Forest, không phải một mô hình boosting, mới là mô hình có Macro-F1 cao nhất, đảo ngược thứ hạng quan sát được trên tập kiểm định cùng kỳ.

Có một điểm lệch khỏi kỳ vọng “ensemble luôn tốt hơn” nhất quán ở cả hai bộ dữ liệu: CatBoost, cũng là một thuật toán boosting, có Macro-F1 và Accuracy thấp hơn rõ rệt so với các mô hình cây/ensemble còn lại (0,5454 ở bộ A, thấp hơn cả Decision Tree 0,5896; 0,6046 ở bộ B trên tập kiểm định, thấp hơn cả Decision Tree 0,6590 và Random Forest 0,6568). Nguyên nhân không nằm ở bản chất thuật toán mà ở cách xử lý mất cân bằng: theo mục 3.7.2, mọi chiến lược khác none được tự động chuyển thành `auto_class_weights=Balanced` cho CatBoost thay vì SMOTE, khiến CatBoost tối ưu hóa để tăng Recall lớp hiếm mạnh hơn nhưng đổi lại Precision và Accuracy tổng thể giảm. Điều này thể hiện rõ ở Bảng 4.4: Weighted-F1 của CatBoost (0,7673) thấp hơn nhiều so với bốn mô hình cây/ensemble còn lại (trên 0,91), dù ROC-AUC macro của CatBoost (0,9195) vẫn cạnh tranh, xác nhận CatBoost giữ được khả năng xếp hạng xác suất tốt dù nhấn cứng sau ngưỡng kém chính xác hơn, đúng theo cùng logic Macro-F1/ROC-AUC đã dùng xuyên suốt chương. Quan sát này củng cố khuyến nghị của Lessmann et al. rằng thứ hạng mô hình phụ thuộc thước đo được chọn và không có một kỹ thuật xử lý mất cân bằng nào luôn tối ưu cho mọi mô hình [17, 7]. Trong dữ liệu của luận văn, hiệu ứng này rõ ràng hơn cả lựa chọn thuật toán, và bằng chứng từ tập kiểm tra độc lập của bộ B cho thấy nó còn rõ ràng hơn khi đánh giá ngoài thời gian.

4.5 Độ nhảy của siêu tham số

Không gian tìm kiếm gồm 65 cấu hình cho bộ A và 60 cấu hình cho bộ B, được trình bày tại Mục 3.8.2 của Chương 3. Phần này so sánh cấu hình mặc định với cấu hình đạt Macro-F1 cao nhất trong phạm vi lưới khảo sát, đồng thời phân tích

mức độ nhảy của từng mô hình đối với siêu tham số.

4.5.1 Cấu hình mặc định so với cấu hình tốt nhất tìm được

Bảng 4.13: So sánh Macro-F1 giữa cấu hình mặc định và cấu hình tốt nhất trong lưới khảo sát

Bộ	Mô hình	Macro-F1 (mặc định)	Macro-F1 (tốt nhất)	Cải thiện
A	Decision Tree	0,5896	0,6086	+3,22%
A	Random Forest	0,6179	0,6303	+2,01%
A	XGBoost	0,6442	0,6442	+0,00%
A	LightGBM	0,6484	0,6484	+0,00%
A	CatBoost	0,5454	0,5677	+4,08%
A	Logistic Regression	0,4204	0,4220	+0,37%
B	LightGBM	0,6954	0,6994	+0,58%
B	XGBoost	0,6941	0,6925	−0,23%
B	Decision Tree	0,6590	0,6653	+0,95%
B	Random Forest	0,6568	0,6653	+1,29%
B	CatBoost	0,6046	0,6228	+3,02%
B	Logistic Regression	0,4186	0,4397	+5,04%

Trong phạm vi các cấu hình được khảo sát, LightGBM đạt Macro-F1 cao nhất ở cả cấu hình mặc định (0,6954) và cấu hình được lựa chọn từ lưới (0,6994, với `max_depth=6`, `learning_rate=0,1`, `n_estimators=400`). Mức cải thiện tương ứng là 0,58%. XGBoost có Macro-F1 giảm 0,23% do lưới của bộ B không bao gồm chính xác cấu hình mặc định với `learning_rate=0,05`. Kết quả này minh họa rằng một không gian tìm kiếm hữu hạn không bảo đảm chứa cấu hình tốt hơn giá trị mặc định.

Nhìn chung, mức cải thiện sau điều chỉnh tham số ở bộ B (từ −0,23% đến +5,04%) khá gần với biên độ quan sát được ở bộ A (0,00% đến +4,08%). Kết quả này phù hợp với đặc điểm bộ dữ liệu: quy mô tập huấn luyện lớn (80.493 hồ sơ) khiến cấu hình mặc định ít có nguy cơ khớp quá mức với nhiễu của các lớp

hiêm hơn, nên dự địa cải thiện từ việc chính quy hóa thêm (giảm độ sâu, tăng mẫu tối thiểu ở lá, giảm tốc độ học) cũng nhỏ hơn. Logistic Regression vẫn là mô hình cải thiện nhiều nhất (+5,04%, từ $C = 1,0$ mặc định lên $C = 10,0$), nhất quán với đặc điểm mô hình tuyến tính đơn giản, dễ hưởng lợi từ việc nới lỏng regularization khi dữ liệu đã đủ lớn.

4.5.2 Độ nhạy tham số theo mô hình

Bảng 4.14: Độ nhạy Macro-F1 theo mô hình (trên toàn bộ lưới đã thử)

Bộ	Mô hình	Macro-F1 nhỏ nhất	Macro-F1 lớn nhất	Biên độ	Độ lệch chuẩn
A	Decision Tree	0,5626	0,6086	0,0460	0,0164
A	CatBoost	0,5259	0,5677	0,0418	0,0128
A	LightGBM	0,6223	0,6484	0,0261	0,0065
A	Logistic Regression	0,3993	0,4220	0,0227	0,0106
A	XGBoost	0,6270	0,6442	0,0173	0,0059
A	Random Forest	0,6135	0,6303	0,0168	0,0048
B	Logistic Regression	0,3277	0,4397	0,1120	0,0506
B	XGBoost	0,6084	0,6925	0,0842	0,0249
B	Decision Tree	0,5866	0,6653	0,0787	0,0328
B	CatBoost	0,5534	0,6228	0,0694	0,0230
B	LightGBM	0,6419	0,6994	0,0575	0,0175
B	Random Forest	0,6271	0,6653	0,0382	0,0140

Bảng 4.14 cho thấy Random Forest có biên độ Macro-F1 nhỏ nhất trong lưới khảo sát của cả hai bộ dữ liệu. Quan sát này phù hợp với cơ chế lấy trung bình trên nhiều cây của phương pháp bagging, vốn có tác dụng giảm phương sai so với cây đơn [6]. Tuy nhiên, kết luận về độ ổn định chỉ có giá trị trong phạm vi các siêu tham số đã khảo sát.

Tuy nhiên, mô hình *nhạy nhất* lại khác nhau giữa hai bộ: ở bộ A, Decision Tree nhạy nhất (biên độ 0,0460); ở bộ B, **Logistic Regression mới là mô hình**

nhảy nhất (biên độ 0,1120), tiếp theo là XGBoost (0,0842) và Decision Tree (0,0787). Với cỡ mẫu huấn luyện lớn (80.493 hồ sơ), Decision Tree không còn dễ overfit/underfit cực đoan theo tham số; Logistic Regression, mô hình tuyến tính với ranh giới quyết định đơn giản, nhảy hơn hẳn với tham số điều chỉnh (C) khi dữ liệu có quan hệ phi tuyến mạnh (thể hiện qua Macro-F1 thấp nhất trong sáu mô hình ở mọi cấu hình, Bảng 4.13). XGBoost nhảy hơn LightGBM trên bộ B (0,0842 so với 0,0575), cho thấy độ nhạy tham số của một thuật toán không phải một đặc tính cố định của bản thân thuật toán mà còn phụ thuộc vào đặc điểm cụ thể của dữ liệu đang xét.

Kết quả trên cần được diễn giải trong giới hạn của thiết kế thực nghiệm. Lưới tham số và cấu hình tốt nhất đều được đánh giá trên cùng tập kiểm định (20% kỳ 20260430), thay vì trên tập kiểm tra độc lập 20260507; vì vậy, mức cải thiện trong Bảng 4.13 có thể lạc quan hơn hiệu quả thực tế trên dữ liệu mới do thiên lệch lựa chọn. Bằng chứng cụ thể cho rủi ro này đã thấy rõ ở Mục 4.4.3, nơi thứ hạng mô hình trên tập kiểm định không giữ nguyên trên tập kiểm tra độc lập. Trước khi xem xét triển khai cấu hình LightGBM đã tinh chỉnh, cần xác nhận lại kết quả trên tập kiểm tra độc lập 20260507 hoặc quy trình RepeatedStratifiedKFold được trình bày tại mục 3.8.2.

4.6 Đôi chiều bốn câu hỏi nghiên cứu

Thứ nhất, nhiều đặc trưng hơn có luôn tốt hơn không? Kết quả phụ thuộc vào từng bộ dữ liệu. Trên bộ A, cấu hình chính gồm 11 biến đạt Macro-F1 bằng 0,6442, so với 0,6434 khi bổ sung SEX và LOAIKH. Trên bộ B, cấu hình 17 biến và 8 biến lần lượt đạt 0,7031 và 0,6967, cao hơn mức 0,6954 của tập đầy đủ. Do

đó, không có đủ cơ sở để khẳng định số lượng biến lớn hơn luôn cải thiện mô hình; giá trị của biến bổ sung cần được đánh giá bằng hiệu quả ngoài mẫu.

Thứ hai, nhóm nào đóng góp lớn nhất? Kết quả khác nhau giữa hai bộ dữ liệu. Nhóm Kỳ hạn khoản vay có tỷ trọng cao nhất ở bộ A với 40,1%. Ở bộ B, nhóm Đặc trưng kỹ thuật đạt 37,2% theo Gain và 38,4% theo SHAP; nhóm Dư nợ & Thanh toán đạt lần lượt 30,8% và 44,6%. Điểm chung là các tín hiệu về thời hạn, tuổi khoản vay và mức độ phơi nhiễm tín dụng có mức độ quan trọng cao hơn phần lớn các nhóm thông tin còn lại.

Thứ ba, có thể giảm còn bao nhiêu biến? Đối với bộ A, cấu hình 9 biến là mốc nhỏ nhất trong các giá trị đã khảo sát duy trì ít nhất 99% Macro-F1 của tập 13 biến; cấu hình chính gồm 11 biến đạt kết quả cao hơn không đáng kể so với tập đầy đủ. Đối với bộ B, 33 cột chung giữa hai kỳ được xử lý thành 20 đặc trưng hợp lệ. Trong số này, cấu hình 8 biến đạt Macro-F1 bằng 0,6967, so với 0,6954 của tập đầy đủ, nên được xem là một cấu hình rút gọn ứng viên.

Thứ tư, nên ưu tiên mở rộng dữ liệu nào? Ở bộ B, hai nhóm có mức độ quan trọng cao nhất là Đặc trưng kỹ thuật và Dư nợ & Thanh toán đều không có giá trị thiếu. Do đó, ưu tiên là duy trì chất lượng ghi nhận ngày giải ngân, ngày kết thúc khế ước, dư nợ và các khoản lãi. Ở bộ A, các trường dữ liệu cũng tương đối đầy đủ, nên cần tập trung vào tính nhất quán và lịch sử biến động theo kỳ. Đối với cả hai bộ, dữ liệu trạng thái theo thời gian, diễn biến dư nợ, lịch trả nợ và các mốc đáo hạn là điều kiện cần để xây dựng nhãn chuyển nhóm phù hợp.

Thứ năm, mô hình có thể dự báo khả năng chuyển nhóm nợ trong một tháng hay không? Trong phạm vi thực nghiệm, kết quả tại Mục 4.7 cung cấp bằng chứng ban đầu về khả năng dự báo chuyển nhóm nợ. XGBoost đạt PR-AUC

0,1806, cao gấp khoảng 67 lần tỷ lệ sự kiện nền (0,268%); khi ưu tiên rà soát 5% hồ sơ có xác suất cao nhất, mô hình nhận diện được 56,6% số khoản vay chuyển sang nhóm nợ cao hơn. Kết quả cho thấy thông tin sẵn có tại thời điểm quan sát chứa tín hiệu liên quan đến diễn biến nhóm nợ sau một tháng và khác về bản chất so với việc phân loại lại trạng thái đã biết. Tuy nhiên, do phân tích chỉ dựa trên một cặp kỳ báo cáo, kết quả cần được xác nhận trên nhiều giai đoạn trước khi xem xét triển khai (Mục 4.7).

4.7 Kết quả bài toán dự báo chuyển nhóm nợ (bộ B)

Mục này báo cáo kết quả thực nghiệm cho bài toán bổ sung đã trình bày phương pháp ở Mục 3.9 Chương 3: dự báo khả năng một khoản vay chuyển sang nhóm nợ cao hơn trong một tháng, trên 98.968 khoản vay khớp giữa hai kỳ báo cáo của bộ B, với 265 sự kiện dương (0,268%).

4.7.1 So sánh mô hình và chiến lược xử lý mất cân bằng

Bảng 4.15 trình bày kết quả kiểm định chéo phân tầng lặp lại (5×10 lần lặp) của sáu mô hình, mỗi mô hình lấy chiến lược xử lý mất cân bằng đạt PR-AUC cao nhất trong ba chiến lược đã khảo sát (không xử lý, SMOTE vừa phải, trọng số lớp; riêng CatBoost chỉ có hai chiến lược do trọng số lớp và SMOTE cùng ánh xạ về một cơ chế, Mục 3.9.4).

Bảng 4.15: So sánh 6 mô hình trên bài toán dự báo chuyển nhóm nợ (chiến lược tốt nhất theo PR-AUC, 5×10 lần lặp)

Mô hình	Chiến lược	PR-AUC	ROC-AUC	Precision(+)	Recall(+)
XGBoost	none	0,1806±0,0491	0,8458±0,0268	0,887±0,121	0,110±0,038
LightGBM	custom	0,1761±0,0488	0,8399±0,0305	0,753±0,145	0,125±0,043
Random Forest	none	0,1679±0,0485	0,8497±0,0256	0,580±0,499	0,016±0,015
CatBoost	none	0,1277±0,0439	0,8307±0,0269	0,866±0,272	0,055±0,026
Decision Tree	custom	0,0805±0,0409	0,6879±0,0451	0,205±0,085	0,101±0,048
Logistic Regression	none	0,0050±0,0008	0,6208±0,0332	0,000	0,000

Precision(+)/Recall(+) là Precision/Recall của riêng lớp “xấu đi” tại ngưỡng mặc định 0,5, không lấy trung bình macro (Mục 3.9.4). Trong phạm vi lưới đã khảo sát, XGBoost với chiến lược none đạt PR-AUC cao nhất, bằng 0,1806, xấp xỉ 67 lần tỷ lệ sự kiện nền (0,268%), và được chọn làm mô hình tốt nhất. Random Forest đạt ROC-AUC cao nhất (0,8497) nhưng PR-AUC thấp hơn XGBoost, cho thấy hai thước đo có thể không đồng thuận ở mức mất cân bằng cực độ, đúng như lý do PR-AUC được chọn làm tiêu chí chính (Mục 3.9.4).

Khoảng cách giữa Logistic Regression (PR-AUC 0,0050, xấp xỉ mức ngẫu nhiên 0,00268) và các mô hình cây/tổ hợp (0,08–0,18) lớn hơn nhiều so với khoảng cách tương ứng ở bài toán phân loại 5 lớp (Bảng 4.4), cho thấy quan hệ giữa đặc trưng tại T và khả năng chuyển nhóm tại $T + 1$ mang tính phi tuyến rõ rệt hơn.

Bảng 4.16 đối chiếu ba chiến lược mất cân bằng cho riêng XGBoost.


Bảng 4.16: Ba chiến lược mất cân bằng đối với XGBoost

Chiến lược	PR-AUC	ROC-AUC	Precision(+)	Recall(+)
none	0,1806±0,0491	0,8458±0,0268	0,887±0,121	0,110±0,038
custom (SMOTE)	0,1710±0,0474	0,8457±0,0285	0,744±0,161	0,120±0,044
class_weight	0,1541±0,0443	0,8265±0,0248	0,074±0,013	0,265±0,049


Không xử lý mất cân bằng (none) đạt PR-AUC cao nhất, phù hợp với phát hiện tương tự đã ghi nhận trong quá trình xây dựng `models.py` ở bài toán 5 lớp (Mục 3.7.2): SMOTE và trọng số lớp không mặc nhiên cải thiện khả năng xếp hạng, dù `class_weight` nâng Recall(+) rõ rệt (từ 0,110 lên 0,265) với cái giá là Precision(+) giảm mạnh (từ 0,887 xuống 0,074); đây là đánh đổi cùng bản chất đã quan sát được ở CatBoost trên bài toán 5 lớp (Bảng 4.4).

4.7.2 Đánh giá minh họa và Recall@k

Bảng 4.15 là bằng chứng chính. Để minh họa cụ thể, mô hình tốt nhất (XGBoost, none) được huấn luyện lại trên một lần chia 80/20 (Mục 3.9.4), đạt PR-AUC 0,1705 và ROC-AUC 0,8487 trên 19.794 hồ sơ kiểm định (53 sự kiện dương), nhất quán với kết quả kiểm định chéo. Tại ngưỡng mặc định 0,5, mô hình chỉ gắn nhãn dương cho 6 trong 53 sự kiện thật (Recall 0,113) nhưng cả 6 dự báo đều đúng (Precision 1,000); Hình 4.1 và Hình 4.2 minh họa ma trận nhầm lẫn và đường cong Precision-Recall tương ứng.



Hình 4.1: Ma trận nhầm lẫn — XGBoost (none), tập kiểm định minh họa




Hình 4.2: Đường cong Precision-Recall — XGBoost (none)

Ngưỡng 0,5 không phản ánh đúng năng lực thực tế của mô hình ở prevalence 0,268%. Bảng 4.17 báo cáo Recall/Precision khi ngân hàng chỉ rà soát top- k % hồ sơ có xác suất cao nhất; đây là chỉ tiêu gắn trực tiếp với năng lực rà soát thực tế, không phụ thuộc việc chọn ngưỡng.


Bảng 4.17: Recall@ k — XGBoost (none), tập kiểm định minh họa (19.794 hồ sơ, 53 sự kiện)

Top- k %	Số hồ sơ	Số sự kiện phát hiện	Recall@ k	Precision@ k
1%	198	14	26,4%	7,1%
2%	396	19	35,8%	4,8%
5%	990	30	56,6%	3,0%
10%	1.979	35	66,0%	1,8%



Hình 4.3: Recall@k — XGBoost (none)

Nếu ngân hàng ưu tiên rà soát 5% hồ sơ có xác suất chuyển nhóm cao nhất (990 trong 19.794 hồ sơ), mô hình phát hiện được 56,6% số khoản vay thực sự chuyển sang nhóm cao hơn trong tháng tiếp theo, so với kỳ vọng chỉ 5% nếu chọn ngẫu nhiên cùng số lượng hồ sơ. Đây là mức tăng hiệu quả rà soát đáng kể so với việc chờ CIC ghi nhận sự kiện đã xảy ra, dù precision tuyệt đối thấp (3,0%) là hệ quả tất yếu của tỷ lệ sự kiện nền chỉ 0,268%. Hình 4.4 cho thấy phân tán PR-AUC của sáu mô hình qua 50 lần lặp kiểm định chéo (chiến lược none), minh họa mức độ không chắc chắn của ước lượng khi lớp dương chỉ có khoảng 53 quan sát mỗi lần kiểm định.



Hình 4.4: Phân tán PR-AUC qua 5×10 lần lặp kiểm định chéo — chiến lược none

4.7.3 Giải thích bằng SHAP

Bảng 4.18 liệt kê các đặc trưng có đóng góp SHAP trung bình lớn nhất đối với lớp “xấu đi”, tính trên mô hình XGBoost (none).

Bảng 4.18: Importance theo SHAP (trung bình $|\phi_j|$, lớp “xấu đi”) — mô hình dự báo chuyển nhóm nợ

Biến	Trung bình $ \phi_j $
Lãi phải thu hạch toán nội bảng	0,9351
Số dư nợ theo nguyên tệ	0,6096
ENG_DAYS_TO_MATURITY	0,5700
ENG_TENOR_ACTUAL_DAYS	0,4978
ENG_LOAN_AGE_DAYS	0,4585
Mã chi nhánh TCTD	0,3810
Lãi suất	0,3494
Lãi chưa thu hạch toán ngoại bảng	0,2175

Lãi phải thu hạch toán nội bảng (lãi đã đến hạn nhưng khách hàng chưa thanh toán) có đóng góp SHAP vượt trội, phù hợp trực giác nghiệp vụ: khoản lãi tồn đọng tại T là dấu hiệu sớm của khó khăn thanh toán trước khi

khoản vay thực sự chuyển nhóm tại $T + 1$. Ba đặc trưng kỹ thuật về thời hạn (ENG_DAYS_TO_MATURITY, ENG_TENOR_ACTUAL_DAYS, ENG_LOAN_AGE_DAYS) và dư nợ hiện tại cũng có vai trò đáng kể, nhất quán với nhóm Đặc trưng kỹ thuật và Dư nợ & Thanh toán đã dẫn đầu ở bài toán phân loại 5 lớp trên cùng bộ B (Bảng 4.12). Số lần cơ cấu lại thời hạn trả nợ và các biến liên quan đến cơ cấu nợ có SHAP xấp xỉ 0 trong mẫu tính toán, phù hợp với tỷ lệ phát sinh cơ cấu rất thấp đã nêu ở Chương 3 (dưới 0,5% hồ sơ), không đủ số lượng để mô hình khai thác như một tín hiệu dự báo ổn định.

Như đã lưu ý ở Mục 3.9.2, các đặc trưng dẫn đầu đều phản ánh trạng thái dư nợ và lãi tại T , tín hiệu dự báo hợp lệ chứ không phải rò rỉ nhãn; tuy nhiên, mức độ quan trọng này chỉ phản ánh cách mô hình sử dụng dữ liệu, không phải bằng chứng nhân quả (Mục 5.4.6).

4.8 Ý nghĩa đối với mô hình chuyển nhóm nợ

Kết quả ở Mục 4.7 cho thấy, với đặc trưng sẵn có tại một thời điểm, mô hình học máy có thể xếp hạng rủi ro chuyển nhóm tốt hơn đáng kể so với ngẫu nhiên (PR-AUC gấp khoảng 67 lần tỷ lệ sự kiện nền) và mang lại giá trị rà soát cụ thể (Recall@5% đạt 56,6%). Đây là bằng chứng thực nghiệm đầu tiên của luận văn cho hướng cảnh báo sớm độc lập với CIC đã đặt ra ở Mục 1.1.3. Tuy nhiên, đây vẫn là một nghiên cứu thăm dò, không phải một hệ thống cảnh báo sớm hoàn chỉnh, do các giới hạn sau:

1. chỉ có đúng một cặp $(T, T + 1)$ với cửa sổ dự báo cố định 1 tháng; chưa kiểm định được trên nhiều cặp kỳ báo cáo hay nhiều cửa sổ dự báo khác nhau (3, 6, 12 tháng);

2. số sự kiện dương rất nhỏ (265) khiến khoảng tin cậy của các chỉ tiêu còn rộng (Hình 4.4), thể hiện rõ ở nhóm 3 mô hình dẫn đầu (XGBoost, LightGBM, Random Forest) có PR-AUC trùng lặp trong khoảng ± 1 độ lệch chuẩn của nhau;
3. nhân chỉ được xác định cho khoản vay khớp ở cả hai kỳ; rủi ro sai lệch do loại khoản vay tất toán/xóa nợ đã được thảo luận ở Mục 3.9.3 nhưng chưa được loại trừ hoàn toàn;
4. ngưỡng quyết định và hệ số ưu tiên top- $k\%$ chưa được gắn với chi phí bỏ sót/rà soát thực tế của ngân hàng; đây là bước tiếp theo cần thiết trước khi xem xét triển khai (Mục 5.5.3).

4.9 Tóm tắt chương

Chương 4 đã trình bày hệ thống thước đo và kết quả thực nghiệm trên hai bộ dữ liệu: đối sánh sáu mô hình, hiệu năng theo số lượng đặc trưng, đóng góp của các nhóm đặc trưng theo Gain và SHAP, độ nhạy siêu tham số qua 125 cấu hình, và đối chiếu với các nghiên cứu benchmark trước đây. Trên tập kiểm định cùng kỳ, LightGBM dẫn đầu ở cả hai bộ dữ liệu; tuy nhiên trên tập kiểm tra độc lập 20260507 của bộ B, thứ hạng mô hình thay đổi và Macro-F1 giảm rõ rệt, cho thấy khoảng cách giữa hiệu năng trong phân phối và hiệu năng ngoài thời gian. Năm câu hỏi nghiên cứu được trả lời chi tiết tại Mục 4.6; các con số cụ thể không nhắc lại ở đây để tránh trùng lặp.

Chương cũng trình bày kết quả của bài toán bổ sung dự báo chuyển nhóm nợ trong 1 tháng trên bộ B (Mục 4.7): XGBoost đạt PR-AUC 0,1806 trên kiểm định chéo lặp lại, gấp khoảng 67 lần tỷ lệ sự kiện nền; ưu tiên rà soát 5% hồ sơ rủi

ro cao nhất phát hiện được 56,6% sự kiện chuyển nhóm thực tế. Đây là bằng chứng thực nghiệm đầu tiên cho hướng cảnh báo sớm độc lập với CIC, dù vẫn còn nhiều giới hạn cần lưu ý trước khi triển khai.

Trên cơ sở các kết quả và hạn chế đã trình bày, Chương 5 sẽ tổng kết những đóng góp chính của luận văn, nêu rõ các hạn chế cần lưu ý và đề xuất kiến nghị đối với ngân hàng cùng hướng nghiên cứu tiếp theo.

Chương 5

KẾT LUẬN VÀ KIẾN NGHỊ

Chương cuối của luận văn tổng hợp các kết quả nghiên cứu và làm rõ ý nghĩa của những bằng chứng thực nghiệm đã trình bày. Trước hết, chương khái quát kết quả trên hai bộ dữ liệu, bao gồm cả bài toán bổ sung dự báo chuyển nhóm nợ trên bộ B, và trả lời trực tiếp năm câu hỏi nghiên cứu được xác lập ở Chương 1. Tiếp theo, các đóng góp về phương pháp và giá trị ứng dụng được hệ thống hóa song song với việc nhận diện những hạn chế liên quan đến dữ liệu, thiết kế kiểm định và khả năng diễn giải mô hình. Trên cơ sở đó, chương đề xuất một số kiến nghị đối với ngân hàng về tổ chức dữ liệu, triển khai và quản trị mô hình. Cuối cùng, các hướng nghiên cứu tiếp theo được trình bày, trong đó trọng tâm là kiểm định độ ổn định của mô hình chuyển nhóm nợ qua nhiều giai đoạn thời gian và mở rộng thành hệ thống cảnh báo sớm rủi ro tín dụng hoàn chỉnh.

5.1 Kết luận chung

Luận văn nghiên cứu khả năng ứng dụng các mô hình học máy trong phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam, đồng thời xây dựng một bài toán bổ sung dự báo khả năng chuyển nhóm

nợ trong một tháng trên bộ B. Nghiên cứu đã xây dựng quy trình tiền xử lý và mô hình hóa, kiểm soát một số nguy cơ rò rỉ thông tin, xử lý hiện tượng mất cân bằng lớp, đối sánh các mô hình và phân tích vai trò của các đặc trưng. Đối với bài toán phân loại tại một thời điểm, kết quả thu được cung cấp cơ sở thực nghiệm cho việc phát triển mô hình cảnh báo sớm. Đối với bài toán chuyển nhóm, luận văn đã tận dụng hai kỳ báo cáo liên tiếp của bộ B để ghép thành cặp $(T, T + 1)$ và huấn luyện, đánh giá trực tiếp, đây là bằng chứng thực nghiệm đầu tiên cho hướng cảnh báo sớm độc lập với CIC; tuy nhiên, do chỉ có đúng một cặp kỳ báo cáo, luận văn chưa kiểm định được khả năng tổng quát hóa của bài toán này qua nhiều cửa sổ dự báo hoặc nhiều giai đoạn thời gian khác nhau.

Bộ dữ liệu A gồm 27.001 hồ sơ và 21 biến ban đầu. Cấu hình huấn luyện chính sử dụng 11 biến, trong khi mô-đun phân tích đặc trưng sử dụng tập mở rộng gồm 13 biến, bao gồm tám biến số và năm biến phân loại. Phép chia có phân tầng tạo ra 21.600 quan sát huấn luyện và 5.401 quan sát kiểm định. Trên tập 11 biến, LightGBM đạt Macro-F1 cao nhất (0,6484); XGBoost đạt Macro-F1 bằng 0,6442 và ROC-AUC macro bằng 0,9201.

Bộ dữ liệu B là dữ liệu Thông tin tín dụng, gồm hai kỳ báo cáo: 100.617 hồ sơ/41 cột thô (kỳ 20260430, dùng huấn luyện/kiểm định) và 100.274 hồ sơ/33 cột thô (kỳ 20260507, dùng làm tập kiểm tra độc lập ngoài thời gian). Vì kỳ 20260507 chỉ có 33/41 cột của kỳ 20260430, mô hình sử dụng 20 đặc trưng xây dựng từ 33 cột chung, gồm 8 biến số thô, 8 biến phân loại và 4 biến tạo thêm. Phép chia phân tầng trên kỳ 20260430 tạo 80.493 mẫu huấn luyện và 20.124 mẫu kiểm định; toàn bộ 100.274 hồ sơ của kỳ 20260507 được giữ lại làm tập kiểm tra độc lập, không tham gia huấn luyện hay chọn mô hình.

Trên bộ dữ liệu B, cả sáu mô hình đều được thực thi thành công. LightGBM

đạt kết quả cao nhất trên tập kiểm định, với Macro-F1 bằng 0,6954, Accuracy bằng 0,9367 và ROC-AUC macro bằng 0,9411. Tuy nhiên, trên tập kiểm tra độc lập của kỳ 20260507, thứ hạng các mô hình thay đổi: Random Forest đạt Macro-F1 bằng 0,5142, cao hơn LightGBM với 0,4952; đồng thời Macro-F1 của tất cả mô hình giảm từ 15–32% so với tập kiểm định. Kết quả này cho thấy chưa có đủ cơ sở để khẳng định khả năng tổng quát hóa ổn định theo thời gian. Việc báo cáo đồng thời Macro-F1, Recall theo từng lớp và kết quả trên tập kiểm tra độc lập góp phần hạn chế những nhận định quá lạc quan nếu chỉ dựa trên Accuracy hoặc một lần chia mẫu ngẫu nhiên trong cùng kỳ dữ liệu.

Đối với bài toán dự báo chuyển nhóm nợ trong một tháng, luận văn ghép 98.968 khoản vay khớp giữa hai kỳ báo cáo của bộ B (20260430 và 20260507) qua khóa Số khế ước, thu được 265 sự kiện chuyển sang nhóm cao hơn (0,268%). XGBoost với chiến lược không xử lý mất cân bằng đạt PR-AUC 0,1806 trên kiểm định chéo phân tầng lặp lại, gấp khoảng 67 lần tỷ lệ sự kiện nền; khi ưu tiên rà soát 5% hồ sơ có xác suất cao nhất, mô hình phát hiện được 56,6% số khoản vay thực sự chuyển nhóm trong tháng tiếp theo. Đây là kết quả thăm dò dựa trên một cặp kỳ báo cáo duy nhất, chưa phải một hệ thống cảnh báo sớm hoàn chỉnh (Mục 4.7).

5.2 Trả lời các câu hỏi nghiên cứu

Bốn câu hỏi nghiên cứu đặt ra ở Chương 1 đã được đối chiếu chi tiết với bằng chứng thực nghiệm tại Mục 4.6 Chương 4. Phần này chỉ tóm lược kết luận và nêu hàm ý ứng dụng, không nhắc lại các con số đã trình bày ở đó.

5.2.1 Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Không. Trên cả hai bộ dữ liệu, một số cấu hình rút gọn đạt Macro-F1 tương đương hoặc cao hơn tập đầy đủ. Một đặc trưng bổ sung chỉ có giá trị khi cung cấp thông tin ngoài mẫu hữu ích; số lượng đặc trưng tự thân không bảo đảm hiệu quả dự báo cao hơn.

5.2.2 Nhóm đặc trưng nào đóng góp lớn nhất?

Kết quả khác nhau giữa hai bộ dữ liệu: nhóm Kỳ hạn khoản vay dẫn đầu ở bộ A; nhóm Đặc trưng kỹ thuật và Dư nợ & Thanh toán dẫn đầu ở bộ B, dù thứ tự hoán đổi giữa Gain và SHAP. Điểm chung là thông tin về thời hạn, tuổi khoản vay và mức độ phơi nhiễm tín dụng luôn có vai trò đáng kể trên cả hai bộ. Các tỷ trọng này phản ánh cách mô hình sử dụng dữ liệu, không phải bằng chứng nhân quả (Mục 5.4.6).

5.2.3 Có thể giảm còn bao nhiêu đặc trưng?

Cả hai bộ dữ liệu đều tìm được cấu hình rút gọn (xem Mục 4.6 Chương 4) không làm giảm Macro-F1 trên tập kiểm định. Tuy nhiên, các môc này chỉ là cấu hình ứng viên từ phân tích khám phá trên cùng một tập kiểm định, chưa phải nghiệm tối ưu, và cần được xác nhận trên dữ liệu độc lập hoặc kiểm định lặp trước khi khuyến nghị triển khai chính thức.

5.2.4 Ngân hàng nên ưu tiên thu thập nhóm thông tin nào?

Ở cả hai bộ, nhóm đặc trưng có mức độ quan trọng cao nhất đều đã tương đối đầy đủ dữ liệu, nên ưu tiên trước mắt là duy trì chất lượng và tính nhất quán của

các trường này, đặc biệt ngày giải ngân, ngày kết thúc khế ước, dư nợ và các khoản lãi phải thu hoặc chưa thu, thay vì mở rộng thu thập. Ngược lại, nhóm có tỷ lệ thiếu cao (như Kỳ hạn & Cơ cấu lại của bộ B) nhưng đóng góp thấp thì chưa được xác định là ưu tiên. Trước khi đầu tư mở rộng một nhóm dữ liệu, ngân hàng cần thực hiện thí nghiệm loại bỏ hoặc bổ sung nhóm đó và lượng hóa lợi ích dự báo tương ứng với chi phí nghiệp vụ.

5.2.5 Mô hình có thể dự báo khả năng chuyển nhóm nợ trong một tháng hay không?

Kết quả thực nghiệm bước đầu xác nhận khả năng dự báo chuyển nhóm nợ trong phạm vi dữ liệu nghiên cứu. Việc ghép hai kỳ báo cáo liên tiếp của bộ B cho phép xây dựng và đánh giá trực tiếp bài toán này. Các đặc trưng tại thời điểm quan sát cung cấp tín hiệu dự báo về khả năng chuyển nhóm sau một tháng: PR-AUC của mô hình cao gấp khoảng 67 lần tỷ lệ sự kiện nền và Recall@5% đạt 56,6%. Kết quả này khác về bản chất so với việc phân loại lại nhóm nợ hiện tại đã được CIC ghi nhận (Mục 1.1.3). Tuy nhiên, bằng chứng mới được xác lập trên một cặp kỳ báo cáo với 265 sự kiện dương; do đó, khả năng tổng quát hóa qua các giai đoạn và cửa sổ dự báo khác cần được tiếp tục kiểm định (Mục 4.7).

5.3 Đóng góp của nghiên cứu

5.3.1 Đóng góp phương pháp

Nghiên cứu xây dựng hai quy trình thực nghiệm độc lập dựa trên cùng một hệ nguyên tắc, bao gồm lựa chọn biến theo phân nhóm nghiệp vụ, xây dựng đặc trưng, điền khuyết, chuẩn hóa, mã hóa, xử lý mất cân bằng lớp và huấn luyện mô

hình. Việc loại NHOMNO khỏi bộ A, đồng thời loại các trường phản ánh trực tiếp nhóm nợ hoặc số ngày quá hạn khỏi bộ B, nhằm hạn chế khả năng mô hình học lại quy tắc hình thành nhãn.

Nghiên cứu cũng tách ba khái niệm thường bị đồng nhất: số cột thô, số đặc trưng hợp lệ và số đặc trưng rút gọn theo hiệu năng. Sự phân biệt này giúp câu hỏi “có cần giữ toàn bộ số cột thô không” được trả lời chặt chẽ hơn. Việc chạy cùng bốn câu hỏi trên hai cấu trúc dữ liệu còn cho thấy kết luận về số lượng và nhóm đặc trưng không nên được khái quát từ một bộ dữ liệu duy nhất. Ở bộ B, việc bổ sung một tập kiểm tra độc lập theo thời gian còn cho thấy ngay cả kết luận rút ra từ một bộ dữ liệu cũng có thể không giữ nguyên khi kiểm tra ngoài thời gian thu thập dữ liệu huấn luyện.

Một đóng góp phương pháp của nghiên cứu là xây dựng thực nghiệm dự báo chuyển nhóm nợ bằng cách ghép hai kỳ báo cáo của bộ B theo khóa định danh khách ước và xác định nhãn $Y_i = \mathbb{I}(G_{i,T+1} > G_{i,T})$. Thiết kế đặc trưng và nhãn được kiểm tra nhằm hạn chế rò rỉ thông tin (Mục 3.9.2). Đồng thời, phương pháp chia mẫu và hệ thống chỉ tiêu đánh giá được điều chỉnh cho phù hợp với tỷ lệ sự kiện dương rất thấp (0,268%), thay vì áp dụng trực tiếp cách đánh giá của bài toán phân loại năm lớp.

5.3.2 Đóng góp thực tiễn

Kết quả cung cấp:

- kết quả đối sánh sáu mô hình được thực thi thành công trên bộ B (và năm mô hình trên bộ A);
- bảng hiệu năng theo lớp trên cả tập kiểm định và tập kiểm tra độc lập của

bộ B, cho thấy rõ khoảng cách giữa hiệu năng “trong phân phối” và hiệu năng ngoài thời gian;

- hai đường cong hiệu quả theo số lượng đặc trưng, trong đó cấu hình 8 biến của bộ B đạt Macro-F1 cao hơn không đáng kể so với tập đầy đủ 20 biến;
- xếp hạng nhóm thông tin nghiệp vụ riêng cho từng bộ, đối chiếu chéo giữa Gain và SHAP;
- khuyến nghị duy trì dữ liệu kỳ hạn ở bộ A, đồng thời duy trì chất lượng dữ liệu Dư nợ & Thanh toán và Đặc trưng kỹ thuật ở bộ B (không phải thu thập thêm, vì hai nhóm này đã không thiếu dữ liệu);
- bằng chứng thực nghiệm đầu tiên cho khả năng dự báo chuyển nhóm nợ trong 1 tháng độc lập với CIC, kèm chỉ tiêu Recall@k gắn trực tiếp với năng lực rà soát của ngân hàng (Mục 4.7).

Những kết quả này có thể hỗ trợ thiết kế thí nghiệm cảnh báo sớm tiếp theo, nhưng chưa nên tích hợp tự động vào quyết định tín dụng. Đặc biệt với bộ B, bằng chứng về khoảng cách hiệu năng ngoài thời gian (mục 5.4.2) và việc bài toán chuyển nhóm mới kiểm định trên một cặp kỳ báo cáo duy nhất (Mục 4.7) là hai lý do trực tiếp để thận trọng.

5.4 Hạn chế của nghiên cứu

5.4.1 Chỉ có một cặp kỳ báo cáo cho bài toán chuyển nhóm

Hai kỳ báo cáo liên tiếp của bộ B (20260430 và 20260507) được ghép thành cặp $(T, T + 1)$ để xây dựng nhãn $Y_i = \mathbb{I}(G_{i,T+1} > G_{i,T})$, huấn luyện mô hình và đánh

giá trực tiếp khả năng dự báo chuyển nhóm (Mục 4.7). Trong khi đó, bộ A chỉ có một mốc thời gian nên không đáp ứng điều kiện xây dựng nhãn cho bài toán này.

Hạn chế còn lại là luận văn mới có đúng một cặp kỳ báo cáo, cách nhau cố định một tháng. Điều này kéo theo ba giới hạn cụ thể: thứ nhất, chưa thể kiểm định mô hình có ổn định qua nhiều giai đoạn thời gian khác nhau hay không, vì kết quả hiện tại có thể đặc thù cho riêng cặp kỳ báo cáo 20260430–20260507; thứ hai, chưa thể mở rộng sang các cửa sổ dự báo khác 1 tháng (3, 6, 12 tháng) vốn có ý nghĩa nghiệp vụ khác nhau đối với công tác thu hồi nợ; thứ ba, không có tầng đánh giá ngoài thời gian độc lập cho riêng bài toán chuyển nhóm tương tự như tập kiểm tra 20260507 của bài toán phân loại 5 lớp (Mục 5.4.2), vì cả hai kỳ đã được dùng để ghép nhãn.

5.4.2 Khoảng cách tổng quát hóa ngoài thời gian ở bộ B

Bộ B có 998 hồ sơ ở nhóm 3 và 1.446 hồ sơ ở nhóm 4, do đó quy mô tuyệt đối của các lớp này không còn là hạn chế chính. Tuy nhiên, trên tập kiểm tra độc lập kỳ 20260507 (Mục 4.4.3), Macro-F1 của các mô hình giảm từ 15–32% so với tập kiểm định nội bộ và thứ hạng mô hình thay đổi. Random Forest đạt kết quả cao nhất trên tập kiểm tra độc lập, trong khi LightGBM chuyển từ vị trí cao nhất trên tập kiểm định xuống vị trí thứ ba.

Kết quả cho thấy phép chia ngẫu nhiên có phân tầng trong cùng một kỳ dữ liệu có thể ước lượng lạc quan hơn khả năng tổng quát hóa theo thời gian. Nguyên nhân có thể bao gồm sự thay đổi quan hệ giữa đầu vào và biến đích, đặc thù của cặp kỳ báo cáo 20260430–20260507 hoặc hiện tượng mô hình khớp với các đặc điểm riêng của kỳ huấn luyện. Do chỉ có hai kỳ báo cáo, luận văn chưa đủ cơ sở

để phân biệt và định lượng từng nguyên nhân.

5.4.3 Thiết kế kiểm định

Các bảng kết quả chính vẫn dựa trên một phép chia ngẫu nhiên có phân tầng; do đó, kết quả có thể phụ thuộc vào hạt giống ngẫu nhiên và chưa phản ánh đầy đủ sự thay đổi phân bố dữ liệu theo thời gian. Với bộ B, tập kiểm tra độc lập kỳ 20260507 (mục 5.4.2) chỉ bổ sung một góc nhìn, chưa thay thế hoàn toàn nhu cầu kiểm định theo thời gian trên nhiều kỳ. Quy trình `RepeatedStratifiedKFold`, với cấu hình mặc định gồm ba lần lặp của kiểm định chéo 5 phần, cho phép tổng hợp Precision, Recall và F1 theo từng nhóm. Cách tiếp cận này giảm mức độ phụ thuộc vào một lần chia mẫu nhưng không thay thế được kiểm định trên dữ liệu ngoài thời gian.

Các giá trị k được khảo sát trên cùng một tập kiểm định trước khi lựa chọn cấu hình có kết quả cao nhất, vì vậy có thể phát sinh thiên lệch lựa chọn. Tập 9 biến của bộ A và tập 8 biến của bộ B chỉ được xem là các cấu hình ứng viên từ phân tích khám phá. Giá trị k cần được lựa chọn trên tập xác thực hoặc thông qua kiểm định chéo lồng nhau, sau đó đánh giá một lần trên tập kiểm tra độc lập. Đối với bộ B, cấu hình 8 biến cần được xác nhận trên kỳ 20260507 trước khi xem xét triển khai.

5.4.4 Mã hóa biến phân loại

Label Encoding có thể tạo thứ tự số giả cho các danh mục. SMOTE sau mã hóa còn có thể nội suy ra giá trị không tương ứng danh mục hợp lệ. Cần so sánh One-Hot Encoding, encoding theo xác suất hoặc mô hình xử lý danh mục

nguyên bản.

5.4.5 Tối ưu và hiệu chỉnh mô hình

Nghiên cứu chưa áp dụng kiểm định chéo lồng nhau và chưa đánh giá mức độ hiệu chỉnh của xác suất dự báo. Đối với bộ A, Logistic Regression không được thực thi lại do khác biệt phiên bản thư viện; đối với bộ B, mô hình đạt Macro-F1 thấp nhất trong sáu mô hình, bằng 0,4186. Phân tích tăng trọng số xác suất của lớp hiếm lựa chọn hệ số trên chính tập đánh giá nên chỉ có ý nghĩa hậu nghiệm và có thể tạo ra kết quả lạc quan. Một quy trình chặt chẽ hơn cần lựa chọn hệ số trên tập xác thực, cố định cấu hình và đánh giá một lần trên tập kiểm tra. Do đó, kết quả đối sánh hiện tại chưa có phạm vi toàn diện như các nghiên cứu quy mô lớn [17]; các cấu hình siêu tham số cũng chưa được xác nhận trên tập kiểm tra độc lập.

5.4.6 Mức độ quan trọng của đặc trưng không phản ánh quan hệ nhân quả

Mức độ quan trọng của đặc trưng và SHAP phản ánh cách mô hình sử dụng dữ liệu, không chứng minh quan hệ nhân quả [18]. Các biến tương quan có thể chia sẻ hoặc thay thế mức độ đóng góp của nhau; chỉ số ưu tiên dữ liệu được sử dụng trong luận văn mới mang tính quy ước và chưa được liên kết với chi phí kinh tế.

Ở bộ B, Gain của LightGBM và SHAP cùng xác định Đặc trưng kỹ thuật và Dư nợ & Thanh toán là hai nhóm có mức độ quan trọng cao nhất, mặc dù thứ tự giữa hai nhóm thay đổi. Nhóm Chi nhánh đạt 15,3% theo Gain nhưng chỉ 5,5% theo SHAP, cho thấy kết quả diễn giải có thể nhạy cảm với thước đo, đặc biệt

đối với biến phân loại có nhiều danh mục. Ở bộ A, mức độ đồng thuận thấp hơn khi hai nhóm Dư nợ–hạn mức và Sản phẩm–mục đích vay thay đổi đáng kể về thứ hạng giữa Gain và SHAP. Vì chỉ số ưu tiên dữ liệu tại Chương 4 được tính từ Gain, mọi kiến nghị đầu tư dữ liệu cần được đối chiếu bằng nhiều phương pháp giải thích trước khi áp dụng.

Đối với bài toán chuyển nhóm nợ, SHAP xác định Lãi phải thu hạch toán nội bảng là đặc trưng có đóng góp lớn nhất (Bảng 4.18). Đây là tín hiệu hợp lý về mặt nghiệp vụ (lãi tồn đọng phản ánh khó khăn thanh toán), nhưng cỡ mẫu tính SHAP chỉ giới hạn trong 265 sự kiện dương nên thứ hạng đặc trưng có thể thay đổi khi có thêm dữ liệu từ các kỳ báo cáo khác; kết luận về đặc trưng dẫn đầu của bài toán này cần được xem là sơ bộ hơn so với bài toán phân loại 5 lớp.

5.5 Kiến nghị đối với ngân hàng

5.5.1 Xây dựng dữ liệu ảnh chụp theo thời gian

Ngân hàng cần lưu trữ dữ liệu ảnh chụp trạng thái khoản vay tại các kỳ cố định, sử dụng khóa định danh khoản vay và khách hàng nhất quán. Mỗi quan sát cần bao gồm ngày ghi nhận, nhóm nợ tại thời điểm ghi nhận và nhóm nợ tại các khoảng dự báo 1, 3, 6 hoặc 12 tháng. Đây là điều kiện tiên quyết để chuyển từ phân loại trạng thái hiện tại sang dự báo khả năng chuyển nhóm nợ.

5.5.2 Ưu tiên chất lượng trước khi mở rộng số lượng biến

Thay vì bổ sung nhiều trường rời rạc, ngân hàng nên:

1. chuẩn hóa ngày giải ngân, ngày kết thúc hợp đồng/khế ước và lịch sử thay đổi kỳ hạn;
2. duy trì tính nhất quán về cấu trúc cột giữa các kỳ báo cáo liên tiếp: bộ B cho thấy 8/41 cột của một kỳ có thể vắng mặt ở kỳ kế tiếp, buộc phải thu hẹp tập đặc trưng để mô hình dùng được xuyên suốt các kỳ;
3. thống nhất danh mục sản phẩm, mục đích vay và hình thức cấp tín dụng;
4. lập data lineage để biết biến tồn tại từ thời điểm nào;
5. giám sát sự thay đổi phân bố và tỷ lệ thiếu theo từng kỳ; đồng thời kiểm định hồi cứu mô hình trên nhiều kỳ báo cáo liên tiếp trước khi triển khai;
6. đối chiếu ít nhất hai thước đo mức độ quan trọng, chẳng hạn Gain và SHAP, trước khi quyết định đầu tư thu thập một nhóm dữ liệu cụ thể.

5.5.3 Thiết kế cảnh báo theo chi phí

Ngưỡng cảnh báo phải dựa trên năng lực xử lý và chi phí sai lầm. Có thể tối ưu:

$$\mathcal{C}(\tau) = c_{FN}FN(\tau) + c_{FP}FP(\tau),$$

trong đó τ là ngưỡng cảnh báo; $FN(\tau)$ là số khoản vay chuyển nhóm nhưng bị bỏ sót; $FP(\tau)$ là số cảnh báo sai; c_{FN} là chi phí trung bình của bỏ sót; và c_{FP} là chi phí rà soát/cơ hội của cảnh báo sai. Ngưỡng tối ưu là giá trị làm $\mathcal{C}(\tau)$ nhỏ nhất dưới các ràng buộc nghiệp vụ.

5.5.4 Quản trị mô hình

Mô hình cần được triển khai dưới vai trò hỗ trợ quyết định, với sự kiểm tra và phê duyệt của cán bộ có thẩm quyền. Ngân hàng cần lưu vết phiên bản dữ liệu, mã nguồn, mô hình, nguyên nhân cảnh báo và kết quả xử lý; theo dõi Macro-F1, Recall của các lớp rủi ro, mức độ hiệu chỉnh xác suất và sự thay đổi phân bố; đồng thời thiết lập lịch tái huấn luyện phù hợp.

5.6 Hướng nghiên cứu tiếp theo

Với bài toán chuyển nhóm nợ đã có bằng chứng thực nghiệm ban đầu (Mục 4.7), hướng nghiên cứu ưu tiên chuyển từ “xây dựng nhân” sang “kiểm định độ ổn định và mở rộng cửa sổ dự báo” trước khi xem xét triển khai. Các bước tiếp theo gồm:

1. thu thập thêm nhiều kỳ báo cáo liên tiếp để có nhiều cặp $(T, T + h)$ độc lập, thay vì chỉ một cặp như hiện tại; đây là điều kiện tiên quyết để kiểm định độ ổn định của mô hình theo thời gian;
2. xây nhân $Y_{i,t}^{(h)}$ cho nhiều cửa sổ dự báo h (3, 6, 12 tháng) khi có đủ chuỗi kỳ báo cáo, thay vì chỉ $h = 1$ tháng như hiện tại;
3. chia dữ liệu theo thời gian và theo khách hàng khi có nhiều kỳ báo cáo hơn;
4. hiệu chỉnh xác suất dự báo (calibration) và gán ngưỡng/hệ số ưu tiên top- $k\%$ với chi phí bỏ sót-rà soát thực tế (Mục 5.5.3), thay vì chỉ báo cáo Recall@ k mô tả như hiện tại;
5. thực hiện thí nghiệm loại bỏ nhóm đặc trưng và đánh giá mức độ quan trọng bằng hoán vị trên tập kiểm định, đối với cả bài toán 5 lớp và bài toán chuyển

nhóm;

6. làm rõ nguyên nhân loại trừ của 1.649 khoản vay không khớp giữa hai kỳ (Mục 3.9.3); cần trường dữ liệu phân biệt tất toán và xóa nợ mà hai file hiện tại không có;
7. thử nghiệm mô hình ordinal, survival hoặc multi-state cho bài toán phân loại 5 lớp vì các nhóm nợ có thứ tự.

Mô hình đa trạng thái có thể mô tả xác suất:

$$p_{ab}^{(h)} = P(G_{i,t+h} = b \mid G_{i,t} = a, \mathbf{X}_{i,t}),$$

trong đó a là nhóm nợ tại thời điểm quan sát; b là nhóm đích sau h kỳ; $\mathbf{X}_{i,t}$ là véc-tơ thông tin sẵn có tại t ; và $p_{ab}^{(h)}$ là xác suất chuyển từ a sang b . Cách tiếp cận này phù hợp hơn phân loại độc lập nếu mục tiêu cuối cùng là ma trận chuyển nhóm.

5.7 Kết luận chương

Chương 5 đã tổng hợp kết quả nghiên cứu tại Mục 4.6 và 4.7 Chương 4 thành câu trả lời cho năm câu hỏi đặt ra ở Chương 1, hệ thống hóa đóng góp về phương pháp và thực tiễn, chỉ rõ các hạn chế, đặc biệt là khoảng cách hiệu năng ngoài thời gian ở bộ B và việc bài toán chuyển nhóm mới kiểm định trên một cặp kỳ báo cáo duy nhất, và đề xuất kiến nghị đối với ngân hàng cùng hướng nghiên cứu tiếp theo. Những nội dung này là cơ sở để tiếp tục hoàn thiện thiết kế dữ liệu, phương pháp kiểm định và mô hình dự báo chuyển nhóm nợ trong các nghiên cứu tiếp theo.

Tài liệu tham khảo

- [1] Edward I. Altman. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609, 1968.
- [2] Bart Baesens, Tony Van Gestel, Stijn Viaene, Maria Stepanova, Johan Suykens, and Jan Vanthienen. Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, 54(6):627–635, 2003.
- [3] Flavio Barboza, Herbert Kimura, and Edward I. Altman. Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83:405–417, 2017.
- [4] Basel Committee on Banking Supervision. Basel Framework: IRB Approach – Risk Components. https://www.bis.org/basel_framework/chapter/CRE/32.htm, 2024. Truy cập ngày 26/07/2026.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [6] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [7] Ian Brown and Christophe Mues. An experimental comparison of

- classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3):3446–3453, 2012.
- [8] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [9] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [10] Jonathan N. Crook, David B. Edelman, and Lyn C. Thomas. Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3):1447–1465, 2007.
- [11] Xolani Dastile, Tugrul Celik, and Moeketsi Potsane. Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing*, 91:106263, 2020.
- [12] DMLC / XGBoost Contributors. XGBoost Documentation: Introduction to Boosted Trees. <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>, 2026. Giấy phép Apache 2.0; truy cập ngày 15/08/2026.
- [13] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [14] David J. Hand and William E. Henley. Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A*, 160(3):523–541, 1997.

- [15] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.
- [16] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3149–3157, 2017.
- [17] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.
- [18] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774, 2017.
- [19] Lundberg, Scott and SHAP Contributors. SHAP Documentation: Waterfall Plot. https://shap.readthedocs.io/en/latest/example_notebooks/api_examples/plots/waterfall.html, 2026. Giấy phép MIT; truy cập ngày 15/08/2026.
- [20] Microsoft Corporation. LightGBM Documentation: Leaf-wise (Best-first) Tree Growth. <https://lightgbm.readthedocs.io/en/latest/Features.html>, 2026. Truy cập ngày 26/07/2026.
- [21] Ngân hàng Nhà nước Việt Nam. Thông tư số 11/2021/TT-NHNN quy định về phân loại tài sản có, mức trích, phương pháp trích lập dự phòng rủi ro và việc sử dụng dự phòng để xử lý rủi ro trong hoạt động của tổ chức tín

dụng, chi nhánh ngân hàng nước ngoài, 2021. Ban hành ngày 30/07/2021, có hiệu lực từ ngày 01/10/2021.

- [22] James A. Ohlson. Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131, 1980.
- [23] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.
- [24] Naeem Siddiqi. *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons, 2006.
- [25] Lyn C. Thomas. A survey of credit and behavioural scoring: Forecasting financial risk of lending to consumers. *International Journal of Forecasting*, 16(2):149–172, 2000.
- [26] Yufei Xia, Chuanzhi Liu, Bin Da, and Faming Xie. A boosted decision tree approach using bayesian hyper-parameter optimization for credit scoring. *Expert Systems with Applications*, 78:225–241, 2017.