

ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

**ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN
DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG
MẠI Ở VIỆT NAM**

ĐÀM CÔNG DANH

danh.dc251317M@sis.hust.edu.vn

Chuyên ngành Toán Tin

Giảng viên hướng dẫn: TS. Lê Kim Thư Chữ ký của GVHD

TS. Lê Thị Thanh An

Bộ môn: Toán Tin

Viện: Toán ứng dụng và Tin học

HÀ NỘI - 2026

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

BẢN XÁC NHẬN CHỈNH SỬA LUẬN VĂN THẠC SĨ

Họ và tên tác giả luận văn: Đàm Công Danh.

Đề tài luận văn: Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam.

Chuyên ngành: Toán Tin.

Mã học viên: 20251317M

Tác giả, Người hướng dẫn khoa học và Hội đồng chấm luận văn xác nhận tác giả đã sửa chữa, bổ sung luận văn theo biên bản họp Hội đồng ngày ... với các nội dung sau.

Ngày tháng năm 2026

Giảng viên hướng dẫn

Tác giả luận văn

CHỦ TỊCH HỘI ĐỒNG

ĐỀ TÀI LUẬN VĂN

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

TS. Lê Kim Thư

Lời cảm ơn

Lời đầu tiên, em xin cảm ơn Khoa Toán Tin đã tạo điều kiện cho phép thực hiện và hỗ trợ em trong quá trình thực hiện nghiên cứu cũng như suốt thời gian theo học chương trình thạc sĩ Toán Tin tại đơn vị.

Đặc biệt, em xin cảm ơn hai cô - TS. Lê Kim Thư và TS. Lê Thị Thanh An đã tận tình quan tâm, hướng dẫn, chia sẻ kinh nghiệm, kiến thức để em có thể hoàn thành được đề tài một cách tốt nhất. Em cũng xin cảm ơn các thầy cô cùng các bạn học viên khóa 2026 trong Khoa Toán Tin đã góp phần giúp em hoàn thành luận văn này.

Mặc dù đã cố gắng nhưng luận văn vẫn không thể tránh khỏi những sai sót. Em mong nhận được những góp ý từ các thầy cô, các bạn độc giả để luận văn được hoàn thiện hơn. Em xin chân thành cảm ơn!

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

LỜI MỞ ĐẦU

Lý do lựa chọn đề tài

Tín dụng là hoạt động cốt lõi của ngân hàng thương mại, đồng thời là nguồn phát sinh rủi ro có ảnh hưởng trực tiếp đến lợi nhuận, chất lượng tài sản và mức độ an toàn của ngân hàng. Vì vậy, đánh giá và xếp hạng tín dụng không chỉ phục vụ quyết định cấp tín dụng mà còn hỗ trợ giám sát khoản vay, phân loại nợ và nhận diện sớm dấu hiệu suy giảm chất lượng tín dụng.

Sự gia tăng về quy mô và mức độ đa dạng của dữ liệu ngân hàng đặt ra yêu cầu đổi mới phương pháp đánh giá rủi ro. Các phương pháp truyền thống có ưu điểm về tính minh bạch, nhưng có thể gặp hạn chế trước quan hệ phi tuyến, tương tác phức tạp và tình trạng mất cân bằng giữa các nhóm nợ. Trí tuệ nhân tạo và học máy vì vậy mở ra khả năng khai thác dữ liệu hiệu quả hơn, đồng thời hỗ trợ chuẩn hóa và tự động hóa một phần quy trình đánh giá.

Trong bối cảnh đó, đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*” được thực hiện nhằm đánh giá khả năng áp dụng các mô hình học máy vào phân loại nhóm nợ trên dữ liệu thực tế. Nghiên cứu đồng thời xem xét vai trò của các nhóm thông tin nghiệp vụ và khả năng rút gọn đặc trưng, qua đó tạo cơ sở cho việc phát triển hệ thống cảnh báo sớm rủi ro tín dụng.

Phần thực nghiệm hiện tại tập trung vào phân loại nhóm nợ và đánh giá mô hình ngoài mẫu. Dự báo khả năng chuyển nhóm nợ theo thời gian được xác định là hướng phát triển tiếp theo khi dữ liệu có đầy đủ lịch sử trạng thái và cửa sổ dự báo.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là việc ứng dụng các phương pháp thống kê và học máy trong phân loại mức độ rủi ro tín dụng. Trọng tâm của luận văn gồm so sánh hiệu năng mô hình, đánh giá ảnh hưởng của mất cân bằng lớp, phân tích vai trò của đặc trưng và đề xuất định hướng dữ liệu cho cảnh báo sớm.

Nghiên cứu sử dụng hai bộ dữ liệu tín dụng đã được ẩn danh từ một ngân hàng thương mại tại Việt Nam. Phạm vi dữ liệu bao gồm thông tin khách hàng, khoản vay và các yếu tố nghiệp vụ liên quan; tên ngân hàng và thông tin định danh trực tiếp không được công bố.

Các mô hình được đánh giá theo quy trình huấn luyện và kiểm định thống nhất trên từng bộ dữ liệu. Kết quả giữa hai bộ chỉ được đối chiếu về xu hướng do khác biệt về quy mô, cấu trúc biến và phân bố nhóm nợ. Các thông số dữ liệu, cấu hình tiền xử lý và thiết kế thực nghiệm được trình bày chi tiết tại Chương 3.

Động lực ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng

Việc ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng được thúc đẩy bởi ba yêu cầu chính: khai thác tốt hơn dữ liệu ngày càng đa dạng; nâng cao tính nhất quán và hiệu quả của quy trình đánh giá; và hỗ trợ nhận diện sớm các khoản vay có dấu hiệu suy giảm. Trong lĩnh vực ngân hàng, hiệu quả dự báo cần đi cùng

khả năng giải thích, kiểm soát và giám sát để mô hình có thể được sử dụng như một công cụ hỗ trợ quyết định.

Tóm tắt nội dung luận văn

Ngoài phần mở đầu, kết luận, tài liệu tham khảo và phụ lục, luận văn được kết cấu thành các chương như sau:

- **Chương 1: Giới thiệu tổng quan về đề tài.** Chương này trình bày bối cảnh nghiên cứu, tính cấp thiết, câu hỏi nghiên cứu, phương pháp nghiên cứu, ý nghĩa và đóng góp của đề tài.
- **Chương 2: Cơ sở lý thuyết và các nghiên cứu liên quan.** Chương này trình bày các khái niệm về tín dụng, rủi ro tín dụng, xếp hạng tín dụng, trí tuệ nhân tạo, học máy và tổng quan các nghiên cứu trong và ngoài nước.
- **Chương 3: Dữ liệu và phương pháp nghiên cứu.** Chương này mô tả hai bộ dữ liệu gốc, hai nhánh tiền xử lý, quy trình xây dựng đặc trưng, xử lý mất cân bằng, lựa chọn mô hình và phương pháp đánh giá số lượng cũng như nhóm đặc trưng.
- **Chương 4: Kết quả thực nghiệm và thảo luận.** Chương này trình bày riêng kết quả trên từng bộ dữ liệu, sau đó đối chiếu bốn câu hỏi về lợi ích của việc bổ sung biến, nhóm thông tin đóng góp lớn nhất, mức rút gọn đặc trưng và ưu tiên đầu tư dữ liệu.
- **Chương 5: Kết luận và khuyến nghị.** Chương này tổng hợp kết quả trên hai bộ dữ liệu, trả lời các câu hỏi nghiên cứu, nêu hạn chế của thiết kế phân loại hiện tại và đề xuất lộ trình phát triển mô hình cảnh báo chuyển nhóm nợ theo thời gian.

Học viên thực hiện

Đàm Công Danh

Mục lục

Lời mở đầu	4
Một số thuật ngữ viết tắt	12
Danh mục hình vẽ	13
Danh mục bảng	16
1 GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI	17
1.1 Bối cảnh và động lực nghiên cứu	17
1.2 Sự phát triển của các phương pháp đánh giá tín dụng	19
1.3 Phát biểu bài toán và phạm vi nghiên cứu	23
1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu	24
1.5 Tóm tắt chương	26
2 CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN	28
2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ	29
2.2 Từ đánh giá truyền thống đến các mô hình học máy	30
2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng	33
2.4 Hệ thống chỉ tiêu đánh giá mô hình	35

2.5	Nghiên cứu liên quan, khoảng trống và định hướng	36
2.6	Tóm tắt chương	38
3	DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	39
3.1	Định hướng và phạm vi thực nghiệm	39
3.2	Quy trình nghiên cứu tổng thể	40
3.3	Bước 1 — Thu thập dữ liệu	42
3.4	Bước 2 — EDA & làm sạch dữ liệu	43
3.5	Bước 3 — Tiền xử lý & chọn biến	50
3.6	Bước 4 — Chia dữ liệu & cân bằng lớp	76
3.7	Bước 5 — Huấn luyện mô hình	79
3.8	Tóm tắt chương	84
4	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	86
4.1	Nguyên tắc báo cáo kết quả	87
4.2	Thuốc đo đánh giá	88
4.3	Kết quả trên bộ dữ liệu A	89
4.4	Kết quả trên bộ dữ liệu B	92
4.5	Độ nhạy siêu tham số — Grid Search	104
4.6	Đối chiếu bốn câu hỏi nghiên cứu	107
4.7	Ý nghĩa đối với mô hình chuyển nhóm nợ	108
4.8	Tóm tắt chương	109
5	KẾT LUẬN VÀ KIẾN NGHỊ	111
5.1	Kết luận chung	111
5.2	Trả lời các câu hỏi nghiên cứu	112

5.3	Đóng góp của nghiên cứu	115
5.4	Hạn chế của nghiên cứu	116
5.5	Kiến nghị đối với ngân hàng	119
5.6	Hướng nghiên cứu tiếp theo	120
5.7	Kết luận chương	121
Tài liệu tham khảo		123

Một số thuật ngữ viết tắt

Viết tắt	Thuật ngữ tiếng Anh	Diễn giải tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ML	Machine Learning	Học máy
NHTM	Commercial Bank	Ngân hàng thương mại
NHNN	State Bank of Vietnam	Ngân hàng Nhà nước Việt Nam
XHTD	Credit Rating	Xếp hạng tín dụng
PD	Probability of Default	Xác suất khách hàng không thực hiện nghĩa vụ trả nợ
LGD	Loss Given Default	Tỷ lệ tổn thất khi xảy ra vỡ nợ
EAD	Exposure at Default	Giá trị dư nợ tại thời điểm vỡ nợ
IV	Information Value	Giá trị thông tin, dùng đánh giá sức phân biệt của đặc trưng
SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật sinh mẫu tổng hợp cho lớp thiểu số
SHAP	SHapley Additive exPlanations	Phương pháp giải thích đóng góp của đặc trưng dựa trên giá trị Shapley
ROC	Receiver Operating Characteristic	Đường cong biểu diễn quan hệ giữa tỷ lệ dương tính thật và dương tính giả
AUC	Area Under the Curve	Diện tích dưới đường cong đánh giá khả năng phân biệt
PR-AUC	Precision–Recall Area Under the Curve	Diện tích dưới đường cong Precision–Recall
F1	F1-score	Trung bình điều hòa của Precision và Recall
CV	Cross-validation	Kiểm định chéo
API	Application Programming Interface	Giao diện lập trình ứng dụng
RF	Random Forest	Thuật toán rừng ngẫu nhiên
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường gradient tối ưu
<i>LightGBM</i>	Light Gradient Boosting Machine	Thuật toán tăng cường gradient dạng cây tối ưu cho hiệu năng

Danh mục hình vẽ

2.1	Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng	30
2.2	Cơ chế cộng dồn các cây trong XGBoost	32
2.3	So sánh phát triển cây theo tầng và theo lá tốt nhất	33
2.4	Nguyên lý phân rã dự báo theo giá trị SHAP	34
3.1	Pipeline nghiên cứu tổng thể — từ thu thập dữ liệu tới kết luận và ứng dụng	41
3.2	Ma trận tương quan giữa 10 biến quan trọng nhất — bộ dữ liệu B	49
3.3	Phân phối INTEREST_RATE theo nhóm nợ — bộ dữ liệu B .	49
3.4	Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001) . . .	55
3.5	Ma trận tương quan Pearson giữa các biến số của bộ dữ liệu A	57
3.6	Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A	57
3.7	15 biến số thiếu dữ liệu nhiều nhất — bộ dữ liệu B	60
3.8	Các tầng số lượng biến trong nghiên cứu	66

Danh mục bảng

2.1	Các nhóm nợ trong nghiên cứu	29
3.1	Phân bố năm nhóm nợ trong bộ dữ liệu A	42
3.2	Phân bố năm nhóm nợ trong dữ liệu	43
3.3	Số bản ghi có trường ngày lưu sai định dạng (số thứ tự Excel) — bộ dữ liệu A	44
3.4	Thống kê mô tả các biến số gốc của bộ dữ liệu A	45
3.5	Số quan sát ngoại lệ theo IQR — các biến gốc của bộ dữ liệu A	45
3.6	Các biến số gốc thiếu dữ liệu nhiều nhất — bộ dữ liệu B . . .	46
3.7	Thống kê mô tả 10 biến số importance cao nhất — bộ dữ liệu B	47
3.8	Số quan sát ngoại lệ theo IQR — 10 biến quan trọng nhất của bộ dữ liệu B	47
3.9	Một số cặp tương quan đáng chú ý — bộ dữ liệu B	48
3.10	Các biến được xây dựng thêm từ dữ liệu ban đầu	51
3.11	Thống kê mô tả ba biến kỹ thuật của bộ dữ liệu A	54
3.12	Số quan sát ngoại lệ theo IQR — ba biến kỹ thuật của bộ dữ liệu A	54
3.13	Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A	56

3.14 Tỷ lệ thiếu của các biến kỹ thuật có tỷ lệ thiếu cao nhất — bộ dữ liệu B	59
3.15 Information Value của 13 biến — bộ dữ liệu A	61
3.16 Phân bố 98 đặc trưng của bộ dữ liệu B theo mức Information Value	63
3.17 Ví dụ ba hồ sơ thật của bộ A trước và sau xử lý	69
3.18 Ví dụ ba hồ sơ thật của bộ B có giá trị thiếu, trước và sau xử lý	70
3.19 Kết quả mô hình cơ sở ở vòng thăm dò ban đầu trên bộ dữ liệu B (34 biến, chỉ dùng trọng số lớp, chưa SMOTE)	75
3.20 Thiết kế lưới Grid Search theo từng mô hình	81
3.21 Thang điểm và hạng tín dụng dùng trong ứng dụng chấm điểm	83
4.1 Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng	89
4.2 Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A . .	90
4.3 Tỷ trọng importance theo nhóm nghiệp vụ của bộ dữ liệu A . .	91
4.4 Kết quả ngoài mẫu của các mô hình trên 98 đặc trưng	92
4.5 Precision, Recall và F1 của XGBoost theo nhóm nợ	93
4.6 Hiệu năng XGBoost theo số lượng đặc trưng Top- k	95
4.7 Tỷ trọng importance của XGBoost theo nhóm nghiệp vụ . . .	97
4.8 Importance theo SHAP (trung bình $ \phi_j $) — bộ dữ liệu A . . .	99
4.9 Tỷ trọng importance theo SHAP theo nhóm nghiệp vụ — bộ dữ liệu A	100
4.10 Top-15 importance theo SHAP — bộ dữ liệu B	101
4.11 Tỷ trọng importance theo SHAP theo nhóm nghiệp vụ — bộ dữ liệu B	102

4.12 So sánh Macro-F1: cấu hình mặc định vs. cấu hình tốt nhất theo	
Grid Search	105
4.13 Độ nhạy Macro-F1 theo mô hình (trên toàn bộ lưới đã thử) . .	106

Chương 1

GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI

Chương này mở đầu luận văn bằng việc trình bày bối cảnh, động lực nghiên cứu, phát biểu bài toán và mục tiêu nghiên cứu. Cụ thể, chương lần lượt: (i) phân tích vai trò của hoạt động tín dụng, rủi ro tín dụng và chuyển đổi số trong ngân hàng; (ii) khái quát sự phát triển của các phương pháp đánh giá tín dụng từ chuyên gia đến mô hình thống kê cùng các nghiên cứu liên quan; (iii) phát biểu chính thức bài toán phân loại năm nhóm nợ và làm rõ phạm vi thực nghiệm so với mục tiêu dài hạn của đề tài; và (iv) xác định mục tiêu, câu hỏi nghiên cứu và phương pháp nghiên cứu sẽ được triển khai xuyên suốt các chương tiếp theo.

1.1 Bối cảnh và động lực nghiên cứu

1.1.1 Hoạt động tín dụng và rủi ro tín dụng

Hoạt động tín dụng có vai trò đặc biệt quan trọng đối với ngân hàng thương mại. Thông qua hoạt động cấp tín dụng, ngân hàng cung ứng vốn cho cá nhân và tổ chức, đồng thời tạo ra nguồn thu từ lãi và phí. Tuy nhiên, do nghĩa vụ trả nợ được thực hiện trong tương lai, ngân hàng luôn phải đối mặt với sự không chắc chắn liên quan đến khả năng trả nợ của khách hàng.

Rủi ro tín dụng phát sinh khi khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính theo cam kết. Rủi ro này có thể bắt nguồn từ năng lực tài chính suy giảm, dòng tiền không ổn định, quản trị doanh nghiệp yếu, biến động thu nhập, thay đổi môi trường kinh doanh, biến động lãi suất, thông tin không đầy đủ hoặc hành vi gian lận. Hậu quả của rủi ro tín dụng có thể thể hiện qua nợ quá hạn, nợ xấu, chi phí dự phòng tăng, lợi nhuận giảm và mức độ an toàn vốn suy giảm.

Trong quản trị hiện đại, đánh giá tín dụng không nên chỉ được thực hiện một lần tại thời điểm phê duyệt. Ngân hàng cần cập nhật thông tin trong toàn bộ vòng đời khoản vay, theo dõi sự thay đổi của dư nợ, hành vi thanh toán, thời hạn, tình trạng cơ cấu lại và nhóm nợ. Điều này tạo ra nhu cầu xây dựng các mô hình có khả năng học từ dữ liệu lịch sử và hỗ trợ dự báo rủi ro theo thời gian.

1.1.2 Chuyển đổi số trong ngân hàng và vai trò của dữ liệu

Chuyển đổi số trong ngân hàng không chỉ là số hóa kênh giao dịch mà còn bao gồm tái cấu trúc quy trình nghiệp vụ, tự động hóa vận hành, xây dựng nền tảng dữ liệu và ứng dụng các mô hình phân tích trong quản trị.

Trong tín dụng, ngân hàng có thể khai thác nhiều nhóm dữ liệu như thông tin định danh, lịch sử hợp đồng, dư nợ, hạn mức, số ngày quá hạn, thời hạn khoản vay, mục đích vay, nhóm nợ, trạng thái cơ cấu lại và dữ liệu hành vi. Khi dữ liệu được làm sạch và quản trị phù hợp, các mô hình học máy có thể hỗ trợ nhận diện quy luật mà quy tắc thủ công khó phát hiện. Tuy nhiên, dữ liệu ngân hàng cũng có những thách thức như giá trị thiếu, sai lệch nghiệp vụ, mất cân bằng lớp, thay đổi theo thời gian và nguy cơ rò rỉ thông tin.

1.2 Sự phát triển của các phương pháp đánh giá tín dụng

1.2.1 Từ đánh giá chuyên gia đến mô hình thống kê

Phương pháp chuyên gia.

Phương pháp chuyên gia dựa trên kinh nghiệm của cán bộ tín dụng và các khung đánh giá như 5C.

Mô hình 5C là khung thẩm định tín dụng truyền thống, trong đó cán bộ tín dụng đánh giá khách hàng theo năm phương diện:

1. *Character* (tư cách và uy tín): mức độ thiện chí trả nợ, lịch sử thực hiện nghĩa vụ, tính trung thực và uy tín của khách hàng;
2. *Capacity* (năng lực trả nợ): khả năng tạo dòng tiền và thu nhập đủ để thực hiện nghĩa vụ trả nợ đúng hạn;
3. *Capital* (năng lực tài chính): quy mô vốn tự có, mức độ lành mạnh tài chính và khả năng hấp thụ tổn thất của khách hàng;
4. *Collateral* (tài sản bảo đảm): giá trị, tính pháp lý, khả năng thanh khoản và mức độ bù đắp tổn thất của tài sản bảo đảm;
5. *Conditions* (điều kiện): mục đích và điều kiện khoản vay, đồng thời bao gồm bối cảnh ngành, thị trường và kinh tế có thể ảnh hưởng đến khả năng trả nợ.

5C không phải là một thuật toán thống kê tự động tạo ra xác suất vỡ nợ. Đây là khung tổ chức thông tin để chuyên gia tổng hợp nhận định hoặc xếp loại theo quy định nội bộ. Vì vậy, chất lượng kết quả phụ thuộc đáng kể vào dữ liệu được cung cấp, bộ tiêu chí đánh giá và kinh nghiệm của người thẩm định.

Thành tựu của phương pháp này là hệ thống hóa các yếu tố định tính và định lượng cần xem xét, cho phép sử dụng thông tin về uy tín, năng lực quản trị, triển vọng ngành và tài sản bảo đảm [13, 22].

Tuy nhiên, phương pháp này phụ thuộc vào kinh nghiệm cá nhân, khó bảo đảm tính nhất quán, khó mở rộng và khó lượng hóa mức đóng góp của từng yếu tố.

Altman và mô hình Z-score.

Altman [1] đã đưa phân tích phân biệt đa biến vào dự báo phá sản doanh nghiệp thông qua mô hình:

$$Z = 1.2X_1 + 1.4X_2 + 3.3X_3 + 0.6X_4 + 1.0X_5.$$

Trong đó Z là điểm tổng hợp; X_1 là vốn lưu động/tổng tài sản; X_2 là lợi nhuận giữ lại/tổng tài sản; X_3 là lợi nhuận trước lãi vay và thuế/tổng tài sản; X_4 là giá trị thị trường vốn chủ sở hữu/giá trị sổ sách tổng nợ; và X_5 là doanh thu/tổng tài sản. Các hệ số 1,2; 1,4; 3,3; 0,6 và 1,0 được Altman ước lượng cho mẫu nghiên cứu gốc, không phải trọng số phổ quát cho mọi ngân hàng [1].

Thành tựu nổi bật của Altman là chứng minh rằng việc kết hợp nhiều tỷ số tài chính có thể dự báo khó khăn tài chính tốt hơn việc xem xét từng chỉ số riêng lẻ. Công trình này tạo nền tảng cho dự báo phá sản và xếp hạng doanh nghiệp.

Hạn chế của mô hình là phụ thuộc vào mẫu doanh nghiệp, ngành, chuẩn kế toán và giai đoạn nghiên cứu. Mô hình sử dụng chủ yếu dữ liệu kế toán, giả định quan hệ tuyến tính và không phù hợp trực tiếp với dữ liệu khách hàng cá nhân hoặc dữ liệu hành vi.

Ohlson và mô hình xác suất phá sản.

Ohlson [19] sử dụng hồi quy logistic để ước lượng xác suất phá sản. Đóng góp quan trọng là chuyển đầu ra từ một điểm phân biệt sang xác suất, tạo điều kiện thuận lợi cho lựa chọn ngưỡng và diễn giải rủi ro.

Hạn chế là quan hệ giữa log-odds và biến đầu vào được giả định tuyến tính, còn các tương tác và quan hệ phi tuyến phải được thiết kế thủ công.

1.2.2 Các nghiên cứu về đánh giá và dự báo rủi ro tín dụng

Hand và Henley.

Hand và Henley [13] hệ thống hóa các phương pháp phân loại thống kê trong đánh giá rủi ro tín dụng người vay. Hai tác giả làm rõ rằng không tồn tại một thuật toán duy nhất luôn tốt nhất trên mọi bộ dữ liệu; kết quả phụ thuộc vào chất lượng dữ liệu, lựa chọn biến, cách chia mẫu và tiêu chí đánh giá.

Hạn chế chủ yếu xuất phát từ bối cảnh thời điểm nghiên cứu: boosting, explainable AI, fairness và dữ liệu quy mô lớn chưa phát triển như hiện nay; phần lớn nội dung tập trung vào phân loại nhị phân.

Lyn C. Thomas.

Thomas [22] có đóng góp nổi bật trong việc hệ thống hóa các mô hình đánh giá hồ sơ tại thời điểm phê duyệt và các mô hình theo dõi hành vi sau giải ngân. Cách tiếp cận này mở rộng phạm vi đánh giá từ quyết định ban đầu sang quản lý khách hàng trong suốt vòng đời khoản vay.

Hạn chế của nhiều mô hình truyền thống được Thomas tổng hợp là tập trung vào dữ liệu có cấu trúc, phân loại tốt-xấu và giả định quan hệ tương đối ổn định theo thời gian.

Jonathan N. Crook.

Crook có nhiều đóng góp trong suy luận đối với hồ sơ bị từ chối, phân tích hành vi, phân tích sống còn và mô hình rủi ro động. Các nghiên cứu của ông làm rõ sai lệch chọn mẫu do dữ liệu huấn luyện thường chỉ gồm khách hàng đã được duyệt và mở rộng bài toán từ “có vỡ nợ hay không” sang “khi nào vỡ nợ” [10].

Hạn chế của reject inference là không thể quan sát chắc chắn nhãn thật của hồ sơ bị từ chối; survival model cũng phụ thuộc vào các giả định có thể không phù hợp với mọi dữ liệu.

Baesens và Lessmann.

Baesens và Lessmann có đóng góp quan trọng trong benchmark giữa các mô hình thống kê và học máy. Lessmann và cộng sự [16] cho thấy thứ hạng mô hình thay đổi theo dữ liệu, thước đo và quy trình thực nghiệm; ensemble thường cạnh tranh nhưng không thể mặc định luôn tối ưu.

Hạn chế của nhiều benchmark là sử dụng dữ liệu công khai nhỏ, cũ, chủ yếu nhị phân và chưa phản ánh đầy đủ dữ liệu ngân hàng thực tế.

Nhận xét tổng hợp. Các công trình nền tảng đã chuyển đánh giá tín dụng từ chủ quan sang định lượng, cho phép ước lượng xác suất rủi ro và xây dựng quy trình kiểm định mô hình trong nhiều giai đoạn của vòng đời khoản vay. Tuy nhiên, các hạn chế chung còn lại gồm tập trung vào phân loại nhị phân, khó mô hình hóa quan hệ phi tuyến, phụ thuộc vào xây dựng biến thủ công, chưa xử lý đầy đủ mất cân bằng lớp, thứ tự nhóm nợ, sự thay đổi phân bố dữ liệu và khả năng giải thích.

1.3 Phát biểu bài toán và phạm vi nghiên cứu

Cho tập dữ liệu:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i, t_i)\}_{i=1}^N,$$

trong đó N là số quan sát; $\mathbf{x}_i \in \mathbb{R}^p$ là véc-tơ gồm p đặc trưng của quan sát i ; $y_i \in \{1, 2, 3, 4, 5\}$ là nhóm nợ; và t_i là thời điểm ghi nhận nếu trường thời gian khả dụng.

Mục tiêu là xây dựng:

$$f_{\theta} : \mathbf{x}_i \longrightarrow (p_{i1}, p_{i2}, p_{i3}, p_{i4}, p_{i5}),$$

trong đó f_{θ} là bộ phân loại được xác định bởi tập tham số θ ; p_{ik} là xác suất do mô hình gán quan sát i vào nhóm k . với:

$$p_{ik} = P(Y_i = k \mid \mathbf{x}_i), \quad \sum_{k=1}^5 p_{ik} = 1.$$

Nhãn dự báo:

$$\hat{y}_i = \arg \max_{k \in \{1, 2, 3, 4, 5\}} p_{ik}.$$

Ký hiệu $\hat{y}_i$ là nhãn dự báo; toán tử $\arg \max$ chọn chỉ số nhóm có xác suất lớn nhất.

Do năm nhóm có quan hệ về mức độ rủi ro:

$$1 < 2 < 3 < 4 < 5,$$

bài toán cần vừa đạt hiệu quả tổng thể, vừa nhận diện nhóm rủi ro cao, giảm khoảng cách sai lệch, hạn chế đánh giá thấp rủi ro, duy trì khả năng tổng quát hóa theo thời gian và bảo đảm khả năng giải thích.

1.3.1 Điểm phát triển so với các công trình đi trước

Nghiên cứu phát triển hơn các công trình đi trước ở các khía cạnh:

1. chuyển từ nhị phân sang phân loại trực tiếp năm nhóm nợ;
2. xem xét thứ tự của nhãn bằng $|y_i - \hat{y}_i|$;
3. sử dụng hai bộ dữ liệu thực tế đã ẩn danh từ một ngân hàng Việt Nam để đối chiếu kết luận trong hai cấu trúc dữ liệu khác nhau;
4. xây dựng đặc trưng nghiệp vụ về thời hạn, mục đích vay, cơ cấu nợ và tính nhất quán;
5. xem mất cân bằng lớp là thành phần trung tâm;
6. cài đặt sáu mô hình và xác nhận lại kết quả của năm mô hình chạy thành công trong môi trường hiện tại;
7. kết hợp hiệu quả dự báo với feature importance và SHAP;
8. lựa chọn mô hình theo hiệu quả, nhận diện rủi ro, sai lệch thứ tự và khả năng giải thích.

Tính mới của luận văn không nằm ở việc phát minh một thuật toán mới, mà nằm ở cách xây dựng, đánh giá và tổ chức bài toán phù hợp hơn với dữ liệu tín dụng thực tế.

1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu

1.4.1 Mục tiêu nghiên cứu

Mục tiêu tổng quát.

Xây dựng và đánh giá các mô hình học máy nhằm hỗ trợ phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam, đồng thời xác định cấu hình đặc trưng có giá trị cho định hướng cảnh báo sớm.

Mục tiêu cụ thể.

1. Hệ thống hóa lý thuyết và nghiên cứu liên quan.
2. Làm sạch và xây dựng đặc trưng từ dữ liệu thực tế.
3. Xây dựng Logistic Regression làm baseline.
4. So sánh với Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost.
5. Đánh giá ảnh hưởng của mất cân bằng lớp.
6. Phân tích tính thứ tự và mức độ nghiêm trọng của sai số.
7. Giải thích kết quả bằng các phương pháp phù hợp.

1.4.2 Câu hỏi nghiên cứu

1. Mô hình nào cân bằng tốt nhất giữa hiệu quả phân loại tổng thể, khả năng nhận diện các nhóm nợ rủi ro và mức độ giải thích được?
2. Nhiều đặc trưng hơn có luôn giúp mô hình phân loại nhóm nợ tốt hơn không?
3. Nhóm đặc trưng nghiệp vụ nào đóng góp lớn nhất cho việc phân loại nhóm nợ?
4. Cần bổ sung cấu trúc dữ liệu và cách kiểm định nào để phát triển mô hình hiện tại thành mô hình dự báo khả năng chuyển nhóm nợ và cảnh báo sớm?

1.4.3 Phương pháp nghiên cứu

Luận văn kết hợp nghiên cứu định tính để tổng quan tài liệu với nghiên cứu định lượng để xử lý dữ liệu, xây dựng mô hình và đánh giá thực nghiệm. Quy trình hiện tại được chạy độc lập trên *Data_credit_rating_VN.xlsx* và *fct_l.xlsx*, gồm làm sạch, xây dựng đặc trưng, EDA, chia ngẫu nhiên phân tầng, xử lý mất cân bằng, huấn luyện, đánh giá và giải thích mô hình. Các kết quả giữa hai bộ chỉ được đối chiếu về xu hướng, không so sánh điểm số như hai mẫu đồng nhất.

Về khoa học, luận văn bổ sung bằng chứng thực nghiệm về phân loại năm nhóm nợ, kết hợp mất cân bằng và khả năng giải thích. Về thực tiễn, kết quả có thể hỗ trợ chuẩn hóa đánh giá, nhận diện khoản vay suy giảm và xây dựng cảnh báo sớm. Mô hình chỉ đóng vai trò hỗ trợ, không thay thế hoàn toàn quyết định của cán bộ tín dụng.

1.5 Tóm tắt chương

Chương 1 đã trình bày bối cảnh và động lực nghiên cứu xuất phát từ vai trò của hoạt động tín dụng và rủi ro tín dụng trong ngân hàng thương mại, khái quát sự phát triển của các phương pháp đánh giá tín dụng từ cách tiếp cận chuyên gia, mô hình thống kê đến các nghiên cứu học máy liên quan, đồng thời phát biểu chính thức bài toán phân loại năm nhóm nợ cùng mục tiêu, câu hỏi và phương pháp nghiên cứu của luận văn. Điểm phát triển so với các công trình đi trước và phạm vi thực nghiệm hiện tại cũng đã được làm rõ để tránh diễn giải vượt quá bằng chứng sẵn có.

Trên cơ sở đó, Chương 2 sẽ hệ thống hóa cơ sở lý thuyết về tín dụng, rủi ro và phân loại nhóm nợ, trình bày các mô hình học máy được sử dụng, những thách

thức đặc thù của dữ liệu tín dụng, hệ thống chỉ tiêu đánh giá và tổng quan các nghiên cứu liên quan, làm nền tảng lý thuyết cho phần dữ liệu và phương pháp thực nghiệm ở Chương 3.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

Kế thừa bối cảnh, phát biểu bài toán và mục tiêu nghiên cứu đã trình bày ở Chương 1, chương này hệ thống hóa cơ sở lý thuyết làm nền tảng cho phần dữ liệu và thực nghiệm ở các chương sau. Chương lần lượt trình bày: (i) khái niệm tín dụng, rủi ro tín dụng, phân loại năm nhóm nợ và tổn thất kỳ vọng; (ii) sự chuyển dịch từ các phương pháp đánh giá truyền thống sang các mô hình học máy, gồm mô hình tuyến tính, cây quyết định và các mô hình boosting được sử dụng trong luận văn; (iii) những thách thức đặc thù khi mô hình hóa dữ liệu tín dụng như mất cân bằng lớp, tính thứ tự của nhóm nợ, thay đổi theo thời gian và khả năng giải thích; (iv) hệ thống chỉ tiêu đánh giá mô hình được dùng xuyên suốt luận văn; và (v) tổng quan các nghiên cứu liên quan, từ đó xác định khoảng trống và định hướng nghiên cứu.

2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ

2.1.1 Khái niệm tín dụng và rủi ro tín dụng

Tín dụng là quan hệ kinh tế trong đó bên cho vay chuyển giao quyền sử dụng một lượng giá trị cho bên đi vay trong một khoảng thời gian xác định, với nghĩa vụ hoàn trả theo các điều kiện đã thỏa thuận.

Rủi ro tín dụng là khả năng phát sinh tổn thất do khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính. Rủi ro chịu ảnh hưởng từ năng lực tài chính, đặc điểm khoản vay, lịch sử tín dụng, chính sách cấp tín dụng và điều kiện kinh tế.

2.1.2 Phân loại nhóm nợ

Bảng 2.1: Các nhóm nợ trong nghiên cứu

1	Nợ đủ tiêu chuẩn	Mức rủi ro thấp.
2	Nợ cần chú ý	Đã xuất hiện dấu hiệu cần theo dõi.
3	Nợ dưới tiêu chuẩn	Khả năng thu hồi suy giảm đáng kể.
4	Nợ nghi ngờ	Mức rủi ro cao.
5	Nợ có khả năng mất vốn	Mức rủi ro cao nhất.


2.1.3 Xếp hạng tín dụng và tổn thất kỳ vọng

Xếp hạng tín dụng là quá trình gán khách hàng hoặc khoản vay vào một hạng rủi ro dựa trên thông tin tài chính, đặc điểm khoản vay và lịch sử thực hiện nghĩa vụ. Trong phạm vi luận văn, năm nhóm nợ được xem là các mức rủi ro có thứ tự; mô hình được xây dựng để hỗ trợ nhận diện nhóm nợ tương ứng của từng quan sát.

Tổn thất kỳ vọng có thể biểu diễn:

$$EL = PD \times LGD \times EAD.$$

Trong đó EL là tổn thất kỳ vọng; PD là xác suất vỡ nợ trong kỳ đánh giá; LGD là tỷ lệ tổn thất khi vỡ nợ sau khi xét khả năng thu hồi; và EAD là dư nợ tại thời điểm vỡ nợ. Luận văn hiện tập trung vào phân loại trạng thái rủi ro, chưa trực tiếp ước lượng đủ ba cấu phần của EL [4].



Hình 2.1: Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng

Nguồn: Tác giả tổng hợp và vẽ lại từ Basel Committee on Banking Supervision [4].

2.2 Từ đánh giá truyền thống đến các mô hình học máy

2.2.1 Sự chuyển dịch từ phương pháp truyền thống sang học máy

Phương pháp chuyên gia có khả năng khai thác thông tin định tính nhưng chủ quan. Z-score của Altman có ý nghĩa nền tảng nhưng phụ thuộc dữ liệu kế toán và quan hệ tuyến tính. Logistic Regression dễ giải thích nhưng khó tự động nắm bắt tương tác phức tạp.

Học máy là nhánh của AI trong đó mô hình học quy luật từ dữ liệu. Bài toán của luận văn thuộc học có giám sát.

2.2.2 Mô hình tuyến tính và cây quyết định

Logistic Regression đa lớp.

$$P(Y = k | \mathbf{x}) = \frac{\exp(\beta_{k0} + \beta_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\beta_{j0} + \beta_j^T \mathbf{x})}.$$

Trong đó K là số lớp; $\mathbf{x}$ là véc-tơ đặc trưng; β_{k0} là hệ số chặn của lớp k ; β_k là véc-tơ hệ số của lớp k ; và mẫu số chuẩn hóa để tổng xác suất của K lớp bằng 1 [14].

Decision Tree.

Decision Tree chia không gian đặc trưng bằng các điều kiện dạng $x_j \leq s$. Mô hình dễ giải thích nhưng dễ overfitting.

Random Forest.

$$\hat{y} = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^B.$$


Trong đó B là số cây; $h_b(\mathbf{x})$ là dự báo lớp của cây thứ b tại hồ sơ $\mathbf{x}$; và mode chọn lớp xuất hiện nhiều nhất trong các dự báo cây [6].

2.2.3 Các mô hình boosting

XGBoost.

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t).$$

Trong đó t là vòng boosting; n là số quan sát huấn luyện; $l(\cdot)$ là hàm mất mát; $\hat{y}_i^{(t-1)}$ là dự báo tích lũy trước vòng t ; f_t là cây mới; và $\Omega(f_t)$ là số hạng phạt độ phức tạp của cây nhằm hạn chế quá khớp [9].




Hình 2.2: Cơ chế cộng dồn các cây trong XGBoost

Nguồn: Tác giả khái quát và vẽ lại từ Chen và Guestrin [9].

Hình 2.2 thể hiện cách dự báo được cập nhật tuần tự. Mỗi cây mới $f_t(\mathbf{x})$ hiệu chỉnh phần sai số còn lại của tổ hợp trước đó; η là hệ số học điều chỉnh mức đóng góp của cây mới. XGBoost đồng thời đưa số hạng chính quy $\Omega(f_t)$ vào hàm mục tiêu để kiểm soát độ phức tạp.

LightGBM.

LightGBM tối ưu tốc độ và bộ nhớ bằng các kỹ thuật như Gradient-based One-Side Sampling và Exclusive Feature Bundling. Thuật toán phát triển cây theo lá tốt nhất, tức là tại mỗi bước ưu tiên tách lá tạo ra mức giảm hàm mất mát lớn nhất. Cách phát triển này có thể hội tụ nhanh nhưng cũng làm cây mất cân đối và dễ quá khớp khi dữ liệu nhỏ; vì vậy cần kiểm soát *num_leaves*, *min_data_in_leaf* và *max_depth* [15, 18].



Hình 2.3: So sánh phát triển cây theo tầng và theo lá tốt nhất

Nguồn: Tác giả vẽ lại từ Ke và cộng sự [15] và tài liệu LightGBM [18].

CatBoost.

CatBoost xử lý biến phân loại và sử dụng ordered boosting để hạn chế leakage [20].

2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng

2.3.1 Thách thức đối với hiệu năng dự báo

Mất cân bằng lớp.

$$\mathcal{L} = - \sum_{i=1}^N w_{y_i} \sum_{k=1}^K \mathbb{I}(y_i = k) \log p_{ik}.$$

Trong đó N là số quan sát; K là số lớp; w_{y_i} là trọng số gán cho lớp thật của quan sát i ; $\mathbb{I}(y_i = k)$ bằng 1 khi $y_i = k$ và bằng 0 trong trường hợp khác; p_{ik} là xác suất dự báo lớp k . Trọng số lớn hơn cho lớp hiếm làm sai số của lớp đó có ảnh hưởng lớn hơn tới hàm mất mát.

Tính thứ tự. Năm nhóm nợ có thứ tự rủi ro từ thấp đến cao nên hai sai số lệch

một bậc và lệch bốn bậc không có mức độ nghiêm trọng như nhau. Luận văn sử dụng Ordinal MAE ở phần chỉ tiêu đánh giá để lượng hóa số bậc sai lệch trung bình; chỉ tiêu này chưa được hàm `compute_metrics()` của mã nguồn báo cáo trong kết quả chính.


Thay đổi theo thời gian.

$$\mathcal{D}_{train} < \mathcal{D}_{validation} < \mathcal{D}_{test}.$$

2.3.2 Khả năng giải thích và yêu cầu ứng dụng

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j.$$

Trong đó $f(\mathbf{x})$ là đầu ra mô hình cần giải thích; ϕ_0 là giá trị nền; p là số đặc trưng; và ϕ_j là đóng góp SHAP của đặc trưng j cho hồ sơ $\mathbf{x}$ [17].



Hình 2.4: Nguyên lý phân rã dự báo theo giá trị SHAP

Nguồn: Tác giả khái quát và vẽ lại từ Lundberg và Lee [17].

Hình 2.4 minh họa tính cộng của SHAP: dự báo bắt đầu từ giá trị nền ϕ_0 , sau đó được điều chỉnh tăng hoặc giảm bởi đóng góp của từng đặc trưng. Dấu của ϕ_j cho biết chiều tác động đối với đầu ra đang được giải thích, còn độ lớn tuyệt đối phản ánh cường độ đóng góp.

2.4 Hệ thống chỉ tiêu đánh giá mô hình

2.4.1 Chỉ tiêu tổng thể và theo lớp

Accuracy.

$$Accuracy = \frac{\sum_{k=1}^K C_{kk}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}.$$

Trong đó C_{ij} là số quan sát có lớp thật i và lớp dự báo j ; tử số là tổng phần tử đường chéo; mẫu số là tổng số quan sát.

Precision, Recall và F1.

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k},$$

Trong đó TP_k là số dự báo đúng lớp k ; FP_k là số quan sát lớp khác bị dự báo nhầm thành k ; và FN_k là số quan sát lớp k bị dự báo sang lớp khác.

$$F1_k = 2 \frac{Precision_k \times Recall_k}{Precision_k + Recall_k}.$$

2.4.2 Chỉ tiêu cho dữ liệu mất cân bằng

Macro F1.

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Weighted F1.

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k.$$

Trong đó n_k là số quan sát thật của lớp k và N là tổng số quan sát. Khi một lớp chiếm tỷ trọng rất lớn, Weighted-F1 có thể che khuất hiệu năng thấp của lớp hiếm.

Balanced Accuracy.

$$\text{Balanced Accuracy} = \frac{1}{K} \sum_{k=1}^K \text{Recall}_k.$$

Balanced Accuracy là trung bình Recall của K lớp, nên mỗi lớp có trọng số như nhau bất kể tần suất.

2.4.3 Chỉ tiêu phản ánh thứ tự nhóm nợ

Ordinal MAE.

$$\text{Ordinal MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

Ký hiệu có ý nghĩa như phần Tính thứ tự; giá trị càng nhỏ thì khoảng cách nhóm dự báo so với nhóm thật càng thấp.

2.5 Nghiên cứu liên quan, khoảng trống và định hướng

2.5.1 Kết quả chính của các nghiên cứu liên quan

Hand và Henley [13] hệ thống hóa các phương pháp phân loại thống kê; Thomas [22] mở rộng phạm vi từ đánh giá tại thời điểm phê duyệt sang theo dõi hành vi trong vòng đời khoản vay. Baesens và cộng sự [2] và Lessmann và cộng sự [16] cho thấy hiệu quả mô hình phụ thuộc vào dữ liệu, thước đo và quy trình đánh giá.

Brown và Mues [7] nhấn mạnh ảnh hưởng của mất cân bằng. Xia và cộng sự [23] cho thấy boosted tree có khả năng cải thiện dự báo. Barboza và cộng sự [3] ghi nhận kết quả cạnh tranh của các mô hình cây trong dự báo phá sản. Dastile và cộng sự [11] chỉ ra các hạn chế phổ biến về dữ liệu nhỏ, mất cân bằng, thiếu

chuẩn đánh giá và khả năng giải thích.

Tại Việt Nam, nghiên cứu thường tập trung vào đánh giá rủi ro tín dụng cá nhân, rủi ro doanh nghiệp và dự báo nợ xấu. Tuy nhiên, chưa có nhiều nghiên cứu công bố việc phân loại trực tiếp năm nhóm nợ trên dữ liệu thực tế, kết hợp so sánh nhiều mô hình, chia dữ liệu theo thời gian, đánh giá có xét thứ tự và phân tích khả năng giải thích.

2.5.2 Khoảng trống và định hướng của luận văn

1. Phần lớn nghiên cứu dùng mục tiêu nhị phân.
2. Tính thứ tự của năm nhóm nợ chưa được khai thác đầy đủ.
3. Dữ liệu thực tế tại ngân hàng Việt Nam ít được công bố.
4. Random split vẫn phổ biến hơn temporal split.
5. Lớp rủi ro cao ít quan sát nhưng chưa được đánh giá đầy đủ.
6. Mô hình phức tạp thường thiếu khả năng giải thích.

Định hướng nghiên cứu. Luận văn xây dựng bài toán năm nhóm nợ, kiểm tra và xây dựng đặc trưng nghiệp vụ, cài đặt Logistic Regression làm baseline, so sánh với mô hình cây và boosting, xử lý mất cân bằng, đánh giá bằng chỉ tiêu đa lớp và giải thích mô hình bằng feature importance và SHAP. Thực nghiệm hiện tại dùng chia ngẫu nhiên phân tầng; chia theo thời gian là yêu cầu cho giai đoạn xây dựng nhãn chuyển nhóm.

2.6 Tóm tắt chương

Chương này đã trình bày cơ sở lý thuyết, thành tựu và hạn chế của các công trình nền tảng, các mô hình được sử dụng, các vấn đề đặc thù của dữ liệu tín dụng, hệ thống chỉ tiêu đánh giá, tổng quan nghiên cứu, khoảng trống và định hướng của luận văn.

Trên cơ sở lý thuyết và định hướng đã xác lập, Chương 3 sẽ trình bày cụ thể nguồn dữ liệu, quy trình xử lý, phân tích khám phá dữ liệu, xây dựng đặc trưng nghiệp vụ và phương pháp thực nghiệm được cài đặt trong mã nguồn trên hai bộ dữ liệu thực tế của luận văn.

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Trên cơ sở lý thuyết và định hướng nghiên cứu đã trình bày ở Chương 2, chương này mô tả dữ liệu và quy trình thực nghiệm được triển khai trong mã nguồn. Nội dung chương bao gồm: (i) định hướng, phạm vi thực nghiệm và tổng quan quy trình nghiên cứu; (ii) thu thập dữ liệu; (iii) phân tích khám phá và làm sạch dữ liệu; (iv) tiền xử lý và lựa chọn biến; (v) phân chia dữ liệu huấn luyện–kiểm định và xử lý mất cân bằng lớp; (vi) huấn luyện mô hình, bao gồm xây dựng, hiệu chỉnh, triển khai và định hướng giám sát mô hình.

3.1 Định hướng và phạm vi thực nghiệm

Tập nguồn bao gồm hai bộ dữ liệu chứa thông tin đã được mã hóa về các khoản vay tại hai ngân hàng ở Việt Nam. Bộ dữ liệu A, **Data_credit_rating_VN.xlsx**, gồm 27.001 quan sát và 21 biến ban đầu; biến đích **NHOMNOMOI** nhận giá trị từ 1 đến 5, tương ứng với năm nhóm nợ. Bộ dữ liệu B, **fct_1.xlsx**, gồm 5.400 quan sát và 178 biến ban đầu; biến đích **CLASSIFICATION** cũng biểu thị

nhóm nợ từ 1 đến 5.

Mục tiêu dài hạn của đề tài là xây dựng mô hình học máy dự báo khả năng chuyển nhóm nợ của khách hàng nhằm hỗ trợ cảnh báo sớm rủi ro tín dụng. Tuy nhiên, do hai bộ dữ liệu hiện có chỉ phản ánh trạng thái nhóm nợ tại một thời điểm, phạm vi thực nghiệm của luận văn được giới hạn ở bài toán phân loại năm nhóm nợ. Kết quả thu được vì vậy đóng vai trò mô hình cơ sở để kiểm chứng quy trình xử lý dữ liệu và phương pháp mô hình hóa, chưa phải bằng chứng thực nghiệm về năng lực dự báo chuyển nhóm nợ trong tương lai.

Nếu có dữ liệu bảng theo thời gian, nhãn chuyển nhóm cần được định nghĩa:


$$Y_{i,t}^{(h)} = \begin{cases} 1, & G_{i,t+h} > G_{i,t}, \\ 0, & G_{i,t+h} \leq G_{i,t}, \end{cases}$$

trong đó i biểu thị khoản vay hoặc khách hàng; t là thời điểm quan sát; h là khoảng dự báo; $G_{i,t} \in \{1, 2, 3, 4, 5\}$ là nhóm nợ tại thời điểm t ; và $Y_{i,t}^{(h)} = 1$ biểu thị sự chuyển dịch sang nhóm có mức rủi ro cao hơn trong khoảng h . Đây là cách xác định nhãn được đề xuất cho nghiên cứu tiếp theo khi có dữ liệu theo thời gian, không phải nhãn được sử dụng trong thực nghiệm hiện tại.

3.2 Quy trình nghiên cứu tổng thể

Quy trình thực nghiệm được tổ chức thành bảy bước tuần tự, thể hiện tại Hình 3.1: (1) thu thập dữ liệu gốc; (2) phân tích khám phá và làm sạch dữ liệu; (3) tiền xử lý và lựa chọn biến, bao gồm tính WOE/IV, mã hóa và chuẩn hóa; (4) phân chia tập huấn luyện–kiểm định và xử lý mất cân bằng lớp; (5) huấn luyện mô hình; (6) đánh giá hiệu quả và giải thích kết quả; và (7) rút ra kết luận cùng

khuyến nghị ứng dụng. Cấu trúc này góp phần hạn chế ảnh hưởng của dữ liệu kiểm định đối với quá trình huấn luyện và phù hợp với nguyên tắc đánh giá ngoài mẫu trong học máy [5, 16].



Hình 3.1: Pipeline nghiên cứu tổng thể — từ thu thập dữ liệu tới kết luận và ứng dụng

3.3 Bước 1 — Thu thập dữ liệu

Bước đầu tiên của quy trình gồm thu thập và kiểm tra hai tệp dữ liệu gốc, xác định biến đích và khảo sát sơ bộ phân bố nhóm nợ trước khi thực hiện các bước xử lý tiếp theo.

3.3.1 Bộ dữ liệu A: `Data_credit_rating_VN`

Bộ dữ liệu A gồm 27.001 hợp đồng vay và không có bản ghi nào bị thiếu dữ liệu ở cột đích **NHOMNOMOI**. Bảng 3.1 cho ta thấy nhóm 1 chiếm 77,65%, trong khi nhóm 3 chỉ chiếm 2,24%. Mức mất cân bằng với bộ dữ liệu này khá cao.

Bảng 3.1: Phân bố năm nhóm nợ trong bộ dữ liệu A

Nhóm	Toàn bộ	Tỷ lệ (%)	Huấn luyện	Kiểm định
1	20.965	77,65	16.771	4.194
2	1.287	4,77	1.030	257
3	604	2,24	483	121
4	784	2,90	627	157
5	3.361	12,45	2.689	672
Tổng	27.001	100,00	21.600	5.401

3.3.2 Bộ dữ liệu B: `fct_l`

Bộ dữ liệu B gồm 5.400 hợp đồng vay và không có bản ghi nào bị thiếu dữ liệu ở cột đích **CLASSIFICATION**. Từ bảng 3.2, ta thấy mức mất cân bằng với bộ dữ liệu này rất cao.

Bảng 3.2: Phân bố năm nhóm nợ trong dữ liệu

Nhóm	Toàn bộ có nhãn	Tỷ lệ (%)	Huấn luyện	Kiểm định
1	5.247	97,51	4.197	1.050
2	87	1,62	70	17
3	11	0,20	9	2
4	13	0,24	10	3
5	23	0,43	18	5
Tổng	5.381	100,00	4.304	1.077

Tỷ lệ nhóm 1 rất cao, trong khi nhóm 3 và 4 chỉ có 11 và 13 quan sát trong toàn bộ dữ liệu. Đây là hạn chế của bộ dữ liệu B. Với hai quan sát nhóm 3 trong tập kiểm định, một dự báo đúng hoặc sai sẽ làm kết quả phân loại theo lớp có phương sai rất lớn và không đủ để khẳng định khả năng tổng quát hóa.

3.4 Bước 2 — EDA & làm sạch dữ liệu

Tiếp theo chúng ta sẽ tiến hành khảo sát hai bộ dữ liệu gốc bằng thống kê mô tả, phát hiện ngoại lệ theo khoảng tứ phân vị (IQR), tỷ lệ giá trị thiếu và ma trận tương quan Pearson giữa các biến số. Mục tiêu của bước này là xác định biến nào cần chuẩn hóa mạnh, biến nào có nguy cơ đa cộng tuyến, và biến nào có phân phối quá lệch để lựa chọn phương pháp điền khuyết phù hợp — không chỉ mô tả mà còn làm căn cứ cho các quyết định tiền xử lý trình bày ở Bước 3 (mục 3.5.7).

3.4.1 Bộ dữ liệu A

Làm sạch định dạng trường ngày

Trước khi tính các thống kê mô tả, hai trường ngày *OPEN_DATE* và *NGAYDENHAN* được kiểm tra định dạng. Kết quả cho thấy phần lớn bản

ghi lưu ngày dưới dạng chuỗi văn bản dd/mm/yyyy (ví dụ “28/12/2010”), nhưng một bộ phận đáng kể lại lưu dưới dạng số thứ tự ngày kiểu Excel (Excel serial date — ví dụ “40490” thay vì “08/11/2010”), phát sinh từ lỗi định dạng ô tính khi xuất dữ liệu nguồn. Bảng 3.3 thống kê số bản ghi bị ảnh hưởng.

Bảng 3.3: Số bản ghi có trường ngày lưu sai định dạng (số thứ tự Excel) — bộ dữ liệu A

Trường	Số bản ghi bị ảnh hưởng	Tỷ lệ (%)
OPEN_DATE	9.949	36,84
NGAYDENHAN	9.890	36,63

Bộ phân tích cú pháp ngày tháng của mã nguồn chỉ nhận diện các mẫu văn bản dd/mm/yyyy và yyyy-mm-dd[hh:mm:ss]; nếu áp dụng trực tiếp lên dữ liệu chưa được kiểm tra định dạng, toàn bộ các bản ghi lưu dưới dạng số thứ tự sẽ bị bỏ qua và chuyển thành giá trị thiếu (NaT) một cách âm thầm — kéo theo *LOAN_TENURE_DAYS* và *DAYS_TO_MATURITY* (mục 3.5.2), hai đặc trưng kỹ thuật được tính trực tiếp từ hai trường này, cũng bị thiếu dữ liệu ở đúng các bản ghi đó. Vì vậy, các số thứ tự ngày kiểu Excel trong hai trường này được quy đổi về đúng giá trị ngày tháng tương ứng theo mốc gốc chuẩn của Excel (30/12/1899), còn các bản ghi đã ở dạng văn bản dd/mm/yyyy được giữ nguyên. Sau bước làm sạch, cả *OPEN_DATE* và *NGAYDENHAN* không còn bản ghi nào bị thiếu hoặc phân tích cú pháp thất bại, phù hợp với nhận định ở Bảng 3.4 rằng bộ A không có biến số nào bị thiếu dữ liệu.

Bảng 3.4 trình bày thống kê mô tả năm biến số gốc của bộ A trên toàn bộ 27.001 quan sát.

Bảng 3.4: Thống kê mô tả các biến số gốc của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
BASE_BAL	$4,28 \times 10^8$	$6,40 \times 10^9$	2	$3,50 \times 10^7$	$3,85 \times 10^{11}$
CURR_BAL	$3,56 \times 10^8$	$5,32 \times 10^9$	1	$4,40 \times 10^7$	$2,96 \times 10^{11}$
LAISUAT	0,0688	0,0681	0	0,1000	0,4000
ORGNBR	58,34	35,95	3	59	138
PARENTORGNBR	42,53	34,29	3	34	138

Không biến số nào của bộ A có giá trị thiếu cho thấy các nhóm nghiệp vụ của bộ dữ liệu A gần như đầy đủ. Tuy nhiên, độ lệch chuẩn của **BASE_BAL** và **CURR_BAL** lớn hơn trung bình hàng chục lần — dấu hiệu phân phối lệch phải mạnh, điển hình của biến tiền tệ trong dữ liệu ngân hàng.

Bảng 3.5 lượng hóa mức độ lệch bằng số quan sát nằm ngoài khoảng $[Q_1 - 1,5IQR, Q_3 + 1,5IQR]$ cho năm biến gốc này.

Bảng 3.5: Số quan sát ngoại lệ theo IQR — các biến gốc của bộ dữ liệu A

Biến	Số ngoại lệ	Tỷ lệ (%)
CURR_BAL	2.462	9,12
BASE_BAL	1.925	7,13
LAISUAT	4	0,01
ORGNBR	0	0,00
PARENTORGNBR	0	0,00

Trong năm biến gốc, **CURR_BAL** và **BASE_BAL** có tỷ lệ ngoại lệ cao nhất (9,12% và 7,13%), nhất quán với độ lệch phải mạnh đã nêu ở Bảng 3.4; **LAISUAT**, **ORGNBR** và **PARENTORGNBR** gần như không có ngoại lệ.

Về biến phân loại, *MJACCTTYPCD* có 3 nhóm, trong đó nhóm CNS (vay tiêu dùng) chiếm 82,51%, MTG (thế chấp) 9,26% và CML (thương mại) 8,23% — mất cân bằng nhưng không đến mức cực đoan như biến đích. *CURRMIACCTTYPCD* có 31 nhóm và *MUCDICHVAY* có 79 nhóm mục đích

vay, với 5 mục đích phổ biến nhất (thẻ Visa/JCB, sửa chữa nhà, tiêu dùng sinh hoạt, nông nghiệp, mua nhượng bất động sản) chiếm 83,06% tổng số hồ sơ. Cả hai biến có bản chất định danh (nominal) không có thứ tự tự nhiên, nhưng pipeline hiện dùng LabelEncoder gán số nguyên theo thứ tự xuất hiện — như đã nêu ở mục tiền xử lý, đây là hạn chế kỹ thuật cần lưu ý khi diễn giải hệ số hoặc ranh giới quyết định của Logistic Regression và Decision Tree.

3.4.2 Bộ dữ liệu B

Khác với bộ A, bộ B có tỷ lệ thiếu dữ liệu rất cao ở nhiều biến gốc. Bảng 3.6 liệt kê 5 biến gốc thiếu nhiều nhất.

Bảng 3.6: Các biến số gốc thiếu dữ liệu nhiều nhất — bộ dữ liệu B

Biến	Tỷ lệ thiếu (%)
EXTEND_SCH_NUM	99,29
BALANCE_MAT	84,32
DISBURSEMENT_AMT_YTD	79,61
LAST_DISBURSEMENT_AMT	79,61
MIN_CONTRACT_RATE	79,61

Nhiều biến thiếu đúng 79,61% cùng lúc (*DISBURSEMENT_AMT_YTD*, *MIN_CONTRACT_RATE*, *PD_BALANCE...*) — dấu hiệu các biến này chỉ được ghi nhận cho một nguồn dữ liệu (*DATASOURCE*) trong hai nguồn PD/LD của bộ B, không phải thiếu ngẫu nhiên. Đây là lý do `SimpleImputer(strategy="median")` được chọn thay vì loại bỏ các cột này: loại bỏ sẽ mất toàn bộ tín hiệu của phân khúc dữ liệu còn lại; điền trung vị bảo toàn được biến trong khi không giả định phân phối cụ thể, phù hợp hơn giá trị trung bình vốn nhạy với đuôi phân phối rất dài của các biến tiền tệ (Bảng 3.7).

Bảng 3.7: Thống kê mô tả 10 biến số importance cao nhất — bộ dữ liệu B

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Thiếu (%)
DISBURSEMENT_AMT_YTD	$-4,78 \times 10^7$	$4,01 \times 10^8$	0	79,61
AGG_PD_BAL_YTD	$3,91 \times 10^7$	$9,80 \times 10^8$	0	0,00
AGG_BAL_YTD	$8,02 \times 10^9$	$7,01 \times 10^{10}$	0	79,61
AGG_PD_BAL_YTD_LCY	$4,33 \times 10^7$	$1,02 \times 10^9$	0	0,00
ACC_PD_BAL_RATE	$1,13 \times 10^{11}$	$2,38 \times 10^{12}$	$5,44 \times 10^7$	0,00
BALANCE	$2,45 \times 10^6$	$5,44 \times 10^7$	0	0,00
BALANCE_PE	$3,01 \times 10^4$	$1,90 \times 10^6$	0	20,39
LN_APPR_AMT	$8,15 \times 10^7$	$6,22 \times 10^8$	0	79,61
INTEREST_RATE	28,74	17,97	27,00	0,00
MIS_DAO	377,79	2.223,65	99,00	1,65

Trung vị bằng 0 ở phần lớn biến trong Bảng 3.7 phản ánh đa số hồ sơ không phát sinh giao dịch trong kỳ báo cáo (giải ngân, dư nợ gộp theo năm...), trong khi trung bình vẫn dương hoặc âm lớn — bằng chứng phân phối rất lệch với đuôi dài, khiến điền khuyết theo trung vị phù hợp hơn theo trung bình. Tỷ lệ ngoại lệ theo IQR (Bảng 3.8) xác nhận điều này: *ACC_PD_BAL_RATE* có tới 18,01% giá trị nằm ngoài khoảng IQR.


Bảng 3.8: Số quan sát ngoại lệ theo IQR — 10 biến quan trọng nhất của bộ dữ liệu B

Biến	Số ngoại lệ	Tỷ lệ (%)
ACC_PD_BAL_RATE	969	18,01
AGG_BAL_YTD	103	9,39
AGG_PD_BAL_YTD	441	8,20
AGG_PD_BAL_YTD_LCY	441	8,20
DISBURSEMENT_AMT_YTD	64	5,83
MIS_DAO	270	5,10
LN_APPR_AMT	21	1,91
BALANCE	36	0,67
BALANCE_PE	5	0,12
INTEREST_RATE	0	0,00


Ma trận tương quan giữa 10 biến này bộc lộ hai vấn đề dữ liệu cần lưu ý khi diễn giải importance ở Chương 4. Thứ nhất, *AGG_PD_BAL_YTD* và *AGG_PD_BAL_YTD_LCY* (bản quy đổi nội tệ) có $r = 0,963$, còn *BALANCE* và *BALANCE_PE* có $r = 0,996$ — hai cặp gần như trùng lặp thông tin nhưng vẫn được giữ lại trong bể 98 đặc trưng vì không vi phạm ngưỡng loại cột hằng số; đây là ứng viên tốt để loại bỏ thêm nếu triển khai một vòng lọc đa cộng tuyến trong tương lai. Thứ hai, một số cặp (ví dụ *BALANCE_PE* với *DISBURSEMENT_AMT_YTD*) cho hệ số tương quan không xác định (NaN) vì hai biến hiếm khi cùng quan sát được trên cùng một hồ sơ — hệ quả trực tiếp của việc nhiều biến chỉ tồn tại ở một trong hai nguồn dữ liệu PD/LD như đã nêu ở trên.

Bảng 3.9: Một số cặp tương quan đáng chú ý — bộ dữ liệu B

Biến 1	Biến 2	Hệ số tương quan r
BALANCE	BALANCE_PE	0,996
AGG_PD_BAL_YTD	AGG_PD_BAL_YTD_LCY	0,963
DISBURSEMENT_AMT_YTD	AGG_BAL_YTD	-0,867
AGG_PD_BAL_YTD	BALANCE_PE	0,530
LN_APPR_AMT	INTEREST_RATE	0,253



Hình 3.2: Ma trận tương quan giữa 10 biến quan trọng nhất — bộ dữ liệu B



Hình 3.3: Phân phối INTEREST_RATE theo nhóm nợ — bộ dữ liệu B

Hình 3.3 minh họa trực tiếp hạn chế cỡ mẫu đã nêu ở Bảng 3.2: hộp của nhóm 3 và 4 được vẽ từ lần lượt chỉ 11 và 13 quan sát, không đủ để ước lượng phân phối tổng thể — khác biệt hình dạng so với ba nhóm còn lại có thể chỉ phản ánh nhiễu mẫu nhỏ, không phải quy luật thực.

3.5 Bước 3 — Tiền xử lý & chọn biến

Bước thứ ba xây dựng tập đặc trưng cuối cùng dùng để huấn luyện: loại các trường có nguy cơ rò rỉ dữ liệu, tạo đặc trưng nghiệp vụ, tính Weight of Evidence/Information Value (WOE/IV) để sàng lọc, xác định pool đặc trưng chính thức, rồi điền khuyết, mã hóa và chuẩn hóa toàn bộ biến. Mọi bước học tham số (trung vị, trung bình, độ lệch chuẩn, danh mục encoder) chỉ thực hiện trên tập huấn luyện để tránh rò rỉ thông tin từ tập kiểm định.

3.5.1 Kiểm soát rò rỉ dữ liệu

Rò rỉ xảy ra khi đầu vào chứa thông tin chỉ có sau thời điểm cần dự báo hoặc là biến đổi trực tiếp của nhãn. Ở bộ A, code loại *NHOMNO_TCBS* và *NHOMNO*; riêng *NHOMNO* có tương quan rất cao với *NHOMNOMOI*, nên nếu giữ lại mô hình có thể học gần trực tiếp trạng thái tạo nhãn. Code cũng loại cột trùng *DUNO_QD*, mô tả văn bản trùng với mã sản phẩm và các trường hằng số hoặc gần như không có thông tin.

Ở bộ B, các biến số ngày quá hạn *NO_OVD_DAYS* và *NO_DAYS_OVERDUE* bị loại. Hai trường *CLASS_CUR* và *CLASSIFICATION_SK* cũng bị loại vì có quan hệ trực tiếp với quy tắc phân loại hoặc biến đích. Nếu giữ chúng, mô hình có thể học lại quy tắc tạo nhãn thay vì phát hiện tín hiệu sớm.

Đối với bài toán chuyển nhóm tương lai, kiểm soát cần chặt hơn: mọi đặc trưng $X_{i,t}$ phải tồn tại tại hoặc trước t , còn nhãn được xác định từ $t + 1$ tới $t + h$. Phép chia ngẫu nhiên đang dùng trong code phù hợp cho kiểm chứng mô hình phân loại hiện trạng, nhưng chưa phải thiết kế tối ưu cho cảnh báo sớm. Khi có dữ liệu thời gian, cần dùng chia theo thời gian để ngăn thông tin tương lai đi

vào huấn luyện.

3.5.2 Xây dựng đặc trưng nghiệp vụ

Hai nhánh dữ liệu sử dụng công thức tạo biến khác nhau. Bộ A tạo ba biến từ ngày mở, ngày đáo hạn, dư nợ hiện tại và dư nợ gốc. Bộ B tạo chín biến kỹ thuật từ dữ liệu dư nợ, thu hồi, lãi suất, ngày giải ngân, ngày đáo hạn, gia hạn và thay đổi hợp đồng.

Các biến này không tồn tại trực tiếp trong dữ liệu ban đầu mà được xây dựng từ một hoặc nhiều trường gốc nhằm chuyển thông tin kỹ thuật thành các đại lượng có ý nghĩa nghiệp vụ rõ ràng hơn. Bảng 3.10 tổng hợp nguồn hình thành và cách diễn giải của toàn bộ 12 biến được bổ sung.

Bảng 3.10: Các biến được xây dựng thêm từ dữ liệu ban đầu

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
A	<i>LOAN_TENURE_DAYS</i>	<i>OPEN_DATE</i> , <i>NGAYDENHAN</i>	Tổng thời hạn theo hợp đồng, tính bằng số ngày từ ngày mở đến ngày đáo hạn. Giá trị lớn biểu thị khoản vay có kỳ hạn dài hơn.
A	<i>DAYS_TO_MATURITY</i>	<i>NGAYDENHAN</i> , ngày tham chiếu d_0	Số ngày còn lại đến ngày đáo hạn. Giá trị dương biểu thị khoản vay chưa đáo hạn; bằng 0 là đáo hạn tại ngày tham chiếu; giá trị âm biểu thị khoản vay đã qua ngày đáo hạn.
A	<i>UTIL_RATE</i>	<i>CURR_BAL</i> , <i>BASE_BAL</i>	Tỷ lệ giữa dư nợ hiện tại và dư nợ gốc. Giá trị gần 1 cho biết dư nợ hiện tại xấp xỉ dư nợ gốc; nhỏ hơn 1 phản ánh dư nợ đã giảm; lớn hơn 1 có thể phản ánh giải ngân bổ sung hoặc biến động số dư.
B	<i>ENG_UTIL_RATE</i>	<i>BALANCE</i> , <i>LN_APPR_AMT</i>	Tỷ lệ sử dụng hạn mức được phê duyệt. Giá trị càng lớn thể hiện mức sử dụng hạn mức càng cao; giá trị lớn hơn 1 cho biết dư nợ ghi nhận vượt hạn mức phê duyệt trong dữ liệu.
B	<i>ENG_COLLECTION_RATIO</i>	<i>ACC_RECEIVED_INTEREST</i> , <i>ACC_RECEIVABLE_INTEREST</i>	Tỷ trọng lãi đã thu trên tổng lãi đã thu và còn phải thu. Giá trị tiến gần 1 biểu thị tỷ lệ thu hồi lãi cao; giá trị tiến gần 0 biểu thị phần lãi còn phải thu chiếm tỷ trọng lớn.

Bộ	Biến được tạo thêm	Biến gốc sử dụng	Ý nghĩa và cách diễn giải
B	<i>ENG_RATE_SPREAD_DELTA</i>	<i>INTEREST_RATE, INTEREST_SPREAD</i>	Chênh lệch giữa lãi suất hiện hành và biên độ lãi suất. Biến này phản ánh phần chênh lệch còn lại sau khi loại biên độ; dấu và độ lớn cần được diễn giải theo quy ước lãi suất của ngân hàng.
B	<i>ENG_DAYS_SINCE_FIRST_DISBURSEMENT</i>	<i>FIRST_DISBURSEMENT_DATE</i> , ngày tham chiếu	Số ngày đã trôi qua kể từ lần giải ngân đầu tiên, phản ánh tuổi của quan hệ tín dụng hoặc khoản vay.
B	<i>ENG_DAYS_SINCE_LAST_DISBURSEMENT</i>	<i>LAST_DISBURSEMENT_DATE</i> , ngày tham chiếu	Số ngày đã trôi qua kể từ lần giải ngân gần nhất. Giá trị nhỏ cho biết hoạt động giải ngân diễn ra gần thời điểm quan sát hơn.
B	<i>ENG_DAYS_TO_MATURITY</i>	<i>FIRST_MATURITY_DATE</i> , ngày tham chiếu	Số ngày còn lại đến ngày đáo hạn đầu tiên. Giá trị âm cho biết ngày đáo hạn đã qua so với thời điểm tham chiếu.
B	<i>ENG_HAS_EXTENSION</i>	<i>EXTENDED_DATE</i>	Biến nhị phân nhận giá trị 1 nếu hồ sơ có ghi nhận ngày gia hạn và 0 nếu không có. Biến phản ánh sự tồn tại của sự kiện gia hạn, không phản ánh nguyên nhân hoặc mức độ rủi ro của sự kiện.
B	<i>ENG_EXTEND_COUNT</i>	<i>EXTEND_SCH_NUM</i>	Số lần hoặc số lịch gia hạn được ghi nhận; giá trị thiếu được quy về 0. Giá trị lớn biểu thị hợp đồng có nhiều lần gia hạn hơn.
B	<i>ENG_HAS_CONTRACT_CHANGE</i>	<i>CONTRACT_CHANGE_COUNT</i>	Biến nhị phân nhận giá trị 1 khi số lần thay đổi hợp đồng lớn hơn 0 và nhận giá trị 0 trong trường hợp còn lại. Biến chỉ phản ánh việc từng phát sinh thay đổi, không cho biết nội dung thay đổi.

Các biến phát sinh trên được tính hoàn toàn từ các trường đầu vào và không sử dụng biến đích. Do đó, bản thân quá trình tạo biến không trực tiếp làm lộ nhãn nhóm nợ. Tuy nhiên, trước khi triển khai thực tế, thời điểm hình thành của từng trường gốc vẫn phải được kiểm tra để bảo đảm trường đó đã tồn tại tại thời điểm dự báo; nếu một trường chỉ phát sinh sau thời điểm quan sát, biến được tạo từ trường đó vẫn có thể gây rò rỉ thông tin theo thời gian.

Đặc trưng của bộ dữ liệu A

Với ngày tham chiếu cố định $d_0 = 31/12/2021$, các biến được tính như sau:

$$LOAN_TENURE_DAYS_i = \max\{0, d_i^{\text{maturity}} - d_i^{\text{open}}\},$$

$$DAYS_TO_MATURITY_i = d_i^{\text{maturity}} - d_0.$$

Trong đó d_i^{open} là ngày mở khoản vay; d_i^{maturity} là ngày đến hạn; chênh lệch ngày được biểu diễn bằng số ngày dương hoặc âm. Việc cố định d_0 giúp cùng một hồ sơ nhận cùng giá trị khi tái chạy.

Tỷ lệ sử dụng dư nợ của bộ A được cài đặt:

$$UTIL_RATE_i = \begin{cases} \text{clip}\left(\frac{CURR_BAL_i}{BASE_BAL_i}, 0, 10\right), & BASE_BAL_i > 0, \\ 0, & BASE_BAL_i \leq 0. \end{cases}$$

Trong đó $CURR_BAL$ là dư nợ hiện tại; $BASE_BAL$ là dư nợ gốc hoặc cơ sở; và toán tử $\text{clip}(x, 0, 10)$ giới hạn giá trị trong đoạn $[0, 10]$ để giảm ảnh hưởng của tỷ số ngoại lệ.

Kiểm tra đặc trưng đã tạo của bộ dữ liệu A

Sau khi ba biến $LOAN_TENURE_DAYS$, $DAYS_TO_MATURITY$ và $UTIL_RATE$ được tạo, mục này khảo sát thống kê mô tả, ngoại lệ và tương quan của chúng cùng năm biến gốc đã trình bày ở Bước 2 (mục 3.4), trước khi tính Information Value ở mục sau.

Bảng 3.11: Thống kê mô tả ba biến kỹ thuật của bộ dữ liệu A

Biến	Trung bình	Độ lệch chuẩn	Nhỏ nhất	Trung vị	Lớn nhất
LOAN_TENURE_DAYS	2.292,5	2.452,0	0	1.461	18.292
DAYS_TO_MATURITY	672,7	2.397,7	-5.513	96	16.798
UTIL_RATE	2,4561	3,2557	2×10^{-8}	0,9429	10,0000

Bảng 3.12: Số quan sát ngoại lệ theo IQR — ba biến kỹ thuật của bộ dữ liệu A


Biến	Số ngoại lệ	Tỷ lệ (%)
DAYS_TO_MATURITY	6.233	23,08
UTIL_RATE	4.646	17,21
LOAN_TENURE_DAYS	2.754	10,20

DAYS_TO_MATURITY có tỷ lệ ngoại lệ cao nhất (23,08%) vì biến này nhận cả giá trị âm (khoản vay đã quá hạn đáo hạn tính đến ngày tham chiếu d_0) lẫn giá trị dương lớn (khoản vay kỳ hạn dài); đây là đặc điểm nghiệp vụ thực, không phải lỗi dữ liệu, nên không bị loại hay cắt ngưỡng. Ngược lại, **UTIL_RATE** có 17,21% ngoại lệ chủ yếu do một bộ phận khách hàng có dư nợ hiện tại vượt xa dư nợ gốc ban đầu (ví dụ giải ngân bổ sung nhiều lần); đây chính là lý do công thức tính **UTIL_RATE** ở trên chủ động **clip** kết quả vào đoạn $[0, 10]$ — nếu không giới hạn, một số ít hồ sơ có tỷ lệ hàng trăm lần sẽ làm lệch cực đoan bước chuẩn hóa z-score của *toàn bộ* biến này khi đưa vào Logistic Regression.

Trong nghiên cứu này, **clip dữ liệu** được hiểu là phép giới hạn giá trị của một biến trong một khoảng xác định, thay vì loại bỏ các quan sát nằm ngoài khoảng đó. Với u là giá trị ban đầu của **UTIL_RATE**, giá trị sau khi giới hạn được xác định như sau:

$$\text{clip}(u; 0, 10) = \min\{\max(u, 0), 10\}.$$

Theo đó, giá trị nhỏ hơn 0 được thay bằng 0, giá trị lớn hơn 10 được thay bằng 10, còn các giá trị thuộc đoạn $[0, 10]$ được giữ nguyên. Ngưỡng trên bằng 10 tương ứng với trường hợp dư nợ hiện tại bằng 10 lần dư nợ gốc. Cách xử lý này không làm giảm số lượng quan sát và vẫn bảo lưu thông tin rằng hồ sơ có mức sử dụng rất cao, đồng thời hạn chế ảnh hưởng chi phối của một số giá trị cực đoan đối với trung bình, độ lệch chuẩn và quá trình ước lượng mô hình. Tuy nhiên, sau khi giới hạn, các mức **UTIL_RATE** lớn hơn 10 không còn được phân biệt với nhau; vì vậy, đây là một lựa chọn tiền xử lý nhằm tăng tính ổn định của mô hình, không hàm ý rằng các giá trị vượt ngưỡng là sai về mặt nghiệp vụ.



Hình 3.4: Phân phối bốn biến số chính của bộ dữ liệu A (n=27.001)

Hình 3.4 minh họa trực quan hai đặc điểm đã nêu bằng số: **BASE_BAL** và **CURR_BAL** lệch phải mạnh trên thang gốc nên được vẽ theo $\log_{10}$ để thấy rõ hình chuông tương đối; **UTIL_RATE** có một cột dồn rõ rệt tại đúng giá trị 10


— bằng chứng trực quan cho thấy phép **clip** đã cắt và dồn một lượng đáng kể hồ sơ (khoảng 3.200, tương ứng phần vượt ngưỡng của 17,21% ngoại lệ ở Bảng 3.12) về đúng biên trên; **DAYS_TO_MATURITY** có hai đỉnh — một quanh 0 (khoản vay gần đáo hạn hoặc mới quá hạn) và một dải trải dài về phía dương (khoản vay kỳ hạn dài).

Ma trận tương quan (Bảng 3.13, minh họa trực quan ở Hình 3.5) cho thấy ba cặp biến có $|r| \geq 0,7$.


Bảng 3.13: Các cặp biến số tương quan mạnh nhất — bộ dữ liệu A

Biến 1	Biến 2	Hệ số tương quan r
LOAN_TENURE_DAYS	DAYS_TO_MATURITY	0,942
BASE_BAL	CURR_BAL	0,923
ORGNBR	PARENTORGNBR	0,738
LAISUAT	LOAN_TENURE_DAYS	0,352
LAISUAT	UTIL_RATE	-0,327

Ba cặp tương quan mạnh nhất đều có cách giải thích nghiệp vụ trực tiếp: *LOAN_TENURE_DAYS* và *DAYS_TO_MATURITY* cùng được tính từ ngày mở và ngày đáo hạn nên gần như là hai phép biến đổi tuyến tính của cùng thông tin gốc; *CURR_BAL* là dư nợ hiện tại nên tương quan cao với dư nợ gốc *BASE_BAL*; *ORGNBR* và *PARENTORGNBR* phản ánh cấu trúc phân cấp chi nhánh–đơn vị cấp trên. Mức tương quan này không đủ cao để loại biến (không có cặp nào $|r| > 0,95$), nhưng đủ để giải thích vì sao trong bảng SHAP ở Chương 4, importance của hai biến kỳ hạn thường lẫn át lẫn nhau tùy ngẫu nhiên hoá của mô hình cây — một hạn chế cố hữu khi diễn giải importance trên các biến tương quan [17].



Hình 3.5: Ma trận tương quan Pearson giữa các biến số của bộ dữ liệu A



Hình 3.6: Phân phối DAYS_TO_MATURITY theo nhóm nợ — bộ dữ liệu A

Hình 3.6 cho thấy trung vị *DAYS_TO_MATURITY* giảm dần khá đều từ nhóm 1 đến nhóm 4 rồi đổi hướng ở nhóm 5 — phù hợp việc đây là biến SHAP xếp hạng cao nhất ở Chương 4, nhưng cũng gợi ý quan hệ giữa biến này và nhóm nợ không hoàn toàn đơn điệu, cần thận trọng khi diễn giải nhân quả.

Tỷ lệ sử dụng hạn mức của bộ dữ liệu B

$$ENG_UTIL_RATE_i = \begin{cases} \frac{BALANCE_i}{LN_APPR_AMT_i}, & LN_APPR_AMT_i > 0, \\ NaN, & \text{ngược lại.} \end{cases}$$

Trong đó *BALANCE* là dư nợ hiện tại của quan sát *i*; *LN_APPR_AMT* là hạn mức được phê duyệt; tỷ số lớn biểu thị mức sử dụng hạn mức cao. Khác với bộ A, trường hợp mẫu số không dương ở bộ B được giữ thiếu để bước imputer xử lý, thay vì gán 0.

Tỷ lệ thu hồi lãi

$$ENG_COLLECTION_RATIO_i = \frac{R_i}{Q_i + R_i + \varepsilon},$$

Trong công thức:

$$R_i = ACC_RECEIVED_INTEREST_i,$$

$$Q_i = ACC_RECEIVABLE_INTEREST_i,$$

với R_i là lãi đã thu lũy kế; Q_i là lãi phải thu lũy kế; và $\varepsilon = 10^{-6}$ là hằng số nhỏ nhằm tránh chia cho 0. Công thức đo tỷ trọng phần lãi đã thu trong tổng lãi đã thu và còn phải thu.

Đặc trưng thời gian và thay đổi hợp đồng của bộ dữ liệu B

Ba biến thời gian được tính bằng chênh lệch ngày, gồm:

- *ENG_DAYS_SINCE_FIRST_DISBURSEMENT*;
- *ENG_DAYS_SINCE_LAST_DISBURSEMENT*;
- *ENG_DAYS_TO_MATURITY*.


Ngoài ra, code tạo cờ có gia hạn, số lần gia hạn và cờ từng thay đổi hợp đồng. Nhánh bộ B hiện dùng ngày chạy chương trình làm ngày tham chiếu, trong khi bộ A đã cố định ngày 31/12/2021. Để tái lập khoa học, nhánh bộ B cần được sửa theo cùng nguyên tắc: dùng ngày chốt dữ liệu cố định hoặc ngày quan sát của từng hồ sơ; nếu không, cùng một hồ sơ có thể nhận giá trị khác khi chạy ở ngày khác.

Kiểm tra đặc trưng đã tạo của bộ dữ liệu B

Sau khi các biến kỹ thuật của bộ B được tạo, mục này kiểm tra tỷ lệ thiếu của ba biến có tỷ lệ thiếu cao nhất trong nhóm này, bổ sung cho bức tranh thiếu dữ liệu của các biến gốc đã trình bày ở Bước 2 (mục 3.4).

Bảng 3.14: Tỷ lệ thiếu của các biến kỹ thuật có tỷ lệ thiếu cao nhất — bộ dữ liệu B

Biến	Tỷ lệ thiếu (%)
ENG_UTIL_RATE	99,61
ENG_DAYS_SINCE_LAST_DISBURSEMENT	82,79
ENG_DAYS_SINCE_FIRST_DISBURSEMENT	79,65



Hình 3.7: 15 biến số thiếu dữ liệu nhiều nhất — bộ dữ liệu B

Phát hiện đáng chú ý nhất là chính *ENG_UTIL_RATE* — biến kỹ thuật do nghiên cứu tự tạo (mục 3.5.2) — lại thiếu tới 99,61%, vì công thức cần đồng thời *BALANCE* và *LN_APPR_AMT* dương, trong khi *LN_APPR_AMT* chỉ có ở một phân khúc nhỏ hồ sơ (khoảng 20,4% theo Bảng 3.7). Đây là hạn chế thực tế của biến kỹ thuật này: nó gần như vô dụng cho phần lớn hồ sơ và không nên được kỳ vọng đóng góp importance đáng kể — đúng như quan sát ở Chương 4, nhóm “Đặc trưng kỹ thuật” chỉ chiếm 6,8% (Gain) hoặc 1,6% (SHAP) tổng importance của bộ B.

3.5.3 Weight of Evidence và Information Value (WOE/IV)

IV là thước đo chuẩn Basel II/III để lượng hóa khả năng một biến tách nhóm nợ “tốt” khỏi nhóm nợ “xấu” trước khi đưa vào mô hình, dùng quy ước nhãn nhị

phân “tốt” = nhóm 1, “xấu” = nhóm 2–5, chia 10 bin theo phân vị cho biến số. Bước này được tính trên pool đặc trưng còn lại sau khi đã loại các trường rò rỉ ở mục 3.5.1 và đã tạo các đặc trưng nghiệp vụ ở mục trên, làm căn cứ định lượng cho việc xây dựng pool đặc trưng chính thức ở mục 3.5.4.

Bảng Information Value đầy đủ của bộ dữ liệu A

Bảng 3.15 tính IV cho toàn bộ 13 biến của pool phân tích (kể cả hai biến *SEX*, *LOAIKH* sẽ được nhắc lại ở mục 3.5.4 khi bàn về lựa chọn tập đặc trưng), xếp giảm dần theo IV.

Bảng 3.15: Information Value của 13 biến — bộ dữ liệu A

Biến	IV	Mức
DAYS_TO_MATURITY	4,5541	(!) Nghi ngờ (leakage?)
CURRMICCTTYPCD	1,9921	(!) Nghi ngờ (leakage?)
LOAN_TENURE_DAYS	1,9410	(!) Nghi ngờ (leakage?)
MUCDICHVAY	1,4141	(!) Nghi ngờ (leakage?)
UTIL_RATE	1,3334	(!) Nghi ngờ (leakage?)
MJACCTTYPCD	0,9695	Rất mạnh
LAISUAT	0,7851	Rất mạnh
BASE_BAL	0,5356	Rất mạnh
PARENTORGNBR	0,3201	Mạnh
CURR_BAL	0,2585	Trung bình
ORGNBR	0,1820	Trung bình
SEX	0,0081	Vô dụng
LOAIKH	0,0000	Vô dụng

Đây là phát hiện cần được nêu rõ thay vì chỉ báo cáo tích cực: **5/13 biến có $IV > 1,0$** — vượt ngưỡng mà Siddiqi xem là “đáng ngờ, có thể là proxy hoặc rò rỉ của biến đích” [21], và đây chính xác là 5 biến đứng đầu bảng SHAP/Gain importance ở Chương 4. Cần phân biệt hai khả năng: (i) các biến này thực sự bị rò rỉ nhãn theo nghĩa được tính từ *NHOMNOMOI* hoặc quy tắc tạo nhãn — nếu

vậy phải loại tương tự *NHOMNO* (mục 3.5.1); hoặc (ii) các biến này có quan hệ nghiệp vụ cực mạnh với nhóm nợ (ví dụ kỳ hạn còn lại phản ánh trực tiếp giai đoạn vòng đời khoản vay) mà không được tính toán từ nhãn, nên IV cao là hợp lý chứ không phải lỗi.

Luận văn nghiên cứu về khả năng (ii) đối với *DAYS_TO_MATURITY*, *LOAN_TENURE_DAYS*, *UTIL_RATE*: cả ba đều được tính từ ngày mở/đáo hạn và dư nợ — các trường tồn tại độc lập với quy trình xếp nhóm nợ, không phải biến phái sinh của *NHOMNOMOI*. Tuy nhiên, với hai biến phân loại nhiều danh mục *CURRMIACTTYP*CD (31 nhóm) và *MUCDICHVAY* (79 nhóm), IV cao một phần có thể là hiện tượng thống kê: biến định danh có rất nhiều danh mục dễ đạt IV cao giả tạo vì mỗi danh mục nhỏ đóng góp lệch xác suất riêng, ngay cả khi không có quan hệ nhân quả mạnh — một hạn chế đã biết của công thức IV khi áp dụng cho biến nhiều danh mục [21]. Vì vậy, luận văn khuyến nghị: (a) giữ nguyên 5 biến này trong mô hình vì không tìm thấy bằng chứng chúng được tính trực tiếp từ nhãn, nhưng (b) nêu rõ đây là hạn chế cần rà soát cùng đơn vị nghiệp vụ trước khi triển khai thực tế, đặc biệt với hai biến phân loại nhiều danh mục.

Bảng Information Value của bộ dữ liệu B

Áp dụng cùng phương pháp tính IV như bộ A (mục 3.5.3) cho toàn bộ 98 đặc trưng của bộ B. Bảng 3.16 tổng hợp số lượng biến theo từng mức IV.

Bảng 3.16: Phân bố 98 đặc trưng của bộ dữ liệu B theo mức Information Value

Mức IV	Số biến	Tỷ lệ (%)
Trung bình (0,1–0,3)	44	44,9
Vô dụng ($< 0,02$)	21	21,4
Yếu (0,02–0,1)	17	17,3
Rất mạnh (0,5–1,0)	8	8,2
(!) Nghi ngờ ($> 1,0$)	5	5,1
Mạnh (0,3–0,5)	3	3,1
Tổng	98	100,0

Phát hiện quan trọng nhất của Bảng 3.16: **21/98 đặc trưng (21,4%) có IV $< 0,02$** , tức về mặt đơn biến được xem là “vô dụng” cho dự báo theo ngưỡng Siddiqi [21] — nhưng vẫn nằm trong bể 98 đặc trưng đưa vào huấn luyện vì quy tắc lọc ở mục 3.5.2 chỉ loại theo tiêu chí leakage/trùng lặp/hàng số, không lọc theo IV. Đây là bằng chứng thống kê trực tiếp bổ sung cho câu trả lời câu hỏi nghiên cứu thứ nhất ở Chương 4 (“nhiều đặc trưng hơn có luôn tốt hơn không?”): hơn 1/5 bể đặc trưng gần như không mang tín hiệu đơn biến, nên phần cải thiện Macro-F1 khi tăng từ Top-60 lên đủ 98 biến (Bảng 4.6) nhiều khả năng đến từ một số ít biến còn lại có IV cao, không phải từ toàn bộ 98 biến đóng góp đều.

Tương tự bộ A, 5 biến có $IV > 1,0$ — *SEAB_POLICY* (1,6559), *ACC_RECEIVABLE_PE* (1,4831), *ACC_RECEIVED_PE* (1,2883), *ACC_PD_BAL_RATE* (1,2188) và *AGG_PD_BAL* (1,1474) — cần được rà soát nghiệp vụ trước khi triển khai thực tế, dù không tìm thấy bằng chứng chúng được tính trực tiếp từ *CLASSIFICATION* trong tài liệu mô tả cột hiện có.

3.5.4 Xây dựng tập đặc trưng huấn luyện

Bộ dữ liệu A: tập 11 biến và tập mở rộng 13 biến

Trang huấn luyện chính sử dụng 11 đặc trưng đã sàng lọc: ba biến phân loại và tám biến số. Trang phân tích đặc trưng mở rộng pool lên 13 biến bằng cách đưa lại *SEX* và *LOAIKH*, là hai biến từng bị loại do Information Value (IV) thấp. Theo bảng IV đầy đủ đã trình bày ở mục 3.5.3 (Bảng 3.15), *SEX* có $IV = 0,008$ và *LOAIKH* có $IV = 0,000$ — mức “Vô dụng” theo ngưỡng phân loại IV phổ biến trong tài liệu chấm điểm tín dụng ($IV < 0,02$ là không có giá trị dự báo, $0,02 \leq IV < 0,1$ là dự báo yếu, $0,1 \leq IV < 0,3$ là trung bình và $IV \geq 0,3$ là mạnh) [21]. Cả hai biến đều nằm sâu dưới ngưỡng 0,02 nên bị loại khỏi bộ 11 biến chính; việc đưa lại chúng vào pool 13 biến ở trang phân tích đặc trưng không nhằm phủ nhận tiêu chí IV, mà để kiểm tra thực nghiệm xem một thước đo đơn biến (univariate) như IV có thể bỏ sót tín hiệu mà mô hình cây đa biến (multivariate) vẫn khai thác được qua tương tác giữa các biến hay không — kết quả thực nghiệm ở Chương 4 cho thấy điều này có xảy ra nhưng với mức cải thiện rất nhỏ.

Sau khi phân tích ngày và tạo biến, bộ A có tám biến số:

- năm biến từ tệp nguồn: *BASE_BAL*, *CURR_BAL*, *LAISUAT*, *ORGNBR* và *PARENTORGNBR*;
- ba biến tạo thêm: *LOAN_TENURE_DAYS*, *DAYS_TO_MATURITY* và *UTIL_RATE*.

Năm biến phân loại trong pool đầy đủ được chia thành:

- ba biến cấu hình chính: *MJACCTTYPCD*, *CURRMIACCTTYPCD* và

MUCDICHVAY;

- hai biến IV thấp đưa lại để kiểm chứng: *SEX* và *LOAIKH*.

Đối với bộ 11 biến chính, phép đếm từ tệp nguồn là:

$$21 - 1 - 10 - 2 + 3 = 11,$$

trong đó 21 là số cột thô; 1 là biến đích; 10 là số trường trong danh sách loại; 2 là hai trường ngày chỉ dùng để tạo biến; và 3 là số biến kỹ thuật được bổ sung. Pool phân tích có 13 biến vì đưa lại hai biến *SEX* và *LOAIKH*.

Bộ dữ liệu B: từ 178 cột thô tới 98 đặc trưng mô hình

Con số 178 là số cột của tệp thô, không phải số biến thực tế đưa vào bộ phân loại. Bước xây dựng bể đặc trưng thô thực hiện ba lớp lọc:

1. loại biến đích;
2. loại trường định danh, khóa thay thế, văn bản tự do và trường gây rò rỉ, gồm *CLASS_CUR*, *CLASSIFICATION_SK*, *NO_OVD_DAYS* và *NO_DAYS_OVERDUE*;
3. không đưa trực tiếp trường ngày vào mô hình; các trường này chỉ dùng để tạo biến thời lượng; đồng thời loại cột chỉ có một giá trị quan sát.


Sau lọc, code giữ 63 biến số và 26 biến phân loại. Bước tạo đặc trưng nghiệp vụ bổ sung 9 biến số, đưa tổng số đầu vào lên:

$$p = 63 + 26 + 9 = 98.$$

Tương đương, phép đếm từ tệp nguồn có thể viết:

$$178 - 1 - 38 - 19 - 31 + 9 = 98.$$

Trong đó 1 là biến đích; 38 là số trường định danh, khóa thay thế hoặc leakage có mặt trong tệp; 19 là số trường ngày không đưa trực tiếp vào mô hình; 31 là số trường còn lại có không quá một giá trị quan sát; và 9 là số biến tạo thêm. Vì vậy, câu hỏi “giảm từ 178 xuống bao nhiêu” được triển khai chính xác hơn thành hai bước: giảm 178 cột thô xuống tệp 98 đặc trưng hợp lệ theo quy tắc nghiệp vụ, sau đó đánh giá khả năng rút gọn tiếp từ 98 đặc trưng.



Hình 3.8: Các tầng số lượng biến trong nghiên cứu

Bên cạnh bề đầy đủ, tệp cấu hình còn khai báo trước một bộ rút gọn gồm 16 biến:

- Nhóm biến số gồm:
 - *INTEREST_RATE*, *INTEREST_SPREAD*;
 - *BALANCE*, *BALANCE_PE*, *BALANCE_PS*;
 - *AGG_DISBURSEMENT_AMT*;
 - *CONTRACT_CHANGE_CNT*, *NUM_GRACE_PERIOD*;
 - *MIS_DAO*, *CURR_MIS_DAO*;
 - *FIXED_RATE*, *LN_APPR_AMT*.
- Nhóm biến phân loại gồm *CATEGORY*, *SEAB_PRODUCTS*, *TERM_SBV* và *DATASOURCE*.

Bộ 16 biến là cấu hình vận hành rút gọn được xác định trước trong mã nguồn; tuy nhiên, mã nguồn hiện tại không lưu bảng IV làm căn cứ cho quá trình lựa chọn. Vì vậy, luận văn sử dụng thuật ngữ “bộ 16 biến định trước”, không đồng nhất tập này với 16 biến có mức độ quan trọng cao nhất của mô hình đầy đủ và không sử dụng nó để thay thế thí nghiệm theo số lượng đặc trưng trên tập 98 biến.

Nhóm đặc trưng nghiệp vụ

Đối với bộ A, code ánh xạ 13 biến vào sáu nhóm: Dư nợ và hạn mức sử dụng; Lãi suất; Kỳ hạn khoản vay; Đơn vị/chi nhánh; Sản phẩm và mục đích vay; Nhân khẩu học có IV thấp. Đối với bộ B, code ánh xạ 98 biến vào chín nhóm: (1) Dư nợ và giải ngân; (2) Lãi suất; (3) Trả nợ và thu hồi; (4) Kỳ hạn và gia hạn; (5) Sản phẩm, mục đích và kênh phân phối; (6) Khách hàng và đối tác; (7) Thay đổi và trạng thái hợp đồng; (8) Bối cảnh và nguồn dữ liệu; và (9) Đặc trưng kỹ thuật.

Việc phân nhóm biến phục vụ hai mục đích: giải thích mô hình ở cấp độ nghiệp vụ và xây dựng khuyến nghị đầu tư dữ liệu. Tuy nhiên, tổng mức độ quan trọng của một nhóm chỉ phản ánh cách mô hình sử dụng dữ liệu hiện có và không cung cấp bằng chứng về quan hệ nhân quả.

3.5.5 Giá trị thiếu và chuẩn hóa

Đối với biến số, `SimpleImputer(strategy="median")` thay giá trị thiếu bằng trung vị học trên tập huấn luyện:

$$\tilde{x}_{ij} = \begin{cases} x_{ij}, & x_{ij} \text{ quan sát được,} \\ \text{median}\{x_{\ell j} : \ell \in \mathcal{T}\}, & x_{ij} \text{ thiếu,} \end{cases}$$

trong đó x_{ij} là giá trị biến j của quan sát i ; $\mathcal{T}$ là tập chỉ số huấn luyện; và $\tilde{x}_{ij}$ là giá trị sau điền khuyết.

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, biến số sau điền khuyết được chuẩn hóa:

$$z_{ij} = \frac{\tilde{x}_{ij} - \mu_j}{\sigma_j},$$

trong đó μ_j và σ_j lần lượt là trung bình và độ lệch chuẩn của biến j sau điền khuyết trên tập huấn luyện; z_{ij} là giá trị chuẩn hóa. Việc chuẩn hóa đặc biệt cần cho hồi quy logistic, còn mô hình cây ít nhạy hơn với thang đo [5, 14].

3.5.6 Biến phân loại

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, code dùng `LabelEncoder` riêng cho từng cột. Nếu giá trị mới không xuất hiện trong huấn luyện, code ánh xạ nó về lớp đầu tiên trong encoder. Đây là cách xử lý kỹ thuật nhưng có thể tạo thứ tự giả cho biến định danh; kết quả cần được xem là hạn chế của pipeline.

CatBoost sử dụng preprocessor riêng: biến số chỉ được điền trung vị, không chuẩn hóa; biến phân loại thiếu được thay bằng UNKNOWN và giữ dạng chuỗi để

thuật toán xử lý trực tiếp, phù hợp cơ chế của CatBoost [20].

Việc chọn trung vị thay vì trung bình cho bước điền khuyết không phải lựa chọn mặc định mà xuất phát trực tiếp từ EDA ở mục 3.4: các biến tiền tệ của cả hai bộ đều lệch phải mạnh (Bảng 3.4, 3.7), độ lệch chuẩn lớn hơn trung bình hàng chục lần và một tỷ lệ đáng kể quan sát là ngoại lệ theo IQR. Trung vị là thống kê bền vững (robust) với ngoại lệ và phân phối lệch, trong khi trung bình sẽ bị kéo về phía các giá trị cực lớn, làm giá trị điền khuyết không đại diện cho đa số hồ sơ điển hình [5].

3.5.7 Ví dụ minh họa trước và sau xử lý

Để cụ thể hóa các công thức trên, Bảng 3.17 trích ba hồ sơ thật trong tập kiểm định của bộ A qua từng bước xử lý.

Bảng 3.17: Ví dụ ba hồ sơ thật của bộ A trước và sau xử lý

Biến	Hồ sơ #5944	Hồ sơ #7333	Hồ sơ #12595
<i>Giá trị thô (không có biến nào thiếu ở bộ A)</i>			
BASE_BAL	201.000.000	5.000.000	300.000.000
CURR_BAL	77.050.000	9.184.112	180.000.000
LAISUAT	0,1173	0,0000	0,1200
UTIL_RATE	0,3833	1,8368	0,6000
MJACCTTYP	CNS	CNS	CNS
CURRMJACCTTYP	TH01	VS01	TH01
<i>Sau chuẩn hóa z-score (học μ, σ trên tập huấn luyện)</i>			
BASE_BAL	-0,0334	-0,0651	-0,0173
CURR_BAL	-0,0501	-0,0628	-0,0310
LAISUAT	0,7095	-1,0111	0,7491
UTIL_RATE	-0,6374	-0,1923	-0,5710
<i>Sau mã hóa LabelEncoder (học trên tập huấn luyện)</i>			
MJACCTTYP	1	1	1
CURRMJACCTTYP	12	22	12

Vì bộ A không có giá trị thiếu, bước điền khuyết không làm thay đổi số liệu — bảng chỉ còn ý nghĩa với các bộ dữ liệu khác có *NaN*. Điểm đáng chú ý là hồ sơ #7333 có *UTIL_RATE* thô bằng 1,8368 (dư nợ hiện tại đã vượt 183,7% dư nợ gốc), sau chuẩn hóa cho z-score $-0,1923$ — âm dù bản thân tỷ lệ sử dụng cao hơn hai hồ sơ còn lại, vì *UTIL_RATE* trung bình toàn mẫu huấn luyện xấp xỉ 2,46 (Bảng 3.11); đây là lý do luận văn nhấn mạnh z-score chỉ có ý nghĩa *tương đối* trong phân phối đã lệch, không nên diễn giải như một chỉ số rủi ro tuyệt đối.

Bảng 3.18 minh họa ba hồ sơ của bộ B có *BASIC_RATE_CODE* bị thiếu thật trong dữ liệu gốc.

Bảng 3.18: Ví dụ ba hồ sơ thật của bộ B có giá trị thiếu, trước và sau xử lý

Biến	Hồ sơ #4741	Hồ sơ #4432	Hồ sơ #487
<i>Giá trị thô</i>			
BALANCE	0	0	0
INTEREST_RATE	0,00	15,75	51,00
BASIC_RATE_CODE	<i>NaN</i>	<i>NaN</i>	<i>NaN</i>
CATEGORY	21051	21051	1014
<i>Sau điền khuyết / mã hóa</i>			
BALANCE (median trên train)	0,0	0,0	0,0
INTEREST_RATE	0,00	15,75	51,00
BASIC_RATE_CODE (CatBoost)	UNKNOWN	UNKNOWN	UNKNOWN

Cả ba hồ sơ trong ví dụ đều có *BASIC_RATE_CODE* thiếu — phù hợp với việc biến này thiếu tới 93,79% trên toàn bộ bộ B. Với CatBoost, giá trị thiếu được thay bằng chuỗi UNKNOWN và mô hình học trực tiếp trên chuỗi; với các mô hình còn lại, UNKNOWN tiếp tục được đưa qua LabelEncoder như một danh mục hợp lệ, nghĩa là “thiếu dữ liệu” bản thân nó trở thành một tín hiệu mà mô hình có thể học được — một cách xử lý thiếu dữ liệu *không hoàn toàn ngẫu nhiên* (not

missing at random) thường gặp trong dữ liệu ngân hàng, nơi việc một trường không được ghi nhận có thể tương quan với loại sản phẩm hoặc kênh xử lý hồ sơ.

3.5.8 Phân tích số lượng và nhóm đặc trưng

Trong cấu hình báo cáo, mô hình XGBoost đầy đủ tạo thứ hạng importance riêng cho từng bộ dữ liệu. Với các đặc trưng được sắp $I_{(1)} \geq \dots \geq I_{(p)}$, tỷ lệ importance tích lũy tại k là:

$$Q(k) = \frac{\sum_{j=1}^k I_{(j)}}{\sum_{j=1}^p I_{(j)}} \times 100\%.$$

Trong đó $I_{(j)}$ là importance của đặc trưng xếp hạng j ; $p = 13$ đối với pool đầy đủ của bộ A và $p = 98$ đối với bộ B; $Q(k)$ không phải tỷ lệ hiệu năng được giữ lại. Do đó, số biến đạt 95% importance chỉ là ứng viên, phải được huấn luyện lại và đánh giá ngoài mẫu. Code kiểm tra các mốc $k \in \{3, 5, 7, 9, 11, 13\}$ cho bộ A và $k \in \{5, 10, 15, 20, 30, 45, 60, 98\}$ cho bộ B.

Đóng góp nhóm g được code tính:

$$I_g = \sum_{j: g(j)=g} I_j, \quad S_g = \frac{I_g}{\sum_r I_r} \times 100\%,$$

trong đó $g(j)$ ánh xạ đặc trưng j sang nhóm nghiệp vụ; I_g là tổng importance và S_g là tỷ trọng của nhóm.

Điểm ưu tiên dữ liệu trong code là:

$$\text{Priority}_g = S_g \left(\frac{M_g}{100} + 0, 1 \right),$$

trong đó M_g là tỷ lệ thiếu trung bình của nhóm g và 0,1 là hệ số nền do tác giả

quy ước. Đây là chỉ số heuristic để sắp xếp thảo luận, chưa phải hàm lợi ích kinh tế đã được hiệu chỉnh.

Ba giới hạn của mô-đun lựa chọn biến cần được giữ trong cách diễn giải. Thứ nhất, nhãn “bộ 11 biến đã chọn” và “bộ 16 biến rút gọn” trong màn hình so sánh hiện lấy Top-11 hoặc Top-16 theo importance, không lấy đúng danh sách cấu hình tương ứng; luận văn vì vậy tính riêng kết quả của bộ 11 biến thực và không sử dụng nhãn Top-16 như bằng chứng cho bộ 16 định trước. Thứ hai, nhiều giá trị k được xem xét trên cùng tập kiểm định, nên lựa chọn k tốt nhất có thiên lệch lựa chọn; các đường cong này chỉ là phân tích khám phá. Thứ ba, tổng importance theo nhóm không thay thế thí nghiệm loại bỏ từng nhóm.

3.5.9 Một vòng thăm dò ban đầu trên bộ dữ liệu B

Trước khi xác lập quy trình tiền xử lý và bề 98 đặc trưng trình bày ở các mục trên, một vòng thăm dò ban đầu đã được thực hiện trên bộ dữ liệu B nhằm hiểu cấu trúc dữ liệu, ước lượng độ khó của bài toán và định hướng các quyết định thiết kế sau này. Vòng thăm dò này dùng quy tắc xử lý đơn giản hơn quy trình chính thức; kết quả của nó **không phải là kết quả chính thức được báo cáo ở Chương 4**, mà chỉ được trình bày ở đây như bằng chứng cho quá trình lặp lại đã dẫn tới các lựa chọn thiết kế cuối cùng, đúng nguyên tắc chỉ báo cáo là kết quả chính thức những gì tái chạy được trực tiếp từ mã nguồn hiện tại.

Làm sạch và phân loại cột

Ở vòng thăm dò này, dữ liệu được kiểm tra tổng quan để xác định cột thiếu nhiều và kiểu dữ liệu sai lệch, sau đó các bản ghi trùng lặp theo khóa nghiệp vụ được loại bỏ, chỉ giữ lại bản ghi mới nhất theo thời gian. Các cột được phân

loại thành nhóm định danh/khóa thay thế (ID/SK), cột ngày, cột đích và cột đặc trưng; nhóm ID/SK bị loại ngay từ đầu vì không có giá trị dự báo. Trường ngày được chuyển đổi bằng phép ép kiểu ngày tháng có dung sai (giá trị không hợp lệ được chuyển thành thiếu thay vì gây lỗi), sau đó tỷ lệ thiếu theo từng cột ngày được kiểm tra riêng.

Giá trị thiếu được xử lý theo quy tắc đơn giản: biến số có tỷ lệ thiếu trên 95% bị loại, các biến số còn lại được điền bằng 0; biến phân loại thiếu được gán nhãn "UNKNOWN"; riêng biến ngày được giữ nguyên giá trị thiếu để chuyển thành đặc trưng phái sinh (số ngày) ở bước sau, thay vì điền trực tiếp. Quy tắc điền 0 cho biến số ở vòng thăm dò này khác với quyết định chính thức dùng trung vị trình bày ở mục 3.4 và mục 3.5.3 — điền 0 là lựa chọn đơn giản, nhanh cho giai đoạn khám phá ban đầu, còn trung vị được chọn về sau vì bền vững hơn trước phân phối lệch mạnh của các biến tiền tệ đã quan sát được ở thống kê mô tả Bước 2. Các bản ghi có biến đích bị thiếu — 19 bản ghi, chủ yếu do khoản vay chưa được giải ngân tại ngày snapshot nên chưa xác định được nhóm nợ — bị loại trước khi huấn luyện.

Đối với ngoại lệ, mỗi biến số được cắt (clip) vào khoảng phân vị 1%–99% ước lượng *trên tập huấn luyện*. Thay vì chỉ cắt và bỏ qua thông tin bất thường, một biến cờ bổ sung được tạo để đánh dấu quan sát nằm ngoài khoảng cắt, giữ lại tín hiệu về việc một hồ sơ có giá trị cực trị hay không — một cải tiến so với việc clip đơn thuần.

Tỷ lệ nợ xấu và Information Value ở vòng thăm dò

Với mỗi biến phân loại và biến số (đã chia bin), tỷ lệ nợ xấu (default rate) theo từng nhóm/bin được tính trực tiếp để có cái nhìn trực quan ban đầu về sức phân

biệt của biến, trước khi tính Information Value theo công thức chuẩn — cùng công thức WOE/IV và cùng ngưỡng phân loại của Siddiqi đã trình bày ở mục 3.5.3.

Ở vòng thăm dò này, một danh sách rò rỉ ban đầu bị loại trước khi tính IV, gồm: biến đích ở dạng khóa thay thế; biến xếp hạng khách hàng có thể được cập nhật trước hoặc trong quá trình xử lý hồ sơ, nên thời điểm ghi nhận không rõ ràng; hai biến trạng thái/nhóm hợp đồng được ghi nhận tại các mốc khác nhau của vòng đời hợp đồng (một tại thời điểm ký, một tại thời điểm đang xét — thường là sau khi ký); và một biến ngày liên quan tới xếp hạng. Sau khi lọc theo ngưỡng $0,02 \leq IV \leq 0,5$, còn lại 34 biến. Danh sách rò rỉ chính thức dùng cho kết quả ở Chương 4 (mục 3.5.1) được xác định theo tiêu chí khác — loại các trường ngày quá hạn ghi nhận trực tiếp trạng thái nợ — và bề đặc trưng cuối cùng giữ lại 98 biến thay vì 34, vì quy tắc lọc chính thức chỉ loại theo tiêu chí rò rỉ/trùng lặp/hàng số chứ không lọc tiếp theo IV (mục 3.5.3), nhằm không loại bỏ sớm các biến có thể vẫn hữu ích khi kết hợp với các biến khác trong mô hình đa biến.

Đáng lưu ý, hai biến trạng thái/nhóm hợp đồng bị loại khỏi vòng thăm dò vì nghi ngờ rò rỉ (do thời điểm ghi nhận không rõ ràng so với thời điểm cần dự báo) lại **không** nằm trong danh sách rò rỉ chính thức và vẫn xuất hiện trong bề 98 đặc trưng cuối cùng — thậm chí là hai trong số các biến có importance cao theo SHAP và Gain ở Chương 4 (*CUSTOMER_CLASS* và *CONTRACT_CLASS*, Bảng 4.10). Đây là một điểm chưa thống nhất giữa hai vòng phân tích, cần được rà soát cùng đơn vị nghiệp vụ về đúng thời điểm ghi nhận của hai trường này trước khi triển khai thực tế, tương tự khuyến nghị đã nêu với các biến có $IV > 1,0$ ở mục 3.5.3.

Đặc trưng thử nghiệm và kết quả mô hình cơ sở

Trên bộ 34 biến, một số đặc trưng phái sinh thử nghiệm được xây dựng theo năm nhóm nghiệp vụ: dư nợ/giải ngân (ví dụ tỷ lệ dư nợ trên tổng giải ngân, giá trị giải ngân theo thang log); lãi suất (áp lực lãi suất tổng hợp, phân bin lãi suất); quá hạn (nhóm mức độ quá hạn, cờ đang quá hạn); thời gian khoản vay (tuổi khoản vay, số ngày từ lần giải ngân gần nhất, số ngày tới đáo hạn, cờ đã đáo hạn); và sản phẩm/phân khúc — cùng các cờ trạng thái hợp đồng và cờ đánh dấu giá trị thiếu theo từng biến. Nhiều ý tưởng trong nhóm này về sau được kế thừa dưới dạng các đặc trưng kỹ thuật chính thức ở mục trên (ví dụ số ngày tới đáo hạn, số ngày từ lần giải ngân gần nhất/đầu tiên, cờ gia hạn và cờ thay đổi hợp đồng), dù tên biến và công thức cụ thể đã được chuẩn hóa lại.

Trên tập huấn luyện/kiểm định chia theo tỷ lệ 80/20 có phân tầng, hai mô hình cơ sở tuyến tính và cây đơn được huấn luyện với biến phân loại mã hóa one-hot và trọng số lớp nghịch đảo tần suất (tương đương `class_weight="balanced"`), chưa áp dụng SMOTE; một mô hình boosting xử lý trực tiếp biến phân loại (không cần one-hot) cũng được thử với cùng nguyên tắc trọng số lớp. Bảng 3.19 tóm tắt kết quả.

Bảng 3.19: Kết quả mô hình cơ sở ở vòng thăm dò ban đầu trên bộ dữ liệu B (34 biến, chỉ dùng trọng số lớp, chưa SMOTE)

Mô hình	Accuracy	Macro-F1
Logistic Regression (one-hot)	0,1253	0,0569
Decision Tree (one-hot, max_depth=10)	0,7103	0,2318
CatBoost (depth=6, learning_rate=0,05, 500 vòng lặp)	0,6685	0,2407

Logistic Regression sụp đổ gần như hoàn toàn (Accuracy 0,1253) — sự kết hợp giữa quan hệ phi tuyến mạnh trong dữ liệu tín dụng (ví dụ các nhóm quá

hạn dạng ngắt quãng) với trọng số lớp nghịch đảo tần suất trên một tập dữ liệu quá lệch khiến gradient của mô hình tuyến tính bị nhiễu loạn. Decision Tree và CatBoost ổn định hơn nhiều nhờ khả năng khoanh vùng các ngưỡng phi tuyến trực tiếp từ dữ liệu; CatBoost còn xử lý trực tiếp biến phân loại mà không cần mã hóa one-hot. Tuy nhiên, ma trận nhầm lẫn của CatBoost cho thấy mô hình gần như không nhận diện được nhóm 3 (Recall bằng 0 trên 2 mẫu kiểm định), trong khi Recall nhóm 2 (0,76) và nhóm 5 (0,60) đạt được là nhờ đánh đổi rất nhiều cảnh báo sai — Precision của hai nhóm này chỉ lần lượt 0,06 và 0,03. Đây là bằng chứng thực nghiệm sớm cho thấy chỉ dùng trọng số lớp là không đủ để xử lý mức mất cân bằng cực đoan của bộ B, và là một trong các lý do luận văn chuyển sang kết hợp SMOTE với nhiều thuật toán boosting khác nhau ở quy trình chính thức (mục 3.6.2) thay vì chỉ dựa vào trọng số lớp.

3.6 Bước 4 — Chia dữ liệu & cân bằng lớp

Bước thứ tư chia dữ liệu thành tập huấn luyện và kiểm định theo nguyên tắc phân tầng, sau đó xử lý mất cân bằng lớp chỉ trên tập huấn luyện.

3.6.1 Chia tập huấn luyện — kiểm định

Mã nguồn đặt tham số **RANDOM_STATE=42**, tỷ lệ kiểm định bằng 0,2 và thực hiện phép chia ngẫu nhiên có phân tầng theo nhãn. Bộ dữ liệu A được chia thành 21.600 quan sát huấn luyện và 5.401 quan sát kiểm định. Bộ dữ liệu B được chia thành 4.304 quan sát huấn luyện và 1.077 quan sát kiểm định.

Mô hình dự báo nhóm nợ hiện tại đang được đánh giá theo hai tầng. Tầng thứ nhất là phép chia 80/20 nêu trên để so sánh trực tiếp với các kết quả đã

tái lập. Tầng thứ hai, tùy chọn **RepeatedStratifiedKFold**, lập phép kiểm định phân tầng 5-fold mặc định ba lần — cơ chế cụ thể được trình bày ở mục 3.7.2 khi bàn về hiệu chỉnh mô hình. Với $R = 3$ lần lặp và $F = 5$ fold, mô hình được ước lượng $R \times F = 15$ lần; mỗi quan sát xuất hiện trong tập kiểm định đúng một lần ở mỗi lượt lặp. Thiết kế này không tạo thêm dữ liệu, nhưng giảm mức phụ thuộc của Recall lớp hiếm vào một phép chia duy nhất.

3.6.2 Xử lý mất cân bằng lớp

SMOTE tạo một điểm tổng hợp:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim U(0, 1),$$

trong đó $\mathbf{x}_i$ là véc-tơ của một quan sát lớp thiểu số; $\mathbf{x}_{nn}$ là một trong các láng giềng gần của nó; λ là số ngẫu nhiên phân bố đều trên $[0, 1]$; và $\mathbf{x}_{\text{new}}$ là điểm nội suy [8].

Đối với bộ A, chiến lược `smote_moderate` nâng số mẫu huấn luyện của các lớp 2, 3, 4 và 5 lần lượt tới 3.000, 2.000, 2.000 và 5.000. Các giá trị gốc tương ứng là 1.030, 483, 627 và 2.689. Đối với bộ B, bảng so sánh mô hình đầy đủ dùng chiến lược tùy chỉnh, nâng bốn lớp này lần lượt tới 300, 100, 100 và 200 từ các mức 70, 9, 10 và 18. SMOTE được đặt sau preprocessor và trước classifier trong pipeline, nên chỉ tác động tới tập huấn luyện.

Ví dụ minh họa SMOTE trên nhóm 3 của bộ B

Với bộ rút gọn 16 biến, nhóm 3 (dưới tiêu chuẩn) của bộ B chỉ có 11 hồ sơ thật, toàn bộ đều có *BALANCE*=0 nhưng *INTEREST_RATE* khác nhau. Lấy hồ sơ đầu tiên làm $\mathbf{x}_i$ (*INTEREST_RATE*=18,135) và hồ sơ láng giềng gần thứ nhất

làm $\mathbf{x}_{nn}$ ($INTEREST_RATE=51,000$), với $\lambda = 0,5$, công thức SMOTE nêu trên cho:

$$x_{\text{new}} = 18,135 + 0,5 \times (51,000 - 18,135) = 34,568.$$

Quan sát tổng hợp này không tồn tại trong dữ liệu gốc nhưng nằm trên đoạn thẳng nối hai hồ sơ thật cùng nhóm 3 trong không gian đặc trưng đã chuẩn hóa; đây chính là cơ chế SMOTE dùng để tăng số mẫu huấn luyện của nhóm 3 từ 9 lên tới 100 theo chiến lược tùy chỉnh (Bảng 3.2). Vì $\mathbf{x}_i$ và $\mathbf{x}_{nn}$ đều có $BALANCE=0$, mọi điểm nội suy giữa chúng cũng có $BALANCE=0$ — minh họa rủi ro đã nêu: khi toàn bộ hồ sơ gốc của một lớp có cùng giá trị ở một biến, SMOTE không tạo thêm biến thiên thực sự cho biến đó, chỉ nhân bản hình học các tổ hợp còn lại.

Code mới còn cho phép học theo chi phí bằng trọng số lớp:

$$w_c = \frac{N}{K n_c},$$

trong đó N là số quan sát huấn luyện, K là số lớp hiện diện và n_c là số quan sát lớp c . Mỗi quan sát i nhận trọng số w_{y_i} . Riêng XGBoost nhận trọng số do `compute_sample_weights()` tính lại trên từng fold thông qua `classifier__sample_weight`; nhờ đó nhánh `class_weight` có hiệu lực mà không dùng tần suất của phần kiểm định. Với CatBoost, mọi lựa chọn xử lý mất cân bằng khác `none` được code chuyển thành `auto_class_weights=Balanced`, không chạy SMOTE trên chuỗi phân loại.

Hai lưu ý cần nêu rõ. Thứ nhất, biến phân loại đã label-encode được SMOTE nội suy như biến số, có thể sinh giá trị không tương ứng danh mục thực. Thứ hai, trang phân tích Top- k của bộ B gọi chiến lược `smote_moderate`, khác với

chiến lược tùy chỉnh của bảng mô hình đầy đủ. Do đó, so sánh số tuyệt đối giữa hai bảng còn chịu ảnh hưởng của chiến lược lấy mẫu. Tài liệu cho thấy xử lý mất cân bằng có thể làm thay đổi thứ hạng mô hình và không có một kỹ thuật luôn tốt nhất [7].

3.7 Bước 5 — Huấn luyện mô hình

Bước thứ năm huấn luyện và tinh chỉnh các mô hình phân loại, đồng thời mô tả cách mô hình được lưu trữ, chuyển hóa thành điểm tín dụng phục vụ ứng dụng, và định hướng giám sát vận hành sau này.

3.7.1 Xây dựng mô hình

Mã nguồn cài đặt Logistic Regression, Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost. Các tham số chính gồm:

- Decision Tree: độ sâu tối đa 10, tối thiểu 10 mẫu ở lá;
- Random Forest: 300 cây, độ sâu tối đa 15, tối thiểu 5 mẫu ở lá [6];
- XGBoost: 400 cây, độ sâu 6, learning rate 0,05, subsample và colsample bằng 0,8 [9];
- LightGBM: 400 cây, độ sâu 8, learning rate 0,05, subsample và colsample bằng 0,8 [15];
- CatBoost: 400 vòng lặp, độ sâu 6, learning rate 0,05 và hàm mất mát đa lớp [20].

Các giá trị trên được thiết lập cố định trong mã nguồn và không phải kết quả của quá trình tìm kiếm theo lưới. Vì vậy, luận văn không xem các cấu hình này

là siêu tham số tối ưu. Trong môi trường tái lập hiện tại, Logistic Regression phát sinh lỗi tương thích giao diện lập trình ứng dụng liên quan đến tham số `multi_class`; do đó, mô hình này chưa được đưa vào bảng kết quả xác nhận ở Chương 4.

3.7.2 Hiệu chỉnh mô hình

Kiểm định phân tầng lặp và hiệu chỉnh quyết định

Gọi m_{rf} là Macro-F1 ở lần lặp r và fold f . Code báo cáo:

$$\bar{m} = \frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F m_{rf}, \quad s_m = \sqrt{\frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F (m_{rf} - \bar{m})^2}.$$

Trong đó $\bar{m}$ là Macro-F1 trung bình và s_m là độ lệch chuẩn theo cách cài đặt `numpy.std` với mẫu số RF . Precision, Recall và F1 từng nhóm được tổng hợp tương tự. `total_support` bằng Rn_c , tức tổng số lần quan sát lớp c xuất hiện trong các tập kiểm định, không phải số khách hàng độc lập mới.

Từ xác suất $\hat{p}_{ic}$, code cho phép nhân hệ số ưu tiên $b_c \geq 1$ cho lớp hiếm:

$$\hat{y}_i = \arg \max_c (b_c \hat{p}_{ic}).$$

Trong đó $\hat{p}_{ic}$ là xác suất quan sát i thuộc lớp c ; b_c là hệ số boost, mặc định bằng 1; và $\hat{y}_i$ là nhãn sau hiệu chỉnh. Lưới thử $b_c \in \{1, 2, 3, 5, 8, 12, 20\}$ nhằm tối đa Macro-F1. Tuy nhiên, giao diện hiện tìm hệ số trên chính tập đang hiển thị kết quả, nên điểm sau boost là hậu nghiệm lạc quan và không được dùng làm kết quả kiểm định chính. Khi triển khai phải chọn b_c trên validation riêng, rồi khóa hệ số trước khi đánh giá test.

Thiết kế Grid Search

Bảng so sánh mô hình ở Chương 4 dùng đúng một cấu hình siêu tham số cố định cho mỗi thuật toán (mục 3.7.1), chưa qua tối ưu. Để trả lời câu hỏi “thử nhiều phiên bản tham số khác nhau có thay đổi kết luận không”, luận văn chạy Grid Search cho cả sáu mô hình trên cả hai bộ dữ liệu, giữ nguyên chiến lược xử lý mất cân bằng và tập huấn luyện/kiểm định của bảng so sánh chính (bộ A: smote_moderate trên 11 biến; bộ B: SMOTE tùy chỉnh trên 98 đặc trưng) — chỉ thay đổi siêu tham số classifier. Lưới tham số được thiết kế riêng cho từng mô hình (Bảng 3.20), tổng cộng 65 cấu hình mỗi bộ, 130 cấu hình cho cả hai bộ.

Bảng 3.20: Thiết kế lưới Grid Search theo từng mô hình

Mô hình	Tham số và giá trị thử	Số cấu hình
Decision Tree	$\text{max_depth} \in \{5, 10, 15, 20\}$, $\text{min_samples_leaf} \in \{5, 10, 20\}$	12
Random Forest	$\text{n_estimators} \in \{100, 300, 500\}$, $\text{max_depth} \in \{10, 15, 20\}$, $\text{min_samples_leaf} \in \{5, 10\}$	18
XGBoost	$\text{max_depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,05; 0,1\}$ tại $\text{n_estimators}=400$, cộng $\text{n_estimators} \in \{200, 600\}$ tại cấu hình mặc định	11
LightGBM	tương tự XGBoost	11
CatBoost	$\text{depth} \in \{4, 6, 8\} \times \text{learning_rate} \in \{0,03; 0,05; 0,1\}$ tại $\text{iterations}=400$	9
Logistic Regression	$C \in \{0,01; 0,1; 1,0; 10,0\}$	4

Đây là lưới cố định, tự thiết kế theo kinh nghiệm phổ biến cho từng họ mô hình, **không phải Grid Search đầy đủ trên toàn bộ không gian siêu tham số** và không dùng cross-validation lồng nhau; cấu hình “tốt nhất” được chọn trên chính tập kiểm định 1 lần duy nhất, nên mang cùng thiên lệch lựa chọn

(selection bias) đã nêu ở mục phân tích Top- k — không nên xem là kết quả benchmark cuối cùng. Kết quả chi tiết của Grid Search — so sánh cấu hình mặc định với cấu hình tốt nhất tìm được và phân tích độ nhạy theo mô hình — được trình bày ở mục 4.5 của Chương 4.

3.7.3 Triển khai mô hình

Sau khi huấn luyện, mô hình được lưu trữ bằng pickle (`model_{key}.pkl`) và mô hình tốt nhất theo ROC-AUC được ghi vào `best_model.txt` để giao diện chọn mặc định. Hai trang ứng dụng dùng mô hình đã lưu để phục vụ chấm điểm: trang *Chấm điểm* áp dụng mô hình cho tập kiểm định đã tách sẵn; trang *Dự báo* cho phép tải lên danh sách khách hàng mới (Excel/CSV) và trả về nhóm nợ dự báo cùng điểm tín dụng cho toàn bộ danh sách.

Xác suất dự báo $\hat{p}_i = (\hat{p}_{i1}, \dots, \hat{p}_{i5})$ được quy đổi thành điểm tín dụng trong thang $[300, 850]$ bằng công thức tuyến tính theo trọng số rủi ro:

$$\text{score}_i = 850 - \left(\sum_{k=1}^5 \hat{p}_{ik} \omega_k \right) \times (850 - 300),$$

trong đó $\omega = (0; 0,25; 0,50; 0,75; 1,0)$ là trọng số rủi ro tăng dần theo nhóm nợ — nhóm 1 (rủi ro thấp nhất) có $\omega_1 = 0$, nhóm 5 (rủi ro cao nhất) có $\omega_5 = 1$; điểm càng cao thể hiện rủi ro càng thấp. Điểm số sau đó được phân vào 8 hạng tín dụng từ A+ đến E theo bảng ngưỡng cố định (Bảng 3.21), mỗi hạng gán một mô tả và một màu hiển thị phục vụ trực quan hóa.

Bảng 3.21: Thang điểm và hạng tín dụng dùng trong ứng dụng chấm điểm

Hạng	Khoảng điểm	Mô tả
A+	750–850	Xuất sắc
A	700–749	Tốt
B+	650–699	Khá
B	600–649	Trung bình khá
C+	550–599	Trung bình
C	500–549	Trung bình yếu
D	450–499	Yếu
E	300–449	Rất yếu / Từ chối

Công thức trên là quy đổi tuyến tính đơn giản theo trọng số rủi ro tự chọn, chưa phải phép hiệu chỉnh xác suất (calibration) hay thang điểm được kiểm định thống kê như các mô hình scorecard chuẩn hóa theo *Points to Double the Odds* [21]; mục đích chính là tạo đầu ra trực quan, dễ diễn giải cho người dùng không chuyên về mô hình, không phải một thang đo rủi ro đã được đối chiếu với tổn thất thực tế.

3.7.4 Giám sát và bảo trì mô hình

Mã nguồn hiện tại chưa triển khai cơ chế giám sát và bảo trì mô hình tự động — không có tiến trình theo dõi phân phối dữ liệu đầu vào (data drift), không lên lịch huấn luyện lại, và chưa lưu vết phiên bản mô hình/dữ liệu một cách có hệ thống ngoài tệp pickle và `best_model.txt`. Đây là khoảng trống cần bổ sung trước khi triển khai thực tế, không phải một kết quả đã kiểm chứng của luận văn. Định hướng cụ thể — gồm giám sát Macro-F1 và Recall lớp rủi ro theo thời gian, kiểm tra calibration, phát hiện drift và thiết lập lịch tái huấn luyện — được trình bày như một kiến nghị đối với ngân hàng ở mục *Quản trị mô hình* tại Chương 5.

3.8 Tóm tắt chương

Chương 3 đã trình bày năm bước đầu của pipeline nghiên cứu theo đúng mã nguồn. Bước 1 (thu thập dữ liệu) xác định bộ A gồm 27.001 hồ sơ, 21 cột thô và bộ B gồm 5.400 dòng, 178 cột thô. Bước 2 (EDA & làm sạch dữ liệu) bổ sung thống kê mô tả, tỷ lệ ngoại lệ theo IQR, ma trận tương quan và tỷ lệ thiếu cho cả hai bộ. Bước 3 (tiền xử lý & chọn biến) kiểm soát rò rỉ, xây dựng đặc trưng nghiệp vụ, tính đầy đủ bảng Information Value — cho thấy 5/13 biến của bộ A và 5/98 biến của bộ B có $IV > 1,0$ (mức Siddiqi xem là đáng ngờ), còn 21/98 biến của bộ B có $IV < 0,02$ (vô dụng theo tiêu chí đơn biến) dù vẫn được giữ trong tập huấn luyện — rồi xây dựng pool 11/13 biến (bộ A) và 98 biến (bộ B), điền khuyết, mã hóa và minh họa bằng ví dụ số cụ thể. Bước 4 (chia dữ liệu & cân bằng lớp) mô tả phép chia phân tầng 80/20 và chiến lược SMOTE/class-weight, minh họa bằng một phép nội suy SMOTE cụ thể trên nhóm 3 của bộ B. Bước 5 (huấn luyện mô hình) mô tả sáu thuật toán được cài đặt, cơ chế hiệu chỉnh qua RepeatedStratifiedKfold và Grid Search (thiết kế lưới 130 cấu hình), cách mô hình được lưu trữ và chuyển hóa thành điểm tín dụng [300, 850] phục vụ ứng dụng chấm điểm, đồng thời nêu rõ giám sát và bảo trì mô hình chưa được triển khai trong mã nguồn hiện tại.

Các lựa chọn kỹ thuật — điền trung vị thay vì trung bình, giới hạn *UTIL_RATE* trong [0, 10], ngưỡng Information Value 0,02 để loại *SEX* và *LOAIKH* — đều được gắn với bằng chứng thống kê cụ thể quan sát được từ chính hai bộ dữ liệu, thay vì áp dụng như quy ước mặc định. Chương cũng thuật lại một vòng thăm dò ban đầu trên bộ dữ liệu B (mục 3.5.9) — dùng quy tắc xử lý đơn giản hơn (34 biến, chỉ trọng số lớp, chưa SMOTE) và cho Macro-F1

thấp hơn nhiều (tốt nhất 0,2407 với CatBoost) — như bằng chứng cho quá trình lặp lại đã dẫn tới quy trình chính thức; vòng thăm dò này cũng phát hiện hai biến (*CUSTOMER_CLASS*, *CONTRACT_CLASS*) bị nghi ngờ rò rỉ nhưng chưa được loại khỏi bề 98 đặc trưng chính thức, cần rà soát thêm.

Trên nền tảng dữ liệu và năm bước phương pháp đã trình bày, Chương 4 sẽ trình bày hai bước cuối của pipeline: hệ thống thước đo đánh giá, kết quả thực nghiệm chi tiết trên cả hai bộ dữ liệu (so sánh mô hình, hiệu năng theo số lượng đặc trưng, đóng góp nhóm đặc trưng, SHAP), kết quả Grid Search, đối chiếu bốn câu hỏi nghiên cứu và thảo luận ý nghĩa của kết quả đối với mục tiêu dự báo chuyển nhóm nợ.

Chương 4

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

Kế thừa dữ liệu và năm bước phương pháp đã trình bày ở Chương 3, chương này trình bày hai bước cuối của quy trình nghiên cứu, gồm đánh giá và giải thích kết quả, kết luận và đề xuất ứng dụng. Các phân tích được thực hiện trên cơ sở kết quả thực nghiệm tái lập trực tiếp từ mã nguồn. Cụ thể, chương lần lượt: (i) xác lập nguyên tắc báo cáo nhằm bảo đảm tính minh bạch và khả năng tái lập; (ii) trình bày hệ thống thước đo đánh giá; (iii) phân tích kết quả so sánh mô hình, hiệu quả theo số lượng đặc trưng và mức đóng góp của các nhóm đặc trưng trên bộ dữ liệu A; (iv) thực hiện các phân tích tương ứng trên bộ dữ liệu B, đồng thời sử dụng SHAP và đối chiếu với các nghiên cứu so sánh mô hình trước đây; (v) đánh giá độ nhạy siêu tham số dựa trên thiết kế tìm kiếm theo lưới đã trình bày ở Chương 3; (vi) trả lời bốn câu hỏi nghiên cứu được xác lập tại Chương 1; và (vii) thảo luận ý nghĩa của kết quả đối với định hướng xây dựng mô hình dự báo chuyển nhóm nợ.

4.1 Nguyên tắc báo cáo kết quả

Các kết quả định lượng trong chương được tái lập trực tiếp từ hai tệp `Data_credit_rating_VN.xlsx` và `fct_1.xlsx` bằng các hàm trong thư mục `src`. Cả hai bộ dữ liệu đều được phân chia theo tỷ lệ 80/20 có phân tầng, với tham số `random_state=42`. Do có sự khác biệt về biến đích, quy mô mẫu, phân bố lớp và không gian đặc trưng, kết quả của từng bộ dữ liệu được trình bày và diễn giải riêng biệt.

Đối với bộ A, bảng so sánh mô hình sử dụng 11 biến trong cấu hình chính và chiến lược `smote_moderate`; phân tích theo số lượng biến được thực hiện trên tập 13 biến. Đối với bộ B, bảng so sánh sử dụng 98 đặc trưng và chiến lược SMOTE tùy chỉnh; thí nghiệm với k đặc trưng quan trọng nhất được huấn luyện lại bằng `smote_moderate`, phù hợp với cách triển khai trong mã nguồn hiện tại. Vì vậy, mỗi kết quả chỉ có ý nghĩa trong cấu hình thực nghiệm tương ứng và không được xem là kết quả của quá trình tìm kiếm siêu tham số.

Trong môi trường thư viện được sử dụng để tái lập kết quả, Logistic Regression phát sinh lỗi tương thích giao diện lập trình ứng dụng liên quan đến tham số `multi_class`. Do đó, hai bảng so sánh chính chỉ báo cáo kết quả của năm mô hình được thực thi thành công. Hạn chế kỹ thuật này cần được lưu ý khi diễn giải mức độ đầy đủ của phép so sánh.

4.2 Thước đo đánh giá

4.2.1 Ma trận nhầm lẫn đa lớp

Với $K = 5$ lớp, phần tử C_{ab} của ma trận nhầm lẫn là số quan sát có lớp thực a nhưng được dự báo thành lớp b . Đường chéo C_{aa} là số dự báo đúng của lớp a . Trong bài toán này, ma trận đa lớp phù hợp hơn cách ký hiệu TP–TN của bài toán nhị phân.

4.2.2 Precision, Recall và F1 theo lớp

Với lớp k :

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k},$$
$$F1_k = \frac{2P_kR_k}{P_k + R_k}.$$

Trong đó TP_k là số quan sát lớp k được dự báo đúng; FP_k là số quan sát thuộc lớp khác nhưng bị dự báo thành k ; FN_k là số quan sát lớp k bị dự báo sang lớp khác; P_k là Precision; R_k là Recall.

Macro-F1 cho trọng số bằng nhau cho năm lớp:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k,$$

trong đó $K = 5$. Weighted-F1 dùng tỷ trọng hỗ trợ:

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k,$$

trong đó n_k là số quan sát thực của lớp k và $N = \sum_k n_k$. Ở bộ B, nhóm 1 chiếm 97,51%, nên Weighted-F1 có thể cao dù mô hình không nhận diện được nhóm

3 và 4; vì vậy Macro-F1 là tiêu chí chính. Bộ A cân bằng hơn nhưng nhóm 1 vẫn chiếm 77,65%, nên cùng nguyên tắc báo cáo được áp dụng.

4.2.3 Accuracy và ROC-AUC đa lớp

$$\text{Accuracy} = \frac{\sum_{k=1}^K C_{kk}}{N}.$$

Accuracy là tỷ lệ tổng dự báo đúng nhưng bị chi phối bởi lớp 1.

Code tính ROC-AUC theo One-vs-Rest và lấy trung bình macro:

$$\text{AUC}_{\text{macro, OvR}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}(y^{(k)}, \hat{p}^{(k)}),$$

trong đó $y^{(k)}$ là nhãn nhị phân “thuộc/không thuộc lớp k ”; $\hat{p}^{(k)}$ là xác suất dự báo cho lớp k ; và AUC đo khả năng xếp hạng giữa mẫu dương và âm [12].

Ngoài bốn chỉ tiêu trên, Chương 3 (mục 3.7.2) đã trình bày cơ chế `RepeatedStratifiedKFold` và hiệu chỉnh ngưỡng theo lớp — hai công cụ hỗ trợ ước lượng ổn định hơn cho các nhóm nợ hiếm, được nhắc lại khi cần trong các mục kết quả dưới đây.

4.3 Kết quả trên bộ dữ liệu A

4.3.1 So sánh mô hình trên bộ 11 đặc trưng

Bảng 4.1: Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Decision Tree	0,8847	0,5896	0,8786	0,8765
Random Forest	0,9052	0,6179	0,8917	0,9182
XGBoost	0,9096	0,6442	0,8982	0,9201
LightGBM	0,9113	0,6484	0,9001	0,9181
CatBoost	0,7497	0,5454	0,8033	0,9006

LightGBM đạt Macro-F1 cao nhất (0,6484), tiếp theo là XGBoost (0,6442). XGBoost đồng thời đạt ROC-AUC macro cao nhất (0,9201). Do mô-đun phân tích đặc trưng trong mã nguồn sử dụng XGBoost làm cấu hình mặc định, các phân tích tiếp theo đối với bộ A được thực hiện trên mô hình này nhằm bảo đảm tính nhất quán với quy trình thực nghiệm.

4.3.2 Hiệu năng theo số lượng đặc trưng

Bảng 4.2: Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A

k	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
3	0,9021	0,6152	0,8873	0,8874
5	0,9022	0,6184	0,8878	0,8887
7	0,9019	0,6212	0,8887	0,9014
9	0,9093	0,6383	0,8975	0,9203
11	0,9074	0,6364	0,8958	0,9223
13	0,9098	0,6434	0,8977	0,9192

Trong các tập Top- k xếp theo importance, pool đủ 13 biến có Macro-F1 cao nhất, nhưng đường cong không đơn điệu: Top-11 thấp hơn Top-9. Quan trọng hơn, khi huấn luyện đúng danh sách 11 biến cấu hình chính thay vì lấy 11 biến đứng đầu, XGBoost đạt Macro-F1 0,6442, nhỉnh hơn 0,6434 của pool 13 biến; Weighted-F1 tăng từ 0,8977 lên 0,8982 và ROC-AUC tăng từ 0,9192 lên 0,9201. Hai biến đưa lại là *SEX* và *LOAIKH* vì vậy không tạo cải thiện có ý nghĩa trong phép chia này.

Top-9 giữ:

$$\rho_{A,9} = \frac{0,6383}{0,6434} \approx 0,9920,$$

tức khoảng 99,20% Macro-F1 của pool 13 biến trong cùng quy trình Top- k . Đây là mốc nhỏ nhất trong các mốc đã thử đạt ít nhất 99%, không phải bằng chứng

rằng chín là số biến tối thiểu tuyệt đối.

4.3.3 Nhóm đặc trưng và chỉ số ưu tiên dữ liệu

Bảng 4.3: Tỷ trọng importance theo nhóm nghiệp vụ của bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng (%)
Kỳ hạn khoản vay	40,1
Sản phẩm và mục đích vay	21,9
Dư nợ và hạn mức sử dụng	12,9
Đơn vị/Chi nhánh	9,4
Nhân khẩu học có IV thấp	8,1
Lãi suất	7,6

Hai biến *DAYS_TO_MATURITY* và *LOAN_TENURE_DAYS* lần lượt có importance 24,48% và 15,63%, làm nhóm Kỳ hạn khoản vay đứng đầu với 40,1%. Nhóm Sản phẩm và mục đích vay đứng thứ hai, đạt 21,9%.

Đường cong tích lũy cần 12/13 biến để đạt 95% importance và 13/13 biến để đạt 99%. Tuy nhiên, mốc này không mâu thuẫn với việc Top-9 giữ 99,20% Macro-F1, vì tổng importance và hiệu năng ngoài mẫu là hai đại lượng khác nhau.

Các nhóm của bộ A hầu như không có giá trị thiếu; chỉ nhóm Nhân khẩu học có IV thấp thiếu trung bình 2,05%. Vì vậy, chỉ số heuristic xếp Kỳ hạn khoản vay ở vị trí đầu chủ yếu do importance, không chứng minh ngân hàng cần thu thập thêm các trường kỳ hạn đang thiếu. Khuyến nghị phù hợp hơn là duy trì chất lượng các trường ngày và phát triển lịch sử theo thời gian.

4.4 Kết quả trên bộ dữ liệu B

4.4.1 Mức độ mất cân bằng và hệ quả đánh giá

Tập kiểm định gồm 1.077 quan sát, trong đó nhóm 1 có 1.050 quan sát, còn nhóm 3 và 4 chỉ có 2 và 3 quan sát. Một bộ phân loại luôn dự báo nhóm 1 đã có Accuracy:

$$\text{Accuracy}_{\text{majority}} = \frac{1.050}{1.077} = 0,9749.$$

Trong đó 1.050 là số mẫu nhóm 1 và 1.077 là tổng số mẫu kiểm định. Vì vậy, Accuracy khoảng 97–98% chưa đủ để chứng minh mô hình nhận diện được rủi ro. Kết quả cần được đọc cùng Macro-F1 và Recall từng nhóm, phù hợp cảnh báo của Brown và Mues về đánh giá dữ liệu tín dụng mất cân bằng [7].

4.4.2 So sánh các mô hình

Bảng 4.4: Kết quả ngoài mẫu của các mô hình trên 98 đặc trưng

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Decision Tree	0,9666	0,3213	0,9669	0,6985
Random Forest	0,9740	0,2595	0,9696	0,9600
XGBoost	0,9814	0,4118	0,9770	0,9781
LightGBM	0,9805	0,3783	0,9753	0,9792
CatBoost	0,9387	0,3334	0,9537	0,9461

XGBoost có Macro-F1 cao nhất (0,4118), trong khi LightGBM có ROC-AUC macro cao hơn nhẹ (0,9792 so với 0,9781). Hai chỉ tiêu trả lời hai câu hỏi khác nhau: Macro-F1 đánh giá chất lượng nhãn cứng sau khi chọn lớp; ROC-AUC đánh giá khả năng xếp hạng xác suất theo từng lớp qua nhiều ngưỡng [12]. Vì mục tiêu nghiệp vụ quan tâm đồng đều hơn tới lớp thiểu số, XGBoost được chọn

làm mô hình phân tích đặc trưng. Kết quả ensemble cạnh tranh hơn cây đơn phù hợp với các nghiên cứu đối sánh trước, nhưng không chứng minh ensemble luôn tốt hơn trong mọi dữ liệu [16].

4.4.3 Kết quả chi tiết theo nhóm nợ

Bảng 4.5: Precision, Recall và F1 của XGBoost theo nhóm nợ

Nhóm	Số mẫu kiểm định	Precision	Recall	F1
1	1.050	0,9859	0,9990	0,9924
2	17	0,6250	0,2941	0,4000
3	2	0,0000	0,0000	0,0000
4	3	0,0000	0,0000	0,0000
5	5	0,7500	0,6000	0,6667

Bảng 4.5 giải thích vì sao Accuracy và Weighted-F1 cao nhưng Macro-F1 thấp. Mô hình dự báo gần như hoàn hảo nhóm 1, nhận diện 5 trong 17 hồ sơ nhóm 2 và 3 trong 5 hồ sơ nhóm 5, nhưng không nhận diện đúng quan sát nào của nhóm 3 và 4. Với cỡ mẫu rất nhỏ, chưa thể kết luận mô hình “không có khả năng” đối với hai nhóm này; kết luận đúng là dữ liệu kiểm định không đủ để ước lượng năng lực một cách ổn định.

So sánh Recall cho thấy:

- Decision Tree: nhóm 2 đạt 0,4118, nhóm 5 đạt 0,2000;
- Random Forest: nhóm 2 đạt 0,2353, nhóm 5 đạt 0;
- XGBoost: nhóm 2 đạt 0,2941, nhóm 5 đạt 0,6000;
- LightGBM: nhóm 2 đạt 0,2941, nhóm 5 đạt 0,4000;
- CatBoost: nhóm 2 đạt 0,5882, nhóm 5 đạt 0,8000, nhưng Accuracy và Weighted-F1 thấp hơn do phát sinh nhiều cảnh báo sai hơn.

CatBoost minh họa rõ đánh đổi giữa phát hiện lớp thiểu số và số cảnh báo sai. Do đó, lựa chọn mô hình triển khai không nên chỉ dựa vào một thứ hạng chung; ngân hàng cần xác định chi phí bỏ sót và chi phí rà soát.

4.4.4 Đánh giá các lớp hiếm bằng quy trình kiểm định lặp

Hàm `repeated_stratified_recall()` báo cáo giá trị trung bình và độ lệch chuẩn của Precision, Recall và F1 theo từng lớp qua nhiều lượt chia mẫu. Với cấu hình mặc định 3×5 -fold, mỗi hồ sơ thuộc nhóm 3 và 4 được đưa vào tập kiểm định ba lần qua các lượt lặp, thay vì suy luận chỉ từ 2 và 3 hồ sơ trong một tập kiểm định duy nhất. Cách tiếp cận này giúp giảm mức độ phụ thuộc của ước lượng vào một lần chia mẫu, nhưng không khắc phục được hạn chế về quy mô dữ liệu gốc. Tổng số lượt quan sát tăng do cùng một hồ sơ được đánh giá lặp lại, chứ không phản ánh số khách hàng độc lập tăng thêm.

Phiên bản mới cũng sửa đường truyền trọng số cho XGBoost: khi chọn `class_weight`, trọng số nghịch đảo tần suất được truyền vào từng lần `fit()`, kể cả trong từng fold. Vì Bảng 4.4 được tạo bằng SMOTE tùy chỉnh, thay đổi này không làm đổi trực tiếp các số đã báo cáo; nó làm cho nhánh cost-sensitive có hiệu lực đúng như lựa chọn trên giao diện.

Chức năng “Tìm hệ số điều chỉnh tối ưu” nhân xác suất dự báo của các lớp hiếm với một hệ số trước khi áp dụng phép `argmax`. Đây là công cụ phân tích độ nhạy nhằm xem xét sự đánh đổi giữa Precision và Recall, không phải một mô hình mới. Do hệ số hiện được lựa chọn trên chính tập đánh giá, Macro-F1 sau điều chỉnh không được đưa vào bảng kết quả chính. Để bảo đảm tính hợp lệ, dữ liệu cần được tách thành ba tập huấn luyện, xác thực và kiểm định; hệ

số được lựa chọn trên tập xác thực và chỉ được đánh giá một lần trên tập kiểm định.

4.4.5 Hiệu năng theo số lượng đặc trưng

Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Các đặc trưng được xếp theo importance của XGBoost đầy đủ, sau đó code huấn luyện lại tại các mốc k . Kết quả được trình bày trong Bảng 4.6.

Bảng 4.6: Hiệu năng XGBoost theo số lượng đặc trưng Top- k

k	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
5	0,9313	0,2746	0,9476	0,5586
10	0,8895	0,2573	0,9242	0,7330
15	0,9415	0,3270	0,9544	0,8823
20	0,9610	0,3661	0,9672	0,8967
30	0,9619	0,3694	0,9672	0,9013
45	0,9740	0,3810	0,9748	0,9644
60	0,9786	0,3923	0,9759	0,9690
98	0,9814	0,4110	0,9787	0,9699

Trong các mốc đã thử, Macro-F1 đạt cao nhất với 98 đặc trưng. Vì vậy, dữ liệu này không ủng hộ kết luận rằng thêm biến làm giảm hiệu năng sau một điểm rõ ràng. Tuy nhiên, đường cong không đơn điệu ở vùng nhỏ (Top-10 thấp hơn Top-5), nên phát biểu đúng là: *nhiều đặc trưng hơn không luôn bảo đảm tốt hơn về mặt lý thuyết; trong thực nghiệm hiện tại, tập đầy đủ cho kết quả tốt nhất trong các mốc đã kiểm tra.*

Phân tích này còn có một hạn chế: mô hình đầy đủ dùng SMOTE tùy chỉnh, trong khi hàm Top- k của trang 7 dùng smote_moderate. Chênh lệch nhỏ giữa kết quả đầy đủ 0,4118 và kết quả $k = 98$ bằng 0,4110 phản ánh sự khác nhau của pipeline. Trước khi dùng kết quả để quyết định sản xuất, cần thống nhất

chiến lược lấy mẫu.

Ngoài ra, các mốc k được xem và lựa chọn trên cùng tập kiểm định 1.077 hồ sơ. Vì vậy, đường cong có vai trò khám phá; một cấu hình rút gọn được chọn từ đường cong phải được khóa trước và đánh giá lại bằng validation lồng nhau hoặc trên kỳ dữ liệu mới.

Có thể giảm còn bao nhiêu đặc trưng?

Theo tổng importance, 62 đặc trưng đầu tiên chiếm 95% và 72 đặc trưng chiếm 99% importance. Tuy nhiên, importance tích lũy không đồng nghĩa với hiệu năng được duy trì. Tại $k = 60$, tỷ lệ Macro-F1 so với $k = 98$ là:

$$\rho_{60} = \frac{0,3923}{0,4110} \approx 0,9545.$$

Trong đó 0,3923 là Macro-F1 của Top-60 và 0,4110 là Macro-F1 của tập 98 biến trong cùng quy trình Top- k . Như vậy Top-60 giữ khoảng 95,45% Macro-F1.

Nếu tiêu chí “gần như toàn bộ” được đặt ở mức 99% Macro-F1, chưa có cấu hình rút gọn nào trong các mốc đã thử đạt yêu cầu; kết luận thận trọng là **chưa thể giảm tiếp dưới 98 đặc trưng theo ngưỡng 99%**. Nếu ngân hàng chấp nhận giữ khoảng 95% Macro-F1 để đổi lấy mô hình gọn hơn, Top-60 là ứng viên, giảm:

$$\frac{98 - 60}{98} \times 100\% \approx 38,78\%$$

số biến mô hình. Cấu hình này phải được kiểm định lặp hoặc kiểm định theo thời gian trước khi khuyến nghị triển khai.

Ở cấp dữ liệu thô, quy trình đã giảm từ 178 cột xuống 98 đặc trưng hợp lệ,

tương đương loại:

$$\frac{178 - 98}{178} \times 100\% \approx 44,94\%.$$

Mức giảm này chủ yếu đến từ kiểm soát ID, leakage, ngày thô và biến hằng số, không phải lựa chọn dựa trên hiệu năng.

4.4.6 Đóng góp của các nhóm đặc trưng

Bảng 4.7: Tỷ trọng importance của XGBoost theo nhóm nghiệp vụ

Nhóm nghiệp vụ	Tỷ trọng (%)
Dư nợ và giải ngân	46,4
Lãi suất	15,0
Sản phẩm, mục đích và kênh phân phối	9,7
Trả nợ và thu hồi	7,9
Đặc trưng kỹ thuật	6,8
Kỳ hạn và gia hạn	6,1
Khách hàng và đối tác	4,2
Thay đổi và trạng thái hợp đồng	3,6
Bối cảnh và nguồn dữ liệu	0,2

Nhóm Dư nợ và giải ngân đóng góp lớn nhất, chiếm 46,4% tổng importance. Các biến đứng đầu gồm *DISBURSEMENT_AMT_YTD*, *AGG_PD_BAL_YTD*, *AGG_BAL_YTD*, *AGG_PD_BAL_YTD_LCY* và *ACC_PD_BAL_RATE*. Biến đơn lẻ đứng đầu là *BASIC_RATE_CODE* thuộc nhóm Lãi suất, với importance khoảng 9,62%.

Kết quả này trả lời câu hỏi “mô hình sử dụng nhóm nào nhiều nhất”, nhưng chưa trả lời hoàn toàn “nhóm nào tạo giá trị biên lớn nhất”. Importance có thể bị chia sẻ giữa các biến tương quan. Để kết luận mạnh hơn cần thí nghiệm loại bỏ từng nhóm và đo chênh lệch Macro-F1 ngoài mẫu; phiên bản code hiện tại mới tổng hợp importance, chưa thực hiện group ablation.

4.4.7 Ưu tiên đầu tư dữ liệu

Tỷ lệ thiếu trung bình của hai nhóm đứng đầu là 49,38% đối với Dư nợ và giải ngân và 54,65% đối với Lãi suất. Theo chỉ số heuristic được cài đặt, ba ưu tiên đầu là:

1. Dư nợ và giải ngân: 46,4% importance, 49,38% thiếu, điểm ưu tiên 27,55;
2. Lãi suất: 15,0% importance, 54,65% thiếu, điểm ưu tiên 9,70;
3. Sản phẩm, mục đích và kênh phân phối: 9,7% importance, 49,88% thiếu, điểm ưu tiên 5,81.

Vì điểm ưu tiên là tích của importance với một hàm quy ước của tỷ lệ thiếu, kết quả không nên được diễn giải thành lợi tức đầu tư định lượng. Khuyến nghị phù hợp là ưu tiên kiểm kê nguồn, chuẩn hóa định nghĩa và cải thiện độ đầy đủ của nhóm Dư nợ và giải ngân trước; sau đó chạy lại group ablation để xác nhận giá trị biên.

4.4.8 Giải thích mô hình và giới hạn của importance

Mã nguồn hỗ trợ SHAP, dựa trên giá trị Shapley [17]. Với mô hình cộng tính giải thích:

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j,$$

trong đó $f(\mathbf{x})$ là đầu ra của mô hình tại hồ sơ $\mathbf{x}$ trên thang mà explainer sử dụng; ϕ_0 là giá trị nền; và ϕ_j là phần đóng góp của đặc trưng j . Giá trị $\phi_j > 0$ làm đầu ra của lớp đang xét tăng so với nền, còn $\phi_j < 0$ làm giảm.

SHAP giải thích dự báo của mô hình, không chứng minh rằng thay đổi biến sẽ gây ra thay đổi rủi ro. Đặc biệt, các biến số dư và giải ngân có tương quan có

thể chia sẻ importance. Vì vậy, kết luận nghiệp vụ cần kết hợp SHAP, phân tích ổn định và hiểu biết chuyên gia.

Kết quả SHAP trên bộ dữ liệu A

SHAP được tính bằng TreeExplainer cho đúng mô hình XGBoost đã dùng ở bảng so sánh chính (11 biến, smote_moderate), trên toàn bộ 5.401 quan sát kiểm định. Bảng 4.8 liệt kê trung bình $|\phi_j|$ của từng biến trên cả năm lớp.

Bảng 4.8: Importance theo SHAP (trung bình $|\phi_j|$) — bộ dữ liệu A

Biến	Trung bình $ \phi_j $
DAYS_TO_MATURITY	0,8489
UTIL_RATE	0,3217
LOAN_TENURE_DAYS	0,2652
CURR_BAL	0,2493
LAISUAT	0,2404
PARENTORGNBR	0,2219
ORGNBR	0,2176
BASE_BAL	0,1903
CURRMIACCTTYPCD	0,1419
MUCDICHVAY	0,0699
MJACCTTYPCD	0,0220

DAYS_TO_MATURITY vượt trội các biến còn lại theo SHAP, phù hợp việc nó đứng đầu bảng importance dạng Gain ở Bảng 4.3. Quy về nhóm nghiệp vụ (Bảng 4.9), Kỳ hạn khoản vay vẫn đứng đầu với 39,9% — gần như trùng khớp 40,1% theo Gain — cho thấy kết luận “kỳ hạn là nhóm quan trọng nhất của bộ A” ổn định qua hai phương pháp đo importance khác nhau.

Bảng 4.9: Tỷ trọng importance theo SHAP theo nhóm nghiệp vụ — bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng SHAP (%)
Kỳ hạn khoản vay	39,9
Dư nợ và hạn mức sử dụng	27,3
Đơn vị/Chi nhánh	15,8
Lãi suất	8,6
Sản phẩm và mục đích vay	8,4

Tuy nhiên, hai nhóm còn lại đổi thứ hạng đáng kể: Dư nợ và hạn mức sử dụng tăng từ 12,9% (Gain) lên 27,3% (SHAP), trong khi Sản phẩm và mục đích vay giảm từ 21,9% xuống 8,4%. Khác biệt này phù hợp với đặc điểm biến *MUCDICHVAY* có 79 danh mục: Gain-importance của XGBoost cộng dồn theo số lần một biến được dùng để chia nhánh, nên biến phân loại nhiều danh mục có xu hướng được chọn làm điểm chia thường xuyên hơn dù mức đóng góp thực tế theo từng dự báo (đo bằng SHAP) không lớn tương ứng — một thiên lệch đã được ghi nhận với các thước đo importance dựa trên cấu trúc cây [17]. Vì vậy, luận văn khuyến nghị dùng SHAP làm căn cứ chính khi so sánh nhóm nghiệp vụ, chỉ dùng Gain như tham chiếu bổ sung.

Kết quả SHAP trên bộ dữ liệu B

Với bộ B, SHAP được tính trên mô hình XGBoost 98 biến, SMOTE tùy chỉnh, lấy mẫu tối đa 500 quan sát kiểm định (giới hạn tính toán của TreeExplainer trên không gian 98 chiều). Bảng 4.10 liệt kê 15 biến có $|\phi_j|$ trung bình lớn nhất.

Bảng 4.10: Top-15 importance theo SHAP — bộ dữ liệu B

Biến	$ \phi_j $	Biến	$ \phi_j $
AGG_PD_BAL_YTD	0,5911	ACC_RECEIVED_PE	0,1933
ACC_PD_BAL_RATE	0,4760	SEAB_BIZ_IMEX	0,1870
SEAB_POLICY	0,4539	AGG_DISBURSEMENT_AMT	0,1603
CUSTOMER_CLASS	0,3576	AGG_PD_BAL_YTD_LCY	0,1585
ACC_RECEIVABLE_PE	0,3311	PRODUCT	0,1398
CO_CODE	0,3252		
ACC_RECEIVED_PR	0,3041		
AGG_PD_BAL	0,2499		
MIS_DAO	0,2366		
SEAB_REPAY_SRC	0,2069		

So với Top-10 theo Gain của cùng mô hình (*BASIC_RATE_CODE*, *DISBURSEMENT_AMT_YTD*, *AGG_PD_BAL_YTD*, *AGG_BAL_YTD*, *AGG_PD_BAL_YTD_LCY*, *ACC_PD_BAL_RATE*, *ENG_EXTEND_COUNT*, *CHANNEL_NAME*, *CONTRACT_CLASS*, *BALANCE_MAT*), Top-10 theo SHAP chỉ trùng đúng 2 biến (*AGG_PD_BAL_YTD* và *ACC_PD_BAL_RATE*). Đây là khác biệt lớn hơn nhiều so với bộ A và cần được nêu rõ thay vì bỏ qua: *BASIC_RATE_CODE* đứng đầu Gain-importance nhưng không xuất hiện trong Top-15 SHAP — biến này thiếu tới 93,79% dữ liệu (mục 3.5.7), nên phần lớn giá trị được gán nhãn UNKNOWN; XGBoost có thể dùng UNKNOWN làm điểm chia hiệu quả để tách một số ít hồ sơ có giá trị thật, khiến Gain cao cục bộ, trong khi đóng góp trung bình trên toàn bộ mẫu (đo bằng SHAP) lại thấp vì phần lớn hồ sơ đều nhận cùng giá trị UNKNOWN.

Bảng 4.11: Tỷ trọng importance theo SHAP theo nhóm nghiệp vụ — bộ dữ liệu B

Nhóm nghiệp vụ	Tỷ trọng SHAP (%)	Tỷ trọng Gain (%)
Dư nợ và giải ngân	30,9	46,4
Sản phẩm, mục đích và kênh phân phối	20,7	9,7
Trả nợ và thu hồi	16,9	7,9
Khách hàng và đối tác	14,4	4,2
Kỳ hạn và gia hạn	8,5	6,1
Lãi suất	3,8	15,0
Thay đổi và trạng thái hợp đồng	3,1	3,6
Đặc trưng kỹ thuật	1,6	6,8
Bối cảnh và nguồn dữ liệu	0,0	0,2

Bảng 4.11 cho thấy Dư nợ và giải ngân vẫn là nhóm quan trọng nhất theo cả hai thước đo, nhưng tỷ trọng giảm từ 46,4% (Gain) xuống 30,9% (SHAP) — phần chênh lệch chủ yếu chuyển sang nhóm Sản phẩm, mục đích và kênh phân phối (9,7%→20,7%), Trả nợ và thu hồi (7,9%→16,9%) và Khách hàng và đối tác (4,2%→14,4%). Ngược lại, Lãi suất giảm mạnh từ 15,0% xuống 3,8%. Vì khuyến nghị đầu tư dữ liệu ở mục 4.4.7 được tính từ importance dạng Gain, độ lệch này là một giới hạn cần nêu rõ: nếu tính lại điểm ưu tiên bằng SHAP, thứ hạng ưu tiên giữa Lãi suất và các nhóm Sản phẩm/Trả nợ/Khách hàng có thể thay đổi. Luận văn giữ nguyên bảng ưu tiên theo Gain vì đã được cài đặt sẵn trong `data_investment_priority()`, nhưng khuyến nghị các nghiên cứu tiếp theo dùng SHAP group importance làm phiên bản đối chiếu bắt buộc trước khi ra quyết định đầu tư dữ liệu thực tế.

4.4.9 So sánh với các nghiên cứu benchmarking trước đây

Baesens và cộng sự (2003) so sánh nhiều thuật toán phân loại trên tám bộ dữ liệu tín dụng châu Âu và Mỹ, kết luận rằng các phương pháp phi tuyến (mạng

nơ-ron, SVM) không vượt trội nhất quán so với Logistic Regression, và chênh lệch hiệu năng giữa thuật toán tốt nhất và Logistic Regression trên nhiều bộ dữ liệu là không lớn [2]. Kết quả của bộ A trong Bảng 4.1 một phần phù hợp nhận định này: Logistic Regression đạt Macro-F1 0,4204 — thấp hơn rõ rệt so với XGBoost (0,6442) và LightGBM (0,6484), nhưng ROC-AUC macro của Logistic Regression (0,8059) không quá xa so với nhóm boosting (quanh 0,92), cho thấy Logistic Regression vẫn giữ được khả năng *xếp hạng* rủi ro tương đối tốt dù nhãn cứng sau ngưỡng kém chính xác hơn nhiều — cùng cách phân biệt giữa Macro-F1 (đánh giá nhãn cứng) và ROC-AUC (đánh giá khả năng xếp hạng xác suất) đã dùng để đọc kết quả bộ B ở mục trước.

Lessmann và cộng sự (2015) mở rộng benchmark của Baesens et al. trên nhiều bộ dữ liệu và giai đoạn thời gian mới hơn, kết luận rằng các phương pháp ensemble (Random Forest, Gradient Boosting) có xu hướng thắng thế nhất quán hơn theo thời gian so với các mô hình đơn lẻ, đồng thời khuyến nghị dùng nhiều thước đo (không chỉ Accuracy hoặc AUC) khi lớp mất cân bằng [16]. Cả bộ A và bộ B của luận văn xác nhận nửa đầu nhận định này: bốn phương pháp ensemble/boosting (Random Forest, XGBoost, LightGBM, CatBoost) đều vượt Decision Tree về ROC-AUC ở cả hai bộ, và XGBoost hoặc LightGBM luôn có Macro-F1 cao nhất trong sáu mô hình (Bảng 4.1, 4.4).

Tuy nhiên, có một điểm lệch khỏi kỳ vọng “ensemble luôn tốt hơn”: CatBoost — cũng là một thuật toán boosting — lại có Macro-F1 và Accuracy *thấp nhất* trong bốn mô hình cây/ensemble ở cả hai bộ (0,5454 ở bộ A, thấp hơn cả Decision Tree 0,5896; 0,3334 ở bộ B). Nguyên nhân không nằm ở bản chất thuật toán mà ở cách xử lý mất cân bằng: theo mục 3.6.2, mọi chiến lược khác none được tự động chuyển thành `auto_class_weights=Balanced` cho CatBoost

thay vì SMOTE, khiến CatBoost tối ưu hóa để tăng Recall lớp hiếm mạnh hơn nhưng đổi lại Precision và Accuracy tổng thể giảm — thể hiện rõ ở bảng so sánh Recall theo lớp đã nêu ở trên: Recall nhóm 5 của CatBoost đạt 0,8000, cao nhất trong năm mô hình, trong khi Accuracy chỉ 0,9387. Quan sát này củng cố khuyến nghị của Lessmann et al. rằng thứ hạng mô hình phụ thuộc thước đo được chọn và không có một kỹ thuật xử lý mất cân bằng nào luôn tối ưu cho mọi mô hình [16, 7] — trong dữ liệu của luận văn, hiệu ứng này rõ ràng hơn cả lựa chọn thuật toán.

4.5 Độ nhảy siêu tham số — Grid Search

Thiết kế lưới Grid Search (65 cấu hình mỗi bộ, 130 cấu hình cho cả hai bộ) đã được trình bày ở Chương 3 (mục 3.7.2, Bảng 3.20). Mục này trình bày kết quả: so sánh cấu hình mặc định với cấu hình tốt nhất tìm được, và phân tích độ nhảy Macro-F1 theo mô hình trên toàn bộ lưới đã thử.

4.5.1 Cấu hình mặc định so với cấu hình tốt nhất tìm được

Bảng 4.12: So sánh Macro-F1: cấu hình mặc định vs. cấu hình tốt nhất theo Grid Search

Bộ	Mô hình	Macro-F1 (mặc định)	Macro-F1 (tốt nhất)	Cải thiện
A	Decision Tree	0,5896	0,6086	+3,22%
A	Random Forest	0,6179	0,6303	+2,01%
A	XGBoost	0,6442	0,6442	+0,00%
A	LightGBM	0,6484	0,6484	+0,00%
A	CatBoost	0,5454	0,5677	+4,08%
A	Logistic Regression	0,4204	0,4220	+0,37%
B	Decision Tree	0,3213	0,4360	+35,72%
B	Random Forest	0,2595	0,2720	+4,83%
B	XGBoost	0,4118	0,4278	+3,89%
B	LightGBM	0,3783	0,4372	+15,57%
B	CatBoost	0,3334	0,3634	+9,03%
B	Logistic Regression	0,2792	0,3105	+11,19%

Phát hiện quan trọng nhất của Bảng 4.12: sau khi dò tham số, **LightGBM với `max_depth=4`, `learning_rate=0,03` đạt Macro-F1 0,4372 ở bộ B** — vượt qua **XGBoost mặc định (0,4118)**, vốn là mô hình tốt nhất trong bảng so sánh **chính (Bảng 4.4)**. Nói cách khác, kết luận “XGBoost là mô hình tốt nhất cho bộ B” ở phần trước chỉ đúng *trong phạm vi cấu hình mặc định*; khi mở rộng không gian tìm kiếm, LightGBM với cây nông hơn (`depth 4` thay vì `8`) và tốc độ học chậm hơn (`0,03` thay vì `0,05`) mới là lựa chọn tốt nhất đã tìm được. Đây là minh chứng trực tiếp cho lý do luận văn không tuyên bố các bảng so sánh mô hình là benchmark cuối cùng.

Xu hướng chung: cải thiện do tối ưu tham số lớn hơn nhiều ở bộ B (3,89%–35,72%) so với bộ A (0,00%–4,08%). Điều này nhất quán với đặc điểm dữ liệu: bộ B có cỡ mẫu nhỏ (4.304 hồ sơ huấn luyện) và mất cân bằng cực đoan, nên mô hình mặc định — vốn được thiết kế cho dữ liệu cỡ trung bình — dễ overfit

nhiều ở các lớp hiếm; giảm độ sâu cây, tăng ngưỡng số mẫu tối thiểu ở lá, hoặc giảm tốc độ học đều có tác dụng như một hình thức chính quy hóa ngầm, giúp mô hình khái quát hoá tốt hơn trên tập kiểm định nhỏ.

4.5.2 Độ nhạy tham số theo mô hình

Bảng 4.13: Độ nhạy Macro-F1 theo mô hình (trên toàn bộ lưới đã thử)

Bộ	Mô hình	Macro-F1 nhỏ nhất	Macro-F1 lớn nhất	Biên độ	Độ lệch chuẩn
A	Decision Tree	0,5626	0,6086	0,0460	0,0164
A	CatBoost	0,5259	0,5677	0,0418	0,0128
A	LightGBM	0,6223	0,6484	0,0261	0,0065
A	Logistic Regression	0,3993	0,4220	0,0227	0,0106
A	XGBoost	0,6270	0,6442	0,0173	0,0059
A	Random Forest	0,6135	0,6303	0,0168	0,0048
B	Decision Tree	0,3145	0,4360	0,1215	0,0531
B	LightGBM	0,3477	0,4372	0,0894	0,0272
B	Logistic Regression	0,2536	0,3105	0,0568	0,0234
B	CatBoost	0,3077	0,3634	0,0557	0,0179
B	XGBoost	0,3985	0,4278	0,0293	0,0111
B	Random Forest	0,2571	0,2720	0,0149	0,0056

Bảng 4.13 cho thấy hai quan sát nhất quán ở cả hai bộ dữ liệu. Thứ nhất, **Random Forest luôn là mô hình ổn định nhất** (biên độ nhỏ nhất) — cơ chế lấy trung bình qua nhiều cây độc lập của bagging làm giảm phương sai so với một cây đơn hoặc một chuỗi boosting tuần tự, đúng như lý thuyết của Breiman [6]. Thứ hai, **Decision Tree luôn nhạy nhất với tham số**, đặc biệt ở bộ B (biên độ 0,1215 — gấp 8 lần biên độ của Random Forest trên cùng bộ dữ liệu): một cây đơn không có cơ chế trung bình hóa nên rất dễ chuyển từ overfit (cây sâu, lá nhỏ) sang underfit (cây nông, lá lớn) tùy tham số, đặc biệt trên tập huấn luyện chỉ 4.304 quan sát với các lớp hiếm chỉ 9–18 mẫu.

Ở bộ B, LightGBM cũng khá nhạy (biên độ 0,0894, đứng thứ hai) — phù hợp với việc chính LightGBM là mô hình có cải thiện tuyệt đối lớn nhất sau tinh chỉnh (Bảng 4.12). Ngược lại, XGBoost dù cũng là gradient boosting nhưng ổn định hơn LightGBM khá nhiều (biên độ 0,0293 so với 0,0894) trên cùng bộ dữ liệu và cùng loại lưới tham số — có thể do XGBoost mặc định đã dùng `subsample=0,8` và `colsample_bytree=0,8` (lấy mẫu ngẫu nhiên hàng/cột mỗi cây), tạo hiệu ứng chính quy hóa tương tự Random Forest ngay cả khi không dò thêm tham số.

Hạn chế cần nêu rõ: do lưới tham số và cấu hình tốt nhất đều được đánh giá trên cùng một tập kiểm định duy nhất (không phải validation tách riêng), các con số cải thiện ở Bảng 4.12 có thể lạc quan hơn thực tế khi áp dụng cho dữ liệu mới — đúng cảnh báo chung về thiên lệch lựa chọn đã nêu xuyên suốt chương này đối với mọi lựa chọn dựa trên cùng một holdout. Trước khi dùng cấu hình LightGBM (`depth=4`, `lr=0,03`) làm mô hình sản xuất, cần xác nhận lại bằng validation độc lập hoặc `RepeatedStratifiedKFold` như mục 3.7.2 đã trình bày.

4.6 Đối chiếu bốn câu hỏi nghiên cứu

Thứ nhất, nhiều đặc trưng hơn có luôn tốt hơn không? Bằng chứng phụ thuộc bộ dữ liệu. Trên bộ A, 11 biến cấu hình chính cho Macro-F1 0,6442, nhỉnh hơn 0,6434 khi thêm *SEX* và *LOAIKH*; Top-11 cũng thấp hơn Top-9. Trên bộ B, 98 biến cho kết quả cao nhất trong các mốc Top-*k* đã thử. Vì vậy, không thể suy ra quy tắc “càng nhiều biến càng tốt”; biến mới chỉ có giá trị khi tạo thêm tín hiệu ngoài mẫu.

Thứ hai, nhóm nào đóng góp lớn nhất? Kết quả không đồng nhất máy móc giữa hai bộ. Kỳ hạn khoản vay đứng đầu bộ A với 40,1%, còn Dư nợ và giải ngân đứng đầu bộ B với 46,4%. Điểm chung là tín hiệu mạnh nằm ở cấu trúc khoản vay, thời hạn và diễn biến mức độ phơi nhiễm, thay vì chỉ ở thông tin nhân khẩu học.

Thứ ba, có thể giảm còn bao nhiêu biến? Đối với bộ A, Top-9 là mốc nhỏ nhất đã thử giữ ít nhất 99% Macro-F1 của pool 13 biến; bộ 11 biến cấu hình thực còn nhỉnh hơn pool 13 biến. Đối với câu hỏi xuất phát từ 178 cột của bộ B, quy trình bắt buộc trước hết giảm còn 98 đặc trưng hợp lệ. Nếu yêu cầu giữ ít nhất 99% Macro-F1, chưa có bằng chứng giảm dưới 98; nếu chấp nhận khoảng 95%, Top-60 là ứng viên và giữ khoảng 95,45% Macro-F1 trong cùng pipeline Top- k .

Thứ tư, nên ưu tiên mở rộng dữ liệu nào? Ở bộ B, chỉ số code ưu tiên Dư nợ và giải ngân, sau đó là Lãi suất và Sản phẩm–mục đích–kênh phân phối; cả ba nhóm vừa quan trọng vừa thiếu nhiều. Ở bộ A, các trường hiện gần như đầy đủ, nên thứ hạng Kỳ hạn chủ yếu gợi ý duy trì chất lượng và thu thập lịch sử biến động theo kỳ, không phải bổ sung thêm cột tính cùng loại. Ưu tiên xuyên suốt là dữ liệu snapshot theo thời gian, diễn biến dư nợ/giải ngân, lịch trả nợ và các mốc đáo hạn để có thể tạo nhãn chuyển nhóm đúng nghĩa.

4.7 Ý nghĩa đối với mô hình chuyển nhóm nợ

Kết quả hiện tại chứng minh pipeline có thể phân loại nhóm 1 và một phần nhóm 2, 5, nhưng chưa chứng minh cảnh báo chuyển nhóm. Để chuyển sang mục tiêu đề tài, cần:

1. tạo ảnh chụp dữ liệu ở nhiều thời điểm;
2. xác định ngày quan sát và cửa sổ dự báo;
3. loại mọi biến phát sinh sau ngày quan sát;
4. chia huấn luyện–kiểm định theo thời gian;
5. đánh giá Recall/PR-AUC của sự kiện chuyển nhóm và hiệu chỉnh xác suất;
6. kiểm định hiệu quả cảnh báo bằng chi phí bỏ sót và năng lực rà soát.

4.8 Tóm tắt chương

Chương 4 mở đầu bằng hệ thống thước đo đánh giá (ma trận nhầm lẫn đa lớp, Precision/Recall/F1 theo lớp, Macro-F1, Weighted-F1, Accuracy và ROC-AUC macro) làm cơ sở đọc mọi bảng kết quả tiếp theo. Trên bộ A, LightGBM đạt Macro-F1 0,6484 với 11 biến cấu hình; XGBoost đạt 0,6442. Khi phân tích XGBoost trên pool 13 biến, Top-9 giữ khoảng 99,20% Macro-F1 và nhóm Kỳ hạn khoản vay chiếm 40,1% importance. Trên bộ B, XGBoost đạt Macro-F1 0,4118 với 98 biến và SMOTE tùy chỉnh, nhưng không nhận diện đúng nhóm 3 và 4 trong tập kiểm định rất nhỏ. Trong pipeline Top- k , Top-60 giữ khoảng 95,45% Macro-F1; nhóm Dư nợ và giải ngân chiếm 46,4% importance và đứng đầu chỉ số ưu tiên dữ liệu. Hai thực nghiệm cho thấy giá trị của việc thêm biến phụ thuộc vào bối cảnh dữ liệu.

Kết quả SHAP thật cho thấy Gain-importance của XGBoost và SHAP chỉ đồng thuận một phần — ở bộ B, Top-10 hai phương pháp chỉ trùng 2 biến — nên bảng ưu tiên đầu tư dữ liệu cần được đọc cùng cả hai thước đo. Kết quả Grid Search trên 130 cấu hình đã thiết kế ở Chương 3 cho thấy độ nhạy tham số ở bộ B

(cỡ mẫu nhỏ, mất cân bằng cực đoan) lớn hơn nhiều so với bộ A, và sau khi tinh chỉnh, LightGBM ($\text{max_depth}=4$, $\text{learning_rate}=0,03$) vượt qua XGBoost mặc định để trở thành cấu hình tốt nhất đã tìm được cho bộ B (Macro-F1 0,4372). Các kết luận Top- k , importance nhóm, cấu hình Grid Search và class-boost vẫn cần được xác nhận trên validation hoặc dữ liệu ngoài thời gian trước khi triển khai.

Trên cơ sở các kết quả và hạn chế đã trình bày, Chương 5 sẽ tổng kết những đóng góp chính của luận văn, trả lời trực tiếp bốn câu hỏi nghiên cứu đã đặt ra ở Chương 1, nêu rõ các hạn chế cần lưu ý và đề xuất kiến nghị đối với ngân hàng cùng hướng nghiên cứu tiếp theo.

Chương 5

KẾT LUẬN VÀ KIẾN NGHỊ

Trên cơ sở toàn bộ kết quả thực nghiệm đã trình bày ở Chương 4, chương cuối cùng này tổng kết luận văn. Chương lần lượt trình bày: (i) kết luận chung về pipeline và kết quả chính trên hai bộ dữ liệu; (ii) trả lời trực tiếp bốn câu hỏi nghiên cứu đã đặt ra ở Chương 1; (iii) tổng hợp các đóng góp về phương pháp và thực tiễn của luận văn; (iv) nêu rõ các hạn chế cần lưu ý khi diễn giải và sử dụng kết quả; (v) đề xuất kiến nghị cụ thể đối với ngân hàng về dữ liệu, mô hình và quản trị; và (vi) định hướng các hướng nghiên cứu tiếp theo, đặc biệt là xây dựng mô hình dự báo chuyển nhóm nợ và cảnh báo sớm.

5.1 Kết luận chung

Luận văn giữ nguyên định hướng của đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*”. Trên hai bộ dữ liệu gốc và code hiện có, nghiên cứu đã xây dựng được pipeline phân loại năm nhóm nợ, kiểm soát một số nguồn rò rỉ, xử lý mất cân bằng, so sánh các mô hình cây và phân tích vai trò của đặc trưng. Khả năng chuyển nhóm nợ được xác định là hướng phát triển nhằm hỗ trợ phân loại nợ và cảnh báo sớm

rủi ro tín dụng; kết quả hiện tại là nền tảng cho hướng này, chưa phải kiểm định hoàn chỉnh theo thời gian.

Bộ dữ liệu A có 27.001 hồ sơ và 21 cột thô. Trang huấn luyện chính sử dụng 11 biến cấu hình, còn mô-đun phân tích đặc trưng dùng pool 13 biến gồm tám biến số và năm biến phân loại. Phép chia phân tầng tạo 21.600 mẫu huấn luyện và 5.401 mẫu kiểm định. Trên 11 biến, LightGBM đạt Macro-F1 cao nhất là 0,6484; XGBoost đạt 0,6442 và ROC-AUC macro 0,9201.

Bộ dữ liệu B có 5.400 dòng và 178 cột thô. Sau khi loại 19 dòng thiếu nhãn và các trường không phù hợp, mô hình sử dụng 5.381 quan sát với 98 đặc trưng, gồm 63 biến số thô, 26 biến phân loại và 9 biến tạo thêm. Phép chia phân tầng tạo 4.304 mẫu huấn luyện và 1.077 mẫu kiểm định.

Trên bộ B, trong năm mô hình chạy lại thành công, XGBoost đạt Macro-F1 cao nhất là 0,4118, Accuracy 0,9814 và ROC-AUC macro 0,9781. Tuy nhiên, mô hình không nhận diện đúng nhóm 3 và 4 trong tập kiểm định; hai lớp này chỉ có 2 và 3 quan sát. Do đó, kết quả không cho phép khẳng định mô hình đã giải quyết tốt các lớp rủi ro hiếm. Việc báo cáo Macro-F1 và Recall theo lớp giúp tránh kết luận sai từ Accuracy vốn bị chi phối bởi 97,51% quan sát nhóm 1 ở bộ B.

5.2 Trả lời các câu hỏi nghiên cứu

5.2.1 Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Về lý thuyết, thêm đặc trưng không bảo đảm cải thiện ngoài mẫu vì biến mới có thể trùng lặp hoặc gây nhiễu. Bằng chứng trên hai bộ dữ liệu cũng cho kết quả phụ thuộc bối cảnh. Ở bộ A, XGBoost với đúng 11 biến cấu hình đạt Macro-F1

0,6442, nhỉnh hơn 0,6434 của pool 13 biến sau khi đưa lại *SEX* và *LOAIKH*; trong đường cong Top- k , Top-11 còn thấp hơn Top-9. Ở bộ B, tập 98 biến cho Macro-F1 cao nhất trong các mốc đã thử. Vì vậy, kết luận phù hợp là: thêm biến chỉ hữu ích khi biến đó cung cấp tín hiệu ngoài mẫu mới; số lượng biến tự thân không bảo đảm mô hình tốt hơn.

5.2.2 Nhóm đặc trưng nào đóng góp lớn nhất?

Theo feature importance của XGBoost, nhóm Kỳ hạn khoản vay đứng đầu bộ A với 40,1%; nhóm Sản phẩm và mục đích vay đứng thứ hai với 21,9%. Ở bộ B, nhóm Dư nợ và giải ngân đứng đầu với 46,4%, cao hơn nhóm Lãi suất (15,0%) và nhóm Sản phẩm, mục đích và kênh phân phối (9,7%). Kết quả cho thấy nhóm nổi trội phụ thuộc không gian dữ liệu, nhưng các tín hiệu về thời hạn và mức độ phơi nhiễm tín dụng đều quan trọng. Đây là mức sử dụng của mô hình, chưa phải tác động nhân quả hoặc giá trị biên; cần group ablation để xác nhận.

5.2.3 Có thể giảm từ 178 xuống bao nhiêu đặc trưng?

Đối với bộ A, quy trình giảm 21 cột thô xuống pool 13 biến khả dụng. Top-9 là mốc nhỏ nhất đã thử giữ khoảng 99,20% Macro-F1 của pool 13 biến; đồng thời bộ 11 biến cấu hình thực đạt kết quả nhỉnh hơn pool đầy đủ.

Đối với câu hỏi đặt ra từ 178 cột của bộ B, quy tắc nghiệp vụ và chống rò rỉ trước hết giảm xuống 98 đặc trưng, tức giảm khoảng 44,94%. Trong vòng chọn đặc trưng, Top-60 giữ khoảng 95,45% Macro-F1 của tập 98 biến trong cùng quy trình, nhưng chưa đạt ngưỡng 99%. Vì vậy:

- nếu yêu cầu giữ ít nhất 99% Macro-F1, chưa có bằng chứng để giảm dưới

98 đặc trưng;

- nếu chấp nhận giữ khoảng 95% Macro-F1, Top-60 là cấu hình ứng viên, giảm thêm khoảng 38,78% số biến mô hình.

Không nên dùng mốc 62 biến đạt 95% tổng importance như bằng chứng rằng 95% hiệu năng được giữ lại, vì importance tích lũy và hiệu năng là hai đại lượng khác nhau. Các mốc trên cũng mới là mốc nhỏ nhất trong lưới đã thử, chưa phải nghiệm tối ưu tuyệt đối.

5.2.4 Ngân hàng nên ưu tiên thu thập nhóm thông tin nào?

Ở bộ B, chỉ số ưu tiên trong code xếp Dư nợ và giải ngân trước, sau đó đến Lãi suất và Sản phẩm–mục đích–kênh phân phối. Nhóm Dư nợ và giải ngân vừa có importance cao nhất (46,4%) vừa có tỷ lệ thiếu trung bình 49,38%. Ở bộ A, Kỳ hạn khoản vay đứng đầu theo heuristic, nhưng các trường của nhóm này không thiếu; thứ hạng do đó chủ yếu phản ánh importance, không phải khoảng trống chất lượng dữ liệu.

Ngân hàng nên ưu tiên lưu snapshot theo thời gian, chuẩn hóa ngày giải ngân/đáo hạn, tăng độ đầy đủ và tần suất cập nhật dữ liệu dư nợ–giải ngân, sau đó chuẩn hóa lãi suất, sản phẩm, mục đích và kênh. Trước khi đầu tư quy mô lớn, cần chạy thí nghiệm loại bỏ/bổ sung từng nhóm và lượng hóa lợi ích theo chi phí nghiệp vụ.

5.3 Đóng góp của nghiên cứu

5.3.1 Đóng góp phương pháp

Nghiên cứu xây dựng hai pipeline độc lập nhưng cùng nguyên tắc, gồm lựa chọn cột theo taxonomy nghiệp vụ, tạo đặc trưng, điền khuyết, chuẩn hóa, mã hóa, xử lý mất cân bằng và huấn luyện mô hình. Việc loại *NHOMNO* khỏi bộ A và loại các trường nhóm nợ/ngày quá hạn trực tiếp khỏi bộ B thể hiện chủ đích hạn chế mô hình học lại quy tắc tạo nhãn.

Nghiên cứu cũng tách ba khái niệm thường bị đồng nhất: số cột thô, số đặc trưng hợp lệ và số đặc trưng rút gọn theo hiệu năng. Sự phân biệt này giúp câu hỏi “178 biến có cần thiết không” được trả lời chặt chẽ hơn. Việc chạy cùng bốn câu hỏi trên hai cấu trúc dữ liệu còn cho thấy kết luận về số lượng và nhóm đặc trưng không nên được khái quát từ một bộ dữ liệu duy nhất.

5.3.2 Đóng góp thực tiễn

Kết quả cung cấp:

- kết quả đối sánh năm mô hình chạy thành công trên từng bộ dữ liệu;
- bảng hiệu năng theo lớp, cho thấy rõ điểm yếu ở lớp hiếm của bộ B;
- hai đường cong hiệu năng theo số lượng đặc trưng;
- xếp hạng nhóm thông tin nghiệp vụ riêng cho từng bộ;
- khuyến nghị duy trì dữ liệu kỳ hạn, đồng thời ưu tiên cải thiện dữ liệu Dư nợ và giải ngân.

Những kết quả này có thể hỗ trợ thiết kế thí nghiệm cảnh báo sớm tiếp theo, nhưng chưa nên tích hợp tự động vào quyết định tín dụng.

5.4 Hạn chế của nghiên cứu

5.4.1 Chưa có nhãn chuyển nhóm theo thời gian

Hạn chế lớn nhất là chưa có chuỗi snapshot kèm ngày quan sát và cửa sổ dự báo thống nhất. Bộ A có *NHOMNO* và *NHOMNOMOI*, nhưng chưa xác lập rõ chân trời h cho từng hồ sơ; bộ B chỉ có *CLASSIFICATION* ở bản ghi đang xét. Vì vậy, luận văn chưa ước lượng trực tiếp xác suất chuyển nhóm ngoài thời gian.

5.4.2 Mất cân bằng cực đoan và cỡ mẫu lớp hiếm

Trong bộ B, nhóm 3 và 4 có tổng cộng 11 và 13 hồ sơ. Tập kiểm định chỉ có 2 và 3 hồ sơ, không đủ để ước lượng Recall ổn định. SMOTE tạo điểm tổng hợp nhưng không thay thế thông tin thật và không thể khắc phục hoàn toàn thiếu hụt mẫu gốc [8, 7]. Bộ A có nhiều mẫu lớp hiếm hơn, nhưng nhóm 1 vẫn chiếm 77,65%.

5.4.3 Thiết kế kiểm định

Code vẫn dùng một phép chia ngẫu nhiên phân tầng cho các bảng chính, nên kết quả có thể phụ thuộc seed và chưa phản ánh data drift. Phiên bản mới có *RepeatedStratifiedKFold*, mặc định ba lần lặp của 5-fold, và tổng hợp Precision, Recall, F1 theo từng nhóm. Chức năng này giảm độ nhạy với một holdout đơn nhưng không thay thế kiểm định ngoài thời gian.

Các mốc Top- k được xem xét trên cùng tập kiểm định rồi mới rút ra mốc tốt, gây thiên lệch lựa chọn. Do đó, Top-9 và Top-60 chỉ là ứng viên khám phá; cần chọn k trên validation hoặc nested cross-validation và đánh giá lại một lần trên test độc lập.

5.4.4 Sự không thống nhất trong pipeline

Mô hình đầy đủ của bộ B sử dụng SMOTE tùy chỉnh, còn trang Top- k dùng chiến lược SMOTE ở mức vừa. CatBoost dùng trọng số lớp thay cho SMOTE. Vì vậy, một phần chênh lệch có thể đến từ chiến lược mất cân bằng chứ không chỉ số lượng biến.

Ngoài ra, màn hình hiện gắn nhãn “bộ 11 biến” và “bộ 16 biến” nhưng thực tế truyền Top-11 và Top-16 theo importance, không phải đúng hai danh sách cấu hình. Luận văn đã tránh dùng nhầm hai kết quả này, nhưng code cần được sửa để giao diện phản ánh đúng tập cột.

5.4.5 Mã hóa biến phân loại

Label Encoding có thể tạo thứ tự số giả cho các danh mục. SMOTE sau mã hóa còn có thể nội suy ra giá trị không tương ứng danh mục hợp lệ. Cần so sánh One-Hot Encoding, encoding theo xác suất hoặc mô hình xử lý danh mục nguyên bản.

5.4.6 Khả năng tái lập của biến thời gian

Nhánh bộ A dùng ngày tham chiếu cố định 31/12/2021, nhưng hàm tạo đặc trưng FCT_L dùng ngày chạy hiện tại làm mốc. Điều này làm giá trị biến thời

gian của bộ B thay đổi theo ngày thực thi. Cần dùng ngày chốt dữ liệu cố định hoặc ngày quan sát của từng hồ sơ.

5.4.7 Tối ưu và hiệu chỉnh mô hình

Siêu tham số hiện được cấu hình cố định, chưa có nested cross-validation. Xác suất đầu ra chưa được đánh giá calibration. Logistic Regression chưa chạy lại được do tương thích phiên bản thư viện. Code mới cho phép boost xác suất lớp hiếm để dịch ranh giới quyết định, nhưng đang tìm hệ số trên chính tập huấn luyện kết quả; vì vậy chỉ được xem là phân tích hậu nghiệm và có nguy cơ lạc quan. Cần chọn hệ số trên validation riêng, khóa cấu hình rồi mới đánh giá test. Vì vậy, bảng so sánh chưa phải benchmark cuối cùng như các nghiên cứu quy mô lớn [16].

5.4.8 Importance chưa phải bằng chứng nhân quả

Feature importance và SHAP giải thích hành vi của mô hình, không chứng minh quan hệ nhân quả [17]. Các biến tương quan có thể chia sẻ hoặc thay thế importance; chỉ số ưu tiên dữ liệu hiện là heuristic chưa gắn với chi phí kinh tế.

Quan trọng hơn, hai thước đo importance đã cài đặt — Gain của XGBoost và SHAP — không phải lúc nào cũng đồng thuận. Ở bộ B, Top-10 theo Gain và Top-10 theo SHAP chỉ trùng đúng 2 biến (*AGG_PD_BAL_YTD* và *ACC_PD_BAL_RATE*); nhóm Lãi suất chiếm 15,0% theo Gain nhưng chỉ 3,8% theo SHAP, trong khi nhóm Sản phẩm–mục đích–kênh phân phối tăng từ 9,7% lên 20,7%. Ở bộ A, mức đồng thuận cao hơn nhưng vẫn lệch đáng kể ở hai nhóm Dư nợ–hạn mức (12,9%→27,3%) và Sản phẩm–mục đích vay

(21,9%→8,4%). Vì bảng ưu tiên đầu tư dữ liệu ở Chương 4 được tính từ Gain, kết luận “nên ưu tiên nhóm nào” có thể đổi thứ hạng nếu tính lại bằng SHAP — đây là hạn chế cần nêu rõ với người ra quyết định, không chỉ là chi tiết kỹ thuật: một khuyến nghị đầu tư dữ liệu dựa trên một thước đo importance duy nhất có nguy cơ nhạy cảm với lựa chọn phương pháp hơn là với bản chất dữ liệu.

5.5 Kiến nghị đối với ngân hàng

5.5.1 Xây dựng dữ liệu ảnh chụp theo thời gian

Ngân hàng cần lưu snapshot khoản vay ở các kỳ cố định, với khóa khoản vay/khách hàng nhất quán. Mỗi dòng phải có ngày quan sát, nhóm nợ tại ngày quan sát và nhóm nợ tại các cửa sổ 1, 3, 6 hoặc 12 tháng. Đây là điều kiện tiên quyết để chuyển từ phân loại hiện trạng sang dự báo chuyển nhóm.

5.5.2 Ưu tiên chất lượng trước khi mở rộng số lượng biến

Thay vì bổ sung nhiều trường rời rạc, ngân hàng nên:

1. chuẩn hóa ngày giải ngân, ngày đáo hạn và lịch sử thay đổi kỳ hạn;
2. chuẩn hóa định nghĩa và tần suất cập nhật nhóm Dư nợ và giải ngân;
3. giảm tỷ lệ thiếu của biến lãi suất;
4. thống nhất danh mục sản phẩm, mục đích và kênh;
5. lập data lineage để biết biến tồn tại từ thời điểm nào;
6. giám sát drift và tỷ lệ thiếu theo kỳ;

7. đối chiếu ít nhất hai thước đo importance (Gain và SHAP) trước khi quyết định đầu tư thu thập một nhóm dữ liệu cụ thể, vì hai thước đo có thể xếp hạng nhóm nghiệp vụ khác nhau đáng kể như đã chỉ ra ở mục 5.4.8.

5.5.3 Thiết kế cảnh báo theo chi phí

Ngưỡng cảnh báo phải dựa trên năng lực xử lý và chi phí sai lầm. Có thể tối ưu:

$$\mathcal{C}(\tau) = c_{FN}FN(\tau) + c_{FP}FP(\tau),$$

trong đó τ là ngưỡng cảnh báo; $FN(\tau)$ là số khoản vay chuyển nhóm nhưng bị bỏ sót; $FP(\tau)$ là số cảnh báo sai; c_{FN} là chi phí trung bình của bỏ sót; và c_{FP} là chi phí rà soát/cơ hội của cảnh báo sai. Ngưỡng tối ưu là giá trị làm $\mathcal{C}(\tau)$ nhỏ nhất dưới các ràng buộc nghiệp vụ.

5.5.4 Quản trị mô hình

Mô hình cần được triển khai theo chế độ hỗ trợ quyết định, có human-in-the-loop. Ngân hàng cần lưu phiên bản dữ liệu, code, mô hình, lý do cảnh báo và phản hồi xử lý; theo dõi Macro-F1, Recall lớp rủi ro, calibration và drift; đồng thời thiết lập lịch tái huấn luyện.

5.6 Hướng nghiên cứu tiếp theo

Hướng ưu tiên không phải là thêm ngay mô hình học sâu, mà là hoàn thiện nhãn chuyển nhóm và thiết kế kiểm định. Các bước tiếp theo gồm:

1. xây nhãn $Y_{i,t}^{(h)}$ cho nhiều cửa sổ dự báo;

2. chia dữ liệu theo thời gian và theo khách hàng;
3. chuẩn hóa cùng một pipeline mất cân bằng cho mọi cấu hình;
4. chạy repeated cross-validation hoặc backtesting nhiều kỳ;
5. thực hiện group ablation và permutation importance trên tập kiểm định;
6. đánh giá PR-AUC, calibration, expected cost và độ ổn định;
7. thử nghiệm mô hình ordinal, survival hoặc multi-state vì năm nhóm nợ có thứ tự.

Mô hình đa trạng thái có thể mô tả xác suất:

$$p_{ab}^{(h)} = P(G_{i,t+h} = b \mid G_{i,t} = a, \mathbf{X}_{i,t}),$$

trong đó a là nhóm nợ tại thời điểm quan sát; b là nhóm đích sau h kỳ; $\mathbf{X}_{i,t}$ là véc-tơ thông tin sẵn có tại t ; và $p_{ab}^{(h)}$ là xác suất chuyển từ a sang b . Cách tiếp cận này phù hợp hơn phân loại độc lập nếu mục tiêu cuối cùng là ma trận chuyển nhóm.

5.7 Kết luận chương

Nghiên cứu đã tạo được hai pipeline và bằng chứng thực nghiệm cho bài toán phân loại năm nhóm nợ. Trên bộ A, LightGBM đạt Macro-F1 cao nhất với 11 biến; XGBoost cho thấy 11 biến cấu hình nhỉnh hơn pool 13 biến, và nhóm Kỳ hạn khoản vay có importance lớn nhất. Trên bộ B, XGBoost đạt Macro-F1 cao nhất; nhóm Dư nợ và giải ngân đứng đầu; Top-60 là ứng viên nếu chấp nhận giữ khoảng 95% hiệu năng, còn chưa có bằng chứng giảm dưới 98 biến nếu yêu cầu 99%. Hạn chế về dữ liệu theo thời gian, cỡ mẫu lớp hiếm, lựa chọn k trên cùng

holdout và sự khác nhau của pipeline khiến kết quả chưa thể được diễn giải là mô hình cảnh báo chuyển nhóm hoàn chỉnh.

Đây cũng là nội dung khép lại toàn bộ luận văn: bốn câu hỏi nghiên cứu đặt ra ở Chương 1 đã được trả lời trên cơ sở bằng chứng thực nghiệm của Chương 4, đóng góp và hạn chế đã được nhìn nhận thẳng thắn, còn các kiến nghị đối với ngân hàng và hướng nghiên cứu tiếp theo là cơ sở để các công trình kế thừa hoàn thiện mô hình dự báo chuyển nhóm nợ và cảnh báo sớm trong tương lai.

Tài liệu tham khảo

- [1] Edward I. Altman. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609, 1968.
- [2] Bart Baesens, Tony Van Gestel, Stijn Viaene, Maria Stepanova, Johan Suykens, and Jan Vanthienen. Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, 54(6):627–635, 2003.
- [3] Flavio Barboza, Herbert Kimura, and Edward I. Altman. Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83:405–417, 2017.
- [4] Basel Committee on Banking Supervision. Basel Framework: IRB Approach – Risk Components. https://www.bis.org/basel_framework/chapter/CRE/32.htm, 2024. Truy cập ngày 26/07/2026.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [6] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [7] Ian Brown and Christophe Mues. An experimental comparison of

- classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3):3446–3453, 2012.
- [8] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [9] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [10] Jonathan N. Crook, David B. Edelman, and Lyn C. Thomas. Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3):1447–1465, 2007.
- [11] Xolani Dastile, Tugrul Celik, and Moeketsi Potsane. Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing*, 91:106263, 2020.
- [12] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [13] David J. Hand and William E. Henley. Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A*, 160(3):523–541, 1997.
- [14] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.

- [15] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3149–3157, 2017.
- [16] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.
- [17] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774, 2017.
- [18] Microsoft Corporation. LightGBM Documentation: Leaf-wise (Best-first) Tree Growth. <https://lightgbm.readthedocs.io/en/latest/Features.html>, 2026. Truy cập ngày 26/07/2026.
- [19] James A. Ohlson. Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131, 1980.
- [20] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.
- [21] Naeem Siddiqi. *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons, 2006.
- [22] Lyn C. Thomas. A survey of credit and behavioural scoring: Forecasting

financial risk of lending to consumers. *International Journal of Forecasting*, 16(2):149–172, 2000.

- [23] Yufei Xia, Chuanzhi Liu, Bin Da, and Faming Xie. A boosted decision tree approach using bayesian hyper-parameter optimization for credit scoring. *Expert Systems with Applications*, 78:225–241, 2017.