

ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

**ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN
DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG
MẠI Ở VIỆT NAM**

ĐÀM CÔNG DANH

danh.dc251317M@sis.hust.edu.vn

Chuyên ngành Toán Tin

Giảng viên hướng dẫn: TS. Lê Kim Thư Chữ ký của GVHD

TS. Lê Thị Thanh An

Bộ môn: Toán Tin

Viện: Toán ứng dụng và Tin học

HÀ NỘI - 2026

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

BẢN XÁC NHẬN CHỈNH SỬA LUẬN VĂN THẠC SĨ

Họ và tên tác giả luận văn: Đàm Công Danh.

Đề tài luận văn: Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam.

Chuyên ngành: Toán Tin.

Mã học viên: 20251317M

Tác giả, Người hướng dẫn khoa học và Hội đồng chấm luận văn xác nhận tác giả đã sửa chữa, bổ sung luận văn theo biên bản họp Hội đồng ngày ... với các nội dung sau.

Ngày tháng năm 2026

Giảng viên hướng dẫn

Tác giả luận văn

CHỦ TỊCH HỘI ĐỒNG

ĐỀ TÀI LUẬN VĂN

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG XẾP HẠNG TÍN DỤNG: NGHIÊN CỨU TỪ MỘT NGÂN HÀNG THƯƠNG MẠI Ở VIỆT NAM

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

TS. Lê Kim Thư

Lời cảm ơn

Lời đầu tiên, em xin cảm ơn Viện Toán ứng dụng và Tin học đã tạo điều kiện cho phép thực hiện và hỗ trợ em trong quá trình thực hiện nghiên cứu cũng như suốt thời gian theo học chương trình thạc sĩ Toán Tin tại đơn vị.

Đặc biệt, em xin cảm ơn hai cô - TS. Lê Kim Thư và TS. Lê Thị Thanh An đã tận tình quan tâm, hướng dẫn, chia sẻ kinh nghiệm, kiến thức để em có thể hoàn thành được đề tài một cách tốt nhất. Em cũng xin cảm ơn các thầy cô cùng các bạn học viên khóa 2026 trong Khoa Toán Tin đã góp phần giúp em hoàn thành luận văn này.

Mặc dù đã cố gắng nhưng luận văn vẫn không thể tránh khỏi những sai sót. Em mong nhận được những góp ý từ các thầy cô, các bạn độc giả để luận văn được hoàn thiện hơn. Em xin chân thành cảm ơn!

Hà Nội, ngày tháng năm 2026

Học viên thực hiện

Đàm Công Danh

LỜI MỞ ĐẦU

Lý do lựa chọn đề tài

Tín dụng là hoạt động cốt lõi của ngân hàng thương mại, đồng thời là nguồn phát sinh rủi ro có ảnh hưởng trực tiếp đến lợi nhuận, chất lượng tài sản và mức độ an toàn của ngân hàng. Vì vậy, đánh giá và xếp hạng tín dụng không chỉ phục vụ quyết định cấp tín dụng mà còn hỗ trợ giám sát khoản vay, phân loại nợ và nhận diện sớm dấu hiệu suy giảm chất lượng tín dụng.

Sự gia tăng về quy mô và mức độ đa dạng của dữ liệu ngân hàng đặt ra yêu cầu đổi mới phương pháp đánh giá rủi ro. Các phương pháp truyền thống có ưu điểm về tính minh bạch, nhưng có thể gặp hạn chế trước quan hệ phi tuyến, tương tác phức tạp và tình trạng mất cân bằng giữa các nhóm nợ. Trí tuệ nhân tạo và học máy vì vậy mở ra khả năng khai thác dữ liệu hiệu quả hơn, đồng thời hỗ trợ chuẩn hóa và tự động hóa một phần quy trình đánh giá.

Trong bối cảnh đó, đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*” được thực hiện nhằm đánh giá khả năng áp dụng các mô hình học máy vào phân loại năm nhóm nợ trên dữ liệu thực tế. Nghiên cứu đồng thời xem xét vai trò của các nhóm thông tin nghiệp vụ và khả năng rút gọn đặc trưng, qua đó tạo cơ sở cho việc phát triển hệ thống cảnh báo sớm rủi ro tín dụng.

Phần thực nghiệm hiện tại tập trung vào phân loại nhóm nợ và đánh giá mô hình ngoài mẫu. Dự báo khả năng chuyển nhóm nợ theo thời gian được xác định là hướng phát triển tiếp theo khi dữ liệu có đầy đủ lịch sử trạng thái và cửa sổ dự báo.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là việc ứng dụng các phương pháp thống kê và học máy trong phân loại mức độ rủi ro tín dụng. Trọng tâm của luận văn gồm so sánh hiệu năng mô hình, đánh giá ảnh hưởng của mất cân bằng lớp, phân tích vai trò của đặc trưng và đề xuất định hướng dữ liệu cho cảnh báo sớm.

Nghiên cứu sử dụng hai bộ dữ liệu tín dụng đã được ẩn danh từ một ngân hàng thương mại tại Việt Nam. Phạm vi dữ liệu bao gồm thông tin khách hàng, khoản vay và các yếu tố nghiệp vụ liên quan; tên ngân hàng và thông tin định danh trực tiếp không được công bố.

Các mô hình được đánh giá theo quy trình huấn luyện và kiểm định thống nhất trên từng bộ dữ liệu. Kết quả giữa hai bộ chỉ được đối chiếu về xu hướng do khác biệt về quy mô, cấu trúc biến và phân bố nhóm nợ. Các thông số dữ liệu, cấu hình tiền xử lý và thiết kế thực nghiệm được trình bày chi tiết tại Chương 3.

Động lực ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng

Việc ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng được thúc đẩy bởi ba yêu cầu chính: khai thác tốt hơn dữ liệu ngày càng đa dạng; nâng cao tính nhất quán và hiệu quả của quy trình đánh giá; và hỗ trợ nhận diện sớm các khoản vay có dấu hiệu suy giảm. Trong lĩnh vực ngân hàng, hiệu quả dự báo cần đi cùng

khả năng giải thích, kiểm soát và giám sát để mô hình có thể được sử dụng như một công cụ hỗ trợ quyết định.

Tóm tắt nội dung luận văn

Ngoài phần mở đầu, kết luận, tài liệu tham khảo và phụ lục, luận văn được kết cấu thành các chương như sau:

- **Chương 1: Giới thiệu tổng quan về đề tài.** Chương này trình bày bối cảnh nghiên cứu, tính cấp thiết, câu hỏi nghiên cứu, phương pháp nghiên cứu, ý nghĩa và đóng góp của đề tài.
- **Chương 2: Cơ sở lý thuyết và các nghiên cứu liên quan.** Chương này trình bày các khái niệm về tín dụng, rủi ro tín dụng, xếp hạng tín dụng, trí tuệ nhân tạo, học máy và tổng quan các nghiên cứu trong và ngoài nước.
- **Chương 3: Dữ liệu và phương pháp nghiên cứu.** Chương này mô tả hai bộ dữ liệu gốc, hai nhánh tiền xử lý, quy trình xây dựng đặc trưng, xử lý mất cân bằng, lựa chọn mô hình và phương pháp đánh giá số lượng cũng như nhóm đặc trưng.
- **Chương 4: Kết quả thực nghiệm và thảo luận.** Chương này trình bày riêng kết quả trên từng bộ dữ liệu, sau đó đối chiếu bốn câu hỏi về lợi ích của việc bổ sung biến, nhóm thông tin đóng góp lớn nhất, mức rút gọn đặc trưng và ưu tiên đầu tư dữ liệu.
- **Chương 5: Kết luận và khuyến nghị.** Chương này tổng hợp kết quả trên hai bộ dữ liệu, trả lời các câu hỏi nghiên cứu, nêu hạn chế của thiết kế phân loại hiện tại và đề xuất lộ trình phát triển mô hình cảnh báo chuyển nhóm nợ theo thời gian.

Học viên thực hiện

Đàm Công Danh

Mục lục

Lời mở đầu	4
Một số thuật ngữ viết tắt	12
Danh mục hình vẽ	13
Danh mục bảng	14
1 GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI	15
1.1 Bối cảnh và động lực nghiên cứu	15
1.2 Sự phát triển của các phương pháp đánh giá tín dụng	17
1.3 Phát biểu bài toán và phạm vi nghiên cứu	21
1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu	23
1.5 Đóng góp và ý nghĩa nghiên cứu	24
2 CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN	26
2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ	26
2.2 Từ đánh giá truyền thống đến các mô hình học máy	28
2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng	31
2.4 Hệ thống chỉ tiêu đánh giá mô hình	32

2.5	Nghiên cứu liên quan, khoảng trống và định hướng	34
2.6	Tóm tắt chương	35
3	DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	36
3.1	Định hướng và phạm vi thực nghiệm	36
3.2	Quy trình nghiên cứu và khả năng tái lập	37
3.3	Nguồn và cấu trúc dữ liệu	38
3.4	Kiểm soát rò rỉ dữ liệu	43
3.5	Tạo đặc trưng nghiệp vụ	44
3.6	Tiền xử lý trong pipeline	46
3.7	Xử lý mất cân bằng	47
3.8	Các mô hình được cài đặt	48
3.9	Thước đo đánh giá	49
3.10	Phân tích số lượng và nhóm đặc trưng	51
3.11	Tóm tắt chương	53
4	KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	54
4.1	Nguyên tắc báo cáo kết quả	54
4.2	Kết quả trên bộ dữ liệu A	55
4.3	Kết quả trên bộ dữ liệu B	57
4.4	Đối chiếu bốn câu hỏi nghiên cứu	64
4.5	Ý nghĩa đối với mô hình chuyển nhóm nợ	65
4.6	Tóm tắt chương	65
5	KẾT LUẬN VÀ KIẾN NGHỊ	67
5.1	Kết luận chung	67

5.2	Trả lời các câu hỏi nghiên cứu	68
5.3	Đóng góp của nghiên cứu	70
5.4	Hạn chế của nghiên cứu	71
5.5	Kiến nghị đối với ngân hàng	74
5.6	Hướng nghiên cứu tiếp theo	75
5.7	Kết luận chương	76
Tài liệu tham khảo		77

Một số thuật ngữ viết tắt

Viết tắt	Thuật ngữ tiếng Anh	Diễn giải tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ML	Machine Learning	Học máy
NHTM	Commercial Bank	Ngân hàng thương mại
NHNN	State Bank of Vietnam	Ngân hàng Nhà nước Việt Nam
XHTD	Credit Rating	Xếp hạng tín dụng
PD	Probability of Default	Xác suất khách hàng không thực hiện nghĩa vụ trả nợ
LGD	Loss Given Default	Tỷ lệ tổn thất khi xảy ra vỡ nợ
EAD	Exposure at Default	Giá trị dư nợ tại thời điểm vỡ nợ
IV	Information Value	Giá trị thông tin, dùng đánh giá sức phân biệt của đặc trưng
SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật sinh mẫu tổng hợp cho lớp thiểu số
SHAP	SHapley Additive exPlanations	Phương pháp giải thích đóng góp của đặc trưng dựa trên giá trị Shapley
ROC	Receiver Operating Characteristic	Đường cong biểu diễn quan hệ giữa tỷ lệ dương tính thật và dương tính giả
AUC	Area Under the Curve	Diện tích dưới đường cong đánh giá khả năng phân biệt
PR-AUC	Precision–Recall Area Under the Curve	Diện tích dưới đường cong Precision–Recall
F1	F1-score	Trung bình điều hòa của Precision và Recall
CV	Cross-validation	Kiểm định chéo
API	Application Programming Interface	Giao diện lập trình ứng dụng
RF	Random Forest	Thuật toán rừng ngẫu nhiên
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường gradient tối ưu
<i>LightGBM</i>	Light Gradient Boosting Machine	Thuật toán tăng cường gradient dạng cây tối ưu cho hiệu năng

Danh mục hình vẽ

2.1	Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng	28
2.2	Cơ chế cộng dồn các cây trong XGBoost	29
2.3	So sánh phát triển cây theo tầng và theo lá tốt nhất	30
2.4	Nguyên lý phân rã dự báo theo giá trị SHAP	32
3.1	Quy trình thực nghiệm được triển khai trong mã nguồn	38
3.2	Các tầng số lượng biến trong nghiên cứu	41

Danh mục bảng

2.1	Các nhóm nợ trong nghiên cứu	27
3.1	Phân bố năm nhóm nợ trong bộ dữ liệu A	39
3.2	Phân bố năm nhóm nợ trong dữ liệu	40
4.1	Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng	55
4.2	Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A	55
4.3	Tỷ trọng importance theo nhóm nghiệp vụ của bộ dữ liệu A	56
4.4	Kết quả ngoài mẫu của các mô hình trên 98 đặc trưng	57
4.5	Precision, Recall và F1 của XGBoost theo nhóm nợ	58
4.6	Hiệu năng XGBoost theo số lượng đặc trưng Top- k	60
4.7	Tỷ trọng importance của XGBoost theo nhóm nghiệp vụ	62

Chương 1

GIỚI THIỆU TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh và động lực nghiên cứu

1.1.1 Hoạt động tín dụng và rủi ro tín dụng

Hoạt động tín dụng có vai trò đặc biệt quan trọng đối với ngân hàng thương mại. Thông qua hoạt động cấp tín dụng, ngân hàng cung ứng vốn cho cá nhân và tổ chức, đồng thời tạo ra nguồn thu từ lãi và phí. Tuy nhiên, do nghĩa vụ trả nợ được thực hiện trong tương lai, ngân hàng luôn phải đối mặt với sự không chắc chắn liên quan đến khả năng trả nợ của khách hàng.

Rủi ro tín dụng phát sinh khi khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính theo cam kết. Rủi ro này có thể bắt nguồn từ năng lực tài chính suy giảm, dòng tiền không ổn định, quản trị doanh nghiệp yếu, biến động thu nhập, thay đổi môi trường kinh doanh, biến động lãi suất, thông tin không đầy đủ hoặc hành vi gian lận. Hậu quả của rủi ro tín dụng có thể thể hiện qua nợ quá hạn, nợ xấu, chi phí dự phòng tăng, lợi nhuận giảm và mức độ an toàn vốn suy giảm.

Trong quản trị hiện đại, đánh giá tín dụng không nên chỉ được thực hiện một lần tại thời điểm phê duyệt. Ngân hàng cần cập nhật thông tin trong toàn bộ

vòng đời khoản vay, theo dõi sự thay đổi của dư nợ, hành vi thanh toán, thời hạn, tình trạng cơ cấu lại và nhóm nợ. Điều này tạo ra nhu cầu xây dựng các mô hình có khả năng học từ dữ liệu lịch sử và hỗ trợ dự báo rủi ro theo thời gian.

1.1.2 Chấm điểm và xếp hạng tín dụng

Chấm điểm tín dụng là quá trình sử dụng dữ liệu để tính toán một điểm số, một xác suất hoặc một giá trị định lượng phản ánh mức độ rủi ro của khách hàng. Xếp hạng tín dụng là quá trình chuyển kết quả đánh giá thành các nhóm hoặc hạng rủi ro có ý nghĩa quản trị. Hai khái niệm có liên hệ chặt chẽ nhưng không hoàn toàn đồng nhất.

Trong hoạt động ngân hàng, kết quả chấm điểm và xếp hạng có thể được sử dụng để hỗ trợ quyết định cấp tín dụng, xác định hạn mức, xây dựng chính sách lãi suất, giám sát khoản vay, phân loại khách hàng, hỗ trợ trích lập dự phòng và xây dựng hệ thống cảnh báo sớm.

Đối với nghiên cứu này, đầu ra cần dự báo là nhóm nợ từ 1 đến 5. Vì vậy, thuật ngữ “phân loại nhóm nợ” được sử dụng để mô tả trực tiếp bài toán, trong khi “chấm điểm tín dụng” và “xếp hạng tín dụng” được sử dụng trong phần cơ sở lý thuyết và tổng quan nghiên cứu.

1.1.3 Chuyển đổi số trong ngân hàng và vai trò của dữ liệu

Chuyển đổi số trong ngân hàng không chỉ là số hóa kênh giao dịch mà còn bao gồm tái cấu trúc quy trình nghiệp vụ, tự động hóa vận hành, xây dựng nền tảng dữ liệu và ứng dụng các mô hình phân tích trong quản trị.

Trong tín dụng, ngân hàng có thể khai thác nhiều nhóm dữ liệu như thông tin

định danh, lịch sử hợp đồng, dư nợ, hạn mức, số ngày quá hạn, thời hạn khoản vay, mục đích vay, nhóm nợ, trạng thái cơ cấu lại và dữ liệu hành vi. Khi dữ liệu được làm sạch và quản trị phù hợp, các mô hình học máy có thể hỗ trợ nhận diện quy luật mà quy tắc thủ công khó phát hiện. Tuy nhiên, dữ liệu ngân hàng cũng có những thách thức như giá trị thiếu, sai lệch nghiệp vụ, mất cân bằng lớp, thay đổi theo thời gian và nguy cơ rò rỉ thông tin.

1.2 Sự phát triển của các phương pháp đánh giá tín dụng

1.2.1 Từ đánh giá chuyên gia đến mô hình thống kê

Phương pháp chuyên gia.

Phương pháp chuyên gia dựa trên kinh nghiệm của cán bộ tín dụng và các khung đánh giá như 5C.

Mô hình 5C là khung thẩm định tín dụng truyền thống, trong đó cán bộ tín dụng đánh giá khách hàng theo năm phương diện:

1. *Character* (tư cách và uy tín): mức độ thiện chí trả nợ, lịch sử thực hiện nghĩa vụ, tính trung thực và uy tín của khách hàng;
2. *Capacity* (năng lực trả nợ): khả năng tạo dòng tiền và thu nhập đủ để thực hiện nghĩa vụ trả nợ đúng hạn;
3. *Capital* (năng lực tài chính): quy mô vốn tự có, mức độ lành mạnh tài chính và khả năng hấp thụ tổn thất của khách hàng;
4. *Collateral* (tài sản bảo đảm): giá trị, tính pháp lý, khả năng thanh khoản và mức độ bù đắp tổn thất của tài sản bảo đảm;

5. *Conditions* (điều kiện): mục đích và điều kiện khoản vay, đồng thời bao gồm bối cảnh ngành, thị trường và kinh tế có thể ảnh hưởng đến khả năng trả nợ.

5C không phải là một thuật toán thống kê tự động tạo ra xác suất vỡ nợ. Đây là khung tổ chức thông tin để chuyên gia tổng hợp nhận định hoặc chấm điểm theo quy định nội bộ. Vì vậy, chất lượng kết quả phụ thuộc đáng kể vào dữ liệu được cung cấp, tiêu chí chấm điểm và kinh nghiệm của người thẩm định.

Thành tựu của phương pháp này là hệ thống hóa các yếu tố định tính và định lượng cần xem xét, cho phép sử dụng thông tin về uy tín, năng lực quản trị, triển vọng ngành và tài sản bảo đảm [13, 21].

Tuy nhiên, phương pháp này phụ thuộc vào kinh nghiệm cá nhân, khó bảo đảm tính nhất quán, khó mở rộng và khó lượng hóa mức đóng góp của từng yếu tố.

Altman và mô hình Z-score.

Altman [1] đã đưa phân tích phân biệt đa biến vào dự báo phá sản doanh nghiệp thông qua mô hình:

$$Z = 1.2X_1 + 1.4X_2 + 3.3X_3 + 0.6X_4 + 1.0X_5.$$

Trong đó Z là điểm tổng hợp; X_1 là vốn lưu động/tổng tài sản; X_2 là lợi nhuận giữ lại/tổng tài sản; X_3 là lợi nhuận trước lãi vay và thuế/tổng tài sản; X_4 là giá trị thị trường vốn chủ sở hữu/giá trị sổ sách tổng nợ; và X_5 là doanh thu/tổng tài sản. Các hệ số 1,2; 1,4; 3,3; 0,6 và 1,0 được Altman ước lượng cho mẫu nghiên cứu gốc, không phải trọng số phổ quát cho mọi ngân hàng [1].

Thành tựu nổi bật của Altman là chứng minh rằng việc kết hợp nhiều tỷ số

tài chính có thể dự báo khó khăn tài chính tốt hơn việc xem xét từng chỉ số riêng lẻ. Công trình này tạo nền tảng cho dự báo phá sản và xếp hạng doanh nghiệp.

Hạn chế của mô hình là phụ thuộc vào mẫu doanh nghiệp, ngành, chuẩn kế toán và giai đoạn nghiên cứu. Mô hình sử dụng chủ yếu dữ liệu kế toán, giả định quan hệ tuyến tính và không phù hợp trực tiếp với dữ liệu khách hàng cá nhân hoặc dữ liệu hành vi.

Ohlson và mô hình xác suất phá sản.

Ohlson [19] sử dụng hồi quy logistic để ước lượng xác suất phá sản. Đóng góp quan trọng là chuyển đầu ra từ một điểm phân biệt sang xác suất, tạo điều kiện thuận lợi cho lựa chọn ngưỡng và diễn giải rủi ro.

Hạn chế là quan hệ giữa log-odds và biến đầu vào được giả định tuyến tính, còn các tương tác và quan hệ phi tuyến phải được thiết kế thủ công.

1.2.2 Chấm điểm hành vi và nghiên cứu đối sánh mô hình

Hand và Henley.

Hand và Henley [13] hệ thống hóa các phương pháp phân loại thống kê trong consumer credit scoring. Hai tác giả làm rõ rằng không tồn tại một thuật toán duy nhất luôn tốt nhất trên mọi bộ dữ liệu; kết quả phụ thuộc vào chất lượng dữ liệu, lựa chọn biến, cách chia mẫu và tiêu chí đánh giá.

Hạn chế chủ yếu xuất phát từ bối cảnh thời điểm nghiên cứu: boosting, explainable AI, fairness và dữ liệu quy mô lớn chưa phát triển như hiện nay; phần lớn nội dung tập trung vào phân loại nhị phân.

Lyn C. Thomas.

Thomas [21] có đóng góp nổi bật trong việc hệ thống hóa application scoring

và behavioural scoring. Ông mở rộng credit scoring từ quyết định phê duyệt ban đầu sang quản lý khách hàng trong suốt vòng đời khoản vay.

Hạn chế của nhiều mô hình truyền thống được Thomas tổng hợp là tập trung vào dữ liệu có cấu trúc, phân loại tốt–xấu và giả định quan hệ tương đối ổn định theo thời gian.

Jonathan N. Crook.

Crook có nhiều đóng góp trong reject inference, behavioural scoring, survival analysis và mô hình rủi ro động. Các nghiên cứu của ông làm rõ selection bias do dữ liệu huấn luyện thường chỉ gồm khách hàng đã được duyệt và mở rộng bài toán từ “có vỡ nợ hay không” sang “khi nào vỡ nợ” [10].

Hạn chế của reject inference là không thể quan sát chắc chắn nhãn thật của hồ sơ bị từ chối; survival model cũng phụ thuộc vào các giả định có thể không phù hợp với mọi dữ liệu.

Baesens và Lessmann.

Baesens và Lessmann có đóng góp quan trọng trong benchmark giữa các mô hình thống kê và học máy. Lessmann và cộng sự [16] cho thấy thứ hạng mô hình thay đổi theo dữ liệu, thước đo và quy trình thực nghiệm; ensemble thường cạnh tranh nhưng không thể mặc định luôn tối ưu.

Hạn chế của nhiều benchmark là sử dụng dữ liệu công khai nhỏ, cũ, chủ yếu nhị phân và chưa phản ánh đầy đủ dữ liệu ngân hàng thực tế.

Nhận xét tổng hợp. Các công trình nền tảng đã chuyển đánh giá tín dụng từ chủ quan sang định lượng, tạo ra điểm số và xác suất rủi ro, hình thành application scoring, behavioural scoring và quy trình kiểm định mô hình. Tuy nhiên, các hạn chế chung còn lại gồm tập trung vào nhị phân, khó mô hình hóa phi tuyến,

phụ thuộc vào xây dựng biến thủ công, chưa xử lý đầy đủ mất cân bằng, thứ tự, drift và explainability.

1.3 Phát biểu bài toán và phạm vi nghiên cứu

Cho tập dữ liệu:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i, t_i)\}_{i=1}^N,$$

trong đó N là số quan sát; $\mathbf{x}_i \in \mathbb{R}^p$ là véc-tơ gồm p đặc trưng của quan sát i ; $y_i \in \{1, 2, 3, 4, 5\}$ là nhóm nợ; và t_i là thời điểm ghi nhận nếu trường thời gian khả dụng.

Mục tiêu là xây dựng:

$$f_\theta : \mathbf{x}_i \longrightarrow (p_{i1}, p_{i2}, p_{i3}, p_{i4}, p_{i5}),$$

trong đó f_θ là bộ phân loại được xác định bởi tập tham số θ ; p_{ik} là xác suất do mô hình gán quan sát i vào nhóm k . với:

$$p_{ik} = P(Y_i = k \mid \mathbf{x}_i), \quad \sum_{k=1}^5 p_{ik} = 1.$$

Nhãn dự báo:

$$\hat{y}_i = \arg \max_{k \in \{1, 2, 3, 4, 5\}} p_{ik}.$$

Ký hiệu $\hat{y}_i$ là nhãn dự báo; toán tử $\arg \max$ chọn chỉ số nhóm có xác suất lớn nhất.

Do năm nhóm có quan hệ về mức độ rủi ro:

$$1 < 2 < 3 < 4 < 5,$$

bài toán cần vừa đạt hiệu quả tổng thể, vừa nhận diện nhóm rủi ro cao, giảm khoảng cách sai lệch, hạn chế đánh giá thấp rủi ro, duy trì khả năng tổng quát hóa theo thời gian và bảo đảm khả năng giải thích.

1.3.1 Điểm phát triển so với các công trình đi trước

Nghiên cứu phát triển hơn các công trình đi trước ở các khía cạnh:

1. chuyển từ nhị phân sang phân loại trực tiếp năm nhóm nợ;
2. xem xét thứ tự của nhãn bằng $|y_i - \hat{y}_i|$;
3. sử dụng hai bộ dữ liệu thực tế đã ẩn danh từ một ngân hàng Việt Nam để đối chiếu kết luận trong hai cấu trúc dữ liệu khác nhau;
4. xây dựng đặc trưng nghiệp vụ về thời hạn, mục đích vay, cơ cấu nợ và tính nhất quán;
5. xác định chia theo thời gian là yêu cầu cho giai đoạn dự báo chuyển nhóm; thực nghiệm hiện tại dùng phép chia ngẫu nhiên phân tầng do dữ liệu chưa tạo được nhãn theo kỳ;
6. xem mất cân bằng lớp là thành phần trung tâm;
7. cài đặt sáu mô hình và xác nhận lại kết quả của năm mô hình chạy thành công trong môi trường hiện tại;
8. kết hợp hiệu quả dự báo với feature importance và SHAP;
9. lựa chọn mô hình theo hiệu quả, nhận diện rủi ro, sai lệch thứ tự và khả năng giải thích.

Tính mới của luận văn không nằm ở việc phát minh một thuật toán mới, mà nằm ở cách xây dựng, đánh giá và tổ chức bài toán phù hợp hơn với dữ liệu tín dụng thực tế.

1.4 Mục tiêu, câu hỏi và phương pháp nghiên cứu

1.4.1 Mục tiêu nghiên cứu

Mục tiêu tổng quát.

Xây dựng và đánh giá các mô hình học máy nhằm hỗ trợ phân loại năm nhóm nợ trên hai bộ dữ liệu thực tế của một ngân hàng thương mại tại Việt Nam, đồng thời xác định cấu hình đặc trưng có giá trị cho định hướng cảnh báo sớm.

Mục tiêu cụ thể.

1. Hệ thống hóa lý thuyết và nghiên cứu liên quan.
2. Làm sạch và xây dựng đặc trưng từ dữ liệu thực tế.
3. Xây dựng Logistic Regression làm baseline.
4. So sánh với Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost.
5. Đánh giá ảnh hưởng của mất cân bằng lớp.
6. Phân tích tính thứ tự và mức độ nghiêm trọng của sai số.
7. Xác định yêu cầu kiểm tra khả năng tổng quát hóa theo thời gian cho bước phát triển tiếp theo.
8. Giải thích kết quả bằng các phương pháp phù hợp.

1.4.2 Câu hỏi nghiên cứu

1. Mô hình nào cân bằng tốt nhất giữa hiệu quả phân loại tổng thể, khả năng nhận diện các nhóm nợ rủi ro và mức độ giải thích được?
2. Nhiều đặc trưng hơn có luôn giúp mô hình phân loại nhóm nợ tốt hơn không?
3. Nhóm đặc trưng nghiệp vụ nào đóng góp lớn nhất cho việc phân loại nhóm nợ?
4. Có thể giảm từ 178 xuống bao nhiêu đặc trưng mà vẫn giữ gần như toàn bộ hiệu năng?
5. Nếu ngân hàng muốn đầu tư mở rộng dữ liệu, nên ưu tiên thu thập những nhóm thông tin nào để đạt hiệu quả cao nhất?
6. Cần bổ sung cấu trúc dữ liệu và cách kiểm định nào để phát triển mô hình hiện tại thành mô hình dự báo khả năng chuyển nhóm nợ và cảnh báo sớm?

1.4.3 Phương pháp nghiên cứu

Luận văn kết hợp nghiên cứu định tính để tổng quan tài liệu với nghiên cứu định lượng để xử lý dữ liệu, xây dựng mô hình và đánh giá thực nghiệm. Quy trình hiện tại được chạy độc lập trên *Data_credit_rating_VN.xlsx* và *fct_l.xlsx*, gồm làm sạch, xây dựng đặc trưng, EDA, chia ngẫu nhiên phân tầng, xử lý mất cân bằng, huấn luyện, đánh giá và giải thích mô hình. Các kết quả giữa hai bộ chỉ được đối chiếu về xu hướng, không so sánh điểm số như hai mẫu đồng nhất. Chia theo thời gian được đề xuất cho giai đoạn có dữ liệu chuyển nhóm.

1.5 Đóng góp và ý nghĩa nghiên cứu

Về khoa học, luận văn bổ sung bằng chứng thực nghiệm về phân loại năm nhóm nợ, kết hợp mất cân bằng, yếu tố thời gian và khả năng giải thích. Về thực tiễn, kết quả có thể hỗ trợ chuẩn hóa đánh giá, nhận diện khoản vay suy giảm và xây dựng cảnh báo sớm. Mô hình chỉ đóng vai trò hỗ trợ, không thay thế hoàn toàn quyết định của cán bộ tín dụng.

Chương 2

CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1 Nền tảng tín dụng, rủi ro và phân loại nhóm nợ

2.1.1 Khái niệm tín dụng và rủi ro tín dụng

Tín dụng là quan hệ kinh tế trong đó bên cho vay chuyển giao quyền sử dụng một lượng giá trị cho bên đi vay trong một khoảng thời gian xác định, với nghĩa vụ hoàn trả theo các điều kiện đã thỏa thuận.

Rủi ro tín dụng là khả năng phát sinh tổn thất do khách hàng hoặc đối tác không thực hiện đầy đủ nghĩa vụ tài chính. Rủi ro chịu ảnh hưởng từ năng lực tài chính, đặc điểm khoản vay, lịch sử tín dụng, chính sách cấp tín dụng và điều kiện kinh tế.

2.1.2 Phân loại nhóm nợ

Bảng 2.1: Các nhóm nợ trong nghiên cứu

1	Nợ đủ tiêu chuẩn	Mức rủi ro thấp.
2	Nợ cần chú ý	Đã xuất hiện dấu hiệu cần theo dõi.
3	Nợ dưới tiêu chuẩn	Khả năng thu hồi suy giảm đáng kể.
4	Nợ nghi ngờ	Mức rủi ro cao.
5	Nợ có khả năng mất vốn	Mức rủi ro cao nhất.


2.1.3 Chấm điểm, xếp hạng và tổn thất kỳ vọng

Chấm điểm tín dụng tạo ra một giá trị định lượng phản ánh rủi ro; xếp hạng tín dụng gán khách hàng hoặc khoản vay vào một nhóm rủi ro. Hai khái niệm liên hệ nhưng không đồng nhất [13, 21].

Tổn thất kỳ vọng có thể biểu diễn:

$$EL = PD \times LGD \times EAD.$$

Trong đó EL là tổn thất kỳ vọng; PD là xác suất vỡ nợ trong kỳ đánh giá; LGD là tỷ lệ tổn thất khi vỡ nợ sau khi xét khả năng thu hồi; và EAD là dư nợ tại thời điểm vỡ nợ. Luận văn hiện tập trung vào phân loại trạng thái rủi ro, chưa trực tiếp ước lượng đủ ba cấu phần của EL [4].



Hình 2.1: Các cấu phần của tổn thất kỳ vọng trong rủi ro tín dụng

Nguồn: Tác giả tổng hợp và vẽ lại từ Basel Committee on Banking Supervision [4].

2.2 Từ đánh giá truyền thống đến các mô hình học máy

2.2.1 Sự chuyển dịch từ phương pháp truyền thống sang học máy

Phương pháp chuyên gia có khả năng khai thác thông tin định tính nhưng chủ quan. Z-score của Altman có ý nghĩa nền tảng nhưng phụ thuộc dữ liệu kế toán và quan hệ tuyến tính. Logistic Regression dễ giải thích nhưng khó tự động nắm bắt tương tác phức tạp.

Học máy là nhánh của AI trong đó mô hình học quy luật từ dữ liệu. Bài toán của luận văn thuộc học có giám sát.

2.2.2 Mô hình tuyến tính và cây quyết định

Logistic Regression đa lớp.

$$P(Y = k | \mathbf{x}) = \frac{\exp(\beta_{k0} + \beta_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\beta_{j0} + \beta_j^T \mathbf{x})}.$$

Trong đó K là số lớp; $\mathbf{x}$ là véc-tơ đặc trưng; β_{k0} là hệ số chặn của lớp k ; β_k là véc-tơ hệ số của lớp k ; và mẫu số chuẩn hóa để tổng xác suất của K lớp bằng 1

[14].

Decision Tree.

Decision Tree chia không gian đặc trưng bằng các điều kiện dạng $x_j \leq s$. Mô hình dễ giải thích nhưng dễ overfitting.

Random Forest.

$$\hat{y} = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^B.$$


Trong đó B là số cây; $h_b(\mathbf{x})$ là dự báo lớp của cây thứ b tại hồ sơ $\mathbf{x}$; và mode chọn lớp xuất hiện nhiều nhất trong các dự báo cây [6].

2.2.3 Các mô hình boosting

XGBoost.

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t).$$

Trong đó t là vòng boosting; n là số quan sát huấn luyện; $l(\cdot)$ là hàm mất mát; $\hat{y}_i^{(t-1)}$ là dự báo tích lũy trước vòng t ; f_t là cây mới; và $\Omega(f_t)$ là số hạng phạt độ phức tạp của cây nhằm hạn chế quá khớp [9].




Hình 2.2: Cơ chế cộng dồn các cây trong XGBoost

Nguồn: Tác giả khái quát và vẽ lại từ Chen và Guestrin [9].

Hình 2.2 thể hiện cách dự báo được cập nhật tuần tự. Mỗi cây mới $f_t(\mathbf{x})$ hiệu chỉnh phần sai số còn lại của tổ hợp trước đó; η là hệ số học điều chỉnh mức đóng góp của cây mới. XGBoost đồng thời đưa số hạng chính quy $\Omega(f_t)$ vào hàm mục tiêu để kiểm soát độ phức tạp.

LightGBM.

LightGBM tối ưu tốc độ và bộ nhớ bằng các kỹ thuật như Gradient-based One-Side Sampling và Exclusive Feature Bundling. Thuật toán phát triển cây theo lá tốt nhất, tức là tại mỗi bước ưu tiên tách lá tạo ra mức giảm hàm mất mát lớn nhất. Cách phát triển này có thể hội tụ nhanh nhưng cũng làm cây mất cân đối và dễ quá khớp khi dữ liệu nhỏ; vì vậy cần kiểm soát *num_leaves*, *min_data_in_leaf* và *max_depth* [15, 18].



Hình 2.3: So sánh phát triển cây theo tầng và theo lá tốt nhất

Nguồn: Tác giả vẽ lại từ Ke và cộng sự [15] và tài liệu LightGBM [18].

CatBoost.

CatBoost xử lý biến phân loại và sử dụng ordered boosting để hạn chế leakage [20].

2.3 Những thách thức khi mô hình hóa dữ liệu tín dụng

2.3.1 Thách thức đối với hiệu năng dự báo

Mất cân bằng lớp.

$$\mathcal{L} = - \sum_{i=1}^N w_{y_i} \sum_{k=1}^K \mathbb{I}(y_i = k) \log p_{ik}.$$

Trong đó N là số quan sát; K là số lớp; w_{y_i} là trọng số gán cho lớp thật của quan sát i ; $\mathbb{I}(y_i = k)$ bằng 1 khi $y_i = k$ và bằng 0 trong trường hợp khác; p_{ik} là xác suất dự báo lớp k . Trọng số lớn hơn cho lớp hiếm làm sai số của lớp đó có ảnh hưởng lớn hơn tới hàm mất mát.

Tính thứ tự. Năm nhóm nợ có thứ tự rủi ro từ thấp đến cao nên hai sai số lệch một bậc và lệch bốn bậc không có mức độ nghiêm trọng như nhau. Luận văn sử dụng Ordinal MAE ở phần chỉ tiêu đánh giá để lượng hóa số bậc sai lệch trung bình; chỉ tiêu này chưa được hàm `compute_metrics()` của mã nguồn báo cáo trong kết quả chính.


Thay đổi theo thời gian.

$$\mathcal{D}_{train} < \mathcal{D}_{validation} < \mathcal{D}_{test}.$$

2.3.2 Khả năng giải thích và yêu cầu ứng dụng

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j.$$

Trong đó $f(\mathbf{x})$ là đầu ra mô hình cần giải thích; ϕ_0 là giá trị nền; p là số đặc trưng; và ϕ_j là đóng góp SHAP của đặc trưng j cho hồ sơ $\mathbf{x}$ [17].



Hình 2.4: Nguyên lý phân rã dự báo theo giá trị SHAP

Nguồn: Tác giả khái quát và vẽ lại từ Lundberg và Lee [17].

Hình 2.4 minh họa tính cộng của SHAP: dự báo bắt đầu từ giá trị nền ϕ_0 , sau đó được điều chỉnh tăng hoặc giảm bởi đóng góp của từng đặc trưng. Dấu của ϕ_j cho biết chiều tác động đối với đầu ra đang được giải thích, còn độ lớn tuyệt đối phản ánh cường độ đóng góp.

2.4 Hệ thống chỉ tiêu đánh giá mô hình

2.4.1 Chỉ tiêu tổng thể và theo lớp

Accuracy.

$$Accuracy = \frac{\sum_{k=1}^K C_{kk}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}.$$

Trong đó C_{ij} là số quan sát có lớp thật i và lớp dự báo j ; tử số là tổng phần tử đường chéo; mẫu số là tổng số quan sát.

Precision, Recall và F1.

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k},$$

Trong đó TP_k là số dự báo đúng lớp k ; FP_k là số quan sát lớp khác bị dự báo

nhầm thành k ; và FN_k là số quan sát lớp k bị dự báo sang lớp khác.

$$F1_k = 2 \frac{Precision_k \times Recall_k}{Precision_k + Recall_k}.$$

2.4.2 Chỉ tiêu cho dữ liệu mất cân bằng

Macro F1.

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Weighted F1.

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k.$$

Trong đó n_k là số quan sát thật của lớp k và N là tổng số quan sát. Khi một lớp chiếm tỷ trọng rất lớn, Weighted-F1 có thể che khuất hiệu năng thấp của lớp hiếm.

Balanced Accuracy.

$$Balanced Accuracy = \frac{1}{K} \sum_{k=1}^K Recall_k.$$

Balanced Accuracy là trung bình Recall của K lớp, nên mỗi lớp có trọng số như nhau bất kể tần suất.

2.4.3 Chỉ tiêu phản ánh thứ tự nhóm nợ

Ordinal MAE.

$$Ordinal MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

Ký hiệu có ý nghĩa như phần Tính thứ tự; giá trị càng nhỏ thì khoảng cách nhóm dự báo so với nhóm thật càng thấp.

2.5 Nghiên cứu liên quan, khoảng trống và định hướng

2.5.1 Kết quả chính của các nghiên cứu liên quan

Hand và Henley [13] hệ thống hóa các phương pháp thống kê; Thomas [21] mở rộng từ application scoring sang behavioural scoring. Baesens và cộng sự [2] và Lessmann và cộng sự [16] cho thấy hiệu quả mô hình phụ thuộc vào dữ liệu, thước đo và quy trình đánh giá.

Brown và Mues [7] nhấn mạnh ảnh hưởng của mất cân bằng. Xia và cộng sự [22] cho thấy boosted tree có khả năng cải thiện dự báo. Barboza và cộng sự [3] ghi nhận kết quả cạnh tranh của các mô hình cây trong dự báo phá sản. Dastile và cộng sự [11] chỉ ra các hạn chế phổ biến về dữ liệu nhỏ, mất cân bằng, thiếu chuẩn đánh giá và khả năng giải thích.

Tại Việt Nam, nghiên cứu thường tập trung vào credit scoring cá nhân, rủi ro doanh nghiệp và dự báo nợ xấu. Tuy nhiên, chưa có nhiều nghiên cứu công bố việc phân loại trực tiếp năm nhóm nợ trên dữ liệu thực tế, kết hợp so sánh nhiều mô hình, temporal split, ordinal evaluation và explainability.

2.5.2 Khoảng trống và định hướng của luận văn

1. Phần lớn nghiên cứu dùng mục tiêu nhị phân.
2. Tính thứ tự của năm nhóm nợ chưa được khai thác đầy đủ.
3. Dữ liệu thực tế tại ngân hàng Việt Nam ít được công bố.
4. Random split vẫn phổ biến hơn temporal split.
5. Lớp rủi ro cao ít quan sát nhưng chưa được đánh giá đầy đủ.

6. Mô hình phức tạp thường thiếu khả năng giải thích.

Định hướng nghiên cứu. Luận văn xây dựng bài toán năm nhóm nợ, kiểm tra và xây dựng đặc trưng nghiệp vụ, cài đặt Logistic Regression làm baseline, so sánh với mô hình cây và boosting, xử lý mất cân bằng, đánh giá bằng chỉ tiêu đa lớp và giải thích mô hình bằng feature importance và SHAP. Thực nghiệm hiện tại dùng chia ngẫu nhiên phân tầng; chia theo thời gian là yêu cầu cho giai đoạn xây dựng nhân chuyển nhóm.

2.6 Tóm tắt chương

Chương này đã trình bày cơ sở lý thuyết, thành tựu và hạn chế của các công trình nền tảng, các mô hình được sử dụng, các vấn đề đặc thù của dữ liệu tín dụng, tổng quan nghiên cứu, khoảng trống và định hướng của luận văn.

Chương 3

DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Định hướng và phạm vi thực nghiệm

Chương này mô tả quy trình được cài đặt trong mã nguồn Python trên đúng hai tệp dữ liệu gốc trong thư mục `code/data/raw`. Bộ dữ liệu A, `Data_credit_rating_VN.xlsx`, gồm 27.001 dòng và 21 cột thô; biến đích *NHOMNOMOI* nhận giá trị từ 1 đến 5. Bộ dữ liệu B, `fct_1.xlsx`, gồm 5.400 dòng và 178 cột thô; sau khi loại 19 dòng không có nhãn *CLASSIFICATION*, còn 5.381 quan sát hợp lệ.

Cần phân biệt mục tiêu dài hạn của đề tài với phạm vi mà hai tệp hiện tại cho phép kiểm định. Mục tiêu dài hạn là dự báo khả năng chuyển nhóm nợ để hỗ trợ cảnh báo sớm. Bộ A có đồng thời *NHOMNO* và *NHOMNOMOI*, nhưng mã nguồn loại *NHOMNO* do tương quan rất cao với biến đích và chưa xác lập rõ ngày quan sát, chân trời dự báo cho từng hồ sơ. Bộ B chỉ có nhãn *CLASSIFICATION* tại bản ghi đang xét. Do đó, thực nghiệm được diễn giải thận trọng là **phân loại năm nhóm nợ**, đóng vai trò mô hình nền và kiểm

chúng quy trình dữ liệu; chưa được coi là phép kiểm định ngoài thời gian của một mô hình chuyển nhóm.


Nếu có dữ liệu bảng theo thời gian, nhãn chuyển nhóm cần được định nghĩa:

$$Y_{i,t}^{(h)} = \begin{cases} 1, & G_{i,t+h} > G_{i,t}, \\ 0, & G_{i,t+h} \leq G_{i,t}, \end{cases}$$

trong đó i là khoản vay hoặc khách hàng; t là ngày quan sát; h là cửa sổ dự báo; $G_{i,t} \in \{1, 2, 3, 4, 5\}$ là nhóm nợ tại thời điểm t ; và $Y_{i,t}^{(h)} = 1$ biểu thị chuyển sang nhóm có mức rủi ro cao hơn trong h kỳ. Công thức này là thiết kế đề xuất cho giai đoạn triển khai tiếp theo, không phải nhãn đã có trong thực nghiệm hiện tại.

3.2 Quy trình nghiên cứu và khả năng tái lập

Quy trình gồm: (i) đọc và kiểm tra dữ liệu; (ii) loại trường định danh và trường có nguy cơ rò rỉ; (iii) tạo đặc trưng nghiệp vụ; (iv) chia tập huấn luyện–kiểm định; (v) học toàn bộ bước điền khuyết, mã hóa và chuẩn hóa chỉ trên tập huấn luyện; (vi) xử lý mất cân bằng; (vii) huấn luyện mô hình; và (viii) đánh giá đa chỉ tiêu. Cách tổ chức pipeline nhằm hạn chế dữ liệu kiểm định ảnh hưởng ngược tới quá trình huấn luyện, phù hợp nguyên tắc đánh giá ngoài mẫu trong học máy [5, 16].



Hình 3.1: Quy trình thực nghiệm được triển khai trong mã nguồn

Mã nguồn đặt tham số `RANDOM_STATE=42`, tỷ lệ kiểm định bằng 0,2 và thực hiện phép chia ngẫu nhiên có phân tầng theo nhãn. Bộ A được chia thành 21.600 quan sát huấn luyện và 5.401 quan sát kiểm định. Bộ B được chia thành 4.304 quan sát huấn luyện và 1.077 quan sát kiểm định.

Phiên bản ứng dụng hiện tại cung cấp hai tầng đánh giá. Tầng thứ nhất là phép chia 80/20 nêu trên để so sánh trực tiếp với các kết quả đã tái lập. Tầng thứ hai, tùy chọn `RepeatedStratifiedKFold`, lặp phép kiểm định phân tầng 5-fold mặc định ba lần. Với $R = 3$ lần lặp và $F = 5$ fold, mô hình được ước lượng $R \times F = 15$ lần; mỗi quan sát xuất hiện trong tập kiểm định đúng một lần ở mỗi lượt lặp. Thiết kế này không tạo thêm dữ liệu, nhưng giảm mức phụ thuộc của Recall lớp hiếm vào một phép chia duy nhất.

3.3 Nguồn và cấu trúc dữ liệu

3.3.1 Bộ dữ liệu A: `Data_credit_rating_VN`

Bộ A có 27.001 hồ sơ và không thiếu biến đích `NHOMNOMOI`. Bảng 3.1 cho thấy nhóm 1 chiếm 77,65%, trong khi nhóm 3 chỉ chiếm 2,24%. Mức mất cân bằng vẫn đáng kể nhưng nhẹ hơn nhiều so với bộ B.

Bảng 3.1: Phân bố năm nhóm nợ trong bộ dữ liệu A

Nhóm	Toàn bộ	Tỷ lệ (%)	Huẩn luyện	Kiểm định
1	20.965	77,65	16.771	4.194
2	1.287	4,77	1.030	257
3	604	2,24	483	121
4	784	2,90	627	157
5	3.361	12,45	2.689	672
Tổng	27.001	100,00	21.600	5.401

Trang huấn luyện chính sử dụng 11 đặc trưng đã sàng lọc: ba biến phân loại và tám biến số. Trang phân tích đặc trưng mở rộng pool lên 13 biến bằng cách đưa lại *SEX* và *LOAIKH*, là hai biến từng bị loại do Information Value thấp. Cách thiết kế này cho phép kiểm tra trực tiếp liệu bổ sung các biến yếu có cải thiện hiệu năng hay không.

Sau khi phân tích ngày và tạo biến, bộ A có tám biến số:

- năm biến từ tệp nguồn: *BASE_BAL*, *CURR_BAL*, *LAISUAT*, *ORGNBR* và *PARENTORGNBR*;
- ba biến tạo thêm: *LOAN_TENURE_DAYS*, *DAYS_TO_MATURITY* và *UTIL_RATE*.

Năm biến phân loại trong pool đầy đủ được chia thành:

- ba biến cấu hình chính: *MJACCTTYP**CD*, *CURRMIACCTTYP**CD* và *MUCDICHVAY*;
- hai biến IV thấp đưa lại để kiểm chứng: *SEX* và *LOAIKH*.

Đối với bộ 11 biến chính, phép đếm từ tệp nguồn là:

$$21 - 1 - 10 - 2 + 3 = 11,$$

trong đó 21 là số cột thô; 1 là biến đích; 10 là số trường trong danh sách loại; 2 là hai trường ngày chỉ dùng để tạo biến; và 3 là số biến kỹ thuật được bổ sung. Pool phân tích có 13 biến vì đưa lại hai biến *SEX* và *LOAIKH*.

3.3.2 Bộ dữ liệu B: fct_l và phân bố nhân

Bảng 3.2 trình bày phân bố quan sát được đọc trực tiếp từ dữ liệu và phép chia của code.

Bảng 3.2: Phân bố năm nhóm nợ trong dữ liệu

Nhóm	Toàn bộ có nhân	Tỷ lệ (%)	Huấn luyện	Kiểm định
1	5.247	97,51	4.197	1.050
2	87	1,62	70	17
3	11	0,20	9	2
4	13	0,24	10	3
5	23	0,43	18	5
Tổng	5.381	100,00	4.304	1.077

Tỷ lệ nhóm 1 rất cao, trong khi nhóm 3 và 4 chỉ có 11 và 13 quan sát trong toàn bộ dữ liệu. Đây là hạn chế quyết định của thực nghiệm. Với hai quan sát nhóm 3 trong tập kiểm định, một dự báo đúng hoặc sai làm Recall thay đổi 0,5; vì vậy kết quả theo lớp có phương sai rất lớn và không đủ để khẳng định khả năng tổng quát hóa.

3.3.3 Bộ dữ liệu B: từ 178 cột thô tới 98 đặc trưng mô hình

Con số 178 là số cột của tệp thô, không phải số biến thực tế đưa vào bộ phân loại. Bước xây dựng bề đặc trưng thô thực hiện ba lớp lọc:

1. loại biến đích;

2. loại trường định danh, khóa thay thế, văn bản tự do và trường gây rò rỉ, gồm *CLASS_CUR*, *CLASSIFICATION_SK*, *NO_OVD_DAYS* và *NO_DAYS_OVERDUE*;
3. không đưa trực tiếp trường ngày vào mô hình; các trường này chỉ dùng để tạo biến thời lượng; đồng thời loại cột chỉ có một giá trị quan sát.


Sau lọc, code giữ 63 biến số và 26 biến phân loại. Bước tạo đặc trưng nghiệp vụ bổ sung 9 biến số, đưa tổng số đầu vào lên:

$$p = 63 + 26 + 9 = 98.$$

Tương đương, phép đếm từ tệp nguồn có thể viết:

$$178 - 1 - 38 - 19 - 31 + 9 = 98.$$

Trong đó 1 là biến đích; 38 là số trường định danh, khóa thay thế hoặc leakage có mặt trong tệp; 19 là số trường ngày không đưa trực tiếp vào mô hình; 31 là số trường còn lại có không quá một giá trị quan sát; và 9 là số biến tạo thêm. Vì vậy, câu hỏi “giảm từ 178 xuống bao nhiêu” được triển khai chính xác hơn thành hai bước: giảm 178 cột thô xuống tập 98 đặc trưng hợp lệ theo quy tắc nghiệp vụ, sau đó đánh giá khả năng rút gọn tiếp từ 98 đặc trưng.



Hình 3.2: Các tầng số lượng biến trong nghiên cứu

Bên cạnh bề đầy đủ, tệp cấu hình còn khai báo trước một bộ rút gọn gồm 16 biến:

- Nhóm biến số gồm:
 - *INTEREST_RATE, INTEREST_SPREAD;*
 - *BALANCE, BALANCE_PE, BALANCE_PS;*
 - *AGG_DISBURSEMENT_AMT;*
 - *CONTRACT_CHANGE_CNT, NUM_GRACE_PERIOD;*
 - *MIS_DAO, CURR_MIS_DAO;*
 - *FIXED_RATE, LN_APPR_AMT.*
- Nhóm biến phân loại gồm *CATEGORY, SEAB_PRODUCTS, TERM_SBV* và *DATASOURCE*.

Bộ 16 biến là cấu hình vận hành gọn được định trước trong code; mã nguồn hiện tại không lưu bảng IV chứng minh quá trình lựa chọn này. Do đó, luận văn gọi đúng đây là “bộ 16 biến định trước”, không đồng nhất nó với Top-16 của mô hình đầy đủ và không dùng nó thay cho thí nghiệm Top-*k* trên bề 98 biến.

3.3.4 Nhóm đặc trưng nghiệp vụ

Đối với bộ A, code ánh xạ 13 biến vào sáu nhóm: Dư nợ và hạn mức sử dụng; Lãi suất; Kỳ hạn khoản vay; Đơn vị/chi nhánh; Sản phẩm và mục đích vay; Nhân khẩu học có IV thấp. Đối với bộ B, code ánh xạ 98 biến vào chín nhóm: (1) Dư nợ và giải ngân; (2) Lãi suất; (3) Trả nợ và thu hồi; (4) Kỳ hạn và gia hạn; (5) Sản phẩm, mục đích và kênh phân phối; (6) Khách hàng và đối tác; (7) Thay đổi và trạng thái hợp đồng; (8) Bối cảnh và nguồn dữ liệu; và (9) Đặc trưng kỹ thuật.

Việc nhóm biến phục vụ hai mục đích: giải thích mô hình ở cấp nghiệp vụ và xây dựng khuyến nghị đầu tư dữ liệu. Tuy nhiên, tổng importance của nhóm chỉ phản ánh cách mô hình đã sử dụng dữ liệu hiện có; nó không chứng minh quan hệ nhân quả.

3.4 Kiểm soát rò rỉ dữ liệu

Rò rỉ xảy ra khi đầu vào chứa thông tin chỉ có sau thời điểm cần dự báo hoặc là biến đổi trực tiếp của nhãn. Ở bộ A, code loại *NHOMNO_TCBS* và *NHOMNO*; riêng *NHOMNO* có tương quan rất cao với *NHOMNOMOI*, nên nếu giữ lại mô hình có thể học gần trực tiếp trạng thái tạo nhãn. Code cũng loại cột trùng *DUNO_QD*, mô tả văn bản trùng với mã sản phẩm và các trường hằng số hoặc gần như không có thông tin.

Ở bộ B, các biến số ngày quá hạn *NO_OVD_DAYS* và *NO_DAYS_OVERDUE* bị loại. Hai trường *CLASS_CUR* và *CLASSIFICATION_SK* cũng bị loại vì có quan hệ trực tiếp với quy tắc phân loại hoặc biến đích. Nếu giữ chúng, mô hình có thể học lại quy tắc tạo nhãn thay vì phát hiện tín hiệu sớm.

Đối với bài toán chuyển nhóm tương lai, kiểm soát cần chặt hơn: mọi đặc trưng $X_{i,t}$ phải tồn tại tại hoặc trước t , còn nhãn được xác định từ $t + 1$ tới $t + h$. Phép chia ngẫu nhiên đang dùng trong code phù hợp cho kiểm chứng mô hình phân loại hiện trạng, nhưng chưa phải thiết kế tối ưu cho cảnh báo sớm. Khi có dữ liệu thời gian, cần dùng chia theo thời gian để ngăn thông tin tương lai đi vào huấn luyện.

3.5 Tạo đặc trưng nghiệp vụ

Hai nhánh dữ liệu sử dụng công thức tạo biến khác nhau. Bộ A tạo ba biến từ ngày mở, ngày đáo hạn, dư nợ hiện tại và dư nợ gốc. Bộ B tạo chín biến kỹ thuật từ dữ liệu dư nợ, thu hồi, lãi suất, ngày giải ngân, ngày đáo hạn, gia hạn và thay đổi hợp đồng.

3.5.1 Đặc trưng của bộ dữ liệu A

Với ngày tham chiếu cố định $d_0 = 31/12/2021$, code tính:

$$\begin{aligned} LOAN_TENURE_DAYS_i &= \max\{0, d_i^{\text{maturity}} - d_i^{\text{open}}\}, \\ DAYS_TO_MATURITY_i &= d_i^{\text{maturity}} - d_0. \end{aligned}$$

Trong đó d_i^{open} là ngày mở khoản vay; d_i^{maturity} là ngày đến hạn; chênh lệch ngày được biểu diễn bằng số ngày dương hoặc âm. Việc cố định d_0 giúp cùng một hồ sơ nhận cùng giá trị khi tái chạy.

Tỷ lệ sử dụng dư nợ của bộ A được cài đặt:

$$UTIL_RATE_i = \begin{cases} \text{clip}\left(\frac{CURR_BAL_i}{BASE_BAL_i}, 0, 10\right), & BASE_BAL_i > 0, \\ 0, & BASE_BAL_i \leq 0. \end{cases}$$

Trong đó $CURR_BAL$ là dư nợ hiện tại; $BASE_BAL$ là dư nợ gốc hoặc cơ sở; và toán tử $\text{clip}(x, 0, 10)$ giới hạn giá trị trong đoạn $[0, 10]$ để giảm ảnh hưởng của tỷ số ngoại lệ.

3.5.2 Tỷ lệ sử dụng hạn mức của bộ dữ liệu B

$$ENG_UTIL_RATE_i = \begin{cases} \frac{BALANCE_i}{LN_APPR_AMT_i}, & LN_APPR_AMT_i > 0, \\ NaN, & \text{ngược lại.} \end{cases}$$

Trong đó *BALANCE* là dư nợ hiện tại của quan sát *i*; *LN_APPR_AMT* là hạn mức được phê duyệt; tỷ số lớn biểu thị mức sử dụng hạn mức cao. Khác với bộ A, trường hợp mẫu số không dương ở bộ B được giữ thiếu để bước imputer xử lý, thay vì gán 0.

3.5.3 Tỷ lệ thu hồi lãi

$$ENG_COLLECTION_RATIO_i = \frac{R_i}{Q_i + R_i + \epsilon},$$

Trong công thức:

$$R_i = ACC_RECEIVED_INTEREST_i,$$

$$Q_i = ACC_RECEIVABLE_INTEREST_i,$$

với R_i là lãi đã thu lũy kế; Q_i là lãi phải thu lũy kế; và $\epsilon = 10^{-6}$ là hằng số nhỏ nhằm tránh chia cho 0. Công thức đo tỷ trọng phần lãi đã thu trong tổng lãi đã thu và còn phải thu.

3.5.4 Đặc trưng thời gian và thay đổi hợp đồng của bộ dữ liệu B

Ba biến thời gian được tính bằng chênh lệch ngày, gồm:

- *ENG_DAYS_SINCE_FIRST_DISBURSEMENT*;
- *ENG_DAYS_SINCE_LAST_DISBURSEMENT*;
- *ENG_DAYS_TO_MATURITY*.

Ngoài ra, code tạo cờ có gia hạn, số lần gia hạn và cờ từng thay đổi hợp đồng. Nhánh bộ B hiện dùng ngày chạy chương trình làm ngày tham chiếu, trong khi bộ A đã cố định ngày 31/12/2021. Để tái lập khoa học, nhánh bộ B cần được sửa theo cùng nguyên tắc: dùng ngày chốt dữ liệu cố định hoặc ngày quan sát của từng hồ sơ; nếu không, cùng một hồ sơ có thể nhận giá trị khác khi chạy ở ngày khác.

3.6 Tiền xử lý trong pipeline

3.6.1 Giá trị thiếu và chuẩn hóa

Đối với biến số, `SimpleImputer(strategy="median")` thay giá trị thiếu bằng trung vị học trên tập huấn luyện:

$$\tilde{x}_{ij} = \begin{cases} x_{ij}, & x_{ij} \text{ quan sát được,} \\ \text{median}\{x_{\ell j} : \ell \in \mathcal{T}\}, & x_{ij} \text{ thiếu,} \end{cases}$$

trong đó x_{ij} là giá trị biến j của quan sát i ; $\mathcal{T}$ là tập chỉ số huấn luyện; và $\tilde{x}_{ij}$ là giá trị sau điền khuyết.

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, biến số sau điền khuyết được chuẩn hóa:

$$z_{ij} = \frac{\tilde{x}_{ij} - \mu_j}{\sigma_j},$$

trong đó μ_j và σ_j lần lượt là trung bình và độ lệch chuẩn của biến j sau điền khuyết trên tập huấn luyện; z_{ij} là giá trị chuẩn hóa. Việc chuẩn hóa đặc biệt cần cho hồi quy logistic, còn mô hình cây ít nhạy hơn với thang đo [5, 14].

3.6.2 Biến phân loại

Đối với Logistic Regression, Decision Tree, Random Forest, XGBoost và LightGBM, code dùng LabelEncoder riêng cho từng cột. Nếu giá trị mới không xuất hiện trong huấn luyện, code ánh xạ nó về lớp đầu tiên trong encoder. Đây là cách xử lý kỹ thuật nhưng có thể tạo thứ tự giả cho biến định danh; kết quả cần được xem là hạn chế của pipeline.

CatBoost sử dụng preprocessor riêng: biến số chỉ được điền trung vị, không chuẩn hóa; biến phân loại thiếu được thay bằng UNKNOWN và giữ dạng chuỗi để thuật toán xử lý trực tiếp, phù hợp cơ chế của CatBoost [20].

3.7 Xử lý mất cân bằng

SMOTE tạo một điểm tổng hợp:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim U(0, 1),$$

trong đó $\mathbf{x}_i$ là véc-tơ của một quan sát lớp thiểu số; $\mathbf{x}_{nn}$ là một trong các láng giềng gần của nó; λ là số ngẫu nhiên phân bố đều trên $[0, 1]$; và $\mathbf{x}_{\text{new}}$ là điểm nội suy [8].

Đối với bộ A, chiến lược smote_moderate nâng số mẫu huấn luyện của các lớp 2, 3, 4 và 5 lần lượt tới 3.000, 2.000, 2.000 và 5.000. Các giá trị gốc tương ứng là 1.030, 483, 627 và 2.689. Đối với bộ B, bảng so sánh mô hình đầy đủ dùng chiến lược tùy chỉnh, nâng bốn lớp này lần lượt tới 300, 100, 100 và 200 từ các mức 70, 9, 10 và 18. SMOTE được đặt sau preprocessor và trước classifier trong pipeline, nên chỉ tác động tới tập huấn luyện.

Code mới còn cho phép học theo chi phí bằng trọng số lớp:

$$w_c = \frac{N}{K n_c},$$

trong đó N là số quan sát huấn luyện, K là số lớp hiện diện và n_c là số quan sát lớp c . Mỗi quan sát i nhận trọng số w_{y_i} . Riêng XGBoost nhận trọng số do `compute_sample_weights()` tính lại trên từng fold thông qua `classifier__sample_weight`; nhờ đó nhánh `class_weight` có hiệu lực mà không dùng tần suất của phần kiểm định. Với CatBoost, mọi lựa chọn xử lý mất cân bằng khác `none` được code chuyển thành `auto_class_weights=Balanced`, không chạy SMOTE trên chuỗi phân loại.

Hai lưu ý cần nêu rõ. Thứ nhất, biến phân loại đã label-encode được SMOTE nội suy như biến số, có thể sinh giá trị không tương ứng danh mục thực. Thứ hai, trang phân tích Top- k của bộ B gọi chiến lược `smote_moderate`, khác với chiến lược tùy chỉnh của bảng mô hình đầy đủ. Do đó, so sánh số tuyệt đối giữa hai bảng còn chịu ảnh hưởng của chiến lược lấy mẫu. Tài liệu cho thấy xử lý mất cân bằng có thể làm thay đổi thứ hạng mô hình và không có một kỹ thuật luôn tốt nhất [7].

3.8 Các mô hình được cài đặt

Mã nguồn cài đặt Logistic Regression, Decision Tree, Random Forest, XGBoost, LightGBM và CatBoost. Các tham số chính gồm:

- Decision Tree: độ sâu tối đa 10, tối thiểu 10 mẫu ở lá;
- Random Forest: 300 cây, độ sâu tối đa 15, tối thiểu 5 mẫu ở lá [6];

- XGBoost: 400 cây, độ sâu 6, learning rate 0,05, subsample và colsample bằng 0,8 [9];
- LightGBM: 400 cây, độ sâu 8, learning rate 0,05, subsample và colsample bằng 0,8 [15];
- CatBoost: 400 vòng lặp, độ sâu 6, learning rate 0,05 và hàm mất mát đa lớp [20].

Các giá trị này được cấu hình cố định trong code, không phải kết quả Grid Search. Vì vậy, luận văn không tuyên bố đã tối ưu siêu tham số. Logistic Regression trong môi trường tái chạy hiện tại phát sinh lỗi tương thích API do tham số `multi_class`; mô hình này chưa được đưa vào bảng kết quả xác nhận ở Chương 4.

3.9 Thước đo đánh giá

3.9.1 Ma trận nhầm lẫn đa lớp

Với $K = 5$ lớp, phần tử C_{ab} của ma trận nhầm lẫn là số quan sát có lớp thực a nhưng được dự báo thành lớp b . Đường chéo C_{aa} là số dự báo đúng của lớp a . Trong bài toán này, ma trận đa lớp phù hợp hơn cách ký hiệu TP–TN của bài toán nhị phân.

3.9.2 Precision, Recall và F1 theo lớp

Với lớp k :

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k},$$

$$F1_k = \frac{2P_kR_k}{P_k + R_k}.$$

Trong đó TP_k là số quan sát lớp k được dự báo đúng; FP_k là số quan sát thuộc lớp khác nhưng bị dự báo thành k ; FN_k là số quan sát lớp k bị dự báo sang lớp khác; P_k là Precision; R_k là Recall.

Macro-F1 cho trọng số bằng nhau cho năm lớp:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k,$$

trong đó $K = 5$. Weighted-F1 dùng tỷ trọng hỗ trợ:

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k,$$

trong đó n_k là số quan sát thực của lớp k và $N = \sum_k n_k$. Ở bộ B, nhóm 1 chiếm 97,51%, nên Weighted-F1 có thể cao dù mô hình không nhận diện được nhóm 3 và 4; vì vậy Macro-F1 là tiêu chí chính. Bộ A cân bằng hơn nhưng nhóm 1 vẫn chiếm 77,65%, nên cùng nguyên tắc báo cáo được áp dụng.

3.9.3 Accuracy và ROC-AUC đa lớp

$$\text{Accuracy} = \frac{\sum_{k=1}^K C_{kk}}{N}.$$

Accuracy là tỷ lệ tổng dự báo đúng nhưng bị chi phối bởi lớp 1.

Code tính ROC-AUC theo One-vs-Rest và lấy trung bình macro:

$$\text{AUC}_{\text{macro, OvR}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}(y^{(k)}, \hat{p}^{(k)}),$$

trong đó $y^{(k)}$ là nhãn nhị phân “thuộc/không thuộc lớp k ”; $\hat{p}^{(k)}$ là xác suất dự báo cho lớp k ; và AUC đo khả năng xếp hạng giữa mẫu dương và âm [12].

3.9.4 Kiểm định phân tầng lặp và hiệu chỉnh quyết định

Gọi m_{rf} là Macro-F1 ở lần lặp r và fold f . Code báo cáo:

$$\bar{m} = \frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F m_{rf}, \quad s_m = \sqrt{\frac{1}{RF} \sum_{r=1}^R \sum_{f=1}^F (m_{rf} - \bar{m})^2}.$$

Trong đó $\bar{m}$ là Macro-F1 trung bình và s_m là độ lệch chuẩn theo cách cài đặt `numpy.std` với mẫu số RF . Precision, Recall và F1 từng nhóm được tổng hợp tương tự. `total_support` bằng Rn_c , tức tổng số lần quan sát lớp c xuất hiện trong các tập kiểm định, không phải số khách hàng độc lập mới.

Từ xác suất $\hat{p}_{ic}$, code cho phép nhân hệ số ưu tiên $b_c \geq 1$ cho lớp hiếm:

$$\hat{y}_i = \arg \max_c (b_c \hat{p}_{ic}).$$

Trong đó $\hat{p}_{ic}$ là xác suất quan sát i thuộc lớp c ; b_c là hệ số boost, mặc định bằng 1; và $\hat{y}_i$ là nhãn sau hiệu chỉnh. Lưới thử $b_c \in \{1, 2, 3, 5, 8, 12, 20\}$ nhằm tối đa Macro-F1. Tuy nhiên, giao diện hiện tìm hệ số trên chính tập đang hiển thị kết quả, nên điểm sau boost là hậu nghiệm lạc quan và không được dùng làm kết quả kiểm định chính. Khi triển khai phải chọn b_c trên validation riêng, rồi khóa hệ số trước khi đánh giá test.

3.10 Phân tích số lượng và nhóm đặc trưng

Trong cấu hình báo cáo, mô hình XGBoost đầy đủ tạo thứ hạng importance riêng cho từng bộ dữ liệu. Với các đặc trưng được sắp $I_{(1)} \geq \dots \geq I_{(p)}$, tỷ lệ

importance tích lũy tại k là:

$$Q(k) = \frac{\sum_{j=1}^k I_{(j)}}{\sum_{j=1}^p I_{(j)}} \times 100\%.$$

Trong đó $I_{(j)}$ là importance của đặc trưng xếp hạng j ; $p = 13$ đối với pool đầy đủ của bộ A và $p = 98$ đối với bộ B; $Q(k)$ không phải tỷ lệ hiệu năng được giữ lại. Do đó, số biến đạt 95% importance chỉ là ứng viên, phải được huấn luyện lại và đánh giá ngoài mẫu. Code kiểm tra các mốc $k \in \{3, 5, 7, 9, 11, 13\}$ cho bộ A và $k \in \{5, 10, 15, 20, 30, 45, 60, 98\}$ cho bộ B.

Đóng góp nhóm g được code tính:

$$I_g = \sum_{j: g(j)=g} I_j, \quad S_g = \frac{I_g}{\sum_r I_r} \times 100\%,$$

trong đó $g(j)$ ánh xạ đặc trưng j sang nhóm nghiệp vụ; I_g là tổng importance và S_g là tỷ trọng của nhóm.

Điểm ưu tiên dữ liệu trong code là:

$$\text{Priority}_g = S_g \left(\frac{M_g}{100} + 0, 1 \right),$$

trong đó M_g là tỷ lệ thiếu trung bình của nhóm g và 0,1 là hệ số nền do tác giả quy ước. Đây là chỉ số heuristic để sắp xếp thảo luận, chưa phải hàm lợi ích kinh tế đã được hiệu chỉnh.

Ba giới hạn của mô-đun lựa chọn biến cần được giữ trong cách diễn giải. Thứ nhất, nhãn “bộ 11 biến đã chọn” và “bộ 16 biến rút gọn” trong màn hình so sánh hiện lấy Top-11 hoặc Top-16 theo importance, không lấy đúng danh sách cấu hình tương ứng; luận văn vì vậy tính riêng kết quả của bộ 11 biến thực và không sử dụng nhãn Top-16 như bằng chứng cho bộ 16 định trước. Thứ hai,

nhiều giá trị k được xem xét trên cùng tập kiểm định, nên lựa chọn k tốt nhất có thiên lệch lựa chọn; các đường cong này chỉ là phân tích khám phá. Thứ ba, tổng importance theo nhóm không thay thế thí nghiệm loại bỏ từng nhóm.

3.11 Tóm tắt chương

Chương 3 đã mô tả hai nhánh dữ liệu đúng theo code. Bộ A có 27.001 hồ sơ, 21 cột thô, 11 biến cấu hình chính và pool kiểm chứng 13 biến. Bộ B có 5.400 dòng, 178 cột thô, 5.381 quan sát có nhãn và 98 đặc trưng mô hình. Chương cũng làm rõ thực nghiệm hiện tại là phân loại năm nhóm nợ, chưa phải kiểm định dự báo chuyển nhóm theo thời gian. Các công thức, ký hiệu, chiến lược SMOTE, tham số mô hình, thước đo và giới hạn của mô-đun Top- k đã được giải thích để làm cơ sở đọc kết quả Chương 4.

Chương 4

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

4.1 Nguyên tắc báo cáo kết quả

Các con số trong chương này được tái chạy trực tiếp từ hai tệp `Data_credit_rating_VN.xlsx` và `fct_1.xlsx` bằng các hàm trong thư mục `src`. Cả hai nhánh dùng phép chia 80/20 có phân tầng và `random_state=42`. Kết quả của hai bộ được trình bày riêng vì khác nhau về biến đích, quy mô, phân bố lớp và không gian đặc trưng.

Với bộ A, bảng so sánh mô hình dùng đúng 11 biến cấu hình chính và chiến lược `smote_moderate`; phân tích số lượng biến dùng pool 13 biến của trang 7. Với bộ B, bảng so sánh mô hình dùng 98 đặc trưng và SMOTE tùy chỉnh; thí nghiệm Top- k huấn luyện lại bằng `smote_moderate`, đúng như code hiện tại. Mọi con số đều gắn với cấu hình cụ thể, không phải kết quả Grid Search.

Logistic Regression phát sinh lỗi tương thích API do tham số `multi_class` trong môi trường thư viện hiện tại. Vì vậy, hai bảng so sánh chỉ đưa năm mô hình chạy thành công.

4.2 Kết quả trên bộ dữ liệu A

4.2.1 So sánh mô hình trên bộ 11 đặc trưng

Bảng 4.1: Kết quả ngoài mẫu trên bộ dữ liệu A với 11 đặc trưng

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Decision Tree	0,8847	0,5896	0,8786	0,8765
Random Forest	0,9052	0,6179	0,8917	0,9182
XGBoost	0,9096	0,6442	0,8982	0,9201
LightGBM	0,9113	0,6484	0,9001	0,9181
CatBoost	0,7497	0,5454	0,8033	0,9006

LightGBM đạt Macro-F1 cao nhất, bằng 0,6484; XGBoost đứng sát sau với 0,6442 và có ROC-AUC macro cao nhất, bằng 0,9201. Trang 7 mặc định dùng XGBoost để phân tích đặc trưng, nên các kết quả tiếp theo của bộ A được tính từ XGBoost nhằm giữ đúng luồng code.

4.2.2 Hiệu năng theo số lượng đặc trưng

Bảng 4.2: Hiệu năng XGBoost theo Top- k đặc trưng của bộ dữ liệu A

k	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
3	0,9021	0,6152	0,8873	0,8874
5	0,9022	0,6184	0,8878	0,8887
7	0,9019	0,6212	0,8887	0,9014
9	0,9093	0,6383	0,8975	0,9203
11	0,9074	0,6364	0,8958	0,9223
13	0,9098	0,6434	0,8977	0,9192

Trong các tập Top- k xếp theo importance, pool đủ 13 biến có Macro-F1 cao nhất, nhưng đường cong không đơn điệu: Top-11 thấp hơn Top-9. Quan trọng hơn, khi huấn luyện đúng danh sách 11 biến cấu hình chính thay vì lấy 11

biến đứng đầu, XGBoost đạt Macro-F1 0,6442, nhỉnh hơn 0,6434 của pool 13 biến; Weighted-F1 tăng từ 0,8977 lên 0,8982 và ROC-AUC tăng từ 0,9192 lên 0,9201. Hai biến đưa lại là *SEX* và *LOAIKH* vì vậy không tạo cải thiện có ý nghĩa trong phép chia này.

Top-9 giữ:

$$\rho_{A,9} = \frac{0,6383}{0,6434} \approx 0,9920,$$

tức khoảng 99,20% Macro-F1 của pool 13 biến trong cùng quy trình Top- k . Đây là mốc nhỏ nhất trong các mốc đã thử đạt ít nhất 99%, không phải bằng chứng rằng chín là số biến tối thiểu tuyệt đối.

4.2.3 Nhóm đặc trưng và chỉ số ưu tiên dữ liệu

Bảng 4.3: Tỷ trọng importance theo nhóm nghiệp vụ của bộ dữ liệu A

Nhóm nghiệp vụ	Tỷ trọng (%)
Kỳ hạn khoản vay	40,1
Sản phẩm và mục đích vay	21,9
Dư nợ và hạn mức sử dụng	12,9
Đơn vị/Chi nhánh	9,4
Nhân khẩu học có IV thấp	8,1
Lãi suất	7,6

Hai biến *DAYS_TO_MATURITY* và *LOAN_TENURE_DAYS* lần lượt có importance 24,48% và 15,63%, làm nhóm Kỳ hạn khoản vay đứng đầu với 40,1%. Nhóm Sản phẩm và mục đích vay đứng thứ hai, đạt 21,9%.

Đường cong tích lũy cần 12/13 biến để đạt 95% importance và 13/13 biến để đạt 99%. Tuy nhiên, mốc này không mâu thuẫn với việc Top-9 giữ 99,20% Macro-F1, vì tổng importance và hiệu năng ngoài mẫu là hai đại lượng khác nhau.

Các nhóm của bộ A hầu như không có giá trị thiếu; chỉ nhóm Nhân khẩu học có IV thấp thiếu trung bình 2,05%. Vì vậy, chỉ số heuristic xếp Kỳ hạn khoản vay ở vị trí đầu chủ yếu do importance, không chứng minh ngân hàng cần thu thập thêm các trường kỳ hạn đang thiếu. Khuyến nghị phù hợp hơn là duy trì chất lượng các trường ngày và phát triển lịch sử theo thời gian.

4.3 Kết quả trên bộ dữ liệu B

4.3.1 Mức độ mất cân bằng và hệ quả đánh giá

Tập kiểm định gồm 1.077 quan sát, trong đó nhóm 1 có 1.050 quan sát, còn nhóm 3 và 4 chỉ có 2 và 3 quan sát. Một bộ phân loại luôn dự báo nhóm 1 đã có Accuracy:

$$\text{Accuracy}_{\text{majority}} = \frac{1.050}{1.077} = 0,9749.$$

Trong đó 1.050 là số mẫu nhóm 1 và 1.077 là tổng số mẫu kiểm định. Vì vậy, Accuracy khoảng 97–98% chưa đủ để chứng minh mô hình nhận diện được rủi ro. Kết quả cần được đọc cùng Macro-F1 và Recall từng nhóm, phù hợp cảnh báo của Brown và Mues về đánh giá dữ liệu tín dụng mất cân bằng [7].

4.3.2 So sánh các mô hình

Bảng 4.4: Kết quả ngoài mẫu của các mô hình trên 98 đặc trưng

Mô hình	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
Decision Tree	0,9666	0,3213	0,9669	0,6985
Random Forest	0,9740	0,2595	0,9696	0,9600
XGBoost	0,9814	0,4118	0,9770	0,9781
LightGBM	0,9805	0,3783	0,9753	0,9792
CatBoost	0,9387	0,3334	0,9537	0,9461

XGBoost có Macro-F1 cao nhất (0,4118), trong khi LightGBM có ROC-AUC macro cao hơn nhẹ (0,9792 so với 0,9781). Hai chỉ tiêu trả lời hai câu hỏi khác nhau: Macro-F1 đánh giá chất lượng nhãn cứng sau khi chọn lớp; ROC-AUC đánh giá khả năng xếp hạng xác suất theo từng lớp qua nhiều ngưỡng [12]. Vì mục tiêu nghiệp vụ quan tâm đồng đều hơn tới lớp thiểu số, XGBoost được chọn làm mô hình phân tích đặc trưng. Kết quả ensemble cạnh tranh hơn cây đơn phù hợp với các nghiên cứu đối sánh trước, nhưng không chứng minh ensemble luôn tốt hơn trong mọi dữ liệu [16].

4.3.3 Kết quả chi tiết theo nhóm nợ

Bảng 4.5: Precision, Recall và F1 của XGBoost theo nhóm nợ

Nhóm	Số mẫu kiểm định	Precision	Recall	F1
1	1.050	0,9859	0,9990	0,9924
2	17	0,6250	0,2941	0,4000
3	2	0,0000	0,0000	0,0000
4	3	0,0000	0,0000	0,0000
5	5	0,7500	0,6000	0,6667

Bảng 4.5 giải thích vì sao Accuracy và Weighted-F1 cao nhưng Macro-F1 thấp. Mô hình dự báo gần như hoàn hảo nhóm 1, nhận diện 5 trong 17 hồ sơ nhóm 2 và 3 trong 5 hồ sơ nhóm 5, nhưng không nhận diện đúng quan sát nào của nhóm 3 và 4. Với cỡ mẫu rất nhỏ, chưa thể kết luận mô hình “không có khả năng” đối với hai nhóm này; kết luận đúng là dữ liệu kiểm định không đủ để ước lượng năng lực một cách ổn định.

So sánh Recall cho thấy:

- Decision Tree: nhóm 2 đạt 0,4118, nhóm 5 đạt 0,2000;

- Random Forest: nhóm 2 đạt 0,2353, nhóm 5 đạt 0;
- XGBoost: nhóm 2 đạt 0,2941, nhóm 5 đạt 0,6000;
- LightGBM: nhóm 2 đạt 0,2941, nhóm 5 đạt 0,4000;
- CatBoost: nhóm 2 đạt 0,5882, nhóm 5 đạt 0,8000, nhưng Accuracy và Weighted-F1 thấp hơn do phát sinh nhiều cảnh báo sai hơn.

CatBoost minh họa rõ đánh đổi giữa phát hiện lớp thiểu số và số cảnh báo sai. Do đó, lựa chọn mô hình triển khai không nên chỉ dựa vào một thứ hạng chung; ngân hàng cần xác định chi phí bỏ sót và chi phí rà soát.

4.3.4 Đánh giá lớp hiếm trong code mới

Hàm `repeated_stratified_recall()` báo cáo trung bình và độ lệch chuẩn Precision, Recall, F1 theo lớp qua nhiều fold. Với cấu hình mặc định 3×5 -fold, mỗi hồ sơ nhóm 3 và 4 được kiểm định ba lần qua các lượt lặp, thay vì kết luận từ đúng 2 và 3 hồ sơ của một holdout. Cách này làm ước lượng ổn định hơn nhưng không giải quyết thiếu dữ liệu gốc: tổng support tăng do cùng hồ sơ được đánh giá lặp lại, không phải do có thêm khách hàng độc lập.

Phiên bản mới cũng sửa đường truyền trọng số cho XGBoost: khi chọn `class_weight`, trọng số nghịch đảo tần suất được truyền vào từng lần `fit()`, kể cả trong từng fold. Vì Bảng 4.4 được tạo bằng SMOTE tùy chỉnh, thay đổi này không làm đổi trực tiếp các số đã báo cáo; nó làm cho nhánh cost-sensitive có hiệu lực đúng như lựa chọn trên giao diện.

Chức năng “Tìm boost tối ưu” nhân xác suất các lớp hiếm trước phép `argmax`. Đây là công cụ phân tích độ nhạy để đổi Precision lấy Recall, không phải mô hình mới. Do hệ số hiện được tìm trên chính tập đánh giá, Macro-F1 sau boost

không được đưa vào bảng kết quả chính. Muốn sử dụng hợp lệ, cần tách train–validation–test, chọn hệ số trên validation và chỉ đánh giá một lần trên test.

4.3.5 Hiệu năng theo số lượng đặc trưng

Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Các đặc trưng được xếp theo importance của XGBoost đầy đủ, sau đó code huấn luyện lại tại các mốc k . Kết quả được trình bày trong Bảng 4.6.

Bảng 4.6: Hiệu năng XGBoost theo số lượng đặc trưng Top- k

k	Accuracy	Macro-F1	Weighted-F1	ROC-AUC macro
5	0,9313	0,2746	0,9476	0,5586
10	0,8895	0,2573	0,9242	0,7330
15	0,9415	0,3270	0,9544	0,8823
20	0,9610	0,3661	0,9672	0,8967
30	0,9619	0,3694	0,9672	0,9013
45	0,9740	0,3810	0,9748	0,9644
60	0,9786	0,3923	0,9759	0,9690
98	0,9814	0,4110	0,9787	0,9699

Trong các mốc đã thử, Macro-F1 đạt cao nhất với 98 đặc trưng. Vì vậy, dữ liệu này không ủng hộ kết luận rằng thêm biến làm giảm hiệu năng sau một điểm rõ ràng. Tuy nhiên, đường cong không đơn điệu ở vùng nhỏ (Top-10 thấp hơn Top-5), nên phát biểu đúng là: *nhiều đặc trưng hơn không luôn bảo đảm tốt hơn về mặt lý thuyết; trong thực nghiệm hiện tại, tập đầy đủ cho kết quả tốt nhất trong các mốc đã kiểm tra.*

Phân tích này còn có một hạn chế: mô hình đầy đủ dùng SMOTE tùy chỉnh, trong khi hàm Top- k của trang 7 dùng smote_moderate. Chênh lệch nhỏ giữa kết quả đầy đủ 0,4118 và kết quả $k = 98$ bằng 0,4110 phản ánh sự khác nhau của pipeline. Trước khi dùng kết quả để quyết định sản xuất, cần thống nhất

chiến lược lấy mẫu.

Ngoài ra, các mốc k được xem và lựa chọn trên cùng tập kiểm định 1.077 hồ sơ. Vì vậy, đường cong có vai trò khám phá; một cấu hình rút gọn được chọn từ đường cong phải được khóa trước và đánh giá lại bằng validation lồng nhau hoặc trên kỳ dữ liệu mới.

Có thể giảm còn bao nhiêu đặc trưng?

Theo tổng importance, 62 đặc trưng đầu tiên chiếm 95% và 72 đặc trưng chiếm 99% importance. Tuy nhiên, importance tích lũy không đồng nghĩa với hiệu năng được duy trì. Tại $k = 60$, tỷ lệ Macro-F1 so với $k = 98$ là:

$$\rho_{60} = \frac{0,3923}{0,4110} \approx 0,9545.$$

Trong đó 0,3923 là Macro-F1 của Top-60 và 0,4110 là Macro-F1 của tập 98 biến trong cùng quy trình Top- k . Như vậy Top-60 giữ khoảng 95,45% Macro-F1.

Nếu tiêu chí “gần như toàn bộ” được đặt ở mức 99% Macro-F1, chưa có cấu hình rút gọn nào trong các mốc đã thử đạt yêu cầu; kết luận thận trọng là **chưa thể giảm tiếp dưới 98 đặc trưng theo ngưỡng 99%**. Nếu ngân hàng chấp nhận giữ khoảng 95% Macro-F1 để đổi lấy mô hình gọn hơn, Top-60 là ứng viên, giảm:

$$\frac{98 - 60}{98} \times 100\% \approx 38,78\%$$

số biến mô hình. Cấu hình này phải được kiểm định lặp hoặc kiểm định theo thời gian trước khi khuyến nghị triển khai.

Ở cấp dữ liệu thô, quy trình đã giảm từ 178 cột xuống 98 đặc trưng hợp lệ,

tương đương loại:

$$\frac{178 - 98}{178} \times 100\% \approx 44,94\%.$$

Mức giảm này chủ yếu đến từ kiểm soát ID, leakage, ngày thô và biến hằng số, không phải lựa chọn dựa trên hiệu năng.

4.3.6 Đóng góp của các nhóm đặc trưng

Bảng 4.7: Tỷ trọng importance của XGBoost theo nhóm nghiệp vụ

Nhóm nghiệp vụ	Tỷ trọng (%)
Dư nợ và giải ngân	46,4
Lãi suất	15,0
Sản phẩm, mục đích và kênh phân phối	9,7
Trả nợ và thu hồi	7,9
Đặc trưng kỹ thuật	6,8
Kỳ hạn và gia hạn	6,1
Khách hàng và đối tác	4,2
Thay đổi và trạng thái hợp đồng	3,6
Bối cảnh và nguồn dữ liệu	0,2

Nhóm Dư nợ và giải ngân đóng góp lớn nhất, chiếm 46,4% tổng importance. Các biến đứng đầu gồm *DISBURSEMENT_AMT_YTD*, *AGG_PD_BAL_YTD*, *AGG_BAL_YTD*, *AGG_PD_BAL_YTD_LCY* và *ACC_PD_BAL_RATE*. Biến đơn lẻ đứng đầu là *BASIC_RATE_CODE* thuộc nhóm Lãi suất, với importance khoảng 9,62%.

Kết quả này trả lời câu hỏi “mô hình sử dụng nhóm nào nhiều nhất”, nhưng chưa trả lời hoàn toàn “nhóm nào tạo giá trị biên lớn nhất”. Importance có thể bị chia sẻ giữa các biến tương quan. Để kết luận mạnh hơn cần thí nghiệm loại bỏ từng nhóm và đo chênh lệch Macro-F1 ngoài mẫu; phiên bản code hiện tại mới tổng hợp importance, chưa thực hiện group ablation.

4.3.7 Ưu tiên đầu tư dữ liệu

Tỷ lệ thiếu trung bình của hai nhóm đứng đầu là 49,38% đối với Dư nợ và giải ngân và 54,65% đối với Lãi suất. Theo chỉ số heuristic được cài đặt, ba ưu tiên đầu là:

1. Dư nợ và giải ngân: 46,4% importance, 49,38% thiếu, điểm ưu tiên 27,55;
2. Lãi suất: 15,0% importance, 54,65% thiếu, điểm ưu tiên 9,70;
3. Sản phẩm, mục đích và kênh phân phối: 9,7% importance, 49,88% thiếu, điểm ưu tiên 5,81.

Vì điểm ưu tiên là tích của importance với một hàm quy ước của tỷ lệ thiếu, kết quả không nên được diễn giải thành lợi tức đầu tư định lượng. Khuyến nghị phù hợp là ưu tiên kiểm kê nguồn, chuẩn hóa định nghĩa và cải thiện độ đầy đủ của nhóm Dư nợ và giải ngân trước; sau đó chạy lại group ablation để xác nhận giá trị biên.

4.3.8 Giải thích mô hình và giới hạn của importance

Mã nguồn hỗ trợ SHAP, dựa trên giá trị Shapley [17]. Với mô hình cộng tính giải thích:

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j,$$

trong đó $f(\mathbf{x})$ là đầu ra của mô hình tại hồ sơ $\mathbf{x}$ trên thang mà explainer sử dụng; ϕ_0 là giá trị nền; và ϕ_j là phần đóng góp của đặc trưng j . Giá trị $\phi_j > 0$ làm đầu ra của lớp đang xét tăng so với nền, còn $\phi_j < 0$ làm giảm.

SHAP giải thích dự báo của mô hình, không chứng minh rằng thay đổi biến sẽ gây ra thay đổi rủi ro. Đặc biệt, các biến số dư và giải ngân có tương quan có

thể chia sẻ importance. Vì vậy, kết luận nghiệp vụ cần kết hợp SHAP, phân tích ổn định và hiểu biết chuyên gia.

4.4 Đối chiếu bốn câu hỏi nghiên cứu

Thứ nhất, nhiều đặc trưng hơn có luôn tốt hơn không? Bằng chứng phụ thuộc bộ dữ liệu. Trên bộ A, 11 biến cấu hình chính cho Macro-F1 0,6442, nhỉnh hơn 0,6434 khi thêm *SEX* và *LOAIKH*; Top-11 cũng thấp hơn Top-9. Trên bộ B, 98 biến cho kết quả cao nhất trong các mốc Top-*k* đã thử. Vì vậy, không thể suy ra quy tắc “càng nhiều biến càng tốt”; biến mới chỉ có giá trị khi tạo thêm tín hiệu ngoài mẫu.

Thứ hai, nhóm nào đóng góp lớn nhất? Kết quả không đồng nhất mấy mốc giữa hai bộ. Kỳ hạn khoản vay đứng đầu bộ A với 40,1%, còn Dư nợ và giải ngân đứng đầu bộ B với 46,4%. Điểm chung là tín hiệu mạnh nằm ở cấu trúc khoản vay, thời hạn và diễn biến mức độ phơi nhiễm, thay vì chỉ ở thông tin nhân khẩu học.

Thứ ba, có thể giảm còn bao nhiêu biến? Đối với bộ A, Top-9 là mốc nhỏ nhất đã thử giữ ít nhất 99% Macro-F1 của pool 13 biến; bộ 11 biến cấu hình thực còn nhỉnh hơn pool 13 biến. Đối với câu hỏi xuất phát từ 178 cột của bộ B, quy trình bắt buộc trước hết giảm còn 98 đặc trưng hợp lệ. Nếu yêu cầu giữ ít nhất 99% Macro-F1, chưa có bằng chứng giảm dưới 98; nếu chấp nhận khoảng 95%, Top-60 là ứng viên và giữ khoảng 95,45% Macro-F1 trong cùng pipeline Top-*k*.

Thứ tư, nên ưu tiên mở rộng dữ liệu nào? Ở bộ B, chỉ số code ưu tiên Dư nợ và giải ngân, sau đó là Lãi suất và Sản phẩm–mục đích–kênh phân phối; cả ba

nhóm vừa quan trọng vừa thiếu nhiều. Ở bộ A, các trường hiện gần như đầy đủ, nên thứ hạng Kỳ hạn chủ yếu gợi ý duy trì chất lượng và thu thập lịch sử biến động theo kỳ, không phải bổ sung thêm cột tính cùng loại. Ưu tiên xuyên suốt là dữ liệu snapshot theo thời gian, diễn biến dư nợ/giải ngân, lịch trả nợ và các mốc đáo hạn để có thể tạo nhãn chuyển nhóm đúng nghĩa.

4.5 Ý nghĩa đối với mô hình chuyển nhóm nợ

Kết quả hiện tại chứng minh pipeline có thể phân loại nhóm 1 và một phần nhóm 2, 5, nhưng chưa chứng minh cảnh báo chuyển nhóm. Để chuyển sang mục tiêu đề tài, cần:

1. tạo ảnh chụp dữ liệu ở nhiều thời điểm;
2. xác định ngày quan sát và cửa sổ dự báo;
3. loại mọi biến phát sinh sau ngày quan sát;
4. chia huấn luyện–kiểm định theo thời gian;
5. đánh giá Recall/PR-AUC của sự kiện chuyển nhóm và hiệu chỉnh xác suất;
6. kiểm định hiệu quả cảnh báo bằng chi phí bỏ sót và năng lực rà soát.

4.6 Tóm tắt chương

Trên bộ A, LightGBM đạt Macro-F1 0,6484 với 11 biến cấu hình; XGBoost đạt 0,6442. Khi phân tích XGBoost trên pool 13 biến, Top-9 giữ khoảng 99,20% Macro-F1 và nhóm Kỳ hạn khoản vay chiếm 40,1% importance. Trên bộ B, XGBoost đạt Macro-F1 0,4118 với 98 biến và SMOTE tùy chỉnh, nhưng không

nhận diện đúng nhóm 3 và 4 trong tập kiểm định rất nhỏ. Trong pipeline Top- k , Top-60 giữ khoảng 95,45% Macro-F1; nhóm Dư nợ và giải ngân chiếm 46,4% importance và đứng đầu chỉ số ưu tiên dữ liệu. Hai thực nghiệm cho thấy giá trị của việc thêm biến phụ thuộc vào bối cảnh dữ liệu. Các kết luận Top- k , importance nhóm và class-boost vẫn cần được xác nhận trên validation hoặc dữ liệu ngoài thời gian trước khi triển khai.

Chương 5

KẾT LUẬN VÀ KIẾN NGHỊ

5.1 Kết luận chung

Luận văn giữ nguyên định hướng của đề tài “*Ứng dụng trí tuệ nhân tạo trong xếp hạng tín dụng: nghiên cứu từ một ngân hàng thương mại ở Việt Nam*”. Trên hai bộ dữ liệu gốc và code hiện có, nghiên cứu đã xây dựng được pipeline phân loại năm nhóm nợ, kiểm soát một số nguồn rò rỉ, xử lý mất cân bằng, so sánh các mô hình cây và phân tích vai trò của đặc trưng. Khả năng chuyển nhóm nợ được xác định là hướng phát triển nhằm hỗ trợ phân loại nợ và cảnh báo sớm rủi ro tín dụng; kết quả hiện tại là nền tảng cho hướng này, chưa phải kiểm định hoàn chỉnh theo thời gian.

Bộ dữ liệu A có 27.001 hồ sơ và 21 cột thô. Trang huấn luyện chính sử dụng 11 biến cấu hình, còn mô-đun phân tích đặc trưng dùng pool 13 biến gồm tám biến số và năm biến phân loại. Phép chia phân tầng tạo 21.600 mẫu huấn luyện và 5.401 mẫu kiểm định. Trên 11 biến, LightGBM đạt Macro-F1 cao nhất là 0,6484; XGBoost đạt 0,6442 và ROC-AUC macro 0,9201.

Bộ dữ liệu B có 5.400 dòng và 178 cột thô. Sau khi loại 19 dòng thiếu nhãn và các trường không phù hợp, mô hình sử dụng 5.381 quan sát với 98 đặc trưng,

gồm 63 biến số thô, 26 biến phân loại và 9 biến tạo thêm. Phép chia phân tầng tạo 4.304 mẫu huấn luyện và 1.077 mẫu kiểm định.

Trên bộ B, trong năm mô hình chạy lại thành công, XGBoost đạt Macro-F1 cao nhất là 0,4118, Accuracy 0,9814 và ROC-AUC macro 0,9781. Tuy nhiên, mô hình không nhận diện đúng nhóm 3 và 4 trong tập kiểm định; hai lớp này chỉ có 2 và 3 quan sát. Do đó, kết quả không cho phép khẳng định mô hình đã giải quyết tốt các lớp rủi ro hiếm. Việc báo cáo Macro-F1 và Recall theo lớp giúp tránh kết luận sai từ Accuracy vốn bị chi phối bởi 97,51% quan sát nhóm 1 ở bộ B.

5.2 Trả lời các câu hỏi nghiên cứu

5.2.1 Nhiều đặc trưng hơn có luôn giúp mô hình tốt hơn không?

Về lý thuyết, thêm đặc trưng không bảo đảm cải thiện ngoài mẫu vì biến mới có thể trùng lặp hoặc gây nhiễu. Bằng chứng trên hai bộ dữ liệu cũng cho kết quả phụ thuộc bối cảnh. Ở bộ A, XGBoost với đúng 11 biến cấu hình đạt Macro-F1 0,6442, nhỉnh hơn 0,6434 của pool 13 biến sau khi đưa lại *SEX* và *LOAIKH*; trong đường cong Top-*k*, Top-11 còn thấp hơn Top-9. Ở bộ B, tập 98 biến cho Macro-F1 cao nhất trong các mốc đã thử. Vì vậy, kết luận phù hợp là: thêm biến chỉ hữu ích khi biến đó cung cấp tín hiệu ngoài mẫu mới; số lượng biến tự thân không bảo đảm mô hình tốt hơn.

5.2.2 Nhóm đặc trưng nào đóng góp lớn nhất?

Theo feature importance của XGBoost, nhóm Kỳ hạn khoản vay đứng đầu bộ A với 40,1%; nhóm Sản phẩm và mục đích vay đứng thứ hai với 21,9%. Ở bộ B,

nhóm Dư nợ và giải ngân đứng đầu với 46,4%, cao hơn nhóm Lãi suất (15,0%) và nhóm Sản phẩm, mục đích và kênh phân phối (9,7%). Kết quả cho thấy nhóm nổi trội phụ thuộc không gian dữ liệu, nhưng các tín hiệu về thời hạn và mức độ phơi nhiễm tín dụng đều quan trọng. Đây là mức sử dụng của mô hình, chưa phải tác động nhân quả hoặc giá trị biên; cần group ablation để xác nhận.

5.2.3 Có thể giảm từ 178 xuống bao nhiêu đặc trưng?

Đối với bộ A, quy trình giảm 21 cột thô xuống pool 13 biến khả dụng. Top-9 là mốc nhỏ nhất đã thử giữ khoảng 99,20% Macro-F1 của pool 13 biến; đồng thời bộ 11 biến cấu hình thực đạt kết quả nhỉnh hơn pool đầy đủ.

Đối với câu hỏi đặt ra từ 178 cột của bộ B, quy tắc nghiệp vụ và chống rò rỉ trước hết giảm xuống 98 đặc trưng, tức giảm khoảng 44,94%. Trong vòng chọn đặc trưng, Top-60 giữ khoảng 95,45% Macro-F1 của tập 98 biến trong cùng quy trình, nhưng chưa đạt ngưỡng 99%. Vì vậy:

- nếu yêu cầu giữ ít nhất 99% Macro-F1, chưa có bằng chứng để giảm dưới 98 đặc trưng;
- nếu chấp nhận giữ khoảng 95% Macro-F1, Top-60 là cấu hình ứng viên, giảm thêm khoảng 38,78% số biến mô hình.

Không nên dùng mốc 62 biến đạt 95% tổng importance như bằng chứng rằng 95% hiệu năng được giữ lại, vì importance tích lũy và hiệu năng là hai đại lượng khác nhau. Các mốc trên cũng mới là mốc nhỏ nhất trong lưới đã thử, chưa phải nghiệm tối ưu tuyệt đối.

5.2.4 Ngân hàng nên ưu tiên thu thập nhóm thông tin nào?

Ở bộ B, chỉ số ưu tiên trong code xếp Dư nợ và giải ngân trước, sau đó đến Lãi suất và Sản phẩm–mục đích–kênh phân phối. Nhóm Dư nợ và giải ngân vừa có importance cao nhất (46,4%) vừa có tỷ lệ thiếu trung bình 49,38%. Ở bộ A, Kỳ hạn khoản vay đứng đầu theo heuristic, nhưng các trường của nhóm này không thiếu; thứ hạng do đó chủ yếu phản ánh importance, không phải khoảng trống chất lượng dữ liệu.

Ngân hàng nên ưu tiên lưu snapshot theo thời gian, chuẩn hóa ngày giải ngân/đáo hạn, tăng độ đầy đủ và tần suất cập nhật dữ liệu dư nợ–giải ngân, sau đó chuẩn hóa lãi suất, sản phẩm, mục đích và kênh. Trước khi đầu tư quy mô lớn, cần chạy thí nghiệm loại bỏ/bổ sung từng nhóm và lượng hóa lợi ích theo chi phí nghiệp vụ.

5.3 Đóng góp của nghiên cứu

5.3.1 Đóng góp phương pháp

Nghiên cứu xây dựng hai pipeline độc lập nhưng cùng nguyên tắc, gồm lựa chọn cột theo taxonomy nghiệp vụ, tạo đặc trưng, điền khuyết, chuẩn hóa, mã hóa, xử lý mất cân bằng và huấn luyện mô hình. Việc loại *NHOMNO* khỏi bộ A và loại các trường nhóm nợ/ngày quá hạn trực tiếp khỏi bộ B thể hiện chủ đích hạn chế mô hình học lại quy tắc tạo nhãn.

Nghiên cứu cũng tách ba khái niệm thường bị đồng nhất: số cột thô, số đặc trưng hợp lệ và số đặc trưng rút gọn theo hiệu năng. Sự phân biệt này giúp câu hỏi “178 biến có cần thiết không” được trả lời chặt chẽ hơn. Việc chạy cùng bốn câu hỏi trên hai cấu trúc dữ liệu còn cho thấy kết luận về số lượng và nhóm đặc

trung không nên được khái quát từ một bộ dữ liệu duy nhất.

5.3.2 Đóng góp thực tiễn

Kết quả cung cấp:

- kết quả đối sánh năm mô hình chạy thành công trên từng bộ dữ liệu;
- bảng hiệu năng theo lớp, cho thấy rõ điểm yếu ở lớp hiếm của bộ B;
- hai đường cong hiệu năng theo số lượng đặc trưng;
- xếp hạng nhóm thông tin nghiệp vụ riêng cho từng bộ;
- khuyến nghị duy trì dữ liệu kỳ hạn, đồng thời ưu tiên cải thiện dữ liệu Dư nợ và giải ngân.

Những kết quả này có thể hỗ trợ thiết kế thí nghiệm cảnh báo sớm tiếp theo, nhưng chưa nên tích hợp tự động vào quyết định tín dụng.

5.4 Hạn chế của nghiên cứu

5.4.1 Chưa có nhãn chuyển nhóm theo thời gian

Hạn chế lớn nhất là chưa có chuỗi snapshot kèm ngày quan sát và cửa sổ dự báo thống nhất. Bộ A có *NHOMNO* và *NHOMNOMOI*, nhưng chưa xác lập rõ chân trời h cho từng hồ sơ; bộ B chỉ có *CLASSIFICATION* ở bản ghi đang xét. Vì vậy, luận văn chưa ước lượng trực tiếp xác suất chuyển nhóm ngoài thời gian.

5.4.2 Mất cân bằng cực đoan và cỡ mẫu lớp hiếm

Trong bộ B, nhóm 3 và 4 có tổng cộng 11 và 13 hồ sơ. Tập kiểm định chỉ có 2 và 3 hồ sơ, không đủ để ước lượng Recall ổn định. SMOTE tạo điểm tổng hợp nhưng không thay thế thông tin thật và không thể khắc phục hoàn toàn thiếu hụt mẫu gốc [8, 7]. Bộ A có nhiều mẫu lớp hiếm hơn, nhưng nhóm 1 vẫn chiếm 77,65%.

5.4.3 Thiết kế kiểm định

Code vẫn dùng một phép chia ngẫu nhiên phân tầng cho các bảng chính, nên kết quả có thể phụ thuộc seed và chưa phản ánh data drift. Phiên bản mới có RepeatedStratifiedKFold, mặc định ba lần lặp của 5-fold, và tổng hợp Precision, Recall, F1 theo từng nhóm. Chức năng này giảm độ nhạy với một holdout đơn nhưng không thay thế kiểm định ngoài thời gian.

Các mốc Top- k được xem xét trên cùng tập kiểm định rồi mới rút ra mốc tốt, gây thiên lệch lựa chọn. Do đó, Top-9 và Top-60 chỉ là ứng viên khám phá; cần chọn k trên validation hoặc nested cross-validation và đánh giá lại một lần trên test độc lập.

5.4.4 Sự không thống nhất trong pipeline

Mô hình đầy đủ của bộ B sử dụng SMOTE tùy chỉnh, còn trang Top- k dùng chiến lược SMOTE ở mức vừa. CatBoost dùng trọng số lớp thay cho SMOTE. Vì vậy, một phần chênh lệch có thể đến từ chiến lược mất cân bằng chứ không chỉ số lượng biến.

Ngoài ra, màn hình hiện gắn nhãn “bộ 11 biến” và “bộ 16 biến” nhưng thực

tế truyền Top-11 và Top-16 theo importance, không phải đúng hai danh sách cấu hình. Luận văn đã tránh dùng nhầm hai kết quả này, nhưng code cần được sửa để giao diện phản ánh đúng tập cột.

5.4.5 Mã hóa biến phân loại

Label Encoding có thể tạo thứ tự số giả cho các danh mục. SMOTE sau mã hóa còn có thể nội suy ra giá trị không tương ứng danh mục hợp lệ. Cần so sánh One-Hot Encoding, encoding theo xác suất hoặc mô hình xử lý danh mục nguyên bản.

5.4.6 Khả năng tái lập của biến thời gian

Nhánh bộ A dùng ngày tham chiếu cố định 31/12/2021, nhưng hàm tạo đặc trưng FCT_L dùng ngày chạy hiện tại làm mốc. Điều này làm giá trị biến thời gian của bộ B thay đổi theo ngày thực thi. Cần dùng ngày chốt dữ liệu cố định hoặc ngày quan sát của từng hồ sơ.

5.4.7 Tối ưu và hiệu chỉnh mô hình

Siêu tham số hiện được cấu hình cố định, chưa có nested cross-validation. Xác suất đầu ra chưa được đánh giá calibration. Logistic Regression chưa chạy lại được do tương thích phiên bản thư viện. Code mới cho phép boost xác suất lớp hiếm để dịch ranh giới quyết định, nhưng đang tìm hệ số trên chính tập huấn luyện kết quả; vì vậy chỉ được xem là phân tích hậu nghiệm và có nguy cơ lạc quan. Cần chọn hệ số trên validation riêng, khóa cấu hình rồi mới đánh giá test. Vì vậy, bảng so sánh chưa phải benchmark cuối cùng như các nghiên cứu quy mô

lớn [16].

5.4.8 Importance chưa phải bằng chứng nhân quả

Feature importance và SHAP giải thích hành vi của mô hình, không chứng minh quan hệ nhân quả [17]. Các biến tương quan có thể chia sẻ hoặc thay thế importance; chỉ số ưu tiên dữ liệu hiện là heuristic chưa gắn với chi phí kinh tế.

5.5 Kiến nghị đối với ngân hàng

5.5.1 Xây dựng dữ liệu ảnh chụp theo thời gian

Ngân hàng cần lưu snapshot khoản vay ở các kỳ cố định, với khóa khoản vay/khách hàng nhất quán. Mỗi dòng phải có ngày quan sát, nhóm nợ tại ngày quan sát và nhóm nợ tại các cửa sổ 1, 3, 6 hoặc 12 tháng. Đây là điều kiện tiên quyết để chuyển từ phân loại hiện trạng sang dự báo chuyển nhóm.

5.5.2 Ưu tiên chất lượng trước khi mở rộng số lượng biến

Thay vì bổ sung nhiều trường rời rạc, ngân hàng nên:

1. chuẩn hóa ngày giải ngân, ngày đáo hạn và lịch sử thay đổi kỳ hạn;
2. chuẩn hóa định nghĩa và tần suất cập nhật nhóm Dư nợ và giải ngân;
3. giảm tỷ lệ thiếu của biến lãi suất;
4. thống nhất danh mục sản phẩm, mục đích và kênh;
5. lập data lineage để biết biến tồn tại từ thời điểm nào;
6. giám sát drift và tỷ lệ thiếu theo kỳ.

5.5.3 Thiết kế cảnh báo theo chi phí

Ngưỡng cảnh báo phải dựa trên năng lực xử lý và chi phí sai lầm. Có thể tối ưu:

$$\mathcal{C}(\tau) = c_{FN}FN(\tau) + c_{FP}FP(\tau),$$

trong đó τ là ngưỡng cảnh báo; $FN(\tau)$ là số khoản vay chuyển nhóm nhưng bị bỏ sót; $FP(\tau)$ là số cảnh báo sai; c_{FN} là chi phí trung bình của bỏ sót; và c_{FP} là chi phí rà soát/cơ hội của cảnh báo sai. Ngưỡng tối ưu là giá trị làm $\mathcal{C}(\tau)$ nhỏ nhất dưới các ràng buộc nghiệp vụ.

5.5.4 Quản trị mô hình

Mô hình cần được triển khai theo chế độ hỗ trợ quyết định, có human-in-the-loop. Ngân hàng cần lưu phiên bản dữ liệu, code, mô hình, lý do cảnh báo và phản hồi xử lý; theo dõi Macro-F1, Recall lớp rủi ro, calibration và drift; đồng thời thiết lập lịch tái huấn luyện.

5.6 Hướng nghiên cứu tiếp theo

Hướng ưu tiên không phải là thêm ngay mô hình học sâu, mà là hoàn thiện nhãn chuyển nhóm và thiết kế kiểm định. Các bước tiếp theo gồm:

1. xây nhãn $Y_{i,t}^{(h)}$ cho nhiều cửa sổ dự báo;
2. chia dữ liệu theo thời gian và theo khách hàng;
3. chuẩn hóa cùng một pipeline mất cân bằng cho mọi cấu hình;
4. chạy repeated cross-validation hoặc backtesting nhiều kỳ;

5. thực hiện group ablation và permutation importance trên tập kiểm định;
6. đánh giá PR-AUC, calibration, expected cost và độ ổn định;
7. thử nghiệm mô hình ordinal, survival hoặc multi-state vì năm nhóm nợ có thứ tự.

Mô hình đa trạng thái có thể mô tả xác suất:

$$p_{ab}^{(h)} = P(G_{i,t+h} = b \mid G_{i,t} = a, \mathbf{X}_{i,t}),$$

trong đó a là nhóm nợ tại thời điểm quan sát; b là nhóm đích sau h kỳ; $\mathbf{X}_{i,t}$ là véc-tơ thông tin sẵn có tại t ; và $p_{ab}^{(h)}$ là xác suất chuyển từ a sang b . Cách tiếp cận này phù hợp hơn phân loại độc lập nếu mục tiêu cuối cùng là ma trận chuyển nhóm.

5.7 Kết luận chương

Nghiên cứu đã tạo được hai pipeline và bằng chứng thực nghiệm cho bài toán phân loại năm nhóm nợ. Trên bộ A, LightGBM đạt Macro-F1 cao nhất với 11 biến; XGBoost cho thấy 11 biến cấu hình nhỉnh hơn pool 13 biến, và nhóm Kỳ hạn khoản vay có importance lớn nhất. Trên bộ B, XGBoost đạt Macro-F1 cao nhất; nhóm Dư nợ và giải ngân đứng đầu; Top-60 là ứng viên nếu chấp nhận giữ khoảng 95% hiệu năng, còn chưa có bằng chứng giảm dưới 98 biến nếu yêu cầu 99%. Hạn chế về dữ liệu theo thời gian, cỡ mẫu lớp hiếm, lựa chọn k trên cùng holdout và sự khác nhau của pipeline khiến kết quả chưa thể được diễn giải là mô hình cảnh báo chuyển nhóm hoàn chỉnh.

Tài liệu tham khảo

- [1] Edward I. Altman. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609, 1968.
- [2] Bart Baesens, Tony Van Gestel, Stijn Viaene, Maria Stepanova, Johan Suykens, and Jan Vanthienen. Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, 54(6):627–635, 2003.
- [3] Flavio Barboza, Herbert Kimura, and Edward I. Altman. Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83:405–417, 2017.
- [4] Basel Committee on Banking Supervision. Basel Framework: IRB Approach – Risk Components. https://www.bis.org/basel_framework/chapter/CRE/32.htm, 2024. Truy cập ngày 26/07/2026.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [6] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [7] Ian Brown and Christophe Mues. An experimental comparison of

- classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3):3446–3453, 2012.
- [8] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [9] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [10] Jonathan N. Crook, David B. Edelman, and Lyn C. Thomas. Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3):1447–1465, 2007.
- [11] Xolani Dastile, Tugrul Celik, and Moeketsi Potsane. Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing*, 91:106263, 2020.
- [12] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [13] David J. Hand and William E. Henley. Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A*, 160(3):523–541, 1997.
- [14] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.

- [15] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3149–3157, 2017.
- [16] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.
- [17] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774, 2017.
- [18] Microsoft Corporation. LightGBM Documentation: Leaf-wise (Best-first) Tree Growth. <https://lightgbm.readthedocs.io/en/latest/Features.html>, 2026. Truy cập ngày 26/07/2026.
- [19] James A. Ohlson. Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131, 1980.
- [20] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.
- [21] Lyn C. Thomas. A survey of credit and behavioural scoring: Forecasting financial risk of lending to consumers. *International Journal of Forecasting*, 16(2):149–172, 2000.

- [22] Yufei Xia, Chuanzhi Liu, Bin Da, and Faming Xie. A boosted decision tree approach using bayesian hyper-parameter optimization for credit scoring. *Expert Systems with Applications*, 78:225–241, 2017.